Kurseinheit 1

Statistische Datenanalyse

Inhalt der Kurseinheit

Studierhinweise zu Kurseinheit 1 **5**

1 Statistische Datenanalyse **9**
1.1 Beispiele von Datensätzen 10
1.2 Historisches zur Statistik 20

2 Grundbegriffe und graphische Darstellungen **23**
2.1 Datenerhebung 23
2.2 Datentypen 24
2.3 Reduktion und Darstellungen von Daten 29

Lösungen zu den Aufgaben aus dem Kapitel 2 **49**

3 Kenngrößen und Verteilungen **55**
3.1 Lagemaße und weitere Mittelwerte 55
3.2 Streumaße und TSCHEBYSCHEV-Ungleichung 68
3.3 Boxplots und Perzentilbänder 76
3.4 Indexzahlen 79

Lösungen zu den Aufgaben aus dem Kapitel 3 **83**

4 Regression und Korrelation **93**
4.1 Lineare Regression 93
4.2 Korrelationskoeffizient 103

Lösungen zu den Aufgaben aus dem Kapitel 4 **109**

Studierhinweise

An dieser Stelle wird eine Übersicht darüber gegeben, was Sie in der ersten Kurseinheit erwartet. Zuvor möchte ich ein paar Bemerkungen machen, wie man sich den vorliegenden Kurs erarbeiten kann. Es sind ein paar Überzeugungen des Autors, die nicht jeden Lerntyp unter Ihnen perfekt ansprechen können.

Sie haben bereits erste Erfahrungen im Umgang mit einem mathematischen Text. Daher fasse ich mich möglichst kurz. Bedenken Sie bitte, dass ein mathematischer Text nicht schnell gelesen werden kann. Ein gutes und wichtiges Hilfsmittel, die Lesegeschwindigkeit zu drosseln, ist Papier und Schreibzeug. Wenn Sie einen Beweis durcharbeiten (oder eine Definition oder die Aussage eines Satzes verstehen wollen), schreiben Sie Details oder Zwischenschritte auf. Stellen Sie sich bei jeder Definition und jedem beschriebenen Sachverhalt die Frage: Kenne ich ein Beispiel für diesen Sachverhalt? Und kenne ich ein Beispiel, wo die Voraussetzungen nicht erfüllt sind? Wenn Sie die Formulierung eines Satzes gelesen haben, sortieren Sie für sich genau, was die Voraussetzungen sind, was die Behauptung ist, und was genau zu tun ist, um einen Beweis zu führen.

Versuchen Sie über Mathematik zu sprechen. Wenn niemand zuhören mag, kann auch lautes Lesen eine gute Übung sein. Lösen Sie die im Text gestellten Übungsaufgaben und beschäftigen Sie sich ausführlich mit den Einsendeaufgaben. Versuchen Sie sich an den Übungsaufgaben dann, wenn Sie im Text auf sie treffen. Sie sollen Ihnen helfen, sich an einen neuen Begriff zu gewöhnen und sich zu kontrollieren, ob Sie damit umgehen können. An den Aufgaben können Sie messen, ob Ihnen der Umgang mit Mathematik bereits gelingt. Wenn es noch nicht gelingt, verzweifeln Sie nicht. Werten Sie das als ein Zeichen, dass Sie mit den Begriffen und Aussagen der Sätze noch nicht sicher genug umgehen können. Ohne den Versuch der selbständigen Erarbeitung der begleitenden Übungsaufgaben werden Sie Probleme bei der Bearbeitung der Einsendeaufgaben haben. Aber viel wichtiger: Sie sind ohne diese Übungen insgesamt nicht in der Lage, aktiv mit Mathematik umzugehen. Doch nur dies kann das Ziel eines Studiums sein. Niemand lernt Mathematik durch passives Aufnehmen von Lehrstoff. Damit steht die Mathematik

nicht alleine da. Das Erlernen zum Beispiel von Fremdsprachen oder das Spielen eines Instrumentes funktioniert auch nicht durch passives Aufnehmen von Lehrstoff.

Die erste Kurseinheit ist relativ unabhängig von den folgenden. Die Kurseinheiten danach bauen aufeinander auf. In Kurseinheit 7 benötigen Sie viele Detailkenntnisse der Kurseinheiten 2–6.

Notationen und die Struktur einer jeden Kurseinheit werden erläutert oder sind selbstredend. In diesem Kurs wird das Ende eines Beweises durch das Beweisabschlusszeichen □ angezeigt.

Kommen wir nun zu den Inhalten der ersten Kurseinheit.

Im *ersten Kapitel* geht es darum, Sie mit verschiedenartigen Datensätzen vertraut zu machen. Sie lernen typische Fragestellungen zu erhobenen Daten kennen sowie Anwendungsgebiete und ihre typischen statistischen Probleme. Darüber hinaus werden ein paar Fakten der Historie der Statistik gesammelt. Dies ist ein Einstieg in die statistische Datenanalyse.

Nach Durcharbeiten dieses Kapitels können Sie unterschiedliche Aspekte der Statistik unterscheiden und kennen unterschiedliche Datensätze.

Im *zweiten Kapitel* geht es um viele Grundbegriffe der statistischen Datenanalyse sowie um eine Vielzahl von graphischen Darstellungsformen von Datensätzen. Dieses Kapitel ist mathematisch nicht tief und gehört eher zur Allgemeinbildung.

In *Abschnitt* 2.1 geht es um unterschiedliche Formen der Erhebung und Erzeugung von Daten. Nach Durcharbeiten dieses Abschnitts kennen Sie Zufallsstichproben und mehrstufige Verfahren.

In *Abschnitt* 2.2 sammeln wir Grundbegriffe wie das *Merkmal* und die *Stichprobe* sowie klassische Notationsformen für *Merkmalsausprägungen*. Sie lernen unterschiedliche *Skalen* voneinander zu unterscheiden. Diskutiert werden ferner Transformationen, die das so genannte Skalenniveau erhalten. Nach Durcharbeiten dieses Abschnitts können Sie vor allem die Nominalskala, die Ordinalskala und drei metrische Skalen (Intervall-, Verhältnis- und Absolutskala) unterscheiden und zu allen Skalen Beispiele nennen.

In *Abschnitt* 2.3 lernen Sie erste Datenreduktionen kennen. Dazu gehören Häufigkeitsbestimmungen und das Ordnen von Stichproben (die Rangbestimmung). Es werden eine Vielzahl von graphischen Darstellungsformen aufgeführt. Betont werden dabei vor allem Vor- und Nachteile dieser Darstellungen sowie die Zuordnungen, welche Darstellungen für welche Skalenniveaus geeignet sind. Nach Durcharbeiten dieses Abschnitts können Sie Balkendiagramme, Säulendiagramme, Lini-

endiagramme, Häufigkeitspolynome, Histogramme und Stamm-Blatt-Diagramme unterscheiden und die wesentlichen Charakteristika beschreiben.

Nach Durcharbeiten dieses Kapitels sollten Sie entscheiden können, welche rechnerischen Datenreduktionen und graphischen Darstellungen von Datensätzen man bei welchen Datensätzen (Skalenniveaus) verwendet.

In *Kapitel drei* geht es um Kenngrößen und Verteilungen.

In *Abschnitt* 3.1 führen wir Lagemaße und Mittelwerte ein. Zu den Lagemaßen gehören der Modalwert, der Median, das arithmetische Mittel und die p-Quantile. Das geometrische und harmonische Mittel werden ausführlich diskutiert. Dies sind keine Lagemaße. Es wird herausgearbeitet, zu welchen Skalenniveaus welche Mittelwerte und Lagemaße bestimmt werden können. Abschließend werden die Kennzahlen miteinander verglichen, was zu dem Begriff der Schiefe sowie zum Beweis der so genannten AGM-Ungleichung führt. Nach Durcharbeiten dieses Abschnitts können Sie zuordnen, zu welchen Merkmalstypen man welche Lagemaße und Mittelwerte (grundsätzlich) bestimmen kann. Sie können insbesondere die unterschiedlichen Situationen, in denen das arithmetische, das geometrische und das harmonische Mittel verwendet werden, beschreiben und dies mit Hilfe von Beispielen verdeutlichen.

In *Abschnitt* 3.2 lernen Sie unterschiedliche Streumaße sowie die Tschebyschev-Ungleichung kennen. Zu den Streumaßen gehören die Spannweite, die mittlere absolute Abweichung, die empirische Varianz sowie Quantilsabstände. Nach Durcharbeiten dieses Abschnitts können Sie diese Streumaße voneinander unterscheiden. Insbesondere kennen Sie die unterschiedlichen minimierenden Eigenschaften des Medians und des arithmetischen Mittels in Bezug auf absolute und quadratische Abweichungen, sie können die $\frac{1}{n-1}$-Normierung bei der Definition der empirischen Varianz begründen und kennen die Aussage der Tschebyschev-Ungleichung.

Im *Abschnitt* 3.3 werden zwei weitere Darstellungsformen von Datensätzen studiert, die auf den Streumaßen des Abschnitts zuvor basieren. Es werden Boxplots und Perzentilbänder diskutiert. Nach Durcharbeiten dieses Abschnitts können Sie präzise diese beiden Darstellungsformen beschreiben und voneinander abgrenzen.

In *Abschnitt* 3.4 werden abschließend Indexzahlen diskutiert. Nach Durcharbeiten dieses Abschnitts sind Sie mit Verbraucherindizes, dem DAX und dem ifo-Index sowie dem Banzhaf-Index vertraut.

Nach Durcharbeiten des dritten Kapitels sollten Sie verschiedene Lage- und Streumaße unterscheiden können und ihre jeweiligen Verwendungen kennen. Darstellungsformen, die die Lage- und Streumaße verwenden, sollten Sie insbesondere von den Darstellungsformen aus Kapitel 2 abgrenzen können.

Im *vierten Kapitel* der ersten Kurseinheit werden Zusammenhänge zwischen zwei oder mehreren Merkmalen untersucht.

In *Abschnitt* 4.1 werden Ursache-Wirkungs-Beziehungen untersucht. Dabei wird die Methode der kleinsten Quadrate am Beispiel der linearen Regression vorgestellt. Nach Durcharbeiten dieses Abschnitts sind Sie in der Lage, die lineare Regression herzuleiten und durchzuführen, sowie ihre Aussagekraft und ihre Fehlinterpretationen zu benennen. Sie können die Regressionsgerade ohne Verwendung der Analysis von Funktionen mehrerer Veränderlicher herleiten.

In *Abschnitt* 4.2 wird eine Maßzahl für den linearen Gleichklang zweier Merkmale hergeleitet: Der Korrelationskoeffizient. Es werden Eigenschaften dieses Koeffizienten hergeleitet. Nach Durcharbeiten dieses Abschnitts kennen Sie zwei verschiedene Herleitungen für den Korrelationskoeffizienten und beherrschen die Interpretation dieser Kenngröße.

Diese Kurseinheit ist eine ausführliche Einführung in die moderne statistische Datenanalyse.

Kapitel 1

Statistische Datenanalyse

Eine *Statistik* ist eine Zusammenstellung von Daten, sehr häufig sind dies Zahlen. Eine Statistik enthält zum Beispiel Daten über Bevölkerungsgruppen, ökonomische Tätigkeiten, Krankheiten, Wetterlagen oder Umwelteinflüsse. Statistiken beschreiben häufig in einem weiteren Sinn den Zustand des Staates. Der Name geht zurück auf das italienische Wort *statista*, den Staatsmann, oder auf das lateinische Wort *status (rei publicae)*, den Zustand des Staates. In den empirischen Wissenschaften werden zu denkbaren Fragestellungen nach Möglichkeit Daten gesammelt. Dies geschieht durch *Beobachtungen* von Phänomen oder durch eigens geplante *Experimente*.

Wir wollen in dieser Kurseinheit Konzepte entwickeln und darstellen, die für den Umgang mit Daten im Alltag, im Studium und in der Wissenschaft sehr wichtig sind. Man spricht von der *beschreibenden*, der *deskriptiven Statistik*. Daten, die in einer so genannten Stichprobe gesammelt werden, sollen in möglichst kompakter und aussagekräftiger Form dargestellt werden. Dies geschieht durch *Kennzahlen* und durch *bildliche Darstellungen*. Die Kurseinheit ist mathematisch gesehen sehr elementar und gehört zur Allgemeinbildung. Sie bereitet die mathematische Statistik vor, in der man untersucht, welche Schlussfolgerungen aus zufälligen Beobachtungen gezogen werden können. Man spricht von der *beurteilenden Statistik*. Hierzu benötigt man die Wahrscheinlichkeitstheorie. Daher wird die mathematische (beurteilende) Statistik erst in der letzten Kurseinheit das Thema sein. Die Einteilung in beschreibende und beurteilende Statistik ist sprachlich gesehen etwas irreführend, wird doch der Eindruck erweckt, als sei die beschreibende Statistik frei von Beurteilungen. Wir alle wissen, dass Darstellungen von Daten häufig das vorrangige Ziel verfolgen, die Beurteilung der Beobachter (potenzielle Kunden oder Wähler) zu beeinflussen. Auch wenn das Kapitel mathematisch nicht sehr tief ist, wird man erkennen, dass die Auswahl eines sachangemessenen Konzepts zur Ana-

lyse eines Datensatzes schwierig sein kann. Welche Probleme treten bereits bei der Erhebung von Daten auf? Welche Kennzahlen sind geeignet, was ist eine gute Darstellung? Es wird keine der Fragen allgemein verbindlich zu klären sein.

1.1 Beispiele von Datensätzen

Wir sammeln zunächst einige Beispiele von Daten, die wir im weiteren Verlauf untersuchen wollen. In Kapitel 2 werden die verschiedenen Arten von Daten, Datentypen, genauer beschrieben.

1.1.1 Beispiele: von Datensätzen

(a) Gregor Johann Mendel (1822–1884) züchtete Nachkommen von zwei Erbsensorten, die sich in der Gestalt der Samen unterschieden: Jeder Samen kann eindeutig als rund oder kantig erkannt werden. Runde Samen vererben sich dominant. Kreuzt man diese (hybriden) Pflanzen, so sollten sie runde und kantige Samen im Verhältnis 3:1 zeigen. Im Jahre 1865 erhielt Mendel 5474 runde und 1850 kantige Samen, also ein Verhältnis von 2.96:1. Tabelle 1.1 listet die Ergebnisse für die 10 Pflanzen von Mendels ersten Versuchs.

Pflanze	1	2	3	4	5	6	7	8	9	10
rund	45	27	24	19	32	26	88	22	28	25
kantig	12	8	7	10	11	6	24	10	6	7
Verhältnis : 1	3.8	3.4	3.4	1.9	2.9	4.3	3.7	2.2	4.7	3.6

Tab. 1.1: Die Ergebnisse für die 10 Pflanzen des ersten Versuchs von Mendel.

(b) Bei der Untersuchung von Teichmuscheln im Zürichsee wurde ein Gitterraster über den Seeboden gelegt und für jedes Quadrat gezählt, wieviele Muscheln darin zu finden waren (siehe Abb. 1.1).

Es zeigen sich gewisse Anhäufungen. Sind sie „rein zufällig“? Ergibt es Sinn, nach den Ursachen dieser Ansammlungen zu fragen?

(c) Eine in heutiger Zeit typische Datenerhebung erfolgt über Fragebögen. Hier ist ein Ausschnitt eines *Fragebogen zum Mathematikunterricht an der Schule*:

1. Alter in Jahren:
2. Geschlecht:
3. Kurs / Klasse:

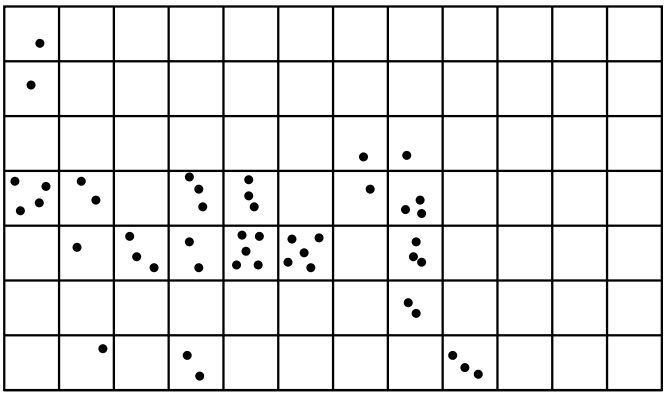

Abb. 1.1: Dispersionsmuster von Teichmuscheln im Zürichsee

4. Letzte Zeugnisnote in Mathematik (1 für „sehr gut“ bis 6 für „ungenügend“):
5. Studienwunsch:
6. Berufswunsch:
7. Mit welcher Note (1 bis 6) würden Sie Ihre derzeitigen Fähigkeiten in Mathematik selbst bewerten:
8. Mit welcher Note (1 bis 6) würden Sie die Qualität Ihres derzeitigen Mathematikunterrichtes bewerten:
9. Wie viele Stunden etwa haben Sie in der letzten Woche außerhalb des Unterrichts für Mathematik gearbeitet:
10. Bekommen oder bekamen Sie in Mathematik Nachhilfeunterricht? Ja Nein

Bewerten Sie auf einer Skala von 1 (ganz unwichtig) bis 10 (ganz wichtig), wie wichtig Ihnen die folgenden Dinge im Mathematikunterricht wären:

1. ein Lehrer, der gut erklären kann
2. herausfordernde Problemstellungen, bei denen man lange um eine Lösung ringen muss
3. Gruppenarbeit
4. viele Übungsaufgaben, an denen man eine vorgeübte Musterlösung einüben kann
5. ein Schulbuch, in dem man alles nachlesen kann

6. außermathematische Beispiele, an denen man vor allem erleben kann, wofür Mathematik nützlich sein könnte

7. intermathematische Beispiele, an denen man vor allem die gedankliche Logik der Mathematik nachvollziehen kann

(d) Eine so genannte *Urliste*: Untersuchung der vier Merkmale Geschlecht (G), Körpergröße in cm (Gr), Körpergewicht in kg (Ge) und Haarfarbe (H) bei den 100 Teilnehmern einer Stochastik-Vorlesung, siehe Tabelle 1.2.

(e) Einer Datensammlung aus der Phase der *Industrialisierung Deutschlands* im vorletzten Jahrhundert entnehmen wir einen Datensatz über die Mortalität, ausgehend von in der Regel eindeutig diagnostizierbaren Infektionskrankheiten bakteriellen oder viralen Ursprungs, siehe Tabelle 1.3. Diese Tabelle wirkt aus heutiger Sicht überraschend, da es Impfstoffe gibt.

(f) Einige Studenten der Universität Bonn wurden nach ihrem zweiten Studienfach gefragt und wie viele Stunden pro Woche sie dafür aufbringen. Die entsprechende Urliste hat die folgende Gestalt:

$(B, 12), (B, 18), (S, 8), (A, 10), (P, 26), (S, 15), (P, 30), (B, 4), (S, 28), (P, 6), (B, 19), (S, 18), (S, 16), (B, 8), (A, 30), (P, 22), (B, 27), (P, 11), (S, 29), (A, 5), (B, 12), (B, 23), (P, 6), (S, 34), (P, 15), (P, 30), (S, 17), (B, 9), (S, 32), (B, 10), (B, 25), (P, 13), (B, 22), (S, 19).$

Hierbei steht B für Biologie, S für Sport, P für Physik und A für alle anderen Fächer.

(g) Wir betrachten die Stimmverteilung gewählter Parteien bei der Bundestagswahl 2005. In der Stichprobe vom Umfang n aller gültigen Zweitstimmen ergibt sich die in Tabelle 1.4 dargestellte Häufigkeitsverteilung.

(h) Bei der Schulleistungsstudie PISA 2000 (**P**rogramme for **I**nternational **S**tudent **A**ssessment) lagen die getesteten deutschen Schülerinnen und Schüler mit einem durchschnittlichen Testwert von 490 Punkten in Mathematik *signifikant* unter dem OECD-Durchschnitt (**O**rganisation for **E**conomic **C**o-operation and **D**evelopment). Weitere häufig zitierte Aussagen zu dieser Studie sind, dass der Abstand zwischen guten und schlechten Schülern in Deutschland besonders groß ist, sowie, dass der Zusammenhang zwischen Mathematik- und Naturwissenschaftsleistungen sehr hoch ist. Tabelle 1.5 macht Angaben zur Mathematikleistungen bei PISA 2000.

Nr.	G	Gr	Ge	H	Nr.	G	Gr	Ge	H	Nr.	G	Gr	Ge	H
1	w	179	63	sch	35	m	170	58	bra	68	m	173	65	blo
2	m	180	71	rot	36	w	180	75	blo	69	m	184	77	bra
3	w	196	74	blo	37	w	179	66	bra	70	m	196	85	rot
4	m	178	73	blo	38	w	168	60	bra	71	m	186	75	bra
5	m	182	75	bra	39	m	163	54	gra	72	m	184	75	bra
6	w	172	58	blo	40	m	188	81	sch	73	m	187	75	bra
7	w	178	68	bra	41	w	183	70	sch	74	m	179	72	blo
8	m	205	88	rot	42	w	166	70	blo	75	w	174	68	bra
9	m	183	75	blo	43	m	185	77	bra	76	w	160	50	bra
10	m	176	67	sch	44	w	171	58	bra	77	m	180	68	bra
11	m	179	75	rot	45	w	176	64	blo	78	m	180	65	blo
12	w	183	70	blo	46	m	178	70	bra	79	m	172	66	bra
13	w	157	45	rot	47	w	163	55	sch	80	w	185	72	bra
14	w	180	70	bra	48	w	172	62	rot	81	w	187	72	blo
15	m	188	76	blo	49	m	177	65	bra	82	w	150	43	sch
16	w	174	63	bra	50	w	173	65	blo	83	m	187	80	blo
17	m	202	90	sch	51	m	199	91	gra	84	m	185	100	bra
18	m	189	81	blo	52	m	174	69	rot	85	m	194	75	bra
19	w	170	60	gra	53	w	170	60	blo	86	w	163	51	blo
20	m	172	56	blo	54	w	177	60	rot	87	m	181	85	blo
21	w	165	65	bra	55	m	185	75	sch	88	w	186	70	blo
22	m	175	69	sch	56	m	159	50	sch	89	m	197	84	bra
23	m	177	65	rot	57	m	190	78	bra	90	w	152	41	bra
24	w	171	60	blo	58	m	174	65	blo	91	w	192	75	bra
25	m	187	90	bra	59	m	186	81	bra	92	w	177	67	blo
26	m	169	65	bra	60	w	178	65	bra	93	m	167	60	bra
27	w	183	70	bra	61	w	176	65	blo	94	w	170	62	bra
28	m	161	65	bra	62	m	192	83	blo	95	m	177	73	gra
29	w	174	63	gra	63	m	180	72	blo	96	m	182	75	blo
30	m	186	85	bra	64	m	181	75	bra	97	m	182	70	bra
31	m	165	55	bra	65	m	188	85	blo	98	m	183	65	bra
32	m	181	75	bra	66	m	171	60	bra	99	m	185	80	rot
33	w	175	67	blo	67	w	161	47	bra	100	m	189	81	bra
34	m	183	70	bra										

Tab. 1.2: Urliste

Jahr	Pocken	Scharlach	Masern & Röteln	Diphtherie & Krupp	Keuch-husten	Typhus	Ruhr	Tuber-kulose
1878	0.07	8.06	3.40	16.59	5.32	6.09	1.42	32.51
1879	0.13	4.43	2.10	14.54	4.88	4.98	1.19	32.46
1880	0.26	4.45	3.81	13.28	5.82	5.37	2.19	31.12
1881	0.36	6.29	3.09	14.59	5.07	5.44	1.48	30.89
1882	0.36	5.96	3.58	18.04	5.66	4.88	1.46	30.88
1883	1.91	4.71	3.71	16.40	5.26	4.53	1.48	31.75
1884	0.15	5.86	4.75	17.57	5.17	4.43	1.34	31.02
1885	0.14	6.20	5.60	18.81	4.76	3.40	0.61	30.76
1886	0.05	4.34	6.82	19.41	5.35	3.14	0.59	31.14
1887	0.05	2.90	4.00	17.64	5.07	2.64	0.35	29.33
1888	0.03	2.30	2.84	13.25	4.98	2.31	0.32	28.92
1889	0.05	2.63	3.18	13.83	4.55	2.40	0.36	27.97
1890	0.01	2.90	4.06	14.54	5.78	2.04	0.27	28.11
1891	0.01	1.64	2.04	12.05	4.48	2.00	0.27	26.72
1892	0.03	2.06	3.48	13.20	4.57	2.04	0.33	25.01
1893	0.04	3.23	2.84	17.97	4.95	1.71	0.37	24.96
1894	0.02	2.17	3.11	14.73	4.72	1.51	0.35	23.89
1895	0.01	2.23	1.95	9.06	3.89	1.48	0.62	23.26
1896	0.00	2.16	3.17	7.60	4.65	1.35	0.24	22.07
1897	0.00	1.70	2.11	6.22	4.69	1.33	0.29	21.81
1898	0.00	2.36	2.77	5.56	3.90	1.14	0.26	20.08
1899	0.01	3.67	2.95	5.63	4.04	1.33	0.37	20.71
1900	0.01	3.60	2.04	4.83	3.98	1.38	0.21	21.13

Quelle: Königliches Statistisches Bureau in Berlin(Hg.): Die Sterblichkeit nach Todesursachen und Altersklassen der Gestorbenen

Tab. 1.3: Tod durch Infektionskrankheiten in Preußen

Partei	Anzahl	%
SPD	16194665	34.2
CDU	13136740	27.8
CSU	3494309	7.4
GRÜNE	3838326	8.1
FDP	4648144	9.8
Die Linke	4118194	8.7
Offensive D	3338	0.0
REP	266101	0.6
NPD	748568	1.6
Die Tierschutzpartei	110603	0.2
GRAUE	198601	0.4
PBC	108605	0.2
DIE FRAUEN	27497	0.1
FAMILIE	191842	0.4
BÜSo	35649	0.1
BP	35543	0.1
ZENTRUM	4010	0.0
Deutschland	9643	0.0
AGFG	21350	0.0
APPD	4233	0.0
50Plus	10536	0.0
MLPD	45238	0.1
Die PARTEI	10379	0.0
PSG	15605	0.0
Pro DM	10269	0.0

Tab. 1.4: Stimmverteilung bei der Bundestagswahl 2005

Mathematik

Länder	Mittelwerte (Standardfehler in Klammern)	Spann-breite
Japan	557 (5.5)	286
Korea	547 (2.8)	276
Neuseeland	537 (3.1)	325
Finnland	536 (2.2)	264
Australien	533 (3.5)	299
Kanada	533 (1.4)	278
Schweiz	529 (4.4)	329
Vereinigtes Königreich	529 (2.5)	302
Belgien	520 (3.9)	350
Frankreich	517 (2.7)	292
Österreich	515 (2.5)	306
Dänemark	514 (2.4)	283
Island	514 (2.3)	277
Liechtenstein	514 (7.0)	322
Schweden	510 (2.5)	309
Irland	503 (2.7)	273
OECD-Durchschnitt	500 (0.7)	329
Norwegen	499 (2.8)	303
Tschechische Republik	498 (2.8)	320
Vereinigte Staaten	493 (7.6)	325
Deutschland	490 (2.5)	338
Ungarn	488 (4.0)	321
Russische Föderation	478 (5.5)	343

Quelle: Deutsches PISA-Konsortium (2003), S. 52.

Tab. 1.5: Mathematikleistungen bei PISA 2000

Punkte	Absolute Häufigkeit	Relative Häufigkeit
0	1	0.9%
1	4	3.4%
2	6	5.1%
3	5	4.3%
4	9	7.7%
5	9	7.7%
6	12	10.3%
7	10	8.5%
8	14	12.0%
9	12	10.3%
10	9	7.7%
11	8	6.8%
12	5	4.3%
13	6	5.1%
14	4	3.4%
15	3	2.6%

Tab. 1.6: Abiturklausur-Punktzahl bei 117 Schülerinnen und Schülern

(i) Das Zentral-Abitur ist auf dem Vormarsch. Es bietet Schulen die Möglichkeit, ihre Unterrichtsqualität zu messen. Man bestimme etwa die Anzahl der Schülerinnen und Schüler, die nicht durchfallen. Bei vielen guten Noten geht die Schule vermutlich davon aus, dass im Vergleich gute Arbeit geleistet worden ist. Im Abitur werden die Leistungen mit 0 bis 15 Punkten bewertet. Wieviel Schülerinnen und Schüler haben höchstens 4 Punkte (Defizit) oder mindestens 10 Punkte (gut oder sehr gut)? Bei einem Abiturjahrgang am Carl-von-Ossietzky-Gymnasium, mit 117 Schülerinnen und Schülern, stellt sich die Verteilung der Schülerinnen und Schüler auf die 16 möglichen Merkmale 0 bis 15 Punkte für die erste schriftliche Abiturprüfung wie in Tabelle 1.6 dar.

1.1.2 Aufgabe: Machen Sie sich rückblickend zu den Datensätzen aus Beispiele 1.1.1 Gedanken, in wieweit sich die Daten in unterschiedliche Datentypen einteilen lassen und wie man die Daten repräsentieren könnte. Gibt es Ihnen bekannte Kennzahlen, die Sie bei den einzelnen Datensätzen zur Beschreibung dieser bestimmen würden? (Diese Aufgabe hat den Zweck, nochmals die Beispielsammlung unter gewissen Sortier-Aspekten zu studieren. Die Fragen sind aber so unverbindlich formuliert, dass diese Aufgabe nicht mustergelöst wird.)

Die Beispiele zeigen, dass Daten *zufälligen Schwankungen* unterliegen. Dies wird besonders deutlich beim Verteilungsmuster von Teichmuscheln. Bei anderen Datensätzen schlummert die Zufälligkeit in der Form der Datenerhebung. Die Daten beschreiben jeweils Einheiten (Personen, Messungen, Noten,...), die als zufällige Stichprobe aus einer großen *Grundgesamtheit* von Einheiten aufgefasst werden können. Jede Einheit hat zwar eine Individualität, aber die Ergebnisse von vielen Einheiten weisen in der Regel Gesetzmäßigkeiten auf. Man spricht davon, dass den zufälligen Unregelmäßigkeiten der Einzelerscheinungen die statistische Gesetzmäßigkeit der Massenerscheinung gegenüber steht. Zur Beschreibung dieser Gesetzmäßigkeiten dienen die Modelle der Wahrscheinlichkeitsrechnung, siehe Kurseinheit 2 und folgende.

Neben der Datenbeschreibung sind die Fragen, mit denen man sich mit Hilfe von Daten beschäftigt, etwa von einem der folgenden Typen:

Fragen zu erhobenen Daten:

- Datenerhebungen (Messungen) enthalten in der Regel Messfehler. Gefragt ist eine *Schätzung* des „wahren Wertes“ mit einer Genauigkeitsangabe.
- Hat eine Behandlung in der Medizin, zum Beispiel die Einnahme eines Medikamentes, einen Effekt? Treten Unterschiede durch die Behandlung rein zufällig auf oder sind sie *signifikant*? Regeln zur Beantwortung heißen *statistische Tests.*
- Besteht ein *Zusammenhang* zwischen den Größen X und Y? Lässt sich Y auf Grund von X vorhersagen? Wenn ja, wie und wie genau?
- Lassen sich in einem Datensatz *unerwartete Strukturen* finden?

Mit Fragen vom Typ der ersten drei Unterpunkte befasst sich die *schließende* oder *analytische Statistik*. Die vierte Frage gehört zum Thema der *erforschenden/explorativen Statistik* oder *explorativen Datenanalyse*, die auf der *beschreibenden Statistik* aufbaut. Wie bereits erwähnt, befassen wir uns mit der analytischen Statistik in der 7. Kurseinheit. In Kapitel 4 deuten wir ein paar wenige Aspekte der explorativen Datenanalyse an.

Es seien hier typische Anwendungsgebiete der Statistik genannt:

Anwendungsgebiete, typische statistische Probleme:

Naturwissenschaften: Wie hängt eine chemische Reaktion von den Ausgangsbedingungen ab? Schätzung von Reserven an Bodenschätzen, Wettervorhersage.

Medizin und Pharmazie: Hat eine Behandlung die erwünschte Wirkung? Lassen sich Krankheiten auf Grund von geeigneten Messgrößen automatisch diagnostizieren? Ausbreitung von Epidemien.

Land- und Forstwirtschaft: Welche Anbaubedingungen sind optimal? Wieviel Holz ist vorhanden?

Produktion, Technik: Läuft eine Produktion normal oder zeigt sie Störungen? Stichworte: Qualitätskontrolle, Qualitätssicherung, Zuverlässigkeit, Risikoanalyse.

Ökonomie, Sozialwissenschaften: Markt- und Meinungsforschung, Untersuchung soziologischer Zusammenhänge mittels Umfragen.

Psychologie, Verhaltensforschung: Vergleich von Lernprozessen, Untersuchung von Wahrnehmungen, Verhalten von Tieren in Abhängigkeit von ihrer Umwelt.

Es erscheint nicht überraschend, dass der Anwendungsbezug der Statistik enorm vielseitig ist. Neben dem Ziel, eine Grundausbildung für Lehrerinnen und Lehrer zu erzielen, bleibt hervorzuheben, dass Forschungsarbeiten in den meisten Disziplinen statistische Auswertungen enthalten. Im späteren Beruf müssen alle wissenschaftlich Ausgebildeten statistische Auswertungen mindestens verstehen können.

In bereits 1984 formulierten Richtlinien und Lehrplänen für die Sekundarstufe I/ Gymnasium des Landes NRW heißt es:

> „Bei vielen wirtschaftlichen, gesellschaftlichen und politischen Problemen wird heute in zunehmendem Maße mit statistischem Datenmaterial argumentiert, in Zeitungen und Zeitschriften sowie im Fernsehen werden in mannigfacher Art Tabellen, graphische Darstellungen und statistische Maßzahlen verwendet. Deshalb ist es wichtig, dass die Schüler dazu befähigt werden, Aussagen der beschreibenden Statistik richtig zu bewerten und ihnen kritisch zu begegnen. Sie sollen auch Möglichkeiten kennenlernen, wir man mit richtigem Datenmaterial durch geschickte Aufbereitung den Leser täuschen kann.“

Richtlinien geben neuerdings der beschreibenden Statistik mehr Gewicht als der Wahrscheinlichkeitsrechnung. Ein Blick ins letzte Jahrhundert zeigt auch, wie im Schulunterricht die Statistik ideologisch und politisch missbraucht/eingesetzt wurde. Aus einem Statistikbuch der ehemaligen DDR (*Statistik*, Berlin 1980, Donda, Herre, Kuhn, Struck):

> „Gründliche Kenntnisse des Marxismus-Leninismus ist die Grundvoraussetzung für alle *statistischen Arbeiten*, um durch sie reale, der

> Wirklichkeit entsprechende Aussagen über die gesellschaftlichen Erscheinungen zu erhalten und dabei nicht nur an der Oberfläche der Erscheinungen zu bleiben, sondern zu ihrem Wesen, den bestimmenden Zusammenhängen und Faktoren vorzustoßen."

Oder an anderer Stelle heißt es weiter:

> „Die kapitalistische Gesellschaftsordnung prägt den *Klassencharakter der Statistik* im kapitalistischen Staat. Ihre konkrete Aufgabe bestand und besteht darin, die für den kapitalistischen Staat, insbesondere für die großen Monopole und ihre Verbände notwendigen Informationen und Kenntnisse über die gesellschaftlichen Prozesse und Erscheinungen zu erarbeiten und gleichzeitig dabei die Klassenverhältnisse, das Wesen des kapitalistischen Staates, insbesondere die Ausbeutung *zu verschleiern.*
>
> Demgegenüber besteht der Klassencharakter im sozialistischen Staat in der *bewußten Parteilichkeit der Statistik*, vor allem in der exakten und wahrhaften Darstellung und der Analyse aller für die planmäßige Leitung wesentlichen gesellschaftlichen Erscheinungen und Prozesse."

Eine *kritische Analyse* des Umgangs mit Statistik im heutigen Deutschland sollte im Beispielmaterial der folgenden Kapitel nicht fehlen.

1.2 Historisches zur Statistik

Bevor wir in die Beschreibung von Daten einsteigen, sei noch ein kurzer Abriss der historischen Entwicklung der deskriptiven Statistik vorausgeschickt. Das Studium diesen Ausflugs kann beim ersten Lesen zunächst ausgelassen werden.

Für die beschreibende Statistik gibt man in der Regel drei Quellen an: die *Amtliche Statistik*, die *Politische Arithmetik* und die *Universitätsstatistik.*

Amtliche Statistik: Man möchte Informationen darüber gewinnen, wie die organisierte Gesellschaft am besten verwaltet werden kann. In Ägypten, China, Indien, Griechenland und Rom interessierte man sich schon vor Jahrtausenden für Größen wie Anzahl der Bewohner, Landbesitz, Bodenschätze, Viehbestand. Etwa 3000 v. Chr. ließen Pharaonen in Ägypten *Volkszählungen,* Landvermessungen und Viehbestandszählungen durchführen. Dabei hatte man bereits die Steuer im Blick, aber auch die Erfassung für den Militärdienst.

In der Bibel werden Volkszählungen erwähnt, etwa im Buch Exodus, Kapitel 30, Vers 11 und folgende. Das Buch *Numeri (Zahlen)* verdankt seinen Namen einer

Volkszählung. Es befasst sich mit der Zählung der wehrpflichtigen Männer. Die bekannteste Stelle ist bei Lukas, Kapitel 2, Verse 1 ff (Weihnachtsevangelium). Dort geht es hauptsächlich um eine Zählung für steuerliche Zwecke. Der römische *Census*, der auf Servius Tullius (um 550 v. Chr.) zurückgeht, war eine alle 5 Jahre wiederholte Erhebung der Bevölkerung. Seit 1957 findet in Deutschland jährlich der so genannte Mikrozensus statt, bei dem ca. 1 % der Haushalte erfaßt werden. Heute kennen wir die statistischen Jahrbücher, die vom Statistischen Bundesamt herausgegeben werden. Der Hintergrund dieser Erhebungen ist in seiner praktischen Bedeutung für Regierungen und Verwaltungen zu sehen.

Politische Arithmetik: Im 17. und 18. Jahrhundert verglich man Geburtenhäufigkeiten und Sterbezahlen beim Studium der Bevölkerungsentwicklung. Man erkannte, dass nicht Einzelerscheinungen, sondern zu homogenen Klassen zusammengefasste Massenerscheinungen wichtig waren. John Graunt (1620–1674) und Sir William Petty (1623–1687) gelten als die Begründer der politischen Arithmetik. Durch das 1662 erschienene Werk *Natural and political observations upon the bills of mortality* gilt Graunt als Begründer der *Biometrie* und der Bevölkerungsstatistik. Ein weiterer Vertreter der politischen Arithmetik war der Astronom und Mathematiker Edmond Halley (1652–1742) (nach ihm ist der von ihm vorhergesagte Halley-Komet benannt). Er erstellte 1693 Sterbetafeln der Stadt Breslau und gilt als Pionier der *Sozialstatistik*. In Deutschland war der Pfarrer Johann Peter Süssmilch (1707–1767) ein prominenter Vertreter der Bevölkerungsstatistik.

Universitätsstatistik: Dies ist die Bezeichnung für die an Universitäten vertretene wissenschaftliche Disziplin. Im 17. Jahrhundert entstand an den Universitäten ein Lehrangebot. Hermann Conring (1606–1681) begründete die wissenschaftliche Staatskunde als *Wissenschaft und Lehre von den Staatsmerkwürdigkeiten*. Seine Vorlesungen befassten sich mit Staatenkunde unter den Gesichtspunkten Bevölkerung, Staatsform, Verwaltung und Finanzen. Gottfried Achenwall (1719–1772), Professor in Marburg und später in Göttingen, führte den Namen der Statistik für diese neue Disziplin ein. Achenwall kann aber nicht als Begründer der Statistik angesehen werden. Von deutschen Universitäten aus verbreitete sich die Statistik auf andere Länder Europas wie Ungarn und England. Mit Jakob Bernoulli (1654–1705) wurde mit Entstehen der Wahrscheinlichkeitsrechnung der Einfluss wahrscheinlichkeitstheoretischer Überlegungen auf die Statistik bemerkbar! In seiner berühmten Schrift *Ars conjectandi*, die erst acht Jahre nach seinem Tod veröffentlicht wurde, liefert das erstmals formulierte und bewiesene *schwache Gesetz der großen Zahlen* den Zusammenhang zwischen der mathematischen und der statistischen Wahrscheinlichkeit (der relativen Häufigkeit im heute üblichen Sprachgebrauch). Lambert A.J. Quetelet (1796–1874) glaubte, dass

soziale und gesellschaftliche Erscheinungen auf Gesetzmäßigkeiten verweisen, die man durch statistische Erhebungen entdecken und erforschen könne. Er führte 1853 die vermutlich erste wissenschaftlich fundierte Volkszählung in Belgien durch und organisierte den ersten internationalen Statistikkongress in Brüssel. Wenig später, im Jahre 1885, erfolgte die Gründung des Internationalen Statistischen Instituts (ISI). Sir Francis Galton (1822–1911) entwickelte die Korrelationsrechnung zur Auswertung seiner Daten zur Vererbungslehre (er ist ein Vetter von Charles Darwin (1809–1882)). Sein Schüler Karl Pearson (1857–1936) war Mitbegründer der Zeitschrift *Biometrika*, einer noch heute sehr angesehenen wissenschaftlichen Zeitschrift.

Im 20. Jahrhundert entwickelten sich die Methoden der Wahrscheinlichkeitstheorie rasant, und damit auch viele neue Verfahren in der Statistik. Es beginnt das, was man heute die *mathematische Statistik* nennt, also die analytische oder die beurteilende Statistik, die ja Gegenstand der 7. Kurseinheit ist. Ein geschichtlicher Überblick über manche Entwicklungen der mathematischen Statistik befindet sich im Anhang, in dem man auch Grundzüge der Geschichte der Wahrscheinlichkeitstheorie finden kann.

Kapitel 2

Grundbegriffe und graphische Darstellungen

2.1 Datenerhebung

Daten werden erhoben, wenn einer (Forschungs-) Frage nachgegangen werden soll. Es ist nicht leicht und zugleich sehr wichtig genau zu überlegen, welche Daten zur Beantwortung einer Frage benötigt werden und wie sie beschafft werden können.

Man unterscheidet die *Erhebung* bereits vorliegender Daten von der *Erzeugung* (Befragung, Messung). Bei der Erzeugung von Daten wird in der Regel von einem *Experiment* gesprochen (etwa klinische Studien). Bei Erhebungen unterscheidet man die *Vollerhebung* (etwa eine Volkszählung; oder man erhebt von allen(!) Kindern einer Klasse die Augenfarbe) von der *Stichprobenerhebung.* Vollerhebungen sind in der Regel aufwendig, so dass sehr häufig Stichprobenerhebungen verwendet werden. Zur so genannten *Stichprobentheorie* gehört die Klärung des geeigneten Stichprobenumfangs sowie die Art der Erhebung. Man unterscheidet zwischen den folgenden möglichen *Stichproben* :

- *Einfache Zufallsstichprobe:* Jede der $\binom{N}{n} := \frac{N!}{n!(N-n)!}$ möglichen Stichproben der Größe n aus einer Grundgesamtheit mit N Elementen hat die gleiche Wahrscheinlichkeit. Die Grundgesamtheit ist die Gesamtmenge aller in Frage kommenden Untersuchungseinheiten. Wir setzen an dieser Stelle voraus, dass bekannt ist, dass der Binomialkoeffizient $\binom{N}{n}$ alle möglichen Stichproben zählt. In der zweiten Kurseinheit werden wir uns mit dieser und anderen kombinatorischen Fragen beschäftigen.

- *geschichtete Stichprobenverfahren:* Hier werden die N Elemente in Teilge-

samtheiten (Schichten) mit $N_1, \ldots, N_L$ Elementen aufgeteilt. Die Teilgesamtheiten schließen sich aus und ergänzen sich genau zur Grundgesamtheit. Nun zieht man aus den Teilgesamtheiten mit irgendeinem Verfahren Stichproben. Zieht man jeweils eine einfache Stichprobe, spricht man von *geschichteten Zufallsstichproben.*

- *mehrstufige Verfahren:* Zum Beispiel werden in der ersten Stufe einige Städte im Ruhrgebiet ausgesucht, aus diesen dann einige Bezirke, auf der dritten Stufe dann aus den Stadtbezirken Häuser, auf der vierten Stufe werden dort lebende Personen ausgewählt und befragt.

Die Datenerhebung, die wir nicht weiter betrachten werden, ist natürlich schon eine vielfach unterschätzte Fehlerquelle. Messinstrumente können falsch justiert sein. Die Telefonumfrage läßt den Glücklichen ohne Telefon unberücksichtigt. Interessant sind auch Beispiele der folgenden Bauart: Ein Fragebogen untersucht das Sexualverhalten heterosexueller Menschen. Die Frage nach der Anzahl verschiedener Sexualpartner im Leben ergab in einer Studie die folgende überraschende Antwort. Frauen haben durchschnittlich sieben, Männer zehn verschiedene Sexualpartner. Da die Bevölkerung in der befragten Region beinahe je zur Hälfte aus Männern und Frauen besteht, haben wohl etliche Befragte nicht die Wahrheit gesagt.

Ab nun beginnen wir immer in dem Moment, in dem wir einen Datensatz zur Verfügung haben.

2.2 Datentypen

Wir führen zunächst einige wichtige Grundbegriffe ein.

Die *statistische Einheit* ist das Objekt, an dem die interessierende Größe erfasst wird. Beispiele sind Untersuchungen von Trinkwasser oder Erhebungen an einer Universität in NRW.
Das *Merkmal* ist die interessierende Größe. Dies wären zum Beispiel der Sauerstoffanteil im Trinkwasser oder die Studierendenzahlen einer Universität in NRW.
Die *Merkmalsausprägung* ist ein konkreter Wert des Merkmals für eine bestimmte statistische Einheit. Ein Beispiel ist 7.6 mg/l im Wasserwerk Bottrop oder 21.000 Studierende an der Universität Bielefeld.
Die *Grundgesamtheit* ist die Gesamtmenge aller für die Fragestellung relevanten statistischen Einheiten. Die *Stichprobe* ist die untersuchte Teilmenge der Grundgesamtheit. Den Begriff der Stichprobe haben wir zur Beschreibung verschiedener Stichprobenerhebungen bereits kennengelernt.

Die Grundgesamtheit bezeichnen wir häufig mit Ω, eine statistische Einheit mit ω. Eine Funktion, die ω die Merkmalsausprägung $X(\omega)$ zuordnet, nennen wir häufig $X : \Omega \to S, \omega \mapsto X(\omega)$, wobei S die Menge aller möglichen Merkmalsausprägungen bezeichnet. Beim Sauerstoffgehalt ist $S = \mathbb{R}_+$ (die Menge der nicht-negativen reellen Zahlen), bei der Studierendenzahl $S = \mathbb{N}_0$ (die Menge der natürlichen Zahlen inklusive Null, d.h., $\mathbb{N}_0 = \mathbb{N} \cup \{0\} = \{0, 1, 2, \ldots\}$). Natürlich können auch mehrere Merkmale gleichzeitig erhoben werden. Weiter ist S nicht immer nur ein Zahlenbereich.

2.2.1 Beispiel: Wir untersuchen einen Zusammenhang zwischen dem Rauchverhalten, dem Alter sowie der 100 Meter-Laufzeit in der Bevölkerung Hagens. Dann ist Ω die Menge der Einwohner Hagens und

$$S = \{R, N\} \times \mathbb{N}_0 \times \mathbb{R}_+,$$

wobei R und N für Raucher bzw. Nichtraucher stehen.

2.2.2 Aufgabe: Zu den folgenden Fragen wurden Daten erhoben. Geben Sie jeweils Ω, S und ein $X(\omega)$ an.

(a) Wieviele Abschlüsse im Diplom-Studiengang Mathematik gab es 1990 an den Universitäten in Deutschland?

(b) Gibt es in der Schweiz einen Zusammenhang zwischen dem Jahreseinkommen und dem Wahlverhalten bei der Wahl zum Ständerat?

(c) Es soll ermittelt werden, wieviele Straftaten pro Jahr seit 1980 in der Stadt Hagen verübt wurden.

Bei den Merkmalen sind wir bereits unterschiedlichen *Merkmalstypen* begegnet. Das Merkmal Geschlecht tritt in den Ausprägungen weiblich oder männlich auf; bei Mendels Untersuchung wird zwischen runden und kantigen Samen unterschieden; bei der Haarfarbe der Studierenden zwischen schwarz, rot, blond und braun. Die Abiturleistungen werden mittels der Zahlen zwischen 0 und 15 beschrieben. Die Anzahl der Zweitstimmen für eine Partei bei der Bundestagswahl kann jede natürliche Zahl oder Null sein. Beim Merkmal Körpergröße sind theoretisch alle positiven reellen Zahlen möglich.

Wir beobachten, dass beim Geschlecht, der Samenform, der Haarfarbe und der Abitur-Punktzahl endlich viele Ausprägungen vorliegen. Bei der Abitur-Punktzahl können die Ausprägungen in eine Ordnung gebracht werden. Wer mehr Punkte erreicht hat, hat ein Abitur mit einer höheren Gesamtpunktzahl. Die Merkmalsausprägungen Geschlecht, Samenform oder Haarfarbe können nicht in eine Ord-

nung gebracht werden. Bei den Merkmalen Zweitstimmen-Anzahl und Körpergröße existiert wie bei der Abitur-Punktzahl eine Ordnung.

Man unterscheidet nun zwischen *qualitativen* und *quantitativen* (zählbaren) Merkmalen. Die obigen Beispiele deuten schon an, dass wir dies genauer einteilen können. Man nennt ein Instrument, mit dem man ein Merkmal misst, eine *Skala* (etwa die Temperaturskala eines Thermometers). Mit erhobenen Daten (Merkmalsausprägungen) kann man auf unterschiedliche Art rechnerisch weiterarbeiten. Unterschiedliche Qualitäten von Skalen nennt man *Skalenarten* oder *Skalenniveaus*.

Merkmalseinteilung nach der verwendeten Skala:

- **Nominalskala:** Qualitative Merkmale werden auf der *Nominalskala* gemessen. Diese Merkmalsausprägungen sind qualitativ unterschiedlich. Unterschiedliche Ausprägungen haben unterschiedliche Namen, daher das Wort nominal. Die Ausprägungen solcher Merkmale können nicht geordnet werden. Der einzig mögliche Vergleich ist der Test auf Gleichheit der Ausprägungen zweier Untersuchungsgrößen. Samenform, Haarfarbe und Geschlecht sind nominal skaliert.

- **Ordinal- oder Rangskala:** Qualitative Merkmale werden auf der *Ordinalskala* gemessen, wenn die Merkmalsausprägungen geordnet werden können. Während eine Interpretation der Rangordnung möglich ist, bleibt die Interpretation der Abstände sinnlos. Das Merkmal Abitur-Punktzahlen, genauso wie das Merkmal Schulnoten, ist ordinal skaliert. Ebenso sind mögliche Dienstgrade eines Soldaten oder mögliche erreichte Schulabschlüsse eines Erwachsenen (bei den Ausprägungen kein Schulabschluss, Hauptschulabschluss, Fachoberschulreife, Abitur) ordinal skaliert. Noten sind qualitative Merkmale und keine quantitativen. Jemand, der eine 2 schreibt, hat nicht das halbe Wissen desjenigen, der eine 1 geschrieben hat. Aber auch die schweizerische Notengebung (beste Note 6, schlechteste 1), die Abitur-Punktzahlen von 0 bis 15 oder die Wahl eines Notensystems von A bis E suggeriert eine äquidistante Skala, die es wohl nicht ist.

- **Metrische Skala:** Quantitative Merkmale haben die Eigenschaft, dass es unter den Merkmalsausprägungen eine Rangordnung gibt und zusätzlich Abstände zwischen den Ausprägungen gemessen und interpretiert werden können. Die Ausprägungen von quantitativen Merkmalen sind Zahlen. Metrische Skalen können noch in drei Untertypen unterteilt werden: die *Intervallskala* oder *Verhältnisskala* oder *Absolutskala*. Wir führen dies im Detail aus und geben Beispiele:

1. **Intervallskala:** Hier sind Differenzenbildungen zwischen den Merkmalsausprägungen zulässig. Man kann Abstände bestimmen und gleiche Differenzen von Merkmalen haben die gleiche inhaltliche Bedeutung. Ein Beispiel ist das Merkmal *Temperatur*. Der Unterschied zwischen 25 Grad Celsius und $15^\circ C$ ist derselbe wie zwischen $5^\circ C$ und $-5^\circ C$. Es ist aber falsch zu sagen, $20^\circ C$ sei doppelt so warm wie $10^\circ C$. Quotienten lassen sich also nicht sinnvoll interpretieren. Das gleiche gilt für die Fahrenheit-Skala für die Temperatur: gleiche Differenzen auf der Skala repräsentieren gleiche Temperaturunterschiede, aber 30 Grad Fahrenheit ist nicht nicht doppelt so warm wie 15 Grad. Die Kelvin-Skala löst die Problematik, eine Temperatur-Skala zu finden, bei der Quotienten einen inhaltlichen Sinn haben. Sie gehört zu der nächsten Skala:

2. **Verhältnisskala (Proportionalskala):** Zusätzlich zu den Eigenschaften der Intervallskala existiert hier noch ein natürlicher Nullpunkt. Eine Quotientenbildung ist zulässig und Verhältnisse sind sinnvoll interpretierbar. Das Merkmal *Geschwindigkeit* ist ein klassisches Beispiel. 160 km/h ist doppelt so schnell wie 80 km/h, denn 0 km/h ist ein natürlicher Nullpunkt. Kelvin entwickelte seine Temperaturskala durch Wahl eines absoluten Nullpunkts: eine tiefere Temperatur kann es nach dem dritten Hauptsatz der Thermodynamik nicht geben. Dieser Temperatur entspricht -273.15 Grad Celsius.

   Erinnerung:
   Kelvin - Temperatur T, Celsius - Temperatur ϑ, Fahrenheit - Temperatur F

$$T = 273.15 + \vartheta$$

$$F = 32 + \frac{9}{5}\vartheta; \quad \vartheta = \frac{5}{9}(F - 32)$$

$$\text{Beispiele: } 10^\circ C \mathrel{\hat{=}} (32 + \frac{90}{5})^\circ F = 50^\circ F$$

$$23^\circ F \mathrel{\hat{=}} \frac{5}{9}(23 - 32)^\circ C = -5^\circ C$$

$$32 \cdot \frac{5}{9}{}^\circ C \mathrel{\hat{=}} 64^\circ F; \quad 0^\circ C \mathrel{\hat{=}} 32^\circ F; \quad -17.78^\circ C \mathrel{\hat{=}} 0^\circ F$$

3. **Absolutskala:** Zusätzlich zur Verhältnisskala kommt noch eine natürliche Einheit hinzu. Die Semesterzahl oder die Anzahl der Schülerinnen

und Schüler einer Klasse oder die Wahlberechtigten bei der Bundestagswahl werden am besten durch natürliche Zahlen gemessen und liegen daher auf einer Absolutskala.

2.2.3 Aufgabe: Welche Skalenniveaus haben die Merkmale in den Beispielen 1.1.1, soweit diese bestimmbar sind?

2.2.4 Aufgabe: Welche Skalenniveaus haben die folgenden Merkmale:
Windstärke, Stärke eines Erdbebens, Klausurnote, Schuhgröße, Stromstärke, Autofarbe, Polizeidienstgrade.
Finden Sie für jedes der fünf Skalenniveaus jeweils zwei Merkmale als Beispiele.

2.2.5 Bemerkung: Daten und Merkmale kann man auch in *diskrete* und *kontinuierliche/stetige* einteilen. Diskrete Daten sind dann im Prinzip ganzzahlige Daten, kontinuierliche stammen aus $\mathbb{R}$.

Eine interessante Frage ist die folgende: welche *Transformationen* einer Datenreihe sind erlaubt, ohne dass das Skalenniveau sich verändert? Dazu betrachten wir einen so genannten *Messvorgang* als einen Prozess, bei dem einem Objekt eine reelle Zahl zugeordnet wird. Die Messergebnisse bilden dann eine Zahlenreihe reeller Zahlen. Betrachten wir zunächst nominale Merkmale. Welche Möglichkeiten gibt es, die Merkmalsausprägungen mit reellen Zahlen zu kodieren, ohne dass sich das Skalenniveau beim Messvorgang ändert? Wenn man zum Beispiel das Geschlecht männlich mit 1 und das Geschlecht weiblich mit 2 kodiert, so ist jede alternative Kodierung erlaubt, die zwei verschiedene Zahlen wählt, etwa 4 und 6. Als *niveauerhaltende Transformationen* kommen damit alle injektiven Funktionen infrage. Für ordinal skalierte Daten sind die niveauerhaltenden Transformationen alle streng monotonen Funktionen, denn dann fallen unterschiedliche Werte nicht zusammen und die Reihenfolge bleibt ebenfalls erhalten. Es kann mittels einer solchen Transformation allerdings alles auf den Kopf gestellt werden (streng monoton fallende Funktionen). Ein Beispiel sind die Notenskalen: einmal werden gute Leistungen mit großen Zahlen kodiert (Schweiz, Abitur-Punkte), in der Sekundarstufe I stehen kleine Zahlen für gute Leistungen. Bei den Intervallskalen sollen zusätzlich Abstände erhalten bleiben.

2.2.6 Aufgabe: Zeigen Sie, dass die affin-linearen Funktionen niveauerhaltende Transformationen zwischen Messfunktionen von Intervallskalen sind. Untersuchen Sie, welche Transformationen bei Verhältnisskalen und bei Absolutskalen niveauerhaltend sind.

2.3 Reduktion und Darstellungen von Daten

In der Praxis hat man es mit großen Datenmengen zu tun. Angenommen, es liegen Daten einer Erhebung mittels des Fragebogens aus Beispiel 1.1.1(c) vor. Dort stellt man 17 verschiedenartige Fragen an die Schülerinnen und Schüler einer Klasse oder einer Jahrgangsstufe. Die Menge der Daten muss in einer geeigneten Form auf das Wesentliche reduziert werden. Das Wesentliche muss informativ und sachgerecht dargestellt werden. Doch was bedeutet wesentlich? Es ist klar, dass dieser Punkt vom subjektiven Interesse abhängig bleiben wird. Eine Ausführung, wie sie nun folgen wird, kann nur der Versuch sein, mit plausiblen Reduktionverfahren und Darstellungen von Daten zu konfrontieren, damit verfälschende und tendenziöse Darstellungen entlarvt werden können.

Die erste und einfachste Art der rechnerischen Datenreduktion ist die Bestimmung von absoluten und relativen Häufigkeiten für Merkmalsausprägungen, was bei jedem Skalenniveau erfolgen kann.

2.3.1 Definition: Zu n Beobachtungswerten (Merkmalsausprägungen) $x_1, \ldots, x_n$ heißt $x = (x_1, \ldots, x_n)$ *Stichprobe vom Umfang* n. Die vorkommenden verschiedenen Werte heißen *Merkmalwerte*, in Bezeichnung $x_1^*, \ldots, x_N^*$. Für jeden Merkmalwert x_k^* wird die Anzahl der Merkmalsträger mit diesem Merkmalwert mit $h_k := h(x_k^*)$ bezeichnet und *absolute Häufigkeit* von x_k^* genannt. Mit $r_k := r(x_k^*) := \frac{h_k}{n}$ wird die *relative Häufigkeit* von x_k^* bezeichnet.

2.3.2 Bemerkung: Es gilt:

$$\sum_{k=1}^{N} h_k = n; \quad 0 \leq r_k \leq 1 \quad \text{für alle } k; \quad \sum_{k=1}^{N} r_k = 1\,.$$

2.3.3 Beispiele: Der Urliste aus Beispiel 1.1.1(d) entnehmen wir die folgende Tabelle 2.1 relativer und absoluter Häufigkeiten für die Merkmale *Haarfarbe* und *Geschlecht*:

Ebenso ermitteln wir aus der Urliste aus Beispiel 1.1.1(f) die folgende Tabelle 2.2 relativer und absoluter Häufigkeiten.

Für das ordinale und metrische Skalenniveau können wir die Merkmalsausprägungen ordnen. Wir erstellen eine so genannte geordnete Stichprobe im Sinne der folgenden Definition:

2.3.4 Definition: Wir betrachten eine Stichprobe $x = (x_1, \ldots, x_n)$ von Merkmalsausprägungen auf einer Ordinalskala oder einer metrischen Skala. Mit $x_{[1]}$

Merkmal	Ausprägung	absolute Häufigkeit	relative Häufigkeit
Geschlecht	Weiblich	40	0.40
	Männlich	60	0.60
Haarfarbe	schwarz	10	0.10
	rot	10	0.10
	blond	30	0.30
	braun	45	0.45
	grau	5	0.05

Tab. 2.1: Merkmalshäufigkeiten

Fach	absolute Häufigkeit	relative Häufigkeit
Biologie	12	0.3529
Sport	10	0.2941
Physik	9	0.2647
Andere	3	0.0882

Tab. 2.2: Zweitfachkombinationen bei Lehramtsstudenten

bezeichnen wir den kleinsten Wert im Sinne der Ordnung, mit $x_{[2]}$ den zweitkleinsten u.s.w., mit $x_{[k]}$ die k-te Ordnungsgröße. Dann heißt $\langle x \rangle := (x_{[1]}, \ldots, x_{[n]})$ eine *geordnete Stichprobe*. Der *Rang* einer Merkmalsausprägung x_i innerhalb der Stichprobe gibt an, die wievielt-kleinste Zahl sie ist:

$$\text{Rang}\,\langle x_i \rangle := 1 + \#\{j \,|\, x_j < x_i\} + \frac{1}{2}\#\{j \,|\, j \neq i \;\text{ und }\; x_j = x_i\}\,.$$

2.3.5 Beispiel: Bei 10 Versuchspersonen wurde die durchschnittliche *Schlafverlängerung* durch ein Medikament A gegenüber einem Medikament B gemessen (in Stunden), siehe Cushny and Peebles, 1905, J. Physiol. 32, 501, *Student*, 1908, Biometrika 6,1. Die Ergebnisse waren: $x_1 = 1.2\,, x_2 = 2.4\,, x_3 = 1.3\,, x_4 = 1.3\,, x_5 = 0.0\,, x_6 = 1.0\,, x_7 = 1.8\,, x_8 = 0.8\,, x_9 = 4.6\,, x_{10} = 1.4$. In diesem Beispiel ist nun

$$x_{[1]} = 0.0\,, x_{[2]} = 0.8, x_{[3]} = 1.0\,, x_{[4]} = 1.2, \ldots, x_{[10]} = 4.6.$$

Somit ist $\text{Rang}\,\langle x_1 \rangle = 4$. Bei gleichen Zahlen werden die entsprechenden Rangzahlen gemittelt:

$$\text{Rang}\,\langle x_3 \rangle = \text{Rang}\,\langle x_4 \rangle = \frac{5+6}{2} = 5.5.$$

Erste graphische Darstellungsmöglichkeiten basieren auf der Bestimmung von absoluten und relativen Häufigkeiten. Wir stellen *Säulen-, Balken, und Kreisdiagramme* vor. Graphiken erlauben meist einen raschen Überblick, trotzdem ist ein

gewisser Informationsverlust unvermeidlich, auch liegt eine größere Anfälligkeit gegenüber Fehlinterpretationen und Manipulationen vor.

1. **Balken- oder Säulendiagramme**
Bei einem *Balkendiagramm* werden die absoluten oder relativen Häufigkeiten der Merkmale horizontal als *Breite von Balken* interpretiert. Bei einem *Säulendiagramm* werden die Häufigkeiten vertikal als die *Höhe von Säulen* interpretiert. Balken und Säulen sollten einander nicht berühren und gleich breit sein.

Die Balken bzw. Säulen sollen bei Null beginnen, da Unterschiede über die Breiten- bzw. Höhendifferenz visualisiert werden. Die Reihenfolge, in der die Merkmalsausprägungen in einem dieser Diagramme abgetragen werden, ist bei nominal skalierten Merkmalen unerheblich, bei ordinal skalierten Merkmalen muss die Ordnung in der Darstellung Berücksichtigung finden, bei quantitativen Merkmalen sollte sich auch der Abstand der Ausprägungen proportional wiederfinden.

In der Literatur tauchen auch *Stabdiagramme* auf. Dies sind Säulendiagramme, bei denen die Säulen kaum noch Breitenausdehnung haben, also zu Stäben geschrumpft sind. Wir geben ein paar weitere Beispiele:

2.3.6 Beispiel: Mittels eines Balkendiagrammes wird die gesammte Staatsverschuldung einiger Länder des Jahres 2000 in Milliarden USD dargestellt, siehe Abb. 2.1.

2.3.7 Beispiel: Der Tierbestand auf einem Biohof setzt sich wie folgt zusammen, siehe das zugehörige Säulendiagramm in Abb. 2.2.

Tiere	Rinder	Schweine	Schafe	Ziegen
Anzahl	20	25	11	3

Es können auch mehrere Merkmale gemeinsam in einem Diagramm dargestellt werden.

2.3.8 Beispiel: Tierbestand auf 5 Biohöfen, siehe das zugehörige Säulendiagramm in Abb. 2.3.

	B1	B2	B3	B4	B5
Rinder	20	0	12	6	2
Schweine	25	34	3	28	19
Schafe	11	29	23	3	5
Ziegen	3	2	0	0	20

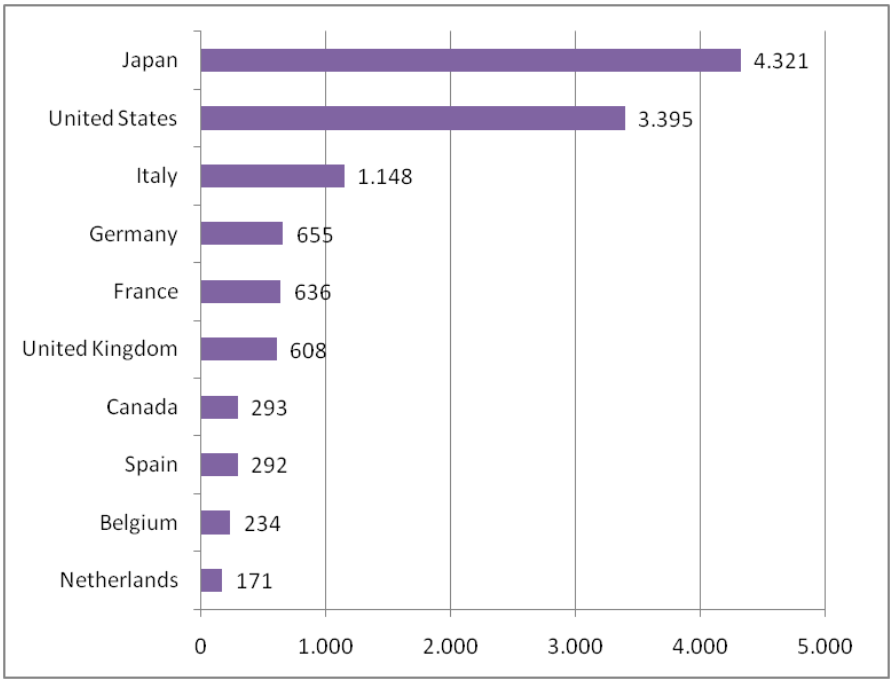

Quelle: OECD.StatExtracts

Abb. 2.1: Gesammte Staatsverschuldung für 2000 in Milliarden USD

2. **Kreisdiagramme**
Nun wird die *Fläche* das Mittel der Veranschaulichung. Es wird jeder Merkmalsausprägung ein Kreissektor zugeordnet. Bezeichne r_k die relative Häufigkeit von x_k^*, und sei α_k der Mittelpunktswinkel des zugehörigen Kreissektors, so wählen wir

$$\alpha_k = r_k \cdot 360°.$$

Die Verhältnisse von Flächeninhalten, Bogenlängen und Winkeln entsprechen dann einander. Kreisdiagramme bieten sich für nominal skalierte Daten an. Die Anordnung kann nicht vollständig dargestellt werden, denn es würde bei Beachtung der Ordnung der kleinsten Ausprägung die größte folgen. Bei Wahlergebnissen bieten die Kreisdiagramme den Vorteil, dass man absolute Mehrheiten leicht ablesen kann. Sind aber relative Mehrheiten entscheidend, verwendet man besser Säulen- oder Balkendiagramme.

2.3.9 Beispiel: Tabelle 2.3 führt die Längen der Grenzen von Deutschland mit seinen Nachbarländern auf: Wir veranschaulichen dies mittels des Kreisdiagramms in Abb. 2.4.

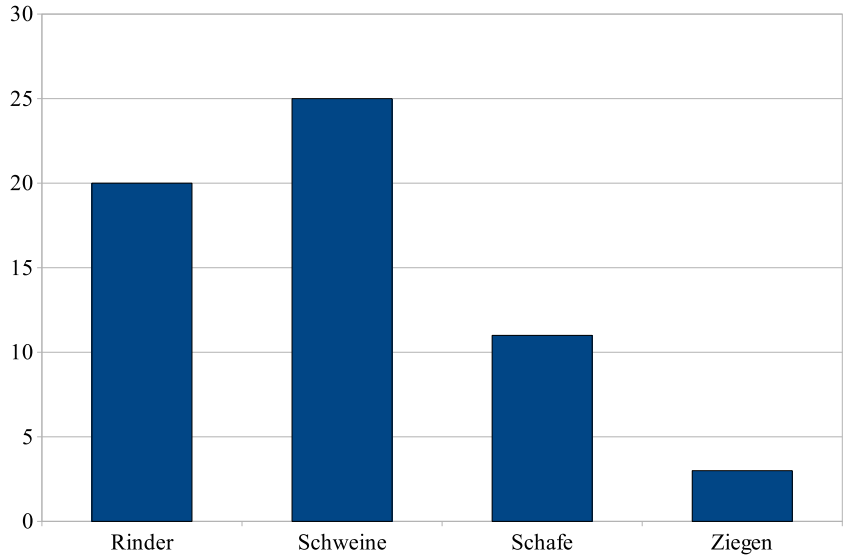

Abb. 2.2: Tierbestand auf einem Biohof

Gemeinsame Grenze mit (Land)	km	Anteil in %
Dänemark	67	1.8
Niederlande	576	15.3
Belgien	155	4.1
Luxemburg	135	3.6
Frankreich	446	11.8
Schweiz	334	8.9
Österreich	784	20.8
Tschechien	810	21.5
Polen	460	12.2
	3.767	100

Tab. 2.3: Längen der Grenzen Deutschlands

3. **Empirische Verteilungsfunktion bei komperativen Merkmalen**
Wir kommen auf Beispiel 1.1.1(i) zurück: Wir wollen aus dem Datensatz ermitteln, wieviele Schülerinnen und Schüler in einem bestimmten Punktebereich liegen. Uns interessiert der *Defizit-Bereich* (höchstens 4 Punkte) und der Bereich *gut und sehr gut*. Allgemeiner interessiert uns die Anzahl der untersuchten Objekte, deren Ausprägung in einem bestimmten Bereich liegt. Dies führt uns zu der folgenden Definition, die nur für komperative Merkmale Sinn macht:

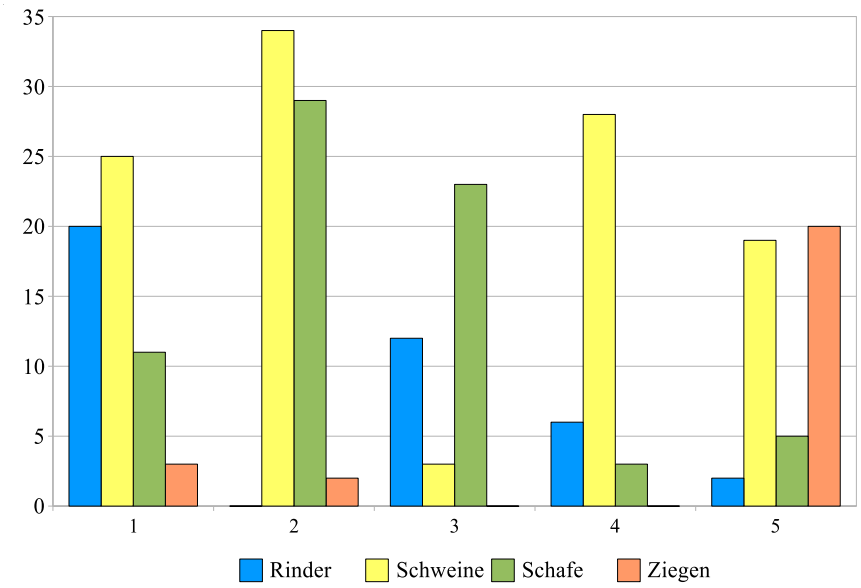

Abb. 2.3: Tierbestand auf fünf Biohöfen

2.3.10 Definition: Gegeben sei eine Stichprobe $(x_1, \ldots, x_n)$. x_k^* komme mit absoluter Häufigkeit $h_k = h(x_k^*)$ und relativer Häufigkeit $r_k = r(x_k^*)$ vor, $k = 1, \ldots, N$. Dann heißt

$$H_k := \sum_{i: x_i^* \leq x_k^*} h_i$$

absolute Summenhäufigkeit von x_k^* und

$$R_k := \sum_{i: x_i^* \leq x_k^*} r_i$$

relative Summenhäufigkeit von x_k^*.

2.3.11 Beispiel: Wir ergänzen die Tabelle in Beispiel 1.1.1(i) durch die absoluten und relativen Summenhäufigkeiten, siehe Tabelle 2.4.

Die Darstellung der relativen Häufigkeiten und der relativen Summenhäufigkeiten in Form eines Säulendiagramms lässt (zum Beispiel) feststellen, oberhalb welcher Punktezahl die Hälfte aller Schülerinnen und Schüler liegt, siehe Abbildung 2.5.

2.3.12 Aufgabe: Zeigen Sie, dass für alle Ausprägungen x_k^* eines Merkmals bei

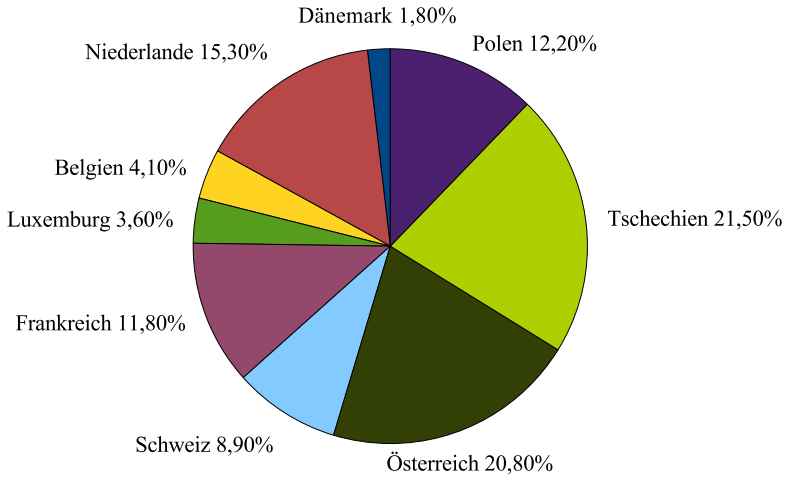

Abb. 2.4: Kreisdiagramm: Länge der Grenzen

Punkte	Absolute Häufigkeit	Relative Häufigkeit	Kumulierte absolute Häufigkeit	Kumulierte relative Häufigkeit
0	1	0.009	1	0.009
1	4	0.034	5	0.043
2	6	0.051	11	0.094
3	5	0.043	16	0.137
4	9	0.077	25	0.214
5	9	0.077	34	0.291
6	12	0.103	46	0.393
7	10	0.085	56	0.479
8	14	0.12	70	0.598
9	12	0.103	82	0.701
10	9	0.077	91	0.778
11	8	0.068	99	0.846
12	5	0.043	104	0.889
13	6	0.051	110	0.940
14	4	0.034	114	0.974
15	3	0.026	117	1.0

Tab. 2.4: Kumulierte Häufigkeiten für Punktezahlen bei der Abiturprüfung

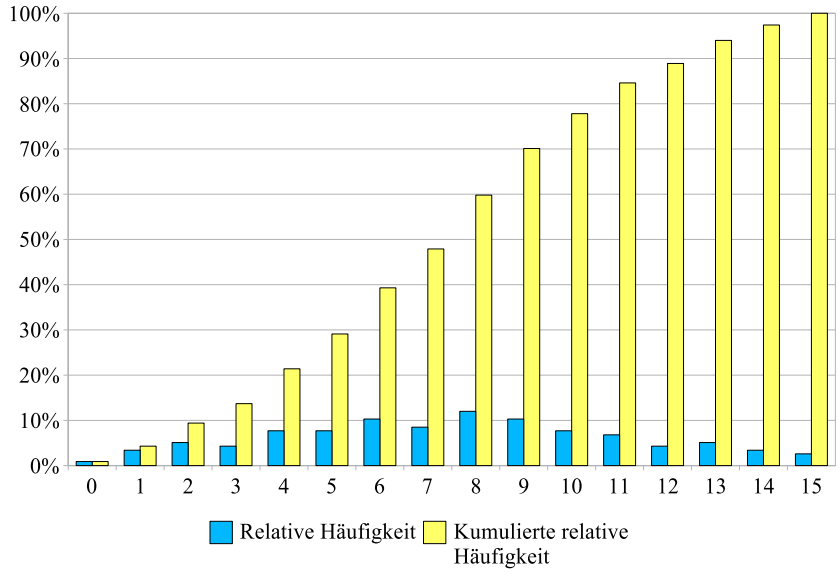

Abb. 2.5: Punktzahlen im Abitur

n untersuchten Merkmalsträgern immer

$$0 \leq \sum_{i:x_i^* \leq x_k^*} r_i \leq 1$$

gilt.

Die Definition der relativen Summenhäufigkeit ist für alle $x \in \mathbb{R}$ verallgemeinerbar und es gilt $0 \leq \sum_{y \leq x} r(y) \leq 1$ für alle $x \in \mathbb{R}$. Dies führt zu der folgenden Definition:

2.3.13 Definition: Die Summe der relativen Häufigkeiten aller Merkmalwerte eines ordinal skalierten Merkmals, die kleiner gleich x sind, heißt *empirische Verteilungsfunktion:*

$$F_n(x) := \sum_{y \leq x} r(y), \quad x \in \mathbb{R}.$$

Es gilt also $F_n(x_k^*) = R_k$. Die empirische Verteilungsfunktion ist somit eine monoton wachsende Treppenfunktion. Die Längen der einzelnen Treppenstufen haben die Bedeutung, dass gleiche Längen als gleiche Abstände interpretiert werden. Dies führt zu dem schon diskutierten Problem bei nur ordinal skalierten Merkmalen. Also ist die empirische Verteilungsfunktion keine angemessene Darstellungsart für

die Daten aus Beispiel 2.3.11. Sie bleibt als Darstellungsform den quantitativen Merkmalen vorbehalten. Dazu ein Beispiel:

2.3.14 Beispiel: 50 Schüler zweier Schulklassen werden der Größe nach in einer Reihe aufgestellt (siehe Tabelle 2.5 und Abb. 2.6).

Körpergröße x_i^*	absolute Häufigkeit h_i	absolute Summenhäufigkeit H_i	relative Häufigkeit r_i	relative Summenhäufigkeit R_i
116	1	1	0.02	0.02
117	2	3	0.04	0.06
118	0	3	0	0.06
119	2	5	0.04	0.10
120	3	8	0.06	0.16
121	4	12	0.08	0.24
122	6	18	0.12	0.36
123	8	26	0.16	0.52
124	7	33	0.14	0.66
125	5	38	0.10	0.76
126	3	41	0.06	0.82
127	1	42	0.02	0.84
128	2	44	0.04	0.88
129	1	45	0.02	0.90
130	2	47	0.04	0.94
131	2	49	0.04	0.98
132	0	49	0	0.98
133	0	49	0	0.98
134	1	50	0.02	1.00
$\sum$	n=50		1.00	

Tab. 2.5: Summenhäufigkeiten einer geordneten Stichprobe

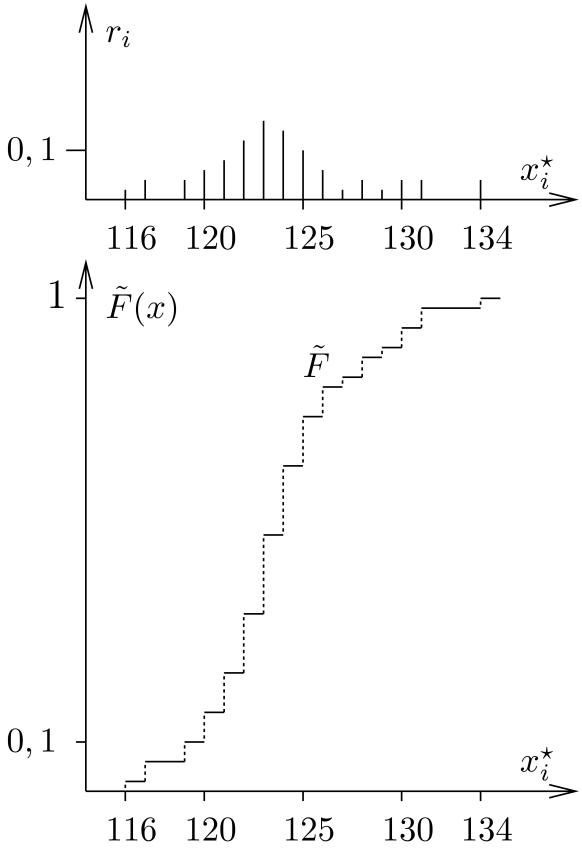

Abb. 2.6: Stabdiagramm und empirische Verteilungsfunktion

4. **Liniendiagramme, Häufigkeitspolygone**
Man trage die relativen oder absoluten Häufigkeiten durch Punkte genau über der Stab- bzw. Balkenmitte auf. Bei zeitlichen Entwicklungen ist der Beobachtungszeitpunkt auf der x-Achse, der dazugehörige Wert auf der y-Achse einzutragen. Benachbarte Punkte werden dann durch Strecken miteinander verbunden. Diese Darstellungsform ist insbesondere geeignet, um mehrere Versuchsreihen miteinander vergleichen zu können, wobei die Darstellung bei mehr als 3-4 Linien ihren Wert verliert.

2.3.15 Beispiel: Man betrachte die Bevölkerungszahlen der unter 15-jährigen Personen in Österreich für die Jahre 1982 – 1992, siehe Tabelle 2.6 und Liniendiagramm 2.7.

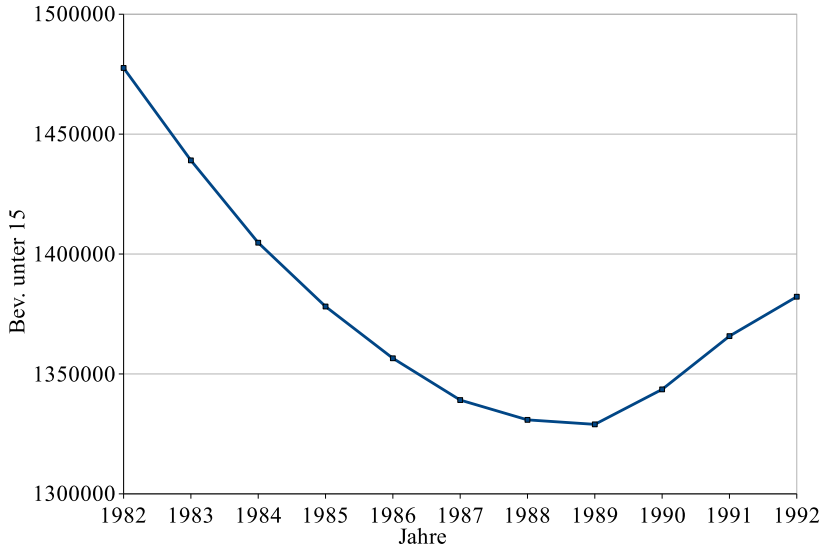

Abb. 2.7: Bevölkerungszahlen der unter 15-jährigen Personen in Österreich für die Jahre 1982 – 1992

Jahr	1982	1983	1984	1985	1986	1987
	1477603	1439068	1404723	1378120	1356534	1339114
Jahr	1988	1989	1990	1991	1992	
	1330843	1328966	1343555	1365772	1382203	

Tab. 2.6: *Quelle:* Bevölkerungsfortschreibung auf Basis der Volkszählung 1981, Österreichisches Statistisches Zentralamt (1993)

2.3.16 Aufgabe: (a) Untersuchen Sie die relativen Häufigkeiten, mit denen in Zeitungen Zahlen mit der von 0 verschiedenen Anfangsziffer $1, 2, 3, \ldots, 9$ vorkommen. Formulieren und diskutieren Sie vor der Untersuchung Ihre Vermutung über die Verteilung dieser Häufigkeiten. Stellen Sie die erhaltene Häufigkeitsverteilung in Form eines Polygonzuges dar. Stimmt sie mit Ihren Erwartungen überein?

(b) Nach dem Benford-Gesetz (Frank Benford (1883–1948)) ist die Verteilung der *in der Wirklichkeit vorkommenden* Zahlen bzw. Messwerte, Rechnungsbeträge, Anzahlen, Kurse usw. gemäß ihrer Anfangsziffern (AZ) ungefähr wie folgt (rH ist die relative Häufigkeit):

AZ	1	2	3	4	5	6	7	8	9
rH	0.301	0.176	0.125	0.097	0.079	0.067	0.058	0.051	0.046

Stimmt die von Ihnen erhaltene Verteilung mit diesem Gesetz überein?

5. **Klassierte Daten, Histogramme**
Was tun, wenn die Anzahl der möglichen Merkmalsausprägungen sehr groß ist? Betrachten wir etwa in Beispiel 1.1.1(d) die Angaben zur Körpergröße oder zum Gewicht. Hier kommen schon recht viele Merkmalsausprägungen vor. Auch das Säulendiagramm zu den Punktzahlen in der ersten schriftlichen Abiturprüfung, siehe Beispiel 1.1.1(i), stößt bereits an die Grenzen dessen, was wir visuell verarbeiten können. Der Ausweg liegt auf der Hand: wir stellen die Daten weniger fein dar, indem wir eine Klassierung bzw. Gruppenbildung vornehmen. Bei den Daten spricht man dann von *klassierten Daten.* Üblicherweise werden die Datenreduktionen durch Klassenbildung für quantitative Merkmale durchgeführt. Klassengrenzen $c_0, \ldots, c_k$, $k \in \mathbb{N}$ führen zu Klassen $\mathcal{C}_l := \{x_i | c_{l-1} < x_i \leq c_l\}$, $1 \leq l \leq k$. Die absoluten Häufigkeiten $h_l = \#\{i \,|\, x_i \in \mathcal{C}_l\}$ erfüllen dann $\sum_l h_l = n$, aber nur, wenn keine Beobachtungen kleiner als c_0 oder größer als c_k sind. Die Klassenbreiten sind dann definiert durch $b_i = c_i - c_{i-1}$, $1 \leq i \leq k$, und als Klassenmitten werden für gewöhnlich die Mittelpunkte zwischen den beiden Klassengrenzen bezeichnet. Diese Definition deutet darauf hin, dass die Klassenbildung auch für ordinal skalierte Merkmale möglich ist. Und so wird es ja auch bei der Notengebung in der Sekundarstufe II gemacht. Die 16 möglichen Punktzahlen werden zu 6 Noten zusammengefasst. Doch erneut: hier sind dann Klassenbreiten und Klassenmitten nicht zwingend inhaltlich interpretierbar, denn Breiten sind Differenzen, und diese sind nur bei quantitativen Merkmalen immer mit Sinn zu versehen.

Wie kann die Anzahl der Klassen sinnvoll gewählt werden? Es ist klar, dass zu wenige Klassen ein zu großer Verlust an Information bedeutet, da dann viele Daten ununterscheidbar in derselben Klasse landen. Bei zu vielen Klassen leidet jede Darstellungsform. Es gibt eine *Faustregel*, die man die *Regel von* STURGE nennt, nach der bei n Daten die Klassenzahl für kleine n (zum Beispiel $n \leq 100$) bei $\sqrt{n}$ liegt, während sie für große n bei $\log_2 n$ liegt.

Klassierte Daten stellen wir durch *Histogramme* dar. Dies sind Säulendiagramme, bei denen aber die Säulen oder Stäbe keinen Abstand voneinander haben. Dies liegt daran, dass wir ordinal skalierte Daten vorliegen haben, was eine lückenlose nebeneinander liegende Einteilung in Klassen erlaubt. Die Merkregel ist, dass bei einem Histogramm die Fläche des Rechtecks die Häufigkeit beschreiben soll. Bei einer Klasseneinteilung mit gleichen Klassenbreiten normiert man (zum Beispiel) die Klassenbreite zu 1 und trägt als Höhe des Rechtecks die absolute oder relative Klassenhäufigkeit ab. Allgemein bestimmt man bei unterschiedlichen Klassenbrei-

ten die Höhe des i-ten Balkens mittels

$$l_i := \frac{\text{absolute Klassenhäufigkeit } h_i}{\text{Klassenbreite}} = \frac{h_i}{c_i - c_{i-1}} \quad , 1 \leq i \leq k\,.$$

Im Falle relativer Häufigkeiten entsprechend

$$l_i := \frac{\text{relative Klassenhäufigkeit}}{\text{Klassenbreite}}\,.$$

Histogramme bieten die Möglichkeit, verschiedene Charakteristika der Daten zu entdecken, wie etwa:

- Sind die Daten annähernd symmetrisch verteilt?
- Wie groß ist die Spannweite der Daten?
- Gibt es Ausreißer in den Daten?
- Existieren Datenkonzentrationen (Cluster)?
- Gibt es Lücken in den Daten?

2.3.17 Beispiel: Wir betrachten einen Datensatz aus *K. Bosch, Elementare Einführung in die angewandte Statistik, Vieweg Studium.* Ein Übungsschein in der Stochastikvorlesung kann erlangt werden, wenn man bei zwei Klausuren von insgesamt 60 möglichen Punkten mindestens 30 erreicht hat. Das Resultat bei $n = 165$ Studierenden ist der Tabelle 2.7 zu entnehmen. Zum einen betrachtet man eine äquidistante Klassenteilung der Punktzahl 60 in 6 Klassen. Zum anderen wird zur Festlegung von Zensuren eine Einteilung in 5 Klassen vorgenommen, die nicht gleich breit sind.

2.3.18 Bemerkung: Die Klassengrenzen für die Punkte sind 0.5, 10.5, 20.5, ..., 50.5 (Eindeutigkeit der Klassenzugehörigkeit). Dies führt zu dem Histogramm in Abbildung 2.8.

2.3.19 Bemerkung: Bei Festsetzung der Zensuren mittels der Klasseneinteilung 0.5, 29.5, 38.5, 46.5, 55.5, 60.5 ergeben sich unterschiedliche Klassenbreiten, siehe Abb. 2.9, das nicht zu empfehlende Histogramm, da es nicht flächenproportional ist, und Abb. 2.10, das flächenproportionale Histogramm.

Punkte-zahl z_k	absolute Häufigkeit h_k	äquidistante Klasseneinteilung: Klasse	äquidistante Klasseneinteilung: absolute Häufigkeit	nichtäquidistante Klassenbildung für die Zensur: Zensur	absolute Häufig-keit	relative Häufig-keit	Klassen-breite	$\frac{\text{abs. Häufigkeit}}{\text{Klassenbreite}}$
0	0							
1	1							
2	3							
3	1							
4	1							
5	6	K_1	17					
6	1							
7	0							
8	0							
9	2							
10	2							
11	1							
12	1							
13	3							
14	2							
15	0							
16	1	K_2	15					
17	3			5	55	0.3333	29	$\frac{55}{29} = 1.897$
18	1							
19	3							
20	0							
21	4							
22	2							
23	4							
24	4							
25	0	K_3	30					
26	4							
27	3							
28	1							
29	1							
30	7							
31	2							
32	9							
33	4							
34	4			4	50	0.3030	9	$\frac{50}{9} = 5.556$
35	9	K_4	51					
36	6							
37	6							
38	3							
39	3							
40	5							
41	5							
42	7							
43	3			3	34	0.2061	8	$\frac{34}{8} = 4.25$
44	5							
45	3	K_5	42					
46	3							
47	3							
48	5							
49	6							
50	2							
51	3			2	24	0.1455	9	$\frac{24}{9} = 2.667$
52	2							
53	1							
54	2							
55	0	K_6	10					
56	0							
57	1							
58	1			1	2	0.0121	5	$\frac{2}{5} = 0.4$
59	0							
60	0							
	$n = 165$		$n = 165$		$n = 165$	1		

Tab. 2.7: Klasseneinteilungen

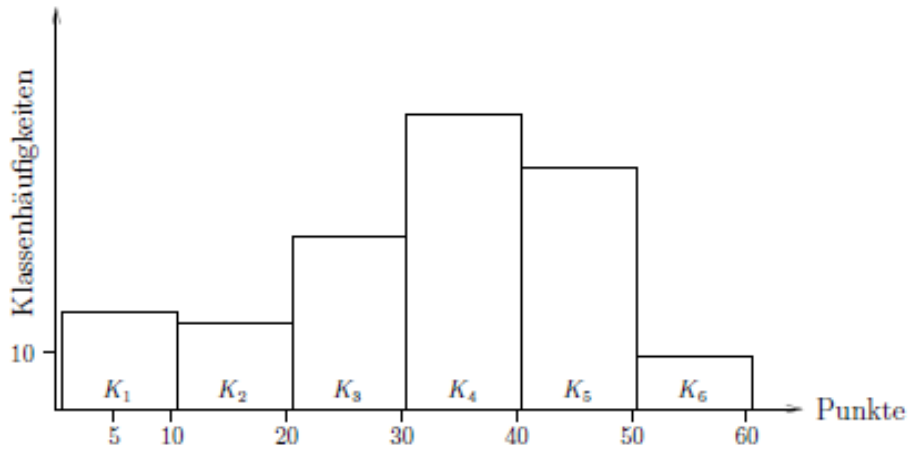

Abb. 2.8: Klassenhäufigkeiten bei äquidistanter Klasseneinteilung

2.3.20 Beispiel: Im Datensatz aus Beispiel 1.1.1(f) erkennen wir besonders gut den Unterschied zwischen einem Säulendiagramm und einem Histogramm. Das gewählte Zweitfach, nominal skaliert, sollte durch ein Stabdiagramm dargestellt werden, die Angaben zur wöchentlichen Arbeitszeit sollten mittels eines Histogramms darstellt werden, das Merkmal liegt auf einer Ordinalskala: siehe Abbildung 2.11.

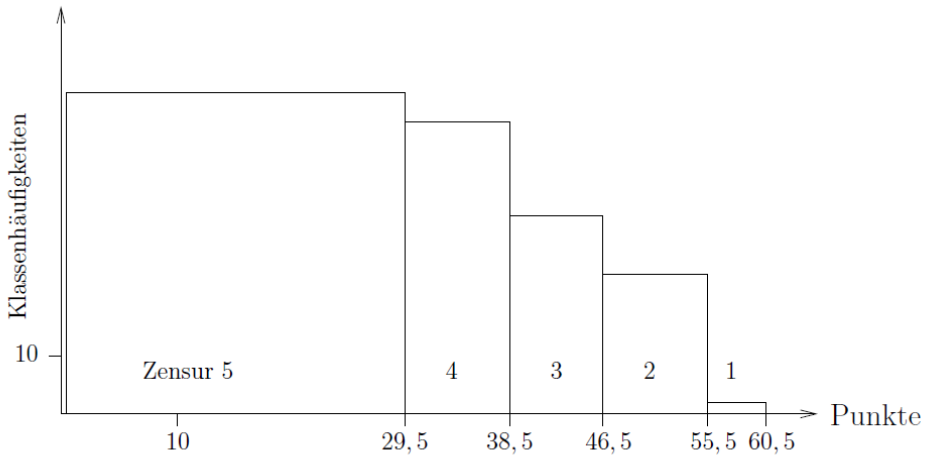

Abb. 2.9: falsches Histogramm bei verschiedenen Klassenbreiten

6. **Klassierte Daten, Stamm-Blatt-Diagramme (Stengel-Blatt)**
Stamm-Blatt-Diagramme gehen auf John W. Tukey (1915–2000) zurück. Turey schrieb 1977 das Buch *Exploratory data analysis*, in dem er in die Detektivarbeit zu Daten einführt.

Wir betrachten ein Beispiel:

2.3.21 Beispiel: Gegeben sind die Korndurchmesser von 30 Steinsalzkörnern in mm, siehe Tabelle 2.8. Daneben befindet sich ein zugehöriges Stamm-Blatt-Diagramm.

3.5	2.4	1.8	3.2	2.4	3.5
3.0	3.5	4.0	1.8	2.9	3.5
2.4	2.9	3.3	2.6	2.6	1.6
3.0	1.5	3.0	2.4	3.9	2.3
2.1	2.7	2.6	4.0	2.9	1.1

Stämme	Blätter
1	15688
2	1344446667999
3	0002355559
4	00

Tab. 2.8: Korndurchmesser in mm

Zunächst hat man eine Klasseneinteilung vorgenommen:
$[1.0, 2.0), [2.0, 3.0), [3.0, 4.0), [4.0, 5.0)$.
Innerhalb einer Klasse muss die führende Ziffer der Dezimaldarstellung aller zugehörigen Zahlen übereinstimmen. Diese wird links einer vertikalen Linie notiert. Es sind dies die *Stämme*. Unter den *Blättern* ist auf der rechten Seite jeweils die zweite

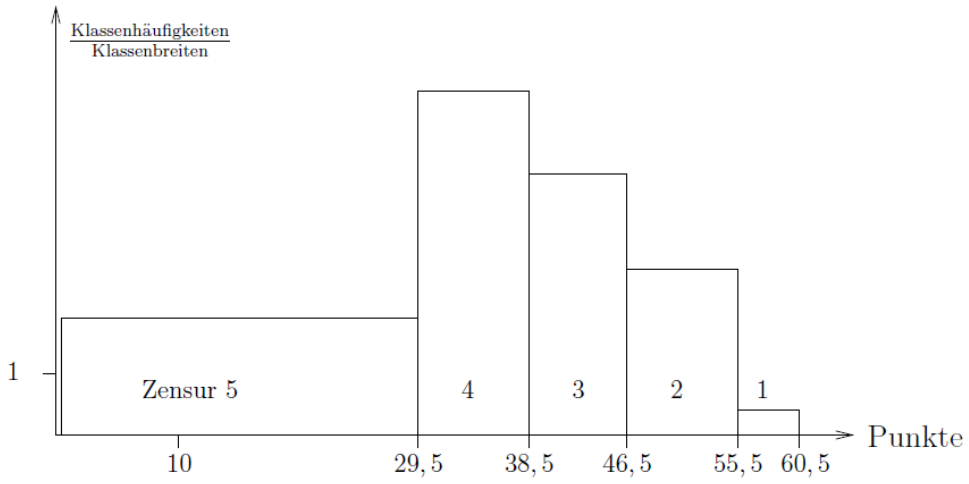

Abb. 2.10: flächenproportionales Histogramm

Ziffer der Zahl (erste Nachkommastelle) eingetragen. Man muss dies nicht sortiert eintragen. Man kann die Urliste der Reihe nach abarbeiten. Jeder Eintrag einer Ziffer muss gleich viel Platz (horizontal und vertikal) einnehmen. Weiter sollen keine Lücken entstehen, also muss zum Beispiel die 3 bei den Stämmen aufgeführt werden, selbst wenn keine Zahl $3.x$ vorkäme.

Mittels eines solchen Diagramms bekommt man einen schnellen Überblick über die Verteilung der Daten. Man kann sogar, im Gegensatz zum Histogramm, jeden einzelnen Datenpunkt rekonstruieren. Daher ist diese Darstellungsform aber für große Datenmengen wenig geeignet.

Hilfreich ist ein Stamm-Blatt-Diagramm auch bei einer vergleichenden Untersuchung eines Merkmals in Bezug auf zwei Vergleichsgruppen, wie das folgende Beispiel zeigt:

2.3.22 Beispiel: *Zweiseitiges Stamm-Blatt-Diagramm:*
Wir betrachten die Körpergrößen aus Beispiel 1.1.1(d), getrennt nach Geschlecht für Schülerinnen (40) und Schüler (60).

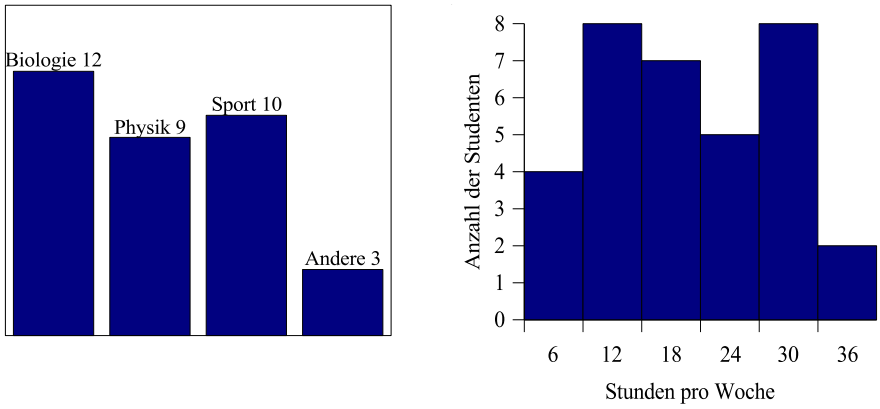

Abb. 2.11: Stabdiagramm und Histogramm

Blätter (weiblich)	Stämme	Blätter (männlich)
027	15	9
0133568	16	13579
0001122223444566778899	17	0134567778899
⋮	18	⋮
	19	
	20	25

2.3.23 Aufgabe: *Ist eine Prüfung schwer?* Von 235 Studierenden sind 7 dreimal durch die Abschlussklausur zur Linearen Algebravorlesung gefallen, 45 zweimal und 89 immerhin einmal. 60 bestanden beim ersten Mal, 34 waren noch nie für die Abschlussklausur angemeldet. Welchen Diagrammtyp würden Sie zur Veranschaulichung wählen?

Es gibt natürlich noch weitere Darstellungsformen. Wir haben bisher zum Beispiel nicht systematisch Darstellungen von Daten für mehrere untersuchte Merkmale betrachtet (man spricht von bivariaten statistischen Verfahren im Fall von zwei Merkmalen). Stichworte sind hier die *Kreuztabelle, gemeinsame Verteilungen, Da-*

tenmatrix sowie *Punktewolke, Streudiagramm oder Scatterplot.* In Kapitel 4 werden wir dies im Rahmen der Untersuchung von Regression und Korrelation andeuten.

Der Hauptzweck von Darstellungen ist die Datenreduktion und bei graphischen Darstellungen die Visualisierung. Auch am Ende dieser Ausführungen sehen wir, die Frage nach einer guten Darstellung nicht allgemein verbindlich klären zu können. Welche Daten soll man wie darstellen? Es gibt viele gute Beispiele und viele Warnungen vor Fehlern und Fallen bei der Darstellung von Daten. Dieses Kapitel hat das Rad zu diesem Thema nicht neu erfunden. Es sei auf die folgenden interessanten Bücher verwiesen. In den populärwissenschaftlichen Büchern von Walter Krämer *So überzeugt man mit Statistik (1994)*, *So lügt man mit Statistik (1998)* und *Statistik verstehen (2002)* findet man die Faustregel:

Säulen für Vergleiche, Torten für Anteile, Kurven für Trends.

Herbert Kütting hat in seinem Buch *Beschreibende Statistik im Schulunterricht (1994)* eine Fülle von interessanten Beispielen zusammengetragen.

In jüngerer Zeit entstand das Buch *Elementare Stochastik (2004)* von Andreas Büchter und Hans-Wolfgang Henn. Es gehört zur Serie *Mathematik für das Lehramt* und enthält zur beschreibenden Statistik eine der ausführlichsten Darstellungen zu diesem Thema.

Lösungen der Aufgaben

Lösungen der Aufgaben in 2.2

Aufgabe 2.2.2

(a) Es bezeichne Ω die Menge aller Personen mit einem Universitätsabschluss im Fach Mathematik im Jahr 1990. Zu $\omega \in \Omega$ definieren wir $X(\omega) = 1$, wenn die Person ω ein Diplom erworben hat, sonst setzen wir $X(\omega) = 0$. Dann ist $\sum_{\omega \in \Omega} X(\omega)$ die Anzahl aller Diplom-Abschlüsse im Jahr 1990. Hier ist $S = \mathbb{N}_0$.

(b) Hier wählen wir Ω als die Menge aller wahlberechtigten Bürger in der Schweiz und $S = \mathbb{R}_+ \times P$, wobei P die Menge aller wählbarer Parteien ist und durch $\mathbb{R}_+$ die Angabe des Jahreseinkommens erfolgt. $X(\omega)$ ordnet dem Wahlberechtigten Bürger sein Jahreseinkommen und die von ihm gewählte Partei zu.

(c) Wir wählen Ω als die Liste der Anzahl der jährlichen Straftaten in Hagen seit 1980. Die Elemente dieser Liste sind natürliche Zahlen und Null. Die Abbildung X_i ordne der Liste den i-ten Eintrag zu. Der Wertebereich jeder dieser Abbildungen ist $S = \mathbb{N}_0$.

Es sei bemerkt, dass andere Wahlen von Ω und damit von X und S möglich sind.

Aufgabe 2.2.3

(a)	MENDEL	Nominalskala
(b)	Muscheln	Verhältnisskala
(c)	Schulfragebogen	Abhängig von der jeweiligen Frage
1)	Alter in Jahren	Ordinalskala
2)	Geschlecht	Nominalskala
3)	Kurs/ Klasse	Nominalskala
4)	Letzte Zeugnisnote in Mathematik	Ordinalskala
5)	Studienwunsch	Nominalskala
6)	Berufswunsch	Nominalskala
7)	Selbsteinschätzung der Mathematiknote	Ordinalskala
8)	Qualitätsnote des Mathematikunterrichts	Ordinalskala
9)	Arbeitsstunden außerhalb des Mathematikunterrichts	Verhältnisskala
10)	Nachhilfeunterricht in Mathematik	Ordinalskala
11)-17)	Bewertungen von 1 bis 10	Intervallskala
(d)	Urliste	Abhängig von der jeweiligen Frage
(G)	Geschlecht	Nominalskala
(Gr)	Körpergröße in cm	Verhältnisskala
(Ge)	Körpergewicht in kg	Verhältnisskala
(H)	Haarfarbe	Nominalskala
(e)	Mortalität in Deutschland während der industriellen Revolution	Absolutskala
(f)	(zweites Studienfach, Zeit für das zweite Studienfach)	(Nominalskala, Verhältnisskala)
(g)	Bundestagswahl 2005	Absolutskala
(i)	Verteilung der Abiturnoten	Absolutskala

Aufgabe 2.2.4

Windstärke: Die Windstärke ist nach BEAUFORT wie folgt definiert.

Windstärke nach BEAUFORT	0	1	2	3	4	5
Windgeschwindigkeit in m/s	0 - 0,2	0,3 - 1,5	1,6 - 3,3	3,4 - 5,4	5,5 - 7,9	8,0 - 10,7

Die Windstärke nach BEAUFORT ist ordinal skaliert.

Stärke eines Erdbebens: Dies ist eine Verhältnisskala, da sie entworfen wurde, um die Stärke von Erdbeben zu vergleichen.

Klausurnote: Bereits in der Beschreibung der Ordinalskala wurde dies als Beispiel genannt.

Schuhgröße: Die französischen Schuhgrößen (Pariser Stich) sind proportional skaliert. Ein Stich (eine Größe) entspricht 2/3 Zentimeter. Hingegen ist die amerikanische Schuhgröße nur intervall skaliert. Sie beginnt mit der französischen Größe 15, also bei 10 cm, mit 0. Pro Schuhgröße kommt ungefähr ein Drittel Inch, genau 0.846 cm, hinzu. Im Gegensatz zur französischen Schuhgröße gibt es bei der amerikanischen auch halbe Größen (z.B. 10 1/2).

Stromstärke: Es gibt eindeutig einen Nullpunkt. Außerdem kann man Verhältnisse betrachten und Quotienten bilden. In diesem Fall liegt eine Verhältnisskala vor.

Autofarbe: Die Farben haben keinerlei Gewichtung oder Ordnung. Autofarben sind nominal skaliert.

Polizeidienstgrade: Wer bei der Bundeswehr war sieht sofort ein, dass Polizeidienstgrade ebenfalls ordinal skaliert sind. Alle anderen machen sich klar, dass durch die Dienstgrade eine Hierarchie beschrieben wird.

Aufgabe 2.2.6

Zeigen Sie, dass die affin-linearen Funktionen niveauerhaltende Transformationen zwischen Messfunktionen von Intervallskalen sind.

Man betrachte die affin-lineare Funktion $f : \mathbb{R} \to \mathbb{R}$, $x \mapsto f(x) := s\,x + t$, wobei $s, t \in \mathbb{R}$ und $s \neq 0$ sind. Man muss zeigen, dass für alle $a, b, c, d \in \mathbb{R}$ gilt:

$$\text{Aus } a - b = c - d \text{ folgt } f(a) - f(b) = f(c) - f(d).$$

Es ergeben sich folgende Äquivalenzumformungen.

$$\begin{aligned} a - b = c - d \quad &\Leftrightarrow \quad f(a-b) = f(c-d) \\ &\Leftrightarrow \quad s(a-b) + t = s(c-d) + t \\ &\Leftrightarrow \quad sa - sb + t = sc - sd + t \\ &\Leftrightarrow \quad sa + t - sb - t = sc + t - sd - t \\ &\Leftrightarrow \quad f(a) - f(b) = f(c) - f(d). \end{aligned}$$

Untersuchen Sie, welche Transformationen bei Verhältnisskalen und bei Absolut-

skalen niveauerhaltend sind.

Im Fall einer Verhältnisskala kann man den Quotienten zweier Merkmalsausprägungen sinnvoll interpretieren. Bei einer Transformation der Skala sollte sich der Quotient nicht verändern. Wenn man in Zentimetern gemessen doppelt so groß ist wie eine andere Person, dann gilt dies auch in Metern. Ein Quotient ändert seinen Wert nicht, wenn gekürzt oder erweitert wird. Somit sind alle Funktionen der Form $f : \mathbb{R} \to \mathbb{R}$, $x \mapsto f(x) := rx$, $r \neq 0$, niveauerhaltend.

Bei einer Absolutskala sind der Nullpunkt und die Einheit, in der gemessen wird, festgelegt also keinerlei Veränderungen möglich. Somit kommt nur die identische Abbildung $f : \mathbb{R} \to \mathbb{R}$, $x \mapsto f(x) := x$ als Transformation in Frage.

Lösungen der Aufgaben in 2.3

Aufgabe 2.3.12

Zunächst sei daran erinnert, dass nach Definition jede relative Häufigkeit $r_i = r(x_i^*)$ nicht-negativ ist. Damit ist auch eine Summe von relativen Häufigkeiten nicht-negativ. Da nun alle relativen Häufigkeiten nicht-negativ sind, wird die relative Summenhäufigkeit $\sum_{i:x_i^* \leq x_k^*} r_i$ für die größte auftretende Merkmalsausprägung maximal, da dann über so viele Summanden wie möglich summiert wird. Diese relative Summenhäufigkeit ist 1, da die Summe aller absoluten Häufigkeiten gleich der Anzahl der Merkmalsträger ist.

Aufgabe 2.3.16

Das Benford-Gesetz besagt, dass für die Wahrscheinlichkeit p_n des Auftretens einer Zahl $n \in \{1, ..., 9\}$ als führende Ziffer gilt

$$p_n = \log_{10}(n+1) - \log_{10}(n) = \log_{10}\left(1 + \frac{1}{n}\right).$$

Diese Werte wurden in der Aufgabenstellung tabelliert. Die Herleitung für dieses Gesetz geben wir an dieser Stelle nicht an.

Aufgabe 2.3.23

Im ersten Satz ist von 235 Studierenden die Rede. $235 - 7 - 45 - 89 = 94$ Studierende wurden bis zum Ende des Satzes noch nicht beschrieben. Sie können entweder Studierende sein, die die Prüfung direkt bestanden haben oder aber noch nie bestanden haben. Im nächsten Satz ist von 60 Studierenden die Rede, die beim ersten Mal bestanden haben. Die verbleibenden waren nie angemeldet. Man kann ein Kreisdiagramm mit 235 Studierenden anlegen, das Studierende beinhaltet, die

mindestens einmal durchgefallen sind. Man kann ein Stabdiagramm mit $235 - 34$ Studierenden anlegen, um zu zeigen, wie der Ausfall aller Studierender ist, die bereits an der Prüfung teilgenommen haben. Man könnte ein Stabdiagramm verwenden, und die 201 Teilnehmer der Prüfung und die 34 bisherigen nicht gemeldeten Studierenden gegenüberstellen.

Kapitel 3

Kenngrößen und Verteilungen

Im vorangegangenen Kapitel erfolgten erste Reduktionen und Darstellungen von Datenreihen. Die Datenreduktion basierte dabei auf der Bestimmung von Häufigkeiten. In diesem Kapitel führen wir einige interessante Kennzahlen/Werte (statistische Maßzahlen) zu erhobenen Stichproben ein. Dabei werden wir *Lagemaße (Lageparameter)* von *Streumaßen (Streuungsparameter)* unterscheiden. Lagemaße sind so etwas wie die Mitte, der Durchschnitt oder der Schwerpunkt einer Stichprobe. Streumaße geben, wie der Name es schon verrät, Auskunft über die Streuung eines Merkmals. Mittels der Lage- und Streumaße werden wir im Anschluss weitere informative graphische Darstellungen vorstellen (Boxplot, Perzentialband).

3.1 Lagemaße und weitere Mittelwerte

Die Wahl des Lageparameters hängt vom Skalenniveau der zugrundeliegenden Daten ab. Bei Abstimmungen nach dem Mehrheitswahlrecht interessiert, wer die meisten Stimmen hat. Bei Leistungsuntersuchungen interessiert der mittlere Leistungswert, der die besseren von den schlechteren Teilnehmern unterscheidet. Im Bereich Wirtschaft interessieren durchschnittliche Zinserträge, u.s.w.

Liegt ein nominal skaliertes Merkmal vor, so gilt der Wert als typisch, der die höchste absolute Häufigkeit und damit die höchste relative Häufigkeit aufweist. Dieser Wert heißt *Modalwert*. Dieser Wert ist nicht eindeutig bestimmt (zum Beispiel bei einem Stimmenpatt zweier oder mehrerer zur Wahl stehender Kandidaten).

3.1.1 Definition: Gegeben sei eine Stichprobe $x = (x_1, \ldots, x_n)$. Der Wert x_i

heißt *Modalwert* oder *Modus* der Stichprobe, wenn gilt:

$$h(x_i) \geq h(x_j) \quad \text{für alle} \quad 1 \leq j \leq n.$$

Dabei bezeichnet $h(x_i)$ die absolute Häufigkeit des Vorkommens der Merkmalsausprägung x_i.

Der Modalwert lässt sich somit für alle Skalenniveaus bestimmen.

Wir betrachten nun Daten eines ordinal skalierten Merkmals. Hier lassen sich die Daten ordnen. Bei einer Klausur zur Stochastikvorlesung kann man einen „Klausurwert“ für die Studierenden finden: Die erreichten Klausurpunkte werden der Größe nach geordnet. Der Klausurwert ist dann so erklärt, dass sich durch ihn die 50 % „guten“ von den 50 % „schlechten“ Studierenden trennen lassen (was zumindest sprachlich als eine Zumutung angesehen werden darf).

3.1.2 Beispiel: In einem Betrieb liegen die folgenden Brutto-Monatseinkommen in EURO vor:

$$x = (1200, 1580, 1370, 6000, 1800, 1650, 950).$$

Ordnet man diese Stichprobe, so steht $x_2 = 1580$ in der Mitte der Stichprobe. Es gibt aber nicht immer nur einen Wert, der in der Mitte liegt: im Datensatz

$$x = (11, 12, 15, 19, 20, 24, 25, 25, 32, 33, 35, 37)$$

kommen 24 und 25 als Mitte in Frage (es liegt eine gerade Anzahl von Daten vor).

3.1.3 Definition: Wir betrachten eine Stichprobe $x = (x_1, \ldots, x_n)$ einer ordinal skalierten Merkmalsausprägung. Jeder Wert $\widetilde{x}$ aus dem Stichprobenraum, für den mindestens die Hälfte der Daten kleiner oder gleich $\widetilde{x}$ ist und auch mindestens die Hälfte der Daten größer oder gleich $\widetilde{x}$ ist, heißt *Median* (oder *Zentralwert*). $\widetilde{x}$ ist genau dann Median der Stichprobe, wenn gilt

$$\sum_{x \geq \widetilde{x}} r(x) \geq 0.5 \quad \text{und} \quad \sum_{x \leq \widetilde{x}} r(x) \geq 0.5.$$

Dabei bezeichnet $r(x)$ die relative Häufigkeit des Vorkommens der Merkmalsausprägung x.

Bezeichnen wir die zu $x = (x_1, \ldots, x_n)$ gehörige geordnete Stichprobe mit $(x_{[1]}, \ldots, x_{[n]})$, so gilt

$$\widetilde{x} = \begin{cases} x_{[\frac{n+1}{2}]}, & \text{falls } n \text{ ungerade,} \\ x_{[\frac{n}{2}]} \text{ oder } x_{[\frac{n}{2}+1]}, & \text{falls } n \text{ gerade.} \end{cases}$$

3.1.4 Beispiel: In einer Umfrage in der Hagener Innenstadt wurde gefragt, ob und wie häufig im Monat die Personen im Internet eine Onlineüberweisung durchführen. Von 500 Befragten haben 285 noch nie eine Onlineüberweisung getätigt. 116 Personen gaben an, zwischen 6 bis 10 Überweisungen pro Monat in dieser Form durchzuführen, die restlichen Personen zwischen 1 und 5 Überweisungen. Der Median der Anzahl der Onlineüberweisungen ist $\widetilde{x} = 0$, denn es sind mindestens die ersten 250 Zahlen kleiner oder gleich Null.

Soll der Median für ein quantitatives Merkmal bestimmt werden, so wählen wir für ein gerades n eine alternative Definition. Wir lassen nicht die freie Wahl zwischen $x_{[\frac{n}{2}]}$ und $x_{[\frac{n}{2}+1]}$, sondern wählen das arithmetische Mittel dieser Werte:

3.1.5 Definition: Zu einer quantitativen Stichprobe $(x_1, \ldots, x_n)$ bezeichne $(x_{[1]}, \ldots, x_{[n]})$ die geordnete Stichprobe. Dann ist der *Median* der Stichprobe definiert durch

$$\widetilde{x} := \begin{cases} x_{[\frac{n+1}{2}]}, & \text{falls } n \text{ ungerade,} \\ \frac{x_{[\frac{n}{2}]}+x_{[\frac{n}{2}+1]}}{2}, & \text{falls } n \text{ gerade.} \end{cases}$$

Diese zweite Wahl der Definition des Medians kann dazu führen, dass der Wert des Medians als Merkmalsausprägung gar nicht gemessen werden kann (so bei Ausprägungen aus $\mathbb{N}$, etwa bei der Zuordnung: 0 entspricht *kein Schulabschluss*, 1 *Hauptschulabschluss*, 2 *Fachhochschulreife*, 3 *Abitur*; der Median 3/2 hat keine inhaltliche Bedeutung). Im folgenden müssen wir darauf achten, welche Definition des Medians wir verwenden. Die Vereinbarung soll sein, dass bei quantitativen Merkmalen Definition 3.1.5 verwendet wird.

Da ein Median in der Mitte der Datenreihe liegt, hat er die folgende plausible Eigenschaft: die Summe der Abstände zu den anderen Daten auf der reellen Zahlengerade ist minimal. Diese Minimumeigenschaft des Medians werden wir später genau formulieren und beweisen (siehe 3.2.4). Sie basiert auf der Möglichkeit, dass man Abstände messen kann, also ein metrisch skaliertes Merkmal vorliegt. Es ist einfach zu sehen, dass $\widetilde{ax+b} = a\widetilde{x} + b$, $a, b \in \mathbb{R}$, gilt, denn diese Transformation ändert die Zahlenwerte, aber nicht die relative Häufigkeiten.

Wir betrachten nun quantitative Merkmale und erinnern an die jedem geläufige Definition des arithmetischen Mittelwertes.

3.1.6 Definition: Wir betrachten eine Stichprobe $x = (x_1, \ldots, x_n)$ einer metrisch

skalierten Merkmalsausprägung. Dann heißt

$$\bar{x} := \frac{x_1 + \cdots + x_n}{n} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

der *empirische Mittelwert* oder das *arithmetische Mittel* der Stichprobe x. Kommen die verschiedenen Merkmale $x_1^*, x_2^*, \ldots, x_N^*$ mit Häufigkeiten $h_1, \ldots, h_N$ vor, so ist

$$\bar{x} = \frac{1}{n} \sum_{k=1}^{N} h_k x_k^* \,.$$

3.1.7 Bemerkung: Manchmal ist von x weder die Urliste noch die Häufigkeitstabelle bekannt, wohl aber eine Klasseneinteilung. Bezeichnet c_k die k-te Klassenmitte, so wählt man für das arithmetische Mittel den Näherungswert

$$\frac{1}{n} \sum_{k=1}^{N} h_k \, c_k.$$

3.1.8 Aufgabe: Bestimmen Sie die Anzahl der Teiler der Zahlen von 1 bis 50 und erstellen Sie ein Stamm-Blatt-Diagramm. Welche Zahlen haben eine ungerade Anzahl von Teilern? Gibt es überhaupt keine Zahl mit 7 Teilern? Welche Zahlen haben viele Teiler? Es sei Q_n die Menge der Quadratzahlen $\leq n$. Was ist die mittlere Anzahl der Teiler der Zahlen in $\{1, 2, \ldots, n\} \setminus Q_n$?

3.1.9 Beispiele: In Beispiel 3.1.2 ergibt sich ein durchschnittliches Einkommen von $\bar{x} = 2078.57$ EURO. Sechs Angestellte erhalten weniger als $\bar{x}$. Der empirische Mittelwert $\bar{x}$ wird durch den *Ausreißer* 6000 EURO (Gehalt des Inhabers?) stark beeinflusst. Der Modalwert und der Median sind gegenüber diesem Ausreißer robuster. In Beispiel 3.1.4 ergibt sich $\bar{x} = 2.45$ (wir verwenden die Klassenmitten 3 und 8); im Durchschnitt hat also jeder Befragte etwas mehr als sechsmal eine Online-Überweisung getätigt. Durch diesen Wert fühlen sich in Wahrheit nur wenige Personen vertreten. Der Median ist erneut vorzuziehen, aber auch nicht sehr aussagekräftig. Es ist ein wenig zu viel verlangt, durch die Angabe einer einzigen Kennzahl eine inhaltsreiche Aussage über die Stichprobe erhalten zu können.

Die Identität $\sum_{i=1}^{n} x_i = n\,\bar{x}$ besagt, dass man mit dem arithmetischen Mittel und der Anzahl der Daten die Summe der Daten kennt und umgekehrt die Kenntnis der Summe der Daten ausreicht, um das arithmetische Mittel zu bestimmen. Ändert man einen Wert, so ändert sich auch das arithmetische Mittel.

Es gilt, dass die Summe der Abstände des arithmetischen Mittels zu den links von ihm gelegenen Daten genauso groß ist wie die Summe der Abstände zu den rechts von ihm gelegenen Daten. Dies ist der Inhalt des Satzes:

3.1.10 Satz: (Schwerpunkteigenschaft des arithmetischen Mittels) Für ein quantitatives Merkmal sei die Stichprobe $x = (x_1, \ldots, x_n)$ mit arithmetischem Mittel $\bar{x}$ gegeben. Dann gilt:

$$\sum_{i=1}^{n} (x_i - \bar{x}) = 0.$$

3.1.11 Aufgabe: Beweisen Sie Satz 3.1.10.

Für das arithmetische Mittel gelten die folgenden einfachen Aussagen:

3.1.12 Satz: Alle vorkommenden Daten seien quantitativ skaliert (sie liegen also in $\mathbb{R}$).

(i) Gegeben sei eine Stichprobe y_1 mit n_1 Daten, eine Stichprobe y_2 mit n_2 Daten, ..., eine Stichprobe y_M mit n_M Daten und jeweils arithmetischen Mittel $\bar{y}_1, \ldots, \bar{y}_M$ gegeben, so ist das arithmetische Mittel der aus den Stichproben $y_1, \ldots, y_M$ zusammengesetzten Stichprobe x gegeben durch

$$\bar{x} = \frac{n_1 \bar{y}_1 + n_2 \bar{y}_2 + \cdots + n_M \bar{y}_M}{n_1 + \cdots + n_M}.$$

(ii) Zu der Stichprobe $x = (x_1, \ldots, x_n)$ sei $y = ax + b = (ax_1 + b, \ldots, ax_n + b)$ mit $a, b \in \mathbb{R}$. Dann gilt $\bar{y} = \overline{ax + b} = a\bar{x} + b$.

(iii) Seien $x = (x_1, \ldots, x_n)$ und $y = (y_1, \ldots, y_n)$ Stichproben. Zu $z = (z_1, \ldots, z_n)$ mit $z_i := ax_i + by_i$ ist $\bar{z} = a\bar{x} + b\bar{y}$.

3.1.13 Aufgabe: Beweisen Sie Satz 3.1.12.

3.1.14 Beispiel: Wir betrachten ein Beispiel, bei dem Satz 3.1.12(ii) zur Anwendung kommt.

x_k^*	4013	4026	4039	4052	4065	4078
h_k	3	4	5	2	3	3
$x_k^* - 4000$	13	26	39	52	65	78
$y_k^* = \frac{x_k^* - 4000}{13}$	1	2	3	4	5	6
$y_k^* h_k$	3	8	15	8	15	18

Die Transformation ermöglicht eine einfachere Bestimmung des arithmetischen Mittels:

$$\bar{y} = \frac{67}{20} = 3.35; \quad x = 13y + 4000$$
$$\Rightarrow \bar{x} = 13\bar{y} + 4000 = 4043.55\,.$$

Bei einer „symmetrischen“ Stichprobe stimmen Mittelwert und Median überein. Der ausgleichende Mittelwert scheint um so weniger geeignet, je weniger „ausgeglichen“ die Verteilung ist.

Man interessiert sich nicht nur für „die Mitte“ im Sinne der bisher eingeführten Kennzahlen *Modalwert, Median, arithmetisches Mittel*. Man möchte zum Beispiel die zur Verfügung gestellte Zeit bei einer Stochastikklausur sinnvoll planen. Ein erklärtes Ziel kann sein, ungefähr 95 % der Studierenden ausreichend Zeit zu geben. Die Wahl des arithmetischen Mittels oder Medians vorliegender Bearbeitungszeiten wäre sicher nicht fair. Der Median teilt eine Gruppe in zwei gleichgroße Teilgruppen. Eine gewünschte Gruppenaufteilung in eine Teilgruppe mit 5 % (die langsamen Studierenden) und die andere mit 95 % der Teilnehmer führt uns zu der folgenden Definition:

3.1.15 Definition: Für ein ordinal skaliertes Merkmal sei eine bereits geordnete Stichprobe $\langle x \rangle = (x_{[1]}, \ldots, x_{[n]})$ gegeben. Dann heißt für $p \in [0,1]$ ein Wert $x_{[k]}$ für den $\sum_{x \geq x_{[k]}} r(x) \geq 1 - p$ und $\sum_{x \leq x_{[k]}} r(x) \geq p$ gilt, ein *p-Quantil* der Stichprobe. Der Median in Definition 3.1.3 ist das 1/2-*Quantil*.

Es gilt:

3.1.16 Satz: In der Situation der Definition 3.1.15 ist für $p \in [0,1]$ ein p-Quantil x_i bestimmt durch

$$i := p\,n \text{ oder } i := p\,n + 1, \text{ falls } p\,n \in \mathbb{N} \text{ bzw. } i := \lfloor p\,n \rfloor + 1, \text{ falls } p\,n \notin \mathbb{N}.$$

Hierbei bezeichnet $\lfloor p\,n \rfloor$ die Gauss-Klammer, also die größte ganze Zahl, die kleiner oder gleich $p\,n$ ist.

3.1.17 Aufgabe: Beweisen Sie Satz 3.1.16.

Alternativ nennt man p-Quantile auch *Perzentile*. Weiterhin sind die folgenden Bezeichnungen üblich: Das 0.25-Quantil heißt *erstes Quartil* oder *unteres Quartil*, dass 0.5-Quantil das *zweites Quartil* (das ist der Median), das 0.75-Quantil das *drittes Quartil*. Das 0. Quartil ist das Minimum und das 4. Quartil das Maxiumum der Stichprobe. Beim 0.1-Quantil spricht man vom *ersten Dezil*.

Mittelwerte sollen die Lage der Daten beschreiben. Werden alle Daten einer Stichprobe um einen festen Wert t verschoben, so sollte ein Mittelwert sich auch um t verschieben. Wir wollen diejenigen Kennzahlen, die dies erfüllen, Lagemaße nennen:

3.1.18 Definition: Ein *Lagemaß* ist eine Abbildung $L : \mathbb{R}^n \to \mathbb{R}$ mit der Eigenschaft, dass für alle $t \in \mathbb{R}$ und alle $(x_1, \ldots, x_n) \in \mathbb{R}^n$ gilt:

$$L(x_1 + t, \ldots, x_n + t) = L(x_1, \ldots, x_n) + t.$$

Wir haben in Satz 3.1.12(ii) bereits bewiesen, dass das arithmetische Mittel ein Lagemaß ist. Auch der Median ist ein Lagemaß, wie bereits diskutiert wurde. Es gilt:

3.1.19 Satz: Der Modalwert, das arithmetische Mittel und die p-Quantile sind Lagemaße.

3.1.20 Aufgabe: Beweisen Sie Satz 3.1.19.

Es gibt einen weiteren Vertreter aus der Gruppe der Lagemaße, das so genannte α-getrimmte Mittel. Dazu sei $(x_{[1]}, \ldots, x_{[n]})$ eine geordnete Stichprobe, dann ist

$$x_{t,\alpha} := \frac{1}{n-2k} \sum_{j=k+1}^{n-k} x_{[j]}$$

das *α-getrimmte Mittel*, wobei $0 < \alpha < 1/2$ und $k := \lfloor n\,\alpha \rfloor$.

Für quantitative Merkmale gibt es noch weitere Mittelwertbildungen, die in der Praxis vorkommen. Das arithmetische Mittel ist nicht immer ein angemessener Mittelwert zur Charakterisierung der Daten (ebensowenig der Modalwert oder ein p-Quantil). Wir betrachten dazu ein Beispiel:

3.1.21 Beispiel: Wir betrachten die Bevölkerungsentwicklung in einer Stadt.

	1988	1989	1990	1991	1992
# Bev.:	100000	150000	195000	214500	257400
Zuwachsrate		50%	30%	10%	20%

Die Zuwachsrate bezieht sich auf das vorangegangene Jahr als Basisjahr. Die Frage ist nun, um wieviel % die Bevölkerung im Durchschnitt gewachsen ist? Der naive Ansatz ist die Bestimmung des arithmetischen Mittels der Zuwachsraten $\bar{x} = 27.5\%$. Doch man sieht einfach, dass man einen wenig geeigneten Mittelwert betimmt hat, denn bei einer jährlichen Zuwachsrate von 27.5% erhält man im Jahr 1992 bereits 264 264 Bewohner, also 6 864 mehr. Das arithmetrische Mittel ist zu groß. Es ist bei der Verwendung des arithmetrischen Mittels nicht beachtet worden, dass die Raten verschiedene Bezugspunkte haben. 50% bezieht sich auf 100 000

Einwohner, 30% auf den Ausgangswert 150 000 (1989: 1.5 mal 100 000 Einwohner), 20% beziehen sich dann auf 214 000, u.s.w.. Der gesamte Wachstumsprozess wird also durch $1.5 \cdot 1.3 \cdot 1.1 \cdot 1.2 = 2.574$ beschrieben. Gesucht ist also eine Zahl g mit $g^4 = 2.574$, also $g = \sqrt[4]{2.574} = 1.26664$. Die durchschnittliche Wachstumsrate beträgt somit 26.664%. („Probe“ : $100\,000 \cdot 1.26664^4 = 257402.5$; eine Abweichung von 3 Personen, was durch Rundungsfehler zu erklären ist).

$$g := \sqrt[4]{1.5 \cdot 1.3 \cdot 1.1 \cdot 1.2}$$

heißt das *geometrische Mittel.*

Diese Mittelwertbildung tritt bei Wachstumsprozessen auf, also etwa bei der Frage nach der durchschnittlichen Wachstumsrate des Bruttosozialprodukts oder bei der Bestimmung durchschnittlicher Zinssätze.

3.1.22 Definition: Gegeben seien Daten $x = (x_1, \ldots, x_n)$ eines quantitativen Merkmals auf einer Verhältnisskala mit $x_i \geq 0$ für $i = 1, \ldots, n$. Dann heißt

$$\bar{x}_g := \sqrt[n]{\prod_{i=1}^{n} x_i}$$

das *geometrische Mittel* der Daten $x_1, \ldots, x_n$.

Da hier multipliziert wird, benötigen wir die Verhältnisskala. Gleiche Verhältnisse sollen die gleiche Bedeutung haben. Für die Bestimmung des arithmetischen Mittels genügte die Wahl eines Intervallniveaus.

Der Begriff geometrisches Mittel erklärt sich so: Nach dem *Höhensatz des* EUKLID *von* ALEXANDRIA (um 300 v. Chr.) gilt in einem rechtwinkligen Dreieck $z = \sqrt[2]{xy}$

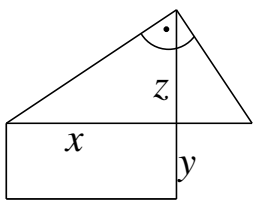

Alternativ ist zu einem Rechteck mit Seitenlängen x und y das Quadrat mit der Seitenlänge $\sqrt{x\,y}$ das einzige flächengleiche Quadrat.

Wir motivieren eine weitere Art der Mittelwertbildung durch das folgende Beispiel:

3.1.23 Beispiel: Ein Zug fährt die ersten 100 km mit einer Geschwindigkeit von 70 km/h, die zweiten 100 km mit 110 km/h. Wie groß ist die Durchschnittsgeschwindigkeit? Die ersten 100 km legt der Zug in 100/70 h zurück, die zweiten in 100/110 h. Die Gesamtfahrzeit beträgt somit $180/77\,h \approx 2.34\,h$. Für die Durchschnittsgeschwindigkeit erhält man damit:

$$200 : \frac{180}{77}\,km/h \approx 85.56\,km/h.$$

Wenn wir diese Rechnung etwas anders notieren, so haben wir die folgende Mittelwertbildung durchgeführt:

$$\bar{x}_h = \frac{200}{\frac{100}{70} + \frac{100}{110}} = \frac{2}{\frac{1}{70} + \frac{1}{110}}.$$

Das arithmetische Mittel ist 90 km/h. Dann würde der Zug 210.6 km zurücklegen. Auch das geometrische Mittel wäre nicht angebracht. Eine ähnliche Aufgabe ist die Bestimmung eines Durchschnittspreises. Ein Hausbesitzer kauft zu drei verschiedenen Zeitpunkten für 100 EURO Heizöl. Die Preise pro Liter waren 0.25 EURO/l, 0.4 EURO/l, 0.5 EURO/l. Wieviel EURO hat im Durchschnitt 1 Liter Heizöl gekostet?

3.1.24 Definition: Für ein quantitatives Merkmal, das auf einer Verhältnisskala gemessen wurde, sei eine Stichprobe $x = (x_1, \ldots, x_n)$ mit $x_i > 0$ für $i = 1, \ldots, n$ gegeben. Dann heißt

$$\bar{x}_h := \frac{1}{\frac{1}{n}\left(\frac{1}{x_1} + \cdots + \frac{1}{x_n}\right)} = \frac{n}{\sum_{i=1}^{n} \frac{1}{x_i}}$$

das *harmonische Mittel* der Daten $x_1, \ldots, x_n$.

3.1.25 Aufgabe: Machen Sie sich klar, dass das geometrische und das harmonische Mittel keine Lagemaße sind, $n \geq 2$.

Warum heißt das harmonische Mittel so? Es hat in der Musik eine besondere Bedeutung für harmonische Töne: Man möchte bei einer Saite denjenigen Ton, dessen Frequenz das arithmetische Mittel der Frequenzen zweier Töne ist, erzeugen. Dazu muss man die Saite an der Stelle abgreifen, die dem harmonischen Mittel der entsprechenden Stellen für die Ausgangstöne entspricht. Die Frequenzen sind umgekehrt proportional zur Länge des schwingenden Teils der Seite. Ein Beispiel: Die reine Quinte ist das arithmetische Mittel aus Grundton und Oktave. Man greift $2/(\frac{1}{1} + \frac{1}{1/2}) = 2/3$ der Saite ab. Weiter gilt: Soll ein Tonintervall $b : a$ durch die

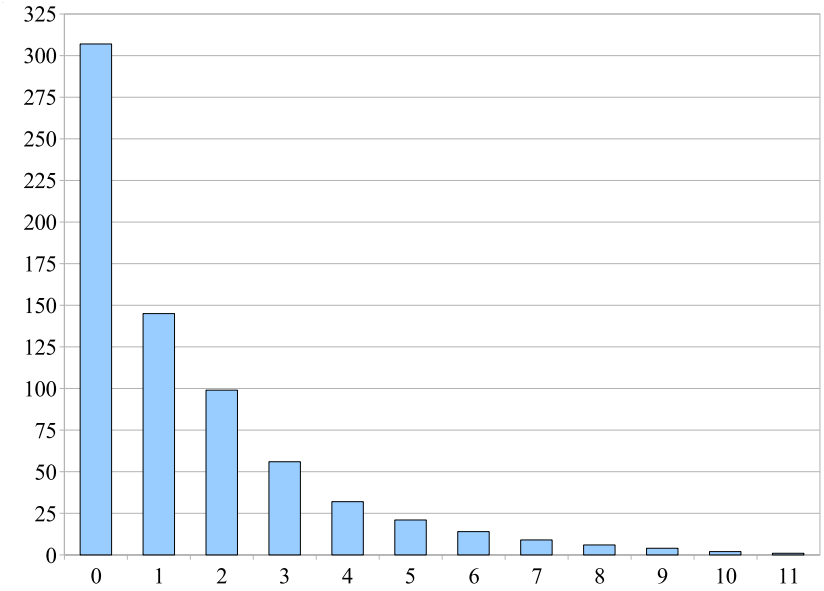

Abb. 3.1: Linksschiefe Verteilung

Frequenz c so geteilt werden, dass $b : c$ und $c : a$ übereinstimmen, so ist für c das geometrische Mittel von a und b zu wählen (Oktave $b : a = 2 : 1$). Das Intervall $\sqrt{2} : 1$ entspricht bei temperierter Stimmung dem Tritonus (=verminderte Quinte) (Dissonanz).

Wie verhalten sich die bisher dargestellten fünf Konzepte der Lagemaß- und Mittelwertbildung zueinander? Kann man die Kennzahlen vergleichen? Wir betrachten das Säulendiagramm in Abbildung 3.1. In einer Stichprobe von 696 Erwachsenen wurde nach der Kinderzahl gefragt.

Hier ist der Modalwert 0, der Median $\tilde{x} = 1$ und das arithmetische Mittel $\bar{x} \approx 1.45$. Es gilt also

$$x_{\text{mod}} \leq \tilde{x} \leq \bar{x}.$$

Man nennt die Verteilung solcher Daten *linksschief*, da der Schwerpunkt der Daten links liegt. Analog spricht man bei $x_{\text{mod}} \geq \tilde{x} \geq \bar{x}$ von *Rechtsschiefe*, bei $x_{\text{mod}} \approx \tilde{x} \approx \bar{x}$ von *Symmetrie*.

Wie verhalten sich arithmetisches, geometrisches und harmonisches Mittel zueinander? Im Fall $n = 2$ (aus Sicht der Datenerhebung nicht so interessant) kann man auf geometrischem Wege das folgende feststellen bzw. herleiten:

n=2: $\dfrac{a+b}{2}$ arithmetrisches Mittel

$\sqrt{ab}$ geometrisches Mittel

$\dfrac{2ab}{a+b} = \dfrac{2}{\frac{1}{a}+\frac{1}{b}}$ harmonisches Mittel

Im rechtwinkliges Dreieck ABC mit der Hypothenuse $a+b$ gilt:

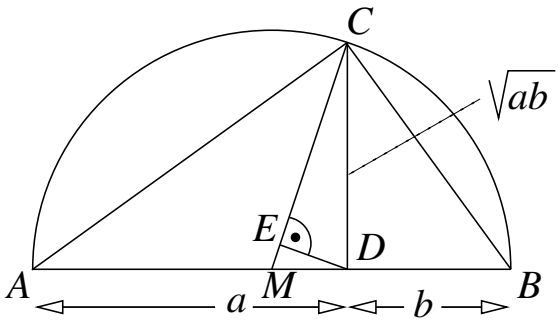

Abb. 3.2: Zeichnerische Darstellung des harmonischen und geometrischen Mittel

$$\begin{array}{llcll} \text{Hypotenuse } a+b: & \overline{MC} & = & (a+b)/2 & \text{(siehe Zeichnung)} \\ & \overline{CD} & = & \sqrt{ab} & \text{(siehe den Höhensatz von Euklid)} \\ & \overline{CE} & = & \dfrac{2ab}{a+b} & \end{array}$$

Die Tatsache, dass $\overline{CE}$ das harmonische Mittel darstellt, benötigt ein paar elementargeometrische Überlegungen.

Aus der Zeichnung (Abbildung 3.2) folgt nun:

$$\frac{2ab}{a+b} < \sqrt{ab} < \frac{a+b}{2}\,.$$

Wir formulieren dies als Satz:

3.1.26 Satz: $a > 0$, $b > 0$, $a, b \in \mathbb{R}$:

$$\frac{2ab}{a+b} \leq \sqrt{ab} \leq \frac{a+b}{2}\,.$$

Beweis: Die zweite Ungleichung sieht man mittels einfach Äquivalenzumformungen wie folgt: $(a-b)^2 \geq 0 \Leftrightarrow a^2 - 2ab + b^2 \geq 0$, und dies ist äquivalent zu

$$a^2 + 2ab + b^2 \geq 4ab. \tag{3.1}$$

Für $a > 0$ und $b > 0$ ist dies äquivalent zu $(a+b)^2 \geq 4ab$, also zu $\frac{a+b}{2} \geq \sqrt{ab}$. Die erste Ungleichung folgt, da (3.1) äquivalent ist zu $(a+b)^2 \geq \frac{(2ab)^2}{ab}$, und somit $\sqrt{ab} \geq \frac{2ab}{a+b}$. □

Es gilt ganz allgemein:

3.1.27 Satz: Zu $x = (x_1, \ldots, x_n)$ mit $x_i > 0$ für $i = 1, \ldots, n$ ist

$$\bar{x}_h \leq \bar{x}_g \leq \bar{x}\,.$$

Wir wollen diesen Satz via Induktion beweisen:

Beweis: Ist die rechte Ungleichung bewiesen, folgt die linke sofort, indem man $(x_1, \ldots, x_n)$ durch $(1/x_1, \ldots, 1/x_n)$ ersetzt und den Kehrwert bildet. Sei $A(x) := \bar{x}$ und $G(x) := \bar{x}_g$, so ist $A(\lambda x) = \lambda A(x)$ und $G(\lambda x) = \lambda G(x)$ für $\lambda \geq 0$. Also kann ohne Einschränkung $A(x) = 1$ angenommen werden (machen Sie sich dies klar). Verschwindet ein x_i oder sind alle x_i gleich, so ist die Behauptung klar. Daher bleibt zusammenfassend zu zeigen:

Sind die x_i positiv und $x_1 + \cdots + x_n = n$ und gibt es ein $x_k \neq 1$, dann ist $x_1 \cdots x_n < 1$. Der Induktionsanfang $n = 1$ tritt nicht auf. Wir betrachten $n = 2$. Dann ist $x_1 = 1 + \epsilon$, $x_2 = 1 - \epsilon$ für ein $\epsilon > 0$, und somit $x_1 x_2 = 1 - \epsilon^2 < 1$, was die Behauptung ist.

Es folgt der Induktionsschluss von n auf $n+1$: Es seien $n+1$ positive Zahlen $x_0, x_1, \ldots, x_n$ mit

$$x_0 + x_1 + \cdots + x_n = n + 1$$

vorgegeben. Sei etwa $x_0 < 1$ und $x_1 > 1$, $x_0 = 1 - \alpha$, $x_1 = 1 + \beta$ mit $\alpha, \beta > 0$. Für $x_1' := x_0 + x_1 - 1 = 1 - \alpha + \beta$ gilt dann $x_1' + x_2 + \cdots + x_n = n$, also nach Induktionsvoraussetzung $x_1' x_2 \cdots x_n \leq 1$.

Wegen $x_0 x_1 = 1 - \alpha + \beta - \alpha\beta < x_1'$ ist $x_0 x_1 x_2 \cdots x_n < x_1' x_2 \cdots x_n \leq 1$. □

Die rechte Ungleichung in Satz 3.1.27 heißt auch *AGM-Ungleichung* (Arithmetisches/Geometrisches/Mittel) und hat viele schöne Anwendungen.

3.1.28 Korollar: Das Produkt von n nichtnegativen Zahlen mit konstanter Summe ist dann und nur dann am größten, wenn alle Faktoren gleich sind.

($n = 2$: Der Inhalt eines Rechtecks von gegebenem Umfang wird für das Quadrat am größten).

Wir wagen an dieser Stelle einen kurzen Ausflug in die Analysis. Hier hat die AGM-Ungleichung hübsche Anwendungen:

(a) Es seien $a \neq 1$, $n \geq 2$ und $p \in \{1, 2, \ldots, n\}$. Dann folgt aus der AGM-Ungleichung

$$\sqrt[n]{a^p} = \sqrt[n]{a^p \cdot \underbrace{1 \cdots 1}_{n-p \text{ mal}}} < \frac{pa + n - p}{n} = 1 + \frac{p}{n}(a-1)$$

die folgende Wurzelabschätzung:

$$\sqrt[n]{a} < 1 + \frac{a-1}{n}.$$

Hier gilt die strikt-kleiner-Relation, siehe Korollar 3.1.28.

(b) Es gilt für alle $n \in \mathbb{N}$: $\sqrt[n]{n} = (\sqrt{n} \cdot \sqrt{n} \cdot 1 \cdots 1)^{1/n} \leq \frac{2\sqrt{n}+n-2}{n} \leq 1 + \frac{2}{\sqrt{n}}$. Weiter gilt für $n \geq 1$: $\sqrt[n]{n} \geq 1$. Also folgt insgesamt

$$\lim_{n\to\infty} \sqrt[n]{n} = 1.$$

3.1.29 Aufgabe: Folgern Sie aus der AGM-Ungleichung für $x \geq -n$ und $x \neq 0$

$$\left(1 + \frac{x}{n}\right)^n < \left(1 + \frac{x}{n+1}\right)^{n+1}.$$

Beweisen Sie, dass $\lim_{n\to\infty}(1 + \frac{x}{n})^n$ existiert.

3.1.30 Aufgabe: Zu $a > 0$, $b > 0$ bezeichne $H(a,b) = \frac{2ab}{a+b}$ das harmonische Mittel und $G(a,b) = \sqrt{a\,b}$ das geometrische Mittel. Zu $0 < a_0 < A_0$ seien $a_{n+1} := H(a_n, A_n)$ und $A_{n+1} := G(a_n, A_n)$ induktiv definiert. Zeigen Sie:

$$\lim_{n\to\infty} a_n = \lim_{n\to\infty} A_n.$$

Wenn wir mit $A(x), G(x)$ und $H(x)$ das arithmetische, geometrische bzw. harmonische Mittel der Stichprobe $x = (x_1, \ldots, x_n)$ bezeichnen, so gilt

$$\left.\begin{matrix} G(x_1, \ldots, x_n) \\ H(x_1, \ldots, x_n) \end{matrix}\right\} = g^{-1}\Big(A(g(x_1), \ldots, g(x_n))\Big) \quad \text{mit} \quad g(x) = \begin{cases} \ln(x) \\ \frac{1}{x} \end{cases}$$

Häufig ist die Stichprobe $x = (x_1, \ldots, x_n)$ – als das Ergebnis einer experimentellen Bestimmung *eines* Wertes – eine Sammlung von Werten, die sich nur wenig von

einem gewissen Wert x unterscheiden. In diesem Fall kann man die Mittelwerte G und H linear approximieren mit der Konsequenz, dass sie sich kaum vom arithmetischen Mittel unterscheiden. Dies sieht man so: Es sei $x > 0$ und $x_i = x + \varepsilon_i$ mit kleinem $|\varepsilon_i|$, $i = 1, \ldots, n$. Weiter bezeichne r_i die relative Häufigkeit von x_i für jedes i. Verwenden wir die Taylor-Approximation

$$f(x + \varepsilon) = f(x) + \varepsilon f'(x) + R$$

für die Funktion $f(x) = x^r$, so folgt

$$\begin{aligned}
G(x_1, \ldots, x_n) &= (x + \varepsilon_1)^{r_1} \cdots (x + \varepsilon_n)^{r_n} \\
&\approx (x^{r_1} + r_1 \varepsilon_1 x^{r_1 - 1}) \cdots (x^{r_n} + r_n \varepsilon_n x^{r_n - 1}) \\
&= x\Big(1 + r_1 \varepsilon_1 \frac{1}{x}\Big) \cdots \Big(1 + r_n \varepsilon_n \frac{1}{x}\Big) \\
&\approx x \left(1 + (r_1 \varepsilon_1 + \cdots + r_n \varepsilon_n) \frac{1}{x}\right) \\
&= x + r_1 \varepsilon_1 + \cdots + r_n \varepsilon_n \\
&= r_1 (x + \varepsilon_1) + \cdots + r_n (x + \varepsilon_n) \\
&= A(x_1, \ldots, x_n).
\end{aligned}$$

Diese Diskussion soll nicht zu Verwirrungen führen: es muß aufmerksam zwischen den unterschiedlichen Mittelwerten unterschieden werden. Liegen jedoch die Daten alle recht nahe beieinander, sind die Werte der drei Mittelwerte ebenfalls dicht beieinander.

3.2 Streumaße und Tschebyschev-Ungleichung

Wir kommen zu den Streumaßen bzw. Streuungsparametern. Die bisherigen Parameter gestatteten keine Aussagen über die Abstände zwischen den einzelnen Stichprobenwerten. Sie beschreiben die Lage bzw. Mitte der Daten. Wir betrachten die beiden folgenden Datensätze

$$x = (3, 3, 3, 4, 4, 4, 5, 6) \quad \text{und} \quad y = (-26, -10, 0, 4, 10, 20, 30).$$

Hier gilt $\bar{x} = \bar{y} = \tilde{x} = \tilde{y} = 4$, aber in x liegen die Werte viel dichter an $\bar{x}$. Die gleiche durchschnittliche Klausurleistung bei einer Stochastikklausur in Bochum und in Hagen ist eine nicht unbedingt interessante Information. In Bochum könnten extrem viele Studierende schlecht abgeschnitten haben und gleichzeitig deutlich mehr Studierende als in Hagen sehr gute Leistungen gezeigt haben. Die mögliche Streuung der Daten gilt es nun zu erfassen.

Die Lageparameter hatten die Eigenschaft, dass eine Verschiebung aller Daten um einen festen Wert den Lageparameter um den gleichen Wert verschiebt. Ein Streumaß sollte hingegen invariant gegenüber einer simultanen Verschiebung aller Daten sein:

3.2.1 Definition: Ein *Streumaß* ist eine Abbildung $s : \mathbb{R}^n \to \mathbb{R}$ mit der Eigenschaft, dass für alle $t \in \mathbb{R}$ und alle $(x_1, \ldots, x_n) \in \mathbb{R}^n$ gilt:

$$s(x_1 + t, x_2 + t, \ldots, x_n + t) = s(x_1, \ldots, x_n).$$

Ab nun setzen wir voraus, dass die Daten von einem *Intervallskalenniveau* herrühren, denn wir wollen Differenzen und Abstände betrachten. Eine erste Streugröße ist die Spannweite:

3.2.2 Definition: Für ein quantitatives Merkmal sei die Stichprobe $(x_1, \ldots, x_n)$ gegeben. Dann heißt

$$\max_{1 \le i \le n} x_i - \min_{1 \le i \le n} x_i$$

die *Spannweite* der Stichprobe.

Die Spannweite, also die Differenz der Extremwerte, muss nicht sehr aussagekräftig sein. Beim Marathon-Lauf muss die Person, die die Zielkamera bedient, allerdings wissen, wann der schnellste und wann der langsamste Läufer im Ziel erwartet werden kann. Hier macht die Angabe der Spannweite der Laufzeiten also durchaus Sinn.

Ein plausibler Ansatz zur Bestimmung der Streuung ist die Bestimmung der Abstände der Daten zu einem vorgegebenen Wert (Punkt/Datum) oder die Bestimmung aller Abstände untereinander. Dabei werden wir aber relative Größen betrachten, also durch die Gesamtzahl der Elemente der Stichprobe teilen (alternativ ist die Vergleichbarkeit schwer zu erreichen: die Streuung würde von der Anzahl der Daten bestimmt sein: je mehr Daten, je größer die Streuung.)

Ein erster Ansatz ist, die Differenzen $(x_i - \bar{x})$ zu addieren, doch die Schwerpunkteigenschaft besagt $\sum_{i=1}^n (x_i - \bar{x}) = n\bar{x} - n\bar{x} = 0$. Das arithmetische Mittel gleicht die einfachen Abweichungen aus. Damit scheidet diese Größe als ein geeignetes Maß für die Abweichung von $\bar{x}$ aus.

3.2.3 Definition: Wir verwenden die Notation wie in Definition 2.3.1.
Gegeben sei eine Stichprobe $x = (x_1, \ldots, x_n)$ eines quantitativen Merkmals. Zu

$x = (x_1, \ldots, x_n)$ heißt

$$d_c := \frac{1}{n} \sum_{i=1}^{n} |x_i - c| = \frac{1}{n} \sum_{k=1}^{N} |x_k^* - c| \, h_k$$

mittlere absolute Abweichung bzgl. c.

Für c in dieser Definition kann man zum Beispiel den Median oder das arithmetische Mittel der Daten wählen. Interessanterweise minimiert der Median die mittlere absolute Abweichung:

3.2.4 Satz: Für jede Stichprobe $x = (x_1, \ldots, x_n)$ eines quantitativen Merkmals und jede reelle Zahl c gilt:

$$d_{\widetilde{x}} = \frac{1}{n} \sum_{i=1}^{n} |x_i - \widetilde{x}| \leq \frac{1}{n} \sum_{i=1}^{n} |x_i - c| = d_c \, .$$

Der Median minimiert die Summe der absoluten Abweichungen.

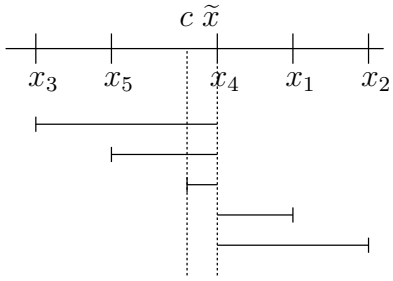

Abb. 3.3: Der Median minimiert die Summe der absoluten Abweichungen.

Heuristische Begründung :
Wir wissen, dass mindestens die Hälfte der Daten größer gleich bzw. kleiner gleich dem Median ist. Verschieben wir im obigen Bild (Abb. 3.3) den Wert c vom Median $\widetilde{x}$ ein wenig nach links, so werden die zwei oberen Balken jeweils um den Betrag dieser Verschiebung $|c - \widetilde{x}|$ kürzer, die drei unteren Balken um denselben Betrag länger. Sobald die Verschiebung den Wert x_1 überschreitet, würde sogar nur ein Balken schrumpfen. Es wird also mindestens die Hälfte der Summanden um $\widetilde{x} - c$ größer und der Rest wird um höchstens den gleichen Betrag kleiner, die Summe wird also insgesamt größer. Diese Argumentation geht analog bei Verschiebung nach rechts. Sie wird in dem nun folgenden Beweis formalisiert.

Beweis: Es sei n gerade. Wir betrachten die geordnete Stichprobe $(x_{[1]}, \ldots, x_{[n]})$. Es gilt

$$\begin{aligned}
d_{\widetilde{x}} &= \frac{1}{n}\sum_{i=\frac{n}{2}+1}^{n}(x_{[i]}-\widetilde{x}) - \frac{1}{n}\sum_{i=1}^{n/2}(x_{[i]}-\widetilde{x}) \\
&= \frac{1}{n}\sum_{i=\frac{n}{2}+1}^{n}(x_{[i]}-c) + \frac{1}{n}\frac{n}{2}(c-\widetilde{x}) - \frac{1}{n}\sum_{i=1}^{n/2}(x_{[i]}-c) - \frac{1}{n}\frac{n}{2}(c-\widetilde{x}) \\
&= \frac{1}{n}\sum_{i=\frac{n}{2}+1}^{n}(x_{[i]}-c) - \frac{1}{n}\sum_{i=1}^{n/2}(x_{[i]}-c).
\end{aligned}$$

Sei nun $c > \widetilde{x}$, dann folgt

$$\begin{aligned}
\sum_{i=\frac{n}{2}+1}^{n}(x_{[i]}-c) &= \sum_{\substack{i\geq\frac{n}{2}+1\\ x_{[i]}<c}}^{n}(x_{[i]}-c) + \sum_{\substack{i\geq\frac{n}{2}+1\\ x_{[i]}\geq c}}^{n}(x_{[i]}-c) \\
&\leq -\sum_{\substack{i\geq\frac{n}{2}+1\\ x_{[i]}<c}}^{n}(x_{[i]}-c) + \sum_{\substack{i\geq\frac{n}{2}+1\\ x_{[i]}\geq c}}^{n}(x_{[i]}-c),
\end{aligned}$$

also

$$\begin{aligned}
d_{\widetilde{x}} &\leq -\frac{1}{n}\sum_{i=1}^{n/2}(x_{[i]}-c) - \frac{1}{n}\sum_{\substack{i\geq n/2+1\\ x_{[i]}<c}}(x_{[i]}-c) + \frac{1}{n}\sum_{x_{[i]}\geq c}(x_{[i]}-c) \\
&= -\frac{1}{n}\sum_{x_{[i]}<c}(x_{[i]}-c) + \frac{1}{n}\sum_{x_{[i]}\geq c}(x_{[i]}-c) \\
&= d_c.
\end{aligned}$$

Für $c < \widetilde{x}$ folgt analog

$$d_{\widetilde{x}} \leq -\frac{1}{n}\sum_{x_{[i]}<c}(x_{[i]}-c) + \frac{1}{n}\sum_{x_{[i]}\geq c}(x_{[i]}-c)$$

und für $c = \widetilde{x}$ ist $d_c = d_{\widetilde{x}}$. □

Wir betrachten nun auch die quadratischen Abstände:

3.2.5 Definition: Ist $x = (x_1, \ldots, x_n)$ eine Stichprobe für ein quantitatives Merkmal mit $n \geq 2$, so heißt

$$s_x^2 := \frac{1}{n-1}\sum_{i=1}^{n}(x_i-\bar{x})^2$$

die *empirische Varianz* von x und $s_x := +\sqrt{s_x^2}$ die *(empirische) Standardabweichung.*

Es ist einfach zu sehen, dass gilt:

$$s_x^2 = \frac{1}{n-1}\sum_{k=1}^{N} h_k(x_k^* - \bar{x})^2 \quad \text{mit} \quad n = \sum_{k=1}^{N} h_k.$$

3.2.6 Aufgabe: Zeigen Sie

(a)
$$s_x^2 = \frac{1}{n-1}\left[\sum_{i=1}^{n} x_i^2 - n\bar{x}^2\right] = \frac{1}{n-1}\left[\sum_{i=1}^{n} x_i^2 - \frac{1}{n}\left(\sum_{i=1}^{n} x_i\right)^2\right].$$

(b) Zu $y = ax + b$ mit $a, b \in \mathbb{R}$ ist $s_y^2 = a^2 s_x^2$.

Das arithmetische Mittel minimiert die Summe quadratischer Abstände:

3.2.7 Satz: Für jede beliebige Konstante c gilt die so genannte *Verschiebungsformel*

$$\sum_{i=1}^{n}(x_i - c)^2 = \sum_{i=1}^{n}(x_i - \bar{x})^2 + n(\bar{x} - c)^2\,.$$

Also minimiert der Mittelwert die Summe der Abstandsquadrate.

Beweis:

$$\begin{aligned}\sum_{i=1}^{n}(x_i - \bar{x} + \bar{x} - c)^2 &= \sum_{i=1}^{n}[(x_i - \bar{x})^2 + 2(\bar{x} - c)(x_i - \bar{x}) + (\bar{x} - c)^2] \\ &= \sum_{i=1}^{n}(x_i - \bar{x})^2 + n(\bar{x} - c)^2 + \underbrace{2(\bar{x} - c)\sum_{i=1}^{n}(x_i - \bar{x})}_{=0}\end{aligned}$$

Es folgt daraus, dass $s_x^2 < \frac{1}{n-1}\sum_{i=1}^{n}(x_i - c)^2$ für alle $c \neq \bar{x}$, da $(\bar{x} - c)^2 > 0$ für alle $c \neq \bar{x}$. □

Die Wahl der quadratischen Abweichung ist also mit ihrer optimalen Anpassung zum arithmetischen Mittel begründbar. Schon CARL FRIEDRICH GAUSS (1777–1855) hat die quadratische Abweichung intensiv untersucht. Wir werden im nächsten Kapitel sehen, dass die Kraft kleinster Abweichungsquadrate bei der Regressionsanalyse erneut deutlich wird.

3.2.8 Aufgabe: Es sei x^* ein Schätzwert für das arithmetische Mittel $\bar{x}$ einer Stichprobe $(x_1, \ldots, x_n)$. Dabei trete die Merkmalsausprägung x_i mit relativer Häufigkeit r_i auf. Warum ist $\bar{x} - x^*$ in der Regel einfacher zu berechnen als $\bar{x}$? Zeigen Sie, dass man das quadratische Mittel der Abweichungen $|\bar{x} - x_i|$ folgendermaßen berechnen kann:

$$\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \sum_{i=1}^{N} r_i(x_i^* - x^*)^2 - (x^* - \bar{x})^2.$$

Woher kommt eigentlich der Nenner $n-1$ bei der Definition von s_x^2? Man hat es doch mit n Daten zu tun! Es gibt ein gutes Argument aus der Wahrscheinlichkeitstheorie/mathematischen Statistik, dass nur $\frac{1}{n-1}$ einen „erwartungstreuen Schätzer für die Varianz bei unabhängig identisch verteilten Zufallsgrößen" liefert. Diese Aussage wird uns in Kurseinheit 7 begegnen. Soweit wollen wir hier aber nicht ausholen. Wir geben gleich ein simples Argument, welches so im Übrigen auch im Schulunterricht seinen Platz finden kann.

Zuvor sei aber bemerkt, dass die empirische Varianz in der Literatur auch mit dem Vorfaktor $1/n$ definiert wird. Wenn man an Einheiten der Daten denkt (etwa die Größe von Kindern, gemessen in Zentimetern), so wird aus Sicht dieser Einheiten die Verwendung der Standardabweichung bevorzugt, weil sie in derselben Einheit misst. Da man bei der empirischen Varianz die Abstandsquadrate betrachtet, bekommen Ausreißer ein starkes Gewicht.

Wir hatten eingangs erwähnt, dass eine Alternative, natürliche Art, die Streuung von n Daten untereinander zu bestimmen, die Berechnung der Abstände aller Daten untereinander ist. Hierbei nehmen wir nicht Bezug zu $\bar{x}$, $\tilde{x}$ oder einem beliebigen anderen festen Wert. Dies führt uns zum Beispiel zur Betrachtung der absoluten oder quadratischen Abweichung

$$\sum_{i,j=1}^{n} |x_i - x_j| \ ; \quad \sum_{i,j=1}^{n} (x_i - x_j)^2 \, .$$

Bei der Wahl quadratischer Abstände ist dabei die folgende Beobachtung interessant:

$$\begin{aligned}
\sum_{i=1}^{n}\sum_{j=1}^{n}(x_i - x_j)^2 &= \sum_{i=1}^{n}\sum_{j=1}^{n}((x_i - \bar{x})^2 + 2(x_i - \bar{x})(-x_j + \bar{x}) + (\bar{x} - x_j)^2) \\
&= \sum_{i,j=1}^{n}(x_i - \bar{x})^2 + 2\sum_{i=1}^{n}\sum_{j=1}^{n}(x_i - \bar{x})(\bar{x} - x_j) + \sum_{i,j=1}^{n}(\bar{x} - x_j)^2
\end{aligned}$$

$$
\begin{aligned}
&= 2\sum_{i,j=1}^{n}(x_i-\bar{x})^2 + 2\sum_{i=1}^{n}\left((x_i-\bar{x})\sum_{j=1}^{n}(\bar{x}-x_j)\right)\\
&= 2n\sum_{i=1}^{n}(x_i-\bar{x})^2,
\end{aligned}
$$

denn $\sum_{j=1}^{n}(\bar{x}-x_j)=0$ (Schwerpunkteigenschaft). Dann ist

$$
\begin{aligned}
s^2 &:= \frac{1}{n(n-1)}\sum_{i=1}^{n}\sum_{j=1}^{n}(x_i-x_j)^2\\
&= 2\,\frac{1}{n-1}\sum_{i=1}^{n}(x_i-\bar{x})^2 = 2s_x^2.
\end{aligned}
$$

Wird $\bar{x}$ zum Beispiel durch den Median $\tilde{x}$ ersetzt, so ist i.A. $\sum_{j=1}^{n}(\tilde{x}-x_j)\neq 0$, also ist in diesem Fall die obige Darstellung nicht möglich.

Die neue, sehr natürliche Schwankungsgröße s^2 ist also bereits durch s_x^2 bis auf den Faktor 2 gegeben. Daher hat sich s_x^2 als Streuungsgröße durchgesetzt, denn die Berechnung ist einfacher.

ABER warum wählen wir bei der Definition von s^2 den Normierungsfaktor $1/(n(n-1))$? Wir addieren doch n^2 Differenz-Quadrate. Wenn diese Wahl des Vorfaktors nicht plausibel ist, so ist es die Wahl des Vorfaktors bei s_x^2 auch nicht. Eine alternative Normierung würde nicht zu einem Vielfachen von s_x^2 führen. Die Antwort ist ziemlich plausibel:

Bei n Daten gibt es zwar n^2 Abweichungen der Daten voneinander, aber davon sind n ohne Beitrag, da $x_i-x_j=0$ für alle $i=j$ gilt. Ein $1/n$-Anteil spielt also gar nicht mit, aber diese Abweichungen vom Wert Null würden beim Teilen durch n^2 mitgezählt. Mit anderen Worten: das Teilen durch n^2 führt zu einer *Unterschätzung der Abweichung*. Man sollte also durch die Anzahl $n^2-n=n(n-1)$ teilen, und so ist s^2 definiert. Wir haben also gut begründen können, warum die Definition von s^2 sinnvoll ist. Mit $s^2=2s_x^2$ ist dann die Wahl der Definition der empirischen Varianz die natürlichere. Wir müssen also doch nicht auf die Kurseinheit 7 warten, um die Definition der empirischen Varianz verstehen zu können. Wir halten fest:

3.2.9 Satz: Die mittlere quadratische Abweichung s^2 der Daten $x=(x_1,\ldots,x_n)$ voneinander ist stets das Doppelte der empirischen Varianz s_x^2:

$$s^2 = 2s_x^2\,.$$

Weitere Streuungsgrößen sind die Quantilabstände:

3.2.10 Definition: Für eine Stichprobe $(x_1, \ldots, x_n)$ eines quantitativen Merkmals bezeichnen wir mit q_p das p-Quantil der Stichprobe. Die Differenz $q_{0.75} - q_{0.25}$ heißt *Quartilsabstand*. Für ein $p \in [0, 0.5]$ heißt $q_{1-p} - q_p$ *p-Quantilsabstand* der Stichprobe.

Wir werden im folgenden Absatz die Bedeutung dieser Streugröße bei den Darstellungsformen der Boxplots und der Perzentilbänder sehen. Der Quartilsabstand veranschaulicht die Spannweite der mittleren 50 % der Daten der Stichprobe.

3.2.11 Aufgabe: Zeigen Sie, dass die Spannweite, die mittlere absolute Abweichung vom Median, die empirische Varianz, die Standardabweichung sowie der Quartilsabstand jeweils ein Streumaß ist. Welche der genannten Streumaße erfüllt die Eigenschaft:

$$s(a\,x_1, a\,x_2, \ldots, a\,x_n) = a\,s(x_1, \ldots, x_n)$$

für alle $a > 0$?

Wir diskutieren abschließend in diesem Unterkapitel eine berühmte Ungleichung, die unabhängig von der konkreten Verteilung einer zugrunde liegenden Stichprobe angibt, wie viele Daten sich in einem symmetrischen Intervall um das arithmetische Mittel herum befinden: die *Tschebyschev-Ungleichung* (Pafnuti Lwowitsch Tschebyschev (1821–1894)). Dazu bezeichne bei einer Stichprobe $(x_1, \ldots, x_n)$ eines quantitativen Merkmals zu einer Teilmenge $A \subset \mathbb{R}$

$$r(A) := r_n(A) := \sum_{x \in A} r_n(x)$$

die relative Häufigkeit von A. Wir betrachten speziell die Menge $A := [\bar{x} - \varepsilon, \bar{x} + \varepsilon]$. Wieviele Daten der Stichprobe liegen in diesem Intervall? Allgemein gilt

$$\frac{n-1}{n} s_x^2 = \sum_{x \in \mathbb{R}} r_n(x)\,(x - \bar{x})^2 = \sum_{x \in A} r_n(x)\,(x - \bar{x})^2 + \sum_{x \in \mathbb{R} \setminus A} r_n(x)\,(x - \bar{x})^2.$$

Für obiges A folgt

$$\frac{n-1}{n} s_x^2 \geq r(\mathbb{R} \setminus A)\,\varepsilon^2.$$

3.2.12 Satz: (Tschebyschev-Ungleichung) Zu einer Stichprobe $(x_1, \ldots, x_n)$ eines quantitativen Merkmals gilt für alle $\varepsilon > 0$

$$r\Big([\bar{x} - \varepsilon, \bar{x} + \varepsilon]\Big) > 1 - \frac{s_x^2}{\varepsilon^2} \frac{n-1}{n} > 1 - \frac{s_x^2}{\varepsilon^2}.$$

Wir wenden die TSCHEBYSCHEV-Ungleichung für Vielfache der Standardabweichung s_x an: Betrachte $A_k := [\bar{x} - k\,s_x, \bar{x} + k\,s_x]$. Für $k = 1$ folgt $r(A_1) > 0$, für $k = 2$ liefert die Ungleichnung $r(A_2) > 0.75$. Weiter gilt $r(A_3) > 0.888$ und $r(A_4) > 0.9375$. Diese Abschätzungen sind im Grunde sehr grob, denn die obige Herleitung zeigt ja, dass wir nur einen Baustein weggelassen haben. Sie gilt aber für jeden beliebigen Datensatz. Mindestens 75% der Werte liegen im $2s_x$-Intervall A_2, mindestens 93% der Werte im $4s_x$-Intervall A_4. Wir werden später sehen, dass man bei konkreten Verteilungen deutlich genauere Abschätzungen erhalten kann. Sind die Daten zum Beispiel normalverteilt, so liegen im $2s_x$-Intervall tatsächlich mehr als 95% der Daten. In diesem Fall liegen bereits ca. 2/3 der Daten im $1s_x$-Intervall.

3.3 Boxplots und Perzentilbänder

Zu einem *Boxplot* sagt man auch *Whiskers Plot* oder einfach *Kastenschaubild.* Man verwendet diese Darstellungsform bei ordinal skalierten Merkmalen. Diese Darstellungsform verwendet die p-Quantile eines Datensatzes. Ein Boxplot wird in der Literatur unterschiedlich verwendet. Wir betrachten exemplarisch die folgende Variante:

Boxplots bestehen aus einer Skala, parallel zur Hauptachse des Plots, einem Rechteck von 0.25-Quantil $q_{0,25}$ bis zum 0.75-Quantil $q_{0,75}$, einem Querstrich in der Höhe des Medians $\tilde{x}$ und Querstrichen auf der Höhe der Extremwerte $x_{[1]}$, $x_{[n]}$ sowie einer Verbindung von den Extremwerten zur Box. Das Boxplot basiert also auf den fünf *Quartilen.* Die Länge der Box visualisiert damit den Quartilsabstand der Stichprobe. An die Box kommen die so genannten *Antennen*, die man auch *Fühler* oder *Whiskers* nennt. Die Gesamtlänge des Boxplots visualisiert also die Spannweite der Stichprobe. Ein Beispiel eines Boxplots finden Sie in Abb. 3.4.

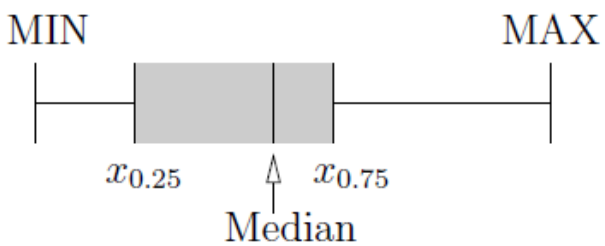

Abb. 3.4: Boxplot, basierend auf 5 Daten, Pentagramm

Zur Erstellung eines Boxplots muss man die Daten anordnen und die Quartile

bestimmen sowie die Box erstellen. Dazu ist bei größeren Datenstichproben ein Statistikprogramm hilfreich.

Es gibt Varianten der Boxplots, die Ausreißer abschneiden, also besonders kleine oder große Werte alternativ berücksichtigen. Im Softwarepaket SPSS (Statistical Product and Service Solutions) unterscheidet man zwischen *Ausreißern* und *Extremwerten*: Als Ausreißer werden die Werte betrachtet, die um mehr als das 1.5-fache des Quartilsabstandes von den Enden der Box entfernt sind. Als Extremwerte werden die Werte betrachtet, die um mehr als das 3-fache des Quartilsabstandes von der Box entfernt sind. Ausreißer und Extremwerte erhalten eigene Symbole und werden einzeln dargestellt. Wenn Ausreißer und damit auch Extremwerte nicht im Boxplot Platz finden, wird damit die Länge der Whiskers auf das 1.5-fache der Box begrenzt. Boxplots kommen häufig dann zum Einsatz, wenn ein Merkmal in mehreren Gruppen gemessen wurde, denn sie sind für einen Vergleich von Datenreihen besonders geeignet. Eine unterschiedliche Gruppengröße spielt beim Vergleich keine direkte Rolle. Boxplots verändern sich bei Veränderung der Lage der Stichprobe. Boxplots geben Auskunft über die Schiefe der Verteilung der Daten: Beim Vergleich der unterschiedlichen Lagemaße hatten wir $x_{\text{mod}} \leq \tilde{x} \leq \bar{x}$ linksschief genannt, $x_{\text{mod}} \geq \tilde{x} \geq \bar{x}$ rechtsschief. Boxplots gehen zurück auf Tukey.

Es gibt noch weitere so genannte *Schiefemaße*: Dies sind Maße für den Grad der Asymmetrie. Verschiedene Schiefemaße haben gemein, dass sie die Richtung der Asymmetrie korrekt anzeigen: positiv bei Rechtsschiefe, negativ bei Linksschiefe. Ein Schiefemaß ist das 3. normierte zentrale Moment

$$g := \frac{\frac{1}{n}\sum_{i=1}(x_i - \bar{x})^3}{\left(\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2\right)^{3/2}} .$$

Die zweite Darstellungsform sind die *Perzentilbänder*. Hierbei werden die Perzentile, also die p-Quantile dargestellt. In der Regel betrachtet man mehr als fünf Perzentile und eher das arithmetische Mittel anstelle des Medians.

Wir betrachten in Abb. 3.5 das Ergebnis der Teilnehmerstaaten im PISA Test 2000 zu den Mathematikleistungen.

Es werden sechs Perzentile und ein Mittelwert dargestellt. Es beginnt beim 5. und endet beim 95. Perzentil. Die fünf Prozent besten und schlechtesten Ergebnisse werden also außer Acht gelassen. Weiter wird das 10., 25., 75. und 90. Perzentil dargestellt. Tatsächlich wird das arithmetische Mittel verwendet, da der Test eine minimale und eine maximale erreichbare Punktzahl festlegt, Ausreißer also nicht

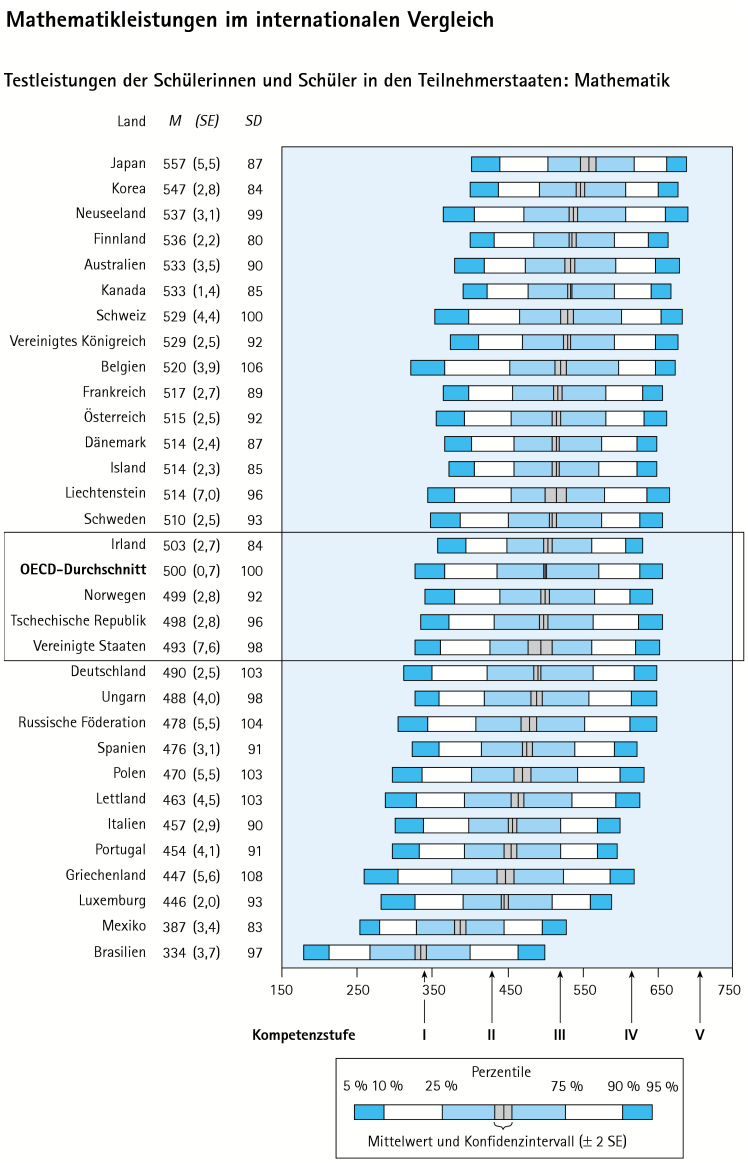

Abb. 3.5: Ergebnisdarstellung mit Perzentilbändern bei PISA 2000 (Deutsches PISA-Konsortium 2001b, S.21)

nur in eine Richtung möglich sind. Es gibt noch eine aus der mathematischen Statistik kommende Begründung für die Darstellung des arithmetischen Mittels. Das so genannte Vertrauensintervall (Konfidenzintervall) wird am arithmetischen Mittel zentriert, und gibt an, ob der mittlere Leistungsunterschied zweier Länder sich signifikant unterscheidet. Es bleiben noch die drei Zahlenwerte, die hinter den Namen der Staaten stehen, zu erklären. M steht für *mean*, das arithmetische Mittel der Testwerte. In der Spalte SE ist der *standard error* gemeint, der mit dem Konfidenzintervall zusammenhängt. SD bezeichnet *standard deviation*, dass ist die Standardabweichung im Sinne unserer Definition.

3.4 Indexzahlen

Bekannte Indexzahlen wie der Index für die Lebenshaltungskosten, der Aktienindex DAX und der Geschäftsklimaindex begegnen uns beinahe täglich in den Medien. Dies sind spezielle Kennwerte von Stichproben, auf die wir jeweils kurz eingehen wollen. Wir stellen desweiteren einen so genannten Macht-Index vor.

Zunächst betrachten wir den *Verbraucherpreisindex für die Lebenshaltungskosten* nach Ernst Laspeyres (1834–1913). Die Veränderung dieses Index nennt man *Inflationsrate*. Man bestimmt zu einem ersten Zeitpunkt den Gesamtpreis für eine festgelegte Menge von unterschiedlichen Waren und Dienstleistungen (der *Warenkorb*). Für die Ware/Dienstleistung $i \in \{1, \ldots, n\}$ sei $p_i(t_0)$ der Preis und $q_i(t_0)$ die Menge, gemessen in Vielfachen einer vorgegebenen Einheit, zum Basiszeitpunkt t_0. Zum Berichtszeitpunkt t_1 seien die Preise $p_i(t_1)$, $i = 1, \ldots, n$, zu der unveränderten Menge $q_i(t_0)$ der Ware i. Dann ist

$$\mathrm{PL}(\mathrm{t}_0, \mathrm{t}_1) := \frac{\sum_{\mathrm{i}=1}^{\mathrm{n}} \mathrm{q_i}(\mathrm{t}_0)\, \mathrm{p_i}(\mathrm{t}_1)}{\sum_{\mathrm{i}=1}^{\mathrm{n}} \mathrm{q_i}(\mathrm{t}_0)\, \mathrm{p_i}(\mathrm{t}_0)}$$

der *Preisindex nach Laspeyres*. Alles hängt von einer geeigneten Wahl des Warenkorbs ab. Dies ist vielfach zu deuten und zu diskutieren, was wir an dieser Stelle aber nicht tun wollen. Mathematisch ist zu bemerken, dass dieser Preisindex ein gewichteter Mittelwert ist. Gemittelt werden hier die Preissteigerungen der einzelnen Waren und Dienstleistungen $\frac{p_i(t_1)}{p_i(t_0)}$. Die Gewichte sind dabei die Ausgaben $q_i(t_0)\, p_i(t_0)$ für die i-te Ware oder Dienstleistung zum Basiszeitpunkt:

$$\mathrm{PP}(\mathrm{t}_0, \mathrm{t}_1) := \frac{\sum_{\mathrm{i}=1}^{\mathrm{n}} \mathrm{q_i}(\mathrm{t}_1)\, \mathrm{p_i}(\mathrm{t}_1)}{\sum_{\mathrm{i}=1}^{\mathrm{n}} \mathrm{q_i}(\mathrm{t}_1)\, \mathrm{p_i}(\mathrm{t}_0)}.$$

Wählt man für die Gewichte für die einzelnen Preissteigerungen bei der Mittelwertbildung nicht die Mengen zum Basiszeitpunkt, sondern zum Berichtszeitpunkt, so

spricht man vom *Paasche-Index* $\mathrm{PP}(\mathrm{t}_0, \mathrm{t}_1)$, benannt nach Hermann Paasche (1851–1925). Diese Wahl soll dem Index eine größere Aktualität verleihen. Auch hier kann Kritik ausführlich diskutiert werden (zu starke Berücksichtigung aktueller Trends), was aber erneut an dieser Stelle nicht ausgeführt wird. Ein Kompromiss der beiden Preisindizes ist ihr geometrisches Mittel, der Preisindex von Irving Fisher (1867–1947).

Was gibt der *DAX* an? Er wird nach der Methode von Laspeyres berechnet. Zugrunde liegen die 30 wichtigsten/größten deutschen Unternehmen. Der Warenkorb wird in der Regel im Herbst festgelegt. Die Gewichte werden aus den Unternehmensgrößen gewonnen, die Preise sind die jeweiligen Aktienkurse. Der *Dow Jones* hingegen ist das ungewichtete arithmetische Mittel der Aktienkurse.

Der *ifo (Geschäftsklima-Index)*, ist eine Zahl, die aus einer Befragung von Unternehmen herrührt. Er beschreibt sich selbst wie folgt: „Der ifo-Index ist ein vielbeachteter Frühindikator für die konjunkturelle Entwicklung Deutschlands. Für die Ermittlung des Index befragt das ifo Institut jeden Monat über 7000 Unternehmen in West- und Ostdeutschland nach ihrer Einschätzung der Geschäftslage (Antwortmöglichkeiten: gut/befriedigend/schlecht) sowie nach ihrer Erwartung für die nächsten sechs Monate (Antwortmöglichkeiten: besser/gleich/schlechter). Die Antworten werden nach der Bedeutung der Branchen gewichtet und aggregiert."

Zur Beurteilung der *Macht* einzelner Wähler oder Mitglieder eines Entscheidungsgremiums betrachtet man so genannte *Macht-Indizes*. Hier ein einfaches Beispiel: Unter n Wählern hat jeder eine Stimme. Jeder Wähler darf ausschließlich mit „Ja“ oder „Nein“ stimmen. Wenn Ω die Menge der Wähler bezeichnet, so sei $S \subseteq \Omega$ die Menge derjenigen Wähler, die einen Antrag (auf Abstimmung für oder gegen Studiengebühren) unterstützt, also die Menge der Wähler, die mit „Ja" stimmen. S heißt dann Koalition. Das Wahlsystem legt fest, welche Mengen S zur Annahme eines Antrags führen. Dies sind die so genannten Gewinnerkoalitionen. Nun heißt in einer Gewinnerkoalition S ein Wähler $i \in S$ *entscheidend* in S, falls $S \setminus \{i\}$ eine Verliererkoalition (eine Menge, die nicht Gewinnerkoalition ist) ist. Der *Banzhaf-Index* (John Banzhaf, geboren 1940) von $i \in \Omega$ ist nun der Quotient aus der Anzahl der Gewinnerkoalitionen, in denen i entscheidend ist, dividiert durch die Gesamtzahl aller Koalitionen, in denen i enthalten ist. Dieser Index hat sich in einfachen Wahlmodellen als ein Maß für die Macht bewährt. Es gibt interessante Beispiele in der Politik. Zu Gründungszeiten der Europäischen Währungsgemeinschaft (später Europäische Union) gab es die sechs Mitgliedstaaten Deutschland, Frankreich, Italien, Niederlande, Belgien und Luxemburg (1958). Jedem Land war für Abstimmungen im Ministerrat ein Stimmgewicht zugeordnet: Deutschland hatte 4, Frankreich 4, Italien 4, Niederlande 2, Belgien 2 Stimmen und Luxemburg

1 Stimme. Das Stimmgewicht eines Landes konnte nur als Block abgegeben werden, z.B. Frankreich konnte entweder mit 4 Stimmen für oder gegen einen Antrag stimmen. Bei einer Abstimmung im Ministerrat waren 12 der insgesamt 17 Stimmen notwendig, um einen Beschluss durchzusetzen. Dieses Wahlsystem wurde im Jahr 1973 verändert. Bis dahin galt: der Banzhaf-Index des Staates Luxemburg war Null, Luxemburg war für keine gewinnende Koalition kritisch. Dies ist für das kleine Land Luxemburg eine böse Überraschung, war aber 15 Jahre die geltende Bestimmung. Es gibt mittlerweile eine reichhaltige Literatur zur Untersuchung von Macht und Machtkonstellationen in Wahlsystemen.

Lösungen der Aufgaben

Lösungen der Aufgaben in 3.1

Aufgabe 3.1.8

In der folgenden Tabelle geben wir in der ersten Spalte die Teileranzahl an, in der zweiten Spalte listen wir diejenigen natürlichen Zahlen kleiner gleich 50 auf, die genau k Teiler haben. Die dritte Spalte protokolliert die absolute Anzahl der Zahlen mit genau k Teilern.

Anzahl der Teiler k	Zahlen	Anzahl der Zahlen mit Teilern k
1	01	1
2	02, 03, 05, 07, 11, 13, 17, 19, 23, 29, 31, 37, 41, 43, 47	15
3	04, 09, 25, 49	4
4	06, 08, 10, 14, 15, 21, 22, 26, 27, 33, 34, 35, 38, 39, 46	15
5	16	1
6	12, 18, 20, 28, 32, 44, 45, 50	8
7	-	0
8	24, 30, 40, 42	4
9	36	1
10	48	1

Mit Hilfe dieser Übersicht, die einem Stamm-Blatt-Diagramm entspricht (die ersten beiden Spalten der Tabelle), machen wir die folgenden Beobachtungen: Die einzige Zahl mit einem Teiler ist die Eins. Primzahlen haben genau zwei Teiler. Viele Zahlen haben vier Teiler, aber nur wenige haben drei Teiler. Auch 5, 7 und 9 Teiler kommen selten vor. Ungerade Teilerzahlen kommen selten vor. Die erste Zahl mit sieben Teilern ist übrigens 64. Gerade Zahlen haben viele Teiler.

Um die mittlere Anzahl der Teiler von $\{1, 2, ..., N\} \setminus Q_n$ zu bestimmen, legen wir die folgenden beiden Tabellen an.

Anzahl der Teiler der Nichtquadratzahlen von 1 bis 50:

Anzahl der Teiler k	Zahlen	Anzahl der Zahlen mit Teilern k
2	02, 03, 05, 07, 11, 13, 17, 19, 23, 29, 31, 37, 41, 43, 47	15
4	06, 08, 10, 14, 15, 21, 22, 26, 27, 33, 34, 35, 38, 39, 46	15
6	12, 18, 20, 28, 32, 44, 45, 50	8
8	24, 30, 40, 42	4
10	48	1

Anzahl der Teiler der Quadratzahlen zwischen 1 und 50:

Anzahl der Teiler k	Zahlen	Anzahl der Zahlen mit Teilern k
1	01	1
3	04, 09, 25, 49	4
5	16	1
7	-	0
9	36	1

Man sieht, dass die mittlere Anzahl der Nichtquadratzahlen $\frac{180}{43}$ ist, denn wir haben 43 Nichtquadratzahlen, und 15 mit zwei Teilern, 15 mit vier Teilern, 8 mit sechs Teilern, 4 mit acht Teilern und eine Zahl mit zehn Teilern.

Aufgabe 3.1.11

Die Lösung ist sehr einfach:

$$\sum_{i=1}^{n} (x_i - \bar{x}) = \sum_{i=1}^{n} x_i - n\frac{x_1 + \cdots + x_n}{n} = \sum_{i=1}^{n} x_i - \sum_{i=1}^{n} x_i = 0.$$

Aufgabe 3.1.13

(i) Nach Voraussetzung hat die Stichprobe y_i den Umfang n_i. Der j-te Wert der Stichprobe y_i wird mit $y_{i,j}$ bezeichnet. Dann ist der Mittelwert die Summe aller $y_{i,j}$ für $i = 1, ..., M,\ j = 1, ..., n_i$, dividiert durch die Anzahl aller Daten $n_1 + \cdots + n_M$. So ergibt sich

$$\begin{aligned}
\bar{x} &= \frac{y_{1,1} + \cdots + y_{1,n_1} + y_{2,1} + \cdots + y_{2,n_2} + \cdots + y_{M,1} + \cdots + y_{M,n_M}}{n_1 + \cdots + n_M} \\
&= \frac{n_1 \frac{1}{n_1} \sum\limits_{i=1}^{n_1} y_{1,i} + \cdots + n_M \frac{1}{n_M} \sum\limits_{i=1}^{n_M} y_{M,i}}{n_1 + ... + n_M} \\
&= \frac{n_1 \bar{y}_1 + \cdots + n_M \bar{y}_M}{n_1 + \cdots + n_M}.
\end{aligned}$$

(ii) Folgt aus (iii) mit $y_i = 1$ für alle $i = 1, \ldots, n$.

(iii) Es gilt

$$\bar{z} = \frac{ax_1 + by_1 + \cdots + ax_n + by_n}{n} = \frac{a}{n} \sum_{i=1}^{n} x_i + \frac{b}{n} \sum_{i=1}^{n} y_i = a\bar{x} + b\bar{y}.$$

Aufgabe 3.1.17

Bezeichne $\langle x \rangle = (x_{[1]}, \ldots, x_{[n]})$ die bereits angeordnete Stichprobe. Für beliebiges $1 \leq i \leq n$ gelten die Ungleichungen

$$\sum_{x \geq x_{[i]}} r(x) = \frac{1}{n} \sum_{\substack{1 \leq k \leq n: \\ x_{[k]} \geq x_{[i]}}} 1 \geq \frac{1}{n} \sum_{k=i}^{n} 1 = \frac{n - i + 1}{n} \tag{3.2}$$

und

$$\sum_{x \leq x_{[i]}} r(x) = \frac{1}{n} \sum_{\substack{1 \leq k \leq n: \\ x_{[k]} \leq x_{[i]}}} 1 \geq \frac{1}{n} \sum_{k=1}^{i} 1 = \frac{i}{n}\,. \tag{3.3}$$

Wir unterscheiden zwei Fälle:
Fall 1: Sei $pn \in \mathbb{N}$. Es sei $i = pn$. Dann gilt nach (3.2) und (3.3)

$$\sum_{x \geq x_{[i]}} r(x) \geq \frac{n - np + 1}{n} = 1 - p + \frac{1}{n} \geq 1 - p$$

sowie

$$\sum_{x \leq x_{[i]}} r(x) \geq \frac{np}{n} = p\,.$$

Mithin ist i ein p-Quantil.
Sei jetzt $i = pn + 1$. Dann gilt wiederum nach (3.2) und (3.3)

$$\sum_{x \geq x_{[i]}} r(x) \geq \frac{n - (np+1) + 1}{n} = \frac{n - np}{n} = 1 - p$$

sowie

$$\sum_{x \leq x_{[i]}} r(x) \geq \frac{np+1}{n} = p + \frac{1}{n} \geq p\,.$$

Mithin ist i ein p-Quantil.
Fall 2: Sei $pn \notin \mathbb{N}$ und $i = \lfloor pn \rfloor + 1$. Dann gilt $pn < i < pn + 1$ und wir erhalten wieder aus (3.2) und (3.3)

$$\sum_{x \geq x_{[i]}} r(x) \geq \frac{n - i + 1}{n} \geq \frac{n - (pn+1) + 1}{n} = 1 - p$$

sowie

$$\sum_{x \leq x_{[i]}} r(x) \geq \frac{i}{n} \geq \frac{pn}{n} = p\,,$$

sodass i ein p-Quantil der Stichprobe ist.

Aufgabe 3.1.20

Seien $x = (x_1, \ldots, x_n)$ eine gegebene Stichprobe, $t \in \mathbb{R}$ und $y := (y_1, \ldots, y_n) := (x_1 + t, \ldots, x_n + t)$. Offenbar gilt dann

$$h(x_i) = h(y_i) \text{ und } r(x_i) = r(y_i) \tag{3.4}$$

für $1 \leq i \leq n$.
Modalwert: Ist x_k ein Modalwert von x, so ist $h(x_k) = \max_{1 \leq j \leq n} h(x_j)$. Nach (3.4) ist dann aber auch $h(y_k) = \max_{1 \leq j \leq n} h(y_j)$, so dass $y_k = x_k + t$ ein Modalwert von y ist.
p-Quantil: Sei x_k ein p-Quantil der Stichprobe x. Dann gilt nach (3.4)

$$\begin{aligned}\sum_{y\geq y_k} r(y) &= \sum_{\substack{1\leq i\leq n:\\ y_i\geq y_k}} r(y_i) = \sum_{\substack{1\leq i\leq n:\\ y_i\geq y_k}} r(x_i) = \sum_{\substack{1\leq i\leq n:\\ x_i\geq x_k}} r(x_i)\\ &= \sum_{x\geq x_k} r(x) \geq 1-p\end{aligned}$$

und analog zeigt man $\sum_{y\leq y_k} r(y) \geq p$.
Für das arithmetische Mittel haben wir bereits in Satz 3.1.12 gesehen, dass es sich um ein Lagemaß handelt.

Aufgabe 3.1.25

Wählen wir zum Beispiel $a = 1$, so gilt für eine für das geometrische Mittel zulässige Stichprobe $x = (x_1, \ldots, x_n) \in \mathbb{R}^n$ im Allgemeinen:

$$\sqrt[n]{(x_1+1)(x_2+1)\cdot\ldots\cdot(x_n+1)} \neq \sqrt[n]{x_1\cdot x_2\cdot\ldots\cdot x_n}+1\,.$$

Um dies einzusehen, setze man etwa $x_1 = 0$ und lasse die anderen x_i variabel. Dann ist jedoch die rechte Seite konstant gleich 1, die linke aber nicht. Daraus folgt, dass das geometrische Mittel für $n \geq 2$ kein Lagemaß sein kann. Um zu sehen, dass für $n \geq 2$ auch das harmonische Mittel kein Lagemaß ist, wählen wir die Stichprobe $x = (1, \ldots, 1, 2)$ und $a = 1$. Dann ist zu zeigen, dass

$$\frac{n}{n-1+\frac{1}{2}}+1 \neq \frac{n}{\frac{n-1}{2}+\frac{1}{3}}$$

gilt, was aber das Ergebnis einer elementaren Rechnung ist.

Aufgabe 3.1.29

Nach Satz 3.1.27 erhalten wir für $0 \neq x \geq -n$

$$\sqrt[n+1]{\left(1+\frac{x}{n}\right)^n} = \sqrt[n+1]{\left(1+\frac{x}{n}\right)^n\cdot 1} < \frac{n\left(1+\frac{x}{n}\right)+1}{n+1} = 1+\frac{x}{n+1}\,,$$

woraus sich sofort die erste Behauptung ergibt. Die reelle Folge $\left((1+\frac{x}{n})^n\right)_{n\geq -x}$ ist somit streng monoton wachsend und konvergiert daher sogar in $\mathbb{R}$, falls sie nach oben beschränkt ist. Um die Beschränktheit zu sehen, definieren wir für $x \in \mathbb{R}$ $E_n(x) = (1+\frac{x}{n})^n$. Zu $x \in \mathbb{R}$ sei $m \in \mathbb{N}$ so groß, dass $x \leq m$ gilt. Dann erhalten wir aus Monotoniegründen

$$E_n(x) \leq E_n(m) \leq E_{n\cdot m}(m) = (E_n(1))^m \leq 3^m\,,$$

was die Beschränktheit der Folge zeigt. Die verwendete Ungleichung $E_n(1) \leq 3$ lässt sich leicht zeigen.

Aufgabe 3.1.30

Diese Aufgabe ist deutlich schwieriger. Wir formulieren und beweisen zunächst die folgende
Behauptung: Die Folgen $(a_n)_{n\in\mathbb{N}}$ und $(A_n)_{n\in\mathbb{N}}$ erfüllen die folgenden Bedingungen: $(a_n)_{n\in\mathbb{N}}$ ist streng monoton wachsend, $(A_n)_{n\in\mathbb{N}}$ ist streng monoton fallend und es gilt $a_n < A_n$ für alle $n \in \mathbb{N}$.
Dies zeigen wir durch vollständige Induktion nach $n \geq 0$.
Induktionsanfang: $n = 0$. Es ist $a_0 < A_0$ nach Voraussetzung.
Induktionsschritt: $n \to n+1$. Da nach der Induktionsvoraussetzung $a_n < A_n$ gilt, erhalten wir

$$a_{n+1} = H(a_n, A_n) = \frac{2}{\frac{1}{a_n} + \frac{1}{A_n}} > \frac{2}{\frac{1}{a_n} + \frac{1}{a_n}} = a_n$$

und

$$A_{n+1} = G(a_n, A_n) = \sqrt{a_n A_n} < \sqrt{A_n^2} = A_n\,,$$

woraus die behaupteten Monotoniebedingungen folgen. Ferner haben wir nach Satz 3.1.27 die Ungleichung

$$a_{n+1} = H(a_n, A_n) < G(a_n, A_n) = A_{n+1}\,.$$

Die Folgen $(a_n)_{n\in\mathbb{N}}$ und $(A_n)_{n\in\mathbb{N}}$ sind somit monoton und beschränkt, so dass sie in $\mathbb{R}$ konvergieren. Um die Gleichheit der Grenzwerte nachzuweisen, müssen wir somit nur noch zeigen, dass die Differenz $A_n - a_n$ gegen 0 konvergiert. Wir erhalten aus der AGM-Ungleichung für beliebiges $n \in \mathbb{N}$:

$$\begin{aligned} A_{n+1} - a_{n+1} &= \sqrt{a_n A_n} - \frac{2a_n A_n}{a_n + A_n} = \sqrt{a_n A_n}\left(1 - \frac{2\sqrt{a_n A_n}}{a_n + A_n}\right) \\ &= \frac{2\sqrt{a_n A_n}}{a_n + A_n}\left(\frac{a_n + A_n}{2} - \sqrt{a_n A_n}\right) < \frac{a_n + A_n}{2} - \sqrt{a_n A_n} \\ &< \frac{a_n + A_n}{2} - a_n = \frac{A_n - a_n}{2} \end{aligned}$$

Induktiv folgt daraus, dass $0 < A_n - a_n < 2^{-n}(A_0 - a_0) \overset{n\to\infty}{\longrightarrow} 0$ gilt.

Lösungen der Aufgaben in 3.2

Aufgabe 3.2.6

(a) Es ist

$$\begin{aligned} s_x^2 &= \frac{1}{n-1}\sum_{i=1}^n (x_i-\bar{x})^2 = \frac{1}{n-1}\sum_{i=1}^n (x_i^2 - 2\bar{x}x_i + \bar{x}^2) \\ &= \frac{1}{n-1}\left(\sum_{i=1}^n x_i^2 - 2\bar{x}\sum_{i=1}^n x_i + n\bar{x}^2\right) = \frac{1}{n-1}\left(\sum_{i=1}^n x_i^2 - 2n\bar{x}^2 + n\bar{x}^2\right) \\ &= \frac{1}{n-1}\left(\sum_{i=1}^n x_i^2 - n\bar{x}^2\right) = \frac{1}{n-1}\left[\sum_{i=1}^n x_i^2 - \frac{1}{n}\left(\sum_{j=1}^n x_j\right)^2\right]. \end{aligned}$$

(b) Es ist $\bar{y} = a\bar{x} + b$, also

$$\begin{aligned} s_y^2 &= \frac{1}{n-1}\sum_{i=1}^n (y_i-\bar{y})^2 = \frac{1}{n-1}\sum_{i=1}^n (ax_i + b - (a\bar{x}+b))^2 \\ &= \frac{1}{n-1}\sum_{i=1}^n a^2(x_i-\bar{x})^2 = a^2 s_x^2\,. \end{aligned}$$

Aufgabe 3.2.8

Im Normalfall sollten die Zahlen $x_i - x^*$ betragsmäßig kleiner sein als die x_i, so dass wir $\bar{x} - x^* = \frac{1}{n}\sum_{i=1}^n (x_i - x^*)$ einfacher berechnen können als $\bar{x}$. Wir haben

$$\begin{aligned} \frac{1}{n}\sum_{i=1}^n (x_i-\bar{x})^2 &= \frac{1}{n}\sum_{i=1}^N h_i(x_i^*-\bar{x})^2 = \sum_{i=1}^N r_i(x_i^* - x^* + (x^*-\bar{x}))^2 \\ &= \sum_{i=1}^N r_i\left((x_i^*-x^*)^2 + 2(x_i^*-x^*)(x^*-\bar{x}) + (x^*-\bar{x})^2\right) \\ &= \sum_{i=1}^N r_i(x_i^*-x^*)^2 + 2(\bar{x}-x^*)(x^*-\bar{x}) + (x^*-\bar{x})^2 \\ &= \sum_{i=1}^N r_i(x_i^*-x^*)^2 - (x^*-\bar{x})^2\,, \end{aligned}$$

woraus die Behauptung unmittelbar folgt.

Aufgabe 3.2.11

Wir betrachten der Reihe nach die genannten Kenngrößen: Seien dazu stets $x = (x_1, \ldots, x_n) \in \mathbb{R}^n$ eine Stichprobe, $t \in \mathbb{R}$ und $a > 0$. Wir setzen $y := (x_1 + t, \ldots, x_n + t)$.
Spannweite: Es ist

$$\max_{1\le i\le n}(x_i + t) - \min_{1\le i\le n}(x_i + t) = \max_{1\le i\le n} x_i + t - (\min_{1\le i\le n} x_i + t) = \max_{1\le i\le n} x_i - \min_{1\le i\le n} x_i\,.$$

Ferner gilt

$$\max_{1\le i\le n} ax_i - \min_{1\le i\le n} ax_i = a(\max_{1\le i\le n} x_i - \min_{1\le i\le n} x_i)\,.$$

Mittlere absolute Abweichung vom Median: Ist x_k ein Median von x, so ist y_k einer von y. Somit gilt $\tilde{y} = \tilde{x} + t$. Damit erhalten wir

$$\frac{1}{n}\sum_{i=1}^{n}|y_i - \tilde{y}| = \frac{1}{n}\sum_{i=1}^{n}|x_i + t - (\tilde{x} + t)| = \frac{1}{n}\sum_{i=1}^{n}|x_i - \tilde{x}|\,.$$

Analog folgt auch

$$\frac{1}{n}\sum_{i=1}^{n}|ax_i - \widetilde{ax}| = a\frac{1}{n}\sum_{i=1}^{n}|x_i - \tilde{x}|\,.$$

Empirische Varianz, empirische Standardabweichung: Es gilt

$$\frac{1}{n-1}\sum_{i=1}^{n}(y_i - \bar{y})^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i + t - (\bar{x} + t))^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2\,.$$

Somit sind dies Streumaße. Die zweite Eigenschaft wird nach Aufgabe 3.2.6 von der empirischen Standardabweichung erfüllt, nicht aber von der empirischen Varianz.

Quartilsabstand: Ist x_k ein p-Quantil von x, so ist y_k eines von y und ax_k eines von ax. Somit gelten die folgenden Gleichungen mit offensichtlicher Notation:

$$q_{0.75}(y) - q_{0.25}(y) = q_{0.75}(x) + t - (q_{0.25}(x) + t) = q_{0.75}(x) - q_{0.25}(x)$$

$$q_{0.75}(ax) - q_{0.25}(ax) = a(q_{0.75}(x) - q_{0.25}(x))$$

Die erste besagt, dass der Quartilsabstand ein Streumaß ist und die zweite zeigt uns, dass er auch die zusätzliche Eigenschaft besitzt.

Kapitel 4

Regression und Korrelation

Wir untersuchen nun Zusammenhänge zwischen zwei oder mehr Merkmalen. Wir vergleichen Daten von zwei Merkmalen, die gleichzeitig an einer statistischen Einheit erhoben werden, z. B. die Körpergröße und das Körpergewicht. Stimmt die bekannte und teils nicht so beliebte Faustformel „Gewicht ist gleich Größe minus 100 abzüglich 15 Prozent“ ? In anderen Beispielen möchte man das Bruttoeinkommen und das Kapitalvermögen bei jungen Familien in Deutschland untersuchen, oder den Zusammenhang zwischen der Geschwindigkeit und dem Bremsweg bei Autos, oder dem Nettoeinkommen und den Mietkosten für das Wohnen in München. Eine Frage ist etwa: Gehen gute Leistungen in Mathematik mit guten Leistungen in Naturwissenschaften einher? Steigen Mietkosten bei höherem Nettoeinkommen, und wenn ja, wie? Wir betrachten in diesem Kapitel zwei Konzepte zur Untersuchung von Zusammenhängen. Zunächst betrachten wir Situationen, bei denen man auf Grund theoretischer Annahmen von einer Ursache-Wirkungs-Beziehung ausgehen kann, konkret betrachten wir den Fall der Annahme eines linearen Zusammenhangs. Dies führt uns zu dem Verfahren der *linearen Regression*. Dann entwickeln wir den so genannten *Korrelationskoeffizienten*, der ein Maß für den linearen Gleichklang ist. Hierbei bedeutet ein Zusammenhang der Merkmale nicht, dass das eine Merkmal ursächlich auf das andere Merkmal Einfluss nimmt.

4.1 Lineare Regression

Das Wort *regressus* kommt aus dem Lateinischen und bedeutet *Rückkehr* oder *Rückzug*. Wir gehen später auf die Herkunft dieses Begriffes ein. Beim Verfahren der Regression möchte man — im linearen Fall — eine Gerade so in die Punktwolke

vorgegebener Wertepaare

$$(x_1, y_1),\ (x_2, y_2), \ldots, (x_n, y_n)$$

zeichnen, dass sie möglichst gut mit der „Richtung der Wolke“ übereinstimmt.

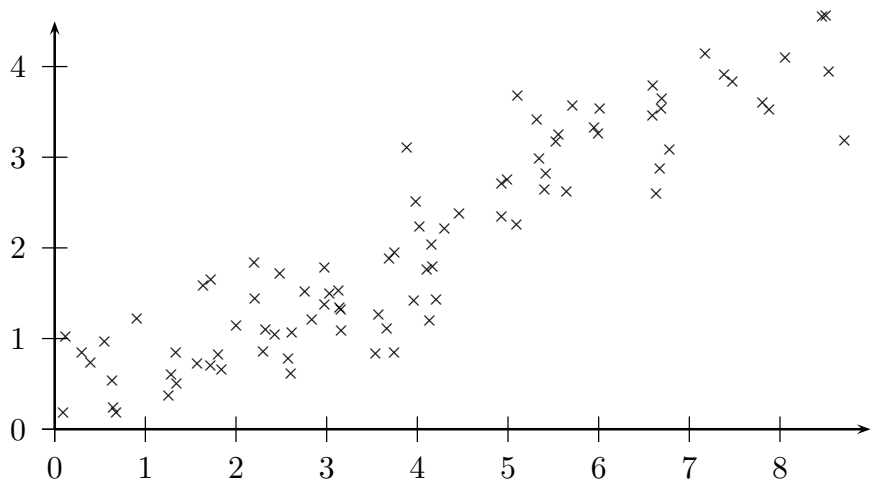

Abb. 4.1: Punktewolke

Die obige Faustregel etwa legt nahe, dass es zwischen Körpergröße und Körpergewicht einen linearen Zusammenhang geben könnte. Messen wir die Länge eines Metallstabes bei unterschiedlichen Temperaturen, so besagt ein physikalisches Gesetz, dass man in einem gewissen Temperaturbereich von einem linearen Zusammenhang zwischen Temperatur und Länge des Metallstabes ausgehen kann. Die Steigung der Geraden in diesem Beispiel wird Ausdehnungskoeffizient genannt. Die Wertepaare $(x_1, y_1), \ldots, (x_n, y_n)$ werden im Allgemeinen, beim letzten Beispiel etwa bedingt durch Messfehler, nicht exakt eine Gerade beschreiben.

Wenn wir eine Ausgleichgerade finden können, so nennt man sie die Regressionsgerade. Die aus der Punktwolke und der Regressionsgeraden bestehende Grafik heißt *Streudiagramm.* Die mit der Regression verbundene zweite Problemstellung ist, dass man aus einem bekannten Wert vom ersten Merkmal auf einen zu erwartenden Wert des zweiten Merkmals schließen möchte: wir erhoffen eine Möglichkeit der *Prognose* oder *Vorhersage.* Mit den x_i, y_i beschreibt man einen Zusammenhang quantitativ, von dem man annimmt, dass er auch gilt, wenn das zweite Merkmal auf Grund neuer Werte des ersten Merkmals vorhergesagt werden soll.

Wir suchen die Koeffizienten einer affin-linearen Funktion $h(x) = ax + b$. Für eine hypothetische Lösung a, b kann man die Abweichungen oder *Residuen*

$$r_i(a, b) := y_i - (ax_i + b)$$

bilden.

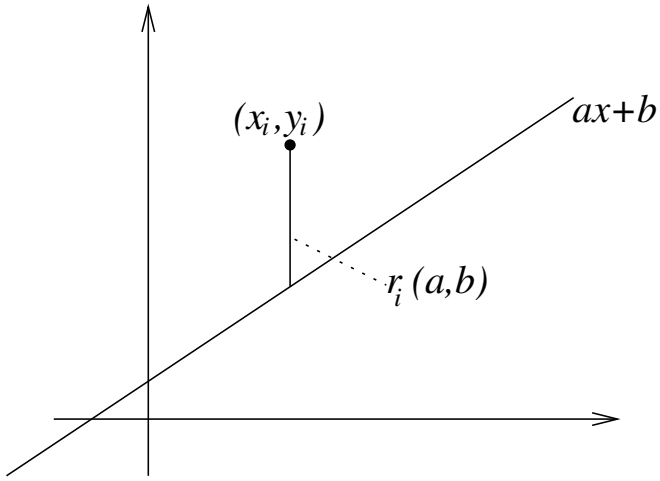

Abb. 4.2: Residuen $r_i(a, b)$

Eine gute Ausgleichsgerade wird in einem geeigneten Sinn diese Residuen minimieren. Da es sowohl negative als auch positive Residuen gibt, ist die Wahl der Summe der Residuen keine geeignete. Wir wählen ein bekanntes Streumaß, zum Beispiel die mittlere absolute Abweichung oder die empirische Varianz. Das gebräuchlichste Maß für die Größe der Abweichungen ist

$$Q(a, b) := \sum_{i=1}^{n} \Big(r_i(a, b) \Big)^2 .$$

Die Forderung geringer Abweichungen führt zu der Bestimmung eines minimalen Wertes von $Q(a, b)$. Dieses Verfahren heißt *Methode der kleinsten Quadrate* (least squares) und wurde von Gauss (1809) und Legendre (1806) eingeführt (Adrien-Marie Legendre (1752–1833)). Hierzu ein historisches Intermezzo:

Der Astronom Guiseppe Piazzi (1746–1826) entdeckte 1801 ein neues Himmelsobjekt, der nur ein Komet oder ein Planet sein konnte. Piazzi verlor ihn nach kurzer Zeit aus den Augen. Er hatte wenige Bahndaten erheben können und wusste, dass eine parabelförmige Umlaufbahn nicht vorliegen konnte. Gauss konnte helfen, indem er eine Ellipse bestimmte, die sich den Bahndaten von Piazzi anpasste. Dazu löste er eine Gleichung 8-ten Grades und entwickelte die Methode

der kleinsten Quadrate. Nach der Bestimmung der Bahn des Planetoiden *Ceres*, so der Name des verlorengegangenen Objekts, entdeckte der Astronom Heinrich Olbers (1758–1840) Ceres in der Neujahrsnacht 1802 wieder. Gauss veröffentlichte seine Methode erst 1809 in seinem Werk *Theoria motus corporum*. Die Bahn des Ceres verläuft zwischen denen von Mars und Jupiter.

Wir müssen eine Funktion in zwei Veränderlichen untersuchen. Die Bestimmung von Extrema ist Stoff einer Analysisausbildung, die über die mathematischen Grundlagenvorlesung hinausgeht. Wenn man die Methoden der mehrdimensionalen Analysis beherrscht, so müssen zunächst die Nullstellen der partiellen Ableitungen bestimmt werden. Wir führen diese Rechnung hier vor. Im Anschluss wird eine Herleitung der Methode der kleinsten Quadrate vorgestellt, die auf die Methoden der mehrdimensionalen Analysis verzichten kann. Wir bestimmen

$$\frac{\partial Q(a,b)}{\partial a} = \sum_{i=1}^{n} 2r_i(a,b)(-x_i) = 0$$

$$\frac{\partial Q(a,b)}{\partial b} = \sum_{i=1}^{n} 2r_i(a,b)(-1) = 0$$

Dies führt zu den Gleichungen

$$\sum_{i=1}^{n}\Big(y_i - (ax_i + b)\Big)x_i = 0 \text{ und } \sum_{i=1}^{n}\Big(y_i - (ax_i + b)\Big) = 0\,.$$

Löst man die 2. Gleichung nach b auf, so folgt

$$b = \frac{1}{n}\sum_{i=1}^{n}(y_i - ax_i) = \bar{y} - a\bar{x},$$

also $\bar{y} = a\bar{x} + b$. Diese Zwischenrechnung bedeutet, dass der Schwerpunkt $(\bar{x}, \bar{y})$ auf der gesuchten Geraden liegt. Es folgt

$$\sum_i\Big(y_i - \bar{y} - a(x_i - \bar{x})\Big)x_i = 0,$$

$$\text{also } a = \frac{\sum_i (y_i - \bar{y})x_i}{\sum_i (x_i - \bar{x})x_i}.$$

Verwendet man $\sum_i (x_i - \bar{x}) = 0$ sowie $\sum_i (y_i - \bar{y}) = 0$, so folgt

$$a = \frac{\sum (y_i - \bar{y})(x_i - \bar{x})}{\sum (x_i - \bar{x})^2} = \frac{\frac{1}{n-1}\sum_{i=1}^{n}(y_i - \bar{y})(x_i - \bar{x})}{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2} =: \frac{s_{xy}}{s_x^2}\,.$$

Es folgt insgesamt

$$a = \frac{s_{xy}}{s_x^2}, \quad b = \bar{y} - a\bar{x} = \bar{y} - \frac{s_{xy}}{s_x^2}\bar{x}.$$

Die partiellen Ableitungen sind bei Wahl dieser Werte für a und b gleich Null. Eine hinreichende Bedingung dafür, dass an dieser Stelle (a, b) ein lokales Minimum vorliegt, ist, dass die Hessesche Matrix von Q im Punkt (a, b) positiv definit ist. Diesen Teil der Rechnung sparen wir uns an dieser Stelle. Tatsächlich handelt es sich um ein lokales Minimum. Die Gleichung der Regressionsgeraden lautet somit

$$y = \bar{y} + \frac{s_{xy}}{s_x^2}(x - \bar{x})\,.$$

Wir halten das Resultat fest:

4.1.1 Satz: Zu gegebenen Datenreihen $x = (x_1, \ldots, x_n)$ und $y = (y_1, \ldots, y_n)$ mit arithmetischem Mittel $\bar{x}$ und $\bar{y}$ ist nach der Methode der kleinsten Quadrate die optimale Ausgleichsgerade $y = a\,x + b$ eindeutig bestimmt mit

$$a := \frac{s_{xy}}{s_x^2}, \quad b := \bar{y} - a\bar{x} = \bar{y} - \frac{s_{xy}}{s_x^2}\bar{x}.$$

Die Gerade heißt *Gerade der linearen Regression* von y auf x oder kurz *Regressionsgerade*. Die Steigung a heißt *Regressionsgewicht* oder *Regressionskoeffizient*.

4.1.2 Bemerkungen: (i) Die Steigung der Regressionsgerade gibt an, wie stark Veränderungen in der unabhängigen Stichprobe x Veränderungen in der abhängigen Stichprobe y verursachen.

(ii) Man nennt die gefundene Regressionsgerade die Ausgleichsgerade bzgl. y. Hier ist die Summe der quadratischen Abweichungen in vertikaler Richtung minimiert worden. Die Ausgleichsgerade bzgl. x mit $x = ay + b$ ergibt sich entlang der obigen Rechnung analog zu:

$$x = \bar{x} + \frac{s_{xy}}{s_y^2}(y - \bar{y})\,.$$

Die beiden Ausgleichsgeraden stimmen in der Regel nicht überein. Sie schneiden sich im Schwerpunkt $(\bar{x}, \bar{y})$. Besteht ein strenger linearer Zusammenhang zwischen den Daten aus x und y, so stimmen die beiden Regressionsgeraden überein, was zur Folge hat, dass das Produkt der Regressionskoeffizienten 1 ist:

$$\frac{s_{xy}}{s_x^2}\,\frac{s_{xy}}{s_y^2} = 1.$$

Dass die linke Seite ein Maß für die „Korrelation" der beiden Merkmale ist, werden wir später genauer sehen.

(iii) Man könnte auch $\sum_{i=1}^{n} |r_i(a,b)|$ (die so genannte L_1-Norm) minimieren. Dieses Verfahren ist eher robust gegenüber extremen y-Werten. Auch ist eine *orthogonale Regression* denkbar, bei der man die Quadratsumme der orthogonalen Abstände $d_i(a,b)$ minimiert, siehe Abbildung 4.3.

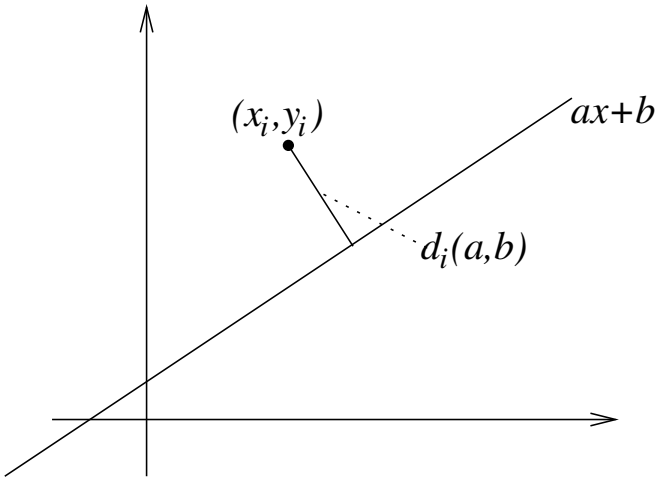

Abb. 4.3: Orthogonale Regression

Wir betrachten wie angekündigt eine Herleitung der Regressionsgerade ohne Verwendung der Methoden der Analysis von Funktionen in mehreren Veränderlichen. Diese Herleitung ermöglicht es auch, Regressionsgeraden zum Gegenstand der Schulmathematik zu machen.

Es wäre von Vorteil, wenn man eine der beiden Variablen (a oder b) verschwinden lassen könnte. Wir betrachten zwei Sichtweisen. Bei der ersten nehmen wir zunächst ohne Begründung an, dass der Schwerpunkt $(\bar{x}, \bar{y})$ auf der gesuchten Regressionsgeraden liegt. Unter dieser Annahme

$$b = \bar{y} - a\bar{x}$$

erhalten wir

$$Q(a,b) = f(a) = \sum_{i=1}^{n} \left(y_i - (ax_i + \bar{y} - a\bar{x})\right)^2 .$$

Dies führt nach elementaren Umformungen auf

$$f(a) = (n-1)\Big(s_{y^2} - 2as_{xy} + a^2 s_x^2\Big)$$

und dann durch Optimierung in a zu der bereits bestimmten Regressionsgeraden. Nun kann man – nach Bestimmung der Regressionsgeraden unter der Annahme,

$(\bar{x}, \bar{y})$ liege auf dieser – im Anschluss klären, dass der Schwerpunkt automatisch auf der Regressionsgeraden liegt. Fordere dazu, $(\bar{x}, \bar{y} + c)$ liege auf $y = ax + b$ (Regressionsgerade), also

$$\begin{aligned} \bar{y} + c &= a\bar{x} + b, \text{ also ist} \\ b &= \bar{y} + c - a\bar{x}, \text{ womit} \\ y &= ax + \bar{y} + c - a\bar{x} = \bar{y} + c + a(x - \bar{x}) \text{ folgt.} \end{aligned}$$

Dies setzen wir einfach ein:

$$\begin{aligned} &\sum_{i=1}^{n} \Big(y_i - \big(\bar{y} + c + a(x_i - \bar{x})\big)\Big)^2 \\ &= \sum_{i=1}^{n} \Bigg(\Big(y_i - \bar{y}\Big)^2 - 2a\Big(y_i - \bar{y}\Big)\Big(x_i - \bar{x}\Big) + a^2\Big(x_i - \bar{x}\Big)^2 + c^2 \\ &\qquad - 2c\Big(y_i - \bar{y}\Big) + 2ac\Big(x_i - \bar{x}\Big)\Bigg) \\ &= (n-1)\Big(s_y^2 - 2as_{xy} + a^2 s_x^2\Big) + nc^2 \\ &\qquad - 2c\sum_{i=1}^{n} \Bigg(\Big(y_i - \bar{y}\Big) - a\Big(x_i - \bar{x}\Big)\Bigg). \end{aligned}$$

Verwendet man $\sum_{i=1}^{n} \Big(y_i - \bar{y}\Big) = 0$ und $\sum_{i=1}^{n} \Big(x_i - \bar{x}\Big) = 0$, erhält man

$$\sum_{i=1}^{n} \Big(y_i - \big(\bar{y} + c + a(x_i - \bar{x})\big)\Big)^2 = (n-1)\Big(s_y^2 - 2as_{xy} + a^2 s_x^2\Big) + nc^2.$$

Dieser Ausdruck wird für $c = 0$ minimal.

Die andere Sichtweise ist, direkt a festzuhalten, also $Q_a(b) := Q(a, b)$ zu betrachten. Dann handelt es sich um eine durch a indizierte Schar von Parabeln, die alle nach oben geöffnet sind, also jeweils ein eindeutiges Minimum aufweisen. Das Minmum $m(a)$ hängt von a ab. Dann bestimmt man dasjenige a, für das $m(a)$ minimal wird. Die Bestimmung der Nullstellen der ersten Ableitung von $Q_a(\cdot)$ führt aber ebenfalls zur Beobachtung, dass der Schwerpunkt auf der gesuchten Geraden liegt. Der Rest der Herleitung erfolgt nun analog.

Das Wort Regression geht auf Sir Francis Galton (1822–1911) zurück. Er stellte fest, dass große Väter häufig große Nachkommen haben, aber dass die durchschnittliche Größe der Nachkommen kleiner ist als die der Väter. Analog haben kleine Väter häufig kleine Nachkommen, aber die Durchschnittsgröße war größer als die der Väter. Es gibt eine Tendenz zur Durchschnittsgröße, es liegt ein

„Zurückgehen“ bzgl. der Größe der Nachkommen auf den Durchschnitt vor. Man spricht hierbei vom *Regressionseffekt* oder von der *Regression zur Mitte.*

Es bleibt festzuhalten, dass sich Regressionsgeraden immer bestimmen lassen, also auch in Situationen, in denen die Annahme eines linearen Zusammenhangs Blödsinn ist. Darüberhinaus muß man bei der Interpretation der berechneten Regressionsgeraden vorsichtig sein. Ausgangspunkt ist etwa eine Stichprobe aus einem bestimmten Bereich, zum Beispiel typische Körpergrößen zwischen 160 cm und 200 cm. Vorhersagen des Körpergewichts für eine seltene Körpergröße wie etwa 140 cm oder 230 cm sollten aus der Geraden nicht abgelesen werden.

Wir betrachten das folgende Beispiel:

4.1.3 Beispiel: Der Spiegel hat 1992 gemeldet, dass die schnellste Frau im Jahr 1998 den Marathon in derselben Zeit läuft wie der schnellste Mann. Wie kommt diese Prognose zustande? Wir betrachten die Entwicklung der Weltrekorde im Marathon bei Männern und Frauen im Zeitraum 1908–1985/88, siehe Tabelle 4.1 und 4.2.

Jahr	Frauen (min)	Geschwindigkeit (m/min)
1963	217,12	194,34
1964	199,55	211,45
1967	195,37	225,12
1970	182,88	230,73
1974	163,90	257,44
1975	158,32	266,52
1977	154,80	272,58
1978	152,50	276,69
1979	147,55	285,97
1980	145,68	289,64
1981	145,48	290,04
1983	142,72	295,65
1985	141,10	299,04
(1998)	(140,80)	(299,71)

Tab. 4.1: Entwicklung der Weltrekorde im Marathon der Frauen. In Klammern der tatsächliche Wert.

Die Regressionsgeraden für die Weltrekorde im Marathon im Vergleich ergeben das Bild in Abbildung 4.4.

Jahr	Männer (min)	Geschwindigkeit (m/min)
1908	175,31	240,69
1909	160,57	262,78
1913	156,11	270,29
1920	152,60	275,51
1925	149,03	283,13
1935	146,70	287,63
1947	145,65	289,70
1952	140,70	299,89
1953	138,58	304,48
1954	137,66	306,52
1958	135,28	311,91
1960	135,27	311,93
1963	134,47	313,79
1964	132,19	319,20
1965	132,00	319,66
1967	129,61	325,55
1969	128,56	328,21
1984	128,08	329,44
1985	127,20	331,72
1988	126,93	332,43
(1998)	(126,04)	(324,66)

Tab. 4.2: Entwicklung der Weltrekorde im Marathon der Männer. In Klammern der tatsächliche Wert.

Dem Bild entnimmt man, dass die Frauen die Durchschnittsgeschwindigkeit in den Jahren 1962-1992 erheblich verbessern konnten. Die Steigerung bei den Männern verlief deutlich langsamer. 1998 hat sich aber der Abstand zwischen den Zeiten sogar etwas vergrößert. Die lineare Regression darf nicht dazu führen, dass man solch falsche Prognosen formuliert!

4.1.4 Aufgabe: Eine alternative Methode zur Bestimmung einer Ausgleichsgeraden ist die folgende: Man zerlege die Punktwolke in zwei etwa gleich große Teilwolken, und bestimme zu beiden Wolken den Schwerpunkt. Dann wähle man als Ausgleichsgerade die Gerade durch diese Schwerpunkte. Dabei ordne man die Punkte nach der Größe der x-Werte oder der y-Werte und zerlege dann in zwei Punktwolken. An einem 50 cm langen Aluminiumstab wurde die Längenzunahme Δl (gemessen in 1/100 Millimeter) bei Erwärmung gemessen, siehe Tabelle 4.3

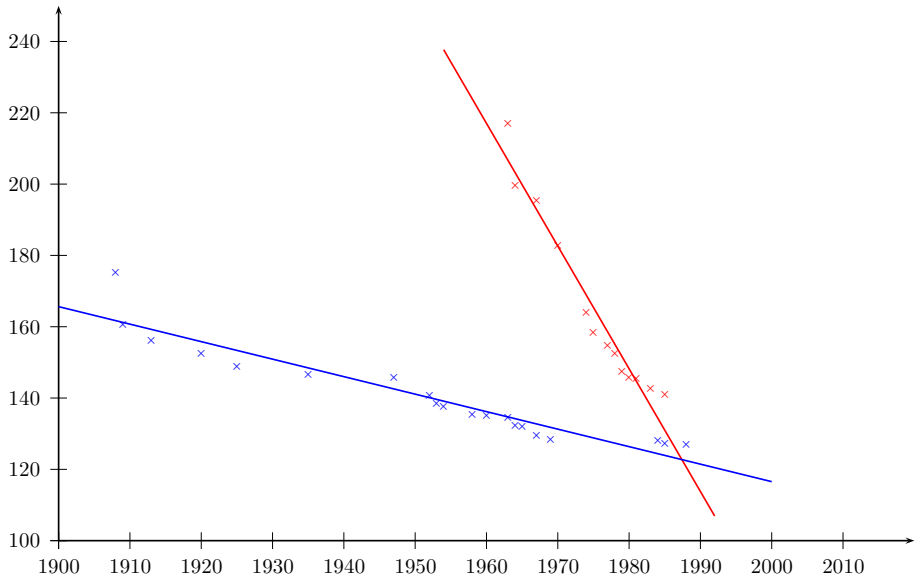

Abb. 4.4: Regressionsgeraden

Temperatur in Grad	0	10	20	30	40	50	60	70	80	90
Δl	0	12	24	37	48	59	74	82	97	105

Tab. 4.3: Die gemessene Längenzunahme Δl (gemessen in 1/100 Millimeter) bei Erwärmung eines 50 cm langen Aluminiumstabs

Berechnen Sie den Ausdehnungskoffizient, also die relative Längenänderung bei Zunahme der Temperatur um 1 Grad. Verwenden Sie dazu zunächst die Methode der kleinsten Quadrate, im Anschluss dann die soeben beschriebene Alternativmethode.

4.1.5 Aufgabe: Wir betrachten drei Merkmale und zugehörige Stichproben x, y und z der Länge n. Die *Regressionsebene* von z bezüglich x und y mit der Gleichung

$$z = \alpha\, x + \beta\, y + \gamma$$

sei dadurch festgelegt, dass

$$\sum_{i=1}^{n} \Big(z_i - (\alpha\, x_i + \beta\, y_i + \gamma) \Big)^2$$

minimal ist. Stellen Sie ein lineares Gleichungssytem zur Berechnung der Koeffizienten α, β, γ auf.

Bleibt zu bemerken, dass sich die Methode der kleinsten Quadrate nicht auf den Fall der linearen Regression beschränkt. Die Methoden zur Bestimmung anderer Regressionen wie etwa der *polynomialen Regression* oder der *mehrfach linearen Regression* verwenden Techniken der Linearen Algebra wie den Begriff der orthogonalen Projektion. Man untersucht das so genannte *allgemeine lineare Modell* und kommt zur Theorie von Gauss und Andrei Andreyevich Markov (1856–1922). Dies verfolgen wir hier nicht weiter.

4.2 Korrelationskoeffizient

Wir motivieren nun einen Koeffizienten, der als Maß des Zusammenhangs zwischen Merkmalen dienen kann. Genauer suchen wir ein Maß für die Güte des linearen Zusammenhangs zweier Merkmale. Dies führt zu einem so genannten *Korrelationskoeffizienten.*

Zunächst bekommt der Ausdruck s_{xy}, der den Regressionskoeffizient mitbestimmt, einen eigenen Namen:

4.2.1 Definition: Für zwei intervallskalierte Merkmale seien die Stichproben $x = (x_1, \ldots, x_n)$ und $y = (y_1, \ldots, y_n)$ gegeben. Dann bezeichnet man

$$s_{xy} := \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})$$

als die *empirische Kovarianz* der beiden Messreihen.

4.2.2 Aufgabe: Zeigen Sie, dass

$$s_{xy} = \frac{1}{n-1} \left(\sum_{i=1}^{n} x_i \, y_i - n \, \bar{x} \, \bar{y} \right)$$

gilt.

Auf der Suche nach einem Maß für die Stärke (Güte) des linearen Zusammenhangs zweier Merkmale gehen wir wie folgt vor: Wir betrachten die y-Werte auf der bestimmten Regressionsgerade,

$$\hat{y}_i := a \, x_i + b$$

für jedes $i = 1, \ldots, n$. Jetzt *vergleichen* wir die empirische Varianz der $\hat{y}_i$ Werte auf der Regressionsgeraden mit der Varianz der tatsächlichen y_i-Werte aus der

Erhebung. Die empirische Varianz der "Hutwerte" ist gegeben durch

$$\frac{1}{n-1}\sum_{i=1}^{n}(\hat{y}_i - \bar{\hat{y}})^2\,,$$

wenn $\bar{\hat{y}}$ das arithmetische Mittel der $\hat{y}_i$, $i = 1, \ldots, n$, bezeichnet. Es gilt $\hat{y}_i - \bar{y} = a(x_i - \bar{x})$ und $\hat{y}_i = ax_i - a\bar{x} + \bar{y}$, also ist

$$\bar{\hat{y}} = \frac{1}{n}\sum_{i=1}^{n}(ax_i - a\bar{x} + \bar{y}) = \bar{y},$$

und somit

$$\begin{aligned}\frac{1}{n-1}\sum_{i=1}^{n}(\hat{y}_i - \bar{\hat{y}})^2 &= \frac{1}{n-1}\sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2 = \frac{1}{n-1}\sum_{i=1}^{n}(a(x_i - \bar{x}))^2 \\ &= a^2 s_x^2 = \frac{s_{xy}^2}{s_x^4}s_x^2 = \frac{s_{xy}^2}{s_x^2}.\end{aligned}$$

Diese Varianz wollen wir mit der Varianz der y-Werte vergleichen, also mit s_y^2. Daher betrachten wir den Quotienten

$$\frac{s_{xy}^2}{s_x^2 s_y^2}.$$

Diese Zahl ist ein Maß für die Stärke der linearen Abhängigkeit der beiden Datenreihen:

4.2.3 Definition: Gegeben seien für zwei intervallskalierte Merkmale die Stichproben $x = (x_1, \ldots, x_n)$ und $y = (y_1, \ldots, y_n)$. Die Zahl $r_{xy} := \dfrac{s_{xy}}{s_x s_y}$ mit $s_x \neq 0$ und $s_y \neq 0$ heißt *Korrelationskoeffizient* nach Auguste Bravais (1811–1863) und Karl Pearson. s_{xy} bestimmt das Vorzeichen von r_{xy}.

4.2.4 Bemerkungen: (i) Mit $\tilde{x}_i = \frac{x_i - \bar{x}}{s_x}$ und $\tilde{y}_i = \frac{y_i - \bar{y}}{s_y}$ ist $\tilde{x}_i \cdot \tilde{y}_i$ ein Maß für den Zusammenhang und liefert die Darstellung

$$r_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}\tilde{x}_i\tilde{y}_i,$$

also den Korrelationskoeffizienten. Mit dieser alternativen Darstellung befassen wir uns einen Augenblick. Stellen wir mittels einer Punktewolke die Wertepaare $(x_1, y_1), \ldots, (x_n, y_n)$ dar, so erhalten wir in der Regel rasch einen ersten Eindruck über einen möglichen Zusammenhang zwischen den beiden

Merkmalen. Der Eindruck hängt aber stark von der gewählten Skalierung auf beiden Achsen ab. Weiter bleibt eventuell unberücksichtigt, dass die beiden Merkmale auf unterschiedlichen Skalen gemessen wurden. Die Willkür der Skalierung kann durch die Wahl so genannter *standardisierter Daten* behoben werden. Wir betrachten anstelle von x_i den Wert $\tilde{x_i} = (x_i - \bar{x})/s_x$ und analog $\tilde{y_i}$. Es ist einfach zu sehen, dass die Stichprobe $z := (\tilde{x_1}, \ldots, \tilde{x_n})$ das arithmetische Mittel $\bar{z} = 0$ und die Varianz $s_z^2 = 1$ hat. Gehen wir nun von einem standardisierten Wertepaar $(\tilde{x_i}, \tilde{y_i})$ aus, so erzeugt dieses ein Rechteck mit dem Flächeninhalt $\tilde{x_i}\,\tilde{y_i}$. Dieser Flächeninhalt trägt ein Vorzeichen. Liegt das Wertepaar im II. oder IV. Quadrant des Koordinatensystems, so liegt ein negativer Wert vor, da genau einer der beiden Werte negativ ist. Wertepaare im I. und III. Quadranten liefern positive Werte. Man betrachte nun den mittleren orientierten Flächeninhalt aller Wertepaare, erneut gewichtet mit $1/(n-1)$ anstatt mit $1/n$. Dies ist der Korrelationskoeffizient r_{xy}.

(ii) Wir erinnern an Bemerkung 4.1.2(ii): r_{xy} ist bis auf das Vorzeichen das geometrische Mittel der Steigungen der Regressionsgeraden bzgl. x und bzgl. y. Die Interpretation: Die beiden Regressionsgeraden können nur dann übereinstimmen, wenn alle Punkte auf einer Geraden liegen. „Driften“ die Punkte auseinander, wird der Winkel zwischen den beiden Regressionsgeraden größer. Im Extremfall sind sie zueinander orthogonal. Aus einem hohen Korrelationskoeffizienten schließen wir auf einen inhaltlichen, linearen Zusammenhang, nicht notwendig auf einen ursächlichen Zusammenhang. Das klassische Beispiel ist: leben auf dem Lande mehr Störche und werden mehr Kinder geboren (in zeitlicher Entwicklung), so ist damit nicht gesagt, dass der Storch die Kinder bringt, auch wenn die Vorstellung, dass dem so wäre, für Kinder schön ist. Was ein hoher Wert für den Koeffizienten ist, klären wir in Satz 4.2.6.

4.2.5 Aufgabe: Gegeben seien zwei Stichproben $x = (x_1, \ldots, x_n)$ und $y = (y_1, \ldots, y_n)$. Zeigen Sie für $R(a,b) := \sum_{i=1}^n (y_i - b - ax_i)^2$ mit a, b gegeben durch die Werte in Satz 4.1.1, dass

$$R(a,b) = (n-1)\left(s_y^2 - \frac{s_{xy}^2}{s_x^2}\right) = (n-1)(s_y^2 - a^2\, s_x^2) = (n-1)(1 - r_{xy}^2)s_y^2$$

gilt.

Welche Werte kann der Korrelationskoeffizient r_{xy} annehmen?

4.2.6 Satz: Es gilt $-1 \leq r_{xy} \leq 1$.

Beweis: Für $u, v \in \mathbb{R}$ gilt:

$$\sum_{i=1}^{n} (u(x_i - \bar{x}) + v(y_i - \bar{y}))^2 = u^2 \sum_{i=1}^{n} (x_i - \bar{x})^2 + 2uv \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}) + v^2 \sum_{i=1}^{n} (y_i - \bar{y})^2.$$

Daraus folgt

$$0 \leq \frac{1}{n-1} \sum_{i=1}^{n} (u(x_i - \bar{x}) + v(y_i - \bar{y}))^2 = u^2 s_x^2 + 2uv s_{xy} + v^2 s_y^2.$$

Wir wählen nun $u = s_y$ und $v = -s_x$ und erhalten

$$\begin{aligned} s_x^2 s_y^2 + 2(s_y)(-s_x) s_{xy} + s_x^2 s_y^2 &\geq 0 \\ s_x s_y s_{xy} &\leq s_x^2 s_y^2 \\ r_{xy} &\leq 1. \end{aligned}$$

Wählen wir $u = s_y$ und $v = s_x$, so folgt

$$s_y^2 s_x^2 + s_x s_y s_{xy} \geq 0,$$

also $r_{xy} \geq -1$. □

Der Beweisweg des obigen Satzes entspricht dem einer sehr bekannten Ungleichung:

4.2.7 Satz: (Ungleichung von Cauchy-Schwarz) Für reelle Zahlen $x_1, \ldots, x_n$ und $y_1, \ldots, y_n$ gilt

$$\left(\sum_{i=1}^{n} x_i y_i \right)^2 \leq \left(\sum_{i=1}^{n} x_i^2 \right) \left(\sum_{i=1}^{n} y_i^2 \right).$$

Die Ungleichung ist benannt nach Augustin Louis Cauchy (1789–1857) und Hermann Amandus Schwarz (1843–1921).

Beweis: Für jedes $u \in \mathbb{R}$ gilt

$$0 \leq \sum_{i=1}^{n} (u x_i + y_i)^2 = u^2 \sum_{i=1}^{n} x_i^2 + 2u \sum_{i=1}^{n} x_i y_i + \sum_{i=1}^{n} y_i^2 =: a u^2 + 2bu + c,$$

wobei wir

$$a := \sum_{i=1}^{n} x_i^2, \quad b := \sum_{i=1}^{n} x_i y_i, \quad c := \sum_{i=1}^{n} y_i^2$$

gesetzt haben. Für den Fall, dass $a > 0$, wählen wir nun $u = -\frac{b}{a}$ und erhalten

$$0 \leq a \frac{b^2}{a^2} - 2b \frac{b}{a} + c = \frac{1}{a}(ac - b^2),$$

also $b^2 \leq ac$, was die Behauptung ist. Im Fall $a = 0$ folgt $x_1 = x_2 = \cdots = x_n = 0$, und in diesem Fall ist die Ungleichung ohnehin erfüllt. □

In manchen Lehrbüchern wird für Satz 4.2.6 ein alternativer Beweis gegeben, der die CAUCHY-SCHWARZ-Ungleichung voraussetzt. Der Beweis nutzt das kanonische Skalarprodukt im $\mathbb{R}^n$, welches wir mit $\langle \cdot, \cdot \rangle$ bezeichnen. Es sei $u_i = x_i - \bar{x}$, $v_i = y_i - \bar{y}$. Mit $\|x\|$ bezeichnen wir die EUKLIDische Norm von $x \in \mathbb{R}^n$. Dann ist $\|x\|^2 = \langle x, x \rangle = \sum_{i=1}^n x_i^2$ und analog $\|y\|^2 = \sum_{i=1}^n y_i^2$. Nun gilt $(n-1)s_x^2 = \|u\|^2$, $(n-1)s_y^2 = \|v\|^2$ und $(n-1)s_{xy} = \langle u, v \rangle = \|u\| \, \|v\| \cos \angle(u, v)$, wobei $\angle(u, v)$ den Winkel zwischen den Vektoren u and v bezeichnet. Somit haben wir für den Korrelationskoeffizienten die Darstellung

$$r_{xy} = \frac{\langle u, v \rangle}{\|u\| \, \|v\|} = \cos \angle(u, v).$$

gefunden. Mit Hilfe der Ungleichung von CAUCHY-SCHWARZ, $|\langle x, y \rangle| \leq \|x\| \, \|y\|$, folgt die Aussage in Satz 4.2.6 ebenfalls.

Dem folgenden Satz entnehmen wir weitere Eigenschaften des Korrelationskoeffizienten:

4.2.8 Satz: Aus $|r_{xy}| = 1$ folgt die lineare Beziehung $y_i = ax_i + b$ für $i = 1, \ldots, n$ mit $a = r_{xy} \frac{s_y}{s_x}$ und $b = \bar{y} - r_{xy} \frac{s_y}{s_x} \bar{x}$. Liegen alle Punkte $(x_i, y_i), i = 1, \ldots, n$, auf einer Geraden $ax + b$, so gilt

$$r_{xy} = \begin{cases} 1 & \text{für } a > 0, \\ -1 & \text{für } a < 0 \end{cases}$$

(für $a = 0$ ist wegen $s_y = 0 \quad r_{xy}$ nicht definiert).

Beweis: Wir zeigen zunächst: $r_{xy} = 1$ genau dann, wenn $\tilde{x}_i = \tilde{y}_i$ für alle $i = 1, \ldots, n$ (hierbei verwenden wir die Bezeichnung aus Bemerkung 4.2.4(i)). Wenn $\tilde{x}_i = \tilde{y}_i$ für alle i gilt, so folgt mit der Darstellung des Korrelationskoeffizienten aus Bemerkung 4.2.4(i) $r_{xy} = \frac{1}{n-1} \sum_{i=1}^n \tilde{x}_i{}^2 = 1$, denn dies ist die empirische Varianz des standardisierten Datensatzes. Mit

$$\sum_{i=1}^n \tilde{x}_i{}^2 = \sum_{i=1}^n \tilde{y}_i{}^2 = n - 1$$

folgt

$$0 \leq \sum_{i=1}^n (\tilde{x}_i - \tilde{y}_i)^2 = 2(n-1) - 2 \sum_{i=1}^n \tilde{x}_i \tilde{y}_i.$$

Ist nun umgekehrt $r_{xy} = 1$, also $\sum_{i=1}^n \tilde{x}_i \tilde{y}_i = n - 1$, so folgt daraus, dass die EUKLIDische Norm von $\tilde{x} - \tilde{y}$ Null ist, also $\tilde{x}_i = \tilde{y}_i$ für alle i.

Aus $\tilde{x}_i = \frac{x_i - \bar{x}}{s_x} = \tilde{y}_i = \frac{y_i - \bar{y}}{s_y}$ erhält man

$$y_i = \frac{s_y}{s_x}(x_i - \bar{x}) + \bar{y},$$

also hängen die Daten der Stichprobe y affin-linear von den Daten der Stichprobe x mit positivem $a = \frac{s_y}{s_x}$ ab. Wenn nun umgekehrt ein Zusammenhang der Form $y_i = ax_i + b$ mit $a > 0$ vorliegt, so folgt

$$\tilde{y}_i = \frac{y_i - \bar{y}}{s_y} = \frac{a\,x_i + b - a\,\bar{x} - b}{a\,s_x} = \tilde{x}_i.$$

Dies war zu zeigen. Der Fall $r_{xy} = -1$ verläuft analog. □

Bei den Werten $r_{xy} \in \{-1, 1\}$ spricht man auch von einer *perfekten Korrelation*. Hier entsprechen steigende Werte der unabhängigen Variablen steigenden Werten der abhängigen Variable ($r_{xy} = 1$) bzw. fallenden Werten der abhängigen Variablen ($r_{xy} = -1$). Bei Werten von 0 bis 0.5 bzw. bis -0.5 spricht man von einer *schwachen positiven* bzw. *negativen Korrelation*, bei Werten von 0.8 bis 1 von einer *starken Korrelation*. Ist der Wert des Korrelationskoeffizienten Null oder nahe bei Null, sagt man, dass keine (lineare) Korrelation vorliegt, wobei in diesem Fall die Möglichkeit anderer Zusammenhänge besteht. Im Rahmen der Einführung in die Wahrscheinlichkeitstheorie werden uns *zufällig* gewählte Wertepaare (x_i, y_i) begegnen. Mit dieser Formulierung meint man, dass die Daten stochastisch unabhängig realisiert wurden. Diese Zufälligkeit gibt der Korrelationskoeffizient in der Regel recht gut wieder: Er wird nahe bei Null liegen, wobei dies dennoch keinen Hinweis auf einen linearen Zusammenhang gibt. Umgekehrt lässt ein Wert r_{xy} nahe bei Null nicht auf unabhängig realisierte Daten schliessen. Die Daten können zum Beispiel durch eine quadratische Funktion deterministisch erzeugt werden, und gleichzeitig ein r_{xy} nahe Null besitzen.

Lösungen der Aufgaben

Lösungen der Aufgaben in 4.1

Aufgabe 4.1.4

Wir nehmen die Temperaturen als x-Werte und die Längendifferenzen als y-Werte. Zunächst berechnen wir die Regressionsgerade $y = ax + b$ auf Grund der vorliegenden Daten. Man erhält $\bar{x} = 45$ und $\bar{y} = 53.8$. Weiter ist $a = \frac{s_{xy}}{s_x^2}$. Wir erhalten $9s_{xy} = 9760$ und $9s_x^2 = 8250$. Somit ist $a = \frac{s_{xy}}{s_x^2} = \frac{9760}{8250} = 1.1830... \approx 1.18$. Ferner ist $b = \bar{y} - a\bar{x} = 0.5636... \approx 0.56$. Die Regressionsgerade lautet also (in etwa) $y = 1.18x + 0.56$.
Nun verwenden wir die alternative Vorgehensweise. Dazu fassen wir jeweils die ersten 5 Datenpaare und die letzten 5 Datenpaare zu einer Wolke zusammen und bilden die jeweiligen Schwerpunkte $(\overline{x_1}, \overline{y_1}) = (20, 24.2)$ sowie $(\overline{x_2}, \overline{y_2}) = (70, 83.4)$. Die Gerade durch diese beiden Punkte ist bekanntlich gegeben durch $y = \frac{\overline{y_2}-\overline{y_1}}{\overline{x_2}-\overline{x_1}}(x - \overline{x_1}) + \overline{y_1} = 1.184x + 0.52$. Wir sehen also, dass (in diesem Beispiel) beide Verfahren nahezu dasselbe Ergebnis liefern.

Aufgabe 4.1.5

Wir müssen die Funktion $g : \mathbb{R}^3 \to \mathbb{R}$ mit $g(\alpha, \beta, \gamma) := \sum_{i=1}^n \Big(z_i - (\alpha x_i + \beta y_i + \gamma)\Big)^2$ auf ein Minimum hin untersuchen. Dazu berechnen wir die partiellen Ableitungen von g und setzen diese gleich 0. Wir verwenden also Kenntnisse der Analysis von Funktionen in mehreren Veränderlichen. Zunächst ist

$$\begin{aligned} g(\alpha, \beta, \gamma) &= \sum_{i=1}^n \Big(z_i^2 - 2z_i x_i \alpha - 2z_i y_i \beta - 2z_i \gamma + \\ &\qquad \alpha^2 x_i^2 + 2x_i y_i \alpha\beta + 2x_i \alpha\gamma + \beta^2 y_i^2 + 2y_i \beta\gamma + \gamma^2\Big). \end{aligned}$$

Wir erhalten somit

$$0 = \frac{\partial g}{\partial \alpha}(\alpha, \beta, \gamma) = \sum_{i=1}^n (-2z_i x_i + 2x_i^2 \alpha + 2x_i y_i \beta + 2x_i \gamma)$$

$$= -2\sum_{i=1}^{n} z_i x_i + 2\alpha \sum_{i=1}^{n} x_i^2 + 2\beta \sum_{i=1}^{n} x_i y_i + 2\gamma \sum_{i=1}^{n} x_i$$

sowie

$$\begin{aligned} 0 = \frac{\partial g}{\partial \beta}(\alpha, \beta, \gamma) &= \sum_{i=1}^{n} (-2z_i y_i + 2x_i y_i \alpha + 2y_i^2 \beta + 2y_i \gamma) \\ &= -2\sum_{i=1}^{n} z_i y_i + 2\alpha \sum_{i=1}^{n} x_i y_i + 2\beta \sum_{i=1}^{n} y_i^2 + 2\gamma \sum_{i=1}^{n} y_i \end{aligned}$$

und

$$\begin{aligned} 0 = \frac{\partial g}{\partial \gamma}(\alpha, \beta, \gamma) &= \sum_{i=1}^{n} (-2z_i + 2x_i \alpha + 2y_i \beta + 2\gamma) \\ &= -2\sum_{i=1}^{n} z_i + 2\alpha \sum_{i=1}^{n} x_i + 2\beta \sum_{i=1}^{n} y_i + 2n\gamma. \end{aligned}$$

Diese drei Gleichungen bilden das gewünschte lineare Gleichungssystem in den Koeffizienten α, β und γ.

Lösungen der Aufgaben in 4.2

Aufgabe 4.2.2

Wir multiplizieren aus und fassen zusammen:

$$\begin{aligned} s_{xy} &= \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}) \\ &= \frac{1}{n-1} \sum_{i=1}^{n} (x_i y_i - y_i \bar{x} - x_i \bar{y} + \bar{x}\bar{y}) \\ &= \frac{1}{n-1} \left(\sum_{i=1}^{n} x_i y_i - n \frac{1}{n} \sum_{i=1}^{n} y_i \bar{x} - n \frac{1}{n} \sum_{i=1}^{n} x_i \bar{y} + n\bar{x}\bar{y} \right) \\ &= \frac{1}{n-1} \left(\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y} - n\bar{x}\bar{y} + n\bar{x}\bar{y} \right) \\ &= \frac{1}{n-1} \left(\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y} \right). \end{aligned}$$

Aufgabe 4.2.5

Zunächst lösen wir die Klammer auf und formen die Terme passend um.

$$\begin{aligned}
R(a,b) &= \sum_{i=1}^{n}(y_i - b - ax_i)^2 \\
&= \sum_{i=1}^{n}\Big(y_i^2 + b^2 + a^2x_i^2 - 2y_ib + 2abx_i - 2ay_ix_i\Big) \\
&= \sum_{i=1}^{n}\Big((y_i-\bar{y})^2 + 2(y_i-\bar{y})\bar{y} + \bar{y}^2\Big) + a^2\sum_{i=1}^{n}\Big((x_i-\bar{x})^2 + 2(x_i-\bar{x})\bar{x} + \bar{x}^2\Big) \\
&\quad - 2a\sum_{i=1}^{n}\Big((y_i-\bar{y})(x_i-\bar{x}) + \bar{y}(x_i-\bar{x}) + \bar{x}(y_i-\bar{y}) + \bar{y}\bar{x}\Big) \\
&\quad + nb^2 - 2nb\bar{y} + 2nab\bar{x} \\
&= (n-1)s_y^2 + a^2(n-1)s_x^2 - 2a(n-1)s_{xy} + n(\bar{y} - b - a\bar{x})^2.
\end{aligned}$$

Aus Satz 4.1.1 folgt

$$b = \bar{y} - \frac{s_{xy}}{s_x^2}\bar{x} = \bar{y} - a\bar{x}, \quad a = \frac{s_{xy}}{s_x^2}.$$

Wenn man dies in die letzte Zeile der vorangegangenen Rechnung einsetzt, erhält man

$$\begin{aligned}
R(a,b) &= (n-1)s_y^2 + (n-1)\frac{s_{xy}^2}{s_x^2} - 2(n-1)\frac{s_{xy}^2}{s_x^2} \\
&= (n-1)\left(s_y^2 - \frac{s_{xy}^2}{s_x^2}\right) \\
&= (n-1)(s_y^2 - a^2s_x^2) \\
&= (n-1)\left(1 - a^2\frac{s_x^2}{s_y^2}\right)s_y^2 \\
&= (n-1)\left(1 - \frac{s_{xy}^2}{s_x^2s_y^2}\right)s_y^2 \\
&= (n-1)(1 - r_{xy}^2)s_y^2.
\end{aligned}$$

Es gilt $r_{xy} \in [-1, 1]$.