Kurseinheit 4

Zufallsvariablen und Momente

Inhalt der Kurseinheit

Studierhinweise zu Kurseinheit 4 **251**

10 Zufallsvariablen und Verteilungen **253**
10.1 Diskrete Zufallsgrößen und ihre Verteilungen 253
10.2 Unabhängigkeit 262
10.3 Zufallsgrößen und Verteilungsfunktionen 264

Lösungen zu den Aufgaben aus dem Kapitel 10 **273**

11 Erwartungswert, Varianz und Korrelation **281**
11.1 Erwartungswert 281
11.2 Varianz und Kovarianz 293
11.3 Regression und Korrelation 303

Lösungen zu den Aufgaben aus dem Kapitel 11 **307**

Studierhinweise

In der vierten Kurseinheit lernen wir den in der Wahrscheinlichkeitstheorie zentralen Begriff der *Zufallsvariable* kennen und betrachten Kenngrößen von Zufallsgrößen wie den Erwartungswert und die Varianz.

In *Kapitel zehn* werden Zufallsvariablen eingeführt.

In *Abschnitt* 10.1 geht es um diskrete Zufallsgrößen und ihre Verteilungen. Wir greifen viele Modelle und Resultate mithilfe von Zufallsgrößen erneut auf, darunter viele der Produktexperimente aus Kapitel 9.1 sowie viele Modelle und Beispiele aus Kapitel 6.1. Auch neue Beispiele treten hinzu. Nach Durcharbeiten dieses Abschnitts können Sie mit dem Begriff Zufallsgröße und ihrer Verteilung umgehen und kennen viele klassische Verteilungen der diskreten Wahrscheinlichkeitstheorie.

In *Abschnitt* 10.2 wird der Begriff der Unabhängigkeit auf Zufallsgrößen übertragen. Wir diskutieren hierzu Beispiele. Sie beherrschen den Inhalt von Satz 10.2.3 sowie 10.2.4. Diese Resultate werden sehr häufig verwendet.

Im letzten *Abschnitt* 10.3 werden absolutstetige Zufallsgrößen und Zufallsvektoren diskutiert. Wir lösen uns von den diskreten Modellen. Es wird der Begriff einer Zufallsgröße auf einem allgemeinen Wahrscheinlichkeitsraum definiert. Darüberhinaus werden die Begriffe *Dichte*, *Verteilungsfunktion* und *absolutstetig* eingeführt und anhand von Beispielen erläutert. Weiter werden Zufallsvektoren und n-dimensionale Dichten sowie gemeinsame Dichten eingeführt. Nach Durcharbeiten dieses Abschnitts kennen Sie die Definition einer Zufallsgröße und Dichten. Weiter assoziieren Sie mit Produktdichten Unabhängigkeit.

In *Kapitel elf* geht es um den Erwartungswert, die Varianz und die Korrelation.

In *Abschnitt* 11.1 definieren wir den Erwartungswert für diskrete und absolutstetige Zufallsgrößen und ordnen den empirischen Mittelwert ein. Wir sammeln Rechenregeln für den Erwartungswert und bestimmen diese Kenngröße für eine Vielzahl von Modellen. Dabei ist die Diskussion des Quicksort-Algorithmus das aufwendigste Beispiel. Weiter ordnen wir die verschiedenen Mittelwerte aus Kapitel drei ein

und beweisen eine Verallgemeinerung der AGM-Ungleichung. Schließlich definieren wir den Median einer Zufallsgröße. Nach Durcharbeiten dieses Abschnitts sollten Sie in der Lage sein, den Erwartungswert zu allen im Kurs bisher vorgekommenen Zufallsgrößen bestimmen zu können. Sie kennen ein Beispiel eines Modells, in dem der Erwartungswert nicht existiert und können erste empirische Kennzahlen aus Kapitel drei in der Sprache der Zufallsgrößen einordnen.

In *Abschnitt* 11.2 definieren wir die Varianz für diskrete und absolutstetige Zufallsgrößen und ordnen die empirische Varianz ein. Nach der Bestimmung der Varianz in ersten Beispielen definieren wir die Kovarianz zweier Zufallsgrößen und bestimmen die Varianz einer Summe von Zufallsgrößen. Es folgt die Einführung von unkorrelierten Zufallsgrößen, die Gleichheit von Bienaymé und weitere Beispiele. Nach Durcharbeiten dieses Abschnitts können Sie in den Modellen dieses Kurses die Varianz bestimmen. Sie sind in der Lage, Unkorreliertheit und Unabhängigkeit zu unterscheiden. Sie kennen die allgemeine Formel aus Satz 11.2.16 sowie die Eigenschaft, dass der Erwartungswert des Produkts unabhängiger Zufallsgrößen das Produkt der Erwartungswerte ist, sobald alle Erwartungswerte existieren.

In *Abschnitt* 11.3 wird die Regressionsgerade und der Korrelationskoeffizient für zwei Zufallsgrößen eingeführt und es werden Eigenschaften hergeleitet, die wir in der Situation von Stichprobenerhebungen in Kapitel vier bereits kennengelernt haben. Nach Durcharbeiten dieses Abschnitts können Sie vor allem die Begriffe in Bezug zu den gleichen Begriffen in der statistischen Datenerhebung in Kapitel vier setzen.

Kapitel 10

Zufallsvariablen und Verteilungen

Wir führen nun *Zufallsvariablen* ein. Für einen diskreten Wahrscheinlichkeitsraum (Ω, p) ist eine Zufallsvariable einfach eine reellwertige Abbildung $X : \Omega \to \mathbb{R}$. Der tiefere Sinn einer Abbildung kann als eine Reduktion der im Definitionsbereich gegebenen Information angesehen werden. Verschiedene Elementarereignisse werden unter einem vorgegebenen Aspekt zu neuen Ereignissen zusammengefügt. Wir beschreiben uns interessierende Ereignisse mithilfe von Abbildungen. Hat man sich erst einmal an Zufallsvariablen gewöhnt, staunt man schnell, bisher ohne sie ausgekommen zu sein. Für einen allgemeinen Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, P)$ wird nicht jede Abbildung eine Zufallsvariable sein. Das liegt grob gesprochen daran, dass wir einer Menge der Form

$$\{\omega \in \Omega : a \leq X(\omega) < b\}, \quad a, b \in \mathbb{R},$$

eine Wahrscheinlichkeit zuordnen wollen, aber diese Menge im Allgemeinen nicht zum Definitionsbereich $\mathcal{A}$ von P gehören muss. In einem diskreten Wahrscheinlichkeitsraum tritt das Problem nicht auf, da P hier auf der Potenzmenge $\mathcal{P}(\Omega)$ definiert ist, also für jede Teilmenge zur Verfügung steht.

10.1 Diskrete Zufallsgrößen und ihre Verteilungen

10.1.1 Definition: Sei (Ω, p) ein diskreter Wahrscheinlichkeitsraum. Dann heißt eine Abbildung $X : \Omega \to \mathbb{R}$ eine *(diskrete) Zufallsgröße* oder *(diskrete) Zufallsvariable.*

Für die formale Definition ist p zunächst völlig belanglos. Eine Zufallsgröße ist

einfach eine Abbildung und keine „zufällige“ Abbildung. Natürlich werden wir jedoch nun die Eigenschaften von X im Zusammenhang mit p untersuchen.

Es bezeichne $X(\Omega)$ das Bild von Ω unter X, d.h. die höchstens abzählbare Menge reeller Zahlen $\{X(\omega) : \omega \in \Omega\}$. Für $A \subseteq \mathbb{R}$ ist $X^{-1}(A) = \{\omega \in \Omega : X(\omega) \in A\}$ eine Teilmenge von Ω, d.h. ein Ereignis. Wir nennen dies das Ereignis, „dass X einen Wert in A annimmt“. Wir benutzen die folgenden Kurzschreibweisen:

$$\begin{aligned}
\{X \in A\} &:= \{\omega \in \Omega : X(\omega) \in A\} = X^{-1}(A), \\
\{X = z\} &:= \{\omega \in \Omega : X(\omega) = z\} = X^{-1}(\{z\}), \\
\{X \leq z\} &:= \{\omega \in \Omega : X(\omega) \leq z\} = X^{-1}((-\infty, z]) \qquad \text{etc.}
\end{aligned}$$

Statt $P(\{X \in A\})$, $P(\{X = z\})$ schreiben wir einfach $P(X \in A)$, $P(X = z)$ etc. Wir schreiben meistens ein Komma anstelle von „und“ bzw. des mengentheoretischen Durchschnitts innerhalb der Klammer in $P(\quad)$. Sind etwa X, Y Zufallsgrößen und $A, B \subseteq \mathbb{R}$, so schreiben wir $P(X \in A,\, Y \in B)$ für $P(\{X \in A\} \cap \{Y \in B\})$ oder noch ausführlicher $P(\{\omega : X(\omega) \in A \text{ und } Y(\omega) \in B\})$.

Wir sind Zufallsgrößen bereits in vielen Beispielen begegnet.

10.1.2 Beispiele: (a) Es sei X die Augensumme beim zweimaligen Werfen eines Würfels. Zur formalen Beschreibung dieses Versuchs betrachten wir den W.-Raum (Ω, p) mit $\Omega := \{1, 2, 3, 4, 5, 6\}^2$ und der Gleichverteilung p, also $p((i, j)) = 1/36$ für alle $(i, j) \in \Omega$. Die Zufallsgröße $X : \Omega \to \mathbb{R}$ mit $X((i, j)) = i + j$ für alle $(i, j) \in \Omega$ beschreibt dann die Augensumme, und es gilt z.B.

$$P(X = 3) = P(\{(1, 2), (2, 1)\}) = 1/18$$

und

$$P(X \leq 4) = P(\{(1, 1), (1, 2), (2, 1), (1, 3), (2, 2), (3, 1)\}) = 1/6.$$

(b) Es bezeichne X die Anzahl der Erfolge in einem Bernoulli-Experiment der Länge n. Setzen wir $X_i = 1$, falls der i-te Versuch ein Erfolg ist, und $X_i = 0$ sonst $(1 \leq i \leq n)$, so folgt $X = \sum_{i=1}^{n} X_i$.

(c) Für eine beliebige Teilmenge $A \subseteq \Omega$ definieren wir die *Indikatorfunktion* 1_A von A durch

$$1_A(\omega) := \begin{cases} 1\,, & \text{falls} \quad \omega \in A, \\ 0\,, & \text{falls} \quad \omega \notin A. \end{cases}$$

Der Wert der Indikatorfunktion zeigt für jedes ω an, ob $\omega \in A$ gilt oder nicht. Im vorangegangenen Beispiel ist $X_i(\omega) = 1_{\{1\}}(\omega_i)$, $\omega = (\omega_1, \ldots, \omega_n) \in \{0, 1\}^n$.

(d) Im Beispiel des Auto-Ziege-Problems, siehe 8.2.6, hatten wir bereits mit L und S zwei Zufallsgrößen verwendet. Diese Größen gaben die Nummer der gewählten Tür des Spielers S und des Talkmasters/Leiters L an.

Bevor wir weiteren Zufallsgrößen zu bereits diskutierten Zufallsexperimenten begegnen, geben wir hier ein etwas komplizierteres Beispiel aus der Informatik.

10.1.3 Beispiel: (Quicksort-Algorithmus) Der Algorithmus sortiert eine Liste von n Zahlen der Größe nach. Der Bequemlichkeit halber wollen wir annehmen, dass alle Elemente der Liste verschieden sind. Es gibt verschiedene Versionen dieses Algorithmus; wir betrachten zunächst die folgende, welche für die Praxis nicht die optimale ist. Im ersten Schritt wird das erste Element der Liste mit den $n-1$ anderen verglichen und dann an die richtige Stelle gebracht. Das heißt, die Elemente, die kleiner sind, werden vor dieses erste Element der ursprünglichen Liste gebracht, und die größeren werden hinter ihm gelassen. Dabei wird jedoch zunächst die interne Reihenfolge der größeren und der kleineren Elemente nicht angetastet.

Zum Beispiel wird aus $\underline{6}$ 8 3 5 1 7 nach dem ersten Schritt 3 5 1 $\underline{6}$ 8 7. Die kleineren Elemente (im Beispiel oben 3 5 1) und die größeren (im Beispiel 8 7) bilden nun zwei kürzere Teillisten. Die Prozedur ruft sich nun rekursiv auf, um diese zu ordnen. Listen der Länge 0 und 1 brauchen nicht mehr geordnet zu werden. Dies ist das Abbruchkriterium für den Algorithmus. Wir definieren den Aufwand für diesen Algorithmus als die Anzahl der Vergleiche zweier Zahlen, die bis zum Schluss benötigt werden. Natürlich ist dies eine Vereinfachung der realen Situation. Der tatsächliche Aufwand hängt auch sehr von der Programmiersprache ab. Im ersten Schritt werden stets $n-1$ Vergleiche durchgeführt. Wie viele jedoch nachher gebraucht werden, hängt davon ab, wie die Einteilung in die Teillisten erfolgt. Im obigen numerischen Beispiel:

1. Schritt:			5 Vergleiche.
Ordnen von	$\underline{3}$ 5 1	1 $\underline{3}$ 5:	2 Vergleiche.
Ordnen von	$\underline{8}$ 7	7 $\underline{8}$:	1 Vergleich.
Zusammen also:			8 Vergleiche.

Man kann sich leicht überlegen, dass der Algorithmus im ungünstigsten Fall insgesamt $(n-1)+(n-2)+\cdots+1 = n(n-1)/2$ Vergleiche benötigt (z.B. wenn die Liste schon geordnet ist!). In der Regel braucht man jedoch bedeutend weniger. Tatsächlich gehört er zu den schnellsten Sortieralgorithmen. Was heißt „in der Regel“? Wir machen dazu ein wahrscheinlichkeitstheoretisches Modell: Als gleich wahrscheinliche Elementarereignisse nehmen wir die möglichen Reihenfolgen einer Menge von n verschiedenen Elementen. Wir haben also $n!$ Elementarereignisse. X_n

sei die Anzahl der benötigten Vergleiche bei Quicksort, etwa $X_1 = 0$ für jede einelementige Liste. Dann ist z.B. $X_6((6,8,3,5,1,7)) = 8$, wie oben berechnet, oder $X_6((1,3,5,6,7,8)) = 15$. Einfacher in der Analyse ist die *randomisierte* Variante des Quicksort. Wir wählen gleich zu Beginn ein Element der n Zahlen zufällig, d.h. gleichverteilt aus. Dann bestimmen wir die beiden Teillisten der Elemente, die kleiner bzw. größer als das ausgesuchte Element sind. Mit den Teillisten verfahre man dann wieder analog. Wir werden stochastische Aspekte dieses Beispiels in Kapitel 11 diskutieren.

10.1.4 Aufgabe: Bestimmen Sie zu obiger Liste von sechs Zahlen alle möglichen Werte X_6 für den randomisierten Quicksort-Algorihmus.

10.1.5 Beispiel: (Mehrstufige Zufallsexperimente) Die Konstruktion eines mehrstufigen Zufallsexperiments haben wir in Teilkapitel 8.3 vorgestellt. Wir ergänzen diese Konstruktion nun durch Zufallsgrößen, die den Ausgang des i-ten Teilexperiments beschreiben. Es seien $\Omega := \Omega_1 \times \cdots \times \Omega_n$ und die Familie der Übergangswahrscheinlichkeiten

$$p_i(\omega_i|\omega_1, \ldots, \omega_{i-1}), \quad i = 1, \ldots, n$$

wie in Teilkapitel 8.3 gegeben. Es sei nun $X_i : \Omega \to \Omega_i$ gegeben durch $X_i(\omega) = \omega_i$ für $\omega = (\omega_1, \ldots, \omega_n)$. Man spricht von der i-ten *Projektionsabbildung* oder kurz von der i-ten *Projektion*. In der Sprache dieser Zufallsgrößen gilt nun:

10.1.6 Satz: Es existiert ein Wahrscheinlichkeitsmaß P auf $(\Omega, \mathcal{P}(\Omega))$ mit den Eigenschaften

(i) Für alle $\omega_1 \in \Omega_1$ gilt $P(X_1 = \omega_1) = p_1(\omega_1)$.

(ii) Für alle $i = 2, \ldots, n$ und alle $\omega_i \in \Omega_i$ gilt

$$P(X_i = \omega_i | X_1 = \omega_1, \ldots, X_{i-1} = \omega_{i-1}) = p_i(\omega_i|\omega_1, \ldots, \omega_{i-1}),$$

sofern $P(X_1 = \omega_1, \ldots, X_{i-1} = \omega_{i-1}) > 0$.

P ist gegeben durch $P(\{\omega\}) = p(\omega)$, wobei p durch den *Produktansatz* in (8.6) definiert ist.

10.1.7 Aufgabe: Es ist eine wertvolle Übung, entlang der Konstruktion in Teilkapitel 8.3 den obigen Satz zu beweisen. Die Argumente waren im Wesentlichen schon alle da.

Es sei $X : \Omega \to \mathbb{R}$ eine Zufallsgröße. Für $z \in X(\Omega)$ sei $f(z) := f_X(z) := P(X = z)$. Da die Ereignisse $\{X = z\}$ für verschiedene $z \in X(\Omega)$ sich gegenseitig ausschließen und

$$\Omega = \bigcup_{z \in X(\Omega)} \{X = z\}$$

gilt, folgt

$$\sum_{z \in X(\Omega)} f(z) = 1.$$

$(X(\Omega), f)$ ist somit ein W.-Raum.

10.1.8 Definition: Es sei (Ω, p) ein diskreter W.-Raum und $X : \Omega \to \mathbb{R}$ eine Zufallsgröße. Dann heißt $f := f_X$ mit $f(z) := P(X = z)$, $z \in X(\Omega)$, die *Verteilung* der Zufallsgröße X.

Aus der Verteilung einer Zufallsgröße lässt sich $P(X \in A)$ für jede Teilmenge A von $\mathbb{R}$ berechnen:

$$P(X \in A) = \sum_{z \in A \cap X(\Omega)} f(z).$$

Verteilungen sind jedoch oft kompliziert und in vielen praktisch wichtigen Beispielen nicht explizit berechenbar (zum Beispiel beim Quicksort-Algorithmus). Zunächst betrachten wir aber einige Beispiele, bei denen die Verteilung einfach angegeben werden kann:

10.1.9 Beispiel: (Augensumme beim zweimaligen Würfeln) Es sei X die Augensumme bei einem Wurf mit zwei Würfeln. Es ist

$$X(\Omega) = \{2, 3, 4, \ldots, 12\},$$

und $f(2) = f(12) = \frac{1}{36}$, $f(3) = f(11) = \frac{1}{18}$, $f(4) = f(10) = \frac{1}{12}$, $f(5) = f(9) = \frac{1}{9}$, $f(6) = f(8) = \frac{5}{36}$ und $f(7) = \frac{1}{6}$.

10.1.10 Beispiel: (Binomialverteilte Zufallsgrößen) Sei X die Anzahl der Erfolge in einem Bernoulli-Experiment der Länge n und Erfolgswahrscheinlichkeit p. Dann ist, wie wir schon in Kapitel 9.2 berechnet haben:

$$b(k; n, p) := P(X = k) = \binom{n}{k} p^k (1-p)^{n-k} \quad \text{für } k \in \{0, 1, \ldots, n\}.$$

10.1.11 Definition: Eine Zufallsgröße mit der Verteilung $b(k; n, p)$ heißt *binomialverteilt* mit Parametern p und n. Eine Zufallsvariable mit der Verteilung $b(k; 1, p)$, $k = 0, 1$, heißt *Bernoulli-verteilt* mit Parameter p.

Also ist zu jedem $A \subseteq \Omega$ in einem diskreten W.-Raum (Ω, p) die Zufallsgröße 1_A BERNOULLI-verteilt mit Parameter $P(A)$.

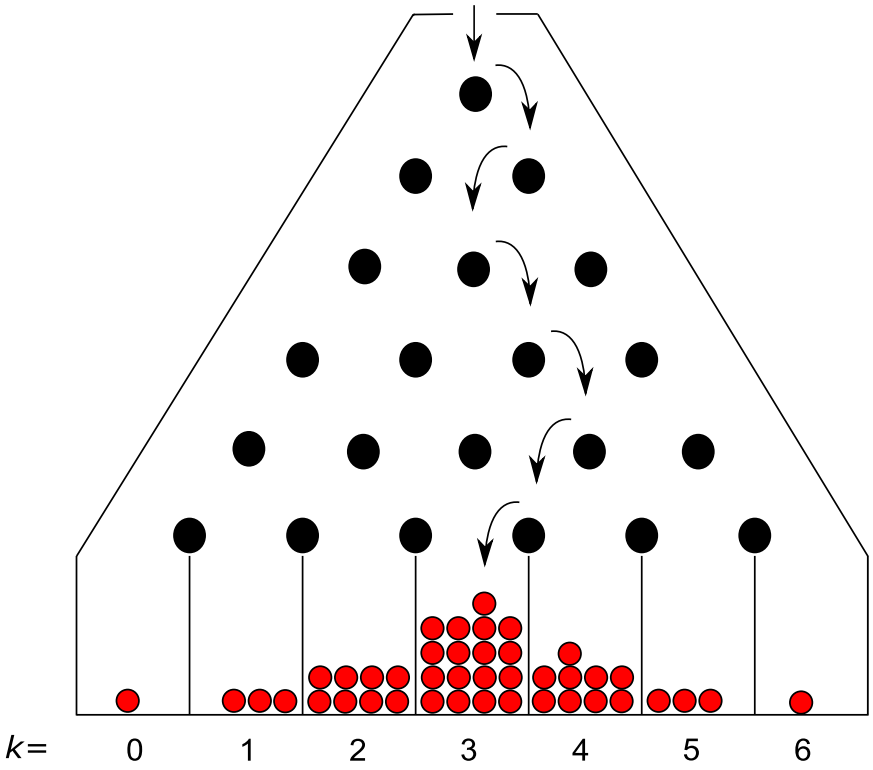

Abb. 10.1: GALTON-Brett für $n = 6$. Die Pfeile markieren den möglichen Weg einer Kugel. Eine Kugel passiert nacheinander $n = 6$ Reihen von Stiften, an denen sie jeweils mit Wahrscheinlichkeit $1/2$ rechts oder links vorbeirollt.

10.1.12 Beispiel: (POLYÁ-Verteilung, hypergeometrische Verteilung)
Wir betrachten das Urnenmodell von POLYÁ, siehe Beispiele 8.3.5 und 9.3.7. Dort war A_i das Ereignis, beim i-ten Zug eine rote Kugel zu ziehen. Nun betrachten wir die Zufallsgröße $X_i := 1_{A_i}$, $i = 1, \ldots, n$, sowie

$$X := \sum_{i=1}^{n} X_i,$$

also die Anzahl der roten Kugeln nach n Zügen. Dann gilt

$$P(X = k) = \binom{n}{k} \frac{\prod_{i=0}^{k-1}(r + i \cdot c) \cdot \prod_{i=0}^{n-k-1}(s + i \cdot c)}{\prod_{i=0}^{n-1}(r + s + i \cdot c)}.$$

für alle $k \in \{0, \ldots, n\}$. Die Verteilung von X heißt *Polyá-Verteilung* mit den Parametern n, r, s und c. Der Spezialfall $c = 0$ ist die Binomialverteilung. Hier sind die Parameter n, r und s. Wir setzen dann $p := \frac{r}{r+s}$ und haben die Parameter so reduziert, dass wir mit Definition 10.1.11 übereinstimmen. Im Fall $c = -1$ heißt die Verteilung von X *hypergeometrische Verteilung*. Hier sind die Parameter ebenfalls n, r und s. Im hypergeometrisch verteilten Fall wählen wir die Schreibweise:

$$h(k; n, r, s) = P(X = k) = \binom{n}{k} \frac{\prod_{i=0}^{k-1}(r-i) \prod_{i=0}^{n-k-1}(s-i)}{\prod_{i=0}^{n-1}(r+s-i)}. \tag{10.1}$$

10.1.13 Aufgabe: Von 500 Richtern eines Gerichts neigen 200 den linken Parteien zu, 300 den rechten Parteien. Es werde zufällig ein Tribunal aus $n = 2k+1$ Richtern gewählt. Wie groß ist die Wahrscheinlichkeit, dass es in diesem Tribunal eine rechte Mehrheit gibt? Es wird sich zeigen, dass diese Wahrscheinlichkeit als Funktion von k schnell gegen 1 wächst: Je größer das Tribunal ist, desto wahrscheinlicher ist eine rechte Mehrheit.

10.1.14 Beispiel: (Geometrische Verteilung) Wir betrachten das Beispiel 9.2.7: In einem Bernoulli-Experiment der Länge n mit Erfolgswahrscheinlichkeit p führen wir das Experiment so lange fort, bis zum erstenmal „Erfolg“ eintritt. X sei der Zeitpunkt des ersten Erfolges. Wir wählen $\Omega = \mathbb{N}$, wobei $k \in \mathbb{N}$ das Elementarereignis ist, dass der erste Erfolg zum Zeitpunkt k vorkommt. Dann gilt

$$P(X = k) = (1-p)^{k-1} \cdot p.$$

Wir haben bereits in Beispiel 9.2.7 gezeigt, dass diese Wahrscheinlichkeiten eine Verteilung ergeben, also aufsummiert den Wert 1 liefern. Eine Zufallsgröße, die diese Verteilung hat, heißt *geometrisch* verteilt.

10.1.15 Aufgabe: Zeigen Sie: Ist X geometrisch verteilt, so gilt $P(X = \infty) = 0$.

Geometrisch verteilte Zufallsgrößen haben die folgende interessante Eigenschaft:

10.1.16 Satz: Sei X geometrisch verteilt. Für $k \in \mathbb{N}$ ist die bedingte Wahrscheinlichkeit $P(\, X = n - 1 + k | X \geq n\,)$ gleich $P(X = k)$, also insbesondere unabhängig von $n \in \mathbb{N}$.

Beweis: Für alle $k, n \in \mathbb{N}$ gilt

$$P(\, X = n - 1 + k \mid X \geq n\,) = \frac{P(X = n-1+k)}{P(X \geq n)} = \frac{p(1-p)^{n-1+k-1}}{\sum_{m=n}^{\infty} p(m)}$$

und

$$\sum_{m=n}^{\infty} p(m) = \sum_{m=n}^{\infty} (1-p)^{m-1}p = (1-p)^{n-1} \sum_{m=0}^{\infty} (1-p)^m p = (1-p)^{n-1}.$$

Somit folgt $p(1-p)^{n+k-2} / \sum_{m=n}^{\infty} p(m) = (1-p)^{k-1}p$. □

Der Satz hat die folgende intuitive Interpretation: Die Tatsache, dass bis zu einem Zeitpunkt kein Erfolg eingetreten ist, verändert nicht die bedingte Verteilung des Moments des ersten Erfolges, gerechnet von diesem Zeitpunkt an. Viele Menschen sind anderer Ansicht, da sie, geleitet von der Beobachtung, dass sich Erfolge und Misserfolge zum Beispiel bei einem symmetrischen Bernoulli-Experiment ungefähr ausgleichen, dem Trugschluss erliegen, dass nach einer langen Pechsträhne die Wahrscheinlichkeit für einen Erfolg steigt. Man spricht von der *Gedächtnislosigkeit* der geometrischen Verteilung.

10.1.17 Beispiel: (negative Binomialverteilung, Pascal-Verteilung) Zugrunde liegt wieder ein Bernoulli-Experiment der Länge n mit Erfolgswahrscheinlichkeit p. In Beispiel 9.2.7 haben wir die Wahrscheinlichkeit berechnet, dass dem r-ten Erfolg genau k mal Misserfolg vorangegangen ist. Wir definieren nun die Zufallsgröße U_r auf dem in Beispiel 9.2.7 betrachteten W.-Raum (Ω_r, p_r) als die Anzahl der Misserfolge, die man vor dem r-ten Erfolg hatte. Dann gilt

$$P(U_r = k) = \binom{k+r-1}{k} p^r (1-p)^k$$

für alle $k \geq 0$. Die Verteilung dieser Zufallsgröße heißt die *negative Binomialverteilung* oder die *Pascal-Verteilung*. Im Fall $r = 1$ ist U_1 die Anzahl der Misserfolge vor dem ersten Erfolg. Es gilt

$$P(U_1 = k) = (1-p)^k p.$$

Man beachte, dass $U_1 + 1$ geometrisch verteilt ist. Für die Begründung dieser Namensgebung siehe Beispiel 9.2.7.

10.1.18 Beispiel: (Geburtstagsproblem/Problem der ersten Kollision) In Beispiel 6.2.11 haben wir das Geburtstagsproblem kennengelernt. Die Wahrscheinlichkeit, dass n Personen an verschiedenen Tagen ($m = 365$) Geburtstag haben, ist

$$\frac{(m)_n}{m^n}.$$

Dies entspricht der Lösung des Problems, dass bei der rein zufälligen sukzessiven Besetzung von m verschiedenen *Fächern* alle n *Teilchen* in unterschiedlichen Fächern landen. Zu diesem Verteilungsproblem betrachten wir nun die Zufallsgröße X_m, definiert als der Zeitpunkt der ersten *Kollision* beim sukzessiven rein zufälligen Besetzen von m Fächern. Dabei meint Kollision den Zeitpunkt, an dem ein bereits besetztes Fach erneut besetzt wurde. Für eine erste Kollision benötigt man mindestens 2 und höchstens $m+1$ Versuche, also nimmt die Zufallsgröße Werte aus $\{2, 3, \ldots, m+1\}$ an und es gilt

$$P(X_m \geq n+1) = \frac{(m)_n}{m^n}$$

bzw.

$$P(X_m \leq n) = 1 - \prod_{i=1}^{n-1}\left(1 - \frac{i}{m}\right).$$

10.1.19 Aufgabe: Man betrachte den Grundraum

$$\Omega := \{(\omega_1, \ldots, \omega_{m+1}) : \omega_i \in \{1, \ldots, m\}, i = 1, \ldots, m+1\}.$$

Definieren Sie die Kollisionszeit X_m als Zufallsgröße auf Ω.

10.1.20 Aufgabe: Es wird als eine Sensation betrachtet, dass bei einer Ziehung im LOTTO-Spiel 6 aus 49 im Jahre 1995 die gleichen 6 Zahlen wie bei einer Ziehung im Jahr 1986 gezogen wurden. Es ergibt sich, dass die Ziehung 1996 die 3016-te Ziehung nach der Vergleichsziehung im Jahre 1986 war. Kommentieren Sie dies unter Verwendung der Resultate in Beispiel 6.2.11 bzw. 6.2.16.

10.1.21 Aufgabe: Im *Rencontre-Problem*, Beispiel 6.2.27, definieren wir die Zufallsgröße X_n als die Anzahl der Fixpunkte einer rein zufälligen Permutation von $\{1, 2, \ldots, n\}$. Zeigen Sie:

(a) Die Anzahl der Permutationen von $\{1, 2, \ldots, n\}$, welche genau k Fixpunkte besitzt, ist

$$\binom{n}{k} \cdot \mathcal{R}_{n-k},$$

wobei $\mathcal{R}_n$ die *Rencontre-Zahl* aus Beispiel 6.2.27 ist.

(b) Es gilt

$$P(X_n = k) = \frac{1}{k!}\sum_{i=0}^{n-k}\frac{(-1)^i}{i!}, \qquad k = 0, 1, \ldots, n.$$

10.2 Unabhängigkeit

Wir werden nun den Begriff der stochastischen Unabhängigkeit von Zufallsgrößen einführen. Wir wollen Zufallsgrößen unabhängig nennen, wenn der Ausgang einer der Zufallsgrößen nicht vom Ausgang der anderen abhängt. Zu zwei Zufallsvariablen X und Y wirkt es plausibel, sie unabhängig zu nennen, wenn die Ereignisse $\{X = x\}$ und $\{Y = y\}$ unabhängig sind für jedes $x \in X(\Omega)$ und $y \in Y(\Omega)$. Dann müssen wir noch beachten, dass die Definition der stochastischen Unabhängigkeit von n Ereignissen mit etwas Vorsicht erfolgt. Tatsächlich wirkt die folgende Definition in diesem Sinne unvorsichtig. Der darauffolgende Satz rechtfertigt die Definition.

10.2.1 Definition: Es seien n diskrete Zufallsgrößen $X_1, \ldots, X_n$ auf einem W.-Raum (Ω, p) definiert. Sie heißen *unabhängig*, wenn

$$P(X_1 = z_1, \ldots, X_n = z_n) = P(X_1 = z_1) \cdots P(X_n = z_n) \tag{10.2}$$

für alle $z_i \in X_i(\Omega)$, $i \in \{1, \ldots, n\}$, gilt.

10.2.2 Satz: Die folgenden vier Aussagen über die diskreten Zufallsgrößen X_1, $X_2, \ldots, X_n$, definiert auf einem W.-Raum (Ω, p), sind äquivalent

(i) $X_1, \ldots, X_n$ sind unabhängig.

(ii) Für alle $A_1, \ldots, A_n \subseteq \mathbb{R}$ gilt

$$P(X_1 \in A_1, X_2 \in A_2, \ldots, X_n \in A_n) = P(X_1 \in A_1) \cdots P(X_n \in A_n).$$

(iii) Für alle $A_1, \ldots, A_n \subseteq \mathbb{R}$ sind die Ereignisse $\{X_1 \in A_1\}, \ldots, \{X_n \in A_n\}$ unabhängig.

(iv) Für $z_1 \in X_1(\Omega), \ldots, z_n \in X_n(\Omega)$ sind die Ereignisse $\{X_1 = z_1\}, \ldots, \{X_n = z_n\}$ unabhängig.

Beweis: (i)⇒(ii): Summation der Gleichung in (10.2) über $(z_1, \ldots, z_n) \in A_1 \times A_2 \times \cdots \times A_n$ liefert (ii).

(ii)⇒(iii): Nach Lemma 9.1.13 ist zu zeigen, dass für $(i_1, \ldots, i_n) \in \{1, c\}^n$ die Gleichung

$$P\left(\bigcap_{j=1}^{n} \{X_j \in A_j\}^{i_j}\right) = \prod_{j=1}^{n} P(\{X_j \in A_j\}^{i_j})$$

gilt, wobei $\{X_j \in A_j\}^1 := \{X_j \in A_j\}$ ist. Nun ist jedoch $\{X_j \in A_j\}^c = \{X_j \in A_j^c\}$. Wir können deshalb einfach (ii) mit A_j oder A_j^c anstelle von A_j anwenden.

(iii)⇒(iv) ist offensichtlich und (iv)⇒(i) ergibt sich aus der Definition. □

Ein wichtiges Resultat ist, dass Transformationen diskreter Zufallsgrößen die stochastische Unabhängigkeit erhalten.

10.2.3 Satz: Sind die Zufallsgrößen $X_1, \ldots, X_n$ auf einem W.-Raum (Ω, p) definiert und stochastisch unabhängig, und sind $f_i : \mathbb{R} \to \mathbb{R}$ für $i = 1, \ldots, n$ beliebige Funktionen, so sind die Zufallsgrößen $Y_i := f_i \circ X_i$, $i = 1, \ldots, n$, unabhängig.

Beweis: Für beliebige $y_1, \ldots, y_n \in \mathbb{R}$ sei $A_i := \{x_i \in \mathbb{R} : f_i(x_i) = y_i\}$. Dann ist $\{Y_i = y_i\} = \{X_i \in A_i\}$. Die Aussage folgt somit aus Satz 10.2.2. □

10.2.4 Aufgabe: Wir betrachten ein Bernoulli-Experiment der Länge n mit Parameter p. X_i bezeichne den Ausgang des i-ten Versuchs, also $P(X_i = 1) = p = 1 - P(X_i = 0)$, $i = 1, \ldots, n$. Zeigen Sie, dass $X_1, \ldots, X_n$ unabhängig sind. Zeigen Sie weiter, dass $S_{n-1} := X_1 + X_2 + \cdots + X_{n-1}$ unabhängig von X_n ist.

Aufgabe 10.2.4 folgt aus einem allgemeinen Prinzip: Wenn wir n unabhängigen Zufallsgrößen in zwei oder endlich viele Teilmengen zerlegen, und in jeder Teilmenge die zugehörigen Zufallsgrößen mittels einer Verknüpfung zu einer neuen Zufallsgröße zusammenfügen, sind die neu entstehenden Zufallsgrößen wieder stochastisch unabhängig. Wir führen dies aber mathematisch nicht aus.

10.2.5 Beispiel: (Pascal-Verteilung) Wir betrachten ein Bernoulli-Experiment der Länge n mit Parameter p. X_i bezeichne den Ausgang des i-ten Versuchs, also $P(X_i = 1) = p = 1 - P(X_i = 0)$, $i = 1, \ldots n$. Es sei

$$S_n := X_1 + X_2 + \cdots + X_n.$$

Wir betrachten nun die minimale Anzahl T_r von Wiederholungen des einzelnen Bernoulli-Experiments, die man benötigt, um r-mal Erfolg zu erhalten:

$$T_r := \inf\{n : S_n = r\}.$$

T_r nimmt Werte in $\{r, r+1, \ldots\}$ an. Es gilt $\{T_r = n\} = \{S_{n-1} = r-1, X_n = 1\}$. Mithilfe von Aufgabe 10.2.4 folgt nun

$$P(T_r = n) = P(S_{n-1} = r-1) \cdot P(X_n = 1) = \binom{n-1}{r-1} p^{r-1}(1-p)^{n-r} \cdot p. \quad (10.3)$$

Die Zufallsgröße $U_r := T_r - r$ gibt die Anzahl der vergeblichen Versuche (Misserfolge) an, die man vor dem r-ten Erfolg machen musste. Dies ist genau die Zufallsgröße, die wir in Beispiel 10.1.17 betrachtet haben. Wir erhalten mittels (10.3) unmittelbar

$$P(U_r = k) = P(T_r = r + k) = \binom{k+r-1}{r-1} p^r (1-p)^k = \binom{k+r-1}{k} p^r (1-p)^k$$

eine alternative Herleitung der Pascal-Verteilung; vergleiche mit Beispiel 9.2.7.

10.2.6 Aufgabe: Gegeben seien zwei unabhängige Zufallsgrößen X_1, X_2 mit

$$P(X_i = 1) = P(X_i = -1) = \frac{1}{2} \qquad \text{für } i = 1, 2.$$

Sind die drei Zufallsgrößen X_1, X_2 und $X_3 := X_1 \cdot X_2$ unabhängig? Sind sie paarweise unabhängig?

10.3 Zufallsgrößen und Verteilungsfunktionen

Im diskreten Fall hatten wir jede Abbildung X von Ω nach $\mathbb{R}$ Zufallsgröße genannt. Für einen allgemeinen Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, P)$ ist dies nicht zweckmäßig. Wir hatten bereits erwähnt, dass wir Ereignissen der Form $\{a < X \leq b\}$ Wahrscheinlichkeiten zuordnen wollen, aber diese Mengen nicht automatisch zum Definitionsbereich $\mathcal{A}$ von P gehören.

Zur Erinnerung: $\mathcal{A}$ ist eine σ-Algebra. Dieses Mengensystem möge alle diejenigen Mengen enthalten, für die wir eine Wahrscheinlichkeit bestimmen wollen. Wir können aber im Allgemeinen nicht pragmatisch vorgehen, und einfach die Potenzmenge $\mathcal{P}(\Omega)$ wählen, da wir zum Beispiel in $[0, 1]$ nicht jeder Teilmenge eine Wahrscheinlichkeit P zuordnen können, sodass P ein W.-Maß wird. Daher ist im allgemeinen Fall die σ-Algebra zwar möglichst groß zu wählen, aber nur so groß, dass P auch noch definiert werden kann. In $\mathbb{R}^d$ hatten wir die σ-Algebra der Borel'schen Mengen $\mathcal{B}^d$ als Definitionsbereich eines W.-Maßes kennengelernt. Für eine Abbildung $X : \Omega \to \mathbb{R}$ wollen wir $P(X \in B)$ für eine beliebige Borel-Menge $B \in \mathcal{B}$ bestimmen. Das geht nur, wenn

$$\{X \in B\} = X^{-1}(B) \in \mathcal{A}$$

gilt. Das Urbild einer beliebigen Borel-Menge muss in $\mathcal{A}$ liegen. Dann können wir die Menge $(X \in B)$ *messen*. Man nennt daher die Eigenschaft

$$X^{-1}(B) \in \mathcal{A} \quad \text{für alle} \quad B \in \mathcal{B}$$

Messbarkeit von X in Bezug auf $\mathcal{A}$ und $\mathcal{B}$.

Für unsere Zwecke genügt die folgende Definition:

10.3.1 Definition: Es sei $(\Omega, \mathcal{A}, P)$ ein Wahrscheinlichkeitsraum und $X : \Omega \to \mathbb{R}$ eine Abbildung. X heißt *Zufallsgröße* (oder Zufallsvariable), wenn für alle $a \in \mathbb{R}$ gilt:

$$X^{-1}(]-\infty, a]) \in \mathcal{A}.$$

10.3.2 Bemerkung: Der Begriff Zufallsgröße hat zunächst nichts mit der Wahrscheinlichkeit P zu tun. Liegt keine Wahrscheinlichkeit vor, so spricht man von einer *messbaren* Abbildung auf $(\Omega, \mathcal{A})$. Die Familie $\mathcal{A}_X := \{A \subseteq \mathbb{R} : X^{-1}(A) \in \mathcal{A}\}$ ist eine σ-Algebra. Dies ist eine einfache Übung. Ist X eine Zufallsgröße, so gilt nach Definition $]-\infty, a] \in \mathcal{A}_X$ für jedes $a \in \mathbb{R}$. Somit liegt auch jedes Intervall der Form $]a, b] =]-\infty, b] \cap (]-\infty, a])^c$ in $\mathcal{A}_X$. Da $\mathcal{B}$ von Intervallen dieser Form erzeugt wird, liegt somit das Urbild jeder Borel'schen Menge in $\mathcal{A}$. Eine äquivalente Definition einer Zufallsgröße ist also durch die Forderung gegeben, dass das Urbild jeder Borel'schen Menge in der vorgegebenen σ-Algebra $\mathcal{A}$ „landet". Unsere Definition ist bequemer.

Mithilfe eines W.-Raums $(\Omega, \mathcal{A}, P)$ und einer Zufallsgröße $X : \Omega \to \mathbb{R}$ können wir nun alle Wahrscheinlichkeiten $P(X \in B)$ mit $B \in \mathcal{B}$ sammeln. Dies liefert ein Wahrscheinlichkeitsmaß auf $(\mathbb{R}, \mathcal{B})$, denn $P(X \in B) \geq 0$, $P(X \in \mathbb{R}) = P(X^{-1}(\mathbb{R})) = P(\Omega) = 1$ und für eine Folge paarweise disjunkter Borel-Mengen $(B_i)_{i\geq 1}$ gilt

$$\begin{aligned} P\Big(X \in \bigcup_{i\geq 1} B_i\Big) &= P\Big(X^{-1}\Big(\bigcup_{i\geq 1} B_1\Big)\Big) = P\Big(\bigcup_{i\geq 1} X^{-1}(B_i)\Big) \\ &= \sum_{i\geq 1} P(X^{-1}(B_i)) = \sum_{i\geq 1} P(X \in B_i), \end{aligned}$$

wobei wir im vorletzten Schritt die σ-Additivität von P verwendet haben. Das halten wir fest:

10.3.3 Definition: Es sei $X : \Omega \to \mathbb{R}$ eine Zufallsgröße auf einem W.-Raum $(\Omega, \mathcal{A}, P)$. Dann heißt das Wahrscheinlichkeitsmaß $X(P) = P_X$, definiert durch

$$P_X(B) := P(X \in B), \quad B \in \mathcal{B},$$

das Bildmaß von P unter X oder die *Verteilung* von X unter P.

Natürlich stellt sich die Frage, ob sich dieser abstrakte Aufwand lohnt. Welche nichtdiskreten Zufallsgrößen haben wir vor Augen? Welche werden wir in diesem Kurs kennenlernen? Für die wichtige Klasse kontinuierlicher Verteilungen führen wir nun den Begriff der *Dichte* ein.

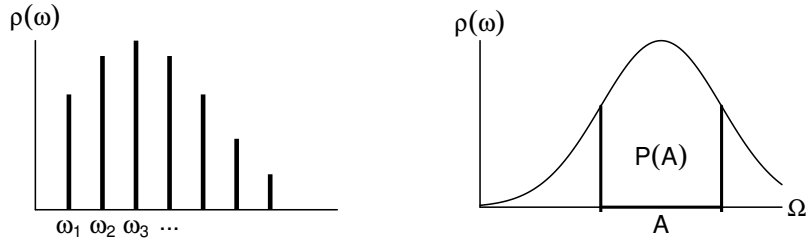

Abb. 10.2: Links: Stabdiagramm einer diskreten Zähldichte ρ. Rechts: Kontinuierliche Dichtefunktion ρ, deren Integrale über ein Ereignis A die Wahrscheinlichkeit $P(A)$ ergibt.

10.3.4 Definition: Eine LEBESGUE-integrierbare Funktion $f : \mathbb{R} \to [0, \infty)$ heißt *Dichte*, wenn $\int_{-\infty}^{\infty} f(x)\,dx = 1$ gilt. ($\int \ldots dx$ bezeichne das LEBESGUE-Integral.)

Falls das LEBESGUE-Integral nicht bekannt ist, so setze man voraus, dass f RIEMANN-integrierbar ist und das *uneigentliche RIEMANN-Integral* $\int_{-\infty}^{\infty} f(x)\,dx$ existiert und gleich 1 ist (BERNHARD RIEMANN (1826–1866)).

10.3.5 Beispiele: (a) Die Dichte der *Standard-Normalverteilung* ist definiert durch

$$\varphi(x) := \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \quad x \in \mathbb{R}.$$

Tatsächlich gilt $\int_{-\infty}^{\infty} \varphi(x)\,dx = 1$. Dies kann man nicht mit den Methoden aus dem Kurs „Mathematische Grundlagen“ beweisen. Der Grund ist, dass wir keine Stammfunktion angeben können, also der Hauptsatz der Differential- und Integralrechnung nicht angewendet werden kann. Im Rahmen des Studiums der Gamma-Funktion oder der Einführung von Mehrfachintegralen lernt man in der fortgeschrittenen Analysis unterschiedliche Techniken (Satz von Fubini, Substitution mit Polarkoordinaten) kennen, mit deren Hilfe das obige Integral bestimmt werden kann. Wir warten an dieser Stelle einfach ab. In Kurseinheit 5 werden wir einen Beweis mittels eines wahrscheinlichkeitstheoretischen Argumentes geben. Dieses Argument verwendet implizit, aber maßgeblich, die STIRLING-Approximation. Dort trat bereits der Faktor $\sqrt{2\pi}$ auf!

(b) Zu jedem $\mu \in \mathbb{R}$ (das Mittel) und $\sigma^2 > 0$ (die Varianz) ist durch

$$\varphi(x;\mu,\sigma^2) := \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/(2\sigma^2)}, \quad x \in \mathbb{R},$$

eine Dichte gegeben. Dies nennt man die Dichte der *Normalverteilung zu den Parametern μ und σ^2*, siehe Abbildung 10.3. Durch die Transformation $y = (x-\mu)/\sigma$ geht die Funktion $\varphi(\,\cdot\,;\mu,\sigma^2)$ in die Dichte $\varphi(\,\cdot\,;0,1)$ der Standard-Normalverteilung aus Beispiel (a) über, und es gilt

$$\int_{-\infty}^{\infty} \varphi(x;\mu,\sigma^2)\,dx = \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-y^2/2}\,dy = 1.$$

Wir verwenden also die Substitutionsregel.

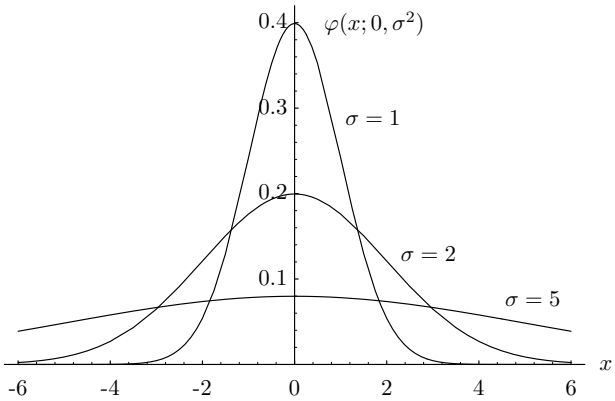

Abb. 10.3: Normalverteilungen

(c) Für $a < b$ ist die Dichte der *gleichförmigen Verteilung auf* $[a,b]$ definiert durch

$$f(x) := \begin{cases} \frac{1}{(b-a)}, & \text{falls} \quad x \in [a,b], \\ 0, & \text{falls} \quad x \in \mathbb{R} \setminus [a,b]. \end{cases}$$

(d) Die Dichte der *Exponentialverteilung zum Parameter* $\lambda > 0$ ist definiert durch

$$f(x) := \begin{cases} \lambda e^{-\lambda x}, & \text{falls} \quad x \geq 0, \\ 0, & \text{falls} \quad x < 0. \end{cases}$$

(e) Die Dichte der *Cauchy-Verteilung zum Parameter* $c > 0$ ist definiert durch

$$f(x) := \frac{c}{\pi} \frac{1}{x^2 + c^2}, \quad x \in \mathbb{R},$$

siehe Abbildung 10.4.

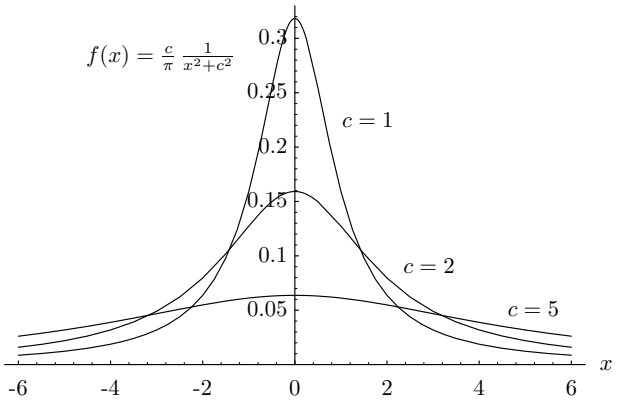

Abb. 10.4: CAUCHY-Verteilungen

10.3.6 Bemerkung: Die Begrifflichkeit *Dichte einer Verteilung* klärt sich in Kürze. Die obigen Beispiele sind zunächst einfach Beispiele für Dichten.

10.3.7 Aufgabe: Zeigen Sie, dass es sich bei den Beispielen 10.3.5(d) und 10.3.5(e) um Dichten handelt.

10.3.8 Aufgabe: Man bestimme Konstanten c_1, c_2, c_3 und c_4, sodass die folgenden Funktionen auf $\mathbb{R}$ Dichten werden:

$$\begin{aligned} f_1(x) &:= c_1(\alpha^2 + (x-\beta)^2)^{-1}, \qquad \alpha, \beta \in \mathbb{R}, \\ f_2(x) &:= 1_{[0,\pi]} \cdot c_2 \cdot \sin(x), \\ f_3(x) &:= 1_{\{x>1\}} \cdot c_3 \cdot x^{-r}, \qquad r > 1, \\ f_4(x) &:= 1_{\{x>0\}} \cdot c_4 \cdot e^{-\lambda^2 x}, \qquad \lambda \neq 0. \end{aligned}$$

10.3.9 Definition: 1. Eine Funktion $F : \mathbb{R} \to [0,1]$ heißt *Verteilungsfunktion*, wenn die folgenden Eigenschaften gelten:

(i) F ist monoton steigend, d.h. für alle $s \leq t$ gilt $F(s) \leq F(t)$.

(ii) F ist rechtsseitig stetig, d.h. für jedes $t \in \mathbb{R}$ und jede gegen t konvergente Folge $(t_n)_{n\in\mathbb{N}}$ mit $t_n \geq t$ für alle $n \in \mathbb{N}$ gilt $\lim_{n\to\infty} F(t_n) = F(t)$.

(iii) $\lim_{t\to\infty} F(t) = 1$ und $\lim_{t\to-\infty} F(t) = 0$.

2. Es sei f eine Dichte. Eine Verteilungsfunktion F heißt *absolutstetig* mit Dichte f, wenn

$$F(t) = \int_{-\infty}^{t} f(s)\, ds$$

für jedes $t \in \mathbb{R}$ gilt.

10.3.10 Bemerkung: Für jede Dichte f ist natürlich $\int_{-\infty}^{t} f(s)\,ds$ eine Verteilungsfunktion, die nicht nur (ii) erfüllt, sondern sogar stetig ist. Wir nennen eine stetige Funktion $F : \mathbb{R} \to [0,1]$, die (i) und (iii) erfüllt, eine *stetige* Verteilungsfunktion. Nicht jede stetige Verteilungsfunktion hat eine Dichte, was hier nicht gezeigt wird.

10.3.11 Definition: Es seien $(\Omega, \mathcal{F}, P)$ ein Wahrscheinlichkeitsraum und X eine Zufallsgröße, dann heißt die Funktion $F_X(t) := P(X \leq t)$, $t \in \mathbb{R}$, die *Verteilungsfunktion* von X.

Für eine diskrete Zufallsgröße X lässt sich die Verteilungsfunktion leicht beschreiben: In den (höchstens abzählbar vielen) Punkten $t \in X(\Omega)$ hat F_X einen Sprung der Höhe $P(X = t)$ und ist in diesem Punkt rechtsseitig stetig. Ansonsten ist sie konstant. Offensichtlich erfüllt F_X dann (i)–(iii) der Definition 10.3.9.

10.3.12 Definition: Es seien $(\Omega, \mathcal{F}, P)$ ein Wahrscheinlichkeitsraum und f eine Dichte. Eine Zufallsgröße X heißt *absolutstetig* mit Dichte f, falls

$$F_X(t) = \int_{-\infty}^{t} f(s)\,ds$$

für alle $t \in \mathbb{R}$ gilt.

Für welche stochastischen Modelle die aufgeführten Beispiele von Dichten auftreten wird später geklärt.

Eine Dichte ist nicht ganz eindeutig durch die Zufallsgröße bzw. deren Verteilungsfunktion bestimmt. Hat zum Beispiel X die in Beispiel 10.3.5(c) angegebene Dichte, so ist

$$\widetilde{f}(x) := \begin{cases} \frac{1}{(b-a)}\,, & \text{falls} \quad x \in (a,b), \\ 0\,, & \text{falls} \quad x \in \mathbb{R} \setminus (a,b), \end{cases}$$

ebensogut eine Dichte für X. Änderungen einer Dichte in abzählbar vielen Punkten ändern an den Integralen nichts. Das ist für das Lebesgue-Integral klar.

Eine absolutstetige Verteilungsfunktion braucht natürlich keine stetige Dichte zu besitzen. Ist jedoch eine Dichte f in einem Punkt a stetig, so gilt nach dem Hauptsatz der Differential- und Integralrechnung

$$f(a) = \frac{dF(x)}{dx}\bigg|_{x=a}.$$

Also hat eine Verteilungsfunktion F genau dann eine stetige Dichte, wenn sie stetig differenzierbar ist. Diese stetige Dichte ist, wenn sie existiert, eindeutig durch F bestimmt.

Hat eine Zufallsgröße X eine Dichte f, so gilt für alle $a < b$

$$P(a < X \leq b) = P(X \leq b) - P(X \leq a) = \int_a^b f(x)\,dx.$$

Weiter gilt für alle $n \in \mathbb{N}$

$$P(X = x) \leq P\Big(x - \frac{1}{n} \leq X \leq x\Big) = \int_{x-\frac{1}{n}}^{x} f(x)\,dx,$$

also $P(X = x) = 0$ für jedes $x \in \mathbb{R}$. Demzufolge gilt

$$P(a < X \leq b) = P(a \leq X \leq b) = P(a \leq X < b) = P(a < X < b).$$

Wir nennen eine Zufallsgröße *normalverteilt, gleichförmig verteilt, exponentialverteilt* bzw. *Cauchy-verteilt*, wenn sie eine Dichte gemäß Beispiel 10.3.5, (b), (c), (d) bzw. (e) hat.

Als nächstes wollen wir gemeinsame Eigenschaften von mehreren Zufallsgrößen $X_1, \ldots, X_n$, definiert auf einem gemeinsamen W.-Raum $(\Omega, \mathcal{A}, P)$, betrachten. Für diskrete Zufallsvariablen haben wir das folgende Beispiel bereits kennengelernt:

10.3.13 Beispiel: Wir betrachten das Modell des *Multinomialexperiments*, siehe Beispiel 9.2.6. Eine Urne enthalte r_1 Kugeln der Farbe 1, …, r_k Kugeln der Farbe k. Es sei $r_1 + r_2 + \cdots + r_k = m$ und $p_i = r_i/m$ für $i = 1, \ldots, k$. Sei A_{ij} das Ereignis, dass die j-te Ziehung eine Kugel der Farbe i liefere (bei n Ziehungen mit Zurücklegen). Wir setzen

$$X_{ij} := 1_{A_{ij}}, \qquad X_i := \sum_{j=1}^{n} X_{ij}$$

für jedes $1 \leq i \leq k$ und $1 \leq j \leq n$. Dann ist X_i die Anzahl der Kugeln von der Farbe i, die man nach n Ziehungen gezogen hat. Die Verteilung des Vektors $(X_1, \ldots, X_k)$ ist dann gegeben durch

$$\binom{n}{n_1, \ldots, n_k} p_1^{n_1} \cdot \ldots \cdot p_k^{n_k}.$$

Die Verteilung des Vektors $(X_1, \ldots, X_k)$ heißt die *Multinomialverteilung*.

10.3.14 Aufgabe: Zeigen sie, dass $X_{i_1,1}, \ldots, X_{i_n,n}$ unabhängig sind, $(i_1, \ldots, i_n) \in \{1, \ldots, k\}^n$. Zeigen Sie weiter

$$P(X_{ij} = 1) = p_i$$

für alle $1 \leq i \leq k$ und $1 \leq j \leq n$.

Wir führen nun den Begriff einer mehrdimensionalen Dichte ein, streifen kurz den Begriff der Unabhängigkeit von n nicht notwendig diskreten Zufallsgrößen und charakterisieren die Unabhängigkeit in dem Spezialfall, dass jede Zufallsgröße absolutstetig ist. Sollten Sie das Mehrfachintegral noch nicht kennen, sind die folgenden Definitionen formal vermutlich trotzdem zu verstehen.

10.3.15 Definition:

(i) Eine LEBESGUE-integrierbare Funktion $f : \mathbb{R}^n \to [0, \infty)$ heißt *n-dimensionale Dichte*, wenn

$$\int_{\mathbb{R}^n} f(x)\, dx = 1$$

ist, wobei x ein n-Tupel $(x_1, \ldots, x_n)$ aus dem $\mathbb{R}^n$ bezeichnet.

(ii) Die Funktion f sei eine n-dimensionale Dichte und $X_1, \ldots, X_n$ seien n Zufallsgrößen. Man sagt, dass sie die *gemeinsame Dichte* f haben, wenn

$$P(X_1 \leq a_1,\, X_2 \leq a_2, \ldots, X_n \leq a_n) = \int_{(-\infty, a_1] \times \cdots \times (-\infty, a_n]} f(x)\, dx$$

für alle $a_1, \ldots, a_n \in \mathbb{R}$ gilt.

In Anlehnung an die allgemeine Definition 10.3.1 einer Zufallsgröße erscheint die Verallgemeinerung der Definition 10.2.1 der Unabhängigkeit von diskreten Zufallsgrößen für beliebige Zufallsgrößen beinahe überflüssig. Wir geben sie aber an:

10.3.16 Definition: Gegeben sei ein W.-Raum $(\Omega, \mathcal{A}, P)$ und n Zufallsgrößen X_1, $\ldots, X_n$, definiert auf $(\Omega, \mathcal{A}, P)$. Sie heißen *unabhängig*, wenn für alle $a_1, \ldots, a_n \in \mathbb{R}$ gilt:

$$P(X_1 \leq a_1, \ldots, X_n \leq a_n) = P(X_1 \leq a_1) \cdot \ldots \cdot P(X_n \leq a_n).$$

10.3.17 Bemerkung: Man prüft leicht nach, dass diese Definition für diskrete Zufallsgrößen äquivalent zu der bereits gegebenen ist.

10.3.18 Satz: $X_1, \ldots, X_n$ seien n Zufallsgrößen, definiert auf einem gemeinsamen W.-Raum $(\Omega, \mathcal{A}, P)$. Jedes der X_j habe eine Dichte f_j. (Wir setzen nicht voraus, dass eine gemeinsame Dichte existiert.) Dann sind die Zufallsgrößen $X_1, \ldots, X_n$ genau dann unabhängig, wenn eine gemeinsame Dichte für $X_1, \ldots, X_n$ durch $\mathbb{R}^n \ni (x_1, x_2, \ldots, x_n) \mapsto f_1(x_1) f_2(x_2) \ldots f_n(x_n)$ gegeben ist.

Beweis: Ist $\mathbb{R}^n \ni (x_1, x_2, \ldots, x_n) \mapsto f_1(x_1) f_2(x_2) \ldots f_n(x_n)$ eine gemeinsame Dichte, so ergibt sich für alle $a_1, \ldots, a_n \in \mathbb{R}$

$$\begin{aligned} P(X_1 \leq a_1, \ldots, X_n \leq a_n) &= \int_{-\infty}^{a_1} \cdots \int_{-\infty}^{a_n} f_1(x_1) \ldots f_n(x_n)\, dx_n \ldots dx_1 \\ &= \prod_{j=1}^{n} \int_{-\infty}^{a_j} f_j(x_j)\, dx_j = \prod_{j=1}^{n} P(X_j \leq a_j). \end{aligned}$$

Hierbei haben wir den Satz von Guido Fubini (1879–1943) verwendet: Das Mehrfachintegral ist gleich dem Produkt der Einzelintegrale, da der Integrand in den einzelnen Variablen getrennt auftritt. Somit sind $X_1, \ldots, X_n$ unabhängig. Sind die Zufallsvariablen $X_1, \ldots, X_n$ unabhängig, so folgt

$$\begin{aligned} P(X_1 \leq a_1, \ldots, X_n \leq a_n) &= \prod_{j=1}^{n} P(X_j \leq a_j) \\ &= \prod_{j=1}^{n} \int_{-\infty}^{a_j} f_j(x_j)\, dx_j \\ &= \int_{-\infty}^{a_1} \cdots \int_{-\infty}^{a_n} f_1(x_1) \ldots f_n(x_n)\, dx_n \ldots dx_1, \end{aligned}$$

und somit ist $\mathbb{R}^n \ni (x_1, \ldots, x_n) \mapsto f_1(x_1) \ldots f_n(x_n)$ eine gemeinsame Dichte. Erneut wurde der Satz von Fubini verwendet. $\square$

Lösungen der Aufgaben

Lösungen der Aufgaben in 10.1

Aufgabe 10.1.4

Im günstigsten Fall benötigt man acht Vergleiche. Nach der ersten Runde hat man im günstigsten Fall eine Teilliste mit drei und eine mit zwei Elementen. Für die Teilliste mit zwei Elementen benötigt man auf jeden Fall noch einen Vergleich. Zum Sortieren der Teilliste mit drei Elementen sind im besten Fall nur noch zwei Vergleiche notwendig. Daher kommt man nicht mit weniger als acht Vergleichen aus. Hat man nach der ersten Runde eine Teilliste der Länge vier und eine der Länge eins, so benötigt man für die Viererliste noch mindestens 4 Vergleiche. In diesem Fall benötigt man daher mindestens 9 Vergleiche. Im günstigsten Fall sind 8 und im ungünstigsten Fall 15 Vergleiche notwendig.

Aufgabe 10.1.7

Es gilt $\{\omega\} = \bigcap_{i=1}^{n} \{X_i = w_i\}$. Die Multiplikationsformel (Satz 8.3.1) für die Ereignisse $A_i := \{X_i = \omega_i\}$ ist unter den Voraussetzungen (i) und (ii) identisch mit dem Produktansatz (8.6). Daher kann P nicht anders als durch den Produktansatz definiert sein:

$$P(\{\omega\}) = p_1(\omega_1)p_2(\omega_2|\omega_1)p_3(\omega_3|\omega_1,\omega_2)\cdots p_n(\omega_n|\omega_1,...,\omega_{n-1}).$$

Sei P nun so definiert. Dann folgt für alle $1 \leq k \leq n$ und $\omega_1,...,\omega_k$ durch Summation über $\omega_{k+1},...,\omega_n$

$$\begin{aligned} P(X_1 = \omega_1,...,X_k = \omega_k) &= \sum_{\omega_{k+1}\in\Omega_{k+1},...,\omega_n\in\Omega_n} P(\{(\omega_1,...,\omega_n)\}) \\ = \; & p_1(\omega_1)\cdots p_k(\omega_k|\omega_1,...,\omega_{k-1}) \cdot \sum_{\omega_{k+1}\in\Omega_{k+1}} p_{k+1}(\omega_{k+1}|\omega_1,....,\omega_k)\cdots \\ & \cdots \sum_{\omega_n\in\Omega_n} p_n(\omega_n|\omega_1,...,\omega_{n-1}). \end{aligned}$$

Die letzte Summe ist nach Voraussetzung Eins. Für die vorletzte Summe ergibt sich dann ebenfalls Eins. Fährt man so fort, dann ergibt sich die gesamte Mehrfachsumme zu Eins. Für $k = 1$ folgt dann (i). Summiert man dann über die ω_1, so hat man gezeigt, dass P ein Wahrscheinlichkeitsmaß ist. Wenn $k > 1$ ist, dann folgt

$$P\left(X_1 = \omega_1, ..., X_k = \omega_k\right) = P\left(X_1 = \omega_1, ..., X_{k-1} = \omega_{k-1}\right) p_k(\omega_k | \omega_1, ..., \omega_{k-1})$$

und somit (ii).

Aufgabe 10.1.13

Es muss gelten $0 \leq k \leq 249$, damit $1 \leq 2k + 1 \leq 500$ erfüllt ist. Z_{2k+1} sei die Anzahl der linken Richter in dem Tribunal. Die gesuchte Wahrscheinlichkeit ist dann $P_{2k+1} := P\left(Z_{2k+1} \leq k\right)$. Es gilt

$$P_{2k+1} = \sum_{i=0}^{k} P\left(Z_{2k+1} = i\right) = \sum_{i=0}^{k} \frac{\binom{200}{i}\binom{300}{2k+1-i}}{\binom{500}{2k+1}}.$$

Die nachfolgende Tabelle zeigt, wie schnell die Wahrscheinlichkeit gegen 1 strebt.

k	0	1	2	3	4	5	8	12	28	249
P_{2k+1}	0.6	0.648	0.683	0.711	0.735	0.756	0.805	0.852	0.948	1

Aufgabe 10.1.15

Es sei A_k das Ereignis, zum Zeitpunkt k zum ersten Mal Erfolg zu haben. Für ein X, welches geometrisch verteilt ist, gilt dann $\{X = k\} = A_1^c \cap A_2^c \cap \cdots \cap A_{k-1}^c \cap A_k$. Betrachten wir nun

$$B_k := \bigcap_{j=1}^{k} A_j^c,$$

so steigt die Folge der Ereignisse $(B_k)_k$ gegen $\bigcap_{j\geq 1} A_j^c$ ab und es gilt mit der Stetigkeit der Wahrscheinlichkeit

$$P(X = \infty) = P\left(\bigcap_{j\geq 1} A_j^c\right) = \lim_{k\to\infty} P\left(A_1^c \cap \cdots \cap A_k^c\right) = \lim_{k\to\infty} (1-p)^k = 0.$$

Aufgabe 10.1.19

Es sei Ω wie in der Aufgabenstellung gegeben. Für $\omega = (\omega_1, ..., \omega_{m+1}) \in \Omega$ definieren wir

$$X_m(\omega) := \min\Big\{k : k \in \{2, ..., m+1\} \text{ und } \omega_k \in \{\omega_1, ..., \omega_{k-1}\}\Big\}.$$

Aufgabe 10.1.20

Wir können Beispiel 10.1.18 anwenden. Die Zufallsvariable X_m der ersten Kollision bestimmt hier den Zeitpunkt der ersten Kollision einer LOTTO-Ziehung seit der genannten im Jahre 1995. Kollision bedeutet hier vollständige Übereinstimmung der Ziehungen. Also ist $m = \binom{49}{6} = 13983816$, die Anzahl aller Möglichkeiten 6 aus 49 zu ziehen. Wir wollen $P(X_m \leq 3016)$ bestimmen. Wir verwenden die Formel in Beispiel 10.1.18 und erhalten $P(X_m \leq 3016) \approx 0.2775$. Das ist wohl keine Größenordnung, bei der man von einer Sensation sprechen sollte.

Aufgabe 10.1.21 (a) Zunächst gibt es $\binom{n}{k}$ Möglichkeiten der Auswahl der k Fixpunkte aus den n Zahlen. Bei gegebener fester Wahl von k Fixpunkten existieren nach Beispiel 6.2.27 $\mathcal{R}_{n-k}$ Möglichkeiten, die restlichen $n-k$ Zahlen fixpunktfrei zu permutieren. Nach der Produktregel folgt daraus bereits die Aussage in Teil (a).

(b) Wenn A_i das Ereignis bezeichnet, dass i ein Fixpunkt ist (siehe die Bezeichnung in Beispiel 6.2.27), so ist

$$X_n = \sum_{i=1}^{n} 1_{A_i}$$

die Anzahl der Fixpunkte. Dann ist mithilfe von (a)

$$P(X_n = k) = \frac{1}{n!}\binom{n}{k} \cdot \mathcal{R}_{n-k}.$$

Nun verwenden wir noch

$$\mathcal{R}_{n-k} = (n-k)! \sum_{i=0}^{n-k} \frac{(-1)^i}{i!}$$

(siehe Beispiel 6.2.27) und erhalten insgesamt

$$P(X_n = k) = \frac{1}{k!} \sum_{i=0}^{n-k} \frac{(-1)^i}{i!}.$$

Lösungen der Aufgaben in 10.2

Aufgabe 10.2.4

Für den Beweis der ersten Aussage verwenden wir Satz 10.2.2 (iv). Hier ist $X_i(\Omega) = \{0,1\}$ für $i = 1,\ldots,n$. Es sei also ein n-Tupel $(i_1,\ldots,i_n) \in \{0,1\}^n$ gegeben. Dann gilt mit $k := \sum_{j=1}^n i_j$:

$$\begin{aligned} P(X_1 = i_1,\ldots,X_n = i_n) &= \prod_{j=1}^n p^{i_j}(1-p)^{1-i_j} = p^{\sum_{j=1}^n i_j}(1-p)^{n-\sum_{j=1}^n i_j} \\ &= p^k(1-p)^{n-k} = \prod_{j:i_j=1} p \cdot \prod_{j:i_j=0}(1-p), \end{aligned}$$

und dies ist offenbar auch gleich $\prod_{j=1}^n P(X_j = i_j)$.
Für den Beweis der zweiten Aussage gehen wir nun analog vor: Die Zufallsvariable S_{n-1} hat Werte in $\{0,\ldots,n-1\}$. Für $i \in \{0,1\}$ und $k \in \{0,\ldots,n-1\}$ gilt unter Verwendung von der Unabhängigkeit der X_i

$$\begin{aligned} P(S_{n-1} = k, X_n = i) &= \sum_{\substack{i_1,\ldots,i_{n-1}\in\{0,1\}:\\ \sum_{j=1}^{n-1} i_j = k}} P(X_1 = i_1,\ldots,X_{n-1} = i_{n-1}, X_n = i) \\ &= \sum_{\substack{i_1,\ldots,i_{n-1}\in\{0,1\}:\\ \sum_{j=1}^{n-1} i_j = k}} \prod_{j=1}^{n-1} P(X_j = i_j)\cdot P(X_n = i) \\ &= P(X_n = i)\cdot p^k(1-p)^{n-1-k} \sum_{\substack{i_1,\ldots,i_{n-1}\in\{0,1\}:\\ \sum_{j=1}^{n-1} i_j = k}} 1 \\ &= P(X_n = i)\cdot \binom{n-1}{k} p^k(1-p)^{n-1-k} \\ &= P(X_n = i)\cdot P(S_{n-1} = k)\,, \end{aligned}$$

denn bekanntlich ist S_{n-1} binomialverteilt zu den Parametern $n-1$ und p.

Aufgabe 10.2.6

Eine einfache Rechnung zeigt, dass X_3 dieselbe Verteilung besitzt, wie X_1 und X_2: Es gilt etwa

$$\begin{aligned} P(X_3 = 1) &= P(X_1 = X_2 = 1) + P(X_1 = X_2 = -1) \\ &= \left(\frac{1}{2}\right)^2 + \left(\frac{1}{2}\right)^2 = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}\,. \end{aligned}$$

Analog zeigt man $P(X_3 = -1) = \frac{1}{2}$. Nach Voraussetzung sind X_1 und X_2 unabhängig. Ferner sind auch X_1 und X_3 unabhängig, denn es gilt zum Beispiel:

$$\begin{aligned} P(X_1 = 1, X_3 = -1) &= P(X_1 = 1, X_2 = -1) = \frac{1}{2} \cdot \frac{1}{2} \\ &= \frac{1}{4} = P(X_1 = 1) \cdot P(X_3 = -1). \end{aligned}$$

Analog überlegt man sich dies für die anderen möglichen Fälle. Ferner folgt aus Symmetriegründen, dass auch X_2 und X_3 unabhängig sind. Somit sind die drei Zufallsvariablen paarweise unabhängig. Jedoch sind X_1, X_2 und X_3 nicht unabhängig, denn es gilt zum Beispiel:

$$P(X_1 = X_2 = 1, X_3 = -1) = P(\emptyset) = 0 \neq \frac{1}{8} = P(X_1 = 1)P(X_2 = 1)P(X_3 = -1)\,.$$

Lösungen der Aufgaben in 10.3

Aufgabe 10.3.7

zu (d): Offenbar ist f nichtnegativ. Für $R > 0$ gilt:

$$\int_0^R \lambda e^{-\lambda x} dx = -e^{-\lambda x}\Big|_0^R = 1 - e^{-R} \overset{R\to\infty}{\longrightarrow} 1\,,$$

sodass f uneigentlich Riemann-integrierbar ist mit Integralwert 1.

zu (e): Wieder ist f offensichtlich nichtnegativ. Für $R, S > 0$ gilt nun

$$\begin{aligned} I_{R,S} &:= \frac{c}{\pi} \int_{-S}^{R} \frac{1}{x^2 + c^2} dx = \frac{1}{\pi} \int_{-S}^{R} \frac{1}{\left(\frac{x}{c}\right)^2 + 1} \cdot \frac{1}{c} dx \\ &= \frac{1}{\pi} \int_{-\frac{S}{c}}^{\frac{R}{c}} \frac{1}{t^2 + 1} = \frac{1}{\pi} \arctan t \Big|_{-\frac{S}{c}}^{\frac{R}{c}} \\ &= \frac{1}{\pi} \left(\arctan\left(\frac{R}{c}\right) - \arctan\left(-\frac{S}{c}\right) \right)\,. \end{aligned}$$

Nun gilt $\lim_{R,S\to+\infty} I_{R,S} = \frac{1}{\pi}(\frac{\pi}{2} - (-\frac{\pi}{2})) = 1$, sodass f uneigentlich Riemann-integrierbar ist mit $\int_{-\infty}^{\infty} f(x)dx = 1$. Daher ist f eine Dichte.

Aufgabe 10.3.8

Wir manipulieren die Integrale im Gegensatz zur letzten Aufgabe als LEBESGUE-Integrale.

(a) Wir haben

$$\begin{aligned}\int_{-\infty}^{\infty} f_1(x)\,dx &= c_1 \int_{-\infty}^{\infty} \frac{1}{\alpha^2+(x-\beta)^2}dx \\ &= \frac{c_1}{|\alpha|}\int_{-\infty}^{\infty} \frac{1}{1+\left(\frac{x-\beta}{|\alpha|}\right)^2}\cdot\frac{1}{|\alpha|}dx \\ &= \frac{c_1}{|\alpha|}\int_{-\infty}^{\infty}\frac{1}{t^2+1}dt = \frac{c_1}{|\alpha|}\arctan(t)\Big|_{-\infty}^{\infty} \\ &= \frac{c_1\cdot\pi}{|\alpha|}\end{aligned}$$

und dies ist genau dann gleich 1, wenn $c_1 = \frac{|\alpha|}{\pi}$. In diesem Fall ist f_1 auch nichtnegativ und damit eine Dichte.

(b) Es gilt

$$\int_0^{\pi} \sin(x)\,dx = -\cos(x)\Big|_0^{\pi} = 2\,,$$

sodass f_2 genau dann eine Dichte ist, wenn $c_2 = \frac{1}{2}$.

(c) Wir berechnen

$$\begin{aligned}\int_1^{\infty} x^{-r}dx &= \lim_{R\to\infty}\frac{1}{1-r}x^{1-r}\Big|_1^R \\ &= \frac{1}{1-r}\left(R^{1-r}-1\right) \overset{R\to\infty}{\longrightarrow} \frac{-1}{1-r} \\ &= \frac{1}{r-1}\,,\end{aligned}$$

wobei für den Grenzübergang die Voraussetzung $r > 1$ wesentlich war. Somit ist f_3 genau dann eine Dichte, wenn $c_3 = r-1$.

(d) Nach Aufgabe 10.3.7 ist f_4 genau dann eine Dichte, wenn $c_4 = \lambda^2$.

Aufgabe 10.3.14

Für $i = 1,\ldots,k$ sowie $j = 1,\ldots,n$ gilt $\{X_{ij} = 1\} = A_{ij}$ und $\{X_{ij} = 0\} = A_{ij}^c$. Sowohl A_{ij} als auch A_{ij}^c hängen nur von dem Ausgang des j-ten Versuchs ab und sind nach Satz 9.18 stochastisch unabhängig. Daher sind die Zufallsvariablen $X_{i_1,1},\ldots,X_{i_n,n}$ ebenfalls stochastisch unabhängig. Weiter gilt:

$$P(X_{ij} = 1) = P(A_{ij}) = p_i\,,$$

was unmittelbar aus der Konstruktion des Produktraumes folgt.

Kapitel 11

Erwartungswert, Varianz und Korrelation

Da sich exakte Verteilungen in manchen Beispielen nur schwer oder gar nicht explizit berechnen lassen, ist es wichtig, dass es gewisse Kenngrößen von Zufallsgrößen gibt, die oft einfacher zu berechnen oder abzuschätzen sind, und die wichtige Informationen über die Zufallsgrößen enthalten. Die wichtigste dieser Größen ist der Erwartungswert, der angibt, wo die Zufallsgröße „im Mittel“ liegt. Wir betrachten in diesem Kapitel darüberhinaus die Varianz, die Kovarianz sowie Momente von Zufallsgrößen und bestimmen diese Kenngrößen in vielen Beispielen. Wir verweisen an geeigneten Stellen auf den Zusammenhang zu den Kenngrößen, die wir in der ersten Kurseinheit kennengelernt haben.

11.1 Erwartungswert

Für diskrete Zufallsgrößen ist der Erwartungswert die Reihe der gewichteten Werte:

11.1.1 Definition: Es sei X eine diskrete Zufallsgröße, definiert auf einem diskreten W.-Raum (Ω, p). Man sagt, dass der Erwartungswert von X existiert, falls $\sum_{z\in X(\Omega)} |z|P(X=z) < \infty$. Der *Erwartungswert von* X ist dann definiert durch

$$\mathbb{E}(X) := \sum_{z\in X(\Omega)} zP(X=z).$$

Wir definieren also $\mathbb{E}(X)$ nur, wenn die Reihe absolut konvergiert. Der Wert der Reihe $\sum_{z\in X(\Omega)} zP(X=z)$ hängt dann nicht von der Reihenfolge der Summanden ab. Es muss hervorgehoben werden, dass der Erwartungswert einer Zufallsgröße nur

von deren Verteilungen abhängt. Zwei verschiedene Zufallsgrößen mit derselben Verteilung haben also denselben Erwartungswert. Wir lassen die Klammern oft weg und schreiben $\mathbb{E}X$ statt $\mathbb{E}(X)$.

Es ist offenbar nicht möglich, diese Definition von $\mathbb{E}(X)$ für eine allgemeine Zufallsgröße zu verwenden. Wir definieren nun den Erwartungswert für eine absolutstetige Zufallsgröße. Dass beide Definitionen ein gemeinsames Dach haben, folgt aus der Konstruktion des Integrals einer Zufallsgröße bezüglich eines Wahrscheinlichkeitsmaßes P. Dies ist ein schönes Stück Mathematik, welches zur Maß- und Integrationstheorie gehört, aber nicht Gegenstand des vorliegenden Kurses ist.

11.1.2 Definition: Die Zufallsgröße X auf einem W.-Raum $(\Omega, \mathcal{A}, P)$ habe eine Dichte f. Ist $\mathbb{R} \ni x \mapsto x\,f(x)$ LEBESGUE-integrierbar, so sagen wir, dass der Erwartungswert von X existiert. Er ist dann definiert durch

$$\mathbb{E}(X) := \int_{-\infty}^{\infty} x\,f(x)\,dx.$$

11.1.3 Bemerkung: Eine Funktion f ist per Definition Lebesgue-integrierbar, falls das Lebesgue-Integral von $|f|$ existiert. Somit existiert auch hier der Erwartungswert $\mathbb{E}(X)$ von X nur dann, wenn der Erwartungswert $\mathbb{E}(|X|)$ von $|X|$ existiert.

Besondere Aufmerksamkeit wird dem Fall einer Zufallsgröße mit endlich vielen Werten geschenkt. Wir nennen dies den *endlichen Fall*:

11.1.4 Definition: Eine diskrete Zufallsgröße, definiert auf einem diskreten W.-Raum (Ω, p), nehme endlich viele Werte an, also $X(\Omega) = \{x_1, \ldots, x_k\}$. Weiter bezeichne $p_i := P(X = x_i)$ für jedes $i = 1, \ldots, k$. Diese Situation nennen wir den *endlichen Fall* und X nennen wir dann *endlich*.

11.1.5 Beispiel: Es sei X endlich im Sinne der Definition 11.1.4, versehen mit der Gleichverteilung $P(X = x_j) := \frac{1}{k}$, $j = 1, \ldots, k$. Dann existiert der Erwartungswert $\mathbb{E}(X)$ und es gilt

$$\mathbb{E}(X) = \frac{1}{k}\,x_1 + \cdots + \frac{1}{k}\,x_k = \frac{1}{k}\sum_{i=1}^{k} x_i.$$

Dies ist das arithmetische Mittel $\bar{x}$ der Werte, siehe Definition 3.1.6. Wir haben die Schwerpunktseigenschaft von $\bar{x}$ hergeleitet: $\sum_i (x_i - \bar{x}) = 0$, siehe 3.1.10. Diese physikalische Interpretation gilt allgemeiner: Es sei X endlich. Die Punkte in $X(\Omega)$ seien Massepunkte auf der reellen Achse. $x_i \in X(\Omega)$ habe die Masse $P(X = x_i)$.

Dann ist $\mathbb{E}(X)$ der Schwerpunkt dieser Masseverteilung. Dies sehen wir so: Wir suchen ein $s \in \mathbb{R}$, welches der Gleichgewichtsbedingung

$$\sum_{i=1}^{k}(x_i - s)P(X = x_i) = 0$$

genügt. Dieses s nennt man Schwerpunkt bzw. Massenmittelpunkt. Es folgt

$$s = \sum_{i=1}^{k} x_i \cdot P(X = x_i) = \mathbb{E}(X).$$

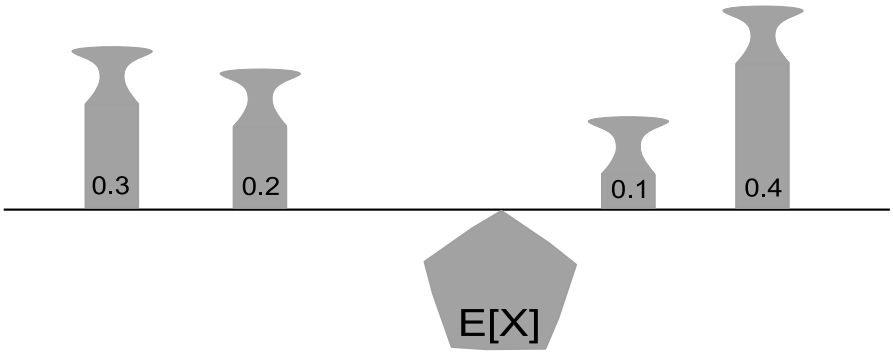

Abb. 11.1: $\mathbb{E}(X)$ als Schwerpunkt einer Massenverteilung

Wir betrachten den Fall einer diskreten Zufallsgröße. In der Definition des Erwartungswertes von X kann man statt über $X(\Omega)$ auch über Ω summieren:

11.1.6 Lemma: (Transportsatz) Sei (Ω, p) ein diskreter W.-Raum und X eine darauf definierte Zufallsgröße. Der Erwartungswert von X existiert genau dann, wenn die Reihe $\sum_{\omega\in\Omega} p(\omega)\, X(\omega)$ absolut konvergiert. In diesem Falle gilt

$$\mathbb{E}(X) = \sum_{\omega\in\Omega} p(\omega)X(\omega).$$

Beweis: Es gilt

$$\begin{aligned}\sum_{z\in X(\Omega)} |z|P(X = z) &= \sum_{z\in X(\Omega)} |z| \sum_{\omega: X(\omega)=z} p(\omega) \\ &= \sum_{(z,\omega): X(\omega)=z} |z|\, p(\omega) = \sum_{\omega\in\Omega} |X(\omega)|\, p(\omega).\end{aligned}$$

Die letzte Gleichheit folgt, da wir Ω disjunkt in die Teilmengen $X^{-1}(z)$, $z \in X(\Omega)$, zerlegt haben. Somit folgt der erste Teil der Behauptung. Der zweite Teil ergibt sich mit einer Wiederholung der obigen Rechnung ohne Absolutbetragszeichen. □

11.1.7 Bemerkung: Der Transportsatz für Zufallsgrößen auf einem W.-Raum $(\Omega, \mathcal{A}, P)$ mit Dichte f lautet:

$$\int_{\mathbb{R}} x f(x)\, dx = \int_{\Omega} X\, dP.$$

Wir wollen und können auf diese Identität nur hinweisen. Die rechte Seite der obigen Gleichung ist das Integral von X bezüglich des W.-Maßes P, welches wir aber nicht einführen.

Wir sammeln nun grundlegende Eigenschaften des Erwartungswertes. Sie sind auch für den Erwartungswert absolutstetiger Zufallsgrößen gültig. Wir verzichten darauf, dies zu formulieren. Fortan sei X eine diskrete Zufallsgröße auf einem diskreten W.-Raum (Ω, p).

11.1.8 Satz: (Linearität und Monotonie)

(i) Ist $c \in \mathbb{R}$ und X die konstante Abbildung nach c (d.h. $X(\omega) = c$ für alle $\omega \in \Omega$), so gilt $\mathbb{E}(X) = c$.

(ii) $X_1, \ldots, X_n$ seien (auf einem gemeinsamen W.-Raum definierte) Zufallsgrößen, deren Erwartungswerte existieren, und $a_1, \ldots, a_n$ seien reelle Zahlen. Ferner sei $a_1X_1 + a_2X_2 + \cdots + a_nX_n$ die Zufallsgröße, deren Wert an jeder Stelle $\omega \in \Omega$ gleich $a_1X_1(\omega) + a_2X_2(\omega) + \cdots + a_nX_n(\omega)$ ist. Dann existiert $\mathbb{E}(a_1X_1 + \cdots + a_nX_n)$ und ist gleich $a_1\,\mathbb{E}(X_1) + \cdots + a_n\,\mathbb{E}(X_n)$. Man sagt, der Erwartungswert ist linear.

(iii) Seien X und Y Zufallsgrößen. Gilt $X \leq Y$ und existieren die Erwartungswerte von X und Y, so gilt $\mathbb{E}(X) \leq \mathbb{E}(Y)$. Man sagt, der Erwartungswert ist monoton.

Beweis: (i) und (iii) sind nach der Definition des Erwartungswertes evident.
Zu (ii): Wir benutzen Lemma 11.1.6 und die Dreiecksungleichung:

$$\begin{aligned} & \sum_{\omega} p(\omega)|a_1X_1(\omega) + \cdots + a_nX_n(\omega)| \\ \leq\ & |a_1| \sum_{\omega} p(\omega)|X_1(\omega)| + \cdots + |a_n| \sum_{\omega} p(\omega)|X_n(\omega)| < \infty. \end{aligned}$$

Somit existiert der Erwartungswert und es gilt

$$\begin{aligned} \mathbb{E}(a_1X_1 + \cdots + a_nX_n) &= \sum_{\omega} p(\omega)(a_1X_1(\omega) + \cdots + a_nX_n(\omega)) \\ &= a_1 \sum_{\omega} p(\omega)X_1(\omega) + \cdots + a_n \sum_{\omega} p(\omega)X_n(\omega) \end{aligned}$$

$$= \quad a_1\mathbb{E}(X_1) + \cdots + a_n\mathbb{E}(X_n).$$

□

11.1.9 Aufgabe: Zeigen Sie: $\mathbb{E}X$ ist genau dann endlich, wenn $\mathbb{E}(|X|)$ endlich ist. Ist $\mathbb{E}X$ endlich, so gilt $|\mathbb{E}X| \leq \mathbb{E}(|X|)$.

11.1.10 Bemerkung: Die Menge aller Zufallsgrößen, die auf Ω definiert sind, ist einfach $\mathbb{R}^\Omega$ und in natürlicher Weise ein $\mathbb{R}$-Vektorraum. Die Menge der Zufallsgrößen, deren Erwartungswert existiert, ist nach Satz 11.1.8(ii) ein Unterraum von $\mathbb{R}^\Omega$. Man bezeichnet ihn oft als $L_1(\Omega, p)$. Der Erwartungswert ist eine lineare Abbildung von $L_1(\Omega, p)$ nach $\mathbb{R}$, also ein Element des Dualraumes von $L_1(\Omega, p)$.

11.1.11 Beispiele: (a) Der Erwartungswert der Indikatorfunktion 1_A von $A \subseteq \Omega$ ist $\mathbb{E}(1_A) = P(A)$, denn $A = \{\omega : 1_A(\omega) = 1\}$ und damit $\mathbb{E}(1_A) = 0 \cdot P(A^c) + 1 \cdot P(A)$.

(b) X sei *binomialverteilt* mit Parametern p, n:
Wir schreiben X als $X_1 + \cdots + X_n$, wobei $X_i = 1$ ist, wenn der i-te Versuch von Erfolg gekrönt war, und andernfalls $X_i = 0$. Es gilt $\mathbb{E}(X_i) = P(X_i = 1) = p$ und mithilfe der Linearität folgt

$$\mathbb{E}(X) = n\,p.$$

Man kann alternativ direkt die Definition der Binomialverteilung verwenden und somit

$$\mathbb{E}(X) = \sum_{k=0}^{n} k\,P(X = k) = \sum_{k=0}^{n} k \binom{n}{k} p^k (1-p)^{n-k}$$

bestimmen. Das liefert natürlich auch $n\,p$, aber warum kompliziert, wenn es auch wesentlich einfacher geht. Man sollte die alternative Bestimmung des Erwartungswertes gleich wieder vergessen. Die Linearität wird auch in den folgenden Beispielen das Leben deutlich vereinfachen.

(c) X sei *Polyá-verteilt* mit Parametern n, r, s und c:
Wir schreiben X erneut als $X_1 + \cdots + X_n$, wobei $X_i = 1$ ist, wenn beim i-ten Versuch eine rote Kugel gezogen wird, und andernfalls $X_i = 0$. Also ist $X_i = 1_{A_i}$ mit dem Ereignis A_i, beim i-ten Zug eine rote Kugel zu ziehen. Dann ist

$$\mathbb{E}(X) = \mathbb{E}(X_1) + \cdots + \mathbb{E}(X_n) = \sum_{i=1}^{n} P(A_i) = n \cdot \frac{r}{r+s}.$$

Der Erwartungswert der Polyá-Verteilung ist somit unabhängig vom Parameter c, der Anzahl der zusätzlich entnommenen bzw. zurückgelegten Kugeln der gleichen Farbe! Natürlich haben wir den Erwartungswert einer binomialverteilten Zufallsgröße wiederentdeckt ($c = 0$, $p = r/(r+s)$). Eine *hypergeometrisch* verteilte Zufallsgröße hat Erwartungswert $\mathbb{E}(X) = n \cdot \frac{r}{r+s}$.

(d) X sei *geometrisch verteilt* mit Parameter $p > 0$:
Es gilt $\mathbb{E}(X) = \sum_{k=1}^{\infty} k(1-p)^{k-1}p$. Eine Anwendung des Quotientenkriteriums zeigt, dass die Reihe konvergiert. Zur Berechnung verwenden wir den folgenden Trick: Sei $f(s) := \sum_{k=1}^{\infty} s^k = s/(1-s)$ für alle $|s| < 1$ (geometrische Reihe). Dann gilt

$$f'(s) = \sum_{k=1}^{\infty} ks^{k-1} = \frac{(1-s) - s(-1)}{(1-s)^2} = \frac{1}{(1-s)^2}.$$

(Frage an den Leser: Warum darf gliedweise differenziert werden?) Setzt man $s = 1 - p$ ein, so ergibt sich

$$\sum_{k=1}^{\infty} k(1-p)^{k-1} = \frac{1}{p^2}, \quad \text{also} \quad \mathbb{E}(X) = \frac{1}{p}.$$

Bei einer fairen Münze ist die mittlere Anzahl der Experimente bis zum Eintreten des ersten Erfolgs zwei. Dies entspricht wohl unserer Intuition.

11.1.12 Aufgabe: Es sei X_r *negativ binomialverteilt* mit Parametern $r \in \mathbb{N}$ und $0 < p < 1$. Bestimmen Sie unter Verwendung des Erwartungswertes einer geometrisch verteilten Zufallsgröße den Erwartungswert $\mathbb{E}(X_r)$.

11.1.13 Beispiel: Zwei Personen stehen an einer Bushaltestelle, an der alle 10 Minuten ein Bus hält. Der Busfahrer entscheidet rein zufällig, welche der beiden Personen er mitnimmt. Diese steigt ein. Vor dem Eintreffen des nächsten Busses kommen zwei weitere Personen an die Haltestelle. Der Busfahrer entscheidet wieder wie oben, u.s.w. Für eine der beiden ersten Personen fragen wir, in den wievielten Bus sie mit welcher Wahrscheinlichkeit einsteigen kann. Wir wählen $\Omega := \mathbb{N}$. Wie groß ist $P(\{n\})$? Das Ereignis $\{n\}$ bedeutet, dass die Person in den n-ten Bus einsteigt, somit alle vorigen Busfahrer eine andere Person gewählt haben. Es warten $k+1$ Personen auf den k-ten Bus! Damit ist

$$\begin{aligned} P(\{n\}) &= \left(1 - \frac{1}{1+1}\right) \cdot \left(1 - \frac{1}{1+2}\right) \cdots \left(1 - \frac{1}{1+(n-1)}\right) \cdot \frac{1}{n+1} \\ &= \frac{1}{2} \cdot \frac{2}{3} \cdots \frac{3}{4} \cdots \frac{n-1}{n} \cdot \frac{1}{n+1} = \frac{1}{n(n+1)}. \end{aligned}$$

Aus Aufgabe 5.1.21 wissen wir bereits, dass sich diese Wahrscheinlichkeiten zu 1 aufsummieren, wir also einen W.-Raum $(\mathbb{N}, p)$ gefunden haben. Nun gilt

$$1 \cdot p(1) + 2 \cdot p(2) + \cdots = \frac{1}{2} + \frac{1}{3} + \frac{1}{4} + \cdots .$$

Das ist die harmonische Reihe, die aber divergiert. Der Erwartungswert existiert in diesem Beispiel nicht! Im Durchschnitt muss man unendlich lange warten, bis man in den Bus einsteigen kann.

11.1.14 Beispiel: (mittlere Anzahl von Fixpunkten einer zufälligen Permutation) Ein Stapel bestehend aus n nummerierten Karten wird zufällig in eine Reihe gelegt. Alle $n!$ Möglichkeiten mögen gleich wahrscheinlich sein. X bezeichne nun die Anzahl der Karten, die in Bezug auf die natürliche Anordnung an „ihrem“ Platz liegen. X nimmt also Werte in $\{0, 1, \ldots, n\}$ an. Wir haben uns mit X schon ausgiebig beschäftigt, siehe Beispiel 6.2.27 und Aufgabe 10.1.21. So kennen wir bereits die Verteilung von X. Von ihr kann man den Erwartungswert ableiten. Wir berechnen diesen Wert hier aber direkt: Dazu sei X_k die Zufallsgröße mit Werten 1 oder 0 je nachdem, ob die Karte mit der Nummer k am k-ten Platz liegt oder nicht. Dann ist $X = X_1 + X_2 + \cdots + X_n$. Jede Karte ist mit Wahrscheinlichkeit $1/n$ am k-ten Platz, also ist $P(X_k = 1) = 1/n$ und $P(X_k = 0) = (n-1)/n$ und somit $\mathbb{E}(X_k) = 1/n$. Damit folgt $\mathbb{E}(X) = 1$. Im Durchschnitt liegt also eine Karte an ihrem Platz.

11.1.15 Aufgabe: Bestimmen Sie den Erwartungswert der Anzahl X der Fixpunkte einer zufälligen Permutation von n Elementen unter Verwendung der Aufgabe 10.1.21.

11.1.16 Beispiel: (randomisiertes Quicksort) Wir erinnern an den randomisierten Quicksort-Algorithmus. Aus einer Liste S von n verschiedenen Zahlen wählen wir rein zufällig ein Element aus. Dann bestimmen wir Teillisten $L_<$ und $L_>$ bestehend aus den Elementen, die kleiner bzw. größer als dieses Element sind. Man verfahre mit den Teillisten dann analog, bis die Menge der n Zahlen in lauter einelementige Mengen zerfallen ist. Es bezeichne mit X_n die Gesamtzahl der durchgeführten Vergleiche zweier Zahlen. Falls der Zufall als Vergleichszahl immer das kleinste oder das größte Element auswählt, benötigt man besonders viele Vergleiche. Es sind

$$(n-1) + (n-2) + (n-3) + \cdots + 1 = n(n-1)/2$$

Vergleiche. Dies nennt man den *worst case*. Quicksort ist besonders schnell, falls stets der mittlere Wert, der *Median*, der zu sortierenden Mengen zufällig gewählt

wird. Dann benötigt man etwa $n \log_2(n)$ Vergleiche, wobei die Anzahl der Iterationen (hier Halbierungen) etwa $\log_2(n)$ ist. Dies ist einfach einzusehen: $\log_2(n)$ ist diejenige Zahl, mit der man 2 potenzieren muss, um n zu erhalten. Insgesamt ist also ein günstiger Verlauf des Quicksort-Algorithmus durch $X_n = n \log_2 n$ gegeben. Wir werden im Folgenden zeigen, dass

$$\mathbb{E}(X_n) = 2(n+1)\Big(1 + \frac{1}{2} + \frac{1}{3} + \cdots + \frac{1}{n}\Big) - 4n$$

gilt, also

$$\mathbb{E}(X_n) = 2n \ln(n) + \mathcal{O}(n).$$

[Zur Erinnerung: Eine Funktion f ist $\mathcal{O}(g)$, falls für eine (endliche) Konstante C $|f| \leq C|g|$ gilt. In $\mathcal{O}(n)$ meint man die Identitätsfunktion $g : n \mapsto n$ definiert auf $\mathbb{N}$.] Da $2\ln(n) \approx 1.39 \log_2(n)$, muss man im Mittel nur 39% mehr Vergleiche als im günstigsten Fall machen. Für S schreiben wir

$$S = \{s_{(1)}, s_{(2)}, \ldots, s_{(n)}\},$$

wobei dies die korrekte Ordnung von S sei, also $s_{(i)} < s_{(j)}$ für $i < j$. Nun gilt

$$X_n = \sum_{1 \leq i < j \leq n} 1_{A_{ij}},$$

wobei A_{ij} das Ereignis bezeichnet, dass es im Verlauf des Algorithmus zum Vergleich von $s_{(i)}$ und $s_{(j)}$ kommt. Dann ist

$$\mathbb{E}(X_n) = \sum_{1 \leq i < j \leq n} P(A_{ij}).$$

Das Ereignis A_{ij} tritt genau dann ein, wenn entweder $s_{(i)}$ oder $s_{(j)}$ das erste der Elemente $s_{(i)}, \ldots, s_{(j)}$ ist, das als Vergleichselement ausgewählt wird. Da jedes der $j - i + 1$ Elemente mit gleicher Wahrscheinlichkeit gewählt wird, folgt

$$P(A_{ij}) = \frac{2}{j - i + 1}$$

für alle $1 \leq i < j \leq n$. Wir erhalten

$$\mathbb{E}(X_n) = 2 \sum_{j=2}^{n} \sum_{i=1}^{j-1} \frac{1}{j - i + 1} = 2 \sum_{j=2}^{n} \sum_{i=2}^{j} \frac{1}{i}.$$

Nun vertauschen wir die Summationsreihenfolge und erhalten

$$\mathbb{E}(X_n) = 2 \sum_{i=2}^{n} \sum_{j=i}^{n} \frac{1}{i} = 2 \sum_{i=2}^{n} (n - i + 1) \frac{1}{i} = 2(n+1) \sum_{i=2}^{n} \frac{1}{i} - 2(n-1).$$

Die Asymptotik folgt nun aus

$$1 + \frac{1}{2} + \frac{1}{3} + \cdots + \frac{1}{n} = \ln(n) + \mathcal{O}(1).$$

Wer das nicht kennt: Wir betrachten die *harmonische Summe*

$$H_n := \sum_{k=1}^{n} \frac{1}{k}.$$

Dann ist

$$H_n - 1 = \sum_{k=2}^{n} \frac{1}{k} < \int_1^n \frac{1}{t}\, dt = \ln(n)$$

sowie

$$H_n - \frac{1}{n} = \sum_{k=1}^{n-1} \frac{1}{k} > \int_1^n \frac{1}{t}\, dt = \ln(n).$$

Zusammenfassend erhalten wir also

$$\ln(n) + \frac{1}{n} < H_n < \ln(n) + 1.$$

In dem in Beispiel 10.1.3 vorgestellten deterministischen Quicksort-Algorithmus (keine zufällige Wahl des ersten Vergleichswertes) ergibt sich mithilfe eines erheblich größeren Rechenaufwands eine vergleichbare Information über $\mathbb{E}(X_n)$:

$$2(n+1)(\ln(n+1) - 2) \le \mathbb{E}(X_n) \le 2(n+1)\ln(n+1).$$

In beiden Fällen gilt also

$$\lim_{n\to\infty} \frac{\mathbb{E}(X_n)}{n\ln(n)} = 2.$$

Man weiß übrigens, dass es keinen Sortieralgorithmus geben kann mit einem Aufwand, dessen Größenordnung unter $n\ln(n)$ liegt. Es gibt einen Algorithmus (*Mergesort*), der jede vorgegebene Liste in weniger als $C\,n\ln(n)$ Schritten ordnet, während Quicksort in ungünstigen Fällen wesentlich mehr Schritte benötigt; C ist hier eine (endliche) Konstante. Der mittlere Aufwand ist bei Quicksort hingegen günstiger als bei Mergesort.

11.1.17 Beispiele: (Erwartungswerte absolutstetiger Verteilungen)

(a) Es sei X standard-normalverteilt. Dann ist

$$\int_{-\infty}^{\infty} |x| \frac{1}{\sqrt{2\pi}} e^{-x^2/2}\, dx = \frac{2}{\sqrt{2\pi}} \int_0^{\infty} x e^{-x^2/2}\, dx = \frac{2}{\sqrt{2\pi}} \left(-e^{-x^2/2}\right)\Big|_0^{\infty} = \sqrt{\frac{2}{\pi}} < \infty.$$

Also existiert der Erwartungswert von X, und es gilt

$$\mathbb{E}(X) = \int_{-\infty}^{\infty} x \frac{1}{\sqrt{2\pi}} e^{-x^2/2}\, dx = 0,$$

da der Integrand eine ungerade Funktion ist.

(b) Es sei X normalverteilt mit den Parametern $\mu \in \mathbb{R}$ und $\sigma > 0$. Mit der Transformation $y := (x-\mu)/\sigma$ folgt unter Verwendung von Beispiel (a)

$$\begin{aligned} \int_{-\infty}^{\infty} |x| \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/2\sigma^2}\, dx &= \int_{-\infty}^{\infty} |\mu + \sigma y| \frac{1}{\sqrt{2\pi}} e^{-y^2/2}\, dy \\ &\leq |\mu| + \sigma \int_{-\infty}^{\infty} |y| \frac{1}{\sqrt{2\pi}} e^{-y^2/2}\, dy < \infty. \end{aligned}$$

Also existiert der Erwartungswert, und es gilt

$$\mathbb{E}(X) = \int_{-\infty}^{\infty} x \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/2\sigma^2} dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} (y\sigma + \mu) e^{-y^2/2}\, dy = \mu.$$

(c) Es sei X exponentialverteilt mit Parameter $\lambda > 0$. Partielle Integration ergibt

$$\mathbb{E}(X) = \int_0^{\infty} \lambda x e^{-\lambda x}\, dx = -x e^{-\lambda x}\Big|_0^{\infty} + \int_0^{\infty} e^{-\lambda x} dx = 0 + \left(-\frac{1}{\lambda} e^{-\lambda x}\right)\Big|_0^{\infty} = \frac{1}{\lambda},$$

insbesondere existiert der Erwartungswert.

Wir werden an anderer Stelle sehen, in welchen stochastischen Modellen die aufgeführten absolutstetigen Zufallsgrößen auftreten.

11.1.18 Aufgabe: Existiert der Erwartungswert einer CAUCHY-verteilten Zufallsgröße zum Parameter $c = 1$ (siehe Beispiel 10.3.5(e)?

Wir hatten in Beispiel 11.1.5 das arithmetische Mittel wiederentdeckt. Auch das geometrische und das harmonische Mittel treten im Zusammenhang mit diskreten Zufallsgrößen auf.

Wir betrachten nun eine endliche Zufallsgröße X (siehe Definition 11.1.4), die nur *positive* Werte $x_1, \ldots, x_k$ annimmt. Es sei $p_i := P(X = x_i)$, $i = 1, \ldots, k$. Dann nennen wir für $r \in \mathbb{R}$

$$m_r = \sum_{i=1}^{k} p_i\, x_i^r \tag{11.1}$$

das *r-te Moment* und $s_r := (m_r)^{1/r}$ die *Abweichung r-ter Ordnung* für $r \neq 0$.

11.1.19 Satz: Der Grenzwert $\lim_{r\to 0} s_r$ existiert und ist gleich $s_0 := \prod_{i=1}^k x_i^{p_i}$.

Wir erkennen, dass s_0 im Spezialfall der Gleichverteilung $p_i = P(X = x_i) = \frac{1}{k}$ das *geometrische Mittel* der Daten $(x_1, \ldots, x_k)$ ist, siehe Definition 3.1.22.

Beweis: Wir verwenden die TAYLOR-Approximation der Exponentialfunktion sowie die Restgliedabschätzung:

$$\exp(r \cdot x) = 1 + r \cdot x + o(r).$$

Hierbei ist $g(r) = o(r)$, wenn $\lim_{r\to 0} \frac{g(r)}{r} = 0$. Es gilt

$$\begin{aligned}
\ln(s_r) &= \frac{1}{r} \ln\Big(\sum_{i=1}^k p_i \exp(r \ln(x_i))\Big) \\
&= \frac{1}{r} \ln\Big(\sum_{i=1}^k p_i (1 + r \ln(x_i) + o(r))\Big) \\
&= \frac{1}{r} \ln\Big(1 + r \sum_{i=1}^k p_i \ln(x_i) + o(r)\Big).
\end{aligned}$$

Also konvergiert $\ln(s_r)$ gegen $\sum_{i=1}^k p_i \ln(x_i)$ für $r \to 0$. □

11.1.20 Satz: Die Abbildung $r \mapsto s_r$ von $\mathbb{R}$ nach $\mathbb{R}^+$ ist monoton wachsend.

Bevor wir den Satz beweisen folgern wir:

11.1.21 Korollar: (Allgemeine AGM-Ungleichung) Es gilt insbesondere

$$s_{-1} \le s_0 \le s_1.$$

Dies ist eine allgemeine Form der AGM-Ungleichung, siehe 3.1.27:

$$s_{-1} = (m_{-1})^{-1} = \left(\sum_{i=1}^k \frac{p_i}{x_i}\right)^{-1}.$$

Dies ist das *harmonische Mittel* zu den Gewichten p_i. Für $p_i = \frac{1}{k}$ falls $i = 1, \ldots, k$ ist es das harmonische Mittel aus Kapitel 3, siehe Definition 3.1.24. Weiter ist

$$s_0 = \prod_{i=1}^k x_i^{p_i}$$

das *geometrische Mittel* zu den Gewichten p_i und

$$s_1 = \sum_{i=1}^{k} p_i\, x_i,$$

das *arithmetische Mittel* zu den Gewichten p_i.

Beweis: Die Funktion $r \mapsto \ln(m_r)$ ist konvex, denn sie ist stetig und mithilfe der Cauchy-Schwarz-Ungleichung (siehe Satz 4.2.7) gilt für $u, v \in \mathbb{R}$:

$$\sum_{i=1}^{k} p_i x_i^{(u+v)/2} \leq \left(\sum_{i=1}^{k} p_i x_i^u\right)^{1/2} \left(\sum_{i=1}^{k} p_i x_i^v\right)^{1/2},$$

also $m_{(u+v)/2} \leq (m_u\, m_v)^{1/2}$ und somit $\ln(m_{(u+v)/2}) \leq \frac{1}{2}\Big(\ln(m_u) + \ln(m_v)\Big)$. Der Graph der Funktion $r \mapsto \ln(m_r)$ geht durch den Nullpunkt, da $m_0 = 1$. Für $r \neq 0$ ist

$$\ln(s_r) = \frac{1}{r}\ln(m_r) = \frac{1}{r}(\ln(m_r) - \ln(m_0)),$$

also ist $\ln(s_r)$ die Steigung der Geraden, die den Nullpunkt mit dem Punkt $(r, \ln(m_r))$ verbindet. Der Konvexität von $r \mapsto \ln(m_r)$ wegen ist damit $\ln(s_r)$ monoton wachsend für $r \neq 0$. Damit ist auch $r \mapsto s_r$ monoton wachsend für $r \neq 0$. Durch s_0 wird s_r stetig im Nullpunkt fortgesetzt. Dies beweist die Aussage des Satzes. □

Der Median einer Stichprobe wurde in 3.1.3 definiert. Wir führen zum Abschluss dieses Teilkapitels den Median einer Zufallsgröße ein.

11.1.22 Definition: Es sei X eine Zufallsvariable auf einem W.-Raum $(\Omega, \mathcal{A}, P)$. Als *Median* von X bezeichnet man jede Zahl M mit

$$P(X \leq M) \geq \frac{1}{2} \quad \text{und} \quad P(X \geq M) \geq \frac{1}{2}.$$

11.1.23 Beispiel: (Radioaktiver Zerfall) Die Zerfallszeit eines radioaktiven Teilchens wird gut begründet durch eine exponentialverteilte Zufallsvariable X beschrieben. Es gilt $P(X \geq a) = \exp(-\lambda a)$ für eine Konstante $\lambda > 0$. Der Median von X ist diejenige Zahl μ mit $\exp(-\lambda\mu) = \frac{1}{2}$, also $\mu = \lambda^{-1}\ln(2)$. Man nennt μ Halbwertszeit.

11.1.24 Aufgabe: Geben Sie eine Definition des p-Quantils einer reellwertigen Zufallsgröße an (siehe Definition 3.1.15).

11.2 Varianz und Kovarianz

Die alleinige Kenntnis von Erwartungswerten ist im Allgemeinen wenig nützlich, wenn nicht gleichzeitig bekannt ist, dass die Zufallsgröße mit hoher Wahrscheinlichkeit „nahe“ beim Erwartungswert liegt.

Dazu ein Beispiel: Ist $P(X = 0) = P(X = 1) = 1/2$, so ist $\mathbb{E}(X) = 1/2$, aber X nimmt diesen Wert nie an. Andererseits: Sei X die mittlere Anzahl der Kopfwürfe bei einem Münzwurf-Experiment der Länge 1000, d.h. die Anzahl der Kopfwürfe dividiert durch 1000. Aus Beispiel 11.1.11(b) wissen wir, dass ebenfalls $\mathbb{E}(X) = 1/2$ gilt. Jedermann „ist bekannt“, dass X mit großer Wahrscheinlichkeit nahe bei $1/2$ liegt. Dies ist der Inhalt des Gesetzes der großen Zahlen, das wir in Kapitel 12 diskutieren und beweisen werden. Die Verteilung von X ist hier ziemlich scharf um $\mathbb{E}(X)$ konzentriert. Ohne solche „Massekonzentrationsphänomene“ gäbe es keine Anwendungen der Wahrscheinlichkeitstheorie.

Ein Maß für die Abweichung, die eine Zufallsgröße von ihrem Erwartungswert hat, ist die sogenannte Varianz:

11.2.1 Definition: Es sei X eine Zufallsgröße mit existierendem Erwartungswert $\mathbb{E}X$. Dann heißt

$$\mathbb{V}(X) := \sum_{z \in X(\Omega)} (z - \mathbb{E}X)^2 P(X = z)$$

die *Varianz* von X und $S(X) := +\sqrt{\mathbb{V}(X)}$ die *Standardabweichung* von X, falls die auftretende (möglicherweise unendliche) Reihe konvergiert.

Die Varianz ist stets nichtnegativ, da die Glieder in der obigen Reihe alle größer oder gleich Null sind. Man sagt oft auch, die Varianz sei unendlich, wenn die Reihe divergiert. Wie der Erwartungswert hängt auch die Varianz einer Zufallsgröße X nicht von der speziellen Gestalt des zugrundeliegenden W.-Raums ab, sondern nur von der Verteilung von X.

11.2.2 Aufgabe: Zeigen Sie: Es gilt $\mathbb{V}(X) = 0$ genau dann, wenn $P(X = \mathbb{E}(X)) = 1$ ist.

Wir definieren nun die Varianz für absolutstetige Zufallsgrößen.

11.2.3 Definition: Die Zufallsgröße X auf einem W.-Raum $(\Omega, \mathcal{A}, P)$ habe eine Dichte f und es existiere $\mathbb{E}(X)$. Ist $\mathbb{R} \ni x \mapsto (x - \mathbb{E}(X))^2 f(x)$ Lebesgue-

integrierbar, so ist die *Varianz* von X definiert durch

$$\mathbb{V}(X) := \int_{-\infty}^{\infty} (x - \mathbb{E}X)^2 f(x)\, dx.$$

11.2.4 Beispiel: (empirische Varianz und Trägheitsmoment) Es sei X eine endliche Zufallsgröße (siehe Definition 11.1.4) und $P(X = x_i) = \frac{1}{k}$ für jedes $i = 1, \ldots, k$. Dann ist mit $\mathbb{E}(X) = \bar{x}$

$$\mathbb{V}(X) = \frac{1}{k} \sum_{i=1}^{k} (x_i - \bar{x})^2 = \frac{k-1}{k}\, s_x^2,$$

wobei s_x^2 die empirische Varianz der Daten $(x_1, \ldots, x_k)$ ist, siehe Definition 3.2.5. Der Erwartungswert konnte als Schwerpunkt der Massepunkte $x_1, \ldots, x_k$ interpretiert werden. Es sei nun $x_i \in X(\Omega)$ mit Masse $P(X = x_i)$. Nun drehen wir die reelle Achse mit einer konstanten Winkelgeschwindigkeit μ um den Schwerpunkt $\mathbb{E}(X)$. Dann sind die Größen $\mu_i = |x_i - \mathbb{E}(X)| \cdot \mu$ die Rotationsgeschwindigkeiten der Massepunkte und $\frac{1}{2} P(X = x_i)\mu_i^2$ sind die Rotationsenergien der Massepunkte. Die gesamte Rotationsenergie ist dann gegeben durch

$$E = \frac{1}{2}\mu^2 \sum_{i=1}^{k} (x_i - \mathbb{E}X)^2 P(X = x_i) = \frac{1}{2}\mu^2 \mathbb{V}(X).$$

Somit ist die Varianz in der Sprache der Physik das *Trägheitsmoment* des Systems von Massepunkten bezüglich der Rotationsachse um den Schwerpunkt.

Für die Diskussion der Varianz und auch in anderen Zusammenhängen ist die nachstehende Folgerung aus Lemma 11.1.6 nützlich:

11.2.5 Lemma: Es seien X eine diskrete Zufallsgröße, definiert auf einem diskreten W.-Raum (Ω, p), und g eine Abbildung von $X(\Omega)$ nach $\mathbb{R}$. Dann ist $g(X)$ eine Zufallsgröße, deren Erwartungswert genau dann existiert, wenn

$$\sum_{z \in X(\Omega)} |g(z)|\, P(X = z) < \infty\ .$$

In diesem Fall gilt

$$\mathbb{E}(g(X)) = \sum_{z \in X(\Omega)} g(z)\, P(X = z).$$

Beweis: Nach Lemma 11.1.6 existiert $\mathbb{E}(g(X))$ genau dann, wenn gilt

$$\sum_{\omega \in \Omega} |g(X(\omega))| p(\omega) < \infty.$$

Nun spalten wir dies nach den Werten von X auf:

$$\begin{aligned}\sum_{\omega\in\Omega} |g(X(\omega))|\, p(\omega) &= \sum_{z\in X(\Omega)} \sum_{\omega: X(\omega)=z} |g(X(\omega))|\, p(\omega) \\ &= \sum_{z\in X(\Omega)} |g(z)| \sum_{\omega: X(\omega)=z} p(\omega) = \sum_{z\in X(\Omega)} |g(z)|\, P(X=z).\end{aligned}$$

Im Falle der Konvergenz dieser Reihe folgt die Behauptung mit derselben Rechnung ohne Absolutbetragszeichen. □

Wir tragen wichtige Eigenschaften der Varianz zusammen:

11.2.6 Lemma:

(i) $\mathbb{V}(X)$ ist der Erwartungswert der Zufallsgröße $\omega \mapsto \Big(X(\omega) - \mathbb{E}X\Big)^2$.

(ii) $\mathbb{V}(X)$ existiert genau dann, wenn $\mathbb{E}(X^2)$ existiert.

(iii) Existiert $\mathbb{V}(X)$, so gilt $\mathbb{V}(X) = \mathbb{E}(X^2) - (\mathbb{E}X)^2$.

(iv) Für $a, b \in \mathbb{R}$ gilt $\mathbb{V}(a + bX) = b^2\mathbb{V}(X)$.

(v) Sind X und Y Zufallsgrößen, deren Varianzen existieren, so existiert die Varianz von $X + Y$.

Beweis:

(i) folgt aus Lemma 11.2.5 mit $g(x) = (x - \mathbb{E}X)^2$.

(ii) Falls $\mathbb{V}(X)$ existiert, so existiert $\mathbb{E}X$ (per Definition). Wegen $z^2 \le 2(\mathbb{E}X)^2 + 2(z - \mathbb{E}X)^2$ für $z \in \mathbb{R}$ folgt

$$\begin{aligned}\sum_{z\in X(\Omega)} z^2 P(X=z) &\le 2(\mathbb{E}X)^2 + 2\sum_{z\in X(\Omega)} (z-\mathbb{E}X)^2 P(X=z) \\ &= 2\Big(\mathbb{E}X\Big)^2 + 2\mathbb{V}(X) < \infty.\end{aligned}$$

Nach Lemma 11.2.5 existiert dann $\mathbb{E}(X^2)$.
Falls $\mathbb{E}(X^2)$ existiert, so folgt

$$\begin{aligned}\sum_{z\in X(\Omega)} |z| P(X=z) &= \sum_{z\in X(\Omega), |z|\le 1} |z| P(X=z) + \sum_{z\in X(\Omega), |z|>1} |z| P(X=z) \\ &\le 1 + \sum_{z\in X(\Omega)} z^2 P(X=z) < \infty.\end{aligned}$$

Somit existiert $\mathbb{E}X$. Wegen $(z - \mathbb{E}X)^2 \le 2(\mathbb{E}X)^2 + 2z^2$ folgt die Existenz von $\mathbb{V}(X)$ wie oben.

(iii) Es gilt nach (i)

$$\begin{aligned}\mathbb{V}(X) &= \mathbb{E}((X-\mathbb{E}X)^2) = \mathbb{E}\Big(X^2 - 2(\mathbb{E}X)X + (\mathbb{E}X)^2\Big) \\ &= \mathbb{E}(X^2) - 2\mathbb{E}X\cdot\mathbb{E}X + (\mathbb{E}X)^2 = \mathbb{E}(X^2) - (\mathbb{E}X)^2.\end{aligned}$$

Dabei haben wir in der dritten Gleichung die Linearität des Erwartungswertes benutzt.

(iv) folgt sofort aus (iii) und der Linearität des Erwartungswertes.

(v) Es gilt $(X(\omega)+Y(\omega))^2 \le 2X(\omega)^2 + 2Y(\omega)^2$ für alle $\omega \in \Omega$. Nach (ii) folgt dann die Existenz von $\mathbb{V}(X+Y)$.

□

11.2.7 Satz: Es sei X eine diskrete Zufallsgröße mit $\mathbb{E}(X^2) < \infty$. Dann gilt für jede reelle Zahl $a \in \mathbb{R}$:

$$\mathbb{E}\Big((X-a)^2\Big) \ge \mathbb{V}(X).$$

Im Spezialfall von endlich vielen Daten hatten wir diesen Satz bereits kennengelernt, siehe die *Verschiebungsformel* in Satz 3.2.7.

Beweis: Für $g(a) := \mathbb{E}\Big((X-a)^2\Big)$ und $\mu := \mathbb{E}(X)$ gilt

$$\begin{aligned}g(a) &= \mathbb{E}\left(\Big((X-\mu)+(\mu-a)\Big)^2\right) \\ &= \mathbb{E}\Big((X-\mu)^2\Big) + 2(\mu-a)\mathbb{E}(X-\mu) + (\mu-a)^2 \\ &= \mathbb{V}(X) + (\mu-a)^2.\end{aligned}$$

□

11.2.8 Aufgabe: Der Ausdruck m_r in (11.1) ist $\mathbb{E}(X^r)$ für die diskrete Zufallsgröße X mit $X(\Omega) = \{x_1, \ldots, x_k\}$, wobei die Werte x_i positiv seien. Zeigen Sie mithilfe von Satz 11.1.20

(a) $\mathbb{E}(|X|) \le \sqrt{\mathbb{E}(X^2)}$.

(b) $\mathbb{E}(|X-\mathbb{E}(X)|) \le \sqrt{\mathbb{E}((X-\mathbb{E}X)^2)}$.

(c) $m_{2n+1} \le (m_{2n}\, m_{2n+2})^{1/2}$. Jedes Moment ungerader Ordnung kann also hier durch Momente gerader Ordnung majorisiert werden.

11.2.9 Beispiele: (a) Es sei 1_A die Indikatorfunktion eines Ereignisses $A \subseteq \Omega$. Dann ist $\mathbb{E}(1_A) = P(A)$ und

$$\mathbb{V}(1_A) = \Big(1 - P(A)\Big)^2 P(A) + \Big(0 - P(A)\Big)^2 \Big(1 - P(A)\Big) = P(A)\Big(1 - P(A)\Big).$$

Viele interessante Zufallsgrößen sind Summen von Indikatoren. Die Berechnung der Varianz einer Summe betrachten wir etwas später.

(b) Wir berechnen die Varianz einer geometrisch verteilten Zufallsgröße X und verwenden dazu denselben Trick wie bei der Berechnung des Erwartungswertes. Sei also $f(s) := \sum_{k=1}^{\infty} s^k = s/(1-s)$ für alle $|s| < 1$. Dann gilt

$$f''(s) = \sum_{k=1}^{\infty} k(k-1)s^{k-2} = \frac{2}{(1-s)^3}, \quad |s| < 1.$$

Es ist $\mathbb{E}(X^2) = \mathbb{E}(X + X(X-1)) = \mathbb{E}(X) + \mathbb{E}(X(X-1))$, und mit Lemma 11.2.5 und der obigen Formel mit $s = 1 - p$ folgt

$$\mathbb{E}(X(X-1)) = \sum_{k=1}^{\infty} k(k-1)p(1-p)^{k-1} = p(1-p)\sum_{k=1}^{\infty} k(k-1)(1-p)^{k-2} = 2\frac{1-p}{p^2},$$

also $\mathbb{E}(X^2) = 1/p + 2(1-p)/p^2 = (2-p)/p^2$, wobei wir $\mathbb{E}(X) = 1/p$ gemäß Beispiel 11.1.11(d) verwendet haben. Aus $\mathbb{V}(X) = \mathbb{E}(X^2) - (\mathbb{E}X)^2$ nach Lemma 11.2.6(iii) folgt

$$\mathbb{V}(X) = \frac{(1-p)}{p^2}.$$

Im Allgemeinen gilt $\mathbb{V}(X+Y) \neq \mathbb{V}(X) + \mathbb{V}(Y)$. Eine einfache Rechnung ergibt nämlich

$$\begin{aligned}
\mathbb{V}(X+Y) &= \mathbb{E}\Big(((X+Y) - \mathbb{E}(X+Y))^2\Big) = \mathbb{E}\Big(((X - \mathbb{E}X) + (Y - \mathbb{E}Y))^2\Big) \\
&= \mathbb{E}\Big((X - \mathbb{E}X)^2\Big) + \mathbb{E}\Big((Y - \mathbb{E}Y)^2\Big) + 2\mathbb{E}\Big((X - \mathbb{E}X)(Y - \mathbb{E}Y)\Big) \\
&= \mathbb{V}(X) + \mathbb{V}(Y) + 2\mathbb{E}\Big((X - \mathbb{E}X)(Y - \mathbb{E}Y)\Big), \qquad (11.2)
\end{aligned}$$

und der letzte Summand ist in vielen Fällen ungleich Null, z.B. für $X = Y$ mit $\mathbb{V}(X) \neq 0$. Dennoch ist der Fall, in dem für zwei Zufallsgrößen X und Y die Gleichung $\mathbb{V}(X+Y) = \mathbb{V}(X) + \mathbb{V}(Y)$ gilt, von besonderem Interesse. Wir werden dies weiter unten diskutieren.

11.2.10 Definition: Sind X und Y zwei Zufallsgrößen, so wird die *Kovarianz* zwischen X und Y definiert durch $\operatorname{cov}(X,Y) := \mathbb{E}((X - \mathbb{E}X)(Y - \mathbb{E}Y))$, falls alle in diesem Ausdruck vorkommenden Erwartungswerte existieren.

11.2.11 Aufgabe: Bestimmen Sie die Kovarianz, wenn X und Y endliche Zufallsgrößen sind mit jeweils k verschiedenen Werten, die alle mit der Wahrscheinlichkeit $1/k$ auftreten. Vergleichen Sie das Resultat mit Definition 4.2.1.

11.2.12 Bemerkung: Eine analoge Überlegung wie im Beweis von Lemma 11.2.6 zeigt, dass $\operatorname{cov}(X,Y)$ genau dann existiert, wenn $\mathbb{E}(X)$, $\mathbb{E}(Y)$ und $\mathbb{E}(XY)$ existieren. In diesem Fall gilt

$$\operatorname{cov}(X,Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y).$$

11.2.13 Aufgabe: Zeigen Sie die Aussage dieser Bemerkung.

11.2.14 Lemma: Es seien X und Y Zufallsgrößen, für die $\operatorname{cov}(X,Y)$ existiert. Dann gelten $\operatorname{cov}(X,Y) = \operatorname{cov}(Y,X)$ und $\operatorname{cov}(\lambda X, \mu Y) = \lambda\mu \operatorname{cov}(X,Y)$ für alle $\lambda, \mu \in \mathbb{R}$. Sind weiter X, X' und Y Zufallsgrößen, für die $\operatorname{cov}(X,Y)$ und $\operatorname{cov}(X',Y)$ existieren, so existiert auch $\operatorname{cov}(X+X',Y)$ und es gilt $\operatorname{cov}(X+X',Y) = \operatorname{cov}(X,Y) + \operatorname{cov}(X',Y)$.

11.2.15 Aufgabe: Beweisen Sie die Aussagen des Lemmas.

Gleichung (11.2) kann wie folgt verallgemeinert werden:

11.2.16 Satz: Es seien $X_1, \ldots, X_n$ diskrete Zufallsgrößen mit existierenden Varianzen und Kovarianzen. Dann gilt

$$\begin{aligned}
\mathbb{V}\left(\sum_{i=1}^n X_i\right) &= \sum_{i=1}^n \mathbb{V}(X_i) + \sum_{i,j=1, i\neq j}^n \operatorname{cov}(X_i, X_j) \\
&= \sum_{i=1}^n \mathbb{V}(X_i) + 2 \sum_{1\leq i<j\leq n} \operatorname{cov}(X_i, X_j).
\end{aligned}$$

Beweis: Es gilt

$$\begin{aligned}
\mathbb{V}\left(\sum_{i=1}^n X_i\right) &= \mathbb{E}\left(\sum_{i=1}^n X_i - \mathbb{E}\left(\sum_{i=1}^n X_i\right)\right)^2 = \mathbb{E}\left(\sum_{i=1}^n (X_i - \mathbb{E}X_i)\right)^2 \\
&= \sum_{i,j=1}^n \mathbb{E}\Big((X_i - \mathbb{E}X_i)(X_j - \mathbb{E}X_j)\Big) \\
&= \sum_{i=1}^n \mathbb{V}(X_i) + \sum_{i,j=1, i\neq j}^n \operatorname{cov}(X_i, X_j).
\end{aligned}$$

Um Klammern einzusparen, verstehen wir unter $\mathbb{E}Y^2$ immer $\mathbb{E}(Y^2)$. Die zweite Gleichung folgt mit $\operatorname{cov}(X_i, X_j) = \operatorname{cov}(X_j, X_i)$. □

11.2.17 Beispiel: (Indikator-Summen) In einem diskreten W.-Raum seien die Ereignisse $A_1, \ldots, A_n$ gegeben. Wir betrachten die Zufallsgröße

$$X := \sum_{i=1}^{n} 1_{A_i}$$

und wollen $\mathbb{V}(X)$ mithilfe des Satzes 11.2.16 bestimmen. Wir haben bereits $\mathbb{V}(1_{A_i}) = P(A_i)(1 - P(A_i))$ gesehen. Nun müssen wir noch $\operatorname{cov}(1_{A_i}, 1_{A_j})$ bestimmen. Wir verwenden nun $1_{A_i} 1_{A_j} = 1_{A_i \cap A_j}$ und erhalten mithilfe der Bemerkung 11.2.12

$$\operatorname{cov}(1_{A_i}, 1_{A_j}) = \mathbb{E}(1_{A_i \cap A_j}) - \mathbb{E}(1_{A_i})\mathbb{E}(1_{A_j}) = P(A_i \cap A_j) - P(A_i)P(A_j).$$

Also folgt mit Satz 11.2.16

$$\mathbb{V}(X) = \sum_{i=1}^{n} P(A_i)(1 - P(A_i)) + 2 \sum_{1 \le i < j \le n} \Big(P(A_i \cap A_j) - P(A_i)P(A_j) \Big). \tag{11.3}$$

Diese Formel vereinfacht sich, wenn zusätzlich gegeben ist, dass alle n Ereignisse $A_1, \ldots, A_n$ gleichwahrscheinlich sind und die Wahrscheinlichkeiten $P(A_i \cap A_j)$ von i und j unabhängig sind. Dann gilt

$$\mathbb{V}(X) = n\, P(A_1)(1 - P(A_1)) + n(n-1)\Big(P(A_1 \cap A_2) - P(A_1)^2 \Big). \tag{11.4}$$

Für austauschbare Ereignisse $A_1, \ldots, A_n$ kann man daher (11.4) anwenden, siehe Kapitel 6, Seite 166.

Das letzte Beispiel legt die Grundlage zur einfachen Ermittlung der Varianz für uns bekannte Verteilungen:

11.2.18 Beispiele: (a) Es sei X binomialverteilt. Dann verwenden wir die gewohnte Darstellung $X = X_1 + \cdots + X_n$, siehe Beispiel 11.1.11(b). Wenn A_i das Ereignis bezeichnet, dass beim i-ten Experiment Erfolg eintritt, also $X_i = 1_{A_i}$ so ist $P(A_i) = p$ und $P(A_i \cap A_j) = p^2$, denn die Ereignisse A_i und A_j sind unabhängig. Also können wir (11.4) anwenden und erhalten

$$\mathbb{V}(X) = np(1-p).$$

(b) Es sei X hypergeometrisch verteilt zu den Parametern n, r und s. Dann ist bei gleicher Darstellung von X wie in (a) und gleicher Wahl des Ereignisses A_i mit Wahrscheinlichkeit $P(A_i) = \frac{r}{r+s}$ und für $i \neq j$

$$P(A_i \cap A_j) = \frac{r \cdot (r-1)}{(r+s) \cdot (r+s-1)}$$

(siehe Beispiel 9.3.2 und 11.1.11(c)). Erneut können wir also (11.4) anwenden und erhalten

$$\begin{aligned}\mathbb{V}(X) &= n \cdot \frac{r \cdot s}{(r+s)^2} + n(n-1) \cdot \frac{r}{r+s} \cdot \left(\frac{r-1}{r+s-1} - \frac{r}{r+s} \right) \\ &= n \cdot \frac{r}{r+s} \left(1 - \frac{r}{r+s} \right) \cdot \left(1 - \frac{n-1}{r+s-1} \right).\end{aligned}$$

(c) Für die Anzahl X der Fixpunkte einer zufälligen Permutation der Zahlen $1, \ldots, n$ sei A_i das Ereignis, dass die Zahl i durch Permutation am i-ten Platz landet. Dann setzen wir $X_i = 1_{A_i}$ und erhalten $P(A_i) = 1/n$, siehe Beispiel 11.1.14. Weiter ist $P(A_i \cap A_j) = \frac{1}{n(n-1)}$. Damit folgt mit (11.4)

$$\mathbb{V}(X) = n \frac{1}{n} \left(1 - \frac{1}{n} \right) + n(n-1) \left(\frac{1}{n(n-1)} - \frac{1}{n^2} \right) = 1.$$

Erwartungswert und Varianz von X stimmen in diesem Beispiel also überein und sind unabhängig von n.

11.2.19 Aufgabe: Vergleichen Sie die Varianz einer binomialverteilten und einer hypergeometrisch verteilten Zufallsgröße.

11.2.20 Aufgabe: Berechnen Sie die Varianz einer Polyá-verteilten Zufallsgröße.

11.2.21 Definition: Die Zufallsgrößen X und Y heißen *unkorreliert*, wenn die Größe $\operatorname{cov}(X, Y)$ existiert und gleich Null ist.

Es folgt nun mit Satz 11.2.16 eine Identität von Irénée-Jules Bienaymé (1796–1878):

11.2.22 Satz: (Gleichheit nach Bienaymé) Sind die diskreten Zufallsgrößen $X_1, \ldots, X_n$ paarweise unkorreliert und existieren die Varianzen, so gilt

$$\mathbb{V}\left(\sum_{i=1}^{n} X_i \right) = \sum_{i=1}^{n} \mathbb{V}(X_i).$$

Die für uns zunächst wichtigste Klasse von unkorrelierten Zufallsgrößen sind unabhängige:

11.2.23 Satz: Zwei unabhängige Zufallsgrößen, deren Erwartungswerte existieren, sind unkorreliert.

Beweis: Es seien X und Y unabhängig. Der Erwartungswert von XY existiert nach Lemma 11.1.6 genau dann, wenn

$$\sum_{\omega\in\Omega} |X(\omega)Y(\omega)|p(\omega) < \infty.$$

Nun gilt

$$\begin{aligned}
\sum_{\omega\in\Omega} |X(\omega)Y(\omega)|p(\omega) &= \sum_{x\in X(\Omega)} \sum_{y\in Y(\Omega)} |xy| \sum_{\omega: X(\omega)=x, Y(\omega)=y} p(\omega) \\
&= \sum_{x\in X(\Omega)} \sum_{y\in Y(\Omega)} |xy| P(X=x,\, Y=y) \\
&= \sum_{x\in X(\Omega)} \sum_{y\in Y(\Omega)} |x|\,|y| P(X=x)P(Y=y) \\
&= \left(\sum_{x\in X(\Omega)} |x| P(X=x)\right)\left(\sum_{y\in Y(\Omega)} |y| P(Y=y)\right) < \infty.
\end{aligned}$$

Daraus folgt die Existenz von $\mathbb{E}(XY)$. Eine Wiederholung der obigen Rechnung ohne Absolutbetragszeichen ergibt $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$. Nach Bemerkung 11.2.12 folgt daraus die Unkorreliertheit von X und Y. □

11.2.24 Bemerkung: Derselbe Beweis ergibt für n Zufallsgrößen $X_1, \ldots, X_n$, die unabhängig sind und deren Erwartungswerte existieren, dass der Erwartungswert von $\prod_{i=1}^n X_i$ existiert und gleich $\prod_{i=1}^n \mathbb{E}X_i$ ist.

11.2.25 Beispiele: (a) Wir betrachten erneut ein Bernoulli-Experiment mit Parametern n, p und setzen $X_i = 1$, falls der i-te Versuch ein Erfolg ist, und $X_i = 0$ sonst ($1 \le i \le n$). Die Unabhängigkeit von $X_1, \ldots, X_n$ folgt aus der Definition. Damit sind sie paarweise unkorreliert. Nach Satz 11.2.22 folgt für die Anzahl $X = \sum_{i=1}^n X_i$ der Erfolge

$$\mathbb{V}(X) = \sum_{i=1}^n \mathbb{V}(X_i) = np(1-p).$$

(b) Um an einem Beispiel zu zeigen, dass die Umkehrung von Satz 11.2.23 nicht gilt, wählen wir $\Omega = \{-1, 0, 1\}$ mit der Gleichverteilung und definieren die Zufallsgröße X durch $X(\omega) = \omega$ für alle $\omega \in \Omega$. Dann gelten $\mathbb{E}(X) = 0$,

$\mathbb{E}(|X|) = 2/3$ und $\mathbb{E}(X|X|) = 0$, also sind X und $|X|$ unkorreliert. Offensichtlich sind X und $|X|$ aber abhängig, denn zum Beispiel ist $\{X = 1, |X| = 0\}$ das unmögliche Ereignis, aber $P(X = 1)P(|X| = 0) = 1/9$.

Wir berechnen abschließend noch die Varianz absolutstetiger Zufallsgrößen:

11.2.26 Beispiele: (a) Es sei X standard-normalverteilt. Dann ist

$$\mathbb{V}(X) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} x^2 e^{-x^2/2}\, dx = \lim_{N\to\infty} \frac{1}{\sqrt{2\pi}} \int_{-N}^{N} x(xe^{-x^2/2})\, dx,$$

und mittels partieller Integration folgt

$$\mathbb{V}(X) = \lim_{N\to\infty} \frac{1}{\sqrt{2\pi}} (-xe^{-x^2/2})\Big|_{-N}^{N} + \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-x^2/2}\, dx = 0 + 1 = 1.$$

(b) Es sei X normalverteilt mit den Parametern $\mu \in \mathbb{R}$ und $\sigma > 0$. Mit der Transformation $y := (x - \mu)/\sigma$ folgt unter Verwendung von Beispiel (a)

$$\mathbb{V}(X) = \int_{-\infty}^{\infty} (x-\mu)^2 \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/2\sigma^2} dx = \frac{\sigma^2}{\sqrt{2\pi}} \int_{-\infty}^{\infty} y^2 e^{-y^2/2}\, dy = \sigma^2.$$

Eine Zufallsgröße X ist genau dann normalverteilt mit Erwartungswert μ und Varianz σ^2, wenn $(X - \mu)/\sigma$ standard-normalverteilt ist. Etwas allgemeiner: Ist X normalverteilt mit Erwartungswert μ und Varianz σ^2 und sind $a, b \in \mathbb{R}$, $a \neq 0$, so ist $aX + b$ normalverteilt mit Erwartungswert $a\mu + b$ und Varianz $a^2\sigma^2$. Dies ergibt sich im Fall $a > 0$ aus der Tatsache, dass sowohl $P(X \leq t) = P(aX + b \leq at + b)$ als auch (mittels der Transformation $y = ax + b$)

$$\int_{-\infty}^{t} \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/2\sigma^2}\, dx = \int_{-\infty}^{at+b} \frac{1}{\sqrt{2\pi}a\sigma} e^{-(y-a\mu-b)^2/2a^2\sigma^2}\, dy$$

für alle $t \in \mathbb{R}$ gelten, also $\varphi(\,\cdot\,; a\mu + b,\, a^2\sigma^2)$ eine Dichte von $aX + b$ ist.

(c) Es sei X exponentialverteilt mit Parameter $\lambda > 0$. Ausmultiplizieren von $(x - 1/\lambda)^2$, Verwenden von $\mathbb{E}(X) = 1/\lambda$ und einmalige partielle Integration liefern

$$\mathbb{V}(X) = \int_0^{\infty} \left(x - \frac{1}{\lambda}\right)^2 \lambda e^{-\lambda x}\, dx = \int_0^{\infty} \lambda x^2 e^{-\lambda x}\, dx - \frac{2}{\lambda}\mathbb{E}(X) + \frac{1}{\lambda^2} = \frac{1}{\lambda^2}.$$

11.3 Regression und Korrelation

Einige der Kennzahlen der ersten Kurseinheit haben wir als Kennzahlen speziell gewählter Zufallsgrößen wiederentdeckt.

Den Korrelationskoeffizienten zweier Zufallsgrößen werden wir nun entdecken, indem wir die lineare Regression aus Kapitel 4 in der Sprache der Zufallsgrößen betrachten. Die Daten sind nun Realisierungen zweier Zufallsgrößen X und Y. Wir untersuchen, ob ein linearer Zusammenhang vorliegt. Dazu minimieren wir die mittlere quadratische Abweichung

$$\mathbb{E}(Y - b - aX)^2.$$

Wir setzen voraus, dass $\mathbb{V}(X)$ und $\mathbb{V}(Y)$ existieren und endlich sind. Es gilt:

11.3.1 Satz: Es seien X und Y definiert auf einem diskreten W.-Raum (Ω, p) mit $\mathbb{V}(X) < \infty$ und $\mathbb{V}(Y) < \infty$. Dann existiert $\operatorname{cov}(X, Y)$. Der Ausdruck $\mathbb{E}(Y-b-aX)^2$ wird minimiert für

$$\tilde{a} = \frac{\operatorname{cov}(X, Y)}{\mathbb{V}(X)}, \quad \tilde{b} = \mathbb{E}(Y) - \tilde{a}\mathbb{E}(X).$$

Der Minimalwert m in $\mathbb{E}(Y - b - aX)^2$ ergibt sich zu

$$m = \mathbb{V}(Y)\left(1 - \frac{\operatorname{cov}(X, Y)^2}{\mathbb{V}(X) \cdot \mathbb{V}(Y)}\right).$$

Vergleichen Sie die Aussage dieses Satzes mit der empirischen linearen Regression, Satz 4.1.1.

Beweis: Für alle $\omega \in \Omega$ gilt $2|X(\omega)Y(\omega)| \leq X^2(\omega) + Y^2(\omega)$. Daraus und aus Lemma 11.2.6(ii) folgt die Existenz von $\mathbb{E}(XY)$ und nach der Bemerkung 11.2.12 auch die von $\operatorname{cov}(X, Y)$.

Wir setzen $Z := Y - aX$. Dann gilt nach Satz 11.2.7

$$\mathbb{E}(Y - b - aX)^2 = \mathbb{E}(Z - b)^2 \geq \mathbb{V}(Z).$$

Wir erhalten Gleichheit bei der Wahl $b = \mathbb{E}(Z) = \mathbb{E}(Y) - a\mathbb{E}(X)$. Das setzen wir ein und erhalten

$$f(a) := \mathbb{E}(Y - \mathbb{E}(Y) + a\mathbb{E}(X) - aX)^2 = \mathbb{E}\Big((Y - \mathbb{E}(Y)) - a(X - \mathbb{E}(X))\Big)^2.$$

Diese Funktion in a wollen wir nun minimieren. Mit $\bar{X} := X - \mathbb{E}(X)$ und $\bar{Y} := Y - \mathbb{E}(Y)$ erhalten wir

$$0 \leq f(a) \quad = \quad \mathbb{E}(\bar{Y}^2) - 2\,a\,\mathbb{E}(\bar{X}\,\bar{Y}) + a^2\,\mathbb{E}(\bar{X}^2)$$

$$= \quad \mathbb{V}(Y) - 2\,a\,\operatorname{cov}(X,Y) + a^2\,\mathbb{V}(X).$$

Damit ist $f(\cdot)$ eine nichtnegative Parabel, die bei $\tilde{a} = \frac{\operatorname{cov}(X,Y)}{\mathbb{V}(X)}$ ihren nichtnegativen Minimalwert m annimmt. Nun müssen wir m noch bestimmen:

$$\begin{aligned} f(\tilde{a}) = m &= \mathbb{V}(Y) - 2\,\frac{\operatorname{cov}(X,Y)^2}{\mathbb{V}(X)} + \frac{\operatorname{cov}(X,Y)^2}{\mathbb{V}(X)} \\ &= \mathbb{V}(Y)\left(1 - \frac{\operatorname{cov}(X,Y)^2}{\mathbb{V}(X)\cdot\mathbb{V}(Y)}\right). \end{aligned}$$

□

11.3.2 Definition: Es seien X und Y definiert auf einem diskreten W.-Raum (Ω, p) mit $\mathbb{V}(X) < \infty$ und $\mathbb{V}(Y) < \infty$. Wir nennen

$$r(X,Y) := \frac{\operatorname{cov}(X,Y)}{\sqrt{\mathbb{V}(X)\,\mathbb{V}(Y)}}$$

den *Korrelationskoeffizienten* von X und Y, benannt nach Pearson.

11.3.3 Satz: In der Situation von Satz 11.3.1 gilt

(1) $|\operatorname{cov}(X,Y)| \leq S(X)S(Y)$ mit $S(X) := +\sqrt{\mathbb{V}(X)}$.

(2) $|r(X,Y)| \leq 1$.

(3) Der Fall $|r(X,Y)| = 1$ tritt genau dann ein, wenn es reelle Zahlen a, b mit $P(Y = aX + b) = 1$ gibt. Aus $r(X,Y) = 1$ folgt $\tilde{a} > 0$, aus $r(X,Y) = -1$ folgt $\tilde{a} < 0$.

Beweis: Die ersten beiden Aussagen folgen, weil der Minimalwert in Satz 11.3.1 nichtnegativ ist (siehe Beweis). Für $|r(X,Y)| = 1$ folgt $m = 0$, also $\mathbb{E}(Y - aX - b)^2 = 0$, also $P(Y = aX + b) = 1$ für geeignete Werte von a und b. Gilt umgekehrt $P(Y = aX + b) = 1$, so folgt $\mathbb{E}(Y - aX - b)^2 = 0$ und $m = 0$. Weiter haben $\tilde{a}$ und $r(X,Y)$ das gleiche Vorzeichen. Damit ist der Satz bewiesen. □

11.3.4 Bemerkung: Der Vollständigkeit halber sei auf den folgenden Sachverhalt hingewiesen: Die Existenz von $\operatorname{cov}(X,Y)$ setzt nach Bemerkung 11.2.12 die Existenz von $\mathbb{E}X$, $\mathbb{E}Y$ und $\mathbb{E}(XY)$ voraus und folgt nach dem obigen Satz aus der Existenz von $\mathbb{V}(X)$ und $\mathbb{V}(Y)$. Letzteres ist jedoch dafür nicht notwendig: Es gibt Zufallsgrößen mit existierender Kovarianz, deren Varianzen nicht existieren.

11.3.5 Aufgabe: Es seien X und Y endlich im Sinne der Definition 11.1.4 und $P(X = x_i) = P(Y = y_i) = 1/k$ für $i = 1, \ldots, k$. Bestimmen Sie $r(X, Y)$ und vergleichen Sie dies mit der Definition 4.2.3.

Lösungen der Aufgaben

Lösungen der Aufgaben in 11.1

Aufgabe 11.1.9

Wir beschränken uns auf diskrete Zufallsvariablen. Nach Definition existiert $\mathbb{E}(|X|)$ genau dann, wenn gilt:

$$\begin{aligned} +\infty &> \sum_{z\in|X|(\Omega)} |z|P(|X|=z) = \sum_{z\in|X|(\Omega)} zP(|X|=z) \\ &= \sum_{z\in|X|(\Omega)} z(P(X=z)+P(X=-z)) = \sum_{x\in X(\Omega)} |x|P(X=x) \end{aligned}$$

und dies ist nach Definition auch die Bedingung dafür, dass $\mathbb{E}(X)$ existiert. Falls $\mathbb{E}(X)$ endlich ist, so ist der Wert der Reihe unten rechts nach obiger Rechnung auch der Wert von $\mathbb{E}(|X|)$. Der Wert von $\mathbb{E}(X)$ hingegen ist dann gegeben durch $\sum_{x\in X(\Omega)} xP(X=x)$ und dieser ist betragsmäßig höchstens kleiner, denn

$$|\mathbb{E}(X)| = \Big|\sum_{x\in X(\Omega)} xP(X=x)\Big| \leq \sum_{x\in X(\Omega)} |x|P(X=x) = \mathbb{E}(|X|).$$

Aufgabe 11.1.12

Nach Beispiel 9.2.7 gibt es eine zu den Parametern p und r negativ binomialverteilte Zufallsvariable Z, die eine Darstellung der Gestalt

$$Z = Y_1 + \ldots + Y_r - r$$

hat, wobei die Y_i, $i = 1, \ldots, r$, unabhängig und geometrisch verteilt sind zum Parameter p (Mit der Notation dieses Beispiels gilt $Y_i(\omega) - 1 = n_i(\omega)$). Da der Erwartungswert nur von der Verteilung der Zufallsvariable abhängt, gilt $\mathbb{E}(X_r) = \mathbb{E}(Z)$ und dies können wir wegen der Linearität des Erwartungswertes und nach Beispiel 11.1.11(d) wie folgt ausrechnen:

$$\mathbb{E}(Z) = \sum_{j=1}^{r} \mathbb{E}(Y_j) - r = \frac{r}{p} - r = \frac{r(1-p)}{p}.$$

Aufgabe 11.1.15

Wir bezeichnen die Zufallsvariable statt mit X mit X_n, um die n-Abhängigkeit zu betonen: Nach Aufgabe 10.1.21 gilt für den Erwartungswert von X_n, welcher wegen des endlichen Wertebereiches existiert:

$$\begin{aligned}
\mathbb{E}(X_n) &= \sum_{k=0}^{n} k \cdot P(X=k) = \sum_{k=1}^{n} k \cdot P(X=k) \\
&= \sum_{k=1}^{n} k \cdot \frac{1}{k!} \sum_{j=0}^{n-k} \frac{(-1)^j}{j!} = \sum_{k=1}^{n} \frac{1}{(k-1)!} \sum_{j=0}^{n-k} \frac{(-1)^j}{j!} \\
&= \sum_{k=0}^{n-1} \sum_{j=0}^{n-1-k} \frac{(-1)^j}{k!j!} = \sum_{(k,j)\in\Delta_{n-1}} \frac{(-1)^j}{k!j!}\,,
\end{aligned}$$

wobei für $m \in \mathbb{N}$ $\Delta_m := \{(k,j) \in \mathbb{N}^2 \ : \ k+j \leq m\}$ sei. Anhand der vorletzten Darstellung in obiger Rechnung sehen wir mittels der Theorie unendlicher Reihen leicht ein, dass $\lim_{n\to\infty} \mathbb{E}(X_n) = e \cdot e^{-1} = 1$ gilt. Wir wollen zeigen, dass sogar für jedes $n \in \mathbb{N}$ die Gleichheit $\mathbb{E}(X_n) = 1$ gilt. Dies tun wir durch vollständige Induktion nach n. Der Induktionsanfang ist dabei klar, auch ohne obige Rechnung. Für den Induktionsschritt nehmen wir an, dass $\mathbb{E}(X_n) = 1$ gilt und behaupten, dass dann auch $\mathbb{E}(X_{n+1}) = 1$ gelten muss. Nach der obigen Rechnung gilt aber:

$$\begin{aligned}
\mathbb{E}(X_{n+1}) &= \sum_{(k,j)\in\Delta_n} \frac{(-1)^j}{k!j!} \\
&= \sum_{(k,j)\in\Delta_{n-1}} \frac{(-1)^j}{k!j!} + \sum_{k,j:k+j=n} \frac{(-1)^j}{k!j!} \\
&= \mathbb{E}(X_n) + \sum_{j=0}^{n} \frac{(-1)^j}{j!(n-j)!} \overset{\text{IV}}{=} 1 + \frac{1}{n!} \sum_{j=0}^{n} (-1)^j \binom{n}{j}.
\end{aligned}$$

Nun gilt aber nach dem Binomischen Lehrsatz

$$\sum_{j=0}^{n} (-1)^j \binom{n}{j} = (1-1)^n = 0\,,$$

sodass die Induktionsbehauptung bewiesen ist. Somit hat eine zufällig, gleichverteilt gewählte Permutation im Mittel genau einen Fixpunkt. Wir sehen, dass auch in diesem Beispiel die Berechnung des Erwartungswertes über die Verteilung der Zufallsvariable X_n wesentlich aufwendiger ist, als die im Text gegebene Herleitung, welche eine Summenzerlegung von X_n und dann die Linearität des Erwartungswertes verwendet.

Aufgabe 11.1.18

Sei f die stetige Dichte der CAUCHY-Verteilung. Wir überprüfen die Funktion $id_{\mathbb{R}} \cdot f$ auf LEBESGUE-Integrierbarkeit:

$$\begin{aligned}
\int_{-\infty}^{\infty} |x| f(x) dx &= \frac{2c}{\pi} \cdot \int_0^{\infty} \frac{x}{x^2+c^2} dx = \frac{2c}{\pi} \cdot \int_0^{\infty} \frac{1}{c} \frac{\frac{x}{c}}{\frac{x^2}{c^2}+1} dx \\
&= \frac{2c}{\pi} \int_0^{\infty} \frac{t}{t^2+1} dt = \frac{c}{\pi} \ln(t^2+1)\Big|_0^{\infty} \\
&= \frac{c}{\pi}(\infty - 0) = \infty.
\end{aligned}$$

Somit ist die Funktion $id_{\mathbb{R}} \cdot f$ nicht LEBESGUE-integrierbar und daher existiert der Erwartungswert einer CAUCHY-Verteilung nicht.

Aufgabe 11.1.24

Seien $(\Omega, \mathcal{A}, P)$ ein W-Raum und sei $X : \Omega \to \mathbb{R}$ eine reellwertige Zufallsvariable. Für $p \in [0,1]$ heißt eine reelle Zahl z ein p-tes Quantil (der Verteilung) von X, wenn gilt:

$$P(X \geq z) \geq 1 - p \quad \text{und} \quad P(X \leq z) \geq p\,.$$

Lösungen der Aufgaben in 11.2

Aufgabe 11.2.2

Nach Definition ist $\mathbb{V}(X) = \sum_{z \in X(\Omega)} (z - \mathbb{E}(X))^2 P(X = z)$. Falls $P(X = \mathbb{E}(X)) = 1$ gilt, so folgt notwendigerweise $P(X = z) = 0$ für alle $z \in X(\Omega) \setminus \{\mathbb{E}(X)\}$. Daraus liest man $\mathbb{V}(X) = 0$ ab. Gilt umgekehrt $\mathbb{V}(X) = 0$, so gilt für jedes $z \in X(\Omega)$, dass $P(X = z) = 0$ ist, oder dass $(z - \mathbb{E}(X))^2 = 0$ ist, also $z = \mathbb{E}(X)$ ist. Da aber X eine diskrete Zufallsvariable ist, muss es ein $z \in X(\Omega)$ geben, welches mit positiver Wahrscheinlichkeit angenommen wird und wir haben gerade gesehen, dass dafür dann höchstens $z = \mathbb{E}(X)$ in Frage kommt. Daraus folgt: $1 = \sum_{z \in X(\Omega)} P(X = z) = P(X = \mathbb{E}(X))$.

Aufgabe 11.2.8

(a) Dies folgt direkt aus $s_1 \leq s_2$.

(b) folgt aus (a) angewandt auf die Zufallsvariable $Y := X - \mathbb{E}(X)$. Da diese den Wert 0 annehmen kann, ist zwar die Voraussetzung der Positivität nicht erfüllt, jedoch sind die Ausdrücke $|0|^1$ und 0^2 wohldefiniert und daher kann man die Aussage von Satz 11.1.20 auch hier verwenden.

(c) Mithilfe der Cauchy-Schwarz-Ungleichung für das Standard-Skalarprodukt im $\mathbb{R}^k$ berechnen wir:

$$\begin{aligned} m_{2n+1} &= \sum_{i=1}^{k} p_i x_i^{2n+1} = \sum_{i=1}^{k} (\sqrt{p_i} x_i^n) \cdot (\sqrt{p_i} x_i^{n+1}) \\ &\leq \left(\sum_{i=1}^{k} (\sqrt{p_i} x_i^n)^2 \right)^{\frac{1}{2}} \cdot \left(\sum_{i=1}^{k} (\sqrt{p_i} x_i^{n+1})^2 \right)^{\frac{1}{2}} \\ &= \left(\sum_{i=1}^{k} p_i x_i^{2n} \right)^{\frac{1}{2}} \cdot \left(\sum_{i=1}^{k} p_i x_i^{2n+2} \right)^{\frac{1}{2}} = (m_{2n} m_{2n+2})^{\frac{1}{2}}. \end{aligned}$$

Alternativ verwenden wir die – ebenfalls mittels der Cauchy-Schwarz-Ungleichung hergeleitete – Ungleichung $m_{(u+v)/2} \leq \left(m_u\, m_v\right)^{1/2}$ (siehe Beweis von Satz 11.1.20) und wählen $u = 2n$ und $v = 2n + 2$.

Aufgabe 11.2.11

Es gilt für zwei endliche Zufallsgrößen mit jeweils k verschiedenen Werten, die alle mit Wahrscheinlichkeit $\frac{1}{k}$ auftreten:

$$\begin{aligned} \operatorname{cov}(X,Y) &= \mathbb{E}\left(\left(X - \sum_{i=1}^{k} x_i \frac{1}{k} \right) \left(Y - \sum_{i=1}^{k} y_i \frac{1}{k} \right) \right) \\ &= \mathbb{E}\left(XY - Y \sum_{i=1}^{k} \frac{x_i}{k} - X \sum_{i=1}^{k} \frac{y_i}{k} + \left(\sum_{i=1}^{k} \frac{x_i}{k} \right) \left(\sum_{i=1}^{k} \frac{y_i}{k} \right) \right) \\ &= \mathbb{E}(XY) - \left(\sum_{i=1}^{k} \frac{x_i}{k} \right) \left(\sum_{i=1}^{k} \frac{y_i}{k} \right) \\ &= \sum_{i=1}^{k} \frac{x_i\, y_i}{k} - \bar{x}\, \bar{y} \\ &= \frac{1}{k} \left(\sum_{i=1}^{k} x_i y_i - k\, \bar{x}\, \bar{y} \right). \end{aligned}$$

Hier ergibt sich als Vorfaktor vor dem Summe $\frac{1}{k}$ und nicht $\frac{1}{k-1}$ wie in 4.2.1.

Aufgabe 11.2.13

Formales Rechnen, ohne die Existenz zu hinterfragen, liefert

$$\begin{aligned} \operatorname{cov}(X,Y) &= \mathbb{E}\left((X - \mathbb{E}X)(Y - \mathbb{E}Y) \right) \\ &= \mathbb{E}\left(XY - X \cdot \mathbb{E}Y - Y \cdot \mathbb{E}X + \mathbb{E}X \cdot \mathbb{E}Y \right) \\ &= \mathbb{E}(XY) - \mathbb{E}X \cdot \mathbb{E}Y - \mathbb{E}X \cdot \mathbb{E}Y + \mathbb{E}X \cdot \mathbb{E}Y \end{aligned}$$

$$= \mathbb{E}(XY) - \mathbb{E}X \cdot \mathbb{E}Y.$$

Aus der Existenz von $\operatorname{cov}(X,Y)$ folgt die der beteiligten Erwartungswerte, also insbesondere die Existenz von $\mathbb{E}X$, $\mathbb{E}Y$ und $\mathbb{E}(XY)$. Die Umkehrung folgt analog.

Aufgabe 11.2.15

Es gilt nach Definition

$$\operatorname{cov}(X,Y) = \mathbb{E}\left((X-\mathbb{E}X)(Y-\mathbb{E}Y)\right) = \mathbb{E}\left((Y-\mathbb{E}Y)(X-\mathbb{E}X)\right) = \operatorname{cov}(Y,X).$$

Weiter gilt für alle $\lambda, \mu \in \mathbb{R}$

$$\begin{aligned}\operatorname{cov}(\lambda X, \mu Y) &= \mathbb{E}\Big(\big(\lambda X - \mathbb{E}(\lambda X)\big)\big(\mu Y - \mathbb{E}(\mu Y)\big)\Big) \\ &= \mathbb{E}\big(\lambda\mu(X-\mathbb{E}X)(Y-\mathbb{E}Y)\big) = \lambda\mu \operatorname{cov}(X,Y).\end{aligned}$$

Und schließlich gilt

$$\begin{aligned}\operatorname{cov}(X+X',Y) &= \mathbb{E}\big((X+X'-\mathbb{E}(X+X'))(Y-\mathbb{E}Y)\big) \\ &= \mathbb{E}\big((X-\mathbb{E}X+X'-\mathbb{E}X')(Y-\mathbb{E}Y)\big) \\ &= \mathbb{E}\big((X-\mathbb{E}X)(Y-\mathbb{E}Y)+(X'-\mathbb{E}X')(Y-\mathbb{E}Y)\big) \\ &= \mathbb{E}\big((X-\mathbb{E}X)(Y-\mathbb{E}Y)\big)+\mathbb{E}\big((X'-\mathbb{E}X')(Y-\mathbb{E}Y)\big) \\ &= \operatorname{cov}(X,Y)+\operatorname{cov}(X',Y).\end{aligned}$$

Aufgabe 11.2.19

Wir haben in Beispiel 11.2.18(a) die Varianz einer binomialverteilten Zufallsgröße X bestimmt. Es gilt $\mathbb{V}(X) = np(1-p)$. In Beispiel 11.2.18(b) wurde die Varianz einer hypergeometrisch verteilten Zufallsgröße Y zu den Parametern n, r und s bestimmt. Es gilt

$$\mathbb{V}(Y) = n \cdot \frac{r}{r+s}\left(1-\frac{r}{r+s}\right)\cdot\left(1-\frac{n-1}{r+s-1}\right).$$

Im binomialverteilten Modell ist p die Erfolgswahrscheinlichkeit. Im Urnenmodell mit r roten und s schwarzen Kugeln ist dies $p = \frac{r}{r+s}$. Somit ist

$$\mathbb{V}(Y) = np(1-p)\Big(1-\frac{n-1}{r+s-1}\Big) \leq \mathbb{V}(X).$$

Aufgabe 11.2.20

Es gilt $X = \sum_{j=1}^{n} 1_{A_j}$ mit $P(A_j) = \frac{r}{r+s}$ und

$$P(A_i \cap A_j) = P(A_1 \cap A_2) = \frac{r(r+c)}{(r+s)(r+s+c)},\ 1 \leq i \neq j \leq n,$$

da die Ereignisse A_1 bis A_n austauschbar sind. Für die Varianz einer Summe von Indikatorvariablen $Z = \sum_{i=1}^{n} 1_{A_j}$ gilt

$$\mathbb{V}(Z) = \sum_{j=1}^{n} P(A_j)\Big(1 - P(A_j)\Big) + 2 \sum_{1 \leq i < j \leq n} \Big(P(A_i \cap A_j) - P(A_i)P(A_j)\Big).$$

Wenn sowohl alle Ereignisse $A_1, ..., A_n$ als auch alle Schnitte $A_i \cap A_j,\ 1 \leq i < j \leq n$ gleichwahrscheinlich sind, dann folgt für die Varianz

$$\mathbb{V}(Z) = nP(A_1)(1 - P(A_1)) + n(n-1)(P(A_1 \cap A_2) - P(A_1)^2).$$

Damit folgt für die Varianz von X

$$\begin{aligned}
&\mathbb{V}(X) \\
&= n\left[\frac{r}{r+s}\left(1 - \frac{r}{r+s}\right) + (n-1)\left(\frac{r(r+c)}{(r+s)(r+s+c)} - \frac{r^2}{(r+s)^2}\right)\right] \\
&= n\left[\frac{r}{r+s}\left(1 - \frac{r}{r+s}\right) + (n-1)\frac{r}{r+s}\left(\frac{r+c}{r+s+c} - \frac{r}{r+s}\right)\right] \\
&= n\frac{r}{r+s}\left[\left(1 - \frac{r}{r+s}\right) + (n-1)\frac{(r+c)(r+s) - r(r+c+s)}{(r+s)(r+s+c)}\right] \\
&= n\frac{r}{r+s}\left[\left(1 - \frac{r}{r+s}\right) + (n-1)\frac{r^2 + rs + rc + sc - r^2 - rc - rs}{(r+s)(r+s+c)}\right] \\
&= n\frac{r}{r+s}\left[\left(1 - \frac{r}{r+s}\right) + (n-1)\frac{rc - rc + sc}{(r+s)(r+s+c)}\right] \\
&= n\frac{r}{r+s}\left[\left(1 - \frac{r}{r+s}\right) + (n-1)\left(\frac{c(r+s)}{(r+s)(r+s+c)} - \frac{rc}{(r+s)(r+s+c)}\right)\right] \\
&= n\frac{r}{r+s}\left(1 - \frac{r}{r+s}\right)\left(1 + \frac{(n-1)c}{r+s+c}\right).
\end{aligned}$$

Lösungen der Aufgaben in 11.3

Aufgabe 11.3.5

Für die Varianz von X ergibt sich

$$\mathbb{V}(X) = \sum_{i=1}^{k} \frac{x_i^2}{k} - \left(\sum_{i=1}^{k} \frac{x_i}{k}\right)^2 = \frac{1}{k}\left(\sum_{i=1}^{k} x_i^2 - \frac{1}{k}\left(\sum_{i=1}^{k} x_i\right)^2\right).$$

Die Varianz von Y ergibt sich analog. Wenn wir dies mit der Definition der empirischen Varianz vergleichen, so sehen wir erneut den Unterschied, dass der erste Faktor hier $\frac{1}{k}$ ist, während er $\frac{1}{k-1}$ in der empirischen Variante ist. Nun diskutieren wir $r(X,Y)$. Es gilt durch einfaches Einsetzen unter Verwendung von Aufgabe 11.2.11

$$\begin{aligned} r(X,Y) &= \frac{\frac{1}{k}\left(\sum\limits_{i=1}^{k} x_i y_i - k\,\bar{x}\,\bar{y}\right)}{\frac{1}{\sqrt{k}}\left(\sum\limits_{i=1}^{k} x_i^2 - \frac{1}{k}\left(\sum\limits_{i=1}^{k} x_i\right)^2\right)^{1/2} \frac{1}{\sqrt{k}}\left(\sum\limits_{i=1}^{k} y_i^2 - \frac{1}{k}\left(\sum\limits_{i=1}^{k} y_i\right)^2\right)^{1/2}} \\ &= \frac{\left(\sum\limits_{i=1}^{k} x_i y_i - k\,\bar{x}\,\bar{y}\right)}{\left(\sum\limits_{i=1}^{k} x_i^2 - \frac{1}{k}\left(\sum\limits_{i=1}^{k} x_i\right)^2\right)^{1/2} \left(\sum\limits_{i=1}^{k} y_i^2 - \frac{1}{k}\left(\sum\limits_{i=1}^{k} y_i\right)^2\right)^{1/2}}. \end{aligned}$$

Da sich die Vorfaktoren wegheben, stimmt diese Definition mit der des empirischen Korrelationskoeffizienten überein.