Kurseinheit 5

Gesetze der großen Zahlen

Inhalt der Kurseinheit

Studierhinweise zu Kurseinheit 5 **319**

12 Schwaches Gesetz der großen Zahlen **321**
12.1 Ungleichungen von Markov und Tschebyschev 322
12.2 Schwaches Gesetz der großen Zahlen; unkorrelierte Zufallsgrößen . . 324
12.3 Weitere Schwache Gesetze und Anwendungen 327

Lösungen zu den Aufgaben aus dem Kapitel 12 **339**

13 Starkes Gesetz der großen Zahlen, Runs **343**
13.1 Exponentielle Abschätzungen und die relative Entropie 343
13.2 Ein starkes Gesetz der großen Zahlen 352
13.3 Erfolgsketten, Runs 355

Lösungen zu den Aufgaben aus dem Kapitel 13 **361**

Studierhinweise

In der fünften Kurseinheit werden das schwache und das starke Gesetz der großen Zahlen formuliert und bewiesen.

In *Kapitel zwölf* wird die Häufigkeitsinterpretation von Wahrscheinlichkeiten mathematisiert. Dies ist das Fundament der Stochastik. Wir leiten schwache Gesetze der großen Zahlen her. Vorab klären wir, dass es sehr unwahrscheinlich ist, dass die relative Häufigkeit genau die Wahrscheinlichkeit ist. Prägen Sie sich das Argument hierzu ein.

In *Abschnitt* 12.1 beweisen wir die Markov- und die Tschebyschev-Ungleichung. Die deterministische Form der letzten Ungleichung aus Kapitel drei wird eingeordnet. Nach Durcharbeiten dieses Abschnitts kennen Sie die beiden Ungleichungen.

In *Abschnitt* 12.2 wird nun ein schwaches Gesetz der großen Zahlen für unkorrelierte Zufallsgrößen mit gleichem Erwartungswert und gleicher Varianz hergeleitet. Es folgt eine ausführliche Diskussion der Interpretation und Bedeutung dieses Gesetzes. Sie kennen am Ende dieses Abschnitts den Beweis von Satz 12.2.1 auswendig und können ihn stets vorführen.

In *Abschnitt* 12.3 lernen wir eine Vielzahl weiterer schwacher Gesetze kennen. Damit räumen wir mit dem falschen Eindruck auf, den viele Lehrbücher zur elementaren Stochastik hinterlassen, dass außerhalb der Welt unkorrelierter Zufallsgrößen über dieses fundamentale Gesetz kein Wort mehr zu verlieren sei. Die Häufigkeitsinterpretation der Wahrscheinlichkeit ist zum Glück an vielen Stellen wahr und wir können dies mit elementaren Kenntnissen diskutieren. Neben einer Anwendung des schwachen Gesetzes, dem Beweis des Approximationssatzes von Weierstrass mithilfe der Stochastik, geben wir mit dem Beispiel des vorteilhaften Spiels, bei dem man auf Dauer verliert, und der Diskussion des Petersburger Paradoxons bereits tiefere Einblicke in die Stochastik. Sie kennen nach Durcharbeiten dieses Abschnitts eine Vielzahl von schwachen Gesetzen und haben alle Beweise im Detail verstanden.

In *Kapitel dreizehn* diskutieren wir das starke Gesetz der großen Zahlen. Zuvor verbessern wir die Ungleichung von TSCHEBYSCHEV.

In *Abschnitt* 13.1 leiten wir eine exponentielle Abschätzung her, die im wesentlichen auf der Anwendung der MARKOV-Ungleichung basiert. Wir entdecken eine Ratenfunktion, die relative Entropie heißt. Eigenschaften dieser Funktion werden auch als Vorbereitung auf spätere Kapitel hergeleitet. Für den fairen Münzwurf wird gezeigt, dass die exponentielle Abschätzung nach oben nicht verbessert werden kann. Dazu nutzen wir die STIRLING-Formel. Mit ein wenig Analysis erhalten wir erstaunliche Verbesserungen bisheriger Resultate. Nach Durcharbeiten dieses Abschnitts kennen Sie den Ansatz von BERNSTEIN und können ihn in seinen wesentlichen Schritten nachvollziehen. Sie kennen weiter die relative Entropie und erste Eigenschaften dieser Funktion.

In *Abschnitt* 13.2 wagen wir einen interessanten Ausblick: Für das BERNOULLI-Experiment leiten wir ein starkes Gesetz der großen Zahlen her. Dabei machen wir uns die Stetigkeitseigenschaft eines Wahrscheinlichkeitsmaßes zunutze und verwenden die exponentielle Abschätzung aus Abschnitt 13.1, um eine grundlegende Summierbarkeitsfrage klären zu können. Sie beherrschen die Aussage des starken Gesetzes und können im Zusammenhang mit diesem Gesetz zu einem maßtheoretischen Grundproblem Stellung beziehen.

Im letzten *Abschnitt* 13.3 diskutieren wir ein starkes Gesetz der großen Zahlen zu Erfolgsketten im BERNOULLI-Experiment. Dabei wird ein fundamentales Lemma von BOREL-CANTELLI hergeleitet. Das neue starke Gesetz klärt eine häufige Fehlinterpretation des starken Gesetzes aus Abschnitt 13.2: Dieses besagt beim fairen Münzwurf nicht, dass Nullen und Einsen in einer regelmäßigen Abwechslung auftreten, sondern nur, dass der relative Anteil der Einsen und Nullen nahe bei $\frac{1}{2}$ liegt. Diese Botschaft können Sie nach Durcharbeiten dieses Abschnitts genau formulieren.

Kapitel 12

Schwaches Gesetz der großen Zahlen

In diesem Kapitel klären wir präzise den mathematischen Hintergrund für das folgende intuitive Verständnis von Wahrscheinlichkeit, was bei sehr vielen Personen — vermutlich — vorliegt:

Führen wir ein Experiment n-mal unabhängig durch und bezeichnen wir mit X_i den Ausgang des i-ten Experiments, so liegt der Mittelwert $\frac{1}{n}\sum_{i=1}^{n} X_i$ in der Nähe eines festen Wertes, so unsere Vermutung. Die Kenntnis des Begriffs Erwartungswert lässt darüberhinaus vermuten, dass dieser Wert der Erwartungswert der obigen Zufallsvariable ist. Sind die X_i alle identisch verteilt, so ist dieser Wert $\mathbb{E}(X_1)$, wobei wir die Linearität des Erwartungswertes verwendet haben. Betrachten wir speziell ein Ereignis A und zählen, wie häufig A in unserer Versuchsreihe eingetreten ist, so bestimmen wir

$$\frac{1}{n}\sum_{i=1}^{n} 1_{\{X_i \in A\}},$$

die relative Häufigkeit des Eintretens von A bei einer sehr großen Anzahl n von Experimenten. Die *Häufigkeitsinterpretation* von Wahrscheinlichkeit sagt, dass dieser Wert die Wahrscheinlichkeit $P(A)$ des Ereignisses A gut beschreibt.

Sind wir in der Lage, bei einer Modellierung im Rahmen der Wahrscheinlichkeitstheorie diese Intuition zu bestätigen? Dazu müssen wir genau klären, in welchem Sinne wir die Näherung zu verstehen haben.

Zunächst klären wir, was die gesuchte Näherung nicht sein kann. Es ist tatsächlich sehr unwahrscheinlich, dass die relative Häufigkeit genau die Wahrscheinlichkeit $P(A)$ ist. Dies rechnen wir in einem einfachen Beispiel aus:

12.0.1 Beispiel: Wir betrachten das Bernoulli-Experiment der Länge $2n$ mit Erfolgswahrscheinlichkeit $p = \frac{1}{2}$, beschrieben durch $(X_i)_i$ mit $P(X_i = 1) = p$. Wie groß ist die Wahrscheinlichkeit, dass die relative Anzahl der Erfolge genau $\frac{1}{2}$ ist? Es gilt

$$P\left(\frac{1}{2n}\sum_{i=1}^{2n} X_i = \frac{1}{2}\right) = b(n; 2n, 1/2) = \binom{2n}{n}\frac{1}{2^{2n}}.$$

Nun verwenden wir die Stirling-Approximation, siehe Satz 7.0.1:

$$P\left(\frac{1}{2n}\sum_{i=1}^{2n} X_i = \frac{1}{2}\right) \sim \frac{(2n)^{2n}\sqrt{2\pi 2n}}{(n^n\sqrt{2\pi n})^2}\frac{1}{2^{2n}} = \frac{1}{\sqrt{\pi n}}.$$

Also liegt die relative Häufigkeit bei großem n nur mit sehr geringer Wahrscheinlichkeit genau bei $p = \frac{1}{2}$.

Es wird sich aber zeigen, dass es immer unwahrscheinlicher wird, dass die relative Häufigkeit der Erfolge deutlich von $\frac{1}{2}$ abweicht! Eine Verallgemeinerung hiervon ist das *schwache Gesetz der großen Zahlen.*

Wir leiten eine sehr nützliche Ungleichung von Markov und Tschebyschev her und formulieren und beweisen dann das schwache Gesetz der großen Zahlen in einigen uns bekannten und in neuen Situationen.

12.1 Ungleichungen von Markov und Tschebyschev

Die Standardabweichung ist ein Maß dafür, wieweit X von $\mathbb{E}(X)$ mit nicht zu kleiner Wahrscheinlichkeit abweichen kann. Diese sehr vage Aussage wird durch die sogenannte *Tschebyschev-Ungleichung* präzisiert. Tschebyschev bewies diese Ungleichung 1867. Wir beweisen gleich eine Ungleichung, von der die Tschebyschev-Ungleichung ein Spezialfall ist. Sie stammt von Markov und wird im folgenden Kapitel ebenfalls von großer Bedeutung sein.

12.1.1 Satz: (Markov-Ungleichung) Es sei ϕ eine auf $[0, \infty)$ definierte, nichtnegative, monoton wachsende Funktion. Es sei X eine Zufallsgröße, für die der Erwartungswert $\mathbb{E}(\phi(|X|))$ existiert. Dann gilt für jedes $a > 0$ mit $\phi(a) > 0$

$$P(|X| \geq a) \leq \frac{\mathbb{E}(\phi(|X|))}{\phi(a)}.$$

Beweis: Sei zunächst X eine diskrete Zufallsgröße. Dann gilt

$$\begin{aligned} P(|X| \geq a) &= \sum_{x \in X(\Omega), |x| \geq a} P(X = x) \leq \sum_{x \in X(\Omega), \phi(|x|) \geq \phi(a)} \frac{\phi(|x|)}{\phi(a)} P(X = x) \\ &\leq \sum_{x \in X(\Omega)} \frac{\phi(|x|)}{\phi(a)} P(X = x) = \frac{\mathbb{E}(\phi(|X|))}{\phi(a)}. \end{aligned}$$

Ist X eine kontinuierliche Zufallsgröße mit Dichte f (siehe Definition 10.3.4) dann gilt analog

$$\begin{aligned} P(|X| \geq a) &= \int_{\mathbb{R}} 1_{[a,\infty)}(|x|)\, f(x)\, dx \leq \int_{\mathbb{R}} 1_{[a,\infty)}(|x|)\, \frac{\phi(|x|)}{\phi(a)}\, f(x)\, dx \\ &\leq \frac{1}{\phi(a)} \int_{\mathbb{R}} \phi(|x|)\, f(x)\, dx = \frac{\mathbb{E}\big[\phi(|X|)\big]}{\phi(a)}. \end{aligned}$$

Im allgemeinen Fall wird in der letzten Ungleichungskette $f(x)dx$ durch $dP(x)$ ersetzt, was wir hier ohne Kenntnisse aus der Maßtheorie nicht weiter ausführen.

□

Es folgt nun die angekündigte Ungleichung von Tschebyschev:

12.1.2 Satz: (Tschebyschev-Ungleichung) Sei X eine Zufallsgröße, deren Erwartungswert $\mathbb{E}(X)$ und Varianz $\mathbb{V}(X)$ existieren. Dann gilt für jedes $a > 0$

$$P(|X - \mathbb{E}X| \geq a) \leq \frac{\mathbb{V}(X)}{a^2}.$$

Beweis: Mit $\phi(x) = x^2$ folgt aus der Markov-Ungleichung

$$P(|X - \mathbb{E}X| \geq a) \leq \frac{1}{a^2}\mathbb{E}((X - \mathbb{E}X)^2) = \frac{\mathbb{V}(X)}{a^2}. \tag{12.1}$$

□

12.1.3 Beispiel: Wenn man den Beweis der Tschebyschev-Ungleichung betrachtet, so wirkt die Ungleichung sehr grob. Es ist interessant, dass es ein relativ einfaches Beispiel gibt, das zeigt, dass man im Allgemeinen diese Ungleichung nicht verbessern kann. Sei $a > 1$ und X eine Zufallsgröße, die als Werte $-a$, $+a$ und 0

annimmt und deren Verteilung gegeben ist durch $P(X = -a) = P(X = +a) = 1/(2a^2)$ und $P(X = 0) = 1 - 1/a^2$. Wir erhalten

$$\mathbb{E}(X) = -a \cdot \frac{1}{2a^2} + a \cdot \frac{1}{2a^2} = 0$$

und

$$\mathbb{V}(X) = \mathbb{E}(X^2) = a^2 \cdot \frac{1}{2a^2} + a^2 \cdot \frac{1}{2a^2} = 1.$$

Damit folgt

$$P(|X - \mathbb{E}(X)| \geq a) = P(|X| \geq a) = P(X = -a) + P(X = +a) = \frac{1}{a^2} = \frac{\mathbb{V}(X)}{a^2}.$$

Dennoch ist die Ungleichung in vielen Fällen keine sehr gute Abschätzung. Für viele Zufallsgrößen können Abweichungen vom Erwartungswert sehr viel besser als mit der Tschebyschev-Ungleichung abgeschätzt werden. Wir werden dies im nächsten Kapitel diskutieren.

12.1.4 Aufgabe: Beweisen Sie die Tschebyschev-Ungleichung in Satz 3.2.12 durch Verwendung des endlichen Falls, definiert in 11.1.4.

12.2 Schwaches Gesetz der großen Zahlen; unkorrelierte Zufallsgrößen

Die Bedeutung der Tschebyschev-Ungleichung liegt mehr in der Theorie. Sie ist gut genug, um das nachfolgende Gesetz der großen Zahlen zu beweisen.

Mit Blick auf das Beispiel 12.0.1 suchen wir noch nach einem geeigneten Konvergenzbegriff. Die folgende abgeschwächte Vermutung liegt nahe: Gilt

$$\lim_{n\to\infty} P\left(\left|\frac{1}{2n}\sum_{i=1}^{2n} X_i - \frac{1}{2}\right| \leq \varepsilon\right) = 1 \tag{12.2}$$

für alle $\varepsilon > 0$? Das entspräche dann der angekündigten Aussage, dass es immer unwahrscheinlicher wird, dass die relative Häufigkeit der Erfolge deutlich von $\frac{1}{2}$ abweicht.

Ein Gesetz von dieser Bauart wurde bereits im Jahre 1689 von Jakob Bernoulli für den Fall des n-maligen Münzwurfes bewiesen. Dieses Theorem steht in der *Ars conjectandi*, einer sehr berühmten Lehrschrift, welche erst acht Jahre nach Bernoullis Tod 1713 in Basel erschien.

12.2.1 Satz: (Schwaches Gesetz der großen Zahlen) Es seien für jedes $n \in \mathbb{N}$ auf einem diskreten Wahrscheinlichkeitsraum paarweise unkorrelierte Zufallsgrößen $X_1, X_2, \ldots, X_n$ gegeben, die von n abhängen dürfen, die aber alle den gleichen Erwartungswert E und die gleiche Varianz V besitzen. Sei $S_n := X_1 + \cdots + X_n$. Dann gilt für jedes $\varepsilon > 0$

$$\lim_{n\to\infty} P\left(\left|\frac{S_n}{n} - E\right| \geq \varepsilon\right) = 0.$$

Beweis: Wir wenden die Tschebyschev-Ungleichung an.

$$P\left(\left|\frac{S_n}{n} - E\right| \geq \varepsilon\right) \leq \frac{1}{\varepsilon^2}\mathbb{V}\left(\frac{S_n}{n}\right) = \frac{1}{n^2\varepsilon^2}\mathbb{V}(S_n).$$

Dabei haben wir verwendet, dass eine Konstante aus der Varianz quadratisch nach vorne gezogen wird, siehe Lemma 11.2.6(iv). Da die Zufallsgrößen nach Voraussetzung paarweise unkorreliert sind, folgt aus der Gleichung von Bienaymé, Satz 11.2.22:

$$P\left(\left|\frac{S_n}{n} - E\right| \geq \varepsilon\right) \leq \frac{1}{n^2\varepsilon^2}nV.$$

Die rechte Seite konvergiert für $n \to \infty$ gegen Null. □

12.2.2 Bemerkung: (Interpretation) Falls wir beliebig oft ein Experiment wiederholen und annehmen, dass die Ergebnisse (Zufallsgrößen) paarweise voneinander unabhängig oder mindestens unkorreliert sind, so ist die Wahrscheinlichkeit für ein Abweichen der Mittelwerte der ersten n Experimente vom Erwartungswert schließlich (d.h. für hinreichend große n) beliebig klein.

Die Abschätzung Bernoullis für $P\left(\left|\frac{S_n}{n} - E\right| \geq \varepsilon\right)$ war bereits viel besser als hier angegeben. Wir werden im nächsten Kapitel eine Abschätzung der folgenden Form herleiten: Es gibt zu $\varepsilon > 0$ und $0 < p < 1$ eine Konstante $c(\varepsilon, p)$, sodass für alle n gilt:

$$P\left(\left|\frac{S_n}{n} - E\right| \geq \varepsilon\right) \leq 2\exp(-c(\varepsilon, p)n).$$

12.2.3 Bemerkung: Die Voraussetzungen des Satzes wirken umständlich. Wieso setzen wir nicht einfach voraus, dass $(X_i)_{i\in\mathbb{N}}$ eine Folge von unkorrelierten Zufallsgrößen ist? Die Antwort ist einfach: Wir haben keine Möglichkeiten, eine derartige unendliche Folge auf einem abzählbaren Wahrscheinlichkeitsraum zu definieren (außer im ganz einfachen Fall, wo die X_i alle konstant sind). Grundsätzlich kann

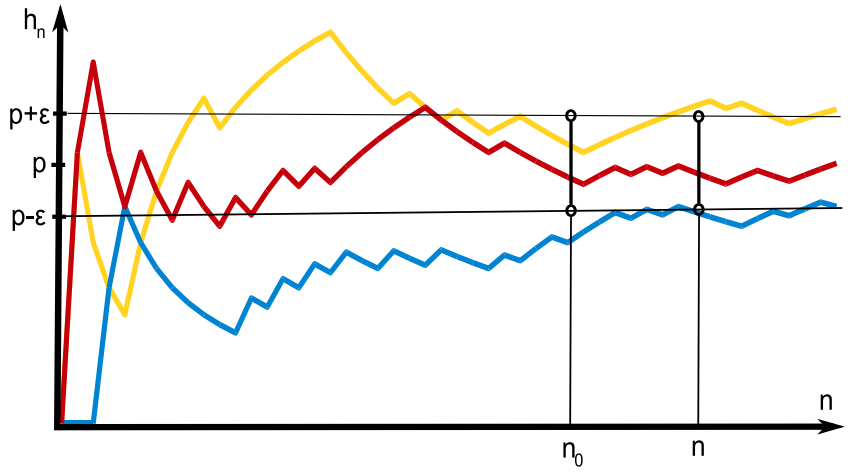

Abb. 12.1: Veranschaulichung des schwachen Gesetzes

aber ein gemeinsamer W.-Raum gefunden werden, auf dem eine gewünschte Folge von paarweise unkorrelierten Zufallsgrößen definiert ist. Es übersteigt nur die Grenzen dieses Kurses, da man dafür die Maßtheorie benötigt.

In Satz 12.2.1 setzen wir voraus, dass für jedes n ein W.-Raum $\Omega^{(n)}$ existiert, auf dem die $X_1, \ldots, X_n$ existieren. Wenn wir sehr genau wären, sollten wir deshalb $X_1^{(n)}, \ldots, X_n^{(n)}$ schreiben. Es macht keine Schwierigkeiten, eine solche Folge von W.-Räumen und die dazugehörenden Zufallsgrößen als mathematisch präzise definierte Objekte zu konstruieren: Es seien $f_1, \ldots, f_n$ beliebige W.-Verteilungen auf abzählbaren Teilmengen A_i von $\mathbb{R}$ (d.h. $f_i : A_i \to [0,1]$ mit $\sum_{x \in A_i} f_i(x) = 1$). Wir konstruieren einen W.-Raum (Ω, p) und unabhängige Zufallsgrößen X_i mit $X_i(\Omega) = A_i$ und Verteilungen f_i entsprechend des uns bekannten Konzepts des Produktraums. Sei $\Omega := A_1 \times \cdots \times A_n$. Für $\omega = (\omega_1, \ldots, \omega_n) \in \Omega$ setzen wir $X_i(\omega) := \omega_i$ für alle i in $\{1, \ldots, n\}$ und $p(\omega) := f_1(\omega_1) f_2(\omega_2) \cdots f_n(\omega_n)$. Per Konstruktion sind $X_1, \ldots, X_n$ unabhängig, also auch unkorreliert. Haben die f_i alle denselben Erwartungswert und dieselbe Varianz (z.B. wenn sie alle gleich sind), so haben die X_i alle denselben Erwartungswert und dieselbe Varianz. Diese Konstruktion können wir für jedes n durchführen.

Der Satz 12.2.1 lässt sich natürlich auf binomialverteilte Zufallsgrößen anwenden, denn diese lassen sich ja in der Form $X_1 + \cdots + X_n$ schreiben, wobei die $X_1, \ldots, X_n$ unabhängig, also auch unkorreliert sind. Es ist lehrreich, die Aussage für diesen Fall zu betrachten: Seien also die X_i unabhängig mit $P(X_i = 1) = p$, $P(X_i = 0) = 1-p$, dann ist $S_n := X_1 + \cdots + X_n$ binomial verteilt mit $\mathbb{E}(X_i) = p$ und $\mathbb{V}(X_i) = p(1-p)$.

Aus Satz 12.2.1 folgt, dass für jedes $\varepsilon > 0$

$$\begin{aligned} P\left(\left|\frac{S_n}{n} - p\right| \geq \varepsilon\right) &= P(|S_n - np| \geq n\varepsilon) \\ &= \sum_{\substack{k:|k-np|\geq n\varepsilon \\ k\in\mathbb{N}_0}} P(S_n = k) = \sum_{\substack{k:|k-np|\geq n\varepsilon \\ k\in\mathbb{N}_0}} \binom{n}{k} p^k (1-p)^{n-k} \end{aligned}$$

mit $n \to \infty$ gegen 0 konvergiert. Insbesondere folgt der Beweis von (12.2).

Man muss sich darüber im Klaren sein, dass keineswegs etwa $P(S_n \neq np)$ gegen Null konvergiert. Im Fall $p = \frac{1}{2}$ hatten wir gesehen:

$$P(S_{2n} \neq n) = 1 - P(S_{2n} = n) \to 1.$$

In der Tat konvergiert $P(|S_n - np| \geq r)$ gegen 1 für jede Zahl $r > 0$. Wir werden dies in Kurseinheit 5 präzisieren.

MERKE: Nicht S_n liegt mit großer Wahrscheinlichkeit (für große n) in der Nähe von np, sondern S_n/n in der Nähe von p.

Der Satz 12.2.1 heißt schwaches Gesetz der großen Zahlen, um es vom sogenannten *starken Gesetz der großen Zahlen* zu unterscheiden. Dieses besagt

$$P\left(\lim_{n\to\infty} \frac{S_n}{n} \text{ existiert und ist } = E\right) = 1. \tag{12.3}$$

(12.3) macht jedoch nur Sinn, wenn *alle* X_i, $i \in \mathbb{N}$, auf *einem* W.-Raum definiert sind. Die Konstruktion eines solchen W.-Raumes macht aber, wie bereits erwähnt, vielleicht unerwartet, erhebliche Probleme. Wir werden im folgenden Kapitel 13 ein starkes Gesetz für Bernoulli-Zufallsgrößen beweisen. Dabei gehen wir einfach von der Existenz des genannten W.-Raums aus!

12.3 Weitere Schwache Gesetze und Anwendungen

Zunächst untersuchen wir die Gültigkeit eines schwachen Gesetzes in uns bekannten Modellen.

12.3.1 Beispiel: (Negative Binomialverteilung) Wir erinnern an Beispiel 9.2.7. Dort bezeichneten wir mit $n(\omega_i)$ die Anzahl der Misserfolge in $\omega_i \in \Omega_1$. Wir definieren nun die Zufallsgrößen $Y_1, Y_2, \ldots, Y_r$ auf Ω_r durch

$$Y_i(\omega) := n(\omega_i), \quad \omega := (\omega_1, \ldots, \omega_r) \in \Omega_r.$$

Dann ist $X_r := Y_1 + \cdots + Y_r$ die Anzahl der Misserfolge vor dem r-ten Erfolg. Wir wissen bereits, dass nach Konstruktion des Produktraumes die Zufallsgrößen $Y_1, \ldots, Y_r$ stochastisch unabhängig, also insbesondere paarweise unkorreliert sind. Weiter gilt

$$P(Y_i = k) = (1-p)^k \cdot p.$$

Also ist $Y_i + 1$ geometrisch verteilt. Nach Beispiel 11.1.11(d) gilt $\mathbb{E}(Y_i) = \frac{1}{p} - 1 = \frac{1-p}{p}$. Der Erwartungwert existiert also und ist unabhängig von i (was nicht überraschen sollte, denn die Y_i sind identisch verteilt). Auch die Varianz existiert. Es gilt

$$\mathbb{V}(Y_i) = \frac{1-p}{p^2},$$

siehe Beispiel 11.2.9(b). Somit können wir Satz 12.2.1 anwenden und erhalten:

$$\lim_{r\to\infty} P\left(\left|\frac{X_r}{r} - \frac{1-p}{p}\right| \geq \varepsilon\right) = 0$$

für jedes $\varepsilon > 0$.

Wir haben in Satz 12.2.1 paarweise Unkorreliertheit gefordert. Bisher haben wir diesen Satz für die spezielle Situation unabhängiger Zufallsgrößen angewendet. Nun interessieren uns Situationen, in denen auch die paarweise Unkorreliertheit nicht gegeben ist, Kovarianzen also auftreten. Wir haben Beispiele kennengelernt, in denen von Null verschiedene Kovarianzen auftraten, so etwa bei der Bestimmung der Anzahl der Fixpunkte einer zufälligen Permutation oder beim Urnenmodell von Polyá. Diesen Beispielen war gemeinsam, dass die untersuchte Zufallsgröße (Anzahl der Fixpunkte, Anzahl der gezogenen roten Kugeln) als Summe von Indikatoren dargestellt werden kann. Wir bereiten daher die Diskussion schwacher Gesetze in diesen Beispielen dadurch vor, dass wir notieren, was eine Anwendung der Tschebyschev-Ungleichung bewirkt:

12.3.2 Beispiel: In einem diskreten W.-Raum seien die Ereignisse $A_1, \ldots, A_n$ gegeben. Wir betrachten die Zufallsgröße

$$X := \sum_{i=1}^{n} 1_{A_i}.$$

Wir betrachten die Situation, dass alle n Ereignisse $A_1, \ldots, A_n$ gleichwahrscheinlich sind und die Wahrscheinlichkeiten $P(A_i \cap A_j)$ von i und j unabhängig sind. Wir verwenden Formel (11.4), sodass

$$P\left(\left|\frac{X}{n} - P(A_1)\right| \geq \varepsilon\right) \leq \frac{P(A_1)\big(1 - P(A_1)\big)}{\varepsilon^2 n} + \frac{n(n-1)}{\varepsilon^2 n^2} \cdot \big(P(A_1 \cap A_2) - P(A_1)^2\big). \tag{12.4}$$

Wir sehen hier genau, wie die Korrelationen ins Spiel kommen. Sind die vorkommenden Wahrscheinlichkeiten $P(A_1)$ und $P(A_1 \cap A_2)$ von n unabhängig, bleibt beim Limesübergang $n \to \infty$ der Ausdruck $\varepsilon^{-2}\big(P(A_1 \cap A_2) - P(A_1)^2\big)$ übrig. Dann wissen wir, dass mittels der Anwendung der TSCHEBYSCHEV-Ungleichung kein schwaches Gesetz der großen Zahlen gefolgert werden kann. Daraus kann nicht geschlossen werden, dass das schwaches Gesetz nicht gilt.

Wir wenden die TSCHEBYSCHEV-Ungleichung (12.4) für Indikatorsummen nun an:

12.3.3 Beispiel: (Fixpunkte) Es sei X die Anzahl der Fixpunkte einer zufälligen Permutation. In Beispiel 11.2.18(c) hatten wir gesehen, dass hier

$$P(A_1) = \frac{1}{n}, \quad \text{und} \quad P(A_1 \cap A_2) = \frac{1}{n(n-1)}$$

gelten. Dann folgt mit (12.4) ein schwaches Gesetz der großen Zahlen:

$$\lim_{n\to\infty} P\left(\left|\frac{X}{n} - \frac{1}{n}\right| \geq \varepsilon\right) = 0$$

für jedes $\varepsilon > 0$.

Komplizierter ist die Diskussion für das Modell der hypergeometrischen Verteilung:

12.3.4 Beispiel: (hypergeometrische Verteilung) Es sei X hypergeometrisch verteilt. Die Berechnungen in Beispiel 11.2.18(b) liefern mithilfe von (12.4):

$$P\left(\left|\frac{X}{n} - \frac{r}{r+s}\right| \geq \varepsilon\right) \leq \frac{r \cdot s}{(r+s)^2}\frac{1}{\varepsilon^2 n} + \frac{n-1}{\varepsilon^2 n} \cdot \left(\frac{r(r-1)}{(r+s)(r+s-1)} - \frac{r^2}{(r+s)^2}\right). \tag{12.5}$$

Nun ist die Anzahl der gezogenen Kugeln n immer kleiner als oder gleich $r+s$. Wenn wir hier im Limesübergang $n \to \infty$ ein schwaches Gesetz erhoffen, so muss auch $r+s \to \infty$. Daher wird man fordern, dass sowohl die Anzahl der roten als auch die Anzahl der schwarzen Kugeln anwächst. Das Anwachsen der beiden Anzahlen geschieht dann in einer Relation

$$\lim_{n\to\infty} \frac{r_n}{s_n} = a \in [0, \infty].$$

Dabei betrachten wir nur Folgen mit $n \leq r_n + s_n$. Der Fall $a = 0$ bedeutet, dass aus nicht näher bekannten Gründen der Anteil der schwarzen Kugeln in Größenordnung schneller wächst als der Anteil der roten Kugeln. Im Fall $a = \infty$ ist es genau

umgekehrt. Der Fall $0 < a < \infty$ bedeutet, dass beide Anzahlen im Verhältnis a wachsen. In diesem Fall konvergiert die rechte Seite in (12.5) gegen Null und wir erhalten ein schwaches Gesetz der großen Zahlen, denn dann ist

$$\lim_{n\to\infty} \frac{r_n}{r_n + s_n} = \frac{a}{a+1} \quad \text{und} \quad \lim_{n\to\infty} \frac{s_n}{r_n + s_n} = \frac{1}{a+1}.$$

Ist der Anteil der roten Kugel sehr klein, $a = 0$, so folgt $\lim_{n\to\infty} P\Big(\big|\frac{X}{n}\big| \geq \varepsilon) = 0$. Man sagt, der relative Anteil der roten Kugeln konvergiert *stochastisch* gegen Null. Dies wirkt plausibel. Für den Fall $a = \infty$ sagt die Abschätzung mithilfe der TSCHEBYSCHEV-Ungleichung nichts aus. Wir sind aber auch nicht überrascht, muss doch nach unseren bisherigen Beispielen immer der Erwartungswert und die Varianz der Zufallsgröße X_i existieren.

12.3.5 Aufgabe: Formulieren Sie im Fall $a \geq 0$ das schwache Gesetz der großen Zahlen für die mittlere Anzahl der gezogenen roten Kugeln im hypergeometrisch verteilten Modell genau. Welches sind die Bedingungen an die Parameter des Modells?

12.3.6 Aufgabe: Es seien $X_1, X_2, \ldots$ Zufallsgrößen, wobei X_n binomialverteilt ist mit den Parametern n und p_n. Zeigen Sie: Gilt $\lim_{n\to\infty} n\, p_n = 0$, so folgt

$$\lim_{n\to\infty} P(|X_n| \geq \varepsilon) = 0$$

für jedes $\varepsilon > 0$.

12.3.7 Aufgabe: Ein Gefäß sei in zwei gleich große miteinander verbundene Teilkammern unterteilt. Es enthalte $n = 0.25 \cdot 10^{23}$ Gasmoleküle[1] (AVOGADRO-Zahl). Wir nehmen an, dass sich zu einem festen Zeitpunkt jedes Molekül mit Wahrscheinlichkeit 1/2 in der linken oder der rechten Teilkammer befindet, unabhängig von allen anderen Molekülen. Wie groß ist die Wahrscheinlichkeit, dass der Anteil der Moleküle in der linken Kammer größer als der in der rechten Kammer ist? Schätzen Sie dazu die Wahrscheinlichkeit dafür ab, dass der Anteil in der linken Kammer größer als

$$\frac{1 + 10^{-8}}{2}$$

ist.

Nun betrachten wir ein Beispiel, in dem die Zufallsgröße komplizierter ist.

[1] Wir haben zur Vereinfachung dieser Aufgabe die AVOGADRO-Zahl so gewählt. Normalerweise wird sie mit $6.0221415(10) \cdot 10^{23}\text{mol}^{-1}$ angegeben.

12.3.8 Beispiel: (Quicksort) Es sei X_n die Anzahl der benötigten Vergleiche bei Quicksort für eine Liste der Länge n. Dann existiert

$$c := \lim_{n\to\infty} \frac{\mathbb{V}(X_n)}{n^2} \tag{12.6}$$

und ist größer als 0. Wir beweisen dies hier nicht. Es ist durchaus eine harte Nuss, die man hier für einen vollständigen Beweis zu knacken hätte[2]. Wichtig ist die Tatsache, dass somit für die Standardabweichung $\sqrt{\mathbb{V}(X_n)} \approx n$ gilt, sie also gegenüber dem Erwartungswert klein ist (zur Erinnerung: $\mathbb{E}(X_n) \approx 2n\ln(n)$). Die Konstante ist

$$c = 7 - 2/(3\pi^2).$$

Zum Beweis hierzu muss man eine recht aufwendige Theorie verwenden. Zu zeigen, dass

$$\limsup_{n\to\infty} \mathbb{V}(X_n)/(n^2\ln^2(n)) = 0$$

gilt, ist übrigens wesentlich einfacher und reicht für den Beweis des folgenden Satzes aus, nach dem die Verteilung der Anzahl der benötigten Vergleiche im relativen Maßstab mehr und mehr um den Erwartungswert konzentriert ist:

12.3.9 Satz: (Schwaches Gesetz der großen Zahlen für Quicksort) Für jedes $\varepsilon > 0$ gilt

$$\lim_{n\to\infty} P\Big(\Big|\frac{X_n}{n\ln(n)} - 2\Big| \geq \varepsilon\Big) = 0.$$

Beweis: Nach unserer Diskussion des Erwartungswertes $\mathbb{E}(X_n)$ in Beispiel 11.1.16 existiert zu $\varepsilon > 0$ ein $N_\varepsilon \in \mathbb{N}$, sodass

$$\Big|\frac{\mathbb{E}(X_n)}{n\ln(n)} - 2\Big| \leq \varepsilon/2$$

für alle $n \geq N_\varepsilon$ gilt. Für jedes derartige n gilt

$$\Big\{\Big|\frac{X_n}{n\ln(n)} - 2\Big| \geq \varepsilon\Big\} \subset \Big\{\Big|\frac{X_n}{n\ln(n)} - \frac{\mathbb{E}(X_n)}{n\ln(n)}\Big| \geq \frac{\varepsilon}{2}\Big\}$$

und mittels mit der Tschebyschev-Ungleichung folgt

$$P\Big(\Big|\frac{X_n}{n\ln(n)} - 2\Big| \geq \varepsilon\Big) \leq P\Big(\Big|\frac{X_n}{n\ln(n)} - \frac{\mathbb{E}(X_n)}{n\ln(n)}\Big| \geq \frac{\varepsilon}{2}\Big) \leq \frac{4}{\varepsilon^2}\,\frac{\mathbb{V}(X_n)}{n^2\ln^2(n)}.$$

Nach (12.6) konvergiert dies gegen 0 für $n \to \infty$. □

[2]Siehe eine Arbeit von V. Iliopoulos und D. Penman „Variance of the number of comparisons of randomised quicksort“, http://arxiv.org/pdf/1006.4063v1.pdf .

12.3.10 Beispiel: (Forsetzung Quicksort) Interessant ist ein Vergleich mit dem Bernoulli-Experiment. Hier hat der Erwartungswert die Größenordnung n, die Standardabweichung die Größenordnung $\sqrt{n}$. Bei Quicksort ist die Standardabweichung nur um $\ln(n)$ kleiner als der Erwartungswert. Die Konzentration um den Erwartungswert ist hier also schwächer. Die Abschätzung mithilfe der Tschebyschev-Ungleichung ist nicht sehr nützlich. Dies soll das folgende Zahlenbeispiel verdeutlichen. Für $\varepsilon = 1$ und unter Verwendung von $c = 7 - 2/(3\pi^2)$ erhält man mithilfe von (12.6)

$$P\left(\frac{X_n}{n\ln(n)} \geq 3\right) \leq \frac{4\mathbb{V}(X_n)}{n^2\ln^2(n)} \approx \frac{28}{\ln^2(n)}.$$

Bei $n = 1700$ Zahlen ist diese Wahrscheinlichkeit knapp kleiner als 0.5, also nicht sehr informativ. Das liegt im Wesentlichen an der Tschebyschev-Ungleichung. Die Wahrscheinlichkeit ist in Wahrheit deutlich kleiner. Wir werden dies nicht weiter verfolgen. Für ein Bernoulli-Experiment verbessern wir die Abschätzung im folgenden Kapitel.

12.3.11 Beispiel: (Approximationssatz von Weierstrass) Eine Anwendung des schwachen Gesetzes der großen Zahlen führt zu der folgenden von Sergej Natanowitsch Bernstein (1880–1968) gegebenen Beweisvariante des Approximationssatzes von Karl Weierstrass (1815–1897). Dieser Satz besagt, dass man jede stetige reelle Funktion f auf dem Einheitsintervall $[0,1]$ durch Polynome, definiert auf $[0,1]$, gleichmäßig approximieren kann. Wir betrachten nun das sogenannte Bernstein-Polynom zu f:

$$B_n^f(x) := \sum_{k=0}^{n} f\left(\frac{k}{n}\right)\binom{n}{k}x^k(1-x)^{n-k}.$$

Wenn S_n eine binomial verteilte Zufallsgröße mit Parametern x und n bezeichnet, so folgt unmittelbar

$$\mathbb{E}\left(f\left(\frac{S_n}{n}\right)\right) = \sum_{k=0}^{n} f\left(\frac{k}{n}\right)P(S_n = k) = B_n^f(x).$$

Da jedes obige f auf $[0,1]$ gleichmäßig stetig ist, gibt es zu jedem $\varepsilon > 0$ ein $\delta(\varepsilon) > 0$ derart, dass für alle $r, s \in [0,1]$ gilt: $|r - s| < \delta(\varepsilon) \Rightarrow |f(r) - f(s)| < \varepsilon$. Nach der Tschebyschev-Ungleichung folgt

$$P\left(\left|\frac{S_n}{n} - x\right| \geq \delta\right) \leq \frac{x(1-x)}{n\delta^2} \leq \frac{1}{4n\delta^2},$$

denn $4x(1-x) = 1-(2x-1)^2 \leq 1$. Es folgt somit die Abschätzung (in der ersten Ungleichung verwende $\left|\mathbb{E}X\right| \leq \mathbb{E}|X|$)

$$\begin{aligned}
|B_n^f(x) - f(x)| &= \left|\mathbb{E}\left(f\left(\frac{S_n}{n}\right) - f(x)\right)\right| \\
&\leq \mathbb{E}\left|f\left(\frac{S_n}{n}\right) - f(x)\right| \\
&= \mathbb{E}\left[\left|\left(f\left(\frac{S_n}{n}\right) - f(x)\right)\right| 1_{(\delta,\infty)}\left(\left|\frac{S_n}{n} - x)\right|\right)\right] \\
&+ \mathbb{E}\left[\left|\left(f\left(\frac{S_n}{n}\right) - f(x)\right)\right| 1_{[0,\delta]}\left(\left|\frac{S_n}{n} - x\right|\right)\right] \\
&\leq 2 \sup_{u\in[0,1]} \left\{|f(u)|\right\} P\left(\left|\frac{S_n}{n} - x\right| > \delta\right) \\
&+ \sup_{|u-v|\leq\delta} \left\{|f(u) - f(v)|\right\} P\left(\left|\frac{S_n}{n} - x\right| \leq \delta\right).
\end{aligned}$$

Der erste Term ist durch $\frac{1}{2n\delta^2} \sup_{u\in[0,1]} \left\{|f(u)|\right\}$ beschränkt, der zweite Term durch ε für $\delta \leq \delta(\varepsilon)$, da f gleichmäßig stetig ist. Indem man also zunächst $\delta = \delta(\varepsilon)$ und dann $n = n(\delta, \varepsilon)$ wählt, erhält man $\sup_{x\in[0,1]} \left\{|B_n^f(x) - f(x)|\right\} \leq 2\varepsilon$. Somit ist gezeigt, dass für jede stetige reelle Funktion auf $[0,1]$ die Folge $(B_n^f)_{n\in\mathbb{N}}$ der zugehörigen Bernstein-Polynome gleichmäßig auf $[0,1]$ gegen f konvergiert. Die Bedeutung dieses probabilistischen Ansatzes für einen Beweis des Approximationssatzes von Weierstrass liegt im kanonischen Auffinden der explizit angebbaren Polynomfolge $(B_n^f)_{n\in\mathbb{N}}$.

Wir betrachten eine weitere Anwendung des schwachen Gesetzes der großen Zahlen:

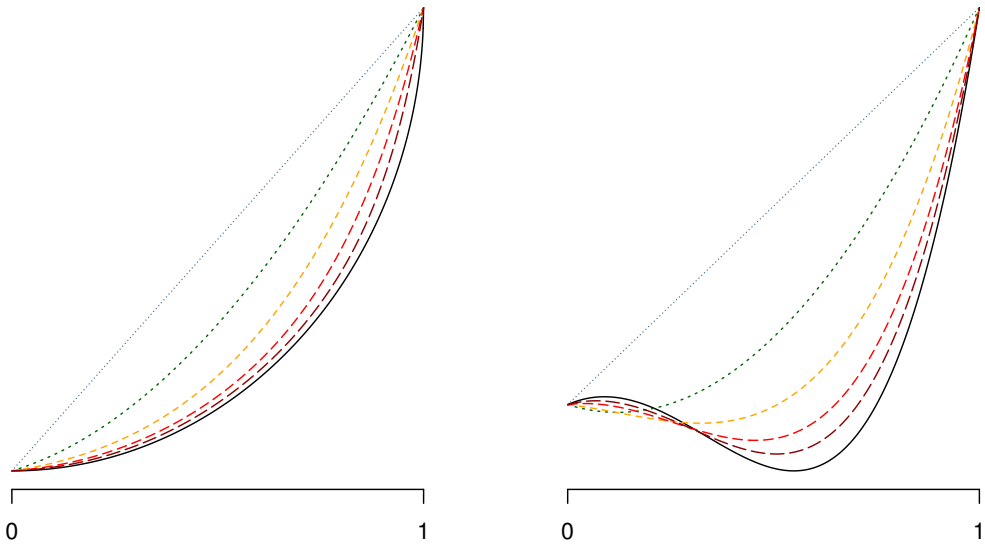

Abb. 12.2: Die BERNSTEIN-Polynome $B_{2^n}^f(x)$ für $n = 0, \ldots, 4$ für zwei Funktionen f (durchgezogen)

12.3.12 Beispiel: (vorteilhaftes Spiel, bei dem man auf Dauer verliert)
Ein Spiel heißt *fair*, wenn in jeder Runde der erwartete Verlust gleich dem erwarteten Gewinn ist. Ist der erwartete Gewinn jeweils größer, heißt das Spiel *vorteilhaft.* Überraschend mag nun sein, dass es vorteilhafte Spiele gibt, bei denen man auf Dauer verliert. Ein erstes bekanntes Beispiel dieser Bauart wurde bereits 1945 von WILLIAM FELLER (1906–1970) gegeben. Wir betrachten hier ein von KRENGEL ausgearbeitetes Beispiel.

Es sei $X_0 = 1$ das Startkapital. Man wirft in jeder Runde eine faire Münze. Das Kapital X_n nach der n-ten Runde sei $X_{n-1}/2$, wenn Kopf im n-ten Wurf fällt, sonst $5X_{n-1}/3$ (man gewinnt Zweidrittel des Kapitalstandes hinzu).

Somit ist das Spiel vorteilhaft: Mit

$$Y_n := \begin{cases} 1/2 & \text{bei Kopf im } n\text{-ten Wurf} \\ 5/3 & \text{sonst} \end{cases}$$

folgt die Darstellung

$$X_n = Y_1 \cdot Y_2 \cdot \ldots \cdot Y_n.$$

Bei einem Kapital von x nach n Runden ist das erwartete Kapital eine Runde später

$$\mathbb{E}(x \cdot Y_{n+1}) = x\mathbb{E}(Y_{n+1}) = \left(\frac{1}{2} \cdot \frac{1}{2} + \frac{1}{2} \cdot \frac{5}{3}\right) \cdot x = \frac{13}{12} \cdot x.$$

Der Gewinn ist also $x/12$. Aus der Unabhängigkeit der Y_i folgt

$$\mathbb{E}(X_n) = \prod_{i=1}^{n} \mathbb{E}(Y_i) = (13/12)^n \to \infty.$$

Das schwache Gesetz der großen Zahlen liefert nun aber eine Überraschung. Es bezeichne μ den Erwartungswert von $\ln(Y_i)$, dann besagt das schwache Gesetz der großen Zahlen:

$$P\left(\left|\frac{1}{n}\Big[\ln(Y_1) + \cdots + \ln(Y_n)\Big] - \mu\right| \geq \varepsilon\right) \to 0$$

für jedes $\varepsilon > 0$. Dies gilt insbesondere für $\varepsilon = -\mu/2$, denn $\mu = (\ln(1/2) + \ln(5/3))/2 = \frac{1}{2}\ln(5/6) < 0$. Also ist

$$\begin{aligned} & P\left(X_n > \exp\left(\frac{\mu n}{2}\right)\right) = P\left(\frac{1}{n}\ln(X_n) - \mu > -\mu/2\right) \\ \leq\ & P\left(\left|\frac{1}{n}\Big[\ln(Y_1) + \cdots + \ln(Y_n)\Big] - \mu\right| > -\mu/2\right) \to 0. \end{aligned}$$

Also ist mit großer Wahrscheinlichkeit das Kapital $X_n \leq \exp(\mu n/2) = (5/6)^{n/4}$, was gegen Null strebt. Der Kapitalstand strebt also auf lange Sicht ziemlich schnell gegen Null. Der Erwartungswert beschreibt hier die Situation nicht vollständig. Er wird zwar groß, ist aber durch Ausreißer bestimmt. Wahrscheinlichere Ausgänge des Experiments beeinflussen ihn nur wenig.

Zum Abschluss sei ein viel diskutiertes Beispiel erwähnt.

12.3.13 Beispiel: (Petersburger Paradoxon) An der Akademie von St. Petersburg wurde 1730 eine Arbeit veröffentlicht, in der Daniel Bernoulli (1700–1784) ein Problem formuliert, welches sein Cousin Nikolaus Bernoulli (1687–1759) im Jahre 1727 diskutiert hatte (beide sind Neffen von Jakob Bernoulli).

Man wirft eine faire Münze solange, bis zum ersten mal Kopf fällt. Erfolgt dies beim r-ten Wurf, so erhält der Spieler von der Bank 2^r Geldeinheiten. Wieviel Einsatz soll ein Spieler einbringen, um ein gerechtes Spiel zu erreichen? Gerecht meint hier, dass der Mittelwert des reinen Gewinns 0 ist. Durchschnittlich muss die Bank

$$\frac{1}{2} \cdot 2 + \frac{1}{4} \cdot 4 + \frac{1}{8} \cdot 8 + \cdots$$

Geldeinheiten zahlen, was ein unendlich großer Betrag ist. Also wäre ein unendlich großer Einsatz angemessen. Dies scheint auf den ersten Blick überraschend. Doch kann das Spiel zu einem gerechten Spiel gemacht werden, sobald man den Einsatz abhängig von der Anzahl der Würfe wählt. Dies zeigte FELLER:

Er bezeichnet ein Spiel mit Einsatz e_n (damit ist der bis zum n-ten Wurf angesammelte Gesamteinsatz gemeint) als fair, wenn für jedes $\varepsilon > 0$ gilt:

$$P\left(\left|\frac{S_n}{e_n} - 1\right| > \varepsilon\right) \to 0,$$

wobei $S_n := X_1 + \cdots + X_n$ die Summe der Gewinnauszahlungen der ersten n Spiele bezeichnet. FELLER zeigte: Das Petersburger Spiel ist fair, wenn man $e_n := n \log_2(n)$ wählt. Wir wollen dieses modifizierte schwache Gesetz der großen Zahlen für das Petersburger Spiel beweisen. Die Verteilung der Zufallsgröße X_i kennen wir:

$$P(X_i = 2^i) = \frac{1}{2^i},\ i \in \mathbb{N}.$$

Die Zufallsgrößen $X_1, \ldots, X_n$ sind unabhängig, denn wir werfen die Münze unabhängig. Dies ist unsere Modellannahme. Da der Erwartungswert von S_n nicht existiert, existiert auch die Varianz nicht. Wir können also die TSCHEBYSCHEV-Ungleichung nicht anwenden, zumindest nicht direkt. Daher versuchen wir die Zufallsgrößen geschickt abzuschneiden. Dabei heißt abschneiden, dass wir die gegebene Zufallsgröße X_i durch den Wert Null ersetzen, wenn sie zu große Werte annimmt. Geschickt bedeutet einfach eine geeignete Wahl von *zu großem Wert* zu treffen, es also so zu wählen, dass ein schwaches Gesetz der großen Zahlen herauskommt. Wir haben schon verraten, dass $e_n = n \log_2(n)$ geeignet sein wird. Dies begründen wir nun im Detail.

Wir führen die folgenden Zufallsgrößen ein:

$$U_k := X_k \, 1_{\{X_k \le e_n\}}$$

und

$$V_k := X_k \, 1_{\{X_k > e_n\}}.$$

Dann ist U_k die abgeschnittene Zufallsgröße. Sie nimmt den Wert Null an, sobald die Zufallsgröße X_k Werte oberhalb e_n annimmt. Nun gilt

$$X_k = X_k \, 1_{\{X_k \le e_n\}} + X_k \, 1_{\{X_k > e_n\}} = U_k + V_k$$

für jedes $k \in \mathbb{N}$. Damit ist

$$S_n = \sum_{i=1}^{n} X_i = \sum_{i=1}^{n} U_i + \sum_{i=1}^{n} V_i.$$

Nun betrachten wir eine in der ersten Begegnung kompliziert wirkende Mengenzerlegung. Es gilt mit $T_n := \sum_{i=1}^n V_i$:

$$\{|S_n - e_n| > \varepsilon \cdot e_n\} = \{|S_n - e_n| > \varepsilon \cdot e_n\} \cap \Big(\{T_n \neq 0\} \cup \{T_n = 0\}\Big).$$

Daraus folgt

$$\{|S_n - e_n| > \varepsilon \cdot e_n\} \subseteq \{T_n \neq 0\} \cup \Big(\{T_n = 0\} \cap \Big\{\Big|\sum_{i=1}^n U_i - e_n\Big| > \varepsilon \cdot e_n\Big\}\Big),$$

und somit

$$P\Big(|S_n - e_n| > \varepsilon \cdot e_n\Big) \leq P(V_1 + \cdots + V_n \neq 0) + P\Big(|U_1 + \cdots + U_n - e_n| > \varepsilon \cdot e_n\Big). \quad (12.7)$$

Im zweiten Summanden stehen die abgeschnittenden Zufallsgrößen, die nach Satz 10.2.3 unabhängig sind. Das Abschneiden birgt die Hoffnung, dass nun der Erwartungswert und die Varianz der U_i existiert und wir die Tschebyschev-Ungleichung anwenden können. Ein geeignetes Abschneiden ist gefunden worden, wenn damit der zweite Term in (12.7) verschwindet, aber auch der erste Term im Limes für $n \to \infty$ gegen Null konvergiert. Wir untersuchen zunächst den ersten Term in (12.7). Wir erhalten

$$\begin{aligned} P(V_1 + \cdots + V_n \neq 0) &= P\Big(\bigcup_{i=1}^n \{V_i \neq 0\}\Big) \\ &\leq \sum_{i=1}^n P\Big(X_i > n \log_2(n)\Big) \\ &= nP\Big(X_1 > n \log_2(n)\Big) = n\, 2^{-a_n} \end{aligned}$$

mit $a_n := \lfloor \log_2(e_n) \rfloor$. Nun ist $n\, 2^{-a_n} \leq \frac{2}{\log_2(n)}$. Also folgt

$$\lim_{n \to \infty} P(V_1 + \cdots + V_n \neq 0) = 0.$$

Nun wollen wir den zweiten Term in (12.7) untersuchen. Hierzu bestimmen wir die Verteilung der U_i sowie $\mathbb{E}(U_i)$ und $\mathbb{V}(X_i)$. Es gilt

$$P(U_i = 0) = 2^{-a_n}, \quad P(U_i = 2^k) = 2^{-k}, k = 1, \cdots, a_n.$$

Daher ist

$$\mathbb{E}(U_i) = 0 \cdot 2^{-a_n} + \sum_{j=1}^{a_n} 2^j \cdot 2^{-j} = a_n$$

und

$$\mathbb{E}(U_i^2) = \sum_{j=1}^{a_n} 2^{2j} \cdot 2^{-j} = \sum_{j=1}^{a_n} 2^j = 2^{a_n+1} - 2 \leq 2e_n.$$

Somit ist $\sum_{i=1}^n \mathbb{E}(U_i) = n\,a_n$ und wegen der Unabhängigkeit der U_i's

$$\mathbb{V}\Big(\sum_{i=1}^n U_i\Big) = \sum_{i=1}^n \mathbb{V}(U_i) \le \sum_{i=1}^n \mathbb{E}(U_i^2) \le 2n\,e_n,$$

da $a_n = \lfloor \log_2(e_n) \rfloor$. Für eine Zufallsvariable X und $\nu > 0$ gilt nach der Dreiecksungleichung (in der Form $|X + a| \ge |X| - |a|$)

$$\{|X| \ge \nu\} \subseteq \{|X + a| > \nu - |a|\}.$$

Also gilt (mit der Substitution $X := U_1 + \cdots + U_n - e_n, a := e_n - na_n, \nu := \varepsilon \cdot e_n$)

$$\begin{aligned} & P\Big(|U_1 + \cdots + U_n - e_n| > \varepsilon \cdot e_n\Big) \\ \le\ & P\Big(|U_1 + \cdots + U_n - n\,a_n| > \varepsilon \cdot e_n - |n\,a_n - e_n|\Big). \end{aligned}$$

Für $\delta_n := \varepsilon \cdot e_n - |n\,a_n - e_n|$ liefert die Tschebyschev-Ungleichung

$$P\Big(|U_1 + \cdots + U_n - e_n| > \varepsilon \cdot e_n\Big) \le \frac{\mathbb{V}(U_1 + \ldots + U_n)}{\delta_n^2} \le \frac{2n\,e_n}{\delta_n^2}.$$

Nun ist

$$\frac{\delta_n}{e_n} = \varepsilon - \left|\frac{n\,a_n - e_n}{e_n}\right| \to \varepsilon,$$

denn

$$\frac{n\,a_n}{e_n} = \frac{\lfloor \log_2(n \log_2(n)) \rfloor}{\log_2(n)} \to 1$$

für $n \to \infty$. Also folgt

$$\frac{2n\,e_n}{\delta_n^2} = \frac{2n}{e_n(\delta_n/e_n)^2} \to 0.$$

Damit ist das schwache Gesetz von Feller bewiesen.

Lösungen der Aufgaben

Lösungen der Aufgaben in 12.1

Aufgabe 12.1.4

Nach Definition 11.1.4 liegt ein diskreter Wahrscheinlichkeitsraum (Ω, p) sowie eine Zufallsvariable X mit endlich vielen Werten $X(\Omega) = \{x_1, ..., x_k\}$ und $P(X = x_i)$ für alle $i = 1, ..., k$ vor. Dann ist $\mathbb{E}(X) = \bar{x}$ und

$$P\Big(\{|X - \bar{x}| \geq \varepsilon\}\Big) = r(j : |x_j - \bar{x}| \geq \varepsilon),$$

wobei $r(A)$ die relative Häufigkeit einer Teilmenge A beschreibt. Nun ist nach der Ungleichung von Tschebyschev

$$P\Big(|X - \mathbb{E}(X)| \geq \varepsilon\Big) = P\Big(|X - \bar{x}| \geq \varepsilon\Big) \leq \frac{\mathbb{V}(X)}{\varepsilon^2},$$

also

$$r([\bar{x} - \varepsilon, \bar{x} + \varepsilon]) > 1 - \frac{\mathbb{V}(X)}{\varepsilon^2}.$$

Da $\mathbb{V}(X) = \frac{1}{k}\sum_{j=1}^{k}(x_j - \bar{x})^2$, folgt die Aussage in Satz 3.2.12.

Lösungen der Aufgaben in 12.3

Aufgabe 12.3.5

Es sei $a = 0$: Es gilt $\lim\limits_{n\to\infty} = \frac{r_n}{s_n} = 0$, d.h. der Anteil s_n der schwarzen Kugeln wächst schneller als der Anteil r_n der roten Kugeln. Man betrachtet beide Summanden auf der rechten Seite von (12.5) getrennt.

$$\lim_{n\to\infty} \frac{1}{\varepsilon^2}\left(\frac{r_n(r_n - 1)}{(r_n + s_n)(r_n + s_n - 1)} - \frac{r_n^2}{(r_n + s_n)^2}\right) = 0,$$

da $0 \leq \frac{r_n}{s_n+r_n} \leq \frac{r_n}{s_n}$, und somit $\frac{r_n}{s_n+r_n}$ auch eine Nullfolge ist. Nun betrachtet man den ersten Summanden: Es gilt

$$0 \leq \frac{r_n\, s_n}{(r_n+s_n)^2}\frac{1}{\varepsilon^2 n} \leq \frac{2}{\varepsilon^2 n},$$

und damit konvergiert auch der erste Summand gegen Null für $n \to \infty$.

Es sei $0 < a < \infty$: Auch hier ist die Konvergenz der rechten Seite von (12.5) gegen Null für $n \to \infty$ zu zeigen. Nun gilt

$$\lim_{n\to\infty} \frac{r_n}{r_n+s_n} = \frac{a}{a+1} \quad \text{und} \quad \lim_{n\to\infty} \frac{s_n}{r_n+s_n} = \frac{1}{a+1},$$

also

$$\lim_{n\to\infty} \frac{r_n\, s_n}{(r_n+s_n)^2} = \frac{a}{(a+1)^2},$$

womit

$$\lim_{n\to\infty} \frac{r_n s_n}{(r_n+s_n)^2}\frac{1}{\varepsilon^2 n} = 0.$$

Für die Untersuchung des zweiten Summanden stellen wir fest, dass gilt

$$\lim_{n\to\infty} \left(\frac{r_n(r_n-1)}{(r_n+s_n)(r_n+s_n-1)}\right) = \lim_{n\to\infty} \left(\frac{r_n^2}{(r_n+s_n)^2}\right) = \frac{a^2}{(a+1)^2}.$$

Damit ist auch der zweite Summand eine Nullfolge in n.

Aufgabe 12.3.6

Es gilt $|X_n| \leq |X_n - n\,p_n| + n\,p_n$ und somit zu jedem vorgegebenem $\varepsilon > 0$ die Inklusion

$$\{|X_n| \geq \varepsilon\} \subseteq \{|X_n - n\,p_n| + n\,p_n \geq \varepsilon\} \subseteq \{|X_n - n\,p_n| \geq \varepsilon/2\}$$

für ein genügend großes n: Denn wegen $\lim_{n\to\infty} n\,p_n = 0$ existiert zu vorgegebenem $\varepsilon > 0$ ein n_0 mit $n\,p_n < \varepsilon/2$ für jedes $n \geq n_0$. Für diese n gilt somit

$$P\Big(|X_n| \geq \varepsilon\Big) \leq P\Big(|X_n - n\,p_n| \geq \varepsilon/2\Big).$$

Mithilfe der Tschebyschev-Ungleichung gilt

$$P\Big(|X_n - n\,p_n| \geq \varepsilon/2\Big) \leq \frac{\mathbb{V}(X_n)}{(\varepsilon/2)^2} = \frac{4n\,p_n(1-p_n)}{\varepsilon^2}.$$

Damit und mit $\lim\limits_{n\to\infty} n\,p_n = 0$ folgt $\lim\limits_{n\to\infty} P\Big(|X_n| \geq \varepsilon\Big) = 0$ für jedes $\varepsilon > 0$.

Aufgabe 12.3.7

Es seien $X_1, ..., X_n$ BERNOULLI-verteilte Zufallsgrößen zum Parameter $p = 1/2$, welche jeweils den Wert 1 annehmen, wenn das Gasmolekül in der linken Hälfte ist, und 0 sonst. Dann gilt aus Symmetriegründen und nach der TSCHEBYSCHEV-Ungleichung

$$\begin{aligned} P\left(\frac{1}{n}\sum_{i=1}^{n} X_i \geq \frac{1+10^{-8}}{2}\right) &= \frac{1}{2}P\left(\left|\frac{1}{n}\sum_{i=1}^{n} X_i - \frac{1}{2}\right| \geq 5\cdot 10^{-9}\right) \\ &\leq \frac{1}{2}\frac{1/4}{n\,(5\cdot 10^{-9})^2} = \frac{1}{2}\frac{1}{n\,10^{-16}} = 2\cdot 10^{-7}. \end{aligned}$$

Diese Wahrscheinlichkeit ist so klein, dass die hinterfragten Abweichungen nicht beobachtet werden. Tatsächlich ist die Abweichung extrem viel kleiner. Die Abschätzung mithilfe der TSCHEBYSCHEV-Ungleichung ist ziemlich grob. Eine bessere Abschätzung, die in Kapitel 13 thematisiert wird, liefert die unvorstellbar kleine Schranke $10^{-1500000}$.

Kapitel 13

Starkes Gesetz der großen Zahlen, Runs

In diesem Kapitel leiten wir zunächst im Fall des Bernoulli-Experiments eine wesentliche Verbesserung der Abschätzung her, die man mittels der Tschebyschev-Ungleichung erhält. Zur Erinnerung: Die Tschebyschev-Ungleichung lieferte

$$P\left(\left|\frac{S_n}{n} - p\right| \geq \varepsilon\right) \leq \frac{p(1-p)}{\varepsilon^2 n} \tag{13.1}$$

für jedes $\varepsilon > 0$. Eine Verbesserung dieser Abschätzung basiert auf einem Ansatz von Bernstein, der geschickt die Markov-Ungleichung verwendete. Bei den Rechnungen tritt eine sehr wichtige Funktion auf, die man die *relative Entropie* nennt. Ihr asymptotisches Verhalten wird in späteren Kapiteln maßgeblich die Untersuchung der Binomialverteilung bestimmen. Die verbesserte Abschätzung wird verwendet, um ein starkes Gesetz der großen Zahlen für das Bernoulli-Experiment herzuleiten. Sie dient auch zur Herleitung eines weiteren Gesetzes der großen Zahlen, welches bei der Untersuchung von Erfolgsketten, sogenannten *Runs*, einen interessanten Einblick in das Verhalten eines Bernoulli-Experiments gibt.

13.1 Exponentielle Abschätzungen und die relative Entropie

Wir untersuchen, wie schnell die Folge im schwachen Gesetz der großen Zahlen gegen Null konvergiert.

Es sei S_n die Anzahl der „Kopf“-Würfe nach n Würfen. Für den symmetrischen

Münzwurf $p = 1/2$ mit $\varepsilon = 1/10$ und $n = 1000$ folgt aus (13.1)

$$P\Big(\Big|\frac{S_{1000}}{1000} - \frac{1}{2}\Big| \geq \frac{1}{10}\Big) \leq \frac{1}{40}.$$

Diese Abschätzung liegt jedoch um Größenordnungen über dem Wert der Wahrscheinlichkeit. Eine bessere Abschätzung erhält man auf die folgende Weise:

Sei $\lambda > 0$. Wir wenden die Markov-Ungleichung 12.1.1 für die Zufallsvariable $X = e^{\lambda(S_n - np)}$ und für die monotone Funktion $\phi(x) = x$ an. Es gilt

$$P(S_n - np \geqslant \alpha) = P\left(\left|e^{\lambda(S_n-np)}\right| \geqslant e^{\alpha\lambda}\right) \leqslant \frac{\mathbb{E}\left(\left|e^{\lambda(S_n-np)}\right|\right)}{e^{\alpha\lambda}} = e^{-\alpha\lambda}\mathbb{E}\left(e^{\lambda(S_n-np)}\right),$$

wobei der Erwartungswert auf der rechten Seite existiert, da S_n nur endlich viele Werte annimmt. Dies ist der Ansatz von Bernstein. Um diesen Erwartungswert auszuwerten, schreiben wir $\lambda(S_n - n\,p) = \sum_{i=1}^n \lambda(X_i - p)$, wobei $X_1, \ldots, X_n$ die unabhängigen Zufallsgrößen mit $P(X_i = 1) = p$ und $P(X_i = 0) = 1 - p$ sind, die die Ergebnisse der einzelnen Würfe beschreiben. Da die X_i unabhängig sind, folgt die Unabhängigkeit der $e^{\lambda(X_i - p)}$ aus Satz 10.2.3. Demnach folgt aus der Bemerkung 11.2.24 für jedes $\lambda > 0$

$$P\Big(S_n - n\,p \geq \alpha\Big) \leq e^{-\alpha\lambda} \prod_{i=1}^n \mathbb{E}\Big(e^{\lambda(X_i-p)}\Big) = e^{-\alpha\lambda}\Big(\mathbb{E}\Big(e^{\lambda(X_1-p)}\Big)\Big)^n. \tag{13.2}$$

Nun ist $|X_1 - p| \leq 1$ und $\mathbb{E}(X_1 - p) = 0$. Da die Funktion ϕ_λ konvex ist, ist sie im Intervall $[-1, 1]$ durch die Sekante, die die Punkte $(-1, e^{-\lambda})$ und $(1, e^{\lambda})$ verbindet, nach oben beschränkt:

$$e^{\lambda x} \leq \frac{e^{\lambda} + e^{-\lambda}}{2} + \frac{e^{\lambda} - e^{-\lambda}}{2}\,x = \cosh(\lambda) + \sinh(\lambda)x.$$

Eine Illustration für $\lambda = 2$ sehen Sie in Abb. 13.1. Aus der Monotonie des Erwartungswertes folgt also

$$\mathbb{E}\Big(e^{\lambda(X_1-p)}\Big) \leq \cosh(\lambda) + \sinh(\lambda)\,\mathbb{E}(X_1 - p) = \cosh(\lambda).$$

Jetzt nutzen wir noch die Ungleichung $\cosh(\lambda) \leq e^{\lambda^2/2}$ aus. Sie ergibt sich unmittelbar aus den Potenzreihenentwicklungen

$$\exp(x) = \sum_{k=0}^{\infty} \frac{x^k}{k!} \quad \text{und} \quad \cosh(x) = \sum_{k=0}^{\infty} \frac{x^{2k}}{(2k)!}.$$

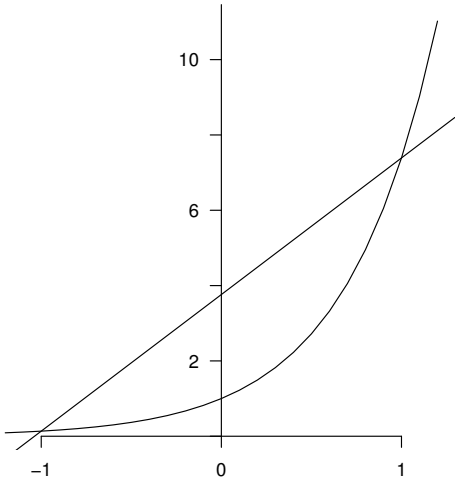

Abb. 13.1: Graphen der Funktionen $x \mapsto x$ und $x \mapsto e^{2x}$.

Wir erhalten

$$P\Big(S_n - n\,p \geq \alpha\Big) \leq e^{-\alpha\lambda} e^{n\lambda^2/2}$$

für jedes $\lambda > 0$. Wir wollen nun $\lambda > 0$ so wählen, dass wir eine möglichst gute obere Abschätzung erhalten, d.h., wir bestimmen das Minimum der Funktion $f(\lambda) = -\alpha\lambda + n\lambda^2/2$. Eine einfache Rechnung ergibt, dass das Minimum bei $\lambda = \frac{\alpha}{n}$ angenommen wird. Einsetzen von $\lambda = \frac{\alpha}{n}$ liefert

$$P\Big(S_n - n\,p \geq \alpha\Big) \leq e^{-\alpha^2/(2n)}.$$

Wir haben also eine Abschätzung erhalten, die nicht vom Parameter p abhängt. Dies ist, wie wir weiter unten sehen, nicht unbedingt von Vorteil. Halten wir dieses Ergebnis, welches Wassily Hoeffding (1914–1991) im Jahre 1963 in einer grundlegenden Arbeit lieferte, fest:

13.1.1 Satz: (Hoeffding-Ungleichung) Bezeichnet S_n die Anzahl der „Kopf"-Würfe nach n Würfen bei einem Bernoulli-Experiment zu den Parametern n und p, so gilt:

$$P\Big(S_n - n\,p \geq \alpha\Big) \leq e^{-\alpha^2/(2n)}.$$

Was hat uns die Anstrengung gebracht? Es folgt aus der Hoeffding-Ungleichung:

$$P\Big(\frac{S_n}{n} - p \geq \alpha\Big) = P\Big(S_n - np \geq n\alpha\Big) \leq e^{-n\alpha^2/2}.$$

Für den symmetrischen Münzwurf sind „Kopf“ und „Zahl“ gleich wahrscheinlich, also gilt

$$P\Big(S_n - \frac{n}{2} \geq \alpha n\Big) = P\Big(S_n - \frac{n}{2} \leq -\alpha n\Big)$$

und somit

$$P\Big(\Big|\frac{S_n}{n} - \frac{1}{2}\Big| \geq \alpha\Big) = P\Big(\Big|S_n - \frac{n}{2}\Big| \geq \alpha n\Big) = 2P\Big(S_n - \frac{n}{2} \geq \alpha n\Big) \leq 2e^{-n\alpha^2/2}.$$

Für $\alpha = 1/10$ und $n = 1000$ erhalten wir dann als Schranke $2e^{-5} < 1/40$.

Eine genauere Analyse des Beweises führt aber recht schnell zu einer wesentlichen Verbesserung unserer exponentiellen Ungleichung. In der obigen Rechnung haben wir zunächst den Erwartungswert $\mathbb{E}(e^{\lambda X})$ einer durch 1 beschränkten Zufallsgröße X nach oben abgeschätzt und anschließend das Resultat im „freien“ Parameter λ optimiert. Nun optimieren wir einfach direkt die aus dem Bernstein-Ansatz gewonnene Abschätzung. Wir untersuchen nun

$$P\Big(\frac{S_n}{n} \geq p + \alpha\Big),\ 0 < \alpha \leq 1 - p.$$

Wir bemerken, dass für $\alpha > 1 - p$ die obige Wahrscheinlichkeit Null ist. Wir ersetzen in (13.2) α durch $\alpha\, n$ und erhalten

$$P\Big(S_n - n\,p \geq \alpha\, n\Big) \leq e^{-\alpha\, n\, \lambda} \prod_{i=1}^{n} \mathbb{E}\Big(e^{\lambda(X_i - p)}\Big) = e^{-\alpha\, n\, \lambda}\Big(\mathbb{E}\Big(e^{\lambda(X_i - p)}\Big)\Big)^n. \tag{13.3}$$

Nun ist

$$\mathbb{E}\Big(e^{\lambda(X_i - p)}\Big) = pe^{\lambda(1-p)} + (1-p)e^{-\lambda p} := M(\lambda).$$

Also folgt

$$P\Big(\frac{S_n}{n} - p \geq \alpha\Big) \leq \exp\Big(n\big[-\alpha\lambda + \ln(M(\lambda))\big]\Big).$$

Diese Abschätzung gilt für jedes $\lambda > 0$, also folgt

$$P\Big(\frac{S_n}{n} - p \geq \alpha\Big) \leq \exp\Big(n \inf_{\lambda > 0}\big[-\alpha\lambda + \ln(M(\lambda))\big]\Big).$$

Setze $f(\lambda) := -\alpha\lambda + \ln(M(\lambda))$. Wir bestimmen das Infimum über f. Dazu bestimmen wir die ersten beiden Ableitungen. Es gilt

$$f'(\lambda) = -\alpha + \frac{M'(\lambda)}{M(\lambda)} = -\alpha + p(1-p)\frac{e^\lambda - 1}{pe^\lambda + (1-p)}$$

und

$$f''(\lambda) = \frac{M''(\lambda)}{M(\lambda)} - \left(\frac{M'(\lambda)}{M(\lambda)}\right)^2 = \frac{p(1-p)e^\lambda}{(pe^\lambda + (1-p))^2} > 0$$

für alle $\lambda > 0$ und alle $0 < p < 1$. Demzufolge ist $f'(\lambda)$ streng monoton steigend. Weiter ist $\lim_{\lambda\to 0} f'(\lambda) = -\alpha < 0$ und $\lim_{\lambda\to\infty} f'(\lambda) = -\alpha + 1 - p \geq 0$. Wenn nun nicht gerade $\alpha = 1 - p$ ist, existiert also eine eindeutig bestimmte Nullstelle λ_0 der Funktion $\lambda \mapsto f'(\lambda)$ auf $\mathbb{R}^+$. An dieser Stelle nimmt f ihr Minimum an. Im speziellen Fall $\alpha = 1 - p$ ist

$$\inf_{\lambda>0} \Big[-\alpha\lambda + \ln(M(\lambda)) \Big] = \lim_{\lambda\to\infty} \Big[-\alpha\lambda + \ln(M(\lambda)) \Big] = \ln(p).$$

Im Fall $\alpha < 1 - p$ führt die Bestimmung $f'(\lambda_0) = 0$ nach einer Nebenrechnung zu

$$\lambda_0 = \ln \frac{(1-p)x}{p(1-x)},$$

wobei $x := \alpha + p$. Einsetzen in f liefert, ebenfalls nach einer Nebenrechnung,

$$f(\lambda_0) = x \ln \frac{p}{x} + (1-x) \ln \frac{1-p}{1-x}.$$

Wir fassen unsere Rechnungen zusammen:

13.1.2 Satz: Für die Anzahl S_n der Erfolge in einem Bernoulli-Experiment der Länge n mit Erfolgswahrscheinlichkeit $p \in (0,1)$ gilt für jedes x mit $x \in [p,1]$:

$$P\left(\frac{S_n}{n} \geq x\right) \leq \exp(-nH(x|p)),$$

wobei

$$H(x|p) := -x \ln \frac{p}{x} - (1-x) \ln \frac{1-p}{1-x}, \quad x \in (0,1),$$

$H(0|p) := -\ln(1-p)$ und $H(1|p) := -\ln(p)$. Analog gilt für $x \in [0,p]$

$$P\left(\frac{S_n}{n} \leq x\right) \leq \exp(-nH(x|p)).$$

Weiter ist $H(x|p) \geq 0$ und $H(x|p) = 0$ genau dann, wenn $x = p$ gilt.

Beweis: Wir haben in unserer Herleitung die erste Abschätzung für jedes $x \in (p,1]$ gezeigt. Für $x = p$ ist aber $H(x|p) = 0$, womit die Ungleichung natürlich in diesem Fall auch gilt. Die Herleitung der zweiten Ungleichung für $x \leq p$ folgt analog und ist eine gute Übung. Die Eigenschaften von $H(\cdot|p)$ folgen aus der Definition. Auch dies ist eine gute Übung. □

13.1.3 Aufgabe: Beweisen Sie alle Details in Satz 13.1.2, die nicht explizit ausgeführt wurden.

Natürlich stellen wir die Frage, was uns diese Anstrengung gebracht hat. Für den symmetrischen Münzwurf gilt

$$P\Big(\Big|\frac{S_n}{n}-\frac{1}{2}\Big|\geq\alpha\Big)=2P\Big(\frac{S_n}{n}\geq\alpha+\frac{1}{2}\Big)\leq 2\exp\Big(-nH\Big(\alpha+\frac{1}{2}\Big|\frac{1}{2}\Big)\Big)$$

für alle $\alpha\in(0,\frac{1}{2})$. Der Graph von $I(\alpha):=H\Big(\alpha+\frac{1}{2}\Big|\frac{1}{2}\Big)$ ist in Abb.13.2 gegeben.

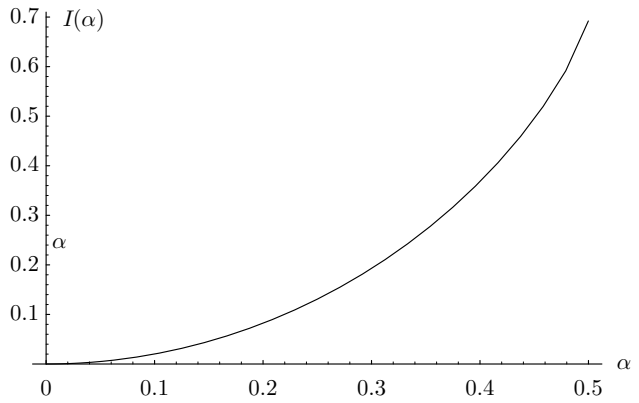

Abb. 13.2: Der Graph von $I(\alpha):=H\Big(\alpha+\frac{1}{2}\Big|\frac{1}{2}\Big)$.

Für $\alpha=1/10$ und $n=1000$ erhalten wir zum Beispiel

$$P\Big(\Big|\frac{S_{1000}}{1000}-\frac{1}{2}\Big|\geq\frac{1}{10}\Big)\leq 2\Big(\frac{5}{6}\Big)^{600}\Big(\frac{5}{4}\Big)^{400}\leq 3.6\cdot 10^{-9},$$

was phantastisch viel besser ist als 1/40 aus der Tschebyschev-Ungleichung oder $2e^{-5}$ aus der Hoeffding-Ungleichung.

Die Abschätzung in Satz 13.1.2 ist immer besser als die in Satz 13.1.1. Dazu zeigt man $H(\alpha+p|p)\geq\alpha^2/2$ für alle $\alpha>0$. Da $H(0+p|p)=0$, folgt dies aus der Tatsache, dass die zweite Ableitung von $H(\alpha+p|p)$ nach α immer größer als 1 ist.

13.1.4 Definition: Die Funktion $H(\cdot|p)$, definiert für alle $x\in[0,1]$ heißt die *relative Entropie*. Der Wert $H(x|p)$ heißt dann die relative Entropie von x bezüglich p.

Wir geben an dieser Stelle die TAYLOR-Entwicklung der relativen Entropie an. Mit ihrer Hilfe kann man beweisen, dass die obere Abschätzung in Satz 13.1.2 immer besser ist als die obere Abschätzung in Satz 13.1.1.

13.1.5 Satz: Die relative Entropie $H(\cdot|p)$ ist auf dem offenen Intervall $(0,1)$ analytisch. Die k-te Ableitung für $k \geq 2$ ist

$$H^{(k)}(x|p) = \frac{(-1)^k (k-2)!}{x^{k-1}} + \frac{(k-2)!}{(1-x)^{k-1}}$$

und die erste Ableitung

$$H'(x|p) = \ln \frac{x}{p} - \ln \frac{1-x}{1-p}.$$

Ferner gilt die Ungleichung

$$|H^{(k)}(x|p)| \leq (k-2)! \left(\frac{1}{x^{k-1}} + \frac{1}{(1-x)^{k-1}} \right), \ k \geq 2.$$

In einem Kurs zu mathematischen Grundlagen wird der Begriff *analytisch* nicht definiert. Analytisch sein bedeutet, um jeden Punkt des Definitionsbereichs in eine Potenzreihe entwickelbar zu sein. Genauer: Ist f eine auf einem offenen Intervall I definierte reellwertige Funktion. Dann heißt f *analytisch* (in I), wenn es zu jedem $x_0 \in I$ ein $r(x_0) > 0$ gibt mit $(x_0 - r(x_0), x_0 + r(x_0)) \subseteq I$ und eine Potenzreihe $\sum_k a_k x^k$, die mindestens in allen Punkten in $(x_0 - r(x_0), x_0 + r(x_0))$ konvergiert, sodass

$$f(x) = \sum_{k=0}^{\infty} a_k (x - x_0)^k$$

für alle $x \in (x_0 - r(x_0), x_0 + r(x_0))$ gilt.

13.1.6 Aufgabe: Zeigen Sie Satz 13.1.5.

13.1.7 Aufgabe: Zeigen Sie: $H(\cdot|p)$ ist stetig, streng monoton wachsend für $x > p$ und streng monoton fallend für $x < p$.

Eine natürliche Frage ist, ob wir die Güte der Abschätzung in Satz 13.1.2 noch verbessern können, also durch geschickte Techniken das Resultat noch verbessern können. Die Antwort auf diese Frage ist im Fall des BERNOULLI-Experimentes, aber auch in vielen anderen Fällen, in denen ein schwaches Gesetz der großen Zahlen zugrundeliegt, nein. Dies wollen wir im Fall des BERNOULLI-Experimentes mit $p = \frac{1}{2}$ beweisen. Das technische Hilfsmittel ist die STIRLING-Approximation, Satz 7.0.1.

13.1.8 Satz: (Ein Prinzip großer Abweichungen für den fairen Münzwurf) Bezeichnet S_n die Anzahl der „Kopf"-Würfe nach n Würfen bei einem BERNOULLI-Experiment zu den Parametern n und $p = \frac{1}{2}$, so gilt für alle $a \geq \frac{1}{2}$:

$$\lim_{n\to\infty} \frac{1}{n} \ln P\Big(\frac{S_n}{n} \geq a\Big) = -H\Big(a\Big|\frac{1}{2}\Big).$$

Hierbei ist $H(x|\frac{1}{2}) := \infty$ für $x \notin [0,1]$.

Beweis: Zunächst betrachten wir den Fall $a > 1$. Hier ist $P\Big(\frac{S_n}{n} \geq a\Big) = 0$, also gilt die Aussage.

Für $a = 1$ gilt

$$\begin{aligned}\lim_{n\to\infty} \frac{1}{n} \ln P\Big(\frac{S_n}{n} \geq 1\Big) &= \lim_{n\to\infty} \frac{1}{n} \ln P\big(S_n = n\big)\\ &= \lim_{n\to\infty} \frac{1}{n} \ln\Big(\frac{1}{2}\Big)^n\\ &= \ln\frac{1}{2} \;=\; -H\Big(1\Big|\frac{1}{2}\Big).\end{aligned}$$

Für $a \in (\frac{1}{2}, 1)$ gilt

$$P\Big(\frac{S_n}{n} \geq a\Big) = \frac{1}{2^n} \sum_{an\leq k\leq n} \binom{n}{k}.$$

Nun betrachten wir die kleinste natürliche Zahl, die größer als $a\cdot n$ ist, und bezeichnen diese mit $g_n(a) := \lceil a\,n\rceil$. Dann ist in der obigen Summe der größte auftretende Binomialkoeffizient

$$Q_n(a) := \max_{an\leq k\leq n} \binom{n}{k} = \binom{n}{g_n(a)},$$

da für $k \geq \frac{n}{2}$ die Zuordnung $k \mapsto \binom{n}{k}$ monoton fallend ist. Damit erhalten wir die Abschätzung

$$\frac{1}{2^n} Q_n(a) \leq P\Big(\frac{S_n}{n} \geq a\Big) \leq (n+1)\frac{1}{2^n} Q_n(a). \tag{13.4}$$

Nun verwenden wir die STIRLING-Formel, Satz 7.0.1:

$$\begin{aligned}&\lim_{n\to\infty} \frac{1}{n} \ln Q_n(a)\\ =\;& \lim_{n\to\infty} \frac{1}{n} \ln \frac{n!}{g_n(a)!\,(n-g_n(a))!}\\ =\;& \lim_{n\to\infty} \frac{1}{n} \ln \frac{\sqrt{2\pi n}\,\left(\frac{n}{e}\right)^n}{\sqrt{2\pi g_n(a)}\,\left(\frac{g_n(a)}{e}\right)^{g_n(a)} \sqrt{2\pi(n-g_n(a))}\,\left(\frac{n-g_n(a)}{e}\right)^{n-g_n(a)}}\end{aligned}$$

$$
\begin{aligned}
&= \lim_{n\to\infty} \frac{1}{n} \ln \frac{n^n}{g_n(a)^{g_n(a)}\,(n-g_n(a))^{n-g_n(a)}} + \lim_{n\to\infty} \frac{1}{2n} \ln \frac{2\pi n}{4\pi^2 g_n(a)(n-g_n(a))} \\
&= \lim_{n\to\infty} \left(\ln(n) - \frac{g_n(a)}{n} \ln\Big(g_n(a)\Big) - \frac{n-g_n(a)}{n} \ln\Big(n-g_n(a)\Big) \right) + 0 \\
&= \lim_{n\to\infty} \Big(\ln(n) - a\ln(na) - (1-a)\ln(n-na) \Big) \\
&= \lim_{n\to\infty} \Big(\ln(n) - a\Big(\ln(a)+\ln(n)\Big) - (1-a)\Big(\ln(1-a)+\ln(n)\Big) \Big) \\
&= -a\,\ln(a) - (1-a)\,\ln(1-a).
\end{aligned}
$$

Nun ist $\lim_{n\to\infty} \frac{1}{n} \ln(2^{-n}) = -\ln(2)$ und

$$\lim_{n\to\infty} \frac{1}{n} \ln \frac{n+1}{2^n} = \lim_{n\to\infty} \frac{1}{n} \ln(n+1) - \ln(2) = -\ln(2).$$

Damit folgt aus (13.4)

$$\lim_{n\to\infty} \frac{1}{n} \ln P\Big(\frac{S_n}{n} \geq a\Big) = -a\,\ln(a) - (1-a)\,\ln(1-a) - \ln(2).$$

Die rechte Seite stimmt mit $-H(a|\frac{1}{2})$ überein und damit ist der Satz bewiesen. □

13.1.9 Bemerkung: Da in obigem Satz $\mathbb{E}(X_1) = \frac{1}{2}$ gilt, betrachten wir dort Abweichungen oberhalb des Erwartungswertes. Die Aussage des Satzes gilt analog für

$$P\Big(\frac{S_n}{n} \leq a\Big)$$

mit $a < \frac{1}{2}$. Dies folgt aus der Symmetrie sowie der Relation $H(1-a|\frac{1}{2}) = H(a|\frac{1}{2})$. Die Details können als Übung ausgeführt werden.

13.1.10 Bemerkung: Die Konvergenzaussage zeigt nun, dass wir die Abschätzung in Satz 13.1.2 nicht verschärfen können (hier gezeigt für $p = \frac{1}{2}$, es gilt aber auch allgemein). Das Prinzip großer Abweichungen wurde in der angegebenen Form von Harald Cramér (1893–1985) im Jahre 1938 bewiesen. Tatsächlich hat die Analyse der Konvergenzgeschwindigkeit beim schwachen Gesetz der großen Zahlen ihren Ursprung schon in der Physik des späten vorletzten Jahrhunderts. Ludwig Boltzmann (1844–1906) betrachtete ein einfaches Modell eines sogenannten idealen Gases. Er teilte gedanklich einen Gasbehälter mit einem festen Volumen in zwei Teilbehälter und dachte sich die Teilchen rein zufällig und unabhängig auf die Teilbehälter verteilt. Bei der Betrachtung der „relativen Häufigkeit“ S_n/n der Teilchen in einem der beiden Teilbehälter kam er zu einem Resultat der Form

$$P\Big(\frac{S_n}{n} \approx p'\Big) \approx \exp(-nH(p'|p)),$$

wenn n die Gesamtzahl der Teilchen bezeichnet. Sei p etwa die Wahrscheinlichkeit eines Teilchens, sich im linken Teilbehälter aufzuhalten. BOLTZMANN erkannte weiter, dass die Abbildung $H(\cdot|p)$ einer Größe entspricht, die in der Thermodynamik und später in der durch ihn mitbegründeten statistischen Mechanik den Namen *Entropie* bekam. Formal entspricht das Prinzip großer Abweichungen dem berühmten BOLTZMANN'schen Gesetz $S = k\ln(W)$, wobei S die Entropie und W die Wahrscheinlichkeit bezeichnet. Hier ist k die bekannte BOLTZMANN-Konstante.

13.2 Ein starkes Gesetz der großen Zahlen

Wie bereits in Kapitel 12.2 angekündigt, wollen wir nun ein *starkes Gesetz der großen Zahlen* im Sinne von (12.3)

$$P\Big(\lim_{n\to\infty} \frac{S_n}{n} \text{ existiert und ist } = E\Big) = 1.$$

beweisen. Es seien $(X_i)_i$ unabhängige Zufallsgrößen mit Werten in $\{0,1\}$ mit $P(X_i = 1) = p$, $p \in (0,1)$. Zur Untersuchung eines Ereignisses der Form wie in (12.3) müssen wir unendlich lange Folgen von Münzwürfen betrachten und wählen daher $\Omega := \{0,1\}^{\mathbb{N}}$. Da nun Ω nicht mehr abzählbar ist, können wir die Wahrscheinlichkeit von Ereignissen nicht gemäß Definition 5.1.4 festlegen. In Ω können Ereignisse eingebettet werden, die nur von endlich vielen Münzwürfen abhängen. Zu $i_1, \ldots, i_n \in \{0,1\}$ sei etwa

$$A_{i_1,\ldots,i_n} := \{\omega \in \Omega : \omega_1 = i_1, \ldots, \omega_n = i_n\}. \tag{13.5}$$

Nun sucht man ein Wahrscheinlichkeitsmaß P auf Ω im Sinne der Definition 5.2.8, sodass dem Ereignis $A_{i_1,\ldots,i_n}$ der vertraute Wert 2^{-n} zugeordnet wird (für $p = 1/2$). Im BERNOULLI-Experiment soll

$$P(A_{i_1,\ldots,i_n}) = p^k(1-p)^{n-k} \tag{13.6}$$

gelten, wobei k wieder die Anzahl der Erfolge beschreibe. Existiert ein derartiges P? Auf der Potenzmenge $\mathcal{P}(\Omega)$ gibt es kein Wahrscheinlichkeitsmaß P, das die KOLMOGOROV'schen Axiome (K1) und (K2) erfüllt (siehe Kapitel 5.2). Es gilt aber das folgende Resultat:

13.2.1 Satz: Auf $\Omega = \{0,1\}^{\mathbb{N}}$ existiert eine σ-Algebra $\mathcal{F} \subset \mathcal{P}(\Omega)$, die alle Mengen der Form (13.5) enthält, und für jedes $p \in [0,1]$ gibt es auf $\mathcal{F}$ ein Wahrscheinlichkeitsmaß $P : \mathcal{F} \to [0,1]$ im Sinne der Definition 5.2.8, sodass (13.6) gilt.

Man wählt im Beweis von Satz 13.2.1 die kleinste σ-Algebra, die die Mengen der Form (13.5) enthält. Wir beweisen den Satz aber nicht, da wir die notwendigen Begriffe und Methoden hier nicht zur Verfügung haben. Wichtig ist, dass man eine Mengenfunktion P auf dem Mengensystem $\mathcal{F}$ hat, in dem sich neue Mengen mithilfe von abzählbaren Mengenoperationen aus den Mengen der Form (13.5) darstellen lassen. Für uns in diesem Kapitel zentral ist die Beobachtung, dass das Ereignis

$$A := \left\{\omega \in \Omega : \lim_{n\to\infty} \frac{S_n(\omega)}{n} \quad \text{existiert und ist} \quad = p\right\}$$

in der σ-Algebra $\mathcal{F}$ liegt. Das machen wir uns im Folgenden klar.

Für eine beliebige Folge $(a_n)_n$ reeller Zahlen gilt $\lim_{n\to\infty} a_n = p$ genau dann, wenn für jedes $m \in \mathbb{N}$ ein $N \in \mathbb{N}$ existiert mit $p - \frac{1}{m} < a_n < p + \frac{1}{m}$ für alle $n \geq N$. Setzen wir nun

$$A_{n,m} := \left\{\omega \in \Omega : p - \frac{1}{m} < \frac{S_n(\omega)}{n} < p + \frac{1}{m}\right\}, \tag{13.7}$$

so gilt

$$A = \bigcap_{m\in\mathbb{N}} \bigcup_{N\in\mathbb{N}} \bigcap_{n:n\geq N} A_{n,m}. \tag{13.8}$$

Die Menge $A_{n,m}$ lässt sich als endliche Vereinigung von Mengen der Form (13.5) darstellen, denn die Zugehörigkeit zu $A_{n,m}$ hängt nur von $\omega_1, \ldots, \omega_n$ ab. Somit ist $A_{n,m} \in \mathcal{F}$. Mit Bemerkung 5.2.2 und Definition 5.2.1 ist damit auch $A \in \mathcal{F}$. Somit ist unter Anwendung von Satz 13.2.1 $P(A)$ definiert. Nun zeigen wir:

13.2.2 Satz: Es seien $(X_i)_i$ unabhängige Zufallsgrößen mit Werten in $\{0, 1\}$ mit $P(X_i = 1) = p$, $p \in (0, 1)$, definiert auf einem Wahrscheinlichkeitsraum $(\Omega, \mathcal{F}, P)$ gemäß Satz 13.2.1. Mit $S_n := \sum_{i=1}^n X_i$ gilt dann

$$P\left(\omega \in \Omega : \lim_{n\to\infty} \frac{S_n(\omega)}{n} \quad \text{existiert und ist} \quad = p\right) = 1.$$

Beweis: Wesentlich für den Beweis wird der Stetigkeitssatz 5.2.11 sowie die abzählbare Subadditivität von P sein. Mithilfe von (13.7) und (13.8) folgt

$$A^c = \left\{\omega \in \Omega : \lim_{n\to\infty} \frac{S_n(\omega)}{n} \quad \text{existiert und ist} \quad = p\right\}^c = \bigcup_{m\in\mathbb{N}} \bigcap_{N\in\mathbb{N}} \bigcup_{n:n\geq N} A_{n,m}^c.$$

Wir zeigen $P(A^c) = 0$. Die Folge der Ereignisse $\bigcap_{N\in\mathbb{N}} \bigcup_{n:n\geq N} A_{n,m}^c$ ist aufsteigend in m. Nach Satz 5.2.11(i) gilt daher

$$P(A^c) = \lim_{m\to\infty} P\left(\bigcap_{N\in\mathbb{N}} \bigcup_{n:n\geq N} A_{n,m}^c\right).$$

Daher genügt es zu zeigen, dass $P\Big(\bigcap_{N\in\mathbb{N}}\bigcup_{n:n\geq N} A^c_{n,m}\Big) = 0$. Wir können uns auf die $m \in \mathbb{N}$ einschränken, für die $0 \leq p - \frac{1}{m} < p + \frac{1}{m} \leq 1$ ist (wir betrachten $p \in (0,1)$). Die Folge $\bigcup_{n:n\geq N} A^c_{n,m}$ ist monoton fallend in N und daher gilt erneut unter Anwendung von Satz 5.2.11(ii)

$$P\Bigg(\bigcap_{N\in\mathbb{N}}\bigcup_{n:n\geq N} A^c_{n,m}\Bigg) = \lim_{N\to\infty} P\Bigg(\bigcup_{n:n\geq N} A^c_{n,m}\Bigg) \leq \limsup_{N\to\infty}\sum_{n=N}^{\infty} P(A^c_{n,m}).$$

Hierbei folgt die letzte Ungleichung mit der σ-Subadditivität von P. Wir können mithilfe von Satz 13.1.2 die Wahrscheinlichkeit von $A^c_{n,m}$ sehr gut abschätzen:

$$\begin{aligned} P(A^c_{n,m}) &= P\Bigg(\frac{S_n}{n} \geq p + \frac{1}{m}\Bigg) + P\Bigg(\frac{S_n}{n} \leq p - \frac{1}{m}\Bigg) \\ &\leq \exp\Bigg(-n\,H\Bigg(p + \frac{1}{m}\Bigg|p\Bigg)\Bigg) + \exp\Bigg(-n\,H\Bigg(p - \frac{1}{m}\Bigg|p\Bigg)\Bigg). \end{aligned}$$

Nun ist $H\Big(p + \frac{1}{m}|p\Big) > 0$ und $H\Big(p - \frac{1}{m}|p\Big) > 0$. Mithilfe der Summation geometrischer Reihen folgt

$$\sum_{n=N}^{\infty} P(A^c_{n,m}) \leq \frac{\exp\Big(-N\,H\Big(p + \frac{1}{m}|p\Big)\Big)}{1 - \exp\Big(-H\Big(p + \frac{1}{m}|p\Big)\Big)} + \frac{\exp\Big(-N\,H\Big(p - \frac{1}{m}|p\Big)\Big)}{1 - \exp\Big(-H\Big(p - \frac{1}{m}|p\Big)\Big)}.$$

Der Limes der rechten Seite dieser Ungleichung für $N \to \infty$ ist gleich Null und damit ist der Satz bewiesen. □

13.2.3 Bemerkung: Der obige Satz gilt viel allgemeiner. Für unabhängige Zufallsvariablen $(X_i)_i$, die alle die gleiche Verteilung besitzen, muss man nur die Existenz des Erwartungswertes $\mathbb{E}(X_1)$ voraussetzen und p durch $\mathbb{E}(X_1)$ ersetzen. Da man dann aber eine Abschätzung vom Typ wie in Satz 13.1.2 nicht mehr zur Verfügung hat, sind andere Argumente erforderlich.

13.2.4 Aufgabe: Es sei

$$M_N := \sup_{n:n\geq N}\left|\frac{S_n}{n} - p\right|.$$

Zeigen Sie, dass für jedes $\varepsilon > 0$

$$\lim_{N\to\infty} P\Big(M_N \geq \varepsilon\Big) = 0$$

gilt, d.h. schwache Konvergenz wie beim schwachen Gesetz der großen Zahlen. Da $M_N \geq \left|\frac{S_N}{N} - p\right|$, ist diese Aussage eine stärkere als die des schwachen Gesetzes der großen Zahlen. Umgekehrt, zeigen Sie, dass aus dieser schwachen Konvergenz von M_N das starke Gesetz der großen Zahlen folgt.

13.3 Erfolgsketten, Runs

Wir betrachten nun eine genauere Untersuchung von *Runs* in einer BERNOULLI-Kette. In einer Folge aus $\{0,1\}^n$ nennen wir jede maximale Teilfolge von einander benachbarten gleichen Ziffern einen *Run*. Bekannt ist das folgende Lehrexperiment. Man teile eine Schulklasse oder die Gruppe der Hörer einer Vorlesung in zwei gleichgroße Gruppen. In der einen Gruppe wird jeder gebeten, eine Münze 200 mal zu werfen und die 0-1-Sequenz aufzuschreiben. In der anderen Gruppe wird jeder gebeten, anstelle des Münzwurfs eine *zufällige* 0-1-Folge der Länge 200 zu notieren, ohne eine Münze zu werfen. Die Zettel werden eingesammelt und die Aufgabe besteht nun darin, anhand der Resultate die Zettel wieder der jeweiligen Gruppe zuzuordnen. Die Behauptung ist, dass dies überwiegend richtig geschehen kann. Der Spielleiter hat dabei eine wichtige Information als Auswahlkriterium an der Hand: In Münzwurfserien der Länge 200 kommen 1-Runs der Länge 7 vor, während die Schüler, die von Hand eine zufällige Serie notieren, es in der Regel scheuen, mehr als viermal hintereinander das gleiche Symbol zu verwenden. Sind 1-Runs einer Länge größer 5 vorhanden, ordnet der Spielleiter den Zettel der Gruppe, die die Münze warfen, zu. Er liegt fast immer richtig. Um dies mathematisch begründen zu können, müssen wir also die Länge des *längsten Runs* von Einsen in einer BERNOULLI-Kette der Länge n untersuchen. Ein heuristisches Argument geht so: Ein 1-Run der Länge m tritt mit Wahrscheinlichkeit p^m auf. Es gibt angenähert n mögliche Positionen für einen Run, also ist $\mathbb{E}(\text{Anzahl der 1-Runs der Länge}\, m) \approx n\, p^m$. Ist nun der längste 1-Run eindeutig, so sollte seine Länge R_n die Gleichung $1 = n\, p^{R_n}$ erfüllen. Die Lösung ist $R_n = \frac{\ln(n)}{\ln(1/p)}$. Im Fall einer fairen Münze ist $\frac{\ln(200)}{\ln(2)} \approx 7.64$.

Es bezeichne R_n die Länge des längsten Runs von Einsen in einer BERNOULLI-Kette der Länge n (mit Erfolgswahrscheinlichkeit p), genauer

$$R_n := \max\left\{ l-k \,:\, 0 \le k < l \le n\,,\ \frac{S_l - S_k}{l-k} = 1 \right\},$$

wobei S_k die Anzahl der Einsen bis zum k-ten Wurf ist. Es gilt ein starkes Gesetz der großen Zahlen:

13.3.1 Satz: (ERDÖS-RÉNYI-Gesetz für Runs) In einem BERNOULLI-Experiment der Länge n mit Erfolgswahrscheinlichkeit p gilt

$$P\left(\lim_{n\to\infty} \frac{R_n}{\ln(n)} \quad \text{existiert und ist} \quad = \frac{1}{\ln(1/p)} \right) = 1.$$

Wir bemerken, dass das typische Verhalten von $\frac{R_n}{\ln(n)}$ durch die relative Entropie

$H(1|p) = \ln(1/p)$ beschrieben wird. Tatsächlich können wir in einer BERNOULLI-Kette der Länge n Segmente maximaler Länge betrachten, deren Mittelwert in einem gegebenen Intervall $I = (a, b)$ (oder $I = [a, b]$) mit $0 \le a < b \le 1$ liegt: Sei

$$R_n^I := \max\left\{ l - k \,:\, 0 \le k < l \le n\,,\ \frac{S_l - S_k}{l - k} \in I \right\}$$

und $H_I := \inf_{x \in I} H(x|p)$. Dann gilt

13.3.2 Satz: (ERDÖS-RÉNYI-Gesetz) Es sei $I = (a, b)$ oder $I = [a, b]$ mit $0 \le a < b \le 1$. In einem BERNOULLI-Experiment der Länge n mit Erfolgswahrscheinlichkeit p gilt

$$P\left(\lim_{n\to\infty} \frac{R_n^I}{\ln(n)} \quad \text{existiert und ist} \quad = \frac{1}{H_I} \right) = 1.$$

Wir beweisen hier Satz 13.3.1. Dieser Beweis ist quasi das ergeizigste Projekt des vorliegenden Kapitels 13. Zu Satz 13.3.1 gibt es natürlich auch eine schwächere Variante in Form eines schwachen Gesetzes. Da wir aber in Kapitel 13.2 schon Erfahrungen mit einem starken Gesetz der großen Zahlen gesammelt haben, wollen wir diese nutzen, um sogar das starke Gesetz zu zeigen.

Wir bereiten den Beweis vor.

13.3.3 Lemma: (von BOREL-CANTELLI) (FRANCESCO CANTELLI (1875–1966)) Gegeben sei ein Wahrscheinlichkeitsraum $(\Omega, \mathcal{F}, P)$ sowie eine Folge von Ereignissen $(A_n)_n$. Wir bezeichnen mit

$$\limsup_{n\to\infty} A_n := \bigcap_{n\ge1} \bigcup_{m=n}^{\infty} A_m.$$

Dann gilt:

$$\text{Aus} \quad \sum_{n\ge1} P(A_n) < \infty \quad \text{folgt} \quad P\Big(\limsup_{n\to\infty} A_n\Big) = 0.$$

Sind die Ereignisse $(A_n)_n$ unabhängig, so gilt:

$$\text{Aus} \quad \sum_{n\ge1} P(A_n) = \infty \quad \text{folgt} \quad P\Big(\limsup_{n\to\infty} A_n\Big) = 1.$$

Beweis: Den Beweis des ersten Teils haben wir bereits im Beweis von Satz 13.2.2 gesehen: Mithilfe des Stetigkeitssatzes 5.2.11 folgt

$$P\Big(\limsup_{n\to\infty} A_n\Big) = \lim_{n\to\infty} P\left(\bigcup_{m\ge n} A_m \right) \le \limsup_{n\to\infty} \sum_{m=n}^{\infty} P(A_m) = 0.$$

Für den zweiten Teil des Beweises nehme man an, die Ereignisse $(A_n)_n$ seien unabhängig. Mithilfe von Satz 5.2.11 folgt analog

$$P\left(\bigcup_{n\geq 1}\bigcap_{m=n}^{\infty} A_m^c\right) = \lim_{n\to\infty} P\left(\bigcap_{m=n}^{\infty} A_m^c\right).$$

Nun sind die Ereignisse $(A_m^c)_m$ ebenfalls unabhängig, siehe Lemma 9.1.13. Also folgt

$$P\left(\bigcup_{n\geq 1}\bigcap_{m=n}^{\infty} A_m^c\right) = \lim_{n\to\infty}\prod_{m\geq n} P(A_m^c) = \lim_{n\to\infty}\exp\left(\sum_{m\geq n}\ln\Big(1-P(A_m)\Big)\right).$$

Nun gilt für $x \in [0,1]$ die Ungleichung $\ln(1-x) \leq -x$ (einfaches Tangenten-Argument), also

$$P\left(\bigcup_{n\geq 1}\bigcap_{m=n}^{\infty} A_m^c\right) \leq \lim_{n\to\infty}\exp\Big(-\sum_{m\geq n} P(A_m)\Big) = 0$$

nach Voraussetzung. Damit ist das Lemma bewiesen. □

Beweis von Satz 13.3.1: Wir betrachten das Ereignis, dass ab Position $i+1$ m-mal hintereinander eine Eins realisiert wird:

$$D_i := D_i(n) := \Big\{X_{i+k} = 1,\ k = 1,\dots,m\Big\},\ i = 0,1,\dots,n-m.$$

Wir erinnern an unsere Heuristik. Dort trat die Gleichung $np^m = 1$ auf, die aufgelöst nach m

$$m = \ln(n)/\ln(1/p) = \log_{1/p}(n)$$

ergab. Wir wählen nun zu einem vorgegebenen $\varepsilon > 0$

$$m := \lceil (1+\varepsilon)\log_{1/p}(n)\rceil.$$

Es gilt $P(D_i) = p^m$ sowie mit unserer Wahl von m

$$n^{-(1+\varepsilon)} \leq P(D_i) = p^m \leq \frac{1}{p} n^{-(1+\varepsilon)}.$$

Weiter betrachten wir das Ereignis, dass an irgendeiner möglichen Position i eine Erfolgskette der Länge m beginnt:

$$E(n) := \bigcup_{i=0}^{n-m} D_i.$$

Wir betrachten nun eine geschickt gewählte Teilfolge $(n_k)_k$: Es sei $n_k := \lceil (1/p)^k \rceil$ sowie $m_k := \lceil (1+\varepsilon) \log_{1/p}(n_k) \rceil$ und das zugehörige Ereignis $E(n_k) = \bigcup_{i=0}^{n_k - m_k} D_i(n_k)$. Dann folgt

$$P\Big(\bigcup_k E(n_k)\Big) \le \sum_{k=1}^{\infty} \sum_{i=0}^{n_k - m_k} P(D_i(n_k)) \le \sum_{k=1}^{\infty} n_k \frac{1}{p} n_k^{-(1+\varepsilon)} < \frac{1}{p} \sum_{k=1}^{\infty} p^{\varepsilon k} < \infty.$$

Damit folgt mithilfe des Lemmas von Borel-Cantelli

$$P\Big(\limsup_{k\to\infty} E(n_k)\Big) = 0.$$

Jetzt sieht man: Die Wahl der Teilfolge $(n_k)_k$ hatte zum Ziel, die Summierbarkeit zu ermöglichen. Nach Definition hat also das Ereignis $\bigcup_{N\in\mathbb{N}} \bigcap_{n_k \ge N} E(n_k)^c$ Wahrscheinlichkeit 1. Also gibt es eine Zahl $N \in \mathbb{N}$, sodass für alle $n_k \ge N$ nirgends eine Erfolgskette der Länge m_k (oder länger) auftritt. Es gilt also mit Wahrscheinlichkeit 1:

$$\frac{R_{n_k}}{\log_{1/p}(n_k)} \le 1.$$

Nun ist nach Definition von R_n diese Zufallsvariable in n monoton wachsend. Wenn wir nun $n \in \mathbb{N}$ so wählen, dass

$$\log_{1/p}(n_k) < \log_{1/p}(n) < \log_{1/p}(n_{k+1}),$$

so folgt

$$P\left(\limsup_{n\to\infty} \frac{R_n}{\log_{1/p}(n)} \le 1\right) = 1$$

(die Details sollen in einer Aufgabe erarbeitet werden).

Im zweiten Schritt zeigen wir nun

$$P\left(\liminf_{n\to\infty} \frac{R_n}{\log_{1/p}(n)} \ge 1\right) = 1\ . \tag{13.9}$$

Wir werden den zweiten Teil des Lemmas von Borel-Cantelli verwenden. Dazu müssen wir unabhängige Ereignisse erzeugen. Dies erreichen wir durch eine einfache *Blockbildung*: Es sei

$$D_{m,i} := \{X_{mi+k} = 1 \quad \text{für alle} \quad k = 1, \dots, m\}.$$

Wir betrachten also disjunkte Blöcke der Länge m. Es sei weiter

$$T_m := \sum_i 1_{D_{m,i}},$$

wobei die Summation über i alle möglichen disjunkten Blöcke der Länge m beschreibt, beginnend bei $i = 0$. Es gibt mindestens $n/m - 1$ dieser Blöcke. Wir wählen als Blocklänge $m_n = \lceil (1-\varepsilon)\log_{1/p}(n)\rceil$. Dann gilt

$$\mathbb{E}(T_{m_n}) \geq \left(\frac{n}{m_n} - 1\right) p^{m_n} \geq \left(\frac{n}{m_n} - 1\right) n^{-(1-\varepsilon)} = \frac{1}{m_n} n^{\varepsilon} - n^{-(1-\varepsilon)}.$$

Damit ist $\lim_{n\to\infty} \mathbb{E}(T_{m_n}) = \infty$. Wir wählen analog zu oben geeignete Mengen $E(n_k)$ und folgern mit dem Lemma von Borel-Cantelli damit

$$P\Big(\limsup_{k\to\infty} E(n_k)\Big) = 1.$$

Daraus folgt mit einem analogen Monotonieargument (siehe Aufgabe) (13.9) und damit der Satz. □

13.3.4 Aufgabe: Der Übergang von der Teilfolge $(n_k)_k$ zur Folge aller natürlichen Zahlen nutzt, dass die Zufallsgröße R_n monoton in n wächst. Führen Sie die Argumente im Beweis im Detail aus.

13.3.5 Bemerkung: Paul Erdös (1914–1996) und Alfréd Rényi (1921–1970) haben diese Resultate im Jahre 1970 in einer Arbeit mit dem Titel *On a new law of large numbers* hergeleitet. Mit verhältnismäßig elementaren Methoden haben wir damit bereits ein recht aktuelles Ergebnis kennengelernt. Bei Modellierungen in der mathematischen Biologie (computational biology) findet das neue Gesetz von Erdös und Rényi viele Anwendungen. Man modelliert dabei zum Beispiel die Reihenfolge des Auftretens der Bausteine einer DNA-Sequenz stochastisch unabhängig und vergleicht einen Teil einer DNA-Sequenz mit einem Teil einer anderen Sequenz. Bei Übereinstimmung der Bausteine der beiden Sequenzen spricht man dann von Erfolg, der mit einer zu bestimmenden Wahrscheinlichkeit auftritt. Gesetze der großen Zahlen geben dann Auskunft über die zu erwartende maximale Länge von Übereinstimmungsbereichen. In naheliegenden Verallgemeinerungen von Satz 13.3.1 werden nicht-unabhängige Folgen untersucht. Im Hinblick auf das Modell der DNA-Sequenzen interessieren auch dann Bereiche der Übereinstimmung, wenn sie nur mittels einer Verschiebung der einen Kette sichtbar wurden: Bei den DNA-Sequenzen beginnt man *irgendwo*, und kann nicht davon ausgehen, dass nur die Übereinstimmungen genetisch von Interesse sind, die bei Wahl des zufälligen Startpunktes der Untersuchung sichtbar wurden. Die dem Satz 13.3.1 vorangestellte Heuristik verrät dann übrigens schon verblüffend gut das Resultat: Wir wollen den längsten Run H_n zweier Sequenzen ermitteln, wenn Verschiebungen

zugelassen sind. Damit hat man n^2 mögliche Startpositionen für ein übereinstimmendes Sequenzstück. Damit wächst H_n wie $\log_{1/p}(n^2) = 2\log_{1/p}(n)$. Tatsächlich gilt für $H_n/\log_{1/p}(n)$ ein starkes Gesetz der großen Zahlen und der Limes ist 2.

Lösungen der Aufgaben

Lösungen der Aufgaben in 13.1

Aufgabe 13.1.3

Sei $p \in (0,1)$. Die Funktion H ist dann definiert durch $H(x|p) := -x \ln \frac{p}{x} - (1-x) \ln \frac{1-p}{1-x}$ für $x \in (0,1)$. Ferner setzt man sie in 0 und 1 stetig fort, das heißt $H(1|p) := -\ln(p)$ und $H(0|p) := -\ln(1-p)$. Man erkennt dann leicht, dass für alle $p \in (0,1)$ und $x \in [0,1]$ gilt:

$$H(x|1-p) = H(1-x|p) \quad \text{oder} \quad H(1-x|1-p) = H(x|p). \tag{13.10}$$

Wir weisen zunächst die Positivitätseigenschaften der Funktion H nach, das heißt $H(x|p) \geq 0$ und $H(x|p) = 0$ genau dann, wenn $x = p$ gilt. Offensichtlich gilt

$$H(p|p) = -p \ln(1) - (1-p) \ln(1) = 0 + 0 = 0\,.$$

Somit müssen wir nur noch zeigen, dass $H(x|p) > 0$ ist für $x \in [0,1] \setminus \{p\}$. Für $x = 0$ oder $x = 1$ ist dies nach obiger Definition klar. Sei also $x \in (0,1)$. Aufgrund der Relation (13.10) können wir uns auf $x \in (p,1)$ beschränken. Dazu betrachten wir erneut die Funktion f aus der Passage vor Satz 13.1.2. Wir setzen $\alpha := x - p > 0$. Es gilt $f(0+) := \lim_{\lambda \downarrow 0} f(\lambda) = 0 + \ln(M(0+)) = 0$. Ferner haben wir gesehen, dass $\lambda_0 := \lambda_0(x,p) := \ln \frac{(1-p)x}{p(1-x)}$ die eindeutige Minimalstelle von f ist. Nun erkennen wir, dass λ_0 positiv ist für alle $1 > x > p$. Da die Funktion f wegen $f'' > 0$ strikt konvex ist, ist die Ableitungsfunktion f' streng monoton wachsend auf $(0, +\infty)$. Wegen $f'(\lambda_0) = 0$ folgt daher $f'(\lambda) < 0$ für alle $\lambda \in (0, \lambda_0)$. Somit ist die Funktion f auf $(0, \lambda_0)$ streng monoton fallend. Wegen $f(0+) = 0$ und $\lambda_0 > 0$ muss daher $f(\lambda_0) < 0$ sein. Da aber $H(x|p) = -f(\lambda_0(x,p))$ ist, folgt die Positivität von $H(x|p)$ für $x > p$.
Nun zeigen wir die Abschätzung

$$P\left(\frac{S_n}{n} \leq x\right) \leq \exp\Big(-n\, H(x|p)\Big) \quad \text{für } x \in [0,p]\,. \tag{13.11}$$

Für $x = 0$ ist $H(0|p) = -\ln(1-p)$ und

$$P\left(\frac{S_n}{n} \leq 0\right) = P(X_1 = X_2 = \ldots = X_n = 0) = (1-p)^n = \exp\Big(-n\,H(0|p)\Big)\,,$$

es gilt also Gleichheit. Für $x = p$ ist wegen $H(p|p) = 0$ die Ungleichung klar. Sei nun $x \in (0,p)$. Wir definieren die Zufallsvariablen $Y_i := 1 - X_i$ für $i = 1, \ldots n$ und sehen, dass diese ebenfalls unabhängig und identisch verteilt sind mit $P(Y_i = 1) = 1-p$ und $P(Y_i = 0) = p$. Wir erhalten unter Verwendung der oberen Abschätzung angewandt auf die Y_i:

$$\begin{aligned} P\left(\frac{S_n}{n} \leq x\right) &= P\left(\frac{n - S_n}{n} \geq 1 - x\right) = P\left(\frac{\sum_{i=1}^n Y_i}{n} \geq 1 - x\right) \\ &\leq \exp\Big(-n\,H(1-x|1-p)\Big) = \exp\Big(-n\,H(x|p)\Big)\,, \end{aligned}$$

wobei wir für die letzte Gleichheit (13.10) verwendet haben.

Aufgabe 13.1.6

Sei $p \in (0,1)$. Wir geben hier bekannt, dass die Logarithmusfunktion auf $(0,+\infty)$ analytisch ist. Somit ist die Funktion $H := H(\cdot|p)$ als Komposition analytischer Funktionen eine analytische Funktion auf $(0,1)$. Anhand der Darstellung $H(x) = -x\ln\frac{p}{x} - (1-x)\ln\frac{1-p}{1-x}$ für $x \in (0,1)$ berechnen wir zunächst H'. Es gilt

$$\begin{aligned} H'(x) &= -\ln\frac{p}{x} - x\cdot\frac{x}{p}\cdot\frac{-p}{x^2} \\ &\quad + 1\cdot\ln\frac{1-p}{1-x} - (1-x)\cdot\frac{1-x}{1-p}\cdot\frac{1-p}{(1-x)^2} \\ &= -\ln\frac{p}{x} + 1 + \ln\frac{1-p}{1-x} - 1 \\ &= \ln\frac{x}{p} - \ln\frac{1-x}{1-p}\,. \end{aligned}$$

Die Formel für $H^{(k)}$ für $k \geq 2$ beweisen wir durch vollständige Induktion nach k. Für die zweite Ableitung ergibt sich

$$\begin{aligned} H''(x) &= \frac{p}{x}\cdot\frac{1}{p} - \frac{1-p}{1-x}\cdot\frac{-1}{1-p} = \frac{1}{x} + \frac{1}{1-x} \\ &= \frac{(-1)^2(2-2)!}{x^{2-1}} + \frac{(2-2)!}{(1-x)^{2-1}}, \end{aligned}$$

und somit gilt der Induktionsanfang. Im Induktionsschritt $k \to k+1$ nehmen wir die Formel für $H^{(k)}$ als wahr an und schließen daraus

$$\begin{aligned} H^{(k+1)}(x) &= \frac{d}{dx}\left(\frac{(-1)^k(k-2)!}{x^{k-1}} + \frac{(k-2)!}{(1-x)^{k-1}}\right) \\ &= \frac{(-1)^k(k-2)![-(k-1)]}{x^k} + \frac{(k-2)![-(k-1)](-1)}{(1-x)^k} \\ &= \frac{(-1)^{k+1}(k+1-2)!}{x^{k+1-1}} + \frac{(k+1-2)!}{(1-x)^{k+1-1}}, \end{aligned}$$

sodass die Induktionsbehauptung erfüllt ist. Schließlich folgt die behauptete Ungleichung leicht aus der Dreiecksungleichung:

$$\begin{aligned} |H^{(k)}(x)| &\leq \left|\frac{(-1)^k(k-2)!}{x^{k-1}}\right| + \left|\frac{(k-2)!}{(1-x)^{k-1}}\right| \\ &= (k-2)!\left(\frac{1}{x^{k-1}} + \frac{1}{(1-x)^{k-1}}\right). \end{aligned}$$

Aufgabe 13.1.7

In Aufgabe 13.1.6 haben wir gezeigt, dass $H(\cdot|p)$ auf dem Intervall $(0,1)$ analytisch ist, also ist diese Funktion insbesondere stetig. Wir müssen somit nur die strenge Monotonie beweisen. Dazu verwenden wir die Ableitungsfunktion, welche nach Aufgabe 13.1.6 gegeben ist durch

$$H'(x) = \ln\frac{x}{p} + \ln\frac{1-p}{1-x}.$$

Ist $x \in (p,1)$, so ist $\frac{x}{p} > 1$ und auch $\frac{1-p}{1-x} > 1$, sodass $H'(x) > 0$ folgt. Somit ist die Funktion auf diesem Intervall streng monoton steigend. Ist andererseits $x \in (0,p)$, so gilt $\frac{x}{p} < 1$ und auch $\frac{1-p}{1-x} < 1$, sodass $H'(x) < 0$ folgt. Daher ist die Funktion auf diesem Intervall streng monoton fallend.

Lösungen der Aufgaben in 13.2

Aufgabe 13.2.4

Im Beweis von Satz 13.2.2 haben wir mit den dort gültigen Bezeichnungen gesehen, dass genau dann $P(A) = 1$ gilt, wenn für jedes $m \in \mathbb{N}$ gilt:

$$P\left(\bigcap_{N\in\mathbb{N}} \bigcup_{n\geq N} A_{n,m}^c\right) = 0. \tag{13.12}$$

Sei zunächst angenommen, dass (13.12) für jedes $m \in \mathbb{N}$ erfüllt ist. Dann wähle man zu gegebenem $\varepsilon > 0$ ein $m \in \mathbb{N}$ mit $\frac{1}{m} < \varepsilon$. Die Folge $(B_{N,\varepsilon})_{N\in\mathbb{N}}$ von Ereignissen mit $B_{N,\varepsilon} := \{M_N \geq \varepsilon\}$ ist offenbar monoton fallend und es gilt weiterhin

$$B_{N,\varepsilon} \subseteq B_{N,\frac{1}{m}} \subset \bigcup_{n\geq N} A^c_{n,2m},$$

wovon man sich leicht überzeugt. Somit folgt aus (13.12) und aus der Stetigkeit des Wahrscheinlichkeitsmaßes von oben, dass gilt:

$$\lim_{N\to\infty} P(M_N \geq \varepsilon) = P\left(\bigcap_{N\in\mathbb{N}} B_{N,\varepsilon}\right) \leq P\left(\bigcap_{N\in\mathbb{N}} \bigcup_{n\geq N} A^c_{n,m}\right) = 0.$$

Somit ist die Bedingung aus der Aufgabenstellung erfüllt. Sei umgekehrt die Bedingung aus der Aufgabenstellung erfüllt. Wir müssen für jedes $m \in \mathbb{N}$ die Relation (13.12) nachweisen. Dazu verwenden wir die oben erklärte Darstellung

$$\bigcup_{n\geq N} A^c_{n,m} \subset B_{N,\frac{1}{m}},$$

aus welcher mithilfe der Stetigkeit des Wahrscheinlichkeitsmaßes von oben folgt:

$$\begin{aligned} P\left(\bigcap_{N\in\mathbb{N}} \bigcup_{n\geq N} A^c_{n,m}\right) &= \lim_{N\to\infty} P\left(\bigcup_{n\geq N} A^c_{n,m}\right) \\ &= \lim_{N\to\infty} P\left(B_{N,\frac{1}{m}}\right) = \lim_{N\to\infty} P\left(M_N \geq \frac{1}{m}\right) = 0. \end{aligned}$$

Lösungen der Aufgaben in 13.3

Aufgabe 13.3.4

Für festes $\omega \in \Omega$ ist die Folge $(R_n(\omega))_{n\in\mathbb{N}}$ offenbar monoton wachsend, da das Maximum in der Definition beim Übergang von n zu $n+1$ höchstens größer werden kann. Mit den Bezeichnungen aus dem Beweis von Satz 13.3.1 sei A die Menge aller ω, sodass

$$\limsup_{k\to\infty} \frac{R_{n_k}(\omega)}{\log_{1/p}(n_k)} \leq 1$$

gilt. Wir wissen bereits, dass dann $P(A) = 1$ gilt und wollen zeigen, dass für festes $\omega \in A$ auch

$$S(\omega) := \limsup_{n\to\infty} \frac{R_n(\omega)}{\log_{1/p}(n)} \leq 1$$

ist. Sei also $\omega \in A$. Da $S(\omega)$ der größte Häufungspunkt der Folge $\left(\frac{R_n(\omega)}{\log_{1/p}(n)}\right)_{n\in\mathbb{N}}$ ist, gibt es eine streng monoton wachsende Indexfolge $(j_l)_{l\in\mathbb{N}}$ mit

$$\lim_{l\to\infty} \frac{R_{j_l}(\omega)}{\log_{1/p}(j_l)} = S(\omega)\,.$$

Für jedes $l \in \mathbb{N}$ gibt es weiter genau ein $k_l \in \mathbb{N}$ mit

$$n_{k_l} < j_l < n_{k_l+1} \quad \text{und somit} \quad \log_{1/p}(n_{k_l}) < \log_{1/p}(j_l) < \log_{1/p}(n_{k_l+1})\,.$$

Aus der Monotonie von $(R_n(\omega))_{n\in\mathbb{N}}$ ergibt sich nun für jedes $l \in \mathbb{N}$:

$$\begin{aligned} \frac{R_{j_l}(\omega)}{\log_{1/p}(j_l)} &\leq \frac{R_{n_{k_l+1}}(\omega)}{\log_{1/p}(n_{k_l})} \\ &= \frac{R_{n_{k_l+1}}(\omega)}{\log_{1/p}(n_{k_l+1})} \cdot \frac{\log_{1/p}(n_{k_l+1})}{\log_{1/p}(n_{k_l})} \end{aligned} \tag{13.13}$$

Ferner haben wir für alle $l \in \mathbb{N}$:

$$\begin{aligned} 1 &\leq \frac{\log_{1/p}(n_{k_l+1})}{\log_{1/p}(n_{k_l})} \leq \frac{\log_{1/p}\left((1/p)^{k_l+1}+1\right)}{\log_{1/p}\left((1/p)^{k_l}\right)} \\ &= \frac{\log_{1/p}\left((1/p)^{k_l+1}\right) + \log_{1/p}(1+p^{k_l+1})}{\log_{1/p}\left((1/p)^{k_l}\right)} \\ &= \frac{k_l + 1 + \log_{1/p}(1+p^{k_l+1})}{k_l} \end{aligned} \tag{13.14}$$

Wegen $\lim_{l\to\infty} \log_{1/p}(1+p^{k_l+1}) = \log_{1/p}(1) = 0$ folgt aus (13.14), dass $\lim_{l\to\infty} \frac{\log_{1/p}(n_{k_l+1})}{\log_{1/p}(n_{k_l})} = 1$ gilt. Somit ergibt sich wegen $\omega \in A$ aus (13.13) die Abschätzung

$$\begin{aligned} S(\omega) &= \lim_{l\to\infty} \frac{R_{j_l}(\omega)}{\log_{1/p}(j_l)} \\ &\leq \limsup_{l\to\infty} \frac{R_{n_{k_l+1}}(\omega)}{\log_{1/p}(n_{k_l+1})} \cdot \lim_{l\to\infty} \frac{\log_{1/p}(n_{k_l+1})}{\log_{1/p}(n_{k_l})} \\ &\leq 1 \cdot 1 = 1\,. \end{aligned}$$

Schließlich erhalten wir

$$P\left(\limsup_{n\to\infty} \frac{R_n(\omega)}{\log_{1/p}(n)} \leq 1\right) \geq P(A) = 1\,,$$

also die Behauptung.