Kurseinheit 6

Grenzwertsätze

Inhalt der Kurseinheit

Studierhinweise zu Kurseinheit 6 **371**

14 Poisson-Approximation **373**
14.1 POISSON-Verteilung und Exponentialverteilung 373
14.2 POISSON-Approximation 377
14.3 Der POISSON'sche Punktprozess 386

Lösungen zu den Aufgaben aus dem Kapitel 14 **395**

15 Der Satz von de Moivre und Laplace **401**
15.1 Der lokale Grenzwertsatz 401
15.2 Der Satz von DE MOIVRE und LAPLACE 408

Lösungen zu den Aufgaben aus dem Kapitel 15 **419**

Studierhinweise

In der sechsten Kurseinheit untersuchen wir die POISSON- und die Normalapproximation der Binomialverteilung.

In *Kapitel vierzehn* geht es um die POISSON-Verteilung und die Exponentialverteilung sowie um die Untersuchung der Approximation durch die POISSON-Verteilung. Dabei begegnen wir der Konstruktion des POISSON-Punktprozesses.

In *Abschnitt* 14.1 motivieren wir die POISSON-Verteilung, bestimmen Erwartungswert und Varianz dieser Verteilung und entdecken die Exponentialverteilung als Wartezeitverteilung auf einen zufälligen Punkt. Diese Verteilung tritt als Spezialfall der Gamma-Verteilung auf. Nach Durcharbeiten dieses Abschnitts wissen Sie, dass die POISSON-Verteilung bei Modellen für die Anzahl von rein zufälligen Zeitpunkten auftritt. Sie kennen unterschiedliche Modelle für das Auftreten zufälliger Zeitpunkte und können die Wartezeit auf den r-ten Zufallszeitpunkt beschreiben.

In *Abschnitt* 14.2 diskutieren wir ausführlich die POISSON-Approximation. Über den klassischen Grenzwertsatz von POISSON hinaus untersuchen wir mittels einer Kopplungsmethode die Güte der Approximation, indem wir eine Fehlerschranke herleiten. Wir geben Beispiele und diskutieren die Approximationsgüte. Nach Durcharbeiten dieses Abschnitts kennen Sie das Kopplungsargument im Beweis der POISSON-Approximation und kennen Modelle, in denen die Bedingung des klassischen Grenzwertsatzes von POISSON realistisch ist.

In *Abschnitt* 14.3 wird für das Streuexperiment von RUTHERFORD eine POISSON-Approximation bewiesen. Wir verallgemeinern die dazu vorgestellten Argumente und konstruieren einen sogenannten Punktprozess. Nach Durcharbeiten dieses Abschnitts beherrschen Sie die Argumente zur Herleitung der POISSON-Approximation im Streuexperiment. Sie können insbesondere die Regularitätsbedingung einordnen.

In *Kapitel fünfzehn* wird der Satz von DE MOIVRE und LAPLACE im BERNOULLI-Experiment bewiesen. Dieser Satz kann als das bedeutendste Resultat eines Stochastik-Kurses angesehen werden.

In *Abschnitt* 15.1 motivieren wir zunächst, in welcher Skalierung wir eine sinnvolle Konvergenz der Binomialwahrscheinlichkeiten erwarten können. Anschließend beweisen wir den lokalen Grenzwertsatz, der lokal die Glockenkurve erkennen lässt. Im Beweis verwenden wir die Formel von STIRLING sowie eine TAYLOR-Approximation der relativen Entropie. Nach Durcharbeiten dieses Abschnitts kennen Sie den Beweis von Lemma 15.1.1 sehr genau und können den Beweis des lokalen Grenzwertsatzes skizzieren.

In *Abschnitt* 15.2 beweisen wir den Grenzwertsatz von DE MOIVRE und LAPLACE mittels RIEMANN-Summen, wir beweisen, dass die Glockenkurve eine Dichte ist und betrachten Anwendungen. Darüberhinaus formulieren wir den zentralen Grenzwertsatz, den wir aber nicht beweisen, und diskutieren die Approximationsgüte im Falle der Normalapproximation, auch im Vergleich zur POISSON-Approximation. Sie kennen am Ende dieses Abschnitts den Beweis von Satz 15.2.1 und können ihn anwenden.

Kapitel 14

Poisson-Approximation

In diesem Kapitel widmen wir uns der POISSON-Verteilung. Sie ist neben der Binomialverteilung die wichtigste diskrete Verteilung in diesem Kurs. Sie tritt in verschiedensten Situationen auf. Wir beschäftigen uns weiterhin mit der sogenannten POISSON-Approximation sowie mit der Konstruktion des POISSON-Punktprozesses.

14.1 Poisson-Verteilung und Exponentialverteilung

Es sei daran erinnert, dass eine Zufallsgrösse X mit der Verteilung

$$P(X = k) = b(k; n, p) = \binom{n}{k} p^k q^{n-k} \quad (q = 1 - p) \text{ für } k = 0, 1, \ldots, n$$

binomialverteilt heißt. Sie ist Ausgangspunkt der folgenden Diskussion:

Wir betrachten einen Druckerserver, der nach dem sogenannten Spooling arbeitet. Dabei werden die Druckaufträge in einer Warteschleife abgelegt. Der Druckerserver sieht periodisch nach, ob Aufträge anliegen und führt diese gegebenenfalls aus. Unsere Modellannahme ist, dass die Aufträge unabhängig und gleichverteilt ankommen. Wir wollen die Wahrscheinlichkeit berechnen, mit der innerhalb eines festen Zeitintervalls $(0, t]$, $t > 0$, genau k Aufträge ausgeführt werden. Wir wählen $\Omega := \mathbb{N}_0$. Wir nehmen nun an, dass der Drucker im angegebenen Zeitintervall n-mal eine Überprüfung der Warteschlange vornimmt und die Abstände zwischen den Überprüfungszeitpunkten gleich seien. Ferner nehmen wir an, dass bei jeder Überprüfung höchstens ein neuer Auftrag eingeht, also die Teilintervalle kurz sind.

Die Wahrscheinlichkeit für das Eintreffen eines neuen Auftrags sei $\lambda t/n$ mit einem Proportionalitätsfaktor $\lambda > 0$. Es erscheint plausibel, dass das Eintreffen eines Druckauftrags in einem Teilintervall nicht davon abhängt, ob in einem anderen Teilintervall ein Auftrag auftritt oder nicht. Wir tun also so, als ob die Druckaufträge in den n Teilintervallen durch n Stichproben mit Zurücklegen aus einer Urne mit einem Anteil von $\lambda t/n$ „Druckkugeln“ ermittelt würden. Wir setzen daher für die gesuchte Wahrscheinlichkeit

$$P(\{k\}) := \lim_{n\to\infty} b(k; n, \lambda t/n) \tag{14.1}$$

an. Hier ist die Erfolgswahrscheinlichkeit $p_n = \frac{\lambda t}{n}$ und der Erwartungswert ist $n\,p_n = \lambda t$. Im Mittel werden also λt Aufträge erteilt. Existiert der Limes in (14.1)? Wir nehmen das Ergebnis vorweg. Es gilt für jedes $k \geq 0$:

$$P(\{k\}) = e^{-\lambda t}\frac{(\lambda t)^k}{k!}. \tag{14.2}$$

Die Reihenentwicklung der Exponentialfunktion zeigt, dass der Limes tatsächlich eine Zähldichte auf $\mathbb{N}_0$ definiert. Das Resultat bedeutet, dass die Binomialverteilung bei einer geeigneten Wahl der Wahrscheinlichkeit p_n durch eine neue Verteilung auf $\mathbb{N}_0$ approximiert werden kann. p_n wird hier mit wachsendem n klein und der Erwartungswert ist konstant. Man spricht daher von einem *Gesetz seltener Ereignisse*: Die Wahrscheinlichkeit p_n eines Erfolges ist hier relativ klein; es ist die Wahrscheinlichkeit dafür, dass der einzelne Summand X_i einer binomialverteilten Zufallsgröße $X := \sum_{i=1}^n X_i$ *nicht* klein ist.

14.1.1 Definition: Für eine reelle Zahl $\alpha > 0$ betrachte man die Wahrscheinlichkeitsverteilung, die durch

$$\pi_\alpha(k) := \frac{e^{-\alpha}}{k!}\alpha^k, \quad k \in \mathbb{N}_0,$$

definiert ist. Eine Zufallsgröße X mit $X(\Omega) = \mathbb{N}_0$ und der Verteilung π_α heißt Poisson-verteilt mit Parameter $\alpha > 0$.

Diese Verteilung ist benannt nach Siméon Denis Poisson (1781–1840).

Tatsächlich gilt

$$\sum_{k=0}^{\infty} \pi_\alpha(k) = e^{-\alpha}\sum_{k=0}^{\infty}\frac{\alpha^k}{k!} = e^{-\alpha}e^{\alpha} = 1\ .$$

π_α ist also eine Wahrscheinlichkeitsverteilung.

Das Eingangsbeispiel der Zählung eintreffender Druckaufträge kann einfach in ein anderes Modell übersetzt werden: Wieviele Schadensmeldungen erhält eine Kfz-Versicherung in einem festen Zeitintervall $(0, t]$, $t > 0$? Welches P ist vernünftig? Wir machen die analogen Modellannahmen. Nun ist $\lambda t/n$ die Wahrscheinlichkeit für das Eintreten eines Schadensfalls in einem der n Teilintervalle. Wir können allgemeiner sagen: Die POISSON-Verteilung tritt bei Modellen für die Anzahl von rein zufälligen Zeitpunkten in einem Zeitintervall auf: Druckeraufträge, Schadensfälle, Anzahl der über einen Mail-Server geleiteten E-Mails oder die Anzahl der Atomzerfallszeitpunkte einer radioaktiven Substanz. Wir werden uns später mit dem letzten Beispiel detailliert beschäftigen.

Der Erwartungswert dieser Verteilung ist leicht auszurechnen:

$$\begin{aligned}\sum_{k=0}^{\infty} k\pi_\alpha(k) &= e^{-\alpha}\sum_{k=0}^{\infty} k\frac{\alpha^k}{k!} = e^{-\alpha}\alpha\sum_{k=1}^{\infty}\frac{\alpha^{k-1}}{(k-1)!}\\ &= e^{-\alpha}\alpha\sum_{k=0}^{\infty}\frac{\alpha^k}{k!} = e^{-\alpha}\alpha e^{+\alpha} = \alpha.\end{aligned}$$

Eine POISSON-verteilte Zufallsgröße hat also Erwartungswert α.

Als nächstes wollen wir die Varianz ausrechnen. Es gilt

$$\begin{aligned}\mathbb{E}\Big(X(X-1)\Big) &= \sum_{k=0}^{\infty} k(k-1)\pi_\alpha(k) = \alpha^2 e^{-\alpha}\sum_{k=2}^{\infty}\frac{\alpha^{k-2}}{(k-2)!}\\ &= \alpha^2 e^{-\alpha}\sum_{k=0}^{\infty}\frac{\alpha^k}{k!} = \alpha^2 e^{-\alpha}e^{\alpha} = \alpha^2.\end{aligned}$$

Nun nutzen wir

$$\begin{aligned}\mathbb{E}\Big(X(X-1)\Big) + \mathbb{E}(X) - (\mathbb{E}X)^2 &= \mathbb{E}(X^2) - \mathbb{E}(X) + \mathbb{E}(X) - (\mathbb{E}X)^2\\ &= \mathbb{V}(X)\end{aligned} \tag{14.3}$$

und erhalten

$$\mathbb{V}(X) = \mathbb{E}\Big(X(X-1)\Big) + \mathbb{E}(X) - (\mathbb{E}X)^2 = \alpha^2 + \alpha - \alpha^2 = \alpha.$$

14.1.2 Lemma: Erwartungswert und Varianz einer POISSON-verteilten Zufallsgröße sind gleich dem Parameter α.

14.1.3 Aufgabe: Wir nehmen die Bestimmung der Varianz mittels (14.3) zum Anlass, die Varianzen bekannter Verteilungen zu bestimmen, indem man $\mathbb{E}(X(X-1))$ berechnet. Berechnen Sie $\mathbb{E}(X(X-1))$ für eine BERNOULLI-verteilte, eine hypergeometrisch verteilte, eine geometrisch verteilte und eine negativ binomialverteilte Zufallsgröße X.

Wir haben in Kapitel 10 die Exponentialverteilung kennengelernt. Im Zusammenhang mit rein zufälligen Zeitpunkten auf dem Zeitintervall $(0, \infty)$ kommt diese Verteilung ins Spiel. Im einführenden Beispiel der zufällig eintreffenden Druckaufträge (oder Schadensmeldungen) führte die Heuristik zu der Annahme, dass die Anzahl der Punkte in $(0, t]$ POISSON-verteilt zum Parameter λt ist. Nun fragen wir, welches Wahrscheinlichkeitsmaß P die Verteilung des r-ten Zufallszeitpunktes beschreibt. Wenn es ein solches P gibt, so berechnet $P((0, t])$ die Wahrscheinlichkeit, dass der r-te Druckauftrag bis zur Zeit t eintritt. Dies ist die Wahrscheinlichkeit für mindestens r Druckaufträge im Zeitraum $(0, t]$. Unsere POISSON-Annahme führt zum Ansatz

$$P((0, t]) = 1 - \sum_{k=0}^{r-1} \pi_{\lambda t}(k).$$

Eine einfache Rechnung zeigt:

$$P((0, t]) = 1 - e^{-\lambda t} \sum_{k=0}^{r-1} \frac{(\lambda t)^k}{k!} = \int_0^t \frac{\lambda^r}{(r-1)!} x^{r-1} e^{-\lambda x}\, dx. \tag{14.4}$$

14.1.4 Aufgabe: Zeigen Sie (14.4).

Die gesuchte Wahrscheinlichkeit P auf $(0, \infty)$ hat also die Dichtefunktion

$$\gamma_{\lambda,r}(x) := \lambda^r x^{r-1} e^{-\lambda x}/(r-1)!$$

Dass dies immer eine Wahrscheinlichkeitsdichte ist, kann man mithilfe der EULER'schen Gammafunktion Γ nachweisen. Für $r = 1$ erhalten wir die Exponentialverteilung: Die Verteilung des ersten Zeitpunktes im POISSON-Modell für rein zufällige Punkte ist die Exponentialverteilung. Man spricht von einer kontinuierlichen Wartezeitverteilung auf den ersten Erfolg, im Unterschied zur diskreten Wartezeitverteilung auf den ersten Treffer im Münzwurf, die durch die geometrische Verteilung gegeben ist.

14.1.5 Definition: Für jedes $\lambda, r > 0$ ist die Dichte der *Gamma-Verteilung* auf $(0, \infty)$ gegeben durch

$$\gamma_{\lambda,r}(x) := \frac{\lambda^r}{\Gamma(r)} x^{r-1} e^{-\lambda x}, \quad x \geq 0.$$

14.1.6 Aufgabe: Die EULER'sche Gammafunktion ist gegeben durch

$$\Gamma(r) := \int_0^\infty y^{r-1} e^{-y}\, dy, \quad r > 0. \tag{14.5}$$

Damit gilt $\Gamma(r) = (r-1)!$ für $r \in \mathbb{N}$. Zeigen Sie, dass die Funktion $\gamma_{\lambda,r}$ eine Dichte ist.

Die Gamma-Verteilung zu den Parametern λ (Skalenparameter) und r (Formparameter) ist die Verteilung des r-ten Zeitpunktes im POISSON-Modell für rein zufällige Zeitpunkte. Man spricht von einer kontinuierlichen Wartezeit auf den r-ten Erfolg, im Unterschied zur diskreten Wartezeit auf den r-ten Treffer im Münzwurf, die der negativen Binomialverteilung unterliegt.

14.1.7 Aufgabe: Bestimmen Sie den Erwartungswert einer Gamma-verteilten Zufallsgröße X.

14.2 Poisson-Approximation

Wir zeigen nun, dass die POISSON-Verteilung eine Approximation der Binomialverteilung ist, wenn n groß und p klein sind. Zunächst überlegt man sich, in welcher Beziehung α zu den Parametern n, p der Binomialverteilung stehen soll. Wir wählen α so, dass die Erwartungswerte übereinstimmen, dass also $\alpha = np$ ist. $b(k; n, p)$ liegt nahe bei $\pi_\alpha(k)$ für $\alpha = np$. Um das zu präzisieren, leiten wir eine konkrete Schranke für

$$\Delta(n,p) := \sum_{k=0}^{\infty} |b(k;n,p) - \pi_{np}(k)|$$

her. Wir zeigen ein allgemeineres Resultat:

14.2.1 Satz: Es seien $X_1, \ldots, X_n$ unabhängige Zufallsvariablen, definiert auf einem gemeinsamen Wahrscheinlichkeitsraum, mit $P(X_i = 1) = p_i$ und $P(X_i = 0) = 1 - p_i$ mit $0 < p_i < 1$ für alle $i = 1, \ldots, n$. Sei $X := X_1 + \cdots + X_n$ und $\lambda := p_1 + \cdots + p_n$, dann gilt:

$$\sum_{k=0}^{\infty} |P(X = k) - \pi_\lambda(k)| \leq 2 \sum_{i=1}^{n} p_i^2.$$

Es folgt also im Fall $p = p_1 = \cdots = p_n$:

14.2.2 Satz: Für alle $n \in \mathbb{N}$ und $p \in (0,1)$ gilt

$$\Delta(n,p) \leq 2np^2. \tag{14.6}$$

Bevor wir Satz 14.2.1 beweisen, notieren wir einige Kommentare:

14.2.3 Bemerkung: Die Schranke ist nur für kleine p_i interessant. Man kann daraus Grenzwertaussagen ableiten. Wir lassen dabei (im Falle $p = p_i$) p von n

abhängen ($p := p_n$) und n nach unendlich streben. Falls $\lim_{n\to\infty} np_n^2 = 0$ gilt, so folgt aus (14.6), dass $\lim_{n\to\infty} \Delta(n, p_n) = 0$ gilt. Insbesondere folgt der sogenannte POISSON'sche Grenzwertsatz, der im Jahre 1832 entdeckt wurde:

14.2.4 Satz: (Grenzwertsatz von POISSON) Ist $\alpha > 0$ und gilt $np_n \to \alpha$ für $n \to \infty$, so gilt für jedes $k \in \mathbb{N}_0$:

$$\lim_{n\to\infty} b(k; n, p_n) = \pi_\alpha(k). \tag{14.7}$$

Dieser Satz beweist (14.1).

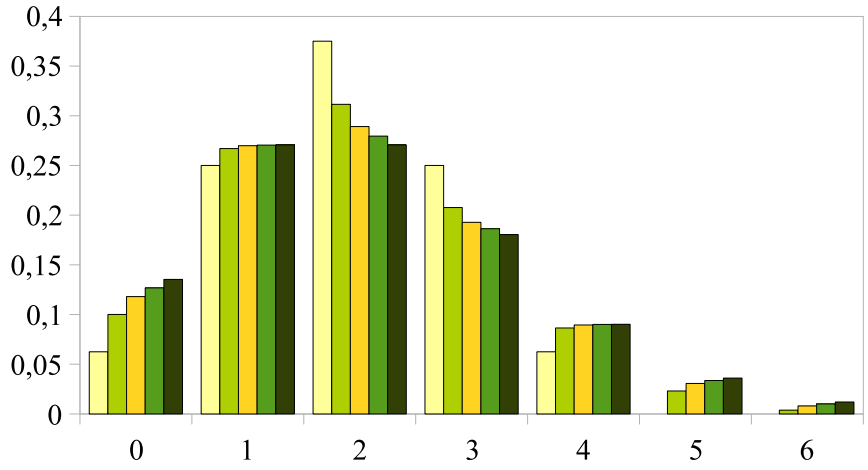

Abb. 14.1: Die POISSON-Approximation im Fall $\alpha = 2$: für $k \in \mathbb{N}_0$ zeigen die Balken von links (hell) nach rechts der Reihe nach $b(k; n; 2/n)$ für $n = 4, 8, 16, 32$, und den Limes $\pi_2(k)$ (dunkel).

14.2.5 Bemerkung: Im Grenzwertsatz von POISSON wird die Konvergenz einer Folge diskreter Verteilungen gegen eine ebenfalls diskrete Verteilung betrachtet, wobei die Limesverteilung auf der abzählbaren Menge $\mathbb{N}_0$ lebt. Wir lernen auch Grenzwertsätze kennen, bei denen aus einer diskreten Verteilung auf einer endlichen oder unendlichen Menge durch Grenzwertbildung eine absolut stetige Verteilung werden kann.

14.2.6 Bemerkung: Wie gut ist die Abschätzung $2np^2$? Wir betrachten den Fall $k = 0$ und erhalten

$$P(X = 0) - \pi_{np}(0) = e^{n\ln(1-p)} - e^{-np}.$$

Verwenden wir nun die TAYLOR-Entwicklung von $\ln(1-p)$, so erhalten wir

$$\Big|P(X=0)-\pi_{np}(0)\Big| \approx \frac{e^{-np}}{2}np^2.$$

Wenn $\frac{e^{-np}}{2}$ nicht zu klein ist, so ist im Fall $k=0$ die Abschätzung (14.6) kaum zu verbessern. Für np groß ist allerdings e^{-np} von Bedeutung. Hier ist die in (14.6) gefundene Abschätzung nicht so gut. Situationen mit großem Erwartungswert np werden demnach nicht in ihrer tatsächlich vorliegenden Güte der Approximation erfasst.

Die Aussage in (14.7) folgt sofort aus (14.6):

Aus $np_n \to \alpha$ folgt $p_n \to 0$ für $n \to \infty$ und $np_n^2 \to 0$. Ferner ist $|b(k;n,p) - \pi_{np}(k)| \leq \Delta(n,p)$ für jedes $k \in \mathbb{N}_0$. Demzufolge gilt

$$\lim_{n\to\infty} |b(k;n,p_n) - \pi_{np_n}(k)| = 0.$$

Wegen $\pi_{np_n}(k) \to \pi_\alpha(k)$ folgt (14.7).

14.2.7 Bemerkung: Die Aussage (14.6) ist auch im Fall, in dem $np_n^2 \to 0$ und $np_n \to \infty$ gelten, von Interesse (z.B. für $p_n = n^{-2/3}$).

Der wichtigste Vorzug von Satz 14.2.1 im Vergleich zu (14.7) ist jedoch, dass eine ganz konkrete Approximationsschranke vorliegt. Zu festem p und n können wir somit eine Abschätzung der Güte der POISSON-Approximation geben. Die Bedingung des Grenzwertsatzes bedeutet hingegen, dass eine wachsende Anzahl von Versuchen eine immer kleiner werdende Erfolgswahrscheinlichkeit p_n so kompensiert, dass die erwartete Erfolgszahl konstant bleibt. Für den reinen Münzwurf mutet die Bedingung kleiner werdender Erfolgswahrscheinlichkeiten etwas seltsam an. Für das eingangs ausgeführte Beispiel der zufällig eintreffenden Druckaufträge oder Schadensfälle hingegen wirkte die Bedingung nicht künstlich. Auch in dem folgenden Beispiel ist die Bedingung sinnvoll:

14.2.8 Beispiel: Wir werfen rein zufällig ein Teilchen in einen Behälter $V \subset \mathbb{R}^3$ mit Volumen $|V|$ und fragen, ob dabei ein vorgegebenes Teilgebiet v mit Volumen $|v|$ getroffen wurde. Wir modellieren mittels $\Omega := \{0,1\}$ für Nicht-Treffer und Treffer des Teilgebietes v und setzen

$$P(\{1\}) := p := \frac{|v|}{|V|}.$$

Das unabhängige Werfen von n Teilchen modellieren wir durch den Produktraum, die zufällige Anzahl der Treffer im Teilgebiet v ist dann binomialverteilt. Nun betrachten wir den Übergang zu einem sehr großen Teilchensystem: Gegeben sei eine Folge $(V_l)_l$ von Teilgebieten, die gegen den $\mathbb{R}^3$ aufsteigen. Die von l abhängige Teilchenzahl n_l sei so gewählt, dass

$$\lim_{l\to\infty} \frac{n_l}{|V_l|} = \varrho > 0.$$

Die Dichte der Teilchen soll also „konstant“ gehalten werden. Dann folgt aus dem Poisson'schen Grenzwertsatz, dass die Trefferzahl Poisson-verteilt ist mit Parameter $\varrho|v|$.

Satz 14.2.1 ist natürlich aufwendiger zu beweisen als Satz 14.2.4. Obwohl – wie oben gesehen – letzterer eine unmittelbare Folge von Satz 14.2.1 ist, skizzieren wir den üblichen Standardbeweis, der sehr kurz ist:

Beweis von Satz 14.2.4: Setze $\alpha_n := np_n$. Nach Voraussetzung gilt $\alpha_n \to \alpha$.

$$\begin{aligned} b(k;n,p_n) &= b\Big(k;n,\frac{\alpha_n}{n}\Big) = \binom{n}{k}\left(\frac{\alpha_n}{n}\right)^k\left(1-\frac{\alpha_n}{n}\right)^{n-k} \\ &= \frac{n(n-1)\cdots(n-k+1)}{k!}\frac{\alpha_n^k}{n^k}\frac{(1-\alpha_n/n)^n}{(1-\alpha_n/n)^k} \\ &= \frac{\alpha_n^k}{k!}\frac{1}{(1-\alpha_n/n)^k}\left(1-\frac{1}{n}\right)\left(1-\frac{2}{n}\right)\times\cdots\times\left(1-\frac{k-1}{n}\right)\left(1-\frac{\alpha_n}{n}\right)^n. \end{aligned}$$

Wegen $\alpha_n \to \alpha$ folgt $\alpha_n/n \to 0$. Weiter hat die Funktion $\ln(x)$ an der Stelle 1 den Ableitungswert 1, also gilt $\ln(1-h) = -h + h\Delta(h)$ mit $\Delta(h) \to 0$ für $h \to 0$. Es folgt

$$\left(1-\frac{\alpha_n}{n}\right)^n = \exp\left(n\left(-\frac{\alpha_n}{n} + \frac{\alpha_n}{n}\Delta\left(\frac{\alpha_n}{n}\right)\right)\right) \to \exp(-\alpha).$$

Wir erhalten also insgesamt

$$\lim_{n\to\infty} b(k;n,p_n) = \frac{\alpha^k}{k!}\lim_{n\to\infty}\left(1-\frac{\alpha_n}{n}\right)^n = e^{-\alpha}\frac{\alpha^k}{k!}.$$

□

Die unten stehende Tabelle gibt einige numerisch ermittelte Anhaltspunkte für den

Vergleich zwischen Binomial- und POISSON-Verteilung ($p := 0.1$).

k	$\pi_{0.5}(k)$	$b(k; 5, 0.1)$
0	0.6065	0.5905
1	0.3033	0.3281
2	0.0768	0.0729
3	0.0126	0.0081
4	0.00158	0.00045
5	0.00016	0.00001

k	$\pi_2(k)$	$b(k; 20, 0.1)$
0	0.1353	0.1216
1	0.2707	0.2702
2	0.2707	0.2852
3	0.1804	0.1901
5	0.0361	0.0319
10	0.000038	0.000052

14.2.9 Beispiel: Wir rechnen ein Beispiel: Gegeben seien 10^4 Säcke mit Korn. Es sei bekannt, dass sich in diesen Säcken 5000 markierte Körner befinden. Wie groß ist die Wahrscheinlichkeit, dass in irgendeinem fixierten Sack wenigstens ein markiertes Korn ist? Es ist $p = \frac{1}{10^4}$ und $n = 5000$ (Körner zufällig auf Säcke verteilen). Also ist $n\,p = 0.5$. Setze $X_k := 1$, wenn das k-te Korn in dem ausgewiesenen Sack ist, und $X_k := 0$ sonst. Dann ist

$$P\left(\sum_{k=1}^{5000} X_k = 0\right) \approx e^{-n\,p} = e^{-0.5},$$

also ist die gesuchte Wahrscheinlichkeit $\approx 1 - e^{-0.5}$. Der Fehler ist kleiner oder gleich 10^{-4}, also erstaunlich klein.

14.2.10 Aufgabe: Auf einem Autobahnabschnitt ereignen sich im Durchschnitt monatlich zwei schwere Verkehrsunfälle. Mit welcher Wahrscheinlichkeit ereignen sich in einem Monat mindestens vier schwere Unfälle?

14.2.11 Aufgabe: In einem Hörsaal seien 253 Studierende. Die Wahrscheinlichkeit p, heute Geburtstag zu haben, sei $p = 1/365$. Durch welche Verteilung kann man die Verteilung der Zahl X derer approximieren, die heute Geburtstag haben?

14.2.12 Aufgabe: Von einer Ware ist ein kleiner Anteil $p = 0.01$ schon bei der Produktion defekt. Wie groß muss man n wählen, damit eine Kiste mit n (unabhängigen) Exemplaren der Ware mit Wahrscheinlichkeit ≥ 0.9 mindestens 150 intakte Exemplare enthält?

Bevor wir den Beweis von Satz 14.2.1 geben, stellen wir einen wichtigen Aspekt der POISSON-Verteilung bereit:

14.2.13 Satz: X und Y seien unabhängig und POISSON-verteilt mit Parametern $\lambda > 0$ beziehungsweise $\mu > 0$. Dann ist $X + Y$ POISSON-verteilt mit Parameter $\lambda + \mu$.

Beweis: Für $n \in \mathbb{N}_0$ gilt:

$$\begin{aligned} P(X+Y=n) &= \sum_{k=0}^{n} P(X=k, Y=n-k) \\ &= \sum_{k=0}^{n} P(X=k)P(Y=n-k) \quad \text{(Unabhängigkeit)} \\ &= \sum_{k=0}^{n} \frac{\lambda^k}{k!}\frac{\mu^{n-k}}{(n-k)!}e^{-\lambda}e^{-\mu} = \frac{1}{n!}\left(\sum_{k=0}^{n}\binom{n}{k}\lambda^k\mu^{n-k}\right)e^{-(\lambda+\mu)} \\ &= \frac{1}{n!}(\lambda+\mu)^n e^{-(\lambda+\mu)} = \pi_{\lambda+\mu}(n). \end{aligned}$$

□

14.2.14 Bemerkung: Per Induktion folgt sofort, dass die Summe von endlich vielen unabhängigen POISSON-verteilten Zufallsgrößen wieder POISSON-verteilt ist, wobei der Parameter sich als Summe der Einzelparameter ergibt.

Der Beweis des Satzes 14.2.1 verwendet eine Technik, die man *Kopplung* nennt. Nehmen wir an, f und g seien zwei Wahrscheinlichkeitsverteilungen auf $\mathbb{N}_0$: $f, g : \mathbb{N}_0 \to [0,1]$, $\sum_{k=0}^{\infty} f(k) = \sum_{k=0}^{\infty} g(k) = 1$. Wir wollen zeigen, dass $\sum_{k=0}^{\infty} |f(k) - g(k)|$ klein ist. Wir werden das tun, indem wir Zufallsgrößen X, Y auf einem gemeinsamen Wahrscheinlichkeitsraum Ω konstruieren, die die Verteilung f beziehungsweise g haben, und die „möglichst weitgehend“ übereinstimmen. Es soll also die folgende Situation vorliegen:

$$f(k) = P(X=k), \quad g(k) = P(Y=k).$$

A sei ein Ereignis mit $X(\omega) = Y(\omega)$ für $\omega \in A$, das heißt $A \subseteq \{\omega : X(\omega) = Y(\omega)\}$. Man sagt, X und Y seien auf A „gekoppelt“.

14.2.15 Lemma: Unter den obigen Bedingungen gilt

$$\sum_{k=0}^{\infty} |f(k) - g(k)| \leq 2P(A^c).$$

Beweis: Es sei $M := \{k \in \mathbb{N}_0 : f(k) > g(k)\}$. Dann ist

$$\begin{aligned}
\sum_{k=0}^{\infty} |f(k) - g(k)| &= \sum_{k \in M} (f(k) - g(k)) - \sum_{k \notin M} (f(k) - g(k)) \\
&= 2 \sum_{k \in M} (f(k) - g(k)) - \sum_{k=0}^{\infty} (f(k) - g(k)) \\
&= 2[P(X \in M) - P(Y \in M)] - (1 - 1) \\
&= 2[P(X \in M, A) + P(X \in M, A^c) - P(Y \in M)] \\
&\leq 2[P(X \in M, A) + P(A^c) - P(Y \in M)] \\
&= 2[P(Y \in M, A) + P(A^c) - P(Y \in M)] \\
&\leq 2P(A^c).
\end{aligned}$$

□

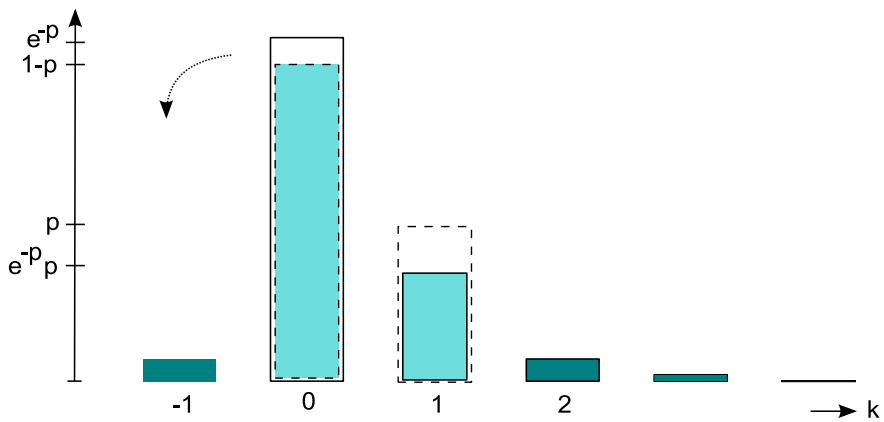

Abb. 14.2: Zur Kopplung einer POISSON-Verteilung zum Parameter p_i (gerahmte Balken) und einer BERNOULLI-Verteilung zum Parameter p_i (gestrichelte Balken). Der hellere *Durchschnitt* der Histogramme, sowie der dunklere *Differenzbereich* definieren die Verteilung der P_i.

Beweis von Satz 14.2.1: Wir wenden nun dieses Kopplungsargument an, um Satz 14.2.1 zu beweisen. Der Hauptteil des Beweises besteht in einer geeigneten Wahl des zugrundeliegenden Wahrscheinlichkeitsraumes. Da wir nur die Verteilung von X berechnen müssen, ist es quasi egal, auf welchem Wahrscheinlichkeitsraum die Zufallsgrößen X_i definiert werden. Es ist für uns nur wichtig, dass die Zufallsgrößen unabhängig sind und $P(X_i = 1) = p_i$ sowie $P(X_i = 0) = 1 - p_i$ gilt. Diese Freiheit nutzen wir für eine Wahl derart, dass eine POISSON-verteilte Zufallsgröße zum Parameter λ möglichst weitgehend mit X in Verteilung übereinstimmt. Dazu

sei $\Omega_i := \{-1, 0, 1, 2, \ldots\}$, $P_i(0) := 1 - p_i$ und $P_i(k) := \frac{e^{-p_i}}{k!} p_i^k$ für $k \geq 1$ sowie $P_i(-1) := 1 - P_i(0) - \sum_{k \geq 1} P_i(k) := e^{-p_i} - (1 - p_i)$. Nach Konstruktion sind somit (Ω_i, P_i) W.-Räume. Betrachte dann den Produktraum (Ω, P) der (Ω_i, P_i) im Sinne der Definition 9.2.1. Wir setzen für $\omega \in \Omega$

$$X_i(\omega) := \begin{cases} 0, & \text{falls} \quad \omega_i = 0, \\ 1, & \text{falls} \quad \omega_i \neq 0 \end{cases}$$

und

$$Y_i(\omega) := \begin{cases} k, & \text{falls} \quad \omega_i = k, k \geq 1, \\ 0, & \text{falls} \quad \omega_i \in \{-1, 0\}. \end{cases}$$

Dann haben nach Definition die Zufallsgrößen X_i die geforderte Verteilung: $P(X_i = 1) = p_i$ und $P(X_i = 0) = 1 - p_i$. Sie sind weiter nach Definition des Produktraumes unabhängig. Die Y_i sind nach Definition Poisson-verteilt zum Parameter p_i und ebenfalls unabhängig. Also folgt mit Lemma 14.2.13, dass $Y := Y_1 + \cdots + Y_n$ Poisson-verteilt ist zum Parameter $\lambda = p_1 + \cdots + p_n$. Nun stimmen die Zufallsgrößen in den Werten 0 und 1 überein, und es ist $P(X_i = Y_i) = P_i(0) + P_i(1) = (1 - p_i) + e^{-p_i} p_i$, und somit

$$P(X_i \neq Y_i) = p_i(1 - e^{-p_i}) \leq p_i^2,$$

denn für $x \geq 0$ gilt $1 - e^{-x} \leq x$. Nach Lemma 14.2.15 folgt dann

$$\sum_{k=0}^{\infty} |P(X = k) - \pi_\lambda(k)| \leq 2P(X \neq Y) \leq 2 \sum_{i=1}^{n} P(X_i \neq Y_i) \leq 2 \sum_{i=1}^{n} p_i^2.$$

Damit ist Satz 14.2.1 bewiesen. □

14.2.16 Beispiel: Satz 14.2.1 betrachtet eine Summe unabhängiger Zufallsgrößen mit Werten in $\{0, 1\}$, also eine Indikatorsumme. Es bezeichne nun X_n die Anzahl der Fixpunkte einer rein zufälligen Permutation der Zahlen $1, 2, \ldots, n$ (siehe Beispiel 6.2.27 - das Rencontre-Problem). Hier ist X_n eine Indikatorsumme von nicht unabhängigen Ereignissen. In Aufgabe 10.1.21 haben wir die Verteilung von X_n hergeleitet:

$$P(X_n = k) = \frac{1}{k!} \sum_{i=0}^{n-k} \frac{(-1)^i}{i!}, \quad i = 0, 1, \ldots, n.$$

Nun ist offensichtlich

$$\lim_{n \to \infty} P(X_n = k) = \frac{1}{k!} e^{-1}.$$

Also nähert sich die Verteilung von X_n für $n \to \infty$ der Poisson-Verteilung zum Parameter $\alpha = 1$ an. Damit liegt ein *Gesetz seltener Ereignisse* auch in diesem

Fall vor. Wir erinnern, dass $\mathbb{E}(X_n) = \mathbb{V}(X_n) = 1$ ist (siehe Beispiel 11.1.14 und 11.2.18(c)). Der Parameter $\alpha = 1$ überrascht uns also gar nicht. Weiter sind nach Lemma 14.1.2 Erwartungswert und Varianz einer POISSON-Verteilung gleich groß. Es mag etwas naiv klingen, dass die Eigenschaft, dass die Anzahl X_n ebenfalls diese Eigenschaft hat, ein Hinweis darauf sein könnte, dass die Verteilung von X_n sich der POISSON-Verteilung annähert. Es gibt aber eine Theorie, die in vielen Modellen bestätigt, dass bei Übereinstimmung von Erwartungswert und Varianz POISSON-Approximierbarkeit vorliegt – bei seltenen Ereignisse. Wir führen dies nicht aus.

Erstaunlich ist, dass viele verschiedene, natürliche oder künstlich erzeugte Zufallserscheinungen recht gut zum POISSON-Schema passen. Zunächst betrachten wir ein historisches Beispiel:

14.2.17 Beispiel: Über einen Zeitraum von 20 Jahren wurde im alten Preußen die Zahl der Toten durch Hufschlag in 10 Kavallerieregimenten beobachtet. Insgesamt hatte man also 200 „Regimentsjahre“ beobachtet. Es ergab sich das folgende Bild:

k =Anzahl der Toten	Anzahl Regimentsjahre mit k Toten	$200 \cdot \pi_\alpha(k)$ mit $\alpha = 0.61$ (gerundet)
0	109	109
1	65	66
2	22	20
3	3	4
4	1	1
≥ 5	0	0

(α wurde so bestimmt, dass sich die beste Übereinstimmung ergibt.)

Die theoretische Begründung für die gute Übereinstimmung ist etwa die: Für den einzelnen Kavalleristen ist die Wahrscheinlichkeit p, in einem Jahr vom Pferd erschlagen zu werden, sehr klein. Hat das Regiment n Kavalleristen, so ist die Verteilung der Anzahl der Toten pro Regiment und Jahr $\approx b(k; n, p) \approx \pi_\alpha(k)$. Nach dem Gesetz der großen Zahlen ist dann bei 200 Wiederholungen des „Versuchs“ die Anzahl der Regimentsjahre mit k Toten $\approx 200 \cdot \pi_\alpha(k)$. Die obige Übereinstimmung ist jedoch eher ungewöhnlich. Wegen der fast perfekten Übereinstimmung wird das Beispiel immer wieder zitiert.

Die bereits 1832 entdeckte POISSON-Approximation blieb lange Zeit vergessen. Erst 1898 zeigte LADISLAUS VON BORTKIEWICZ (1868–1931) in seinem Buch „Das Gesetz der kleinen Zahlen“ die Bedeutung dieser Approximation für die Praxis. Das obige Beispiel entstammt diesem Buch.

14.3 Der Poisson'sche Punktprozess

Als eine Anwendung vom Poisson'schen Grenzwertsatz diskutieren wir nun das Rutherford-Geiger-Müller-Experiment sowie allgemeiner den sogenannten Poisson'schen Punktprozess.

Ernest Rutherford (1871–1937) hat im Jahre 1910 mithilfe eines Geiger-Müller-Zählers über 2608 Zeitintervalle von jeweils 7.5 Sekunden Länge ein radioaktives Präparat untersucht (α-Teilchen). Er hat dabei 10097 Zerfälle gezählt, im Durchschnitt 3.87 Zerfälle innerhalb von 7.5 Sekunden. Die Versuchsergebnisse sind der folgenden Tabelle zu entnehmen:

k	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
n_k	57	203	383	525	532	408	273	139	45	27	10	4	0	1	1

Hier bezeichnet n_k die Anzahl der Zeitintervalle, in denen k Zerfälle beobachtet wurden. Im Folgenden ist die empirische relative Häufigkeitsverteilung zu diesen Daten zu sehen. Darüberhinaus wird die angepasste Poisson-Verteilung in Form eines Stabdiagramms dargestellt. Anpassung bedeutet, dass der Parameter α als das arithmetische Mittel 3.87 angesetzt wurde. Es ist eine erstaunliche Übereinstimmung zu beobachten. Wir wollen dieses Phänomen erklären. Dazu machen wir einige Modellannahmen.

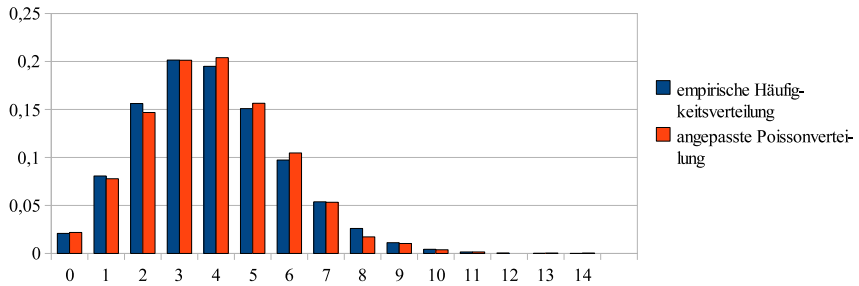

Abb. 14.3: Zerfallshäufigkeiten beim Rutherford-Geiger-Müller-Versuch mit angepasster Poisson-Verteilung

Es sei $I = (0, 1]$ der Untersuchungszeitraum (ohne Einschränkung) und X die Anzahl der Zerfälle in I. Der Erwartungswert von X existiere: $\lambda := \mathbb{E}(X)$. Unter welchen Annahmen ist X annähernd Poisson-verteilt?

Zunächst zerlegen wir I in n gleichlange Teilintervalle I_j, $j = 1, \ldots, n$, und zerlegen

$$X = X_{n,1} + \ldots + X_{n,n},$$

wobei $X_{n,j}$ die Anzahl der Zerfälle in I_j bezeichne. Wir nehmen nun an, dass die $X_{n,j}$ unabhängig und identisch verteilt sind. Die Unabhängigkeitsannahme entspricht der plausiblen Annahme der sogenannten spontanen Emission: Der Zerfall eines Atoms geschehe unabhängig von den anderen Atomen spontan. Der Zerfall geschehe weiterhin ohne Alterungserscheinungen, sodass die Anzahl $X_{n,j}$ nur von der Länge des Intervalls abhänge. Aus dieser Annahme folgt, dass $\mathbb{E}(X_{n,j}) = \lambda/n$.

Die nun folgende Annahme nennt man *Regularitätsbedingung*: Es gelte

$$\lim_{n\to\infty} P\left(\bigcup_{j=1}^{n}\left\{X_{n,j} \geq 2\right\}\right) = 0.$$

Das Auftreten von mehr als einem Zerfall in irgendeinem Teilintervall I_j soll immer unwahrscheinlicher werden, wenn man die Intervallzerlegung verfeinert. Ein hübscher Trick als Folge dieser Regularitätsbedingung ist, die Variable $X_{n,j}$ durch die Indikatorvariable $1_{\{X_{n,j}\geq 1\}}$ zu approximieren. Sobald $X_{n,j} = 0$ oder $X_{n,j} = 1$ ist, stimmt diese Indikatorvariable mit $X_{n,j}$ überein. Wir betrachten

$$Y := \sum_{j=1}^{n} 1_{\{X_{n,j}\geq 1\}}.$$

Mit den $X_{n,j}$ sind die Ereignisse $\{X_{n,j} \geq 1\}$ unabhängig und sie haben alle die gleiche Wahrscheinlichkeit $p_n := P(X_{n,j} \geq 1)$. Somit ist Y binomialverteilt zu den Parametern n und p_n. Nun ist

$$p_n = P(X_{n,j} \geq 1) = \mathbb{E}(1_{\{X_{n,j}\geq 1\}}) \leq \mathbb{E}(X_{n,j}) = \frac{\lambda}{n}.$$

Wir fordern noch $\lim_{n\to\infty} np_n = \lambda$ und erhalten mithilfe des POISSON'schen Grenzwertsatzes 14.2.4

$$\lim_{n\to\infty} P(Y = k) = \pi_\lambda(k).$$

Die Idee ist nun, dass unter Anwendung der Regularitätsbedingung die Approximation durch die Indikatorvariablen so gut ist, dass sich die POISSON'sche Limesverteilung von Y auf X überträgt. Es gilt

$$\begin{aligned} P(X = k) &= P(X = k, X = Y) + P(X = k, X \neq Y) \\ &= P(Y = k, X = Y) + P(X = k, X \neq Y) \\ &= P(Y = k) - P(Y = k, X \neq Y) + P(X = k, X \neq Y). \end{aligned}$$

Wenn das Ereignis $\{X \neq Y\}$ eintritt, muss mindestens ein $X_{n,j}$ verschieden sein von $1_{\{X_{n,j}\geq 1\}}$, also muss mindestens ein $X_{n,j} \geq 2$. Also ist

$$P(X \neq Y) \leq P\left(\bigcup_{j=1}^{n}\left\{X_{n,j} \geq 2\right\}\right),$$

und nach der Regularitätsbedingung folgt $\lim_{n\to\infty} P(X \neq Y) = 0$. Somit folgt insbesondere

$$\lim_{n\to\infty} P(Y = k, X \neq Y) = \lim_{n\to\infty} P(X = k, X \neq Y) = 0$$

und daher $P(X = k) = \lim_{n\to\infty} P(Y = k) = \pi_\lambda(k)$, was zu zeigen war.

14.3.1 Aufgabe: Ein GEIGER-MÜLLER-Zähler registriert ein radioaktives Teilchen, das von einer radioaktiven Quelle emittiert wurde, mit Wahrscheinlichkeit 10^{-3}. Es werden 25000 Teilchen während der vorgegebenen Beobachtungszeit emittiert. Berechnen Sie die Wahrscheinlichkeit dafür, dass der GEIGER-MÜLLER-Zähler kein Teilchen und dass er zwei oder mehr Teilchen registriert.

Wir konstruieren nun ein mathematisches Modell für auf einer Zeitachse zufällig eintretende Vorkommnisse. Beispiele sind ankommende Anrufe in einer Telefonzentrale, die Registrierung radioaktiver Teilchen in einem GEIGER-MÜLLER-Zähler, Impulse in einer Nervenfaser oder die eingangs diskutierten Druckaufträge. Wir hatten bisher gesehen, dass die POISSON-Verteilung auf $\mathbb{N}_0$ ein geeignetes Modell für die Anzahl der rein zufälligen Zeitpunkte in einem Zeitintervall ist.

Die Zeitachse sei nun $(0, \infty)$, und die „Vorkommnisse" seien zufällige Punkte auf dieser Achse, siehe Abb. 14.4. Im Rahmen dieses Kurses ist es nicht möglich, einen formalen Wahrscheinlichkeitsraum zu konstruieren. Das folgende Modell nennen wir den *POISSON'schen Punktprozess*.

Ist $I = (t, t + s]$ ein halboffenes Intervall, so bezeichnen wir mit N_I die zufällige Anzahl der Punkte in I. N_I ist also eine Zufallsgröße mit Werten in $\mathbb{N}_0$. Statt $N_{(0,t]}$ schreiben wir auch einfach N_t.

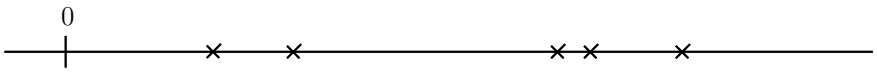

Abb. 14.4: zufällige Punkte

An unser Modell stellen wir eine Anzahl von Bedingungen (P1) bis (P5):

(P1) Die Verteilung von N_I hängt nur von der Länge des Intervalls I ab. Anders ausgedrückt: Haben die beiden Intervalle I, I' dieselbe Länge, so haben die Zufallsgrößen N_I und $N_{I'}$ dieselbe Verteilung. Man bezeichnet das auch als (zeitliche) Homogenität des Punktprozesses.

(P2) Sind $I_1, I_2, \ldots, I_k$ paarweise disjunkte Intervalle, so sind $N_{I_1}, N_{I_2}, \ldots, N_{I_k}$ unabhängige Zufallsgrößen.

(P3) Für alle I (stets mit endlicher Länge) existiert $\mathbb{E}(N_I)$.

(P4) Es existiert ein Intervall I mit $P(N_I > 0) > 0$.

Aus (P1), (P3), (P4) lassen sich schon einige Schlüsse ziehen: Sei

$$\alpha(t) := \mathbb{E}(N_t) \geq 0.$$

Offensichtlich gilt $\alpha(0) = 0$, denn N_0 setzen wir 0. Die Anzahl der Punkte in einer Vereinigung disjunkter Intervalle ist natürlich die Summe der Punktanzahlen in den Einzelintervallen. Insbesondere gilt $N_{t+s} = N_t + N_{(t,t+s]}$. Demzufolge ist $\alpha(t+s) = \alpha(t) + \mathbb{E}(N_{(t,t+s]})$, was wegen (P1) zu $\alpha(t+s) = \alpha(t) + \alpha(s)$ führt. Nach einem Satz aus der Analysis, der hier nicht bewiesen werden soll, muss eine derartige Funktion linear sein, das heißt, es existiert ein $\lambda \geq 0$ mit $\alpha(s) = \lambda s$. Wegen (P4) können wir $\lambda = 0$ sofort ausschließen. In diesem Fall müsste nach (P1) $\mathbb{E}(N_I) = 0$ für jedes Intervall gelten. Dies widerspricht offensichtlich (P4).

Für kleine Intervalle ist die Wahrscheinlichkeit dafür, dass überhaupt ein Punkt in diesem Intervall liegt, klein. Es gilt nämlich:

$$P(N_I \geq 1) = \sum_{k=1}^{\infty} P(N_I = k) \leq \sum_{k=1}^{\infty} kP(N_I = k) = \mathbb{E}(N_I)$$

und demzufolge

$$P(N_{(t,t+\varepsilon]} \geq 1) \leq \lambda\varepsilon \quad \text{für alle } t, \varepsilon \geq 0.$$

Unsere letzte Forderung ist, dass die Wahrscheinlichkeit für zwei oder mehr Punkte in einem kleinen Intervall noch etwas kleiner ist, genauer

(P5) Es sei $\lim_{\varepsilon \to 0} \varepsilon^{-1} P(N_\varepsilon \geq 2) = 0$.

Man kann nachweisen, dass (P5) nur die Möglichkeit von Mehrfachwahlen desselben Punktes ausschließt; wir wollen das jedoch nicht weiter ausführen. (P5) entspricht der Regularitätsannahme im Beispiel des RUTHERFORD-Experiments.

Wir zeigen nicht, dass eine Familie von Zufallsgrößen N_I mit den Eigenschaften (P1)–(P5) als mathematisches Objekt existiert. Wir können dies im Rahmen dieser Vorlesung nicht tun. Wir können jedoch nachweisen, dass für einen Punktprozess, der (P1) bis (P5) erfüllt, die N_I alle POISSON-verteilt sein müssen:

14.3.2 Satz: Sind (P1) bis (P5) erfüllt, so sind für alle $t \geq 0$ und $s > 0$ die Zufallsgrößen $N_{(t,t+s]}$ POISSON-verteilt mit Parameter λs.

Wir führen den Beweis. An einigen Stellen entdecken wir Argumente wieder, die bei der Diskussion des RUTHERFORD-Experiments bereits auftraten.

Beweis: Wegen (P1) genügt es, $N_s = N_{(0,s]}$ zu betrachten. Wir halten $s > 0$ fest. Für $k \in \mathbb{N}$, $1 \le j \le k$, definieren wir

$$X_j^{(k)} := N_{\left(\frac{s(j-1)}{k}, \frac{sj}{k}\right]}$$

und

$$\widetilde{X}_j^{(k)} := \begin{cases} 1, & \text{falls} \quad X_j^{(k)} \ge 1, \\ 0, & \text{falls} \quad X_j^{(k)} = 0. \end{cases}$$

Für jedes feste k sind $X_1^{(k)}, \ldots, X_k^{(k)}$ nach (P2) unabhängig und $\widetilde{X}_1^{(k)}, \ldots, \widetilde{X}_k^{(k)}$ damit auch.

Wir stellen einige einfach zu verifizierende Eigenschaften dieser Zufallsgrößen zusammen:

$$N_s = \sum_{j=1}^{k} X_j^{(k)}. \tag{14.8}$$

Sei $\widetilde{N}_s^{(k)} := \sum_{j=1}^{k} \widetilde{X}_j^{(k)}$. Dann gilt für jede mögliche Konfiguration der Punkte:

$$\widetilde{N}_s^{(k)} \le N_s.$$

Demzufolge gilt für jedes $m \in \mathbb{N}_0$:

$$P(\widetilde{N}_s^{(k)} \ge m) \le P(N_s \ge m). \tag{14.9}$$

Sei

$$\begin{aligned} p_k &:= P(\widetilde{X}_i^{(k)} = 1) = P(X_i^{(k)} \ge 1) \\ &= P\left(N_{\left(\frac{s(i-1)}{k}, \frac{si}{k}\right]} \ge 1\right) \qquad \text{mit (14.8)} \\ &= P(N_{s/k} \ge 1) \qquad \text{mit (P1).} \end{aligned}$$

Dann ist $\widetilde{N}_s^{(k)}$ binomialverteilt mit Parametern k und p_k. Wir verwenden nun (P5), um nachzuweisen, dass sich für große k $\widetilde{N}_s^{(k)}$ nur wenig von N_s unterscheidet (siehe auch die Beweisführung beim RUTHERFORD-Experiment).

$$\begin{aligned} P(\widetilde{N}_s^{(k)} \ne N_s) &= P\left(\bigcup_{i=1}^{k} \{X_i^{(k)} \ge 2\}\right) \le \sum_{i=1}^{k} P(X_i^{(k)} \ge 2) \\ &= kP(N_{s/k} \ge 2) \to 0 \quad \text{für} \quad k \to \infty. \end{aligned} \tag{14.10}$$

Für $m \in \mathbb{N}_0$ und $k \in \mathbb{N}$ gilt:

$$P(N_s = m) \ \ge \ P(\widetilde{N}_s^{(k)} = m, \widetilde{N}_s^{(k)} = N_s)$$

$$\geq \quad P(\widetilde{N}_s^{(k)} = m) - P(\widetilde{N}_s^{(k)} \neq N_s)$$

und

$$\begin{aligned} P(N_s = m) &\leq P(\widetilde{N}_s^{(k)} = m,\, \widetilde{N}_s^{(k)} = N_s) + P(\widetilde{N}_s^{(k)} \neq N_s) \\ &\leq P(\widetilde{N}_s^{(k)} = m) + P(\widetilde{N}_s^{(k)} \neq N_s). \end{aligned}$$

Unter Benutzung von (14.10) folgt:

$$P(N_s = m) = \lim_{k\to\infty} P(\widetilde{N}_s^{(k)} = m) = \lim_{k\to\infty} b(m; k, p_k) \tag{14.11}$$

und analog

$$P(N_s \geq m) = \lim_{k\to\infty} P(\widetilde{N}_s^{(k)} \geq m). \tag{14.12}$$

Wir zeigen nun:

$$\lim_{k\to\infty} kp_k = \lambda s. \tag{14.13}$$

Es gilt

$$\begin{aligned} kp_k &= \mathbb{E}(\widetilde{N}_s^{(k)}) = \sum_{j=1}^{\infty} jP(\widetilde{N}_s^{(k)} = j) = \sum_{j=1}^{\infty}\sum_{l=1}^{j} P(\widetilde{N}_s^{(k)} = j) \\ &= \sum_{l=1}^{\infty}\sum_{j=l}^{\infty} P(\widetilde{N}_s^{(k)} = j) = \sum_{l=1}^{\infty} P(\widetilde{N}_s^{(k)} \geq l). \end{aligned}$$

Die vorletzte Identität erklärt sich durch Vertauschen der Summationsreihenfolge. $P(\widetilde{N}_s^{(k)} \geq l)$ ist nach (14.9) nicht größer als $P(N_s \geq l)$ und strebt nach (14.12) für $k \to \infty$ gegen diese obere Grenze. Nach einem Satz über reelle Zahlenfolgen (Übungsaufgabe!) folgt daraus

$$\lim_{k\to\infty} kp_k = \lim_{k\to\infty} \sum_{l=1}^{\infty} P(\widetilde{N}_s^{(k)} \geq l) = \sum_{l=1}^{\infty} P(N_s \geq l) = \mathbb{E}(N_s) = \lambda s.$$

Damit ist (14.13) gezeigt. Unser Satz folgt nun aus (14.11), (14.13) und dem Grenzwertsatz von POISSON. □

Die Annahmen (P1)–(P5) sind nicht immer sehr realistisch oder nur näherungsweise richtig. Problematisch in Anwendungen sind oft (P1) und (P2). Es gibt viele Möglichkeiten, den POISSON'schen Punktprozess zu verallgemeinern, um dem Rechnung zu tragen; wir wollen darauf nicht eingehen, jedoch ganz kurz auf eine Verallgemeinerung auf mehrdimensionale Räume. Die Zeitachse $(0, \infty)$ wird hier durch einen höherdimensionalen Raum $\mathbb{R}^d$, $d \geq 2$, ersetzt. Man möchte also ein

wahrscheinlichkeitstheoretisches Modell für zufällig im Raum $\mathbb{R}^d$ liegende Punkte konstruieren. Für beschränkte Mengen $A \subset \mathbb{R}^d$ bezeichne N_A die Anzahl der Punkte, die in A liegen. Unter Bedingungen, die analog zu (P1)–(P5) sind, lässt sich nachweisen, dass N_A POISSON-verteilt mit Parameter $\lambda|A|$ sein muss, wobei $|A|$ das d-dimensionale Volumen von A ist (wir denken uns hier einfach alle A, von denen wir bereits das Volumen kennen) und $\lambda > 0$ ein fester Parameter. Wir wollen das nicht beweisen, sondern nur kurz an einem Beispiel illustrieren.

14.3.3 Beispiel: Es wird eine Probe einer Flüssigkeit auf mikroskopisch kleine Partikel untersucht, z.B. Blut auf Bakterien oder Leukozyten, Trinkwasser auf Salmonellen oder ähnliches. In der Praxis wird das oft so gemacht, dass ein kleiner Teil der Probe unter dem Mikroskop untersucht und zusammen mit einem Gitternetz angeschaut wird, siehe Abb 14.5.

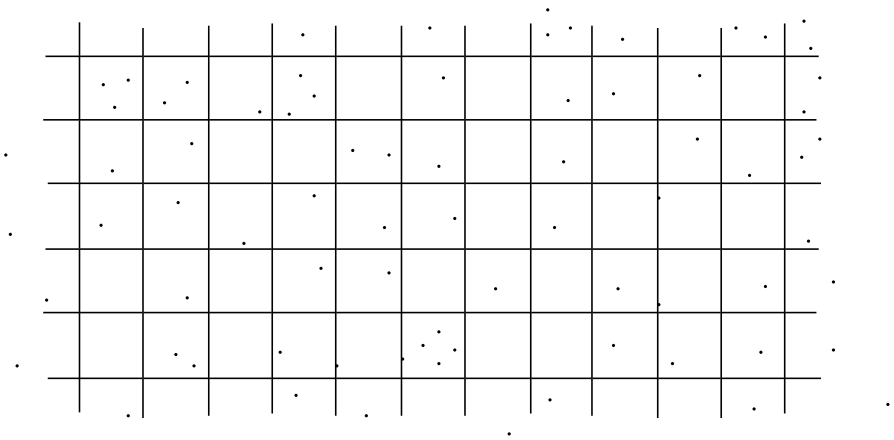

Abb. 14.5: Ein kleiner Teil der Probe unter dem Mikroskop zusammen mit einem Gitternetz

Eine Zählung aller Punkte ist oft zu aufwendig und deshalb begnügt man sich damit, nur einige Gitterquadrate auszuzählen und daraus die Gesamtzahl zu schätzen. Als Basis dieser Schätzung dient meist die Modellannahme, dass die Punkte gemäß eines POISSON'schen Punktprozesses verteilt sind, sodass insbesondere die Anzahl der Punkte N_A, die in einem Quadrat A des Gitters liegen, POISSON-verteilt ist mit Parameter $\lambda|A|$. Mithilfe einer Auszählung von wenigen Quadraten soll dann eine Schätzung des unbekannten Parameters λ vorgenommen werden. Nehmen wir einmal an, ein Laborant zählt m Quadrate $A_1, \ldots, A_m$ aus. Aufgrund dieser Auszählung soll er den Parameter λ schätzen.

Er kann zum Beispiel alles zusammenzählen, $N_A := \sum_{j=1}^m N_{A_j}$, wobei A die Vereinigung $\bigcup_{j=1}^m A_j$ ist. N_A ist ebenfalls POISSON-verteilt mit Parameter $\lambda|A|$. Eine

natürliche Schätzung von λ ist daher

$$\hat{\lambda} := \frac{N_A}{|A|}.$$

Wir wollen nicht weiter darauf eingehen, ob $\hat{\lambda}$ eine gute Schätzung ist. Vielmehr wollen wir begründen, wieso die N_A POISSON-verteilt sein sollten, ohne dabei (P1)–(P5) explizit zu nutzen. Wir stellen uns vor, dass die gesamte Probe auf einer großen Fläche liegt, die in n kleine, aber gleich große Quadrate aufgeteilt ist. Auf der gesamten Fläche sollen m Bakterien liegen, sodass im Mittel auf jedes der Quadrate $\mu := m/n$ kommen. Betrachten wir nun ein festes Quadrat A und nehmen an, dass jedes der Bakterien unabhängig von jedem anderen mit Wahrscheinlichkeit $1/n$ auf A fällt, so ist offenbar

$$P(N_A = k) = b(k; m, 1/n) \approx \pi_\mu(k),$$

falls m, n sehr groß sind. Natürlich ist $\mu = \lambda|A|$, wobei λ die mittlere Anzahl der Bakterien pro Einheitsfläche ist.

Wir können auch begründen, wieso die N_A für verschiedene Quadrate (mit paarweise leerem Schnitt) im Limes unabhängig sind. Wir beschränken uns auf zwei: A_1, A_2.

Um $P(N_{A_1} = k_1,\ N_{A_2} = k_2)$ zu berechnen, stellen wir uns die Bakterien von 1 bis m durchnummeriert vor. Das Bakterium i fällt mit Wahrscheinlichkeit $1/n$ auf A_1, mit derselben Wahrscheinlichkeit auf A_2 und mit Wahrscheinlichkeit $1 - 2/n$ auf keines der beiden (A_1, A_2 sind disjunkt). Eine einfache Abzählung ergibt, dass es $\frac{m!}{k_1!\,k_2!\,(m-k_1-k_2)!}$ Bakterienfolgen gibt mit k_1 Treffern in A_1 und k_2 Treffern in A_2. Ist der Aufenthaltsort der einzelnen Bakterien unabhängig, so ergibt sich also:

$$P(N_{A_1} = k_1,\ N_{A_2} = k_2) = \frac{m!}{k_1!k_2!(m-k_1-k_2)!}\left(\frac{1}{n}\right)^{k_1}\left(\frac{1}{n}\right)^{k_2}\left(1-\frac{2}{n}\right)^{m-k_1-k_2}.$$

Dies konvergiert gegen $\pi_\mu(k_1)\pi_\mu(k_2)$ für $m, n \to \infty$ und $\frac{m}{n} \to \mu > 0$, was man sofort mit demselben Argument wie im Beweis des POISSON'schen Grenzwertsatzes sieht.

Obgleich wir in diesem Argument (P1)–(P5) nicht vorausgesetzt haben, sie sich also von selbst ergeben, so steckt die wesentliche Unabhängigkeitsannahme natürlich darin, dass die einzelnen Bakterien unabhängig von den anderen auf die einzelnen Quadrate fallen. Das ist eine oft etwas fragwürdige Annahme, wenn man nicht weiß, ob die Probe gut durchmischt ist.

Lösungen der Aufgaben

Lösungen der Aufgaben in 14.1

Aufgabe 14.1.3

Wir wenden Lemma 11.2.5 mit $g(x) := x(x-1)$, $x \in \mathbb{R}$, an, um $\mathbb{E}\Big(X(X-1)\Big)$ für diverse diskrete Verteilungen zu bestimmen. Dann kann man mittels

$$\mathbb{V}(X) = \mathbb{E}\Big(X(X-1)\Big) + \mathbb{E}(X) - (\mathbb{E}X)^2$$

die Varianz bestimmen.

1. Es sei X Bernoulli-verteilt zum Parameter p, dann gilt

$$\mathbb{E}\Big(X(X-1)\Big) = \mathbb{E}\Big(g(X)\Big) = g(0)(1-p) + g(1)p = 0.$$

   Dann folgt $\mathbb{V}(X) = p - p^2 = p(1-p)$.

2. Es sei X hypergeometrisch verteilt mit den Parametern r, s und n, dann gilt

$$\mathbb{E}\Big(X(X-1)\Big) = \sum_{k=0}^{n} k(k-1)P(X=k).$$

   Nun gilt

$$\begin{aligned} k \cdot P(X=k) &= \frac{k\frac{r!}{k!(r-k)!}\binom{s}{n-k}}{\frac{(r+s)!}{n!(r+s-n)!}} = \frac{r\binom{r-1}{k-1}\binom{s}{(n-1)-(k-1)}}{\frac{r+s}{n}\binom{r-1+s}{n-1}} \\ &= \frac{nr}{r+s}P(Y=k-1), \end{aligned}$$

   wobei Y eine hypergeometrisch verteilte Zufallsgröße zu den Parametern $r-1$, s und $n-1$ bezeichnet. Also gilt

$$\mathbb{E}\Big(X(X-1)\Big) = \frac{nr}{r+s}\sum_{k=2}^{n}(k-1)\,P(Y=k-1) = \frac{nr}{r+s}\mathbb{E}(Y).$$

Den Erwartungswert einer hypergeometrischen Verteilung kennen wir bereits. Es ist $\mathbb{E}(Y) = \frac{(n-1)(r-1)}{(r+s-1)}$ und somit folgt

$$\mathbb{E}(X(X-1)) = \frac{n(n-1)r(r-1)}{(r+s)(r+s-1)}.$$

Damit kann dann die Formel für die Varianz einer hypergeometrischen Verteilung bestätigt werden.

3. Es sei X geometrisch verteilt zum Parameter p dann gilt

$$\begin{aligned}
\mathbb{E}(X(X-1)) &= \sum_{n=1}^{\infty} n(n-1)(1-p)^{n-1}p \\
&= p(1-p)\sum_{n=1}^{\infty} n(n-1)(1-p)^{n-2} \\
&= p(1-p)\sum_{n=1}^{\infty}\left(\frac{d^2}{dp^2}(1-p)^n\right) \\
&= p(1-p)\frac{d^2}{dp^2}\left(\sum_{n=1}^{\infty}(1-p)^n\right) \\
&= p(1-p)\frac{d^2}{dp^2}\Big(\frac{1-p}{p}\Big) = p(1-p)\frac{2}{p^3} \\
&= \frac{2(1-p)}{p^2},
\end{aligned}$$

wobei wir die geometrische Reihe $\sum\limits_{n=1}^{\infty}(1-p)^n = \frac{1-p}{p}$ und Vertauschung von Ableitung und Reihenbildung angewandt haben. (Letzteres ist hier erlaubt, da $\sum\limits_{n=1}^{\infty}(1-p)^n$ als Potenzreihe in $1-p$ für $|1-p| < 1$ absolut konvergiert.) Damit ist

$$\mathbb{V}(X) = \frac{2(1-p)}{p^2} + \frac{1}{p} - \frac{1}{p^2} = \frac{1-p}{p^2}.$$

4. Es sei X negativ binominalverteilt mit den Parametern r und p, dann gilt

$$\mathbb{E}(X(X-1)) = \sum_{n=r}^{\infty} n(n-1)P(X=n).$$

Nun gilt

$$nP(X=n) \quad = \quad n\frac{(n-1)!}{(r-1)!(n-r)!}p^r(1-p)^{n-r}$$

$$= \frac{r}{p}\binom{n}{r}p^{r+1}(1-p)^{(n+1)-(r+1)} = \frac{r}{p}P(Y=n+1),$$

wobei Y negativ binominalverteilt ist mit den Parametern $r+1$ und p. Also folgt

$$\mathbb{E}(X(X-1)) = \frac{r}{p}\sum_{n=r}^{\infty}(n-1)P(Y=n+1).$$

Es folgt

$$\begin{aligned}\mathbb{E}(X(X-1)) &= \frac{r}{p}\sum_{n=r+1}^{\infty}(n-2)P(Y=n)\\ &= \frac{r}{p}\left(\mathbb{E}(Y) - 2\sum_{n=r+1}^{\infty}P(Y=n)\right) = \frac{r}{p}\Big(\frac{r+1}{p}-2\Big).\end{aligned}$$

Daraus folgt für die Varianz

$$\mathbb{V}(X) = \frac{r}{p}\Big(\frac{r+1}{p}-2\Big) + \frac{r}{p} - \frac{r^2}{p^2} = \frac{r(1-p)}{p^2}.$$

Aufgabe 14.1.4

Um die Gleichung zu zeigen, berechnen wir die Ableitung:

$$\begin{aligned}\frac{d}{dt}\left(1 - e^{-\lambda t}\sum_{k=0}^{r-1}\frac{(\lambda t)^k}{k!}\right) &= \lambda e^{-\lambda t}\sum_{k=0}^{r-1}\frac{(\lambda t)^k}{k!} - e^{-\lambda t}\sum_{k=1}^{r-1}\frac{\lambda^k}{(k-1)!}t^{k-1}\\ &= e^{-\lambda t}\left(\sum_{k=0}^{r-1}\frac{\lambda^{k+1}t^k}{k!} - \sum_{k=0}^{r-2}\frac{\lambda^{k+1}t^k}{k!}\right)\\ &= e^{-\lambda t}\frac{\lambda^r}{(r-1)!}t^{r-1}.\end{aligned}$$

Damit folgt $P((0,t]) = 1 - e^{-\lambda t}\sum_{k=0}^{r-1}\frac{(\lambda t)^k}{k!} = \int_0^t \frac{\lambda^r}{(r-1)!}x^{r-1}e^{-\lambda x}\,dx$.

Aufgabe 14.1.6

Wir substituieren $y = \lambda x$ in (14.5) und erhalten

$$\Gamma(r) = \int_0^{\infty}(\lambda x)^{r-1}e^{-\lambda x}\lambda\,dx = \int_0^{\infty}\lambda^r x^{r-1}e^{-\lambda x}\,dx.$$

Damit folgt

$$\int_0^{\infty}\frac{\lambda^r}{\Gamma(r)}x^{r-1}e^{-\lambda x}\,dx = 1.$$

Aufgabe 14.1.7

Für die Gammafunktion gilt $\Gamma(r+1) = r\Gamma(r)$ für jedes $r > 0$. Damit erhält man für den Erwartungswert

$$\mathbb{E}(X) = \int_0^\infty x\,\gamma_{\lambda,r}(x)\,dx = \frac{\Gamma(r+1)}{\lambda\Gamma(r)} \int_0^\infty \gamma_{\lambda,r+1}(x)\,dx = \frac{r}{\lambda}, \tag{14.14}$$

denn $\gamma_{\lambda,r+1}$ ist eine Wahrscheinlichkeitsdichte.

Lösungen der Aufgaben in 14.2

Aufgabe 14.2.10

Die gegebene Information in der Aufgabenstellung ist sehr gering. Wir kennen weder die Anzahl der Autos, die den Autobahnabschnitt pro Monat befahren, noch kennen wir die Unfallwahrscheinlichkeit eines einzelnen Autos. Eine Binomialverteilung können wir somit nicht verwenden. Daher verwendet man die Poisson-Verteilung mit $\lambda = 2$. Es bezeichne X die durchschnittliche Unfallzahl pro Monat und wir nehmen an, dass diese Zufallsgröße Poisson-verteilt ist zum Parameter $\lambda = 2$. Dann ist

$$P(X \geq 4) = 1 - P(X \leq 3) = 1 - \sum_{k=0}^{3} \frac{2^k}{k!} e^{-2} \approx 0.1429.$$

Alle sieben Monate sollten wir daher mit mindestens 4 schweren Unfällen rechnen.

Aufgabe 14.2.11

Man benutzt die Poisson-Verteilung mit $\lambda = \frac{253}{365}$.

Aufgabe 14.2.12

Für $i = 1, \ldots, n$ beschreibe $X_i = 1$ bzw. $X_i = 0$ den Sachverhalt, dass das i-te Exemplar der Ware intakt bzw. defekt sei. Dann sind $X_1, \ldots, X_n$ nach Annahme unabhängig und weiter ist $S_n := \sum_{i=1}^n X_i$ binomialverteilt zu den Parametern n und 0.99. Wir berechnen mithilfe einer Approximation durch die Poisson-Verteilung zum Parameter $\frac{99n}{100}$. Es gilt

$$\begin{aligned} P(S_n \geq 150) &= 1 - P(S_n \leq 149) = 1 - \sum_{k=0}^{149} b(k; n, 0.99) \\ &\approx 1 - \sum_{k=0}^{149} \pi_{\frac{99n}{100}}(k) = 1 - e^{-\frac{99n}{100}} \cdot \sum_{k=0}^{149} \frac{\left(\frac{99n}{100}\right)^k}{k!} \end{aligned}$$

$$\overset{!}{\geq} 0.9.$$

Wir suchen nun das kleinste n für das

$$e^{-\frac{99n}{100}} \cdot \sum_{k=0}^{149} \frac{\left(\frac{99n}{100}\right)^k}{k!} \leq 0.1$$

gilt.

Lösungen der Aufgaben in 14.3

Aufgabe 14.3.1

Es bezeichne für $i = 1, \ldots, n := 25000$ $X_i = 1$ bzw. $X_i = 0$ den Sachverhalt, dass das i-te emittierte Teilchen vom Geiger-Müller-Zähler registriert werde bzw. nicht registriert werde. Dann sind $X_1, \ldots, X_n$ unabhängig und $S_n := \sum_{i=1}^n X_i$ folgt einer Binomialverteilung zu den Parametern $n = 25000$ und $p := 10^{-3}$. Um die gesuchten Wahrscheinlichkeiten approximativ zu berechnen, verwenden wir die Poisson-Approximation dieser Binomialverteilung durch die π_{25}-Verteilung. Es ist somit $P(S_n = 0) \approx \pi_{25}(0) = e^{-25} \approx 0$ und weiterhin ist

$$\begin{aligned} P(S_n \geq 2) &= 1 - P(S_n = 0) - P(S_n = 1) \approx 1 - \pi_{25}(0) - \pi_{25}(1) \\ &= 1 - e^{-25} - 25 \cdot e^{-25} = 1 - 26 \cdot e^{-25} \approx 1. \end{aligned}$$

Kapitel 15

Der Satz von de Moivre und Laplace

In diesem Kapitel betrachten wir den zentralen Grenzwertsatz für binomialverteilte Zufallsgrößen. Dies ist einer der bedeutendsten Grenzwertsätze der Stochastik. Für unabhängige und identisch verteilte Zufallsgrößen wird das Verhalten der Langzeitmittelwerte untersucht. Beim schwachen Gesetz der großen Zahlen haben wir die Konvergenz der Mittelwerte gegen den gemeinsamen Erwartungswert betrachtet. Ein zentraler Grenzwertsatz beschreibt die asymptotische Größenordnung der Abweichungen der Mittelwerte vom Erwartungswert. Es zeigt sich eine universelle Bedeutung der Normalverteilung, die wir im Rahmen dieses Kurses exemplarisch für Summen von Bernoulli-verteilten Zufallsgrößen studieren. Diese Untersuchung mündet in den Grenzwertsatz von de Moivre und Laplace.

15.1 Der lokale Grenzwertsatz

Zunächst sei daran erinnert, dass die Poisson-Approximation der Binomialverteilung nur sinnvoll ist, wenn n groß und p klein ist. Oft möchte man jedoch $b(k; n, p)$ für einen festen Wert von p und großes n approximieren.

Zunächst betrachten wir $b(n; 2n, 1/2) = \frac{(2n)!}{(n!)^2} 2^{-2n}$. Mithilfe der Stirling-Formel, Satz 7.0.1, folgt

$$b(n; 2n, 1/2) \sim \frac{1}{\sqrt{\pi n}}$$

(siehe Beispiel 12.0.1) und damit $\lim_{n\to\infty} b(n; 2n, 1/2) = 0$. Dabei ist $b(n; 2n, 1/2)$ noch am größten unter den $b(k; 2n, 1/2)$, wie man aus dem Pascal'schen Dreieck für die Binomialkoeffizienten ersehen kann. Allgemeiner gilt für ein beliebiges $p \in$

$(0,1)$

$$\lim_{n\to\infty} \max_{0\le k\le n} b(k;n,p) = 0. \tag{15.1}$$

Wir werden dies später beweisen.

Es bezeichne S_n die Anzahl der Erfolge in einem Bernoulli-Experiment der Länge n und Erfolgswahrscheinlichkeit p. Wir fragen: Wie stark fluktuiert S_n um den Erwartungswert np, in welcher Größenordnung liegen die Abweichungen $S_n - np$ im Limes $n \to \infty$? Wir wissen bereits, dass $S_n - np$ von kleinerer Größenordnung ist als n, denn nach dem Gesetz der großen Zahlen gilt für jedes $\varepsilon > 0$

$$\lim_{n\to\infty} P\left(\left|\frac{S_n}{n} - p\right| \le \varepsilon\right) = \lim_{n\to\infty} P(|S_n - np| \le \varepsilon n) = 1.$$

Weiter gilt nach (15.1) für jedes $a > 0$:

$$\lim_{n\to\infty} P(|S_n - np| \le a) \le (2a+1) \lim_{n\to\infty} \max\{P(S_n)\} = 0.$$

Um eine hinreichende Anzahl von möglichen Werten für S_n zu „erwischen“, die dann zu einer von 0 verschiedenen Grenzwahrscheinlichkeit führen, muss der zugelassene Bereich mit n unendlich groß werden. Die Größenordnung n aus dem Gesetz der großen Zahlen ist zu großzügig bemessen. Für welche Folgen $(a_n)_n$ positiver reeller Zahlen streben die Wahrscheinlichkeiten $P(|S_n - np| \le a_n)$ weder gegen 0 noch gegen 1? Da wir (zumindest für $p = 1/2$) gesehen haben, dass die größten $b(k;n,p)$ von der Größenordnung $1/\sqrt{n}$ sind, ist es plausibel, wenn sich für die benötigte Anzahl eine Größenordnung von $\sqrt{n}$ ergibt. Dies wird durch das folgende Lemma präzisiert:

15.1.1 Lemma: In obiger Situation gilt

$$\lim_{n\to\infty} P(|S_n - np| \le a_n) = \begin{cases} 1, & \text{falls} \quad a_n/\sqrt{n} \to \infty, \\ 0, & \text{falls} \quad a_n/\sqrt{n} \to 0. \end{cases}$$

Beweis: Mithilfe der Tschebyschev-Ungleichung folgt

$$P(|S_n - np| \le a_n) \ge 1 - \frac{np(1-p)}{a_n^2}.$$

Im Fall $a_n/\sqrt{n} \to \infty$ konvergiert die rechte Seite gegen 1, was den ersten Fall beweist. Nun ist für jedes $k \ge 1$

$$b(k;n,p) > b(k-1;n,p)$$

genau dann, wenn $(n-k+1)p > k(1-p)$, also $k < (n+1)p$, gilt. Dies ist in Aufgabe 15.1.2 zu zeigen. Das Histogramm der Binomialverteilung hat also sein Maximum bei $k = k_{n,p} := \lfloor (n+1)p \rfloor$. Damit ist

$$P(|S_n - np| \le a_n) = \sum_{k:|k-np|\le a_n} b(k;n,p) \le (2a_n+1)b(k_{n,p};n,p).$$

Nach der STIRLING-Formel ist nun

$$b(k_{n,p};n,p) \sim \frac{1}{\sqrt{2\pi p(1-p)n}} \left(\frac{np}{k_{n,p}}\right)^{k_{n,p}} \left(\frac{n(1-p)}{n-k_{n,p}}\right)^{n-k_{n,p}}.$$

Wir nutzen nun $|k_{n,p} - np| \le 1$ um zu sehen, dass die rechte Seite durch $C/\sqrt{n}$ für eine Konstante C abgeschätzt werden kann. Zum Beispiel ist der zweite Faktor kleiner gleich $(1+1/k_{n,p})^{k_{n,p}} \le e$. Damit konvergiert $(2a_n+1)b(k_{n,p};n,p)$ im Fall $a_n/\sqrt{n} \to 0$ gegen Null. □

15.1.2 Aufgabe: Zeigen Sie: Für jedes $k \ge 1$ ist

$$b(k;n,p) > b(k-1;n,p)$$

genau dann, wenn $(n-k+1)p > k(1-p)$, also $k < (n+1)p$, gilt.

Also wächst die Abweichung der Summen S_n von np typischerweise mit $\sqrt{n}$. Konvergieren die Wahrscheinlichkeiten $P(|S_n - np| \le c\sqrt{n})$ für fest gewähltes $c > 0$ gegen einen Limes, und wenn ja, wie sieht dieser Limes aus?

Zunächst müssen wir die $b(k;n,p)$ einzeln genauer unter die Lupe nehmen: Es zeigt sich, dass $b(k;n,p)$ durch eine schöne Funktion approximiert werden kann, wenn k in einer Umgebung der Größenordnung $\sqrt{n}$ um den Erwartungswert np liegt. Es ist deshalb günstig, eine Variablentransformation durchzuführen, indem k durch $(k-np)/\sqrt{n}$ ersetzt wird. Tatsächlich dividieren wir durch $\sqrt{np(1-p)}$, was der Standardabweichung der Binomialverteilung entspricht. Wir setzen also

$$x_k := x_k(n,p) := \frac{k-np}{\sqrt{np(1-p)}}. \tag{15.2}$$

x_k hängt natürlich von n und p ab, was wir in der Notation jedoch nicht gesondert betonen. Wir kürzen $1-p$ meist durch q ab.

Der unten stehende Satz besagt, dass $b(k;n,p)$ für große n wie $\frac{1}{\sqrt{2\pi npq}} e^{-x_k^2/2}$ ist. Was soll das aber genau heißen?

Zu schreiben

$$\lim_{n\to\infty} \sqrt{2\pi npq}\, b(k;n,p) = e^{-x_k^2/2}$$

ergibt keinen großen Sinn, denn mit $n \to \infty$ und festem k geht $x_k \to -\infty$. Was wir wollen, ist eine Approximation, wenn k in einer Umgebung der Größenordnung $\sqrt{n}$ um np liegt, das heißt x_k in einer Umgebung der Größenordnung 1 um 0. Es zeigt sich, dass in einem solchen Bereich die Konvergenz sogar gleichmäßig gilt. Wir können den Bereich zusätzlich in n größer werden lassen:

15.1.3 Satz: (lokaler Grenzwertsatz) Es seien $0 < p < 1$, $q := 1 - p$ und $(a_n)_{n\in\mathbb{N}}$ eine Folge strikt positiver, reeller Zahlen mit $\lim_{n\to\infty} a_n^3/\sqrt{n} = 0$. Dann gilt mit x_k aus (15.2)

$$\lim_{n\to\infty} \sup_{k:|x_k|\le a_n} \left| \frac{\sqrt{2\pi npq}\, b(k;n,p)}{e^{-x_k^2/2}} - 1 \right| = 0.$$

15.1.4 Bemerkungen: (a) Ist $a_n = A$ eine beliebige, aber feste positive Konstante, so folgt unmittelbar

$$\lim_{n\to\infty} \sup_{k:|x_k|\le A} \left| \frac{\sqrt{2\pi npq}\, b(k;n,p)}{e^{-x_k^2/2}} - 1 \right| = 0.$$

(b) Wir schreiben nachfolgend stets $b(k;n,p) \sim \frac{1}{\sqrt{2\pi npq}} e^{-x_k^2/2}$ für die obige gleichmäßige Konvergenz und dies auch allgemeiner: Sind $\alpha(k,n)$, $\beta(k,n) > 0$ für $n \in \mathbb{N}_0$, $0 \le k \le n$, so bedeutet (während des unten stehenden Beweises) $\alpha(k,n) \sim \beta(k,n)$, dass für die obige Folge $(a_n)_{n\in\mathbb{N}}$ strikt positiver Zahlen

$$\lim_{n\to\infty} \sup_{k:|x_k|\le a_n} \left| \frac{\alpha(k,n)}{\beta(k,n)} - 1 \right| = 0$$

gilt.

(c) Wir überzeugen uns vom folgenden Sachverhalt, der im Beweis von Satz 15.1.3 mehrfach verwendet wird:

$$\alpha(k,n) \sim \beta(k,n), \;\; \alpha'(k,n) \sim \beta'(k,n) \;\; \Rightarrow \;\; \alpha(k,n)\alpha'(k,n) \sim \beta(k,n)\beta'(k,n). \tag{15.3}$$

Beweis von (15.3): Sei $\alpha := \alpha(k,n), \alpha' := \alpha'(k,n), \beta := \beta(k,n), \beta' := \beta'(k,n)$. Wir verwenden zweimal die Dreiecksungleichung und erhalten

$$\left| \frac{\alpha\alpha'}{\beta\beta'} - 1 \right| \;\le\; \left| \frac{\alpha\alpha'}{\beta\beta'} - \frac{\alpha'}{\beta'} \right| + \left| \frac{\alpha'}{\beta'} - 1 \right|$$

$$\leq \left(\left|\frac{\alpha'}{\beta'} - 1\right| + 1\right)\left|\frac{\alpha}{\beta} - 1\right| + \left|\frac{\alpha'}{\beta'} - 1\right|.$$

Daraus folgt die behauptete Aussage. □

Beweis von Satz 15.1.3: Es gilt nach (15.2)

$$k = np + \sqrt{npq}\, x_k, \quad n - k = nq - \sqrt{npq}\, x_k,$$

also

$$k \sim np, \quad n - k \sim nq.$$

Hierbei ist mit $\sim$ die obige gleichmäßige Konvergenz (Bemerkung 15.1.4(b)) gemeint. Mithilfe der Stirling'schen Formel folgt:

$$\begin{aligned} b(k; n, p) &\sim \frac{\left(\frac{n}{e}\right)^n \sqrt{2\pi n}\, p^k q^{n-k}}{\left(\frac{k}{e}\right)^k \sqrt{2\pi k}\left(\frac{n-k}{e}\right)^{n-k} \sqrt{2\pi(n-k)}} \\ &= \sqrt{\frac{n}{2\pi k(n-k)}}\, \varphi(n,k) \sim \frac{1}{\sqrt{2\pi npq}}\, \varphi(n,k), \end{aligned} \tag{15.4}$$

wobei wir $\varphi(n,k)$ für $(\frac{np}{k})^k(\frac{nq}{n-k})^{n-k}$ schreiben. Man beachte, dass auch hier $\sim$ die obige gleichmäßige Konvergenz bezeichnet. Dass die Stirling-Formel aus Satz 7.0.1 diese Konvergenz impliziert, mache man sich klar. Es ist nun

$$-\ln(\varphi(n,k)) = +nH\left(\frac{k}{n}\middle| p\right),$$

wobei

$$H(x|\, p) := x \ln\left(\frac{x}{p}\right) + (1-x)\ln\left(\frac{1-x}{1-p}\right).$$

Wir kennen diese Funktion schon aus Kapitel 13 (siehe Satz 13.1.2). In Satz 13.1.5 haben wir die Ableitungen von $H(\cdot|p)$ bestimmt. Es gilt $H'(p|\, p) = 0$ und $H''(p|\, p) = 1/p + 1/q = 1/(pq)$. Damit folgt

$$H(x|\, p) = \frac{(x-p)^2}{2pq} + \psi(x-p),$$

wobei wir mit ψ das Restglied in der Taylor-Entwicklung bezeichnen (man denke sich zum Beispiel die Lagrange'sche Form; Joseph-Louis Lagrange (1736–1813)), für die wir also in der Umgebung von p eine Abschätzung

$$|\psi(x-p)| \leq c|x-p|^3$$

mit einer geeigneten Konstante c zur Verfügung haben. Wir erhalten somit

$$\left| H\left(\frac{k}{n}\middle| p\right) - \frac{\left(\frac{k}{n}-p\right)^2}{2pq} \right| \leq c \left|\frac{k}{n} - p\right|^3$$

und damit

$$\left| \ln(\varphi(n,k)) + \frac{n\left(\frac{k}{n}-p\right)^2}{2pq} \right| \leq cn\left|\frac{k}{n} - p\right|^3.$$

Man beachte nun, dass aus der Definition der x_k für eine geeignete Konstante $0 < c' < \infty$ folgt

$$\frac{|k-np|^3}{n^2} = c'\frac{|x_k|^3}{\sqrt{n}}.$$

Wählen wir nun ein k mit $|x_k| \leq a_n$, so konvergiert die rechte Seite der Ungleichung gegen 0 für $n \to \infty$. Dies folgt unmittelbar aus der Bedingung an die Folge $(a_n)_{n\in\mathbb{N}}$. Da nun aber

$$\frac{n\left(\frac{k}{n}-p\right)^2}{2pq} = \frac{x_k^2}{2},$$

erhalten wir

$$\sup_{k:|x_k|\leq a_n} \left| \ln\left[\varphi\left(n,k\right) e^{\frac{x_k^2}{2}}\right]\right| \to 0.$$

Für $x \in \mathbb{R}$ gilt

$$|e^x - 1| = \left|\int_0^x e^t dt\right| \leq e^{|x|}\left|\int_0^x dt\right| = e^{|x|}\,|x|\,.$$

Setze

$$x = \ln\left[\varphi\left(n,k\right) e^{\frac{x_k^2}{2}}\right].$$

Wir erhalten

$$\sup_{k:|x_k|\leq a_n}\left|\frac{\varphi\left(n,k\right)}{e^{-\frac{x_k^2}{2}}} - 1\right| \leq e^{\sup\limits_{k:|x_k|\leq a_n}\left|\ln\left[\varphi(n,k)e^{\frac{x_k^2}{2}}\right]\right|} \sup_{k:|x_k|\leq a_n}\left|\ln\left[\varphi\left(n,k\right) e^{\frac{x_k^2}{2}}\right]\right| \xrightarrow[n\to\infty]{} 0$$

und somit folgt

$$\lim_{n\to\infty}\sup_{k:|x_k|\leq a_n}\left|\frac{\varphi(n,k)}{e^{-x_k^2/2}} - 1\right| = 0.$$

Nach (15.4) ist damit der Satz gezeigt. □

15.1.5 Beispiel: Jemand wirft 1200-mal einen Würfel. Mit welcher Wahrscheinlichkeit hat er genau 200-mal eine 6? Mit welcher Wahrscheinlichkeit 250-mal? Wir berechnen x_k für $k = 200$ bzw. 250, $n = 1200$ und $p = 1/6$. Es gilt $x_{200} = 0$, $x_{250} = \frac{5\sqrt{6}}{\sqrt{10}} \approx 3.873$ sowie

$$b(200; 1200, 1/6) \approx 0.0309019 \quad \text{und} \quad b(250; 1200, 1/6) \approx 0.0000170913.$$

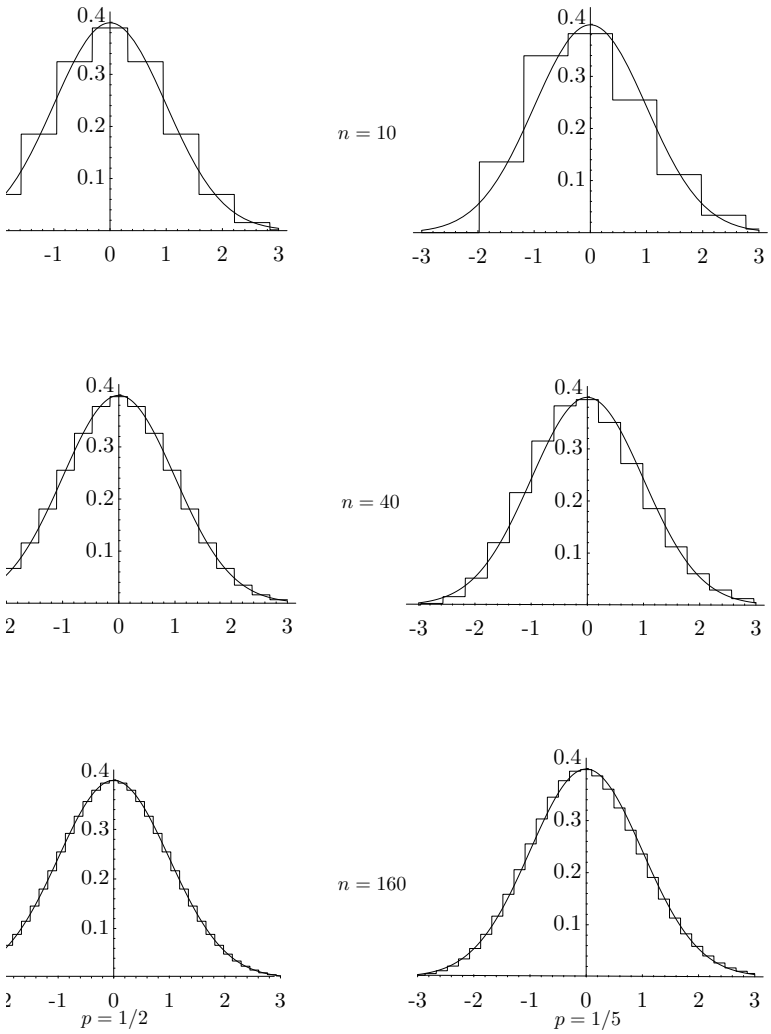

Abb. 15.1: Numerische Illustration von Satz 15.1.3, links für $p = 1/2$ und rechts für $p = 1/5$.

Die sechs Bilder in Abbildung 15.1 (auf Seite 407) illustrieren die Konvergenz der Binomialverteilung gegen die Funktion $\varphi(x) = (2\pi)^{-1/2} \exp(-x^2/2)$. Hier ist

jeweils die Funktion $\varphi(x)$ zusammen mit dem skalierten Histogramm

$$f_{n,p}(x) := \begin{cases} \sqrt{np(1-p)}b(k;n,p), & k \in \{0,1,\dots,n\} \text{ mit } |x-x_k| < \frac{1}{2\sqrt{np(1-p)}}, \\ 0, & \text{andernfalls} \end{cases}$$

der Binomialverteilung $b(\cdot\,;n,p)$ gezeichnet. In der linken Spalte der symmetrische Fall mit $p = 1/2$, in der rechten Spalte der asymmetrische Fall $p = 1/5$.

Wir können noch den versprochenen Beweis von (15.1) nachholen:

Beweis von (15.1)**:** Da die Standardabweichung von S_n gleich $\sqrt{npq}$ ist, so folgt aus der Tschebyschev-Ungleichung, dass für $a > 0$ $P(|S_n - np| \geq a\sqrt{npq}) \leq 1/a^2$ gilt. Da die Summe nichtnegativer Zahlen mindestens so groß wie jedes ihrer Glieder ist, folgt $b(k;n,p) \leq 1/a^2$ für $|x_k| \geq a$. Andererseits ergibt sich aus Satz 15.1.3:

$$\lim_{n\to\infty} \sup_{k:|x_k|\leq a} b(k;n,p) = 0.$$

Da a beliebig groß gewählt werden kann, folgt (15.1). □

Wie üblich muss hier bemerkt werden, dass ein reines Limesresultat für die Güte einer Approximation wie in obigem Rechenbeispiel zunächst natürlich gar nichts aussagt. Gefragt sind konkrete Abschätzungen des Fehlers. Dies ist ein technisch aufwendiges Feld, in das wir in diesem Kurs nicht eintreten werden. Wir werden dennoch am Ende des Kapitels eine Abschätzung der Konvergenzgeschwindigkeit bekanntgeben.

15.2 Der Satz von de Moivre und Laplace

Da die Wahrscheinlichkeiten $b(k;n,p)$ für große n somit alle klein sind, ist man meist eher daran interessiert, Summen dieser Wahrscheinlichkeiten zu approximieren.

15.2.1 Satz: (von de Moivre und Laplace) Für beliebige reelle Zahlen a und b mit $a < b$ gilt:

$$\lim_{n\to\infty} P\left(a \leq \frac{S_n - np}{\sqrt{npq}} \leq b\right) = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-x^2/2}\,dx. \tag{15.5}$$

Beweis: Sei $k \in \{0,\dots,n\}$. Dann ist $\{S_n = k\} = \{(S_n - np)/\sqrt{npq} = x_k\}$. Also ist die links stehende Wahrscheinlichkeit gleich

$$\sum_{k:a\leq x_k\leq b} P(S_n = k) = \sum_{k:a\leq x_k\leq b} b(k;n,p).$$

Wir setzen nun für jeden Summanden auf der rechten Seite seinen in Satz 15.1.3 angegebenen asymptotischen Wert ein und berücksichtigen, dass $x_{k+1} - x_k = \frac{1}{\sqrt{npq}}$ ist. Die Summe dieser Größen nennen wir R_n:

$$R_n := \frac{1}{\sqrt{2\pi}} \sum_{k:a \le x_k \le b} e^{-x_k^2/2}(x_{k+1} - x_k).$$

Unter Verwendung der Gleichmäßigkeit der Konvergenz in $\{k : |x_k| \le A\}$ für jedes A sieht man sofort, dass der Quotient von $P\Big(a \le \frac{S_n - np}{\sqrt{npq}} \le b\Big)$ und dem oben stehenden Ausdruck R_n gegen 1 konvergiert. Das heißt, es existiert eine Nullfolge $(\varepsilon_n)_{n\in\mathbb{N}}$, $\varepsilon_n > 0$, mit

$$R_n(1 - \varepsilon_n) \le P\left(a \le \frac{S_n - np}{\sqrt{npq}} \le b\right) \le R_n(1 + \varepsilon_n). \tag{15.6}$$

Die Zuordnung zwischen k und x_k ist bijektiv. Wenn k von 0 bis n läuft, dann variiert x_k im Intervall $[-\sqrt{np/q}, \sqrt{nq/p}]$ mit der Schrittweite $x_{k+1} - x_k = 1/\sqrt{npq}$. Für hinreichend große n umfaßt dieses Intervall das gegebene Intervall $[a, b]$, und die in $[a, b]$ fallenden Punkte x_k teilen dieses in Teilintervalle derselben Länge $1/\sqrt{npq}$. Wenn nun der kleinste und der größte Wert von k mit $a \le x_k \le b$ gleich j bzw. l ist, dann ist

$$x_{j-1} < a \le x_j < x_{j+1} < \cdots < x_{l-1} < x_l \le b < x_{l+1}$$

und die obige Summe läßt sich schreiben als

$$\sum_{k=j}^{l} \varphi(x_k)(x_{k+1} - x_k),$$

wobei $\varphi(x) := \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$ ist. Das ist eine sogenannte Riemann'sche Summe für das bestimmte Riemann-Integral $\int_a^b \varphi(x)\,dx := \lim_{n\to\infty} R_n$. Üblicherweise gehören jedoch in der Lehrbuchliteratur beim Riemann-Integral die Endpunkte a und b mit zu den Stützstellen der Funktion. Doch macht das für $n \to \infty$ und eine dadurch immer feiner werdende Unterteilung keinen Unterschied. Somit konvergiert R_n gegen das Integral in der Behauptung des Satzes. Dieser folgt nun sofort mit (15.6). □

Abraham de Moivre (1667–1754) veröffentlichte dieses Ergebnis in seiner „*Doctrine of Chances*“ 1714. Laplace erweiterte das Ergebnis und wies dessen Bedeutung in seiner „*Théorie analytique des probabilités*“ 1812 nach. Es handelt sich um den zuerst bekanntgewordenen Spezialfall des *Zentralen Grenzwertsatzes*.

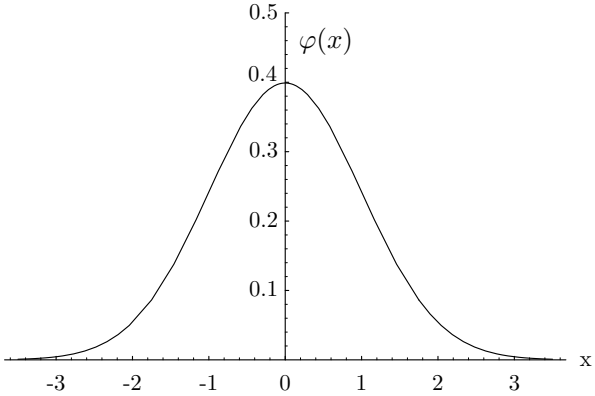

Abb. 15.2: Die Funktion $\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$

Die Funktion $x \mapsto \varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$ heißt auch Gauss'sche Glockenkurve, wegen des glockenförmigen Verlaufs ihres Graphen. Gauss hat sich intensiv mit dem zentralen Grenzwertsatz und der Normalverteilung beschäftigt.

Die Integrale $\int_a^b \varphi(x)\,dx$ sind leider nicht in geschlossener Form mithilfe von Polynomen, rationalen Funktionen, Wurzelausdrücken oder elementaren transzendenten Funktionen (wie sin, cos, exp, etc.) darstellbar.

Es gilt offenbar für $a < b$

$$\int_a^b \varphi(x)\,dx = \int_{-\infty}^b \varphi(x)\,dx - \int_{-\infty}^a \varphi(x)\,dx = \Phi(b) - \Phi(a),$$

wobei wir

$$\Phi(y) := \int_{-\infty}^y \varphi(x)\,dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^y e^{-x^2/2}\,dx \tag{15.7}$$

gesetzt haben. (Es ist leicht ersichtlich, dass das uneigentliche Integral konvergiert.) Der Grenzwertsatz von de Moivre und Laplace lässt vermuten, dass

$$\int_{-\infty}^{\infty} \varphi(x)\,dx = 1, \tag{15.8}$$

denn wählen wir ein sehr kleines a und ein sehr großes b, so ist die Wahrscheinlichkeit der linken Seite von (15.5) nahe 1. Wir geben einen Beweis: Dazu verwenden wir Satz 15.2.1 und setzen

$$S_n^* := \frac{S_n - np}{\sqrt{npq}}.$$

(Für das Argument hier spielt p keine Rolle; wir könnten $p = 1/2$ nehmen.) Sei $a > 0$. Dann ist

$$1 = P(-a \le S_n^* \le a) + P(|S_n^*| > a).$$

Nach der Tschebyschev-Ungleichung gilt:

$$P(|S_n^*| > a) \leq \frac{1}{a^2}\operatorname{Var}(S_n^*) = \frac{1}{a^2}.$$

Nach Satz 15.2.1 gilt

$$\lim_{n\to\infty} P(-a \leq S_n^* \leq a) = \int_{-a}^{a} \varphi(x)\,dx.$$

Demzufolge ist

$$1 - \frac{1}{a^2} \leq \int_{-a}^{a} \varphi(x)\,dx \leq 1$$

für jedes $a > 0$, womit (15.8) bewiesen ist. Wir hatten in Beispiel 10.3.5(a) darauf hingewiesen, dass der Beweis von (15.8) nicht einfach ist. Wir haben ihn hier im Rahmen der Stochastik vorgeführt, indem wir maßgeblich die Güte der Stirling-Approximation verwendet haben. Genau diese liefert den Vorfaktor $\frac{1}{\sqrt{2\pi}}$ auf der rechten Seite von (15.5).

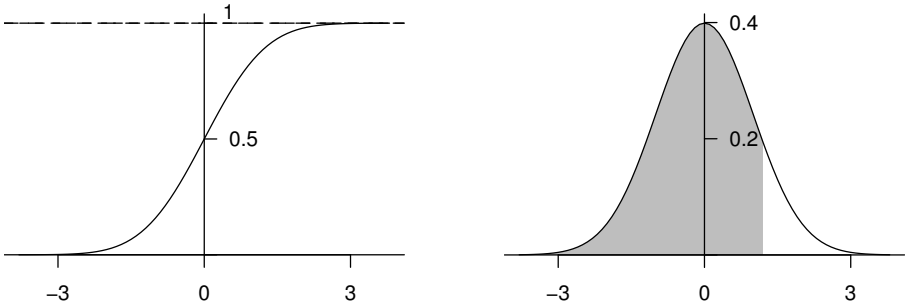

Abb. 15.3: Veranschaulichung der Verteilungsfunktion Φ (links) und ϕ (rechts). Die grau unterlegte Oberfläche unter dem Graphen von ϕ (rechts) entspricht $\Phi(t) = \int_{-\infty}^{t} \phi(u)\,du$.

15.2.2 Bemerkungen: (a) Wegen $\lim_{n\to\infty} \sup_k P(S_n = k) = 0$ ist es natürlich gleichgültig, ob in der Aussage von (15.5) $\leq$ oder $<$ steht.

(b) Es gilt für $a \in \mathbb{R}$:

$$\begin{aligned}
\lim_{n\to\infty} P\left(\frac{S_n - np}{\sqrt{npq}} \leq a\right) &= \Phi(a) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{a} e^{-x^2/2}\,dx, \\
\lim_{n\to\infty} P\left(\frac{S_n - np}{\sqrt{npq}} \geq a\right) &= 1 - \Phi(a).
\end{aligned}$$

Beweis: Wir beweisen in (b) die erste Gleichung; die zweite folgt daraus unmittelbar. Wegen der Symmetrie von φ und (15.8) gilt:

$$\Phi(x) = \int_{-\infty}^{x} \varphi(u)\,du = 1 - \int_{x}^{\infty} \varphi(u)\,du = 1 - \int_{-\infty}^{-x} \varphi(u)\,du = 1 - \Phi(-x)$$

für alle $x \in \mathbb{R}$. Wir setzen wieder $S_n^* := \frac{S_n - np}{\sqrt{npq}}$ und wählen $b > 0$ so groß, dass $-b < a$ gilt. Dann ist nach Satz 15.2.1

$$\begin{aligned}
\limsup_{n\to\infty} P(S_n^* \le a) &= \limsup_{n\to\infty} \Big[P(-b \le S_n^* \le a) + P(S_n^* < -b)\Big] \\
&= \limsup_{n\to\infty} \Big[P(-b \le S_n^* \le a) + (1 - P(S_n^* \ge -b))\Big] \\
&\le \limsup_{n\to\infty} \Big[P(-b \le S_n^* \le a) + (1 - P(-b \le S_n^* \le b))\Big] \\
&= \Phi(a) - \Phi(-b) + \Big[1 - \Phi(b) + \Phi(-b)\Big] \\
&= \Phi(a) + \Phi(-b)
\end{aligned}$$

und

$$\begin{aligned}
\liminf_{n\to\infty} P(S_n^* \le a) &\ge \liminf_{n\to\infty} P(-b \le S_n^* \le a) \\
&= \Phi(a) - \Phi(-b).
\end{aligned}$$

Wegen $\Phi(-b) \to 0$ für $b \to \infty$ folgt die gewünschte Aussage. □

Wir hatten bereits gesehen, dass für $x \le 0$ gilt: $\Phi(x) = 1 - \Phi(-x)$. Es gilt die folgende Approximation für $\Phi(t)$ mit $t \ge 0$ (ohne Beweis):

$$\Phi(t) \approx 1 - \frac{1}{\sqrt{2\pi}} \exp\Big(-\frac{t^2}{2}\Big) \left(\frac{a_1}{1+bt} + \frac{a_2}{(1+bt)^2} + \frac{a_3}{(1+bt)^3}\right)$$

mit $b = 0.33267$, $a_1 = 0.4361$, $a_2 = -0.1202$ und $a_3 = 0.937$.

Der Satz 15.2.1 ist eine Präzisierung des Gesetzes der großen Zahlen, welches besagt, dass für jedes $\varepsilon > 0$ $\lim_{n\to\infty} P\Big(\Big|\frac{S_n}{n} - p\Big| \ge \varepsilon\Big) = 0$ ist. Letzteres können wir sofort auch aus Satz 15.2.1 herleiten:

$$\begin{aligned}
P\left(\left|\frac{S_n}{n} - p\right| \le \varepsilon\right) &= P\left(-\varepsilon \le \frac{S_n}{n} - p \le \varepsilon\right) \\
&= P\left(-\frac{\sqrt{n}\varepsilon}{\sqrt{pq}} \le \frac{S_n - np}{\sqrt{npq}} \le \frac{\sqrt{n}\varepsilon}{\sqrt{pq}}\right) \ge P\left(a \le \frac{S_n - np}{\sqrt{npq}} \le b\right),
\end{aligned}$$

x	0	1	2	3	4	5	6	7	8	9
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7356	0.7389	0.7421	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7703	0.7734	0.7764	0.7793	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8364	0.8389
1.0	0.8413	0.8437	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8728	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8906	0.8925	0.8943	0.8962	0.8979	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9146	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9278	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9624	0.9633
1.8	0.9641	0.9648	0.9656	0.9664	0.9671	0.9678	0.9685	0.9692	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9874	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9895	0.9898	0.9901	0.9903	0.9906	0.9908	0.9911	0.9913	0.9916
2.4	0.9918	0.9920	0.9922	0.9924	0.9926	0.9928	0.9930	0.9932	0.9934	0.9936
2.5	0.9938	0.9939	0.9941	0.9943	0.9944	0.9946	0.9947	0.9949	0.9950	0.9952
2.6	0.9953	0.9955	0.9956	0.9957	0.9958	0.9960	0.9961	0.9962	0.9963	0.9964
2.7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9973
2.8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.9	0.9981	0.9982	0.9982	0.9983	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986
3.0	0.9986	0.9987	0.9987	0.9988	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990

Tab. 15.1: Die Verteilungsfunktion $\Phi(x) = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-u^2/2}\, du$ für $x \geq 0$.
Den Wert etwa für $x = 1.75$ findet man in Zeile 1.7 und Spalte 5: $\Phi(1.75) = 0.9599$.

sofern n so groß ist, dass $\sqrt{n}\varepsilon/\sqrt{pq} \geq b$ und $-\sqrt{n}\varepsilon/\sqrt{pq} \leq a$ sind. Für beliebige Zahlen $a, b \in \mathbb{R}$ ist dies aber für genügend große n der Fall. Somit ist $\lim_{n\to\infty} P(|\frac{S_n}{n} - p| \leq \varepsilon) = 1$ für jedes $\varepsilon > 0$.

Dieser Beweis ist natürlich insgesamt wesentlich aufwendiger als der in Kapitel 12 angegebene. Satz 15.2.1 ist jedoch sehr viel informativer als das Gesetz der großen Zahlen.

15.2.3 Beispiel: (Ein Anwendungsbeispiel) Eine Fabrik stellt ein Werkstück her mit einer Ausschussrate von 10%. Mit welcher Wahrscheinlichkeit sind unter 400 produzierten mehr als 50 defekt? $n := 400$, $p := 0.1$, $np = 40$, $\sqrt{np(1-p)} = 6$ liefert

$$P(S_n > 50) = P\left(\frac{S_n - np}{\sqrt{np(1-p)}} > \frac{5}{3}\right) \approx 1 - \Phi\left(\frac{5}{3}\right) = \Phi\left(-\frac{5}{3}\right) \approx 0.05.$$

Mit welcher Wahrscheinlichkeit sind zwischen 35 und 45 defekt?

$$\begin{aligned} P(35 \leq S_n \leq 45) &= P\left(-\frac{5}{6} \leq \frac{S_n - np}{\sqrt{np(1-p)}} \leq \frac{5}{6}\right) \\ &\approx \Phi\left(\frac{5}{6}\right) - \Phi\left(-\frac{5}{6}\right) = 1 - 2\Phi\left(-\frac{5}{6}\right) \approx 0.6. \end{aligned}$$

Da wir keine Fehlerabschätzungen hergeleitet haben, wissen wir natürlich nicht, wie genau solche Näherungen sind. Die Genauigkeit ist etwas besser, wenn man die Mitte der möglichen Grenzpunkte nimmt; das heißt, im obigen Beispiel schreibt man besser:

$$P(S_n > 50) = P(S_n \geq 50.5) \approx 1 - \Phi\left(\frac{21}{12}\right)$$

$$P(35 \leq S_n \leq 45) = P(34.5 \leq S_n \leq 45.5) \approx 1 - 2\Phi\left(\frac{11}{12}\right).$$

Für $n \to \infty$ ist die Korrektur natürlich belanglos, sie ist jedoch immerhin von der Größenordnung $1/\sqrt{n}$.

15.2.4 Aufgabe: Angenommen, bei der Geburt eines Kindes beträgt die Wahrscheinlichkeit für ein Mädchen $p = 0.495$. Mit welcher Wahrscheinlichkeit gibt es in einer Population von 80 Millionen Menschen höchstens 39 Millionen Frauen?

15.2.5 Aufgabe: Unter n Wählern seien S_n Wähler einer Partei P. Wir verwenden S_n/n als einen Schätzwert für die Wahrscheinlichkeit p, dass ein rein zufällig

befragter Wähler für die Partei P stimmt. Wie groß muss n sein, damit die Wahrscheinlichkeit eines Irrtums von mehr als 1% nicht größer ist als 0.05?

15.2.6 Aufgabe: Ein Hotel hat 100 Betten. Wie viele Reservierungen darf man akzeptieren, wenn nach Erfahrung eine Reservierung mit Wahrscheinlichkeit 0.2 annulliert wird, und die Wahrscheinlichkeit einer Überbuchung höchstens 0.01 betragen soll?

15.2.7 Aufgabe: Zwei Spieler S und T werfen n mal unabhängig eine Münze. Bei Kopf zahlt T an S einen Euro, im Fall von Zahl umgekehrt S an T. Es sei S_n der Kapitalstand von S nach n Spielen. Bestimmen Sie

$$P\Big(-\sqrt{n} \leq S_n \leq \sqrt{n}\Big)$$

approximativ.

Die im vorangegangenen Beispiel erwähnte Korrektur wird *Stetigkeitskorrektur* genannt und begründet sich, wie angedeutet, wie folgt. Mithilfe des Satzes 15.2.1 approximieren wir wie folgt:

$$\begin{aligned} P(k \leq S_n \leq l) &= P\left(\frac{k-np}{\sqrt{np(1-p)}} \leq S_n^* \leq \frac{l-np}{\sqrt{np(1-p)}}\right) \\ &\approx \Phi\left(\frac{l-np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{k-np}{\sqrt{np(1-p)}}\right) \\ &= \Phi_{x_l} - \Phi_{x_k}. \end{aligned}$$

Der Baustein $P(S_n = s)$ ist im Histogramm der standardisierten Binomialverteilung die Fläche eines Rechtecks mit Mittelpunkt x_s und Grundseite $1/\sqrt{np(1-p)}$. Wenn wir nun dieses Flächenstück bei der Approximation des Histogramms durch ein Integral über φ gut erfassen wollen, sollte die obere Integrationsgrenze nicht x_s sondern $x_s + 1/(2\sqrt{np(1-p)})$ sein. Analog sollte die untere Integrationsgrenze angepasst werden.

In früheren Jahren wurde die Bedeutung von Satz 15.2.1 auch dadurch hervorgehoben, dass für die Binomialverteilung die Berechnung von Bereichswahrscheinlichkeiten der Form $P(k \leq S_n \leq l)$ sehr kompliziert war. Mit leistungsfähigen Computer-Algebra-Systemen ist dieses numerische Problem heute überwunden. Phantastisch ist hingegen, dass Satz 15.2.1 sich weitgehend verallgemeinern lässt. Der folgende Satz zeigt die *Universalität* der Normalapproximation. Wir zitieren ihn ohne Beweis. Ein allgemeineres Ergebnis wird für gewöhnlich in einer Vorlesung „Wahrscheinlichkeitstheorie“ bewiesen.

15.2.8 Satz: (Zentraler Grenzwertsatz) Für jedes $n \in \mathbb{N}$ seien auf einem W.-Raum (Ω_n, p_n) n unabhängige Zufallsgrößen $X_1^{(n)}, \ldots, X_n^{(n)}$ definiert, die für alle i und n dieselbe Verteilung haben und deren Erwartungswert E und Varianz V existieren (notwendigerweise für alle $X_i^{(n)}$ dieselben). Dann gilt für jedes $a \in \mathbb{R}$

$$\lim_{n\to\infty} P\left(\frac{1}{\sqrt{n}} \sum_{i=1}^{n} \frac{X_i^{(n)} - E}{\sqrt{V}} \leq a\right) = \Phi(a).$$

Wir sehen also, dass das Verhalten einer Summe unabhängiger und identisch verteilter Zufallsgrößen asymptotisch für $n \to \infty$ nur vom Erwartungswert und von der Varianz, nicht aber von der speziellen Gestalt der Verteilung von X_1 bestimmt wird. Der Begriff *zentraler Grenzwertsatz* beschreibt tatsächlich *nicht* die zentrale Rolle, die dieser Satz in der Stochastik spielt, sondern das Phänomen, dass Wahrscheinlichkeiten zentraler Ereignisse untersucht werden, also solche Ereignisse, die in der Nähe des Erwartungswertes stattfinden.

In Kapitel 3 hatten wir mithilfe der Tschebyschev-Ungleichung für eine Stichprobe $(x_1, \ldots, x_n)$ bewiesen, dass mindestens 50 % der Werte im $2s_x$-Intervall liegen, siehe Satz 3.2.12 und die anschließende Diskussion. Wie ungenau diese Angabe war, können wir nun darstellen. In Satz 15.2.1 sei $a = -k$ und $b = k$. Mit $\mathbb{E}(S_n) = np$ und $\mathbb{V}(S_n) = np(1-p)$ folgt

$$\lim_{n\to\infty} P\Big(\mathbb{E}(S_n) - k\sqrt{\mathbb{V}(S_n)} \leq S_n \leq \mathbb{E}(S_n) + k\sqrt{\mathbb{V}(S_n)}\Big) = \int_{-k}^{k} \varphi(x)\,dx = 2\Phi(k) - 1.$$

Für $k = 2$ ist $2\Phi(2) - 1 \approx 0.954$, also liegt S_n für große n ungefähr mit Wahrscheinlichkeit 0.954 in den Grenzen $\mathbb{E}(S_n) \pm 2\sqrt{\mathbb{V}(S_n)}$.

15.2.9 Aufgabe: Bestimmen Sie obige Approximation auch für $k = 1$ und $k = 3$.

Zum Abschluss dieses Kapitel wollen wir die beiden verschiedenen Approximationen der Binomialverteilung, die Poisson-Approximation und die Normalapproximation, voneinander abgrenzen. Dazu erinnern wir, dass eine Poisson-Approximation gut ist, wenn np^2 klein ist. Dies hatten wir bewiesen, siehe Satz 14.2.1. Mit etwas mehr Aufwand kann die Fehlerschranke in Satz 14.2.1 sogar noch verbessert werden. Es gilt:

$$\Delta(n,p) \leq \min\Big(np^2, p\Big).$$

Man erkennt sofort, dass diese Fehlerabschätzung immer dann die Poisson-Approximation als gut erscheinen lässt, sobald nur p klein ist. Wir beweisen diese Abschätzung nicht. Sie nutzt eine Methode, die auf Charles Stein (geb. 1920) zurückgeht. Stein ist emeritierter Professor an der Stanford University, USA.

Im Fall der Normalapproximation gibt es ebenfalls Fehlerabschätzungen. Wenn man in der Situation von Satz 15.2.8 zusätzlich fordert, dass $\mathbb{E}(|X_1|^3) < \infty$, so kann man beweisen:

$$\sup_{z\in\mathbb{R}}\left|P\left(\frac{1}{\sqrt{n}}\sum_{i=1}^{n}\frac{X_i^{(n)}-E}{\sqrt{V}}\leq z\right)-\Phi(z)\right|\leq 0.8\frac{\mathbb{E}(|X_1-\mathbb{E}(X_1)|^3)}{V^{3/2}}\frac{1}{\sqrt{n}}.$$

Dies ist der Satz von Andrew C. Berry und Carl-Gustav Esseen (1918–2001). Wir beweisen diesen Satz nicht. In der allgemeinen Situation wie in Satz 15.2.8 ist dies ein tiefes Resultat der Wahrscheinlichkeitstheorie. Im Fall der Binomialapproximation könnten wir einen direkten Beweis rein technisch gesehen wagen, aber aus Platzgründen verzichten wir an dieser Stelle darauf. Für Bernoulli-verteilte X_i folgt, dass die Normalapproximation der Binomialverteilung gut ist, wenn

$$\frac{p(1-p)^3+(1-p)p^3}{(p(1-p))^{3/2}}\frac{1}{\sqrt{n}}=\frac{p^2+(1-p)^2}{\sqrt{np(1-p)}}$$

klein ist. Da $1/2\leq p^2+(1-p)^2\leq 1$ gilt, ist dieser Ausdruck klein, wenn $np(1-p)$ groß ist. Liegt p nahe bei 1, so sind beide Approximationen schlecht.

Lösungen der Aufgaben

Lösungen der Aufgaben in 15.1

Aufgabe 15.1.2

Zum Einen gilt

$$b(k;n,p) = \binom{n}{k} p^k (1-p)^{n-k} = \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k},$$

zum Anderen gilt analog

$$b(k-1;n,p) = \binom{n}{k-1} p^{k-1} (1-p)^{n-k+1} = \frac{n!}{(k-1)!(n-k+1)!} p^{k-1} (1-p)^{n-k+1}.$$

Also ist $b(k;n,p) > b(k-1;n,p)$ genau dann, wenn

$$p(n-k+1) > k(1-p)$$

gilt. Und diese Bedingung ist äquivalent zu $k < p(n+1)$.

Lösungen der Aufgaben in 15.2

Aufgabe 15.2.4

Es seien $X_1, ..., X_n$ Bernoulli-verteilte Zufallsvariablen mit der Erfolgswahrscheinlichkeit $p = 0.495$ und $n = 80 \cdot 10^6$. Dann ist $\sum\limits_{i=1}^{n} X_i$ die Anzahl der Frauen und es ergibt sich

$$P\left(\sum_{i=1}^{n} X_i \leq 39 \cdot 10^6\right) \approx \int\limits_{-\infty}^{\frac{39 \cdot 10^6 - np}{\sqrt{np(1-p)}}} \varphi(x)\, dx = \Phi\left(-\frac{600}{\sqrt{19.998}}\right) \approx 10^{-3911}.$$

Dieses Ereignis tritt also praktisch nicht auf, was ein wenig überraschend sein mag.

Aufgabe 15.2.5

Nach der Aufgabenstellung soll gelten

$$P\left(-0.01 \leq \frac{S_n}{n} - p \leq 0,01\right) \geq 0.95.$$

Mit $\sigma_n = \sqrt{npq}$ folgt approximativ mithilfe des Satzes von DE MOIVRE und LAPLACE

$$\begin{aligned} 0.95 &\approx P\left(-\frac{0.01n}{\sigma_n} \leq S_n^* \leq \frac{0.01n}{\sigma_n}\right) \\ &\approx \Phi\left(\frac{0.01n}{\sigma_n}\right) - \Phi\left(\frac{0.01n}{\sigma_n}\right) = 2\Phi\left(\frac{0.01n}{\sigma_n}\right) - 1. \end{aligned}$$

Gesucht ist also das kleinste n mit $\Phi\left(\frac{0.01n}{\sigma_n}\right) = 0.975$. Zu jedem $z \in (0,1)$ existiert eine eindeutig bestimmte Zahl $x = \Phi^{-1}(z)$ mit $\Phi(x) = z$. Es ist $\Phi^{-1}(0.975) = 1.96$. Deswegen muss $\frac{0.01\sqrt{n}}{\sqrt{pq}} \approx 1.96$ sein, also $n \approx p(1-p) \cdot 10000 \cdot 1.96^2$. p ist zwar unbekannt, aber $p(1-p)$ ist maximal $\frac{1}{4}$. Man kommt also in jedem Fall mit

$$n = 2500 \cdot 1.96^2 \approx 9600$$

Befragungen aus. Eine genauere Vorinformation über p führt zu einer geringeren Anzahl an Befragungen. Bei $p \leq 0.1$ ergeben sich etwa 3450 Befragungen.

Aufgabe 15.2.6

Es bezeichne n die Anzahl der akzeptierten Reservierungen und S_n sei die Anzahl der davon nicht annulierten Buchungen. Wir nehmen die einzelnen Buchungen als unabhängig an, so dass S_n binomialverteilt ist zu den Parametern n und $p = 0.8$. Wir rechnen die Wahrscheinlichkeit einer Überbuchung approximativ mithilfe des Satzes von DE MOIVRE und LAPLACE aus:

$$\begin{aligned} P(S_n > 100) &= 1 - P(S_n \leq 100) = 1 - P\left(\frac{S_n - np}{\sqrt{np(1-p)}} \leq \frac{100 - np}{\sqrt{np(1-p)}}\right) \\ &\approx 1 - \Phi\left(\frac{100 - np}{\sqrt{np(1-p)}}\right) \overset{!}{\leq} 0.01. \end{aligned}$$

Für $p = 0.8$ ist dies äquivalent zu

$$\frac{100 - n \cdot 0.8}{\sqrt{n \cdot 0.16}} \geq 2.33,$$

also zu $n \leq 112$. Somit sollte man höchstens 112 Reservierungen zulassen.

Aufgabe 15.2.7

Die Zufallsvariable $X_n := \frac{S_n+n}{2}$ ist binomialverteilt zu den Parametern n und 0.5. Weiter gilt

$$\begin{aligned} P(-\sqrt{n} \leq S_n \leq \sqrt{n}) &= P(-\sqrt{n} \leq 2X_n - n \leq \sqrt{n}) \\ &= P\left(-1 \leq \frac{X_n - 0.5n}{\sqrt{n \cdot 0.5(1-0.5)}} \leq 1\right), \end{aligned}$$

und dies konvergiert nach dem Satz von de Moivre und Laplace für $n \to \infty$ gegen

$$\Phi(1) - \Phi(-1) = 2\Phi(1) - 1 \approx 2 \cdot 0.8413 - 1 = 0.6826\,.$$

Aufgabe 15.2.9

Für $k = 1$ ergibt sich $2\Phi(1) - 1 \approx 0.6826$ und für $k = 3$ ergibt sich $2\Phi(3) - 1 \approx 2 \cdot 0.9986 - 1 = 0.9972$.