Kurseinheit 7

Mathematische Statistik: Schätzen und Testen

Inhalt der Kurseinheit

Studierhinweise zu Kurseinheit 7 **427**

16 Die Theorie des Schätzens **429**
16.1 Statistiken und Schätzer 429
16.2 Maximum-Likelihood-Methode 436
16.3 Erwartungstreue Schätzer 441
16.4 Beste Schätzer 444

Lösungen zu den Aufgaben aus dem Kapitel 16 **449**

17 Testtheorie **455**
17.1 Entscheidungsprobleme 455
17.2 Alternativtests und beste einseitige Tests 463

Lösungen zu den Aufgaben aus dem Kapitel 17 **477**

Studierhinweise

In der siebten und letzten Kurseinheit führen wir in die beurteilende Statistik ein. Auf der Grundlage zufälliger Beobachtungen möchte man auf zugrundeliegende Gesetzmäßigkeiten schließen.

In *Kapitel 16* werden die Grundzüge der Theorie des Schätzens behandelt.

In *Abschnitt* 16.1 werden anhand eines Beispiels zunächst die wesentlichen Fragestellungen der mathematischen Statistik vorgestellt. Ein weiteres Beispiel deutet an, dass zu einem gestellten Schätzproblem mehrere Lösungen durch erste einfache Überlegungen miteinander verglichen werden können. Es werden die Begriffe eines statistischen Modells, eines Standardmodells sowie der Begriff der Statistik und des Schätzers definiert. Nach Durcharbeiten dieses Abschnitts kennen Sie diese Begriffe und erste Beispiele für Schätzer.

In *Abschnitt* 16.2 wird die Likelihood-Funktion und der Maximum-Likelihood-Schätzer eingeführt. Die Methode des Auffindens eines Schätzers nach dem Maximum-Likelihood-Prinzip wird an einigen Beispielen vorgestellt. Nach Durcharbeiten dieses Abschnitts können Sie zu den vorgestellten Beispielen Maximum-Likelihood-Schätzer bestimmen und sind in der Lage, Parameter-Schätzer zu anderen Familien von Wahrscheinlichkeitsverteilungen nach dieser Methode zu bestimmen.

In *Abschnitt* 16.3 wird der Begriff der Erwartungstreue sowie der Begriff der Konsistenz eines Schätzers eingeführt. Nach Durcharbeiten dieses Abschnitts können Sie in allen bisher betrachteten Beispielen diese beiden Gütekriterien untersuchen.

In *Abschnitt* 16.4 untersuchen wir, ob ein gefundener Schätzer in der Klasse aller möglichen erwartungstreuen Schätzer optimal in seinem Streuungsverhalten ist. Das Auffinden solcher gleichmäßig bester Schätzer gelingt mithilfe der Schranke von Cramér und Rao. Die Bestimmung der Fisher-Information führt zu einer unteren Schranke für die Varianz aller erwartungstreuen Schätzer. Es werden Beispiele diskutiert. Nach Durcharbeiten dieses Abschnitts haben Sie den Beweis der Cramér-Rao-Schranke verstanden und können die Fisher-Information in

Beispielen bestimmen.

Im letzten Kapitel, *Kapitel 17*, wird eine Einführung in die Theorie des mathematischen Tests gegeben.

In *Abschnitt* 17.1 wird in fünf Schritten ein statistisches Entscheidungsverfahren vorgestellt. Es mündet in die Definition der Begriffe Nullhypothese, Alternative, Test, randomisierter Test, effektives Niveau, Ablehnungsbereich, Gütefunktion, Macht und Fehler 1. und 2. Art. Auch wird der Begriff eines gleichmäßig besten Tests, ein Test mit größtmöglicher Macht, definiert. Die Begiffe werden anhand einiger Beispiele eingeübt. Erfahrungsgemäß bereitet der Umgang mit mathematischen Tests zunächst größere Probleme. Nach gründlichem Durcharbeiten dieses Abschnitts beherrschen Sie das Fachvokabular der Testtheorie und können damit anhand der Beispiele umgehen. Lernen Sie hier die Begriffe zunächst stur auswendig!

In *Abschnitt* 17.2 wird die Frage nach der Konstruktion gleichmäßig bester Tests untersucht. Der naive Ansatz mithilfe des Likelihood-Quotienten führt bei sogenannten einfachen Testsituationen bereits zu besten Tests, den sogenannten Neyman-Pearson-Tests. Wir geben Beispiele. Mithilfe eines Monotonieargumentes werden beste Tests zu zusammengesetzten Nullhypothesen und Alternativen konstruiert. Die Suche nach wachsenden Likelihood-Quotienten wird im Beispiel des Gauss'schen Modells vorgeführt. Wir entwickeln dabei den einseitigen Gauss-Test und den sogenannten einseitigen Chiquadrat-Test. Dabei leiten wir einige Resultate zur Faltung von Dichten her. Sie kennen am Ende dieses Abschnitts den Beweis des Lemmas von Neyman-Pearson sowie das Monotonieargument, welches im Beispiel des Bananenhändlers zu besten zusammengesetzten Tests führt, und können damit einseitige Tests im Falle monotoner Likelihood-Quotienten konstruieren. Weiter beherrschen Sie die Methode der Faltung zur Bestimmung der Dichte der Summe unabhängiger Zufallsgrößen.

Diese Kurseinheit gibt einen ersten Einblick in die mathematische Statistik.

Kapitel 16

Die Theorie des Schätzens

In dieser Kurseinheit geben wir eine Einführung in die beurteilende Statistik auf der Grundlage der bisher erworbenen Kenntnisse über die Wahrscheinlichkeitstheorie. Wir verwenden an vielen Stellen die Vorgehensweise der schönen Einführung in die Statistik von Herrn Georgii, die er in seinem Buch zur *Stochastik* wählte. In diesem Kapitel widmen wir uns der *Schätzung von Parametern*. Wir wollen aus zufallsgesteuerten Beobachtungen auf zugrundeliegende Gesetzmäßigkeiten schließen. Die Gesetzmäßigkeiten werden im Folgenden durch eine geeignet gewählte Familie von Wahrscheinlichkeitsverteilungen beschrieben. Eine Vorgehensweise der mathematischen Statistik ist das Verfahren der *Schätzung*. Wir wollen einen möglichst guten Tipp für die tatsächlich vorliegende Wahrscheinlichkeitsverteilung geben. Die Mathematisierung der Frage nach der Qualität von Schätzungen wird uns intensiv beschäftigen.

16.1 Statistiken und Schätzer

Wir starten mit einem Beispiel. Ein Bananenhändler erhält $N = 40000$ Bananen aus Kuba. Wieviele der Bananen sind faul? Der Händler nimmt eine Stichprobe von $n = 100$ Bananen. Eine zufällige Anzahl x hiervon ist faul. Was kann man über die wahre Anzahl w der faulen Bananen aussagen? Es gibt verschiedene Vorgehensweisen. Eine naive Vermutung ist, dass $\frac{x}{n} \approx \frac{w}{N}$ gilt. Wir betrachten also

$$W(x) := \left\lfloor \frac{Nx}{n} \right\rfloor$$

und vermuten, dass $W(x)$ Bananen faul sind. Die Abbildung $x \mapsto W(x)$, bei der x eine Beobachtung und $W(x)$ ein resultierender *Schätzwert* für w ist, werden wir

Schätzer nennen. Dabei ist klar, dass $W(x)$ vom Zufall abhängt. Eine andere Stichprobe liefert im Allgemeinen ein anderes x', also einen anderen Schätzwert $W(x')$. Welcher Schätzwert ist *besser*? Ist W eine gute Schätzung? Was sind Qualitätskriterien für eine Schätzung? Wie kann man in komplizierteren Modellen einen Schätzer finden? Man nennt den obigen Schätzer naiv, weil er unvoreingenommen der ersten Idee entspringt, die man so hat. Naiv bedeutet hier keineswegs etwa dumm. Wir klären, in wieweit dieser naive Schätzer mathematisch gerechtfertigt ist.

16.1.1 Bemerkung: (Schätzung mit Angabe des Fehlers) Wir deuten hier an, dass man ein genaueres Verfahren als eine bloße Schätzung anstreben kann: Anstatt in obigem Beispiel $W(x)$ als einen Schätzwert zu wählen, sucht man alternativ ein von x abhängiges Intervall $C(x)$, in dem der wahre Wert w mit großer Wahrscheinlichkeit liegt. Auch $C(x)$ ist zufallsabhängig. Wir streben also an,

$$P_w\left(x:\ w \in C(x)\right) \approx 1$$

für das wahre w und das richtige Wahrscheinlichkeitsmaß P_w. Dies führt zur Bestimmung von sogenannten *Konfidenzintervallen*. Diese alternative Herangehensweise wird aber nicht der Gegenstand dieses Kurses sein.

Wahrscheinlichkeitstheoretisch haben wir das obige Beispiel des Bananenhändlers schon gut im Griff: Die Stichprobe der Bananen entspricht dem Ziehen ohne Zurücklegen von n Kugeln aus einer Urne mit w weißen und $N-w$ schwarzen Kugeln. Somit ist die Anzahl der faulen Bananen in der Stichprobe *hypergeometrisch* verteilt:

$$h(k;n,w,N-w) := \frac{\binom{w}{k}\binom{N-w}{n-k}}{\binom{N}{n}}, \quad k \in \{0,\dots,n\}.$$

Der Wert w ist nun allerdings unbekannt.

Bevor wir in die Schätztheorie einsteigen, sei anhand des Beispiels eine weitere grundlegende Methode der Statistik vorgestellt. Häufig ist die reine Kenntnis von w nicht ausreichend. Ein Vertrag mit dem Lieferanten besage, dass der Preis für die Bananen nur gezahlt werden muss, wenn maximal 5% der Bananen faul sind. Aus der Beobachtung x muss nun eine Entscheidung über die Qualität gefällt werden. Der Händler hat die Wahl zwischen der *Hypothese* H_0: $w \in \{0,\dots,2000\}$ und der *Alternative* H_1: $w \in \{2001,\dots,40000\}$. Ein sogenanntes Entscheidungsverfahren wäre dann: Ist $x \le c$, so entscheidet sich der Händler für die Hypothese, bei $x > c$ erfolge eine Entscheidung für die Alternative. Die mathematische Aufgabe ist nun, c so zu wählen, dass $\sum_{k:k>c} h(k;n,w,N-w)$ für $w \le 2000$ klein ist und für $w > 2000$ möglichst groß. Die Forderungen besagen, dass ein peinlicher Irrtum für

den Händler unwahrscheinlich sein soll, er aber dennoch zu seinem Recht kommt. Die zu bestimmende Entscheidungsregel wird *Test* genannt. Die Entwicklung von Tests wird uns in den Kapiteln 16 und 17 beschäftigen.

16.1.2 Beispiel: (Materialprüfung) Es werden n unabhängige Messungen mit Ergebnissen $x_1, \ldots, x_n$ zur Undurchlässigkeit eines Materials vorgenommen. Häufig wird dabei die folgende Annahme gemacht: Eine Messung ist beinflusst von der Summe vieler kleiner zufälligen Störungen. Daher nimmt man entsprechend des zentralen Grenzwertsatzes an, dass die Messwerte normalverteilt sind. Es sei weiter die Varianz (Güte des Messinstrumentes) dieser Normalverteilung bekannt. Der Erwartungswert sei unbekannt und soll geschätzt werden. Was ist eine gute Schätzung des Erwartungswertes? Vermutlich erscheint jedem Leser das arithmetische Mittel plausibel:

$$M_n(x) := \frac{1}{n} \sum_{i=1}^{n} x_i.$$

Ist diese Schätzung gut?

In einem weiteren Beispiel lernen wir zwei unterschiedliche Schätzer für ein gestelltes Schätzproblem kennen:

16.1.3 Beispiel: Eine Apparatur erzeugt auf eine für uns nicht ersichtliche Art und Weise Zufallszahlen innerhalb eines Intervalls $[0, \vartheta]$. Wir wollen herausbekommen, wie groß ϑ ist. Der Erbauer der Apparatur sei also in der Lage, $\vartheta > 0$ zu wählen. 2 Personen bedienen die Apparatur $n = 10$ Mal und wollen ϑ möglichst besser als die andere Person erraten. Die möglichen Werte von ϑ liegen in $[0, \infty)$. Für jedes $\vartheta > 0$ betrachten wir nun die gleichförmige Verteilung auf $[0, \vartheta]$, siehe Beispiel 10.3.5(c). Die gleichförmige Verteilung nennen wir auch Gleichverteilung. Wenn ϑ vorliegt, nehmen wir an, dass die Zufallszahlen gleichverteilt sind. Es gibt zu jedem $\vartheta > 0$ eine Gleichverteilung und die Aufgabe der Statistik ist, aus den 10 beobachteten Daten (Zufallszahlen) sinnvoll auf die „passende“ Gleichverteilung zu schließen. Zu jedem ϑ liegt die Dichtefunktion $\varrho_\vartheta(x) := \frac{1}{\vartheta}$, $x \in [0, \vartheta]$, vor. Die Wahrscheinlichkeit sowie den Erwartungswert und die Varianz bezüglich dieser Dichte bezeichnen wir im Folgenden mit P_ϑ, $\mathbb{E}_\vartheta$ und $\mathbb{V}_\vartheta$. Wie kann man aus der Stichprobe sinnvoll ϑ schätzen? Die erste Person lasse sich von der folgenden Beobachtung leiten: Der Erwartungswert einer auf $[0, \vartheta]$ gleichverteilten Zufallsvariable bestimmt sich zu

$$\int_0^\vartheta \frac{x}{\vartheta} dx = \frac{\vartheta}{2}.$$

Wählt die erste Person daher die Zufallsgröße

$$Z_n := 2M_n(X) := \frac{2}{n}\sum_{k=1}^{n} X_k,$$

wobei die $X_1, \ldots, X_n$ unabhängig und auf $[0, \vartheta]$ gleichverteilt gewählte Zufallsgrößen seien, so ist $\mathbb{E}(Z_n) = \vartheta$ erreicht. Im Erwartungswert kommt also der zu schätzende Parameter heraus. Dies ist der hier gewählte Ansatz. Person 1 bestimmt aus den Daten also das Doppelte des arithmetischen Mittels. Mithilfe des schwachen Gesetzes der großen Zahlen empfindet Person 1 seine Wahl plausibel, denn es gilt

$$\lim_{n\to\infty} P_\vartheta(|Z_n - \vartheta| > \varepsilon) = 0$$

für alle $\varepsilon > 0$. Hat Person 1 einen guten Schätzer gefunden?

Die zweite Person folgert aus der Tatsache, dass alle beobachteten Daten kleiner als die gesuchte rechte Intervallgrenze sein müssen, dass auch der maximale Wert der Daten noch unterhalb des gesuchten ϑ liegt, aber dichter an diesem Wert liegt, als alle anderen Daten. Daher untersucht er

$$\widetilde{Z}_n := \max(X_1, \ldots, X_n).$$

Es gilt

$$P_\vartheta(\widetilde{Z}_n \le \vartheta - \varepsilon) = P_\vartheta(X_1 \le \vartheta - \varepsilon, \ldots, X_n \le \vartheta - \varepsilon) = \left(\frac{\vartheta - \varepsilon}{\vartheta}\right)^n.$$

Dabei haben wir die Unabhängigkeit der X_i verwendet. Nun konvergiert die rechte Seite gegen Null für $n \to \infty$ für jedes $\varepsilon > 0$. In diesem Sinne scheint die zweite Person auch eine gute Wahl für einen Schätzer getroffen zu haben. Welche Person hat bessere Gewinnchancen? Wir untersuchen die beiden angegebenen Schätzer weiter. Es gilt ja $\mathbb{E}_\vartheta(Z_n) = \vartheta$. Können wir auch $\mathbb{E}_\vartheta(\widetilde{Z}_n)$ bestimmen? Es gilt

$$P_\vartheta(\widetilde{Z}_n \le c) = \left(\frac{c}{\vartheta}\right)^n, \quad c \in [0, \vartheta],$$

also ist

$$[0, \vartheta] \ni \vartheta \mapsto \frac{d}{dx}\left(\frac{x}{\vartheta}\right)^n = nx^{n-1}\vartheta^{-n}$$

die Dichte der Verteilungsfunktion von $\widetilde{Z}_n$. Damit folgt

$$\mathbb{E}_\vartheta(\widetilde{Z}_n) = \int_0^\vartheta x(nx^{n-1}\vartheta^{-n})dx = n\vartheta^{-n}\int_0^\vartheta x^n dx = \frac{n}{n+1}\vartheta, \quad \vartheta > 0.$$

Man kann von einer systematischen Unterschätzung von ϑ sprechen. Aber es gilt immerhin $\lim_{n\to\infty} \mathbb{E}_\vartheta(\widetilde{Z}_n) = \vartheta$. Wenn es geboten sein sollte, dass im Erwartungswert der Schätzung möglichst der zu schätzende Parameter rauskommen möge, so kann man für die 2. Person schnell Abhilfe schaffen und zu

$$Z_n^* := \frac{n+1}{n}\widetilde{Z}_n$$

übergehen, denn dann ist $\mathbb{E}_\vartheta(Z_n^*) = \vartheta$. Ein Qualitätskriterium, welches am Ende eines Stochastikkurses schnell einleuchtet, ist das folgende: Derjenige Schätzer wird als besser erachtet, der im Mittel weniger um den wahren Wert streut. Wir bestimmen daher die Varianzen unserer Schätzer. Es gilt

$$\begin{aligned}\mathbb{V}_\vartheta(Z_n) &= \left(\frac{2}{n}\right)^2 \mathbb{V}_\vartheta\left(\sum_{k=1}^n X_k\right) = \frac{4}{n}\mathbb{V}_\vartheta(X_1)\\ &= \frac{4}{n}\frac{1}{\vartheta}\int_0^\vartheta \left(x - \frac{\vartheta}{2}\right)^2 dx = \frac{\vartheta^2}{3n},\end{aligned}$$

$$\begin{aligned}\mathbb{V}_\vartheta(\widetilde{Z}_n) &= \mathbb{E}_\vartheta(\widetilde{Z}_n^2) - (\mathbb{E}_\vartheta(\widetilde{Z}_n))^2\\ &= \int_0^\vartheta x^2(nx^{n-1}\vartheta^{-n})dx - \left(\frac{n\vartheta}{n+1}\right)^2\\ &= \left(\frac{n}{n+2} - \frac{n^2}{(n+1)^2}\right)\vartheta^2 = \frac{n\vartheta^2}{(n+1)^2(n+2)}.\end{aligned}$$

Also ist

$$\mathbb{V}_\vartheta(Z_n^*) = \left(\frac{n+1}{n}\right)^2 \mathbb{V}_\vartheta(\widetilde{Z}_n) = \frac{\vartheta^2}{n(n+2)}.$$

Nun müssen wir bei der Interpretation der Resultate etwas vorsichtig sein. Zunächst sehen wir, dass $\widetilde{Z}_n$ weniger streut als Z_n^*, aber um den falschen Wert $\frac{n}{n+1}\vartheta$. Für $\widetilde{Z}_n$ sollten wir auch die Streuung um ϑ berechnen:

$$\begin{aligned}\mathbb{E}_\vartheta((\widetilde{Z}_n - \vartheta)^2) &= \mathbb{V}_\vartheta(\widetilde{Z}_n) + (\mathbb{E}_\vartheta(\widetilde{Z}_n) - \vartheta)^2 = \frac{n\vartheta^2}{(n+1)^2(n+2)} + \left(\frac{n\vartheta}{n+1} - \vartheta\right)^2\\ &= \frac{2\vartheta^2}{(n+1)(n+2)}.\end{aligned}$$

Dieser Wert ist ca. doppelt so groß wie $\mathbb{V}_\vartheta(Z_n^*)$, für große n. Es erfolgt nun abschließend ein Zahlenvergleich. Es gilt:

$$\mathbb{V}_\vartheta(Z_{10}) = \frac{\vartheta^2}{30},$$

$$\mathbb{E}_\vartheta((\widetilde{Z}_{10} - \vartheta)^2) = \frac{\vartheta^2}{66}$$
$$\text{und } \mathbb{V}_\vartheta(Z_{10}^*) = \frac{\vartheta^2}{120}.$$

Das Ergebnis ist interessant: Beide Personen verfolgen nicht die optimale Strategie: Z_n^* ist besser in seinem Streuverhalten. Der naive Mittelwertschätzer ist nicht optimal und Z_n^* ist der beste. Gibt es einen besten Schätzer? Diese Frage haben wir hier natürlich nicht beantwortet. Wir sehen an diesem Beispiel aber sehr eindrücklich, dass die Wahl eines geeigneten Schätzers schnell ein kompliziertes Unterfangen werden kann.

Abschließend formalisieren wir ein paar Grundbegriffe.

16.1.4 Definition: Ein *statistisches Modell* ist ein Tripel $(\mathcal{X}, \mathcal{F}, P_\vartheta : \vartheta \in \Theta)$. Hierbei ist $\mathcal{X}$ eine Menge, $\mathcal{F}$ eine σ-Algebra über $\mathcal{X}$ und $\{P_\vartheta : \vartheta \in \Theta\}$ eine mindestens zweielementige Menge von Wahrscheinlichkeitsmaßen auf $(\mathcal{X}, \mathcal{F})$. Θ ist eine beliebige (Index-) Menge.

Wir schreiben $\mathbb{E}_\vartheta$, $\mathbb{V}_\vartheta$ für den Erwartungswert und die Varianz bezüglich P_ϑ. Die Bezeichnung mit $\mathcal{X}$ statt Ω rührt daher, dass die Beobachtungen als Realisierungen einer Zufallsvariable $X : \Omega \to \mathcal{X}$ interpretiert werden.

16.1.5 Definition: (i) Ein statistisches Modell $\mathcal{M} = (\mathcal{X}, \mathcal{F}, P_\vartheta : \vartheta \in \Theta)$ heißt ein *parametrisches Modell* , wenn $\Theta \subseteq \mathbb{R}^d$ für ein $d \in \mathbb{N}$. Ist $d = 1$, so heißt $\mathcal{M}$ ein *einparametriges Modell.*

(ii) Ist $\mathcal{X}$ höchstens abzählbar und $\mathcal{F} = \mathcal{P}(\mathcal{X})$, so heißt $\mathcal{M}$ ein *diskretes Modell.* $\mathcal{M}$ heißt *stetiges Modell* , wenn $\mathcal{X}$ eine Borel'sche Teilmenge eines $\mathbb{R}^n$ ist, $\mathcal{F} = \mathcal{B}_\mathcal{X}^n$ die auf $\mathcal{X}$ eingeschränkte Borel'sche σ-Algebra und jedes P_ϑ eine Dichtefunktion ϱ_ϑ besitzt. $\mathcal{M}$ heißt in beiden Fällen auch kurz *Standardmodell.*

Wir betrachten hier wie in dem bisherigen Kurs nur Standardmodelle. Im diskreten Modell hat P_ϑ immer eine Zähldichte

$$\varrho_\vartheta \ : \ x \mapsto P_\vartheta(\{x\}).$$

Im Standardmodell gilt für $A \in \mathcal{F}$

$$P_\vartheta(A) = \sum_{x \in A} \varrho_\vartheta(x)$$

oder

$$P_\vartheta(A) = \int_A \varrho_\vartheta(x)dx \quad (\text{LEBESGUE-Integral im } \mathbb{R}^n).$$

In der Wahrscheinlichkeitstheorie ist der erste Schritt die Wahl eines geeigneten Wahrscheinlichkeitsraumes (die Modellierung). In diesem Modell bestimmen wir dann Wahrscheinlichkeiten von Ereignissen und interpretieren diese als das, was wir von einer Stichprobe erwarten sollten, die gemäß dem Modell gewählt wird. In der Statistik kennen wir P nicht, aber es liegt eine Stichprobe vor, die gemäß P gewählt wurde. Nun wollen wir Aussagen über P aufgrund der Stichprobe machen.

16.1.6 Definition: Es sei $(\mathcal{X}, \mathcal{F}, P_\vartheta : \vartheta \in \Theta)$ ein statistisches Modell und $(\Sigma, \mathcal{S})$ eine Menge versehen mit einer σ-Algebra.

(i) Eine Zufallsvariable S von $(\mathcal{X}, \mathcal{F})$ nach $(\Sigma, \mathcal{S})$ heißt *Statistik*. Die Interpretation ist: Wir betrachten wohlkonstruierte Abbildungen, die aus den Beobachtungsdaten essentielle Größen herauslösen.

(ii) Es sei $\tau : \Theta \to \Sigma$ eine Abbildung (Interpretation: $\tau(\vartheta)$ ist eine Kenngröße). Eine Statistik $T : \mathcal{X} \to \Sigma$ heißt ein *Schätzer* für τ. (Interpretation: T soll τ schätzen, der Begriff wird aber nicht darauf eingeengt.)

Das statistische Modell in Beispiel 16.1.3 ist durch

$$([0, \infty[, \mathcal{B}_{[0,\infty[}, \mathcal{U}_{[0,\vartheta]} : \vartheta > 0)$$

gegeben, wobei $\mathcal{U}_{[0,\vartheta]}$ die Gleichverteilung auf $[0, \vartheta]$ mit Dichtefunktion $\varrho(x) = \frac{1}{\vartheta}$, $x \in [0, \vartheta]$, bezeichnet.

16.1.7 Aufgabe: Geben Sie ein statistisches Modell für das Schätzproblem des Bananenhändlers an. Geben Sie ein statistisches Modell für die Situation in Beispiel 16.1.2 an.

16.1.8 Aufgabe: Die Strahlenbelastung von Blattspinat soll überprüft werden. Es wird bei n unabhängigen Spinatproben jeweils die Anzahl der Impulse eines GEIGER-MÜLLER-Zählers während einer vorgegebenen Zeitspanne erhoben. Welches statistische Modell ist hier angemessen? Geben Sie einen Schätzer für die Strahlenbelastung an.

Die Definition 16.1.4 eines statistischen Experiments geht davon aus, dass wir von vornherein wissen, dass die Wahrscheinlichkeitsverteilung der beobachteten Daten ein Element der Familie $(P_\vartheta)_{\vartheta \in \Theta}$ ist. Man muss dann Kriterien finden, nach denen

die Wahl getroffen werden soll. Eine deutlich schwierigere Problemstellung der beurteilenden Statistik entsteht in der Situation, in der wir *a priori* nichts oder so gut wie nichts über die Verteilung der Daten wissen. Dies fällt in den Bereich der sogenannten *nicht-parametrischen* Statistik, die wir in diesem Kurs nicht behandeln können. Die Wortwahl ist etwas missverständlich, denn aus mathematischer Sicht ist es der Übergang zu unendlichdimensionalen Parametermengen. Wir vertiefen dies hier nicht.

16.2 Maximum-Likelihood-Methode

Es gibt unterschiedliche Methoden, Schätzer zu konstruieren. Eine beliebte Klasse sind die sogenannten *Maximum-Likelihood*-Schätzer. Das Wort *likelihood* bedeutet *Wahrscheinlichkeit*. Zur Beobachtung x ist $\varrho_\vartheta(x) = P_\vartheta(\{x\})$ die Wahrscheinlichkeit, mit der x eintritt, wenn ϑ der richtige Parameter ist. Ein ϑ mit sehr kleinem $\varrho_\vartheta(x)$ „kann“ nicht der wahre Parameter sein, denn sonst wäre x ein Ausnahmefall gewesen. Wir tippen eher auf ein ϑ, bei dem x mit großer Wahrscheinlichkeit eintritt.

16.2.1 Definition: Es sei $(\mathcal{X}, \mathcal{F}, P_\vartheta : \vartheta \in \Theta)$ ein statistisches Standardmodell. $\varrho : \mathcal{X} \times \Theta \to [0, \infty[$ mit

$$\varrho(x, \vartheta) := \varrho_\vartheta(x)$$

heißt *Likelihood- oder Plausibilitätsfunktion.*

$$\varrho_x = \varrho(x, \cdot) : \Theta \to [0, \infty[, \quad \vartheta \mapsto \varrho(x, \vartheta)$$

heißt *Likelihoodfunktion zum Beobachtungswert* $x \in \mathcal{X}$.

16.2.2 Definition: Ein Schätzer $T : \mathcal{X} \to \Theta$ für ϑ heißt *Maximum-Likelihood-Schätzer* (kurz: ML-Schätzer), wenn

$$\varrho(x, T(x)) = \max_{\vartheta \in \Theta} \varrho(x, \vartheta)$$

für jedes $x \in \mathcal{X}$ gilt.

Ein ML-Schätzer bestimmt *nicht* dasjenige ϑ, für welches die gemachte Beobachtung gerade ein Ereignis darstellt, dem die Verteilung P_ϑ die größte Wahrscheinlichkeit zuordnet. Der ML-Schätzer bestimmt das ϑ, für welches die Beobachtung maximale Wahrscheinlichkeit besitzt, maximal in ϑ.

16.2.3 Beispiel: Wir betrachten das in Teilkapitel 16.1 behandelte Eingangsbeispiel des Bananenhändlers. Hier wollen wir den ML-Schätzer bestimmen. Nun ist $\mathcal{X} := \{0, \ldots, n\}$, $\Theta := \{0, \ldots, N\}$ und die Zähldichte ist

$$\varrho_\vartheta(x) := \frac{\binom{\vartheta}{x}\binom{N-\vartheta}{n-x}}{\binom{N}{n}}.$$

Für welches ϑ ist $\varrho_\vartheta(x)$ maximal? Analog zu Aufgabe 15.1.2 betrachten wir

$$\begin{aligned}\frac{\varrho_\vartheta(x)}{\varrho_{\vartheta-1}(x)} &= \frac{\binom{\vartheta}{x}\binom{N-\vartheta}{n-x}}{\binom{\vartheta-1}{x}\binom{N-\vartheta+1}{n-x}} = \frac{\vartheta(N-\vartheta+1-n+x)}{(\vartheta-x)(N-\vartheta+1)} \geq 1 \\ &\Leftrightarrow \quad \vartheta n \leq (N+1)x \\ &\Leftrightarrow \quad \vartheta \leq \frac{N+1}{n}x,\end{aligned}$$

also ist ϱ_x wachsend auf $\{0, 1, \ldots, \lfloor \frac{N+1}{n}x \rfloor\}$ und fallend für größere Werte. Damit ist für $x < n$

$$T(x) := \left\lfloor \frac{N+1}{n}x \right\rfloor$$

die eindeutige Maximalstelle, solange nicht $\frac{N+1}{n}x \in \mathbb{N}$. Für $x = n$ setzen wir $T(x) = N$. Dies entspricht im Wesentlichen dem naiven Schätzer der Einleitung.

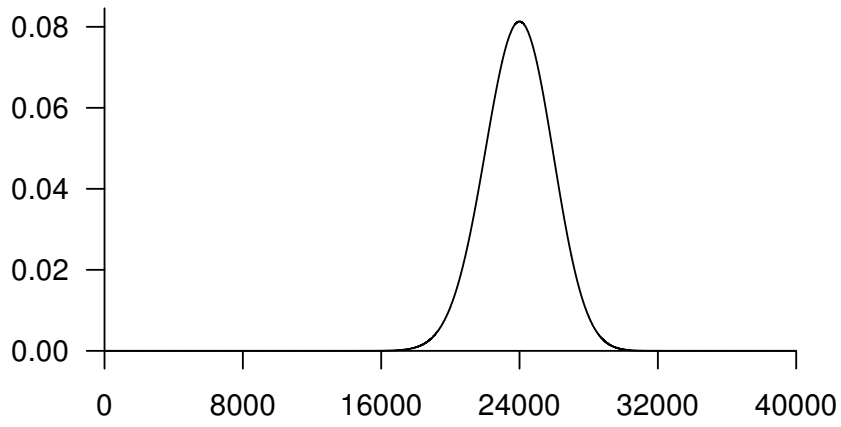

Abb. 16.1: Likelihoodfunktion $\Theta \ni \vartheta \mapsto \rho_\vartheta(x)$ für den Fall $x = 60$

16.2.4 Aufgabe: Bei einer Qualitätskontrolle werden 1000 Sparlampen geprüft. In der Stichprobe waren 30 Exemplare defekt. Bestimmen Sie den Maximum-Likelihood-Schätzer für die Anzahl der defekten Lampen unter den 100000 produzierten Lampen.

16.2.5 Beispiel: (Erfolgswahrscheinlichkeit in der BERNOULLI-Kette) **16.2.5 Beispiel:** (Erfolgswahrscheinlichkeit in der Bernoulli-Kette) Das statistische Modell sei nun

$$(\{0,\ldots,n\}, \mathcal{P}(\{0,\ldots,n\}), \mathcal{B}_{n,\vartheta} : \ \vartheta \in [0,1])$$

mit $\mathcal{B}_{n,\vartheta}(x) := b(x;n,\vartheta) = \binom{n}{x} \vartheta^x (1-\vartheta)^{n-x}$. Mit $\rho_x(\vartheta) = \mathcal{B}_{n,\vartheta}(x)$ ist für $0 < \vartheta < 1$

$$\frac{d}{d\vartheta} \ln \rho_x(\vartheta) = \frac{d}{d\vartheta}\left[\ln \binom{n}{x} + x \ln \vartheta + (n-x) \ln (1-\vartheta)\right]$$

$$= \frac{x}{\vartheta} - \frac{n-x}{1-\vartheta} = \frac{n\left(\frac{x}{n} - \vartheta\right)}{\vartheta(1-\vartheta)}.$$

Für $0 < x < n$ erhalten wir

$$\frac{d}{d\vartheta} \ln \rho_x(\vartheta) > 0 \quad \left(\vartheta \in \left(0, \frac{x}{n}\right)\right) \quad \Longrightarrow \quad \ln \rho_x \text{ monoton wachsend auf } \left[0, \frac{x}{n}\right],$$

$$\frac{d}{d\vartheta} \ln \rho_x(\vartheta) < 0 \quad \left(\vartheta \in \left(\frac{x}{n}, 1\right)\right) \quad \Longrightarrow \quad \ln \rho_x \text{ monoton fallend auf } \left[\frac{x}{n}, 1\right].$$

Da der Logarithmus eine monoton wachsende Funktion ist, haben wir auch

$$\rho_x \text{ monoton wachsend auf } \left[0, \frac{x}{n}\right], \quad \rho_x \text{ monoton fallend auf } \left[\frac{x}{n}, 1\right].$$

Für $\vartheta = \frac{x}{n}$ liegt ein Maximum vor. Der „naive“ Schätzer $x \mapsto T(x) = \frac{x}{n}$ ist der einzige ML-Schätzer für ϑ.

Die Gleichung

$$\max_{\vartheta \in [0,1]} \rho_x(\vartheta) = \rho_x\left(\frac{x}{n}\right)$$

gilt auch für $x = 0$ und $x = n$.

16.2.6 Aufgabe: In einem BERNOULLI-Experiment treten vor dem r-ten Erfolg genau x Misserfolge auf. Berechnen Sie den Maximum-Likelihood-Schätzer für die Erfolgswahrscheinlichkeit.

16.2.7 Beispiel: (Zufallszahlen, siehe Beispiel 16.1.3) Hier ist nun aufgrund der vorausgesetzten Unabhängigkeit der gleichförmig auf $[0, \vartheta]$ verteilten Zufallsgrößen

$$\varrho_x(\vartheta) = \begin{cases} \left(\frac{1}{\vartheta}\right)^n, & \text{falls } x_1, \ldots, x_n \leq \vartheta, \\ 0\,, & \text{sonst} \end{cases}$$

mit $x := (x_1, \ldots, x_n) \in [0, \infty)^n$, $\vartheta > 0$. Die Behauptung ist nun, dass $\widetilde{Z}_n(x) := \max(X_1, \ldots, X_n)$ (die Wahl der 2. Person) der Maximum-Likelihood-Schätzer ist. Dies sieht man so: Es gilt

$$\varrho(x, \max(x_1, \ldots, x_n)) = \max(x_1, \ldots, x_n)^{-n}$$

und

$$\left(\frac{1}{\vartheta}\right)^n \leq \left(\frac{1}{\max(x_1, \ldots, x_n)}\right)^n$$

für alle $x_1, \ldots, x_n \leq \vartheta$. Wäre man also ohne jede Vorüberlegung oder Intuition an dieses statistische Problem herangetreten, so hätte die Methode des ML-Schätzers zu dem Schätzer, den bei uns die 2. Person wählte, geführt.

16.2.8 Beispiel: (Gauss'sches Modell) In Beispiel 16.1.2 waren uns n unabhängige normalverteilte Zufallsgrößen begegnet. Das zugehörige statistische Modell besteht aus $\mathbb{R}^n$, versehen mit der Borel'schen σ-Algebra auf $\mathbb{R}^n$. Ist jedes X_i normalverteilt zu den Parametern μ und σ^2 (siehe Beispiel 10.3.5(b)), so folgt aus der Unabhängigkeit der X_i mit Satz 10.3.18, dass die folgenden Produktdichten zugrundeliegen ($x := (x_1, \ldots, x_n) \in \mathbb{R}^n$ mit $x_i \neq x_j$ für ein Paar i, j, $1 \leq i < j \leq n$):

$$\begin{aligned} \varrho_x(\vartheta) &= \prod_{i=1}^n \varphi(x_i; \mu, \sigma^2) \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\Big(-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}\Big) \end{aligned} \tag{16.1}$$

mit $\vartheta = (\mu, \sigma^2) \in \Theta = \mathbb{R} \times (0, \infty)$. Wir nennen dieses statistische Modell ab nun das *Gauss'sche Modell*. Wir wollen diesen Ausdruck in ϑ maximieren, also den ML-Schätzer für (μ, σ^2) bestimmen. Dabei betrachten wir im ersten Schritt zunächst die Wahl von μ so, dass $\sum_{i=1}^n (x_i - \mu)^2$ minimal wird. Nun wissen wir mit Satz 3.2.7, dass das arithmetische Mittel

$$M_n(x) := \frac{1}{n} \sum_{i=1}^n x_i.$$

die quadratische Abweichung minimiert (siehe auch Satz 11.2.7). Im zweiten Schritt wählen wir σ^2 so, dass $(2\pi\sigma^2)^{-n/2}\exp\Big(-\frac{1}{2\sigma^2}\sum_{i=1}^n (x_i - M_n(x))^2\Big)$ maximal wird. Dazu differenzieren wir den Logarithmus hiervon:

$$-\frac{d}{d\sigma^2}\Big(\frac{n}{2}\ln(2\pi\sigma^2) + \frac{1}{2\sigma^2}\sum_{i=1}^n (x_i - M_n(x))^2\Big) = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}\sum_{i=1}^n (x_i - M_n(x))^2.$$

Dies ist genau dann gleich Null, wenn

$$\sigma^2 = V_n(x) := \frac{1}{n}\sum_{i=1}^n \Big(x_i - M_n(x)\Big)^2.$$

Man muss sich nun aber noch davon überzeugen, dass mit $\Big(M_n(x), V_n(x)\Big)$ eine Maximalstelle gefunden wurde. Dies lassen wir als Übung. Alternativ kann man die Vorgehensweise der Analysis in mehreren Veränderlichen wählen, mit deren Hilfe man die Maximierung der Funktion $\varrho_x(\mu, \sigma^2)$ in zwei Veränderlichen durchführen kann. Für diejenigen Leser, die die Methode kennen: Die Gleichungen

$$\frac{\partial}{\partial\mu}\ln\varrho_x(\mu,\sigma^2) = 0 \quad \text{und} \quad \frac{\partial}{\partial(\sigma^2)}\ln\varrho_x(\mu,\sigma^2) = 0$$

liefern simultan gelöst die obigen Schätzer $M_n(x)$ und $V_n(x)$. Mithilfe der Hesse'schen Matrix überprüft man, dass es sich um ein Maximum handelt (Otto Hesse (1811–1874)): Es gilt

$$\frac{\partial^2}{\partial\mu^2}\ln\varrho_x(\mu,\sigma^2) = -\frac{n}{\sigma^2} \quad \text{und} \quad \frac{\partial^2}{\partial(\sigma^2)^2}\ln\varrho_x(\mu,\sigma^2) = \frac{n}{2\sigma^4} - \frac{1}{\sigma^6}\sum_{i=1}^n (x_i-\mu)^2$$

sowie

$$\frac{\partial^2}{\partial\mu\partial(\sigma^2)}\ln\varrho_x(\mu,\sigma^2) = -\frac{1}{\sigma^4}\sum_{i=1}^n (x_i-\mu).$$

Somit ist $\frac{\partial^2}{\partial\mu^2}\ln\varrho_x(\mu,\sigma^2) < 0$ und die Determinante der Hesseschen Matrix an der Stelle $\Big(M_n(x), V_n(x)\Big)$ ist positiv (gleich $\frac{n^2}{2\sigma^6}$), also ist die Hessesche Matrix negativ definit und somit liegt an der Stelle $\Big(M_n(x), V_n(x)\Big)$ ein isoliertes Maximum vor.

16.2.9 Satz: (ML-Schätzer im Gauss'schen Modell) Der ML-Schätzer im n-fachen Gauss'schen Modell in Beispiel 16.2.8 ist $T = (M_n(X), V_n(X))$ mit

$$M_n(X) = \frac{1}{n}\sum_{i=1}^n X_i \quad \text{und} \quad V_n(X) = \frac{1}{n}\sum_{i=1}^n (X_i - M_n(X))^2.$$

$M_n(X)$ heißt *Stichprobenmittel* und $V_n(X)$ *Stichprobenvarianz.*

16.3 Erwartungstreue Schätzer

Wir beginnen nun, Qualitätsmerkmale von Schätzern zu studieren. Wollen wir in einem statistischen Modell $(\mathcal{X}, \mathcal{F}, P_\vartheta : \vartheta \in \Theta)$ eine Kenngröße τ mithilfe eines Schätzers T schätzen, so wird in der Regel der Schätzfehler $T - \tau(\vartheta)$ von Null verschieden sein. Wir kennzeichnen nun diejenigen Schätzer, bei denen sich im Mittel die Schätzfehler gegenseitig aufheben:

16.3.1 Definition: Es sei $(\mathcal{X}, \mathcal{F}, P_\vartheta : \vartheta \in \Theta)$ ein statistisches Modell und $\tau : \Theta \to \mathbb{R}$ eine reelle „Kenngröße". Ein Schätzer $T : \mathcal{X} \to \mathbb{R}$ für τ heißt *erwartungstreu*, wenn

$$\mathbb{E}_\vartheta(T) = \tau(\vartheta) \qquad \text{für alle} \quad \vartheta \in \Theta.$$

$\mathbb{B}_\vartheta(T) := \mathbb{E}_\vartheta(T) - \tau(\vartheta)$ heißt *Bias* oder *systematischer Fehler* von T.

16.3.2 Bemerkung: Ist $\mathcal{X}$ diskret, so erinnern wir, dass

$$\mathbb{E}_\vartheta(T) = \sum_{x \in \mathcal{X}} T(x) P_\vartheta(\{x\}) = \sum_{x \in \mathcal{X}} T(x) \rho_\vartheta(x)$$

gilt. Ist im kontiuierlichen Fall die Dichte von P_ϑ gegeben durch $\rho_\vartheta(x)$, so haben wir

$$\mathbb{E}_\vartheta(T) = \int_{\mathcal{X}} T(x) \rho_\vartheta(x)\, dx.$$

Erwartungstreue Schätzer sind uns bereits begegnet. Die Schätzer Z_n und Z_n^* in Beispiel 16.1.3 sind erwartungstreu. $\widetilde{Z}_n$ ist nicht erwartungstreu, weshalb man zu Z_n^* übergegangen ist. Der naive Schätzer in der Bernoulli-Kette ist ebenfalls erwartungstreu, siehe Beispiel 16.2.5. Sobald identisch verteilte Zufallsgrößen $X_1, \ldots, X_n$ mit existierendem Erwartungswert vorliegen, ist $\frac{1}{n} \sum_{i=1}^n X_i$ erwartungstreu. Somit sind die Schätzer $M_n(X)$ in den Beispielen 16.1.2 und 16.2.8 erwartungstreu. Nun verallgemeinern wir das Beispiel des Gauss'schen Modells:

16.3.3 Beispiel: (unabhängige Zufallsgrößen) Es seien $X_1, \ldots, X_n$ unabhängige Zufallsgrößen, definiert auf einem Wahrscheinlichkeitsraum $(\Omega, \mathcal{F}, P)$. Sie mögen den Erwartungswert μ und die Varianz σ^2 haben, wobei beide Parameter unbekannt seien. Wir suchen erwartungstreue Schätzer von μ und σ^2. Natürlich ist $M_n(X) = \frac{1}{n} \sum_{i=1}^n X_i$ ein erwartungstreuer Schätzer von μ. Entsprechend unserer Vorkenntnisse aus dem Gauss'schen Modell bestimmen wir nun den Erwartungswert von

$$\frac{1}{n} \sum_{i=1}^n (X_i - M_n(X))^2.$$

Es gilt unter Verwendung bekannter Rechenregeln:

$$\begin{aligned}
\mathbb{E}\left(\sum_{i=1}^{n}(X_i - M_n(X))^2\right) &= \mathbb{E}\left(\sum_{i=1}^{n} X_i^2 - n\, M_n(X)^2\right) \\
&= \sum_{i=1}^{n}\mathbb{E}(X_i^2) - \frac{1}{n}\mathbb{E}\left(\left(\sum_{i=1}^{n} X_i\right)^2\right) \\
&= \sum_{i=1}^{n}(\mathbb{V}(X_i) + \mu^2) - \frac{1}{n}\left(\mathbb{V}\left(\sum_{i=1}^{n} X_i\right) + (n\mu)^2\right) \\
&= n(\sigma^2 + \mu^2) - \frac{1}{n}(n\sigma^2 + n^2\mu^2) = (n-1)\sigma^2.
\end{aligned}$$

Daraus folgt, dass

$$V_n^*(X) := \frac{1}{n-1}\sum_{i=1}^{n}(X_i - M_n(X))^2$$

erwartungstreu ist. Diesen Schätzer kennen wir bereits in der Situation einfacher Zufallsgrößen. Es ist die *empirische Varianz*, siehe Definition 3.2.5. Es wird umgekehrt mit unserer Rechnung eine wichtige, alternative Begründung für die Wahl der Definition der empirischen Varianz nachgereicht: Um Erwartungstreue zu erhalten, muss man durch $n-1$ statt durch n dividieren. Dies gilt ganz allgemein im Modell n unabhängig ausgeführter statistischer Modelle. Man vergleiche dies mit der Diskussion nach Aufgabe 3.2.8.

16.3.4 Aufgabe: Ist der in Aufgabe 16.1.8 angegebene Schätzer erwartungstreu?

Erwartungstreue ist wünschenswert, aber die Kontrolle des *mittleren quadratischen Fehlers* eines Schätzers T für τ

$$\mathbb{F}_\vartheta(T) := \mathbb{E}_\vartheta\Big((T - \tau(\vartheta))^2\Big) = \mathbb{V}_\vartheta(T) + \mathbb{B}_\vartheta(T)^2$$

ist ebenfalls von Bedeutung: Man muss also Varianz *und* Bias gleichzeitig klein halten.

Wir betrachten nun ein weiteres Qualitätsmerkmal für einen Schätzer. Zu n Beobachtungen betrachten wir einen von n abhängigen Schätzer T_n einer Kenngröße und hoffen, dass für große n dieser Schätzer nur wenig vom wahren Wert der zu schätzenden Kenngröße abweicht.

16.3.5 Definition: Für jedes $n \in \mathbb{N}$ sei $\mathcal{M}_n := (\mathcal{X}_n, \mathcal{F}_n, P_{\vartheta,n} : \vartheta \in \Theta)$ ein statistisches Modell mit gemeinsamer Parametermenge Θ. Sei $\tau : \Theta \to \mathbb{R}$ eine reelle Kenngröße und $T_n : \mathcal{X}_n \to \mathbb{R}$ ein Schätzer für τ im statistischen Modell $\mathcal{M}_n$. Die

Folge von Schätzern $(T_n)_{n\geq 1}$ für τ heißt *konsistent*, wenn für alle $\varepsilon > 0$ und für alle $\vartheta \in \Theta$

$$\lim_{n\to\infty} P_{\vartheta,n}(|T_n - \tau(\vartheta)| > \varepsilon) = 0.$$

Die Konsistenz ergibt sich häufig aus einem bekannten schwachen Gesetz der großen Zahlen. So ist der naive Schätzer in Beispiel 16.2.5 konsistent, was unmittelbar aus Satz 12.2.1 folgt. Tatsächlich sind die Schätzer $M_n(X)$ und $V(X)$ in Beispiel 16.3.3 ebenfalls konsistent. Für $M_n(X)$ folgt dies erneut aus Satz 12.2.1. Für $V(X)$ beweisen wir dies hier nicht.

16.3.6 Beispiel: Die mittlere Anzahl von abzuarbeitenden Druckaufträgen für einen Drucker oder die Anzahl der Schadensmeldungen bei einer Kfz-Versicherung ist approximativ POISSON-verteilt. Das zugeordnete statistische Modell ist $\mathcal{X} = \mathbb{N}_0$, $\Theta = (0,\infty)$ und P_ϑ gegeben durch die Zähldichte $\varrho(x,\vartheta) = \frac{\vartheta^x}{x!}e^{-\vartheta}$ für $\vartheta \in \Theta$. Hier ist $M_n(X) = \frac{1}{n}\sum_{i=1}^n X_i$ ein erwartungstreuer Schätzer für ϑ und $(M_n)_n$ ist konsistent nach Satz 12.2.1.

16.3.7 Beispiel: Die Verteilung des ersten Zeitpunktes im POISSON-Modell für rein zufällige Punkte ist die Exponentialverteilung. Wir wählen das statistische Modell $\mathcal{X} = [0,\infty)$, $\Theta = (0,\infty)$ sowie $\varrho(x,\vartheta) = \vartheta e^{-\vartheta x}$ für $\vartheta \in \Theta$. Dann ist $\ln \varrho(x,\vartheta) = -\vartheta x + \ln(\vartheta)$ und daher

$$\frac{d}{d\vartheta} \ln\Big(\varrho(x_1,\vartheta)\cdots\varrho(x_n,\vartheta)\Big) = \frac{d}{d\vartheta}\sum_{i=1}^n [-\vartheta x_i + \ln(\vartheta)].$$

Daher ist $T_n(X) := \frac{1}{M_n(X)}$ mit $M_n(X) = \frac{1}{n}\sum_{i=1}^n X_i$ ein Maximum-Likelihood-Schätzer für ϑ und die Folge $(T_n)_n$ ist konsistent nach Satz 12.2.1.

16.3.8 Aufgabe: Es seien $X_1, X_2, \ldots$ unabhängige, binomialverteilte Zufallsgrößen zu den Parametern p und m. Beide Parameter seien unbekannt. Geben Sie einen Schätzer $(T_n)_n$ für m auf der Grundlage von n Beobachtungen an, sodass die Folge $(T_n)_n$ konsistent ist.

16.3.9 Aufgabe: Betrachten Sie im Modell der BERNOULLI-Kette den Schätzer

$$Y_n := \frac{1}{n+2}\left(1 + \sum_{i=1}^n X_i\right)$$

für die Erfolgswahrscheinlichkeit ϑ. Zeigen Sie $\lim_{n\to\infty} \mathbb{E}_\vartheta(Y_n) = \vartheta$ für alle $\vartheta \in [0,1]$. Zeigen Sie weiter, dass $(Y_n)_n$ für ϑ konsistent ist.

16.4 Beste Schätzer

In Beispiel 16.1.3 haben wir zwei erwartungstreue Schätzer für ein und das gleiche Schätzproblem kennengelernt. Wir haben daraufhin das Varianzverhalten der beiden Schätzer bestimmt und den erwartungstreuen Schätzer mit der kleineren Varianz als den besseren bezeichnet. Dies motiviert die folgende Definition eines weiteren Qualitätsmerkmals von Schätzern.

16.4.1 Definition: Sei $(\mathcal{X}, \mathcal{F}, P_\vartheta : \vartheta \in \Theta)$ ein statistisches Modell. Ein erwartungstreuer Schätzer T für eine reelle Kenngröße $\tau(\vartheta)$ heißt *varianzminimierend* bzw. *gleichmäßig bester Schätzer*, wenn für jeden erwartungstreuen Schätzer S von $\tau(\vartheta)$ gilt:

$$\mathbb{V}_\vartheta(T) \leq \mathbb{V}_\vartheta(S) \quad \text{für alle } \vartheta \in \Theta.$$

Hierbei mögen die Varianzen existieren.

Wir betrachten zunächst eine Bernoulli-Kette $X_1, \ldots, X_n$. Zu reellen Zahlen $0 \leq \alpha_1, \ldots, \alpha_n \leq 1$ mit $\sum_{i=1}^n \alpha_i = 1$ und $\alpha := (\alpha_1, \ldots, \alpha_n)$ sei

$$M_n^\alpha(X) := \sum_{i=1}^n \alpha_i X_i.$$

Dann ist jedes $M_n^\alpha(X)$ ein erwartungstreuer Schätzer von $\vartheta \in [0,1]$, denn

$$\mathbb{E}\left(\sum_{i=1}^n \alpha_i X_i\right) = \sum_{i=1}^n \alpha_i \mathbb{E}(X_i) = \sum_{i=1}^n \alpha_i \vartheta = \vartheta.$$

Insbesondere ist jeder Schätzer X_i erwartungstreu! Damit ist jede einzelne Beobachtung eine erwartungstreue Schätzung für ϑ. Wir beobachten aber nur 0 oder 1, also in der Regel nicht ϑ. Erwartungstreue garantiert nur, dass sich alle Schätzfehler zu Null aufsummieren, die Schätzung selbst kann weit vom wahren Wert entfernt liegen. Dieses einfache Beispiel zeigt, wie wichtig es ist, Qualitätskriterien über die Erwartungstreue hinaus zu entwickeln. Für das Beispiel der Bernoulli-Kette werden wir nun zeigen, dass der naive Schätzer der gleichmäßig beste unter allen erwartungstreuen Schätzern von p ist.

Wir betrachten im Folgenden eine endliche Menge $\mathcal{X}$ und Wahrscheinlichkeitsverteilungen $(P_\vartheta)_{\vartheta \in \Theta}$ auf $\mathcal{X}$. Dabei sei $\Theta \subseteq \mathbb{R}$ ein offenes Intervall. Weiter nehmen wir an, dass die Abbildung $\varrho(x, \cdot) : \Theta \to [0, \infty)$ differenzierbar und strikt positiv ist. $T : \mathcal{X} \to \Theta$ sei ein Schätzer für ϑ. Mit $\mathbb{B}_\vartheta(T) = \mathbb{E}_\vartheta(T) - \vartheta$ bezeichnen wir wieder den Bias. Dann gilt das folgende von Cramér und Calyampudi Radhakrishna Rao (geb. 1920) bewiesene Resultat:

16.4.2 Satz: (Cramér-Rao-Schranke) Unter den obigen Bedingungen gilt für die Varianz $\mathbb{V}_\vartheta(T)$ des Schätzers T die Ungleichung

$$\mathbb{V}_\vartheta(T) \geq \frac{\left(\frac{d\mathbb{B}_\vartheta(T)}{d\vartheta} + 1\right)^2}{I(\vartheta)}. \tag{16.2}$$

Hierbei ist $I(\vartheta)$ die *Fisher-Information* (benannt nach Sir Ronald Fisher (1890–1962)), definiert durch

$$I(\vartheta) := \mathbb{E}_\vartheta\left(\left(\frac{d\ln \varrho_X(\vartheta)}{d\vartheta}\right)^2\right).$$

Für einen erwartungstreuen Schätzer T gilt insbesondere

$$\mathbb{V}_\vartheta(T) \geq \frac{1}{I(\vartheta)}.$$

Von besonderem Interesse sind die erwartungstreuen Schätzer T, für deren Varianz $\mathbb{V}_\vartheta(T) = \frac{1}{I(\vartheta)}$ gilt. Diese haben dann also minimale Varianz unter allen möglichen erwartungstreuen Schätzern.

16.4.3 Beispiel: (Bernoulli-Kette) Das statistische Modell sei gewählt wie in Beispiel 16.2.5. Es bezeichne $X_n(\omega)$ die Anzahl der Erfolge zu $\omega \in \{0,1\}^n$. Mit $\varrho_x(\vartheta) = \binom{n}{x}\vartheta^x(1-\vartheta)^{n-x}$ folgt

$$\frac{d\ln \varrho_{X_n(\omega)}(\vartheta)}{d\vartheta} = \frac{X_n(\omega)}{\vartheta} - \frac{n - X_n(\omega)}{1-\vartheta} = \frac{X_n(\omega) - n\vartheta}{\vartheta(1-\vartheta)}.$$

Demnach ist die Fisher-Information gleich

$$I(\vartheta) = \frac{1}{\vartheta^2(1-\vartheta)^2}\,\mathbb{E}\left(\left(X_n - n\vartheta\right)^2\right) = \frac{1}{\vartheta^2(1-\vartheta)^2}\mathbb{V}(X_n) = \frac{n}{\vartheta(1-\vartheta)}.$$

Die Varianz von X_n/n ist $\frac{\vartheta(1-\vartheta)}{n}$. Also haben wir $\mathbb{V}(X_n/n) = \frac{1}{I(\vartheta)}$ gezeigt: Der naive Schätzer ist ein erwartungstreuer Schätzer mit minimaler Varianz.

Beweis von Satz 16.4.2: Wir differenzieren die Gleichung $\mathbb{B}_\vartheta(T) = \mathbb{E}_\vartheta(T) - \vartheta$ nach ϑ, was wegen den Annahmen des Satzes erlaubt ist:

$$\frac{d\mathbb{B}_\vartheta(T)}{d\vartheta} = \frac{d\mathbb{E}_\vartheta(T)}{d\vartheta} - 1 = \sum_{x\in\mathcal{X}} \frac{d\varrho_x(\vartheta)}{d\vartheta}T(x) - 1$$

$$
\begin{aligned}
&= \sum_{x\in\mathcal{X}} \frac{d\ln \varrho_x(\vartheta)}{d\vartheta}\, T(x)\, \varrho_x(\vartheta) - 1 \\
&= \mathbb{E}_\vartheta\left(\frac{d\ln \varrho_X(\vartheta)}{d\vartheta}\, T\right) - 1. \qquad (16.3)
\end{aligned}
$$

Nun gilt mit $1 = \sum_{x\in\mathcal{X}} \varrho_x(\vartheta)$

$$0 = \sum_{x\in\mathcal{X}} \frac{d\varrho_x(\vartheta)}{d\vartheta} = \mathbb{E}_\vartheta\left(\frac{d\ln \varrho_X(\vartheta)}{d\vartheta}\right),$$

also gilt auch

$$0 = \mathbb{E}_\vartheta\left(\frac{d\ln \varrho_X(\vartheta)}{d\vartheta}\mathbb{E}_\vartheta(T)\right).$$

Aus Gleichung (16.3) und der letzten Identität folgt insgesamt

$$\frac{d\mathbb{B}_\vartheta(T)}{d\vartheta} + 1 = \mathbb{E}_\vartheta\left(\frac{d\ln \varrho_X(\vartheta)}{d\vartheta}\big(T - \mathbb{E}_\vartheta(T)\big)\right).$$

Auf der rechten Seite wenden wir nun die Cauchy-Schwarz-Ungleichung (siehe Satz 4.2.7) an und erhalten

$$\frac{d\mathbb{B}_\vartheta(T)}{d\vartheta} + 1 \le \left(\mathbb{E}_\vartheta\left(\left(\frac{d\ln \varrho_X(\vartheta)}{d\vartheta}\right)^2\right)\mathbb{V}_\vartheta(T)\right)^{1/2} = \sqrt{I(\vartheta)\,\mathbb{V}_\vartheta(T)}.$$

Dies beweist die Behauptung. □

16.4.4 Aufgabe: Es sei $X = (X_1, \ldots, X_n)$ ein Vektor von unabhängigen Zufallsgrößen und $P_x(\vartheta)$ für $x = (x_1, \ldots, x_n)$ von der Form

$$P_x(\vartheta) = \varrho(x_1, \vartheta) \cdots \varrho(x_n, \vartheta).$$

Bestimmen Sie unter den Bedingungen an ϱ wie in Satz 16.4.2 die Fisher-Information

$$I_P(\vartheta) := \mathbb{E}_\vartheta\left(\left(\frac{d\ln P_X(\vartheta)}{d\vartheta}\right)^2\right).$$

16.4.5 Aufgabe: Bestimmen Sie die Fisher-Information in Beispiel 16.3.6. Was besagt dies für die Schätzer $(M_n)_n$?

Einige der bisher betrachteten Schätzer sind ebenfalls gleichmäßig beste Schätzer. Wir müssten dies jeweils nachrechnen. Es gibt einen allgemeinen Ansatz mittels der sogenannten exponentiellen Familien. In einem statistischen Modell $\mathcal{M}$, welches ein einparametriges Standardmodell sei, nennen wir $(P_\vartheta)_{\vartheta\in\Theta}$ eine *exponentielle Familie* bezüglich einer Statistik $T : \mathcal{X} \to \mathbb{R}$, wenn die Likelihoodfunktion die Gestalt

$$\varrho(x,\vartheta) = \exp\Big(a(\vartheta)T(x) - b(\vartheta)\Big)h(x)$$

hat. Hierbei müssen die Funktionen a, b und h gewisse Bedingungen erfüllen. So muss a stetig differenzierbar sein mit Ableitung $a' \neq 0$. Ist die Familie $(P_\vartheta)_{\vartheta\in\Theta}$ exponentiell bezüglich T, so ist T gleichmäßig bester Schätzer für $\mathbb{E}_\vartheta(T)$. Dies ist ein tieferliegendes Resultat, welches wir hier nicht beweisen werden. Viele Familien von Wahrscheinlichkeitsverteilungen sind exponentielle Familien bezüglich interessanter Schätzer.

Lösungen der Aufgaben

Lösungen der Aufgaben in 16.1

Aufgabe 16.1.7

Für das Schätzproblem des Bananenhändlers ist das Modell

$$\mathcal{M}_1 := \Big(\{0,\ldots,100\}, \mathcal{P}\left(\{0,\ldots,100\}\right), h(\cdot, 100, w, 40000-w) \\ : w \in \{0,\ldots,40000\}\Big)$$

möglich. Für die Situation in Beispiel 16.1.2 bietet sich das Modell

$$\mathcal{M}_2 := \Big(\mathbb{R}, \mathcal{B}, N(\vartheta, \sigma^2) : \vartheta \in \mathbb{R}\Big)$$

an, wobei σ^2 die bekannte Varianz ist.

Aufgabe 16.1.8

Es ist sinnvoll, die Impulse einer einzelnen Spinatprobe als Poisson-verteilt mit unbekanntem Parameter $\vartheta > 0$ anzunehmen. Für die einzelne Stichprobe bietet sich dann das folgende statistische Modell an:

$$\mathcal{M} := (\mathbb{N}_0, \mathcal{P}(\mathbb{N}_0), \pi_\vartheta : \vartheta \in (0,\infty))\,.$$

Da die Strahlenbelastung ϑ gerade der Erwartungswert der Verteilung π_ϑ ist, legt das Gesetz der großen Zahlen nahe, den Parameter ϑ durch den Schätzer $T : \mathbb{N}_0^n \to \mathbb{R}$ mit

$$T(X_1,\ldots,X_n) := \frac{1}{n}\sum_{k=1}^{n} X_k$$

zu schätzen. Hierbei seien $X_1,\ldots,X_n$ unabhängige, π_ϑ-verteilte Zufallsgrößen. Da T Werte in $\mathbb{Q}$ annimmt, sehen wir sofort ein, dass wir mit T niemals den exakten Wert von ϑ schätzen, sofern dieser irrational ist.

Lösungen der Aufgaben in 16.2

Aufgabe 16.2.4

Dies ist natürlich im Wesentlichen das gleiche Schätzproblem wie das des Bananenhändlers. Lediglich die Zahlen sind verschieden. Hier ist nämlich $N = 100000$ und $n = 1000$. Ferner ist unsere Stichprobe $x = 30$. Für die Schätzung durch den ML-Schätzer T ergibt sich somit aus der im Text hergeleiteten Formel: $T(x) = T(30) = \left\lfloor \frac{100001}{1000} 30 \right\rfloor = \lfloor 3000.03 \rfloor = 3000$.

Aufgabe 16.2.6

Es sei $\vartheta \in (0,1)$ die unbekannte Erfolgswahrscheinlichkeit. Gemäß der negativ-binomialen Verteilung erhalten wir die Likelihoodfunktion $\varrho_x(\vartheta) := \binom{r+x-1}{x} \vartheta^r (1-\vartheta)^x$. Daraus folgt:

$$\begin{aligned} \frac{d}{d\vartheta} \ln \varrho_x(\vartheta) &= \frac{d}{d\vartheta} \left[\ln \binom{r+x-1}{x} + r \cdot \ln(\vartheta) + x \cdot \ln(1-\vartheta) \right] \\ &= \frac{r}{\vartheta} - \frac{x}{1-\vartheta} \stackrel{!}{=} 0. \end{aligned}$$

Für eine Extremstelle muss also $r(1-\vartheta) = x\vartheta$ gelten. Dies ist äquivalent zu $\vartheta(x+r) = r$ und somit ist

$$\vartheta = \frac{r}{x+r}.$$

Wegen $\frac{d^2}{d\vartheta^2} \ln \varrho_x(\vartheta) = -\frac{r}{\vartheta^2} - \frac{x}{(1-\vartheta)^2} < 0$ folgt, dass durch $T(x) := \frac{r}{x+r}$ der Maximum-Likelihood-Schätzer gegeben ist. Dieser ist einfach die relative Anzahl der Erfolge in den ersten $x+r$ Experimenten und daher auch intuitiv plausibel.

Lösungen der Aufgaben in 16.3

Aufgabe 16.3.4

Der in Aufgabe 16.1.8 bestimmte Schätzer ist natürlich erwartungstreu, denn mit

$$T(X_1, \ldots, X_n) := \frac{1}{n} \sum_{k=1}^{n} X_k$$

ist $\mathbb{E}(T(X_1, \ldots, X_n)) = \mathbb{E}(X_1)$. Da X_1 Poisson-verteilt ist zum Parameter ϑ, ist $\mathbb{E}(X_1) = \vartheta$, also wird der Parameter ϑ mittels T erwartungstreu geschätzt.

Aufgabe 16.3.8

Wir wählen als Schätzer, basierend auf den ersten n Beobachtungen,

$$T_n(X_1, \ldots, X_n) := \max\Big(X_1, \ldots, X_n\Big).$$

Die Konsistenz dieser Folge von Schätzern sieht man so: Zu vorgegebenem $\varepsilon > 0$ ist unter Verwendung der Unabhängigkeit

$$\begin{aligned} P_{m,p}\Big(\max(X_1, \ldots, X_n) \le m - \varepsilon\Big) &= P_{m,p}\Big(X_1 \le m - \varepsilon, \ldots, X_n \le m - \varepsilon\Big) \\ &= \Big(P_{m,p}\Big(X_1 \le m - \varepsilon\Big)\Big)^n. \end{aligned}$$

Hierbei bezeichne $P_{m,p}$ die Binomialverteilung zu den Parametern m und p. Nun ist

$$\sum_{k \le m-\varepsilon} b(k; m, p) = 1 - p^m < 1.$$

Daraus folgt die Konsistenz.

Aufgabe 16.3.9

Zunächst bestimmen wir den Erwartungswert des Schätzers Y_n:

$$\begin{aligned} \mathbb{E}_\vartheta\,(Y_n) &= \mathbb{E}_\vartheta\left(\frac{1}{n+2}\left(1 + \sum_{i=1}^n X_i\right)\right) \\ &= \frac{1}{n+2} + \frac{1}{n+2}\mathbb{E}_\vartheta\left(\sum_{i=1}^n X_i\right) \\ &= \frac{1}{n+2} + \frac{1}{n+2} \cdot n\,\vartheta. \end{aligned}$$

Für $n \to \infty$ konvergiert der erste Summand gegen Null und der zweite gegen ϑ. Damit ist der Schätzer asymptotisch erwartungstreu. Für zwei Folgen von Zufallsgrößen $(X_n)_n$ und $(Z_n)_n$ machen wir die folgende Beobachtung: Gilt für jedes $\varepsilon > 0$

$$\lim_{n\to\infty} P\Big(|X_n| \ge \varepsilon\Big) = 0 \quad \text{und} \quad \lim_{n\to\infty} P\Big(|Z_n| \ge \varepsilon\Big) = 0,$$

so gilt auch

$$\lim_{n\to\infty} P\Big(|X_n + Z_n| \ge \varepsilon\Big) = 0,$$

da

$$P\Big(|X_n + Z_n| \ge \varepsilon\Big) \le P\Big(|X_n| \ge \varepsilon/2\Big) + P\Big(|Z_n| \ge \varepsilon/2\Big).$$

Nun schreiben wir

$$Y_n - \vartheta = \frac{1}{n+2} + \frac{1}{n+2}\sum_{i=1}^{n+2} X_i - \frac{X_{n+1} + X_{n+2}}{n+2} - \vartheta.$$

Nach dem schwachen Gesetz der großen Zahlen wissen wir, dass für jedes $\varepsilon > 0$

$$\lim_{n\to\infty} P\left(\left|\frac{1}{n+2}\sum_{i=1}^{n+2} X_i - \vartheta\right| \geq \varepsilon\right) = 0$$

gilt. Weiter folgt unter Anwendung der Ungleichung von Tschebyschev

$$\lim_{n\to\infty} P\left(\left|\frac{X_{n+1}+X_{n+2}}{n+2}\right| \geq \varepsilon\right) = 0$$

und es gilt

$$\lim_{n\to\infty} P\left(\left|\frac{1}{n+2}\right| \geq \varepsilon\right) = 0.$$

Damit ist die Konsistenz der Folge $(Y_n)_n$ für ϑ gezeigt.

Lösungen der Aufgaben in 16.4

Aufgabe 16.4.4

Wir nutzen die Unabhängigkeit der Zufallsgrößen $(X_1, \ldots, X_n)$ und erhalten

$$\begin{aligned} I_P(\vartheta) &= \mathbb{E}_\vartheta\left(\left(\frac{d\ln\Big(\varrho(X_1,\vartheta)\cdots\varrho(X_n,\vartheta)\Big)}{d\vartheta}\right)^2\right) \\ &= \mathbb{E}_\vartheta\left(\left(\sum_{i=1}^n \frac{d\ln\varrho(X_i,\vartheta)}{d\vartheta}\right)^2\right) \\ &= \sum_{i=1}^n \mathbb{E}_\vartheta\left(\left(\frac{d\ln\varrho(X_i,\vartheta)}{d\vartheta}\right)^2\right). \end{aligned}$$

Somit ist $I_P(\vartheta) = n\, I(\vartheta)$.

Aufgabe 16.4.5

Mit $\varrho(x,\vartheta) = \frac{\vartheta^x}{x!}e^{-\vartheta}$ folgt

$$\begin{aligned} I(\vartheta) &= \sum_{x=0}^\infty \frac{\varrho_x'(\vartheta)^2}{\varrho_x(\vartheta)} \\ &= \sum_{x=0}^\infty \frac{1}{x!}e^\vartheta\vartheta^{-x}\left(-e^{-\vartheta}\vartheta^x + e^{-\vartheta}x\vartheta^{x-1}\right)^2 \\ &= \sum_{x=0}^\infty \frac{\vartheta^x}{x!}e^{-\vartheta}\left(\frac{x}{\vartheta}-1\right)^2 = \frac{1}{\vartheta^2}\mathbb{V}(X) = \frac{1}{\vartheta}, \end{aligned}$$

wenn X eine POISSON-verteilte Zufallsgröße zum Parameter ϑ bezeichnet. Da die Varianz des Schätzers $M_n(X)$ aus Beispiel 16.3.6 gleich ϑ ist, haben wir somit $\mathbb{V}(M_n) = \frac{1}{I(\vartheta)}$ gezeigt. Somit ist M_n ein gleichmäßig bester Schätzer für ϑ. Mit dieser Aussage müssen wir aber etwas vorsichtig sein, denn eigentlich haben wir Satz 16.4.2 nur für Wahrscheinlichkeitsverteilungen auf einer endlichen Menge $\mathcal{X}$ bewiesen. Wir teilen an dieser Stelle nur mit, dass der Satz unter gewissen Summierbarkeitsannahmen auch allgemeiner gilt. Insbesondere ist M_n gleichmäßig bester Schätzer für ϑ.

Kapitel 17

Testtheorie

Wir motivieren die Fragestellungen der Testtheorie durch ein einfaches Problem: Ein neues Medikament soll mit einem bisher verwendeten Medikament verglichen werden. Man möchte natürlich wissen, welches besser wirkt. Bei 10 von 20 Testpersonen habe das neue Medikament eine bessere Heilung bewirkt. Wie können wir nun erfassen, ob dieses Testergebnis reiner Zufall ist oder nicht? Der Schluss, das neue Medikament aufgrund einer Testreihe auf den Markt zu bringen (oder auch nicht), kann ein fataler Fehler sein. Man kann sich stark geirrt haben. Nun kann die statistische Testtheorie Irrtümer nicht vermeiden. Sie soll uns aber Kriterien liefern, nach denen sich die sogenannten Irrtumswahrscheinlichkeiten kontrollieren lassen.

17.1 Entscheidungsprobleme

Wir erinnern an das einführende Beispiel des Bananenhändlers aus Kapitel 16.1. Dort muss laut einer Vereinbarung der Preis für die Bananenlieferung aus Kuba nur gezahlt werden, wenn höchstens 5% der Bananen faul sind. Die Lieferung umfasse $N = 10000$. Der Händler ermittelt aus einer Stichprobe von $n = 50$ Bananen die Anzahl der faulen Bananen. Sein Ziel ist nun, eine Grenze c für die Anzahl der faulen Bananen zu finden, die er bereit ist zu akzeptieren, bei der er also den Preis für die Lieferung bezahlt.

$$\begin{aligned} \text{höchstens } c \text{ Bananen faul} \quad &\Rightarrow \quad \text{Lieferung akzeptieren} \\ \text{mehr als } c \text{ Bananen faul} \quad &\Rightarrow \quad \text{Preisnachlass fordern.} \end{aligned}$$

Wir entwickeln nun entlang dieses Beispiels ein *statistisches Entscheidungsverfahren*, welches man einen *statistischen Test* nennt. Wir gehen in *fünf* Schritten vor.

1. (*statistisches Modell*): Wie bereits in der Theorie der Schätzer stellen wir zu Beginn das zugrundeliegende statistische Modell auf. In unserem Beispiel ist

$$\mathcal{X} = \{0, \ldots, 50\}; \quad \Theta = \{0, \ldots, 10000\}; \quad P_\vartheta = h(\cdot; n, \vartheta, N - \vartheta),\ \vartheta \in \Theta.$$

2. (*Nullhypothese und Alternative*): Nun zerlegen wir die Parametermenge Θ in zwei (disjunkte) Teilmengen $\Theta = \Theta_0 \cup \Theta_1$:

$$\begin{aligned} H_0 : \vartheta \in \Theta_0 \quad &\Leftrightarrow \quad \vartheta \text{ ist akzeptabel } (\textit{Nullhypothese}) \\ H_1 : \vartheta \in \Theta_1 \quad &\Leftrightarrow \quad \vartheta \text{ ist problematisch } (\textit{Alternative}) \end{aligned}$$

   Man sagt: „$H_0 : \vartheta \in \Theta_0$ wird gegen $H_1 : \vartheta \in \Theta_1$ getestet.“ Im Beispiel des Bananenhändlers wählen wir die folgende Nullhypothese und Alternative: $\vartheta \in \Theta_0 = \{0, \ldots, 500\}$ bedeute, dass die Qualität stimmt, das ϑ ist akzeptabel. $\vartheta \in \Theta_1 = \{501, \ldots, 10000\}$ bedeute, die Qualität ist zu schlecht, das ϑ gilt als problematisch.

3. (*Wahl des Irrtumsniveaus*): Wir wählen ein $0 < \alpha < 1$ und fordern, dass die Wahrscheinlichkeit für die Entscheidung für die Alternative, obwohl die Nullhypothese vorliegt, höchstens α betragen soll. Man spricht hierbei von einem *Fehler erster Art*.

4. (*Wahl einer Entscheidungsregel*): Nun wählen wir eine Statistik $\varphi : \mathcal{X} \to [0, 1]$ wie folgt. Die Entscheidung für die Alternative fällt mit Wahrscheinlichkeit $\varphi(x)$, wenn x der Beobachtungswert ist.

$$\begin{aligned} \varphi(x) = 0 \quad &\Leftrightarrow \quad \text{Festhalten an der Hypothese} \\ \varphi(x) = 1 \quad &\Leftrightarrow \quad \text{Verwerfen der Hypothese; Annahme der Alternative} \\ \varphi(x) \in (0, 1) \quad &\Leftrightarrow \quad \text{Keine Klarheit: Durchführung eines Zufallsexperimentes,} \\ &\qquad\quad \text{mit Wahrscheinlichkeit } \varphi(x) \text{ wählt man die Alternative.} \end{aligned}$$

   Wie wählen wir φ in unserem Beispiel? Wir setzen $\varphi(x) = 1_{\{x>c\}}$ oder

$$\varphi(x) = \begin{cases} 1\,, & \text{falls } x > c, \\ \frac{1}{2}\,, & \text{falls } x = c, \\ 0\,, & \text{falls } x < c. \end{cases}$$

   Hierbei ist nun die Wahl von c durch Schritt (3), die Wahl des Irrtumsniveaus, bestimmt: Wir wählen c als die kleinste Zahl, für welche die Forderung im Schritt (3) noch eingehalten wird.

5. (*Durchführung des Experimentes*): Es ist ungemein wichtig, erst jetzt, im 5. und letzten Schritt, das Experiment durchzuführen. Warum? Hier begegnen wir dem alltäglichen Hauptproblem des Umgangs mit mathematischer Statistik. Man sollte Täuschungen und auch Selbsttäuschungen vermeiden, die dadurch entstehen, dass man — zum Beispiel — erst auf der Basis der vorliegenden Daten die Nullhypothese und die Alternative wählt, und sie damit (eventuell ungewollt) „anpasst". Man neigt auch dazu, das Niveau α sowie die Entscheidungsregel den Daten entsprechend „geeignet zu wählen" und „störende Ausreißer" zu eliminieren. In diesem Punkt steckt das Grundproblem der mathematischen Statistik.

Das hiermit vollständig beschriebene Verfahren einer statistischen Entscheidungsfindung ist beinahe symmetrisch in Nullhypothese und Alternative. Nur das Ziel, dass wir die Irrtumswahrscheinlichkeit α eng begrenzen wollen, ist nicht symmetrisch. Wir wollen den Irrtum, die Alternative zu wählen, obwohl die Hypothese vorliegt, klein halten, und nicht anders herum. Das liegt an der inhaltlichen Wahl der Nullhypothese als den „normalen Fall", während die Alternative eine systematische signifikante Abweichung vom Normalfall sei. Wir fassen das obige Verfahren mathematisch enger in die folgende wichtige Definition:

17.1.1 Definition: Es sei $(\mathcal{X}, \mathcal{F}, P_\vartheta : \vartheta \in \Theta)$ ein statistisches Modell und $\Theta = \Theta_0 \cup \Theta_1$ eine (disjunkte) Zerlegung in die *Nullhypothese* und die *Alternative*.

(i) Jede Statistik $\varphi : \mathcal{X} \to [0,1]$, die wir im Folgenden immer als eine Entscheidungsregel interpretieren, heißt ein *Test* von Θ_0 gegen Θ_1. Ein Test heißt *nicht randomisiert*, falls $\varphi(x) \in \{0,1\}\ \forall x \in \mathcal{X}$, andernfalls heißt er *randomisiert*. Im ersten Fall nennen wir die Menge $\{x \in \mathcal{X} : \varphi(x) = 1\}$ den *Ablehnungsbereich* oder *Verwerfungsbereich* des Tests φ.

(ii) Der Wert $\sup_{\vartheta\in\Theta_0} \mathbb{E}_\vartheta(\varphi)$ (die maximale Wahrscheinlichkeit für einen Fehler 1. Art) heißt der *Umfang* oder das *effektive Niveau* von φ. Man nennt φ einen Test zum (Irrtums-)*Niveau* α, wenn $\sup_{\vartheta\in\Theta_0} \mathbb{E}_\vartheta(\varphi) \le \alpha$ gilt.

(iii) Die Funktion $G_\varphi : \Theta \to [0,1]$, $G_\varphi(\vartheta) := \mathbb{E}_\vartheta(\varphi)$, heißt *Gütefunktion* des Tests φ. Für $\vartheta \in \Theta_1$ heißt $G_\varphi(\vartheta)$ die *Macht* oder *Stärke* von φ bei ϑ. Dies ist die Wahrscheinlichkeit, mit der die Alternative erkannt wird, wenn sie vorliegt. Weiter ist $\beta_\varphi(\vartheta) := 1 - G_\varphi(\vartheta)$ die Wahrscheinlichkeit für einen *Fehler 2. Art*. Der Fehler 2. Art bedeutet, dass das Vorliegen der Alternative nicht erkannt wird und die Nullhypothese fälschlich angenommen wird.

Diese sehr umfangreiche Definition sollte im Laufe dieses Kapitels immer wieder verinnerlicht werden. Sie umfasst das wesentliche Sprachwerkzeug der mathemati-

schen Testtheorie und wird von vielen Anwendern verwendet, aber nicht unbedingt verstanden.

Aus der Beschreibung unseres statistischen Entscheidungsverfahrens sowie der Definition 17.1.1 folgt zusammenfassend, dass man zwei zentrale Forderungen an einen mathematischen Test φ stellt:

1. $G_\varphi(\vartheta) \leq \alpha$ für alle $\vartheta \in \Theta_0$: Die Irrtumswahrscheinlichkeit 1. Art soll unter α liegen. Das Niveau des Tests φ soll also den Wert α nicht überbieten.
2. $G_\varphi(\vartheta)$ soll möglichst groß sein für $\vartheta \in \Theta_1$: Die Macht des Tests soll möglichst groß sein, ein Fehler 2. Art möglichst wenig wahrscheinlich.

17.1.2 Definition: Ein Test φ von Θ_0 gegen Θ_1 heißt (gleichmäßig) *bester Test* zum Niveau α, wenn er vom Niveau α ist und für jeden anderen Test ψ zum Niveau α gilt:

$$G_\varphi(\vartheta) \geq G_\psi(\vartheta); \quad \vartheta \in \Theta_1.$$

In der englischen Literatur spricht man von einem *UMP-Test*. Diese Abkürzung steht für *uniformly most powerful*.

Wir sollten also das ehrgeizige Ziel verfolgen, beste Tests im Sinne dieser Definition zu finden. Ein zentrales Problem bei der Formulierung von Tests ist es aber, dass es nicht einfach oder nicht immer möglich ist, das Niveau und die Macht eines Tests geeignet auszubalancieren. Häufig ist es wahr, dass je kleiner das Niveau ist, desto kleiner im Allgemeinen die Macht ist. Die Umsetzung des ehrgeizigen Ziels wird alles andere als klar oder gar einfach sein. Im Übrigen gibt es mathematisch gesehen immer einen Ausweg aus diesem Dilemma: Man erhebe bessere Daten und vor allem mehr Daten. Aber genau dies ist natürlich nicht einfach möglich, man denke nur an Untersuchungen in der Medizin.

17.1.3 Beispiel: Wir führen 20 unabhängige Bernoulli-Experimente mit unbekanntem Erfolgsparameter ϑ durch. Also ist $\Theta = [0,1]$. Unsere Annahme ist, dass die Anzahl X der Erfolge $b(\cdot;20,\vartheta)$-verteilt ist. Somit ist $\mathcal{X} = \{0,\ldots,20\}$ und $P_\vartheta = b(\cdot;20,\vartheta)$. Sei die Hypothese $\Theta_0 = [0,1/2]$. Die Hypothese ist, dass ein neues Medikament zu einer Häufigkeit der Krankheit führt, die kleiner oder gleich $1/2$ ist; dies möge einer Verbesserung gegenüber dem herkömmlichen Medikament entsprechen. Wir suchen den Verwerfungsbereich $R = \{c, c+1, \ldots, n = 20\}$ zum Test $\varphi = 1_{\{c,\ldots,20\}}$ in Abhängigkeit vom Niveau α. Es gilt

$$\mathbb{E}_\vartheta(\varphi) = \sum_{k=c}^{20} \binom{20}{k} \vartheta^k (1-\vartheta)^{20-k}.$$

Nun ist dies in ϑ monoton wachsend, das Supremum über alle $\vartheta \in \Theta_0$ liegt also bei $\vartheta = 1/2$. Wir können nun c als Funktion von α einfach als Lösung der folgenden Ungleichung bestimmen:

$$2^{-20} \sum_{k=c}^{20} \binom{20}{k} \leq \alpha < 2^{-20} \sum_{k=c-1}^{20} \binom{20}{k}.$$

Insbesondere ist beispielsweise für $\alpha \in [0.021, 0.058]$ $c = 15$. Wir können noch die Macht des Tests φ diskutieren. Es gilt:

ϑ	0.6	0.7	0.8	0.9
$\mathbb{E}_\vartheta(\varphi)$	0.126	0.416	0.804	0.989

Dies bedeutet zum Beispiel für den Wert $\vartheta = 0.7$, dass die Wahrscheinlichkeit einer Annahme der Nullhypothese, obwohl sie falsch ist, bei 0.6 liegt. Eine Vergrößerung der Macht, ohne dabei das Niveau des Tests zu vergrößern, ist hier allein durch eine größer gewählte Stichprobe möglich.

17.1.4 Beispiel: (Außersinnliche Wahrnehmungen) Ein in der Literatur viel diskutiertes Beispiel ist das folgende. Ein *Medium* behauptet, mit seinen außersinnlichen Fähigkeiten verdeckte Spielkarten identifizieren zu können. Man legt ihm 20 Mal die Herz-Dame und den Herz-König in zufälliger Anordnung verdeckt vor und lässt es jeweils die Herz-Dame aufdecken. Man zählt die richtig identifizierten Karten. Wir gehen nach obigem Verfahren vor und sehen die Parallelität zu Beispiel 17.1.3. Wieder ist $\mathcal{X} = \{0, \ldots, 20\}$ und $P_\vartheta = b(\cdot, 20, \vartheta)$. Nun ist $\Theta = [\frac{1}{2}, 1]$ und $\Theta_0 = \{\frac{1}{2}\}$ sowie $\Theta_1 =]\frac{1}{2}, 1]$. Der hier mögliche Irrtum ist, der Person mediale Fähigkeiten zu bescheinigen, obwohl bloßes Raten vorliegt. Nun wählen wir $\alpha = 0.05$ und setzen erneut den Test $\varphi = 1_{\{c,\ldots,n\}}$ für ein geeignetes $c \in \mathcal{X}$. Wir werden später beweisen, dass φ für sein effektives Niveau ein bester Test ist. Mit $n = 20$ wählen wir erneut $c = 15$, denn für $\varphi = 1_{\{15,\ldots,20\}}$ ist

$$G_\varphi(1/2) = \sum_{k=15}^{20} b(k; 20, 1/2) \approx 0.02069$$

und für $\psi = 1_{\{14,\ldots,20\}}$ ist

$$G_\psi(1/2) = \sum_{k=14}^{20} b(k; 20, 1/2) \approx 0.0577 > \alpha.$$

Wird das Experiment durchgeführt und beobachtet man 14 Treffer, so folgt $\varphi(x) = 0$, und somit werden die medialen Fähigkeiten nicht bestätigt. Nun wollen wir dieses Resultat etwas kommentieren. Der Tester ist mit seiner Testwahl in gewisser

Weise unzufrieden. Im Zusammenhang mit der behaupteten außersinnlichen Wahrnehmungsfähigkeit sind 14 Treffer nicht schlecht. Der Test ψ hat nur eine geringfügig schlechtere Irrtumswahrscheinlichkeit. Bei einer Irrtumswahrscheinlichkeit von 0.0577 werden bei 14 Treffern mediale Fähigkeiten bestätigt. Diese Veränderung des Testes im Nachhinein ist aber so etwas wie der übliche Betrug des Testers. Ist bei Vorgabe eines Irrtumsniveaus die Schranke $c = 14$ vor dem Experiment festgelegt worden, spricht nichts gegen diese Wahl. Aber im Nachhinein festzustellen, dass die eigentliche Schranke $c = 15$ einem nicht passt, bedeutet, dass der Tester nicht $\psi = 1_{\{14,\ldots 20\}}$, sondern den Test

$$\tilde{\psi}(x) = 1_{\{x,\ldots,20\}}(x)$$

gewählt hat. Dieser Test ist konstant gleich 1 und bedeutet, dass man sich mit Sicherheit für die Alternative entscheidet. Weiter ist dann das Niveau $G_\psi(\frac{1}{2}) = 1$ und die Macht $G_\psi(\vartheta) = 1$ für jedes $\vartheta \in \Theta_1$. Die geringe Macht des Tests φ (siehe Tabelle in Beispiel 17.1.3) spricht nicht unbedingt für φ. Aber diese Beobachtung kann man bereits vor der Ausführung des Experiments machen und somit die Wahl des statistischen Entscheidungsverfahrens anpassen. In unserem Beispiel und in Beispiel 17.1.3 muss man die Anzahl der Versuche erhöhen. Bei festgehaltenem Niveau α und entsprechender neuer Wahl von c erhöht dies die Macht des Tests.

17.1.5 Aufgabe: Erstellen Sie eine zu Beispiel 17.1.3 analoge Tabelle für die Macht des Tests ψ in Beispiel 17.1.4. Diskutieren Sie den Test in Beispiel 17.1.4 für $n = 40$ Experimente.

Im Beispiel 17.1.4 stellt sich die prinzipielle Frage, warum ein Test die Form $\varphi = 1_{\{c,\ldots,n\}}$ haben muss. Ist nicht auch die alternative Form $\psi = 1_{\{c,\ldots,d\}}$ mit $d < n$ sinnvoll? ψ hat ein kleineres Niveau als φ. Ist aber das Medium in guter Form und erzielt mehr als d Treffer, muss die Hypothese der medialen Fähigkeiten bei ψ abgelehnt werden. Die Macht von ψ steigt bei mäßiger Begabung an, fällt aber bei starker Begabung. Insbesondere gilt

$$G_\psi(1) = 0 < \underbrace{G_\psi(1/2)}_{\text{bloßes Raten!}} .$$

Dies wäre absurd. Man akzeptiert dann nämlich die außersinnliche Wahrnehmungsfähigkeit bei einer starken Begabung mit geringerer Wahrscheinlichkeit als im Fall des Ratens. Ein Test sollte eine solch absurde Eigenschaft nicht haben. Dies führt zu der folgenden Definition. Auch wenn wir bestrebt sind, beste Tests zu finden, zeigt die Theorie, dass dabei manchmal der folgende Begriff eine Rolle spielt.

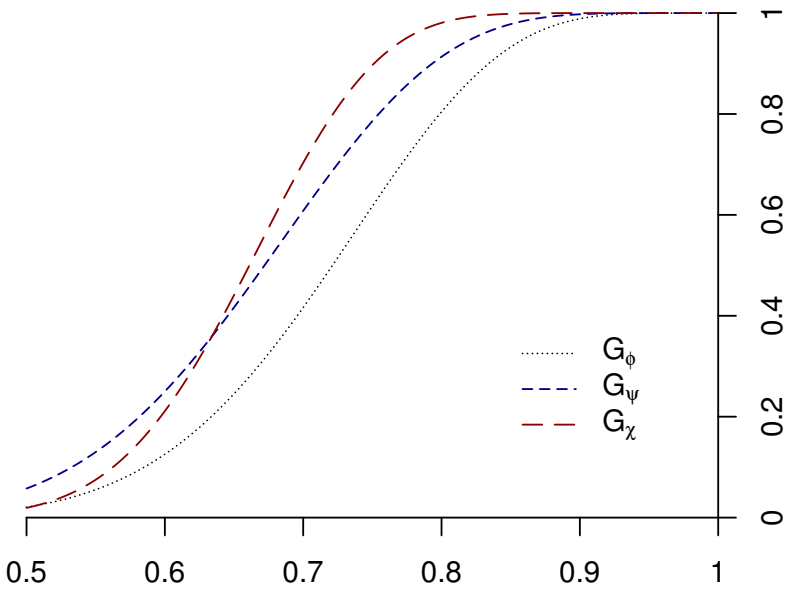

Abb. 17.1: Gütefunktionen der Tests mit Ablehnungsbereich $\{15, \ldots, 20\}$ (schwarz) bzw. $\{14, \ldots, 20\}$ (rot) für $n = 20$, sowie $\{27, \ldots, 40\}$ (blau) für $n = 40$

17.1.6 Definition: Ein Test φ heißt *unverfälscht* zum Niveau α, wenn

$$G_\varphi(\vartheta_0) \leq \alpha \leq G_\varphi(\vartheta_1)$$

für alle $\vartheta_0 \in \Theta_0$ und alle $\vartheta_1 \in \Theta_1$ gilt. Man entscheidet sich mit größerer Wahrscheinlichkeit für die Alternative, wenn sie richtig ist, als wenn sie falsch ist.

Bevor wir beste Test konstruieren, noch ein paar Beispiele. Bisher haben wir in den Beispielen immer explizit Wahrscheinlichkeiten unter der Binomialverteilung verwendet. Im folgenden Beispiel verwenden wir die Normal-Approximation, da n groß ist.

17.1.7 Beispiel: Wir werfen 1000 Mal die Münze und betrachten $\mathcal{X} = \{0, \ldots, 1000\}$, $\Theta = [0, 1]$ und $P_\vartheta = b(\cdot, 1000, \vartheta)$. Sei nun

$$\Theta_0 = \{1/2\} \quad \text{und} \quad \Theta_1 = [0, 1] \setminus \{1/2\}.$$

Wir fragen also, ob die Münze eine faire Münze ist. Es sei $\alpha = 0.05$. Kann man die Nullhypothese bestätigen, wenn man 550 Einsen beobachtet? Dazu bestimmen

wir c, sodass

$$P_{1/2}\big(|X-500|\geq c\big)\leq 0.05,$$

wobei X die Anzahl der Einsen bezeichne. c soll erneut möglichst klein gewählt werden. Nach dem Satz von DE MOIVRE-LAPLACE ist nun

$$P_{1/2}\big(|X-500|\geq c\big)\approx 1-\int_{-c/\sqrt{250}}^{c/\sqrt{250}}\frac{1}{\sqrt{2\pi}}\exp\Big(-\frac{x^2}{2}\Big)\,dx=2\,\Phi\Big(-\frac{c}{\sqrt{250}}\Big).$$

17.1.8 Aufgabe: Ermitteln Sie in Beispiel 17.1.7 mittels der angegebenen Approximation c. Wird die Nullhypothese angenommen? Betrachten Sie die das gleiche Testproblem zum Niveau $\alpha=0.001$.

17.1.9 Beispiel: Der Anteil der Raucher in einer Bevölkerung soll geschätzt werden. Man möchte dies auf 3% genau mit einer 95%igen Sicherheit tun. Die Befragung geschehe nach dem Modell *mit* Zurücklegen. Wieviele Personen müssen befragt werden? Nach Annahme ist die Anzahl der Raucher X binomialverteilt zu den Parametern ϑ und n, wenn n Personen befragt werden. Wir wollen

$$P_\vartheta\left(\left|\frac{X}{n}-\vartheta\right|\leq 0.03\right)\geq 0.95 \tag{17.1}$$

erreichen. Wir kennen ϑ und n nicht. Daher behelfen wir uns erneut durch Anwendung des Grenzwertsatzes von DE MOIVRE-LAPLACE:

$$P_\vartheta\left(\left|\frac{X-n\vartheta}{\sqrt{n\vartheta(1-\vartheta)}}\right|\leq a\right)\approx 2\Phi(a)-1$$

für jedes $a>0$. Die Gleichung $2\Phi(a)-1=0.95$ liefert $a\approx 1.96$, siehe Tabelle 15.1. Somit hat das folgende Ereignis eine Wahrscheinlichkeit nahe bei 0.95:

$$\left\{\left|\frac{X-n\vartheta}{\sqrt{n\vartheta(1-\vartheta)}}\right|\leq 1.96\right\}=\left\{\left|\frac{X}{n}-\vartheta\right|\leq 1.96\sqrt{\frac{\vartheta(1-\vartheta)}{n}}\right\}.$$

Ist nun

$$1.96\sqrt{\frac{\vartheta(1-\vartheta)}{n}}\leq 0.03,$$

so ist (17.1) erfüllt. Dies ist äquivalent zu

$$n\geq\left(\frac{196}{3}\right)^2\vartheta(1-\vartheta).$$

Nun kennen wir ϑ nicht und scheinen uns daher im Kreis zu drehen. Es gilt aber

$$\vartheta(1-\vartheta) \leq \frac{1}{4}$$

für $\vartheta \in [0,1]$. Um der Ungleichung (17.1) zu genügen, verlangen wir, dass

$$n \geq \left(\frac{196}{3}\right)^2 \max_{\vartheta \in [0,1]} \vartheta(1-\vartheta) = \left(\frac{196}{3}\right)^2 \cdot \frac{1}{4} = \frac{9604}{9} \approx 1067{,}111.$$

Damit genügen $n \geq 1068$ Personen, um den Anteil der Raucher in der Bevölkerung mit 95%iger Sicherheit auf 3% genau zu schätzen. Wir haben dabei aber die Normal-Approximation verwendet, sodass das Resultat eine Ungenauigkeit mit sich trägt.

17.1.10 Aufgabe: Ist im obigen Beispiel die geforderte Sicherheit 98% und möchte man mit einer Genauigkeit von 1% schätzen, so muss man bereits $n = 13573$ Personen befragen. Vollziehen Sie die entsprechende Approximation nach. Um wieviel Prozent kann die Stichprobe kleiner gewählt werden, wenn wir das Vorwissen haben, dass $\vartheta \leq 0.3$ ist?

17.2 Alternativtests und beste einseitige Tests

Wir betrachten in diesem Kapitel zunächst die Situation, bei der man nur zwischen zwei Wahrscheinlichkeitsmaßen zu entscheiden hat. Es sei also $\Theta = \{0,1\}$, das heißt das $(\mathcal{X}, \mathcal{F}, P_0, P_1)$ das zugrundeliegende statistische Modell ist. Nun ist $\Theta_0 = \{0\}$ und $\Theta_1 = \{1\}$. Einelementige Nullhypothesen und Alternativen nennt man *einfach*. Das Modell sei ein Standardmodell: P_0 und P_1 haben also die Likelihood-Funktionen ϱ_0 und ϱ_1 (Zähldichten oder Dichtefunktionen). Ohne Beschränkung der Allgemeinheit sei $\varrho_0(x)+\varrho_1(x) > 0$ für alle $x \in \mathcal{X}$. Wir suchen einen besten Test φ von P_0 gegen P_1 zum Niveau α. Nach dem Maximum-Likelihood-Prinzip wird man sich für die Alternative entscheiden, wenn für x $\varrho_1(x)$ hinreichend deutlich über $\varrho_0(x)$ liegt. Daher betrachten wir den *Likelihood-Quotient*

$$R(x) := \begin{cases} \frac{\varrho_1(x)}{\varrho_0(x)}, & \text{falls } \varrho_0(x) > 0, \\ \infty, & \text{falls } \varrho_0(x) = 0 < \varrho_1(x) \end{cases}$$

und einen Test der Gestalt

$$\varphi(x) := \begin{cases} 1, & \text{falls } R(x) > c, \\ 0, & \text{falls } R(x) < c. \end{cases}$$

Jedes φ dieser Bauart heißt *Neyman-Pearson-Test* zum Schwellenwert c, benannt nach Jerzy Neyman (1894–1981) und Egon Pearson (1895–1980). Es gilt der folgende wichtige Satz:

17.2.1 Satz: (Neyman-Pearson-Lemma; 1932) Es sei $(\mathcal{X}, \mathcal{F}, P_0, P_1)$ ein Standardmodell mit einfacher Hypothese und Alternative und $0 < \alpha < 1$ ein vorgegebenes Niveau.

(i) Es existiert ein Neyman-Pearson-Test φ mit $\mathbb{E}_0(\varphi) = \alpha$.

(ii) Jeder Neyman-Pearson-Test φ mit $\mathbb{E}_0(\varphi) = \alpha$ ist ein bester Test zum Niveau α, und jeder beste Test ψ zum Niveau α ist ununterscheidbar von einem Neyman-Pearson-Test.

Beweis: Zunächst beweisen wir Teil (i): Es sei $c > 0$ so gewählt, dass $P_0(R \geq c) \geq \alpha$ und $P_0(R > c) \leq \alpha$ gilt. Man nennt c ein α-*Fraktil* der Verteilung von R unter P_0, wenn $P_0(R > c) \leq \alpha$ und $P_0(R \geq c) \geq \alpha$ gilt. Ein solches Fraktil existiert, denn R nimmt den Wert ∞ nur auf $\{\varrho_0 = 0\}$ an, und diese Menge hat unter P_0 Wahrscheinlichkeit Null. Mit $P_0(R > c) \leq \alpha$ folgt

$$0 \leq \alpha - P_0(R > c) \leq P_0(R \geq c) - P_0(R > c) = P_0(R = c).$$

Nun unterscheiden wir zwei Fälle. Im ersten Fall sei $P_0(R = c) = 0$. Dann ist $\alpha = P_0(R > c)$ und somit ist

$$\varphi = 1_{\{R>c\}}$$

ein Neyman-Pearson-Test mit $\mathbb{E}_0(\varphi) = \alpha$. Im zweiten Fall sei $P_0(R = c) > 0$. Dann setzen wir

$$\gamma := \frac{\alpha - P_0(R > c)}{P_0(R = c)} \quad \in [0, 1].$$

Betrachten wir nun

$$\varphi(x) := \begin{cases} 1\,, & \text{falls } R(x) > c, \\ \gamma\,, & \text{falls } R(x) = c, \\ 0\,, & \text{falls } R(x) < c, \end{cases}$$

so ist

$$\mathbb{E}_0(\varphi) = P_0(R > c) + \gamma P_0(R = c) = \alpha$$

nach Definition von γ. Damit ist Teil (i) bewiesen. Für Teil (ii) nehmen wir an, dass φ ein Neyman-Pearson-Test mit $\mathbb{E}_0(\varphi) = \alpha$ und Schwellenwert c ist. Sei ferner ψ ein beliebiger Test zum Niveau α. Es gilt im Fall von Dichtefunktionen

$$\mathbb{E}_1(\varphi) - \mathbb{E}_1(\psi) = \int_{\mathcal{X}} (\varphi(x) - \psi(x))\varrho_1(x)dx.$$

Im diskreten Fall müssen wir das Integral durch eine Summe ersetzen. Ist $\varphi(x) > \psi(x)$, so ist $\varphi(x) > 0$, also $R(x) \geq c$, also $\varrho_1(x) \geq c\varrho_0(x)$. Ist $\varphi(x) < \psi(x)$, so ist $\varphi(x) < 1$, also $\varrho_1(x) \leq c\varrho_0(x)$. Somit ist

$$h(x) := (\varphi(x) - \psi(x))\varrho_1(x) \geq c(\varphi(x) - \psi(x))\varrho_0(x) =: cg(x).$$

Integration bzw. Summation über x liefert

$$\begin{aligned}\mathbb{E}_1(\varphi) - \mathbb{E}_1(\psi) &= \int_{\mathcal{X}} h(x)dx \geq c \int_{\mathcal{X}} g(x)dx \\ &= c(\mathbb{E}_0(\varphi) - \mathbb{E}_0(\psi)) \\ &= c(\alpha - \mathbb{E}_0(\psi)) \geq 0,\end{aligned}$$

denn ψ hat Niveau α. Also ist φ ein bester Test zu α, wie behauptet. Die Rückrichtung in Teil (ii) beweisen wir hier nicht. □

Ein Neyman-Pearson-Test ist also optimal. Wie groß ist seine Macht? Wir teilen an dieser Stelle mit, dass aufgrund eines Resultats von Stein aus dem Jahre 1952 bekannt ist, dass die Macht eines Neyman-Pearson-Tests mit wachsendem Stichprobenumfang mit exponentieller Geschwindigkeit gegen 1 strebt. Also ist auch in diesem Sinne ein Neyman-Pearson-Test gut. Beim Resultat von Stein spielt übrigens die relative Entropie der beiden Wahrscheinlichkeitsmaße P_0 und P_1 eine entscheidende Rolle: Je größer die relative Entropie zwischen den beiden Maßen ist, desto schneller wächst die Macht des optimalen Tests von P_0 gegen P_1 mit der Anzahl der Beobachtungen. Die relative Entropie hat damit auch in der mathematischen Statistik eine wichtige Interpretation. Sie gilt hier als ein Maß für die statistische Unterscheidbarkeit zweier Wahrscheinlichkeitsmaße.

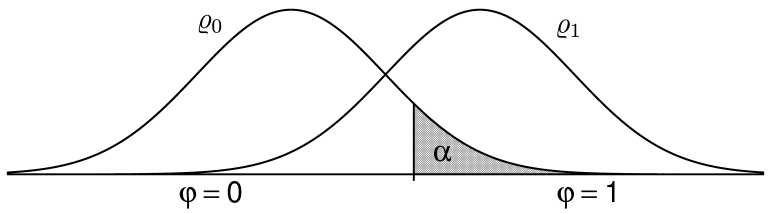

Abb. 17.2: Zur Konstruktion von Neyman-Pearson-Tests

Wir betrachten ein erstes Beispiel:

17.2.2 Beispiel: Es sei $\mathcal{X} = \mathbb{R}$, P_0 eine Normalverteilung zu den Parametern μ_0 und σ^2 sowie P_1 eine Normalverteilung zu den Parametern μ_1 und σ^2. Es sei $\mu_0 < \mu_1$ und $\sigma^2 > 0$. Auf der Grundlage von n Beobachtungen soll nun die Nullhypothese $H_0 : \mu = \mu_0$ gegen die Alternative $H_1 : \mu = \mu_1$ getestet werden. Wir nehmen an, dass die n Beobachtungen unabhängig realisiert seien. Dann können wir den

Likelihood-Quotienten berechnen. Es gilt mit Gleichung (16.1) in Beispiel 16.2.8

$$\begin{aligned} R_n = R_n(X) &= \exp\Big[-\frac{1}{2\sigma^2}\sum_{i=1}^n \Big((X_i-\mu_1)^2-(X_i-\mu_0)^2\Big)\Big] \\ &= \exp\Big[-\frac{n}{2\sigma^2}\Big(2(\mu_0-\mu_1)M_n(X)+\mu_1^2-\mu_0^2\Big)\Big] \end{aligned}$$

mit dem Stichprobenmittel $M_n(X) := \frac{1}{n}\sum_{i=1}^n X_i$. Wir wählen den Neyman-Pearson-Test $\varphi_n := 1_{\{M_n(X)>b_n\}}$, mit b_n, sodass

$$\alpha = \mathbb{E}_0(\varphi_n) = P_0(M_n(X) > b_n).$$

Nun machen wir Gebrauch von der Annahme, dass unter P_0 alle X_i unabhängig und normalverteilt sind zu den Parametern μ_0 und $\sigma^2 > 0$. Damit können wir auch die Verteilung von $M_n(X)$ ausrechnen. Satz 17.2.4 besagt, dass $M_n(X)$ dann ebenfalls normalverteilt ist zu den Parametern μ_0 und σ^2/n. Damit erhalten wir

$$\alpha = P_0(M_n(X) > b_n) = 1 - \Phi\Big(\frac{b_n-\mu_0}{\sqrt{\sigma^2/n}}\Big).$$

Dies ist äquivalent zu

$$\Phi\Big(\frac{b_n-\mu_0}{\sqrt{\sigma^2/n}}\Big) = 1-\alpha$$

und das ist wiederum äquivalent zur Wahl

$$b_n = \mu_0 + \Phi^{-1}(1-\alpha)\sqrt{\frac{\sigma^2}{n}}.$$

Zu vorgegebener Irrtumswahrscheinlichkeit α, Stichprobengröße n sowie bekannter Varianz σ^2 können wir somit den Ablehnungsbereich dieses Tests ausrechnen. Der Test ist ein bester Test zum Niveau α.

17.2.3 Aufgabe: Die Zufallsgröße X sei Poisson-verteilt mit Parameter $\lambda > 0$. Geben Sie den Neyman-Pearson-Test für $H_0 : \lambda = 2$ gegen $H_1 : \lambda = \frac{1}{2}$ zum Niveau $\alpha = 0.2$ an.

In Kapitel 14 haben wir in Satz 14.2.13 die Verteilung der Summe zweier Poisson-verteilter, unabhängiger Zufallsgrößen bestimmt. Unter Annahme der Unabhängigkeit ist die Summe wiederum Poisson-verteilt. Wir können für zwei unabhängige, normalverteilte Zufallsgrößen die gleiche Beobachtung machen. Da wir dies im wahrscheinlichkeitstheoretischen Teil des Kurses nicht benötigten, stellen wir erst jetzt das folgende Resultat bereit:

17.2.4 Satz: Es seien X_i, $1 \le i \le n$, unabhängige und normalverteilte Zufallsgrößen mit Erwartungswerten μ_i und Varianzen σ_i^2. Dann ist $\sum_{i=1}^n X_i$ normalverteilt mit Erwartungswert $\sum_{i=1}^n \mu_i$ und Varianz $\sum_{i=1}^n \sigma_i^2$.

Als Vorbereitung für den Beweis von Satz 17.2.4 wollen wir die Dichte von $X+Y$ berechnen, wenn X und Y unabhängig und ihre Verteilungen durch die Dichten f und g gegeben sind. Wir wollen $P(X+Y \le a)$ für alle $a \in \mathbb{R}$ bestimmen. Mit $C_a := \{(x,y) \in \mathbb{R}^2 : x+y \le a\}$ können wir dies als $P((X,Y) \in C_a)$ schreiben. Der Vektor (X,Y) hat nun nach Satz 10.3.18 die Produktdichte $f\,g$, also folgt

$$P(X+Y \le a) = \int_{C_a} f(x)g(y)\,dx\,dy = \int_{-\infty}^{a}\int_{-\infty}^{\infty} f(u-v)g(v)\,dv\,du. \tag{17.2}$$

17.2.5 Definition: Seien f und g Lebesgue-integrierbare Funktionen auf $\mathbb{R}$. Dann heißt die Funktion

$$(f \star g)(x) := \int_{-\infty}^{\infty} f(x-y)g(y)\,dy, \quad x \in \mathbb{R} \tag{17.3}$$

die *Faltung* von f und g.

Ohne Beweis geben wir an, dass die Faltung $f \star g$ wieder eine Lebesgue-integrierbare Funktionen auf $\mathbb{R}$ definiert. Im Falle von Wahrscheinlichkeitsdichten f ud g definiert $f \star g$ wieder eine Wahrscheinlichkeitsdichte.

Gleichung (17.2) lässt sich nun in der Form

$$P(X+Y \le a) = \int_{-\infty}^{a} (f \star g)(x)\,dx \tag{17.4}$$

schreiben. Mit anderen Worten, die Zufallsvariable $X+Y$ hat die Dichte $f \star g$.

Beweis von Satz 17.2.4: Sind $X_1, \ldots, X_n$ unabhängig, so sind $X_1 + \cdots + X_{n-1}$ und X_n ebenfalls unabhängig (warum?). Der Satz folgt also mit Induktion nach n aus dem Fall $n = 2$. Die Zufallsgrößen $Y_1 := X_1 - \mu_1$ und $Y_2 := X_2 - \mu_2$ sind normalverteilt mit Erwartungswert 0. Nach (17.3) ist die Dichte h von $Y_1 + Y_2$ gegeben durch

$$h(x) = \frac{1}{2\pi\sigma_1\sigma_2}\int_{-\infty}^{\infty} \exp\left(-\frac{1}{2}\left[\frac{(x-y)^2}{\sigma_1^2} + \frac{y^2}{\sigma_2^2}\right]\right) dy$$

für alle $x \in \mathbb{R}$. Schreibt man den Term in der eckigen Klammer (durch quadratisches Ergänzen) in der Form

$$\frac{(x-y)^2}{\sigma_1^2} + \frac{y^2}{\sigma_2^2} = \left(\frac{\sqrt{\sigma_1^2+\sigma_2^2}}{\sigma_1\sigma_2}y - \frac{\sigma_2}{\sigma_1\sqrt{\sigma_1^2+\sigma_2^2}}x\right)^2 + \frac{x^2}{\sigma_1^2+\sigma_2^2}$$

und benutzt die Transformation

$$z(y) := \frac{\sqrt{\sigma_1^2+\sigma_2^2}}{\sigma_1\sigma_2}y - \frac{\sigma_2}{\sigma_1\sqrt{\sigma_1^2+\sigma_2^2}}x,$$

so ergibt sich

$$h(x) = \frac{1}{\sqrt{2\pi(\sigma_1^2+\sigma_2^2)}}\exp\left(-\frac{1}{2}\frac{x^2}{\sigma_1^2+\sigma_2^2}\right)\int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi}}e^{-z^2/2}\,dz.$$

Also ist Y_1+Y_2 normalverteilt mit Erwartungswert 0 und Varianz $\sigma_1^2+\sigma_2^2$. Demzufolge ist X_1+X_2 normalverteilt mit Erwartungswert $\mu_1+\mu_2$ und Varianz $\sigma_1^2+\sigma_2^2$. □

Im Falle einfacher Nullhypothesen und einfacher Alternativen haben wir beste Tests zum Niveau α kennengelernt. Wir suchen nun beste Tests bei zusammengesetzten Nullhypothesen und Alternativen. Mithilfe eines Monotoniearguments kann man sich Satz 17.2.1 zunutze machen. Wir diskutieren dies zunächst am Beispiel des Bananenhändlers.

17.2.6 Beispiel: Es sei $\mathcal{X} = \{0,\dots,n\}$, $\Theta = \{0,\dots,N\}$; $P_\vartheta = h(\cdot;n,\vartheta,N-\vartheta)$, $\vartheta\in\Theta$. Zu einem vorgegebenen Niveau α wollen wir die Nullhypothese

$$\Theta_0 = \{0,\dots,\vartheta_0\}$$

gegen die Alternative

$$\Theta_1 = \{\vartheta_0+1,\dots,N\}$$

für ein fest gewähltes ϑ_0 testen. Dabei gehen wir ganz naiv vor und erinnern uns, wie wir einen Alternativtest gemäß der Konstruktion im Beweis von Satz 17.2.1 erhalten haben: Zu $\vartheta_1\in\Theta_1$ wählen wir einen Neyman-Pearson-Test φ zum Niveau α von $\{\vartheta_0\}$ gegen $\{\vartheta_1\}$ mit

$$\mathbb{E}_{\vartheta_0}(\varphi) = P_{\vartheta_0}(\{c+1,\dots,n\}) + \gamma P_{\vartheta_0}(\{c\}) = \alpha.$$

c und γ hängen nur von ϑ_0 ab. Interessant ist nun, dass der so bestimmte Test φ ein gleichmäßig bester Test von Θ_0 gegen Θ_1 zum Niveau α ist. Dies ist nicht ganz so einfach einzusehen. Wir verwenden im Wesentlichen die folgende Monotonieeigenschaft der Funktion ϱ_ϑ. Wir betrachten zu $\vartheta_2>\vartheta_1$

$$\frac{\varrho_{\vartheta_2}(x)}{\varrho_{\vartheta_1}(x)} =: R_{\vartheta_1,\vartheta_2}(x).$$

Dieser Ausdruck ist wachsend in x, denn

$$R_{\vartheta_1,\vartheta_2}(x) = \prod_{k=\vartheta_1}^{\vartheta_2-1} \frac{\varrho_{k+1}(x)}{\varrho_k(x)} = \prod_{k=\vartheta_1}^{\vartheta_2-1} \frac{(k+1)(N-k-n+x)}{(N-k)(k+1-x)}, \quad x \le \vartheta.$$

und $R_{\vartheta_1,\vartheta_2}(x) = \infty$ für $x > \vartheta_1$. Jeder der Quotienten ist in x streng wachsend (Beweis mittels Differentiation). Nun sei $\tilde{c} := R_{\vartheta_1,\vartheta_2}(c)$. Dann gilt:

$$\begin{aligned} &\text{Ist} \quad R_{\vartheta_1,\vartheta_2}(x) > \tilde{c}, \quad \text{so ist } x > c, \text{ also } \varphi(x) = 1. \\ &\text{Ist} \quad R_{\vartheta_1,\vartheta_2}(x) < \tilde{c}, \quad \text{so ist } \varphi(x) = 0. \end{aligned}$$

Damit ist φ ein Neyman-Pearson-Test von $\{\vartheta_1\}$ gegen $\{\vartheta_2\}$. Für die Wahl $\vartheta_1 = \vartheta_0$ und ein beliebiges $\vartheta_2 > \vartheta_0$ folgt mit Satz 17.2.1: φ ist bester Test von ϑ_0 gegen *jedes* $\vartheta' \in \Theta_1$ zum Niveau α, also gleichmäßig bester Test von ϑ_0 gegen die Alternative Θ_1. Es bleibt somit zu zeigen, dass φ als Test von Θ_0 gegen Θ_1 das Niveau α hat, also $G_\varphi(\vartheta) \le \alpha$ für alle $\vartheta \in \Theta_0$ gilt. Nun wissen wir, dass $G_\varphi(\vartheta_0) = \alpha$ gilt. Also zeigen wir, dass G_φ monoton wachsend ist. Es sei $\vartheta_1 < \vartheta_2$. Wie wir gerade gesehen haben ist φ ein Neyman-Pearson-Test von ϑ_1 gegen ϑ_2, also mit Satz 17.2.1 ein bester Test zum Niveau $\beta := G_\varphi(\vartheta_1)$. Insbesondere ist er besser als der konstante Test $\psi = \beta$. Damit folgt

$$G_\varphi(\vartheta_2) \ge G_\psi(\vartheta_2) = \beta = G_\varphi(\vartheta_1).$$

Das war unsere Behauptung. Interessant ist, dass ein einfaches Testverfahren hier bereits optimal ist.

17.2.7 Aufgabe: Bestimmen Sie c und γ für $n = 50$, $N = 10000$, $\vartheta_0 = 500$ und $\alpha = 0.0025$.

Die obige Diskussion verwendet wesentlich die Monotonie des Dichtequotienten $R_{\vartheta_1,\vartheta_2}$.

17.2.8 Definition: Ein statistisches Standardmodell $(\mathcal{X}, \mathcal{F}, P_\vartheta : \vartheta \in \Theta)$ mit $\Theta \subseteq \mathbb{R}$ hat *wachsende Likelihood-Quotienten (wachsende Dichtequotienten)* bezüglich einer Statistik $T : \mathcal{X} \to \mathbb{R}$, wenn $\forall \vartheta < \vartheta'$ $R_{\vartheta,\vartheta'} := \frac{\varrho_{\vartheta'}}{\varrho_\vartheta}$ eine wachsende Funktion von T ist, also $R_{\vartheta',\vartheta} = f_{\vartheta',\vartheta} \circ T$ für eine wachsende Funktion $f_{\vartheta',\vartheta} : \mathbb{R} \to [0, \infty)$ gilt.

17.2.9 Satz: (einseitige Tests bei monotonen Likelihood-Quotienten)
Sei $(\mathcal{X}, \mathcal{F}, P_\vartheta : \vartheta \in \Theta)$ mit $\Theta \subseteq \mathbb{R}$ ein statistisches Standardmodell mit wachsenden

Likelihood-Quotienten bezüglich T, $\vartheta_0 \in \Theta$ und $0 < \alpha < 1$. Dann existiert ein gleichmäßig bester Test φ zum Niveau α für $H_0 : \vartheta \leq \vartheta_0$ gegen $H_1 : \vartheta > \vartheta_0$. Er hat die Gestalt

$$\varphi(x) = \begin{cases} 1\,, & \text{falls } T(x) > c, \\ \gamma\,, & \text{falls } T(x) = c, \\ 0\,, & \text{falls } T(x) < c, \end{cases}$$

wobei c, γ aus $G_\varphi(\vartheta_0) = \alpha$ gegeben sind. Die Gütefunktion G_φ ist monoton wachsend.

Beweis: Alle Argumente der Diskussion des Beispiels unseres Bananenhändlers übertragen sich. Wir müssen nur x durch $T(x)$ ersetzen. Wir bestimmen c und γ wieder mittels

$$G_\varphi(\vartheta_0) = P_{\vartheta_0}(T > c) + \gamma P_{\vartheta_0}(T = c) = \alpha.$$

□

17.2.10 Aufgabe: Zeigen Sie, dass im Binomialmodell der Likelihood-Quotient bezüglich des Maximum-Likelihood-Schätzers T aus Beispiel 16.2.5 die Bedingungen von Satz 17.2.9 erfüllt.

Wir diskutieren abschließend zwei Testverfahren im Gauss'schen Modell, siehe Beispiel 16.2.8.

17.2.11 Beispiel: (einseitiger Gauss-Test; bekannte Varianz)
Bei den n unabhängigen Beobachtungen im Gauss'schen Modell nehmen wir an, dass die Varianz $\sigma^2 > 0$ bekannt ist. Unser statistisches Modell besteht jetzt aus $\mathcal{X} = \mathbb{R}^n$, der zugehörigen Borel'schen σ-Algebra sowie der Familie der Produktdichten

$$\left(\prod_{i=1}^n \varphi(x_i; \mu, \sigma^2)\right)_{\mu \in \mathbb{R}}$$

(siehe (16.1)). Wir wollen nun die Nullhypothese $H_0 : \mu \leq \mu_0$ gegen die Alternative $H_1 : \mu > \mu_0$ zu einem vorgegebenen $\mu_0 \in \mathbb{R}$ testen. Wir zeigen, dass die zugehörigen Likelihood-Quotienten bezüglich der Mittelwertschätzung $M_n(x)$ wachsend sind. Es gilt:

$$\begin{aligned} \varrho_\mu(x) = \varrho(x, \mu) &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right) \\ &= \exp\left(n \frac{\mu}{\sigma^2} M_n(x) - n\Big(\frac{\mu^2}{2\sigma^2} + \frac{1}{2} \ln(2\pi\sigma^2)\Big)\right) \prod_{i=1}^n \exp\Big(-\frac{x_i^2}{2\sigma^2}\Big). \end{aligned}$$

Somit ist die Monotonie gezeigt: Für $\mu_1 \leq \mu_2$ ist

$$R_{\mu_1,\mu_2}(x) = \frac{\varrho_{\mu_2}(x)}{\varrho_{\mu_1}(x)} = \exp\left(\frac{n}{\sigma^2}(\mu_2 - \mu_1)M_n(x)\right) \exp\left(\frac{n}{2\sigma^2}(\mu_1^2 - \mu_2^2)\right),$$

und dies ist eine in $M_n(x)$ monoton wachsende Funktion, da $\mu_2 - \mu_1 \geq 0$. Wir können nun Satz 17.2.9 anwenden und erhalten einen besten Test für das obige Testproblem zum Niveau α mit dem Ablehnungsbereich

$$\left\{M_n(X) > \mu_0 + \sqrt{\frac{\sigma^2}{n}}\Phi^{-1}(1-\alpha)\right\},$$

denn genau diesen Ablehnungsbereich haben wir in Beispiel 17.2.2 hergeleitet. Der hier entwickelte Test heißt *einseitiger* GAUSS-*Test*, da die Nullhypothese eine Seite von μ_0 beschreibt. Im Gegensatz dazu lässt die Nullhypothese $\mu = \mu_0$ zwei Seiten für die Alternative. Ein Test $H_0 : \mu = \mu_0$ gegen die Alternative $\mu \neq \mu_0$ wird ein zweiseitiger Test genannt. Diesen untersuchen wir nicht näher. Auch wenn die Annahme, die Varianz unserer Beobachtungsdaten sei bekannt, nicht unbedingt realistisch ist, haben wir mit relativ geringem Aufwand einen besten Test konstruiert.

17.2.12 Beispiel: (einseitiger Chiquadrat-Test; bekannter Erwartungswert)
Bei den n unabhängigen Beobachtungen im GAUSS'schen Modell nehmen wir an, dass der Erwartungswert $\mu \in \mathbb{R}$ bekannt ist. Unser statistisches Modell besteht jetzt aus $\mathcal{X} = \mathbb{R}^n$, der zugehörigen BOREL'schen σ-Algebra sowie der Familie der Produktdichten

$$\left(\prod_{i=1}^n \varphi(x_i; \mu, \sigma^2)\right)_{\sigma^2>0}$$

(siehe (16.1)). Nun soll die Nullhypothese $H_0 : \sigma^2 \leq \sigma_0^2$ gegen die Alternative $H_1 : \sigma^2 > \sigma_0^2$ getestet werden. Wir zeigen, dass die zugehörigen Likelihood-Quotienten bezüglich des Schätzers

$$V_n(x) = \sum_{i=1}^n (x_i - \mu)^2$$

wachsend ist. Es gilt:

$$\begin{aligned}\varrho_{\sigma^2}(x) = \varrho(x, \sigma^2) &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^n (x_i - \mu)^2\right) \\ &= \exp\left(-\frac{1}{2\sigma^2}V_n(x) - \frac{n}{2}\ln(2\pi\sigma^2)\right).\end{aligned}$$

Somit ist die Monotonie gezeigt, denn für $\sigma_1^2 \le \sigma_2^2$ ist

$$R_{\sigma_1^2,\sigma_2^2}(x) = \frac{\varrho_{\sigma_2^2}(x)}{\varrho_{\sigma_1^2}(x)} = \exp\left(V_n(x)\left(\frac{1}{2\sigma_1^2} - \frac{1}{2\sigma_2^2}\right)\right) \exp\left(\frac{n}{2}\Big(\ln(2\pi\sigma_1^2) - \ln(2\pi\sigma_2^2)\Big)\right),$$

und dies ist eine monoton wachsende Funktion in $V_n(x)$, da $\frac{1}{2\sigma_1^2} - \frac{1}{2\sigma_2^2} \ge 0$. Wir können daher erneut Satz 17.2.9 anwenden. Nun müssen wir die Gleichung

$$\alpha = G_\varphi(\sigma_0^2) = P_{\sigma_0^2}\Big(V_n(X) > c\Big) + \gamma P_{\sigma_0^2}\Big(V_n(X) = c\Big)$$

in c und γ lösen. Bezüglich $P_{\sigma_0^2}$ gilt $P_{\sigma_0^2}\Big(V_n(X) = c\Big) = 0$ für jedes c, denn mit dem folgenden Satz 17.2.14 hat $V_n(X)$ eine Verteilung mit einer Dichte (siehe Seite 270). Somit können wir $\gamma = 0$ setzen und müssen

$$\alpha = P_{\sigma_0^2}\left(\sum_{i=1}^n (X_i - \mu)^2 > c\right)$$

nach c auflösen. Die Zufallsgröße $X_i - \mu$ ist unter $P_{\sigma_0^2}$ normalverteilt mit Erwartungswert Null und Varianz σ_0^2. Weiter ist dann die Zufallsgröße $\frac{X_i-\mu}{\sigma_0}$ normalverteilt mit Erwartungswert Null und Varianz Eins. Mit

$$\{V_n(X) > c\} = \left\{\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma_0}\right)^2 > \frac{c}{\sigma_0^2}\right\}$$

können wir also die Wahrscheinlichkeit $P_{\sigma_0^2}\Big(V_n(X) > c\Big)$ ausrechnen, sobald wir die Verteilung einer Summe von den Quadraten von n unabhängigen standardnormalverteilten Zufallsgrößen kennen. Diese Verteilung ist bekannt und wir können die Dichte angeben. Das ist der Inhalt des Satzes 17.2.14. Wir nennen die Dichte χ_n^2. Zusammenfassend folgt:

$$G_\varphi(\sigma_0^2) = \int_{\frac{c}{\sigma_0^2}}^\infty \chi_n^2(x)\,dx = \alpha.$$

Bezeichnen wir nun mit $\chi_{n,\alpha}^2$ denjenigen Wert y, für den $\int_y^\infty \chi_n^2(x)\,dx = \alpha$ gilt (das sogenannte α-Fraktil der χ_n^2-Verteilung), so ist $\frac{c}{\sigma_0^2} = \chi_{n,\alpha}^2$. Also ist

$$\left\{\sum_{i=1}^n (X_i - \mu)^2 > \sigma_0^2\,\chi_{n,\alpha}^2\right\}$$

der Ablehnungsbereich des besten Tests φ zu gegebenem Niveau α. Der Test heißt *einseitiger Chiquadrat-Test* (χ^2-Test).

17.2.13 Aufgabe: Bei der Messung der Deklinationskoordinate eines Lichtpunktes am Nachthimmel wurden die folgenden Werte ermittelt:

$34°\,38'$	$34°\,35'$	$34°\,16'$	$34°\,31'$
$34°\,25'$	$34°\,17'$	$34°\,29'$	$34°\,20'$
$34°\,31'$	$34°\,38'$	$34°\,37'$	$34°\,38'$
$34°\,45'$	$34°\,03'$	$34°\,40'$	$34°\,39'$

Wir nehmen an, dass die Werte Realisierungen von unabhängigen, normalverteilten Zufallsvariablen mit gleichem Erwartungswert μ und gleicher Varianz σ^2 sind. Testen Sie die Nullhypothese $H_0 : \mu \leq 34°20'$ gegen die Alternative $H_1 : \mu > 34°20'$ zum Niveau $\alpha = 0.025$. Testen Sie weiter die Nullhypothese $H_0 : \sigma \leq 10'$ gegen die Alternative $H_1 : \sigma > 10'$ zum Niveau $\alpha = 0.025$.

17.2.14 Satz: Die Verteilung der Summe der Quadrate von n unabhängigen $N(0,1)$-verteilten Zufallsgrößen nennt man eine χ^2_n-Verteilung (χ^2-Verteilung mit n Freiheitsgraden). Ihre Dichte ist gegeben durch

$$g_n(x) := \frac{1}{2^{n/2}\Gamma(n/2)}\, x^{(n/2)-1}\, e^{-x/2}, \quad x > 0,$$

wobei Γ die Gammafunktion aus (14.5) ist. Der Erwartungswert einer χ^2_n-verteilten Zufallsgröße ist n, die Varianz $2n$.

Beweis: Wir erinnern an die Definition der *Gammaverteilung*, siehe 14.1.5. Sie hat die Dichte

$$\gamma_{\lambda,r}(x) = \frac{\lambda^r}{\Gamma(r)} x^{r-1} e^{-\lambda x}, \quad x \geq 0.$$

für $\lambda, r > 0$. Wir bestimmen nun die Dichte der Summe zweier unabhängiger, gammaverteilter Zufallsgrößen. Die eine habe die Dichte $\gamma_{1,r}$, die andere die Dichte $\gamma_{1,s}$. Da beide Dichten auf der negativen Halbachse gleich Null sind, tragen in der Dichte der Summe gemäß (17.3), Seite 467, nur die Werte x, y mit $y \geq 0$ und $x - y \geq 0$ zum Wert des Integrals in (17.3) bei, also hat die Summe die Dichte

$$\frac{1}{\Gamma(r)\Gamma(s)} \int_0^x (x-y)^{s-1} e^{-(x-y)} y^{r-1} e^{-y}\, dy.$$

Nun substituieren wir $y = x\,t$ und erhalten

$$= \frac{e^{-x}}{\Gamma(r)\Gamma(s)} \int_0^1 x^{s-1}(1-t)^{s-1} x^{r-1} t^{r-1} x\, dt = \frac{\Gamma(r+s)}{\Gamma(r)\Gamma(s)} \gamma_{1,r+s}(x) \int_0^1 (1-t)^{s-1} t^{r-1}\, dt.$$

Das rechts stehende Integral bezeichnet man als Betafunktion $B(r,s)$. Da die Faltungsdichte eine Dichte ist, muss

$$B(r,s) = \frac{\Gamma(r)\Gamma(s)}{\Gamma(r+s)}$$

gelten. Die Faltungsdichte ist also die Gammadichte $\gamma_{1,r+s}$. Es gilt allgemeiner, dass die Faltungsdichte einer $\gamma_{\lambda,r}$- und einer $\gamma_{\lambda,s}$-Dichte eine $\gamma_{\lambda,r+s}$-Dichte ist. Dies ist eine Übung. Nun ist die Summe von n unabhängigen, $\gamma_{\frac{1}{2},\frac{1}{2}}$-verteilten Zufallsgrößen mittels vollständiger Induktion verteilt mit einer $\gamma_{\frac{1}{2},\frac{n}{2}}$-Dichte. Diese Dichte ist gerade die Dichte g_n. Wir haben den Satz bewiesen, wenn wir nun noch zeigen können, dass das Quadrat einer standard-normalverteilten Zufallsgröße die Dichte $\gamma_{\frac{1}{2},\frac{1}{2}}$ hat. Es gilt allgemein: Ist $X \geq 0$ eine Zufallsgröße mit Dichte f, so gilt

$$P(X^2 \leq y) = \int_0^{\sqrt{y}} f(x)\,dx = \int_0^y f(\sqrt{z})\frac{1}{2\sqrt{z}}\,dz,$$

also hat X^2 die Dichte $\frac{f(\sqrt{y})}{2\sqrt{y}}$. Hat X positive und negative Werte, so ist

$$P(X^2 \leq y) = P(X^2 \leq y, X \geq 0) + P(X^2 \leq y, X < 0)$$

und man erhält die Dichte

$$\frac{f(\sqrt{y})}{2\sqrt{y}} + \frac{f(-\sqrt{y})}{2\sqrt{y}}.$$

Demnach hat das Quadrat einer standard-normalverteilten Zufallsgröße die Dichte

$$\frac{\varphi(\sqrt{x};0,1)}{\sqrt{x}} = \frac{1}{\sqrt{2\pi}}e^{-x/2}x^{-1/2},$$

und dies ist bis auf die Normierungskonstante die $\gamma_{\frac{1}{2},\frac{1}{2}}$-Dichte. Da beides Dichten sein müssen, müssen aber auch die Normierungskonstanten übereinstimmen, also $\Gamma(\frac{1}{2}) = \sqrt{\pi}$. □

17.2.15 Aufgabe: Zeigen Sie: Hat die Zufallsgröße X die Dichte $g(x)$, so hat die Zufallsgröße X/α mit $\alpha > 0$ die Dichte $\alpha g(\alpha x)$. Zeigen Sie weiter: Ist X gammaverteilt zu den Parametern 1 und r, so ist X/λ mit $\lambda > 0$ gammaverteilt zu den Parametern λ und r. Zeigen Sie, dass die Faltungsdichte der Dichten $\gamma_{\lambda,r}$ und $\gamma_{\lambda,s}$ die Gammadichte $\gamma_{\lambda,r+s}$ ist mit $\lambda, r, s > 0$.

Im Gauss'schen Modell haben wir jeweils einen Parameter als bekannt vorausgesetzt und beste einseitige Tests für den anderen Parameter hergeleitet. Es gibt

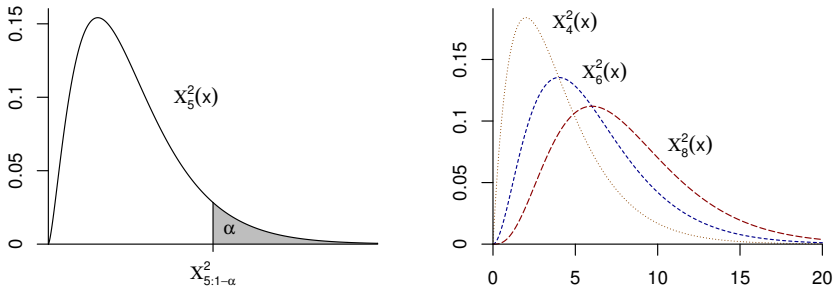

Abb. 17.3: Dichten von χ^2-Verteilungen

auch Tests für den sogenannten zweiparametrigen Fall, in dem sowohl der Erwartungswert als auch die Varianz der Normalverteilung unbekannt sind. Man geht dabei den naiven Weg, dass der Parameter, der nicht getestet werden soll, durch eine Schätzung ersetzt wird. Dieser Weg steckt allerdings voller mathematischer Herausforderungen. Es ist zum einen schwerer, die Verteilungsdichten der neuen Testgrößen zu ermitteln. Man wird zum Chiquadrat-Test für die Varianz und zum t-Test für den Erwartungswert geführt. Darüberhinaus gelingt es nicht ohne weiteres, beste Test zu entwickeln. Bei manchen Nullhypothesen und Alternativen findet man aber in der Teilklasse aller unverfälschten Tests den Besten.

Lösungen der Aufgaben

Lösungen der Aufgaben in 17.1

Aufgabe 17.1.5

Wenn $n = 40$ ist, betrachtet man $P_\vartheta = b(\cdot, 40, \vartheta)$. Man wählt wieder $\alpha = 0.05$ und sucht ein geeignetes c für $\varphi = 1_{\{c,\ldots,40\}}$. Hier wählt man $c = 26$, denn

$$\sum_{k=26}^{40} b(k; 40, 1/2) \approx 0.040 \leq 0.05 < 0.077 \approx \sum_{k=25}^{40} b(k; 40, 1/2)\,.$$

ϑ	0.5	0.6	0.7	0.8	0.9
$\mathbb{E}_\vartheta(\varphi)$	0.04035	0.3174	0.8074	0.9921	0.999...

In diesem Fall ist das effektive Niveau sogar nur 0.04. Ein Testergebnis scheint dann noch genauer zu sein.

Aufgabe 17.1.8

Die Ungleichung $2\Phi\left(-\frac{c}{\sqrt{250}}\right) \leq 0.05$ gilt für $c \geq 31$. Θ_0 wird angenommen, wenn zwischen 469 und 531 Einsen beobachtet werden und sonst verworfen. Bei 550 Einsen würde man die Nullhypothese verwerfen.

Im Fall $\alpha = 0.001$ erhält man die Ungleichung $2\Phi\left(-\frac{c}{\sqrt{250}}\right) \leq 0.001$. In diesem Fall ist $c \geq 53$ und man nimmt die Nullhypothese im Intervall $[447, 553]$ an. Bei 550 beobachteten Einsen würde man hier die Nullhypothese annehmen.

Aufgabe 17.1.10

Bei einer Sicherheit von 98% und einer Genauigkeit von 1% ergibt sich

$$P_\vartheta\left(\left|\frac{X}{n} - \vartheta\right| \leq 0.01\right).$$

Man sucht ein a, sodass $2\Phi(a) - 1 = 0.98$ ist. Dies liefert $a \approx 2.33$. Damit folgt

$$2.33\sqrt{\frac{\vartheta(1-\vartheta)}{n}} \leq 0.01$$

und dies ist äquivalent zu $n \geq 54289\vartheta(1-\vartheta)$. Mit $\vartheta(1-\vartheta) \leq \frac{1}{4}$ folgt $n \geq 13573$. Falls $\vartheta \leq 0.3$ ist, ist $\vartheta(1-\vartheta) \leq 0.21$ und damit benötigt man nur $n \geq 11401$. Man kann also die Stichprobe um 2172 Personen verkleinern.

Lösungen der Aufgaben in 17.2

Aufgabe 17.2.3

Es gilt

$$R(k) = \frac{\varrho_1(k)}{\varrho_0(k)} = e^{-\frac{1}{2}} \frac{\left(\frac{1}{2}\right)^k}{e^{-2}2^k} = e^{\frac{3}{2}}\, 2^{-2k}.$$

Dies Funktion ist offensichtlich in k monoton fallend. Ein nicht randomisierter Neyman-Pearson-Test φ hat einen Verwerfungsbereich der Form $R = \{0, ..., t\}$. Wenn $t = 0$ ist, dann ist $\mathbb{E}_0(\varphi) = e^{-2} \approx 0.135$. Wenn $t = 1$ ist, dann ist $\mathbb{E}_0(\varphi) > 0.2$. Die einzige Lösung ist daher $R = \{0\}$.

Aufgabe 17.2.7

Mithilfe eines Computer-Algebra-Systems wie *Mathematica* oder *Maple* berechnet man die Werte $c = 6$ und $\gamma = 0.52$. Da N groß und sehr viel größer ist als n, kann man aber die hypergeometrische Verteilung durch die Binomialverteilung approximieren. Man bekommt dann ebenfalls $c = 6$ und ein leicht verändertes γ. Auch erscheint bei den gegebenen Werten für n, N und ϑ_0 eine Approximation der Binomialverteilung durch die Normalverteilung oder auch durch die Poisson-Verteilung angebracht. Wir vertiefen dies hier nicht.

Aufgabe 17.2.10

Wir zeigen, dass der Likelihood-Quotient bezüglich der Statistik $T_n(x) := \frac{x}{n}$ (siehe Beispiel 16.2.5) wachsend ist. Zunächst formen wir $\varrho_\vartheta(x)$ geeignet um. Es gilt

$$\begin{aligned} \varrho_\vartheta(x) &= \binom{n}{x} \vartheta^x (1-\vartheta)^{n-x} \\ &= \exp\left(n \ln\left(\frac{\vartheta}{1-\vartheta}\right) T_n(x) + n \ln(1-\vartheta)\right) \binom{n}{x}. \end{aligned}$$

Damit ist

$$R_{\vartheta_1,\vartheta_2}(x) := \frac{\varrho_{\vartheta_2}(x)}{\varrho_{\vartheta_1}(x)}$$

für $\vartheta_1 \leq \vartheta_2$ monoton wachsend in $T_n(x)$, denn

$$R_{\vartheta_1,\vartheta_2}(x) = \exp\left(n \ln\left(\frac{\vartheta_2}{\vartheta_1}\frac{1-\vartheta_1}{1-\vartheta_2}\right) T_n(x)\right)\left(\frac{1-\vartheta_2}{1-\vartheta_1}\right)^n,$$

und mit $\vartheta_1 \leq \vartheta_2$ ist

$$\left(\frac{\vartheta_2}{\vartheta_1}\frac{1-\vartheta_1}{1-\vartheta_2}\right) \geq 1.$$

Aufgabe 17.2.13

Wir testen zunächst die Hypothese bezüglich des Erwartungswertes μ mithilfe des einseitigen Gauss-Tests und nehmen dafür die Standardabweichung $\sigma = 10'$ als bekannt an. Man berechnet $M_n(x) = 34° + 30.125'$ sowie

$$\begin{aligned} \mu_0 + \frac{\sigma}{\sqrt{n}}\Phi^{-1}(1-\alpha) &= 34°20' + \left(\frac{10}{4} \cdot \Phi^{-1}(0.975)\right)' \\ = \quad 34°20' + \left(\frac{5}{2} \cdot 1.96\right)' &= 34° + 24.9'\,. \end{aligned}$$

Somit wird die Nullhypothese zum Niveau $\alpha = 0.025$ verworfen.

Nun testen wir die Hypothese über die Standardabweichung σ mithilfe des einseitigen Chiquadrat-Tests und nehmen dazu den Erwartungswert $\mu = 34°20'$ als bekannt an. Man berechnet $\sum_{i=1}^n (x_i - \mu)^2 = 3534$ Quadratminuten. Ferner ist das 0.025-Fraktil der χ^2_{16}-Verteilung gegeben durch den Wert 26.30. Diesen Wert entnimmt man einer Tabelle, die Werte der Verteilungsfunktion einer χ^2–Verteilung zum Freiheitsgrad 16 angibt. Man sieht hier, dass man für jeden Freiheitsgrad eine eigene Tabelle benötigt. Im Zeitalter der Computer berechne man alternativ mithilfe eines numerischen Integrationsverfahrens das jeweilige Integral. Nun gilt $\sigma_0^2 \cdot 26.30 = 2630$ Quadratminuten (min^2). Somit gilt

$$3534\ \text{min}^2 = \sum_{i=1}^n (x_i - \mu)^2 > \sigma_0^2 \cdot 26.30 = 2630\ \text{min}^2\,,$$

sodass wir auch diese Nullhypothese zum Niveau $\alpha = 0.025$ verwerfen können.

Aufgabe 17.2.15

Sei $z \in \mathbb{R}$ beliebig. Dann gilt für die Verteilungsfunktion von X/α im Punkt z:

$$\begin{aligned} P\left(\frac{X}{\alpha} \leq z\right) &= P(X \leq \alpha z) = \int_{-\infty}^{\alpha z} g(x)dx \\ &= \alpha \cdot \int_{-\infty}^{\alpha z} g\left(\alpha \cdot \frac{x}{\alpha}\right) \cdot \frac{1}{\alpha} dx \\ &= \alpha \int_{-\infty}^{z} g(\alpha y)dy = \int_{-\infty}^{z} \alpha g(\alpha y)dy \end{aligned}$$

Somit ist die Funktion $\mathbb{R} \ni y \mapsto \alpha g(\alpha y) \in \mathbb{R}$ eine Dichte von X/α.
Sei jetzt X gammaverteilt zu den Parametern λ und r. Dann hat X die Dichte

$$x \mapsto \gamma_{1,r}(x) = \frac{1}{\Gamma(r)} x^{r-1} e^{-x} 1_{(0,+\infty)}(x)\,.$$

Nach der soeben bewiesenen Aussage hat dann X/λ die Dichte

$$\begin{aligned} x \mapsto \lambda\gamma_{1,r}(\lambda x) &= \lambda \frac{1}{\Gamma(r)} (\lambda x)^{r-1} e^{-\lambda x} 1_{(0,+\infty)}(\lambda x) \\ &= \frac{\lambda^r}{\Gamma(r)} x^{r-1} e^{-\lambda x} 1_{(0,+\infty)}(x) = \gamma_{\lambda,r}(x)\,. \end{aligned}$$

Da dies ebenfalls eine Dichte der Gammaverteilung zu den Parametern λ und r ist, folgt die zweite Behauptung.
Nach (17.3) ist die Faltungsdichte h von $\gamma_{r,\lambda}$ und $\gamma_{s,\lambda}$ gegeben durch

$$\begin{aligned} h(x) &= \int_{-\infty}^{\infty} \gamma_{r,\lambda}(x-y)\gamma_{s,\lambda}(y)dy \\ &= \int_{-\infty}^{\infty} \frac{\lambda^r}{\Gamma(r)} (x-y)^{r-1} e^{-\lambda(x-y)} 1_{(0,+\infty)}(x-y) \cdot \frac{\lambda^s}{\Gamma(s)} y^{s-1} e^{-\lambda y} 1_{(0,+\infty)}(y)dy \\ &= \frac{\lambda^{r+s} e^{-\lambda x}}{\Gamma(r)\Gamma(s)} \int_0^x (x-y)^{r-1} y^{s-1} dy \cdot 1_{(0,+\infty)}(x) \\ &= \frac{\lambda^{r+s} e^{-\lambda x}}{\Gamma(r)\Gamma(s)} \int_0^x \left(1 - \frac{y}{x}\right)^{r-1} \left(\frac{y}{x}\right)^{s-1} \cdot \frac{1}{x} dy \cdot x^{r+s-1} \cdot 1_{(0,+\infty)}(x) \\ &= \frac{\lambda^{r+s} e^{-\lambda x} x^{r+s-1}}{\Gamma(r)\Gamma(s)} 1_{(0,+\infty)}(x) \int_0^1 (1-t)^{r-1} t^{s-1} dt \end{aligned}$$

$$
\begin{aligned}
&= \frac{\lambda^{r+s} e^{-\lambda x} x^{r+s-1}}{\Gamma(r)\Gamma(s)} 1_{(0,+\infty)}(x) B(r,s) \\
&= \frac{\lambda^{r+s}}{\Gamma(r+s)} e^{-\lambda x} x^{r+s-1} 1_{(0,+\infty)}(x) \,.
\end{aligned}
$$

Da dies eine Dichte der Gammaverteilung zu den Parametern λ und $r+s$ ist, folgt auch die letzte Behauptung.